21世纪液压气动使用维修经典图书系列

液压故障的智能信息诊断与监测

姜万录　刘思远　张齐生　编著

机械工业出版社
CHINA MACHINE PRESS

机械工业出版社液压气动技术类书目(部分)

书号	书名	作者	定价
30986	液压气压传动与控制技术问题对策	方昌林 凌智勇	28.00元
31308	英汉液压气动科技词典	李晓文 李运华	29.00元
23810	现代实用气动技术(第3版)	SMC中国有限公司	95.00元
22599	液压系统设计禁忌	邵俊鹏	32.00元
06535	实用液压技术300题(第3版)	邢鸿雁	32.00元
20520	液压机的设计与应用	俞新陆	78.00元
39966	汽车电液技术	杨华勇 赵静一	00.00元
08950	机械密封实用技术	顾永泉	28.00元
09686	液压与气动设备维修问答	编委会	36.00元
34152	液压系统可靠性工程	赵静一 姚成玉	49.00元
38516	有色金属冶炼设备液压技术及其应用	袁锐波	49.00元
37113	液压变量泵(马达)变量调节原理与应用	吴晓明 高殿荣	39.00元
35617	液压螺纹插装阀	张海平	88.00元
35891	新型液压元件及系统集成技术	袁子荣 等	39.00元
39795	二次调节压力耦联静液传动技术	姜继海	00.00元
41583	液压故障的智能信息诊断与监测	姜万录 刘思远 张齐生	58.00元

地址：北京市百万庄大街22号
邮政编码：100037
电话服务
社服务中心：010-88361066
销售一部：010-68326294
销售二部：010-88379649
读者购书热线：010-88379203
网络服务
教材网：http://www.cmpedu.com
机工官网：http://www.cmpbook.com
机工官博：http://weibo.com/cmp1952
封面无防伪标均为盗版

ISBN 978-7-111-41583-1
策划编辑◎张秀恩 / 封面设计◎陈沛

ISBN 978-7-111-41583-1
9 787111 415831 >
定价：58.00元

21 世纪液压气动使用维修经典图书系列

液压故障的智能信息诊断与监测

姜万录　刘思远　张齐生　编著

机 械 工 业 出 版 社

本书系统地阐述了近年来液压系统故障诊断领域新发展的各种理论及方法，这些理论及方法已经通过了液压系统的故障诊断实验进行了有效的验证。全书共分为13章，深入浅出地介绍了各种新方法及应用。本书的主要内容包括：基于AR模型最佳阶次选择的功率谱分析方法；对几种常用的频谱细化方法进行了对比分析；基于Hilbert-Huang变换的故障特征提取方法；基于Morlet复解析小波簇的带通滤波和包络解调新方法；通过利用轴向柱塞泵出口压力信号的关联维数进行液压泵故障诊断的方法；基于最大Lyapunov指数分析的故障诊断方法；研制了一套基于MCGS组态软件的油液污染度在线监测系统；松散型小波神经网络和紧凑型小波神经网络两种故障诊断方法；证据理论和神经网络相结合的智能故障诊断方法；研究了幅值域和时频域的特征向量提取方法；免疫支持向量机复合的故障诊断方法；基于粗糙集理论的启发式属性约简算法。

本书适用于从事设备状态监测和故障诊断工作的工程技术人员阅读，也可作为高等学校相关专业研究生的教材或参考用书。

图书在版编目（CIP）数据

液压故障的智能信息诊断与监测/姜万录，刘思远，张齐生编著. —北京：机械工业出版社，2013.4

21世纪液压气动使用维修经典图书系列

ISBN 978-7-111-41583-1

Ⅰ.①液… Ⅱ.①姜…②刘…③张… Ⅲ.①液压系统－故障诊断－研究 Ⅳ.①TH137

中国版本图书馆CIP数据核字（2013）第033764号

机械工业出版社（北京市百万庄大街22号 邮政编码100037）

策划编辑：张秀恩 责任编辑：张秀恩 王春雨

版式设计：霍永明 责任校对：刘志文 肖 琳

封面设计：陈 沛 责任印制：张 楠

高教社（天津）印务有限公司印刷

2013年5月第1版第1次印刷

169mm×239mm ·24.75印张·495千字

0001－3000册

标准书号：ISBN 978－7－111－41583－1

定价：58.00元

凡购本书，如有缺页、倒页、脱页，由本社发行部调换

电话服务

社服务中心：(010)88361066

销售一部：(010)68326294

销售二部：(010)88379649

读者购书热线：(010)88379203

策划编辑(010)88379770

网络服务

教材网：http://www.cmpedu.com

机工官网：http://www.cmpbook.com

机工官博：http://weibo.com/cmp1952

封面无防伪标均为盗版

前　言

故障信息诊断预报技术是依据设备或系统运行状态信息，利用各种信息处理或信号处理方法判定故障源和故障程度，预测故障未来的发展趋势，并确定相应维修决策的一门综合性交叉学科。对生产设备进行及时有效的故障诊断与预报，不仅能够提高设备运行的安全性和可靠性，预防灾难性事故的发生，而且还能够提高设备产能和产品质量、降低维修成本，产生巨大的经济效益和社会效益。设备故障检测与诊断技术在现代工业领域已经得到了广泛的应用，它已渗透到航空航天、武器装备、舰船、冶金、化工、能源、工程机械等工程技术领域中，取得了显著成效。

随着现代工业的发展，生产设备逐步趋向于大型化、高速化、多功能化和智能化。而对于生产设备的重要部分——液压系统来说，其功能和结构也变得日趋复杂，品质指标越来越高，系统的非线性和动态时变性变得更强，故障形式也变得复杂多样，强干扰影响下的故障很难通过现有的诊断方法得到有效诊断。液压系统本身所具有的高压、管路封闭及参数可测性差的特点又限制了很多故障诊断方法的应用，所以对液压系统的故障诊断理论和技术水平还有待进一步完善和提高，因而研究和开发新的准确有效的液压系统故障诊断方法在现代工业生产中具有十分重要的意义。

作者近十几年来一直致力于该领域的研究工作，关于工业装备对液压系统故障诊断的需求体会颇深，深感有必要将多年来的研究成果进行归纳总结并撰写一本学术专著，对液压系统故障诊断领域的新理论与新方法及其应用进行系统的介绍，旨在丰富故障诊断的理论体系，使诊断理论满足实用化的需求，建立完善的液压智能故障诊断系统。

本书系统地阐述了近年来液压系统故障诊断领域新发展的各种理论及方法，这些理论及方法已经通过了液压系统的故障诊断实验进行了有效的验证。全书共分为13章，深入浅出地介绍了各种新方法及应用。第1章系统地阐述了液压系统故障诊断技术的发展历程、研究现状及发展趋势以及近年来在液压系统故障诊断领域出现的新理论、新方法；第2章提出了基于AR模型最佳阶次选择的功率谱分析方法，通过真空系统的重要元件——干式真空泵的故障诊断实验分析证明，该方法能有效地提取轴承故障的特征频率；第3章对几种常用的频谱细化方法进行了对比分析，通过实验证明小波变换频谱细化方法以及FFT-FS频谱细化方法对真空泵的轴承故障诊断有较高的准确性；第4章提出了基于Hilbert-Huang变换的故障特征提取方法，并针对采样率过低造成的对经验模态分解（EMD）算法的影响，提出了

EMD 的改进算法，通过干式真空泵的故障诊断实验，并与传统的包络解调方法进行了对比，验证了 Hilbert-Huang 变换在故障特征频率提取方面具有更高的分辨率和准确性；第 5 章提出一种基于 Morlet 复解析小波簇的带通滤波和包络解调新方法，通过合理地选择小波参数，用多个单 Morlet 小波组成的小波簇可构成具有零相移、平顶通带及快速衰减过渡带特性的带通滤波器，这种方法将信号高频带通滤波和 Hilbert 变换两个步骤合二为一，用于提取振动信号的高频谐振成分，通过对干式真空泵故障和液压轴向柱塞泵的诊断实验，验证了该方法能够有效地提取故障特征频率，缩短运算时间，提高故障诊断的实时性；第 6 章提出通过利用轴向柱塞泵出口压力信号的关联维数进行液压泵故障诊断的方法，通过实验测得的泵出口压力信号进行关联维数分析发现，故障信号的关联维数低于正常信号，可利用该性质作为液压泵故障判定的依据；第 7 章提出了基于最大 Lyapunov 指数分析的故障诊断方法，通过对泵出口压力信号最大 Lyapunov 指数的计算结果作为判断系统是否发生故障的依据；第 8 章研制了一套基于 MCGS 组态软件的油液污染度在线监测系统，该系统实现了压差数据的采集、存储、超限报警等功能，并能给出污染度等级检测结果报告，通过利用标准污染度的油液进行标定实验，建立了该系统的污染度数学模型，通过对实际油液进行在线监测实验，验证了该模型的正确性；第 9 章提出了松散型小波神经网络和紧凑型小波神经网络两种故障诊断方法，利用这两种方法分别对液压泵进行故障诊断实验，均取得了较好的诊断效果；第 10 章提出了证据理论和神经网络相结合的智能故障诊断方法，实现了二者的优势互补，利用液压泵典型故障的诊断实验证明，该方法对液压泵常见故障具有良好的诊断效果；第 11 章研究了幅值域和时频域的特征向量提取方法，实验分析了各种有量纲和无量纲幅值域特征指标对液压泵几种典型故障的敏感性，为解决特征向量集合维数高的问题提出了主元分析的特征降维选择方法，利用基于主元分析模型的故障检测方法并结合故障诊断实验验证了该方法的应用效果；第 12 章为解决液压系统普遍存在的典型故障样本严重不足及诊断知识发现困难的问题，提出了免疫支持向量机复合的故障诊断方法，通过液压泵多故障模式的诊断实验验证了该方法在提高故障诊断确诊率方面的优势；第 13 章针对特征向量集中存在冗余属性的问题，提出了基于粗糙集理论的启发式属性约简算法，得到了“最佳属性约简”，有效地去除了冗余属性，以粗糙集理论为基础结合主元分析方法构造了多变量决策树，得到了最小诊断规则信息表，针对现代液压系统故障信息模糊性和不完备性的特点，提出了单传感器多域特征信息融合的贝叶斯网络故障诊断方法以及多源传感器信息融合和贝叶斯网络集成的故障诊断方法，通过液压泵多故障模式的诊断实验验证了这两种方法的有效性。

本书各章均为作者长期从事液压设备状态监测与故障诊断研究工作的成果。本书内容取材于国家自然科学基金资助项目：“基于数据驱动知识发现的智能故障诊

断方法与专家系统关键技术”（51075349）、“冷连轧机轧制工艺规程智能优化的关键问题研究”（50775198），河北省自然科学基金资助项目“少故障样本条件下基于数据挖掘的液压 AGC 系统智能故障诊断理论方法及系统”（E2013203161），河北省教育厅博士基金资助项目“基于多 Agent 及 Internet 融合的远程智能状态监测与故障诊断关键技术”（B2004128），教育部高等学校骨干教师资助项目“多智能理论方法集成的故障诊断预报系统”等部分相关研究成果。

姜万录编写了本书的第 1～7 章、第 9～10 章、第 12 章，刘思远编写了第 11 章、第 13 章，张齐生编写了第 8 章。全书由姜万录统稿。

本书干式真空泵的故障数据采集实验在英国莱斯特大学（University of Leicester）工程系的实验室进行，在此对作者姜万录在英国访学期间的合作教授、工程系主任 Sarah K. Spurgeon 教授及其所领导的研究团队成员 John A. Twiddle 和 Fernando S. Schlindwein 等表示衷心感谢。

本书参考了大量文献，由于篇幅所限未能逐一列出，各章仅列出了主要参考文献，在此对原文作者表示衷心感谢。在本书成稿期间，硕士研究生朱勇同学参与了部分文稿的编辑和整理工作，在此表示感谢。

考虑本书主要面向从事设备故障诊断与维修工作的广大读者，因此作者力求用通俗易懂的语言进行阐述，尽量避免艰涩的基础理论推导内容。由于作者的学术水平有限，书稿虽几经修改，书中缺点和错误在所难免，恳求广大读者给予批评指正。

本书适用于从事设备状态监测和故障诊断工作的工程技术人员阅读，也可作为高等学校相关专业研究生的教材或参考书。

作　者

于燕园

目　录

前言
第 1 章　绪论 …… 1
1.1　液压系统故障诊断技术的发展历程 …… 2
1.2　液压系统故障诊断技术的研究现状 …… 4
1.3　液压系统故障诊断技术的发展趋势 …… 5
1.4　液压系统故障检测与诊断新方法 …… 6
1.4.1　神经网络技术方法 …… 6
1.4.2　支持向量机方法 …… 7
1.4.3　混沌分形理论方法 …… 8
1.4.4　Lyapunov 指数及关联维数方法 …… 9
1.4.5　信息融合技术方法 …… 10
1.4.6　人工免疫系统方法 …… 11
1.4.7　贝叶斯网络方法 …… 12
1.4.8　小波理论方法 …… 12
1.4.9　频谱细化分析方法 …… 13
1.4.10　Hilbert-Huang 变换方法 …… 13
1.5　本书的主要内容 …… 14
参考文献 …… 16
第 2 章　基于 AR 模型的功率谱估计及在故障检测中的应用 …… 18
2.1　常用频谱估计方法 …… 18
2.1.1　常用的几种谱估计方法 …… 18
2.1.2　傅里叶变换技术 …… 18
2.1.3　自回归模型 …… 19
2.1.4　Prony 复极点模型 …… 23
2.1.5　最大似然谱估计法 …… 24
2.2　AR 模型参数的计算方法及阶次选择 …… 24
2.2.1　AR 模型参数计算方法 …… 25
2.2.2　AR 模型阶次选择 …… 30
2.2.3　AR 模型阶次功率谱的仿真算例 …… 33
2.3　干式真空泵及其常见故障 …… 34

2.3.1　干式真空泵 …… 34
2.3.2　干式真空泵常见的故障形式 …… 38
2.3.3　轴承常见故障及其诊断方法 …… 39
2.4　AR 模型功率谱估计方法在干式真空泵故障诊断中的应用 …… 44
2.4.1　干式真空泵信号采集及故障诊断实验 …… 44
2.4.2　基于 AR 模型的功率谱分析法的干式真空泵故障诊断 …… 46
参考文献 …… 50
第 3 章　频谱细化方法及在故障诊断中的应用 …… 52
3.1　时域和频域分析方法 …… 52
3.1.1　傅里叶分析 …… 52
3.1.2　小波分析 …… 53
3.2　频谱细化分析的理论方法 …… 57
3.2.1　频谱细化分析方法 …… 58
3.2.2　几种频谱细化分析方法的比较 …… 64
3.3　频谱细化方法在真空泵轴承故障诊断中的应用 …… 67
3.3.1　小波簇变换频谱细化方法的应用 …… 67
3.3.2　FFT-FS 频谱细化方法的应用 …… 70
3.3.3　结果分析 …… 71
参考文献 …… 71
第 4 章　Hilbert-Huang 变换在故障诊断中的应用 …… 73
4.1　Hilbert-Huang 变换的基本原理 …… 73
4.1.1　Hilbert-Huang 变换中的基本概念 …… 74
4.1.2　Hilbert-Huang 变换算法实现过程 …… 79
4.1.3　Hilbert-Huang 变换存在的问题 …… 82
4.2　EMD 算法的改进 …… 84
4.2.1　采样频率对 EMD 分解的影响及其改进 …… 85
4.2.2　EMD 筛选算法的改进 …… 89
4.2.3　EMD 的端点效应及其改进方法 …… 92
4.3　Hilbert-Huang 变换在真空泵故障诊断中的应用 …… 103
4.3.1　实验信号采集 …… 103
4.3.2　传统的 Hilbert 变换包络解调方法在真空泵故障诊断中的应用 …… 104
4.3.3　Hilbert-Huang 变换在真空泵故障诊断中的应用 …… 105
参考文献 …… 106

第 5 章 小波簇包络解调方法在故障诊断中的应用 …… 108
5.1 包络解调方法的研究现状 …… 108
5.2 振动监测技术 …… 109
5.2.1 机械振动监测与分析技术 …… 109
5.2.2 振动信号的分析与处理 …… 111
5.3 基于复解析小波的包络解调方法 …… 116
5.3.1 信号调制技术 …… 116
5.3.2 解调原理 …… 118
5.3.3 包络解调方法 …… 119
5.3.4 复解析小波的带通滤波特性 …… 122
5.3.5 复解析小波簇的包络解调方法 …… 124
5.4 小波簇包络解调方法在故障诊断中的应用 …… 132
5.4.1 小波簇包络解调方法在真空泵故障诊断中的应用 …… 132
5.4.2 小波簇包络解调方法在液压泵故障诊断中的应用 …… 135
参考文献 …… 138
第 6 章 混沌分形理论在故障诊断中的应用 …… 140
6.1 混沌及分形 …… 140
6.1.1 混沌的特征 …… 140
6.1.2 分形理论 …… 142
6.2 关联维数分析 …… 143
6.2.1 关联维数分析方法 …… 143
6.2.2 几种典型信号的关联维数 …… 146
6.3 基于分形理论的液压泵故障诊断的实验研究 …… 147
6.3.1 实验条件 …… 147
6.3.2 信号的小波消噪与特征提取 …… 148
6.3.3 关联维数计算 …… 149
6.3.4 结果分析 …… 152
参考文献 …… 152
第 7 章 基于 Lyapunov 指数分析的故障诊断方法 …… 154
7.1 混沌运动及 Lyapunov 指数 …… 154
7.1.1 混沌判别方法 …… 154
7.1.2 Lyapunov 指数 …… 155
7.2 Lyapunov 指数算法及其改进 …… 159
7.2.1 标准 QR 分解算法 …… 159
7.2.2 改进的 QR 分解算法 …… 160

7.2.3　Lyapunov 指数算法的实现 …… 164
7.2.4　算法的比较 …… 166
7.3　基于 Lyapunov 指数的混沌检测 …… 168
7.3.1　杜芬方程的混沌特性 …… 168
7.3.2　基于最大 Lyapunov 指数的微弱信号检测方法 …… 171
7.4　基于最大 Lyapunov 指数法的液压泵故障诊断实验 …… 177
7.4.1　基于杜芬方程的最大 Lyapunov 指数故障诊断 …… 178
7.4.2　结果分析 …… 180
参考文献 …… 180
第 8 章　液压油污染度在线监测系统 …… 182
8.1　油液污染监测技术 …… 182
8.1.1　油液污染问题概述 …… 182
8.1.2　油液污染度的评定与测定方法 …… 183
8.1.3　油液污染检测技术的研究现状和发展趋势 …… 184
8.2　油液污染控制技术 …… 185
8.2.1　油液污染度的等级标准 …… 185
8.2.2　油液的污染分析 …… 188
8.2.3　油液的污染控制 …… 190
8.2.4　油液的净化 …… 191
8.3　在线监测装置研制 …… 193
8.3.1　过滤的基本原理 …… 193
8.3.2　过滤介质的选择 …… 194
8.3.3　淤积法测量原理 …… 195
8.3.4　恒功率淤积法测量原理 …… 197
8.3.5　利用阀用直流电磁铁作为动力元件的可行性 …… 199
8.3.6　颗粒尺寸分布对测量的影响 …… 200
8.4　在线监测系统的硬件与软件实现 …… 202
8.4.1　在线监测系统的方案 …… 202
8.4.2　在线监测系统的功能及原理 …… 202
8.4.3　硬件系统 …… 203
8.4.4　在线监测系统的软件实现 …… 206
8.5　在线监测系统的调试与实验 …… 210
8.5.1　实验油样的配制 …… 210
8.5.2　在线监测系统的调试 …… 211
8.5.3　在线监测系统的实验 …… 213

8.5.4 实验结果分析 …… 217
参考文献 …… 218
第9章 基于小波神经网络的故障诊断方法 …… 219
9.1 人工神经网络 …… 219
9.1.1 人工神经元模型应具备的要素 …… 219
9.1.2 神经元之间的连接形式 …… 219
9.1.3 BP 网络学习算法及隐层的设计 …… 220
9.1.4 BP 神经网络应用实例 …… 222
9.2 小波神经网络 …… 223
9.2.1 小波神经网络原理 …… 224
9.2.2 紧致型小波神经网络的结构 …… 224
9.2.3 紧致型小波神经网络的学习算法 …… 225
9.2.4 小波神经网络与传统的 BP 网络比较 …… 227
9.2.5 小波神经网络应用实例 …… 228
9.3 基于小波神经网络的液压泵故障诊断实验 …… 228
9.3.1 实验条件及数据采集 …… 228
9.3.2 基于松散型小波神经网络的液压泵故障诊断 …… 229
9.3.3 基于紧致型小波神经网络的液压泵故障诊断 …… 232
参考文献 …… 233
第10章 证据理论和神经网络集成的信息融合故障诊断方法 …… 235
10.1 数据融合技术 …… 235
10.1.1 数据融合的基本原理 …… 235
10.1.2 数据融合的定义 …… 236
10.1.3 数据融合的层次 …… 237
10.1.4 融合系统的模型结构 …… 237
10.1.5 多传感器融合算法 …… 238
10.2 证据理论和神经网络结合的诊断方法 …… 241
10.2.1 信度函数 …… 241
10.2.2 Dempster 合成法则 …… 243
10.2.3 基于证据理论的决策 …… 245
10.2.4 证据理论的优缺点 …… 246
10.2.5 证据理论和神经网络集成的数据融合诊断方法 …… 247
10.3 轴向柱塞泵的故障诊断实验 …… 250
10.3.1 液压泵的常见故障机理分析 …… 250
10.3.2 常用信号数据源 …… 250

10.3.3　神经网络证据理论液压泵诊断模型结构 …… 251
10.3.4　局部诊断神经网络结构设计 …… 252
10.3.5　神经网络证据理论液压泵诊断决策方法 …… 254
10.3.6　基于神经网络和证据理论集成方法的液压泵诊断实验 …… 254
参考文献 …… 261
第 11 章　液压泵的故障特征提取及特征降维 …… 263
11.1　液压泵的振动和声音信号处理 …… 263
11.1.1　故障信号的采集方法 …… 263
11.1.2　基于 Hilbert 变换的包络解调法 …… 265
11.1.3　基于小波包带通滤波消噪的包络分析信号处理 …… 266
11.1.4　柱塞泵松靴故障的信号处理 …… 266
11.1.5　柱塞泵滑靴磨损故障的信号处理 …… 271
11.1.6　柱塞泵中心弹簧失效故障的信号处理 …… 275
11.2　故障特征向量提取方法 …… 278
11.2.1　信号的幅值域特征提取 …… 278
11.2.2　基于小波包的时频域特征提取 …… 282
11.2.3　液压泵振动信号的幅值域特征提取 …… 282
11.2.4　液压泵振动信号的时频域特征提取 …… 287
11.3　主元分析在特征降维中的应用 …… 289
11.3.1　主元分析方法 …… 289
11.3.2　基于主元分析的故障检测方法 …… 291
11.3.3　主元分析特征提取及降维实例分析 …… 292
11.4　主元分析方法在故障检测中的应用 …… 295
11.4.1　故障检测方法的实现过程 …… 296
11.4.2　故障检测实例分析 …… 296
参考文献 …… 301
第 12 章　免疫机理与支持向量机复合的故障诊断方法 …… 303
12.1　人工免疫机理 …… 303
12.1.1　生物免疫系统 …… 303
12.1.2　人工免疫系统的阴性选择算法 …… 303
12.2　支持向量机 …… 310
12.2.1　支持向量机的基本原理 …… 310
12.2.2　支持向量机的特点 …… 313
12.2.3　基于支持向量机故障诊断的基本步骤 …… 315
12.2.4　支持向量机建立及分析 …… 315

12.2.5 基于支持向量机的液压泵故障诊断分析 …… 318
12.3 基于 NS 机理和 SVM 复合的故障诊断方法 …… 319
12.3.1 传统分类算法的局限性 …… 319
12.3.2 支持向量机的不足 …… 320
12.3.3 NS 与 SVM 复合故障诊断方法 …… 320
12.3.4 诊断实例及分析 …… 323
12.4 基于复合故障诊断方法的液压泵诊断实验及结果分析 …… 326
12.4.1 基于虚拟仪器的液压泵故障诊断实验系统 …… 327
12.4.2 斜盘式轴向柱塞泵典型故障分析 …… 327
12.4.3 液压泵监测信号的采集与处理 …… 328
12.4.4 轴向柱塞泵故障诊断实验及结果分析 …… 334
参考文献 …… 337
第 13 章 信息融合和贝叶斯网络集成的故障诊断方法 …… 340
13.1 粗糙集理论在故障诊断中的应用 …… 340
13.1.1 知识约简 …… 340
13.1.2 决策表属性约简算法 …… 342
13.1.3 多变量决策树的诊断规则提取方法 …… 345
13.2 单传感器多特征信息融合的贝叶斯网络故障诊断方法 …… 351
13.2.1 多传感器信息融合技术 …… 352
13.2.2 基于贝叶斯参数估计算法的信息融合数学模型 …… 353
13.2.3 贝叶斯网络 …… 354
13.2.4 贝叶斯网络分类器 …… 356
13.2.5 液压泵振动信号的故障诊断分析 …… 360
13.3 多源传感器信息融合与贝叶斯网络集成的故障诊断方法 …… 365
13.3.1 多源传感器信息融合与贝叶斯网络集成的故障诊断方法 …… 365
13.3.2 液压泵多故障模式诊断的实验研究 …… 367
参考文献 …… 381

第1章 绪 论

随着生产技术的发展和科学技术的进步，现代化工业大生产的装备自动化水平日益提高，逐步向大型化、连续化、高速化和智能化的方向发展，设备的生产效率得到了显著的提高，在降低了生产成本的同时也保证了产品的产量和质量，但设备的机械结构和系统的功能却变得日趋复杂。由于各种各样不可避免的因素影响，导致装备系统出现各种故障，以致降低或失去其预定的功能。设备因故障停工造成的损失成比例地增加，维修费用也大幅度上升。设备中一个部件发生故障，可能引起整个生产流程的中断，造成巨大的经济损失，甚至会发生灾难性事故，因此对设备的安全性和可靠性提出了越来越高的要求。为此，人们采取了一系列措施，包括提高元器件的可靠性、进行系统的高可靠性设计以及进行控制系统的容错设计等。即便如此，系统最终还是难免发生故障。因此，故障检测与诊断、故障预报技术就成了现代设备运行维护和管理的重要课题。

液压系统在各类工业设备中起着核心的传动和控制作用。现代液压系统具有功率大、体积小、质量轻、响应快、精度高及抗负载刚性大等优点，随着液压系统向快速、大功率、高精度的方向发展，液压系统及设备的功能越来越强大，结构和信息越来越复杂，性能指标越来越高，工作强度越来越大，各部分的关联越来越紧密。对液压系统进行有效的状态监测与故障诊断可以提高设备的安全性和可靠性。不仅能够保证正常的生产工艺过程和产品质量，而且能够避免灾难性事故的发生。在设备维护方面，可以降低维修成本，延长设备的服役寿命，推进设备维修体制与方式的现代化。对生产企业来说，可以提高生产效率，增加产品合格率，减少材料浪费，节约成本。在市场竞争中还能够提高企业的核心竞争力，给企业创造巨大的经济价值。

相反，如果不对液压系统进行状态监测与故障诊断，就将造成严重的后果。由于液压系统在生产线中所处的地位异常重要，一旦发生故障，轻则造成停机或影响产品质量，重则将会使整个生产过程失效，生产线瘫痪，甚至发生人身伤亡，还会产生对环境的污染，给企业造成巨大的经济损失，产生严重的社会影响。

总之，对液压系统设备的早期故障检测与诊断是整个生产流程中必不可少的环节，也是设备维修管理体制中“预知维修”阶段研究的核心问题。不断提高液压系统的故障诊断技术水平，研究和开发各类新的准确有效的故障诊断方法，在现代工业生产中是非常必要且紧迫的。

1.1 液压系统故障诊断技术的发展历程

与其他应用领域的故障诊断技术相比，液压系统的故障诊断技术相对落后，后者主要是以汲取其他领域的研究成果为基础发展起来的。液压系统的故障诊断是针对具体的液压系统，通过分析液压系统特有的失效形式和故障机理，利用现代信息处理技术，对采集的状态监测信号进行模式识别或分类，对故障原因进行分析，并进行故障定位和故障预报等。

在液压系统的运行信息中，包含机械、液压、电气等方面的综合信息。机械设备中所有可能发生的故障在液压系统中都可能发生，如形变、应力疲劳断裂、腐蚀、磨损、冲击断裂、热应力与热变形等。除此之外，液压传动与控制系统还具有其特有的失效形式，如油液污染、泄漏、腐蚀、气蚀、液压卡死、油液温升、管路谐振、电气信号失真、噪声及系统振荡等。

液压系统工作是靠液压油来传递压力能的，油液的状态对液压系统工作的可靠性影响最大。据统计，液压系统的故障有 70% 以上是由于油液污染引起的，而油液中杂质引起的故障又占其中的 90%。因此，对油液污染度的控制是提高液压系统可靠性的首要保证。另外，约有 30% 的故障是液压元件和辅件的磨损、液压卡死及液压冲击造成的。此外，由于系统参数调整和设定不当等也会使液压系统发生故障。

由于油液的粘性和所含空气量变化的非线性、液压系统元件的运动形式多样、系统回路间的相互干涉、动力的传递封闭、参数可测性差等诸多因素的影响，使得液压系统的故障机理分析难以精确。同时，由于液压系统功能的多样性，每一液压系统都有其特有的故障形式，使液压系统的状态监测和故障诊断存在较大困难。因此，针对每个系统进行故障机理分析，建立系统特有的故障样本仍将是今后的重要研究课题。

由于液压系统的失效形式及故障机理的复杂性和多样性，使得故障原因、故障部位、故障程度的诊断比较困难。基于数学模型的故障诊断方法往往需要多种前提条件，例如：需要过程的机理模型知识；模型必须线性化；假设干扰为白噪声等，这些前提条件往往不符合液压系统实际情况。液压系统存在伺服阀、执行器、管路和负载等高度非线性及时变环节，且数学模型比较复杂，现有模型都是在各种假设和近似下得到的。因而在液压系统中，基于数学模型的方法难以取得良好的诊断效果。根据目前已掌握的文献，国内外学者广泛研究基于数据驱动、基于信号处理和基于知识的方法用于液压系统进行故障诊断和预报。

液压系统故障诊断技术紧跟现代工业和现代科学技术发展的步伐，主要经历了以下四个发展阶段：

1. 主观经验诊断法阶段

这是一种主观判断法，是采用看、听、摸、问、闻、阅等方式进行诊断。主要是通过专家和工程技术人员利用简单的诊断仪器多凭借个人的实践经验，判断故障发生的部位、类型、故障程度及产生原因。这类方法由于简单方便，在现代工业装备维修中仍被广泛采用。但是由于这种方法主要依靠专家的经验，所以此方法有着难以克服的局限性：它要求诊断人员必须掌握丰富的故障机理知识和诊断经验，熟知元件的结构、功能、性能等方面的知识，具备综合分析解决问题的能力，这样才能正确地进行故障诊断并提出合理的维修方案。但是，由于人们的感觉不同，判断能力和实践经验亦存在差别，所以诊断结果不可避免地存在差异，维修决策的合理性、正确性难以保证，因此主观诊断法已经越来越难以适应企业现代化生产的需求。

主观经验诊断法是液压故障诊断发展的初级阶段，该方法一般只能对故障进行简单的定性分析，难以做到定量分析。为了弄清复杂液压系统或液压元件故障的产生原因，有时就不得不停机，把它拆卸下来，放到实验台上做定量的性能测试，作进一步判断。

2. 基于数学模型的诊断方法阶段

该类方法对于简单的系统较为适用，但对于现代工业生产过程中的复杂系统就显得无能为力。大规模的复杂系统具有滞后、强耦合性及参数时变性等严重的非线性特性，而且还存在过程不确定性和外界干扰等多种不良因素的影响，噪声统计特性也不理想，因此难于建立精确的数学模型，甚至不存在确定的数学模型，这些原因导致诊断过程很难实现在线状态估计或参数估计。此外，对于系统的故障诊断过程而言，基于模型的诊断方法具有针对性强的特点，一旦确定了诊断模型其诊断能力很大程度上就已经确定了，所以它的功能很难继续扩充及修改，通用性较差。

由于液压系统中的液压元件工作在封闭油路中，工作过程不像机械传动那样直观，也不像电气设备那样易于测量运行参数，参数的可测性较差，也就导致所测得的故障信息存在不完备性。而且影响液压系统特性的因素又多种多样，这些原因使得基于数学模型的诊断方法不能满足对复杂液压系统进行故障诊断的现实需要。

3. 基于数据驱动和信号处理的诊断方法阶段

这类方法首先是用传感器采集获取系统的某些可测量运行参数，这些运行参数在幅值、相位、频率及相关性等方面与故障源之间存在着诸多联系，然后通过信号处理技术手段分析、处理这些运行信息来判断故障发生的原因。从诊断过程来看，这类方法的实质是以传感器技术和动态测试技术为手段，以信号处理和建模处理为基础的诊断技术，衍生出了很多有效的故障诊断方法，例如：时间序列分析法、功率谱分析法、倒频谱分析法、小波分析法等，这些方法都表现出简单实用且鲁棒性强的特点，但是它同样存在一些局限性。

4. 人工智能诊断技术阶段

智能诊断技术是随着信息科学技术和人工智能技术的迅速发展而产生的，它是人工智能技术、计算机技术与液压系统故障诊断技术相结合的产物，也是诊断技术发展进步的必然结果。特别是知识工程、专家系统和人工神经网络在各领域中的广泛应用，促使人们对智能诊断问题进行更加深入、系统的研究。液压系统故障的多样性、突发性、成因的复杂性以及故障诊断过程对领域专家实践经验和诊断策略的高度依赖，使研制智能化的液压故障诊断系统成为该领域当前的发展趋势。

诊断系统的智能性是指它能够有效地获取、传递、处理、再生和利用诊断信息，从而具有对给定环境下的被诊对象进行有效的状态识别和状态预测的能力。因此，智能诊断技术是液压系统故障诊断极具生命力的一个发展方向。目前，该方向的研究主要从两个方面展开：一个是基于专家系统的智能故障诊断技术，另一个是基于神经网络的智能故障诊断技术。然而，诊断系统的智能并不意味着完全代替人的智力活动，将人排除在诊断系统之外。因此，智能诊断系统，是由人（尤其是领域专家）、现代模拟脑功能的硬件及其必要的外部设备、物理器件以及支持这些硬件的平台软件、计算智能为核心的用户程序所组成的人机系统。该系统以对诊断对象进行状态识别和状态预测为目的，是基于知识处理的诊断系统。

1.2 液压系统故障诊断技术的研究现状

液压系统故障诊断技术始于20世纪60年代，以Hunt为首的英国Bath大学和以Collacott为首的英国机器保健和状态监测协会（MHMG & CMA）最先开始研究液压系统故障诊断技术，利用加速度传感器和压力传感器测量液压能源系统的振动信号和压力信号来实现液压泵的故障诊断。此时的测量方法多处于直接测量阶段。20世纪80年代初期至90年代末，基于人工智能的液压故障诊断技术迅速发展起来。加拿大学者Tatge和Winston研究了卫星跟踪天线驱动液压系统的故障诊断。1991年英国Wales大学的Cardiff教授研究了液压系统基于多层感知器（MLP）的神经网络故障诊断方法。1997年法国学者Gaddouna采用未知输入观测器对液压系统进行故障诊断，不久后，基于未知输入观测器的鲁棒故障诊断方法得到了广泛的研究。1998年Bath大学的Growther发表了关于对二阶液压舵机系统的输出矢量空间进行神经网络故障诊断的学术论文。2003年，哥伦比亚学者Linaric等采用神经网络非线性辨识方法对电液伺服系统中的故障进行建模，据此实现了该系统的故障诊断。同年，加拿大学者An等利用广义卡尔曼滤波方法对液压系统状态进行估计预测，实现了液压系统电气环节的故障诊断。

国内液压系统故障诊断技术的研究起步比较晚，诊断技术水平与工业发达国家相比还存在一定差距，但从近十几年的发展状况来看，该技术发展迅猛。1986年

浙江大学路甬祥、陈章位等对液压系统故障机理与诊断技术作了深入的研究。2001年燕山大学姜万录将混沌微弱信号检测方法和小波变换的方法引入到液压泵故障的振动信号处理中，对液压泵脱靴故障进行了有效诊断，2007年又深入研究了基于小波簇的带通滤波及包络解调方法并成功应用于干式真空泵的故障诊断中。北京航空航天大学机械电子工程系从1994年开始致力于液压系统故障诊断的研究，相继利用专家系统、神经网络、小波分析、鲁棒智能监测与诊断方法实现液压泵、液压舵机系统的故障诊断。其中王少萍在分析了液压泵故障机理的基础上，采用神经网络及专家系统对液压泵的诊断问题进行了全面深入的研究。

1.3 液压系统故障诊断技术的发展趋势

液压系统故障诊断是一个目前的热点研究领域。随着相关学科理论与技术的更新和发展，新理论、新技术不断地引入液压系统故障诊断领域中，使之不断完善。将各种智能方法应用到液压系统故障诊断技术中是液压系统故障诊断技术的发展趋势。

1. 智能诊断方法

随着人工智能技术的迅速发展，遗传算法、神经网络、专家系统等智能诊断方法逐步应用到液压系统故障诊断领域。在众多的神经网络结构中，以基于BP算法的多层感知器（MLP）神经网络理论最完善，在液压系统故障诊断中应用最广泛且最成功。许多应用实例表明，结合人工智能和领域专家知识的智能型专家系统是进行液压系统故障诊断的有效途径。

2. 虚拟仪器技术

随着计算机技术、微电子技术和软件技术的迅速发展和不断更新，虚拟仪器技术逐渐兴起。它改变了传统仪器的概念、模式和结构，改变了人们的仪器观。它是人们通过计算机对复杂数据进行可视化操作以及交互的一种全新的方式。随着虚拟仪器技术的进一步发展和在智能故障诊断系统中的广泛应用，它将给智能故障诊断技术带来一次深刻革命。

3. 多传感器信息融合

液压系统的设备结构复杂，故障特征间存在耦合，不同的故障形式可能表现相同的特征信息。所以凭借单一传感器信息进行分析，反映的状态行为是不完整的，难以准确诊断系统故障。基于多源信息综合处理的信息融合技术将成为故障诊断研究的热点，该方法将来自液压系统某一故障的多源信息加以智能融合，产生比单一信息源更精确、更完备的估计和判断。与经典信号处理方法相比较，信息融合处理的多传感器信息具有更复杂的形式，故障信息可以在不同的信息层次上融合。采用多传感器信息融合方法，可有效提高诊断决策的鲁棒性。

4. 多诊断方法相结合

液压系统故障诊断的各种方法都有一定的适用范围，在制定诊断策略时，应将各方法取长补短并进行合理有效地结合，充分利用不同诊断方法的优势，提高诊断策略的综合性能。例如，基于神经网络的专家系统故障诊断方法，该方法利用神经网络的并行处理能力、自学习功能以及网络结构鲁棒性强的优点，克服了传统专家系统知识获取和表达困难、推理容易陷入组合爆炸的问题；将专家知识以权值和阈值的形式存储于网络中，充分利用专家经验和神经网络的学习、联想功能，诊断过程中能不断地归纳出新规则，丰富专家系统知识库；同时，神经网络结合专家系统的解释机制，克服了神经网络故障诊断解释不直观等缺点。

5. 远程网络故障诊断

基于分布式技术和网络通信技术的远程故障诊断是故障诊断领域的另一个发展方向。液压系统远程故障诊断技术是将液压故障诊断技术与计算机网络技术相结合，利用网络系统建立诊断中心，在异地对远程现场液压系统实施监测，根据测试数据对设备运行状态进行分析诊断。它可以使故障诊断变得灵活方便，并能有效提高诊断的精确性及工作效率，减少维护时间和费用，同时实现资源共享。

1.4 液压系统故障检测与诊断新方法

液压系统故障诊断技术中基于知识的方法的研究及应用较多采用故障树（Fault Tree，FT）分析方法、人工神经网络（Artificial Neural Network，ANN）方法、专家系统（Expert System，ES）方法、模糊数学方法等单一诊断方法，但这些诊断方法存在诸多不足和局限，通用性差，而基于以上方法融合的智能诊断方法可充分发挥各自优势、克服各自的缺陷，将成为今后较长一段时间的研究热点。

1.4.1 神经网络技术方法

人工神经网络是指一种旨在模仿人脑结构及其功能的信息处理系统。它的研究始于 1943 年，心理学家 W. S. McCulloch 和数学家 W. Pitts 总结了生物神经元的一些基本生理特征，提出了人工神经元的数学描述与结构，即 MP 模型。1949 年，心理学家 Hebb 提出了神经元之间突触强度调整的假设，为构造有学习功能的神经网络模型奠定了基础。1957 年，Rosenblatt 提出了感知机模型，并首次把神经网络理论付诸工程实践，主要用于模式识别、联想记忆等方面。1961 年，B. Widrow 和 Hoff 提出了自适应线性单元网格，它可用于自适应滤波、预测和模式识别。1969 年，人工智能专家 M. Minsky 和 S. Papert 出版了影响很大的《Perception》一书，指出单层感知器只能用于线性问题的求解，而对于像 XOR（异或）这样简单的非线性问题却无法求解，这一论断导致神经网络研究陷入了长达 10 年的低潮期。

在这个低潮期，仍有许多学者继续进行探索，并取得了一些重要成果。芬兰的T. Kohonen教授提出了自组织映射理论，美国Grossberg教授提出了自适应共振理论ART，日本学者福岛邦彦提出了认知机模型。这些研究成果对以后神经网络的研究和发展都产生了重要影响。

20世纪80年代，神经网络的研究又获得了重大突破，其标志是1982年美国加州理工学院生物物理学家J. J. Hopfield发表了著名的“Hopfield模型”理论。这是一个非线性动力系统的模型，他在这种网络模型的研究中，首次引用了网络能量函数的概念，并给出了网络稳定性判据。1984年，Hopfield又提出了用运算放大器实现该网络模型的电子线路，为神经网络的工程实现指明了方向。继Hopfield的文章之后，很多学者对该网络进行了比较深入的研究和改进，Hinton等人提出了大规模并行网络学习机，并明确提出了隐单元的概念。他们用统计物理学的概念和方法来研究神经网络，并提出了被称为Boltzmann机的神经网络，其学习过程采用模拟退火技术，有效地克服了Hopfield网络存在的能量局部极小问题。

此后，许多科研工作者提出了多种具备不同信息处理能力的神经网络模型。神经网络已被应用到各个领域，并在智能控制、模式识别、故障诊断、计算机视觉、自适应滤波和信号处理、非线性优化、自动目标识别、连续语音识别、声呐信号的处理、知识处理、传感技术、生物医学工程等方面取得令人鼓舞的进展。神经网络涉及的知识面广，并且在人们逐步对它的数学基础进行研究的过程中，它也逐渐开始从其初始的生物背景中脱离开来，形成了一种真正意义上的多学科交叉的边缘学科。这样使得神经网络技术不仅沿着自身理论研究的道路深入下去，更形成了与许多新兴学科相互结合融合的新热点，如同模糊逻辑、专家系统、进化计算、混沌和量子计算、自适应、自组织等理论的结合。

神经网络技术的研究热潮的形成从根本上说是由其自身的优越性决定的。神经网络至少在如下两个方面是十分诱人的：

1）神经网络的本质是非线性系统，具有充分逼近任意复杂非线性关系的能力，加之其自学习和自组织的能力，使得自动知识获取成为可能，为人们进一步研究智能化机器提供了条件。

2）神经网络的并行处理能力、分布存储和容错性、信息处理和存储的合一性、鲁棒性等特点使其有可能成为新一代计算机的体系结构。

1.4.2 支持向量机方法

诞生于20世纪70年代的统计学习理论系统地研究了机器学习问题，对有限样本情况下的统计学习问题提供了一种有效的解决途径，弥补了传统统计学的不足。与传统的统计学相比，统计学习理论着重研究有限样本情况下的统计规律和学习方法，在这种体系下的统计推理不仅考虑了对渐进性能的要求，而且追求得到现有信

息条件下的最优解。其核心内容包括：基于经验风险最小化准则的统计学习一致性条件；统计学习方法推广性的界；在推广性的界的基础上建立的小样本归纳推理准则；实现新准则的实际方法。其中最有指导性的理论结果是推广性的界，与此相关的一个核心概念是 VC 维（Vapnik-Chervonenkis Dimension）。

统计学习理论系统地研究了对于各种类型的函数集，其经验风险和真实风险之间的关系，即推广性的界。关于两类问题，结论是：对函数集中的所有函数，经验风险 $R_{emp}(\omega)$ 和真实风险 $R(\omega)$ 之间至少以 $1-\eta$ 的概率满足如下关系

$$R(\omega) \leqslant R_{emp}(\omega) + \sqrt{\frac{h(\ln(2n/h)+1) - \ln(\eta/4)}{n}} \tag{1-1}$$

式中，h 是函数集的 VC 维；n 是样本数；η 是置信范围区间。

这一结论说明了学习机器的真实风险由两部分组成：一部分是经验风险（训练误差），另一部分称为置信范围，它与学习机器的 VC 维 h 及训练样本数 n 有关，可以简单表示为

$$R(\omega) \leqslant R_{emp}(\omega) + \Phi(h/n) \tag{1-2}$$

它表明在有限训练样本下，学习机器的 VC 维越高（复杂性越高）则置信范围越大，导致真实风险与经验风险之间可能的差别就越大。这就是为什么会出现过学习的原因。机器学习过程不但要使经验风险最小，还要使 VC 维尽量小，以缩小置信范围，才能取得较小的真实风险，从而对未知样本有较好的推广性。

早期的统计学习理论一直停留在抽象的理论和概念的探索中，而它在模式识别问题中往往趋于保守，数学上比较艰涩，直到 20 世纪 90 年代以前还没有提出能够将其理论付诸实践的有效方法，加之当时正处在其他学习方法飞速发展的时期，因此一直没有得到充分的重视。到 20 世纪 90 年代中期，随着其理论的不断发展和成熟，也由于神经网络等学习方法在理论上难以有实质性进展，该理论才受到越来越广泛的重视，并在统计学习理论的基础上又发展了一种新的学习方法——支持向量机。

支持向量机（Support Vector Machine，SVM）的诞生较好地解决了以往许多学习方法中小样本、非线性和高维数等实际难题，并克服了神经网络等学习方法中网络结构难以确定、收敛速度慢、易陷于局部极小值、过学习与欠学习以及训练时需要大量数据样本等不足，可以使在小样本情况下建立的分类器具有很强的推广能力，为液压系统故障的智能诊断提供了一种新的研究方法。

1.4.3 混沌分形理论方法

混沌是非线性动力学系统所特有的一种运动形式，广泛地存在于自然界、人类社会以及自然科学、社会科学等各个领域。混沌学与相对论、量子力学被誉为 20 世纪物理学的三大发现。

20世纪60年代，美国著名气象学家E. Lorenz在研究天气预报模型时发现，当选取一定参数的时候，一个由确定的三阶常微分方程组描述的大气对流模型，变得不可预测了，这就是有趣的“蝴蝶效应”。1963年，E. Lorenz形象地说：“巴西境内的一只蝴蝶扇动翅膀，可能引起得克萨斯州的一场龙卷风”。混沌现象的内涵为：简单确定性的非线性系统可以产生不稳定但有界的、貌似随机的不确定运动。

混沌吸引子具有自相似结构。混沌是在时间尺度内反映世界的复杂性，分形则是在空间尺度上反映世界的复杂性，二者之间有密不可分的内在联系：混沌是时间尺度上的分形；而分形则是空间尺度上的混沌。分形理论的发展为复杂的非线性系统的故障诊断提供了新的方法。

近年来，利用混沌的性质检测噪声背景中的故障特征信息成了故障检测与诊断领域的研究热点，国内外不少学者都进行了这方面的研究工作。姜万录等利用混沌振子的间歇混沌运动对小信号的敏感性及对噪声的免疫力来诊断齿轮单齿缺陷故障、轴向柱塞泵脱靴故障以及传感器周期干扰故障，取得了较好的效果。还有学者研究了碰摩故障转子的非线性特性，研究结果表明当转速较大时，系统具有丰富的非线性行为，并研究了系统的分叉和混沌等复杂行为。

1.4.4 Lyapunov指数及关联维数方法

混沌运动的基本特点是对初始条件极为敏感。两个很靠近的初始值所产生的轨道，随着时间推移按指数方式分离，Lyapunov指数就是定量描述这一现象的量，即Lyapunov指数是与相空间中不同方向上轨道的收缩和膨胀特征有关的一个平均量，每一个Lyapunov指数都可以看做相空间该方向上相对运动的局部变形的平均，同时又都是由系统长时间演变决定的。所以，无论从空间还是时间的意义上来说，Lyapunov指数不是局部量，而是整体特性的一个表示。在Lyapunov指数谱中，最小Lyapunov指数决定轨道收敛的快慢，最大Lyapunov指数则决定轨道发散即覆盖整个吸引子的快慢，即Lyapunov指数反映了运动系统在初始条件发生微小变化时所导致的在相空间内轨道不同方向上的变化程度，是用来刻画非线性系统混沌吸引子“奇异”程度的一个十分重要的参数，因而广泛地应用于刻画非线性系统的行为。

近几十年来，Lyapunov指数已经广泛地用于判别系统的混沌行为，进行故障诊断，并成为一种极其重要的判别工具。Lyapunov指数值表征了系统混沌的程度，为系统的预测和决策提供了重要信息。因而，Lyapunov指数作为混沌的一个极其重要的特征量用于系统的状态监测与诊断，是非常有研究意义的。

由于混沌态时系统的最大Lyapunov指数大于零，而当系统处于周期态时，最大Lyapunov指数等于零，利用这一点就可以确定系统的阈值：最大Lyapunov指数

的符号从大于零变为小于零的时刻，所对应的参数值就是阈值。所以，Lyapunov指数不仅是判别混沌存在与否的重要指标，也可以用来求取系统从混沌态跃变到周期态的阈值，为系统状态判断提供有效工具。

此外，由于设备结构及其工况的复杂性，其非线性因素的影响程度是不同的，因此有时很难仅通过频谱分析来对设备的工作状态及时准确地做出评价。近年来，众多学者利用关联维数分析方法的非线性分析能力，进行了大量的理论研究及工程应用。

1.4.5 信息融合技术方法

一方面，从诊断学角度来看，任何一种诊断信息都是模糊的、不确定的、不完备的。任何一类诊断对象，采用单一方面或单一信息域的信息来反映其状态行为都是不完整的。因此，在实际诊断过程中，只有从多方面或多信息域获得关于诊断对象的多维信息，才能对机器进行更可靠、更准确的诊断；另一方面，随着所获取诊断信息的增多，非常有必要引入和研究适用于故障诊断领域的信息融合技术，来充分挖掘信息的内涵，并对多源或多域诊断信息进行有效地融合利用，从而提高故障诊断的准确性、有效性和可靠性，如图1-1所示。这些信息从不同侧面、不同层次和不同程度反映了机器运行情况的好坏，如果能够充分加以利用，就可以有效地提高诊断的精度和可靠性。

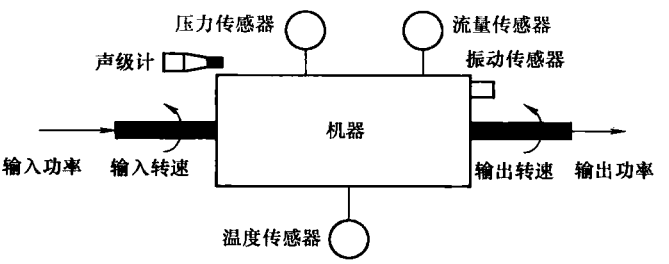

图1-1 机器运行过程中的各种诊断信息

信息融合技术的基本原理和出发点是：充分利用多个信息源，通过对它们所提供信息的合理支配和使用，把多个信息源在空间或时间上的互补信息按照某种准则进行组合，以获得对被测对象的一致性解释或描述，从而使该信息系统的性能优于各信息子集简单组合所获得的性能。把多传感器信息融合技术应用于故障诊断系统中，可提高系统故障的诊断精度，并在一定程度上获得精确的状态估计，从而能改善检测性能，提高诊断结果的置信度，同时能充分利用传感器资源，最大限度地发挥系统功能和提高信息资源的利用率。

信息融合技术在故障诊断中的应用方法很多，常用的信息融合方法有：贝叶斯参数估计、D-S证据理论、卡尔曼滤波、模糊逻辑理论和神经网络理论等。

目前，故障诊断方法及应用技术虽然已有了长足的发展，但对于大型、复杂系统的在线运行检测与故障诊断，需要从各种运行状态信息和已有的各种知识进行信息的融合、分析处理。利用信息融合技术可得到比单一信息源或单一信息域更精确、更合理的判断。随着科学技术的发展，新的、更有效的信息融合理论方法与技术将不断推出，基于多传感器信息融合技术的故障诊断方法将不断地完善并获得更为广泛的应用。

1.4.6 人工免疫系统方法

人工免疫系统（Artificial Immune System，AIS）是模仿生物免疫系统功能的一种智能方法，受生物免疫系统的启发，提供了噪声忍耐、无师学习、自组织、记忆等进化学习机理。结合分类器、神经网络和机器推理等系统的一些优点，提供了新颖的解决问题的方法和途径。其研究成果涉及控制、数据处理、优化学习和故障诊断等许多领域，已经成为继神经网络、模糊逻辑和进化计算后人工智能的又一研究热点。人工免疫系统的主要应用领域见表1-1。

表1-1 人工免疫系统主要应用领域

应用领域	示 例
自动控制	电压调节器的控制，复杂动力学系统自适应控制
动态规划	电网规划
系统设计	设计人工神经网络
组合优化	TSP问题，CDMA多用户检测
图像处理	图像分割，立体分配
数据处理	数据压缩与聚类
知识发现	数据库知识发现
机器人	多智能体决策系统，分布式自动机器人系统
故障检测与诊断	油井升降机，旋转机械在线故障诊断
计算机网络安全	病毒防护与入侵检测

如何利用免疫机制解决工程问题，关键之处还在于抽象，从具体问题出发，在免疫系统中寻求解决问题的灵感。新的人工免疫系统方法只能从工程问题与免疫系统的有机结合中凝练出来，脱离具体问题研究人工免疫系统，无论从医学角度还是工程角度都是没有意义的。相信随着医学免疫学和计算机科学技术的不断发展，人们对免疫系统的认识会进一步深化，现有的免疫机制会利用得更好，也一定会发现更多可借鉴的性质。

1.4.7 贝叶斯网络方法

由于现代设备的复杂性、测试手段的局限性以及知识表达的不精确性，使得故障征兆和故障原因之间的映射表现为随机性和不确定性。在设备故障诊断过程中，信息获取这一重要环节受到众多因素的限制，获得的信息是有限的和不全面的，信息可能是不完整和不精确的。因此，如何在不完整、不确定信息的条件下完成故障诊断的推理过程是故障诊断技术所面临的一个关键问题。研究表明，贝叶斯网络是解决这种问题的有效方法之一。

贝叶斯网络（Bayesian Network）是由 Pearl 于 1986 年提出的基于概率推理的图形化网络，而贝叶斯公式则是这个概率网络的基础。所谓概率推理就是通过变量信息来获取概率信息的过程，基于概率推理的贝叶斯网络是为了解决不确定和不完整性问题而提出的，它对于解决复杂设备不确定性和关联性引起的故障有很大优势。贝叶斯网络作为一种新兴的不确定性知识处理方法，有着坚实的概率论基础，并能够很好地表达知识结构，所以引起了人们的广泛重视，在很多领域的应用中都取得了令人满意的结果。尤其在故障诊断领域，它以坚实的理论基础、自然的表达方式、灵活的推理能力以及方便的决策机制，成为故障诊断等领域中的研究热点之一。在前人研究的基础上仍然有很大的发展空间，有重要的研究价值和很好的发展前景。

贝叶斯网络应用于故障诊断的优势如下：

① 贝叶斯网络有坚实的理论基础。

② 贝叶斯网络有成熟的概率推理算法。

③ 贝叶斯网络更适合于表达设备故障诊断问题。

④ 贝叶斯网络具有很强的学习能力。

1.4.8 小波理论方法

小波变换思想是由法国从事石油信号处理的工程师 Morlet 在 1984 年首先提出的。国内的小波分析研究始于 20 世纪 80 年代后期，当时大多是消化吸收国外的研究成果，所进行的主要是基础理论研究。进入 90 年代以来，国内一些高校相继开展了小波理论的工程应用研究，先后在电子技术、机械工程、信息科学、计算机科学、采矿工程、电力系统工程等领域开展了应用研究，取得了很多应用成果。

小波变换从基函数角度出发，吸取傅里叶变换中的三角函数基与短时傅里叶变换中的时移函数的特点，形成振荡、衰减的基函数（小波函数）。它在时域和频域同时具有良好的局部化性质。

小波变换以不同的尺度来观察信号，将信号分解到同一尺度的不同子频带中，既可看到信号的全貌，又可看到信号的细节，具有多分辨分析能力。它能实现用高

的频率分辨率分析信号的低频段，用高的时间分辨率分析信号的高频段，这与人们的视觉和听觉习惯是一致的。而且小波变换适当离散化后能构成标准正交系，在频域中能够实现互不相交的二进频带分割。小波包分析对小波变换中没有分解的高频段信号进行再分解，在不同的尺度上对各种频率作不同的分辨率选择，应用更加灵活。小波变换非常适用于探测正常信号中叠加的瞬态反常突变信息并展示其成分，利用观测信号的奇异性以及频率结构的变化进行故障诊断。

小波变换对设备的状态监测及早期故障诊断具有特别重要的意义，在这方面已有诸多应用。例如，对离心压缩机喘振故障的信号进行小波分析，捕捉喘振先兆信号的特征频率，并对信号进行关联维数分析，可以区分不同的故障类型；运用 Lipschitz 指数对突变信号的奇异性进行定量描述，可用于电液伺服阀多种故障并发时幅值大小的定量诊断；将小波包与模糊聚类神经网络相结合进行故障诊断；将小波分析方法与分形几何结合用来评估机械表面信号的特征等等。

1.4.9 频谱细化分析方法

频谱细化分析是20世纪70年代发展起来的一种重要的频谱分析手段，也是目前虚拟仪器（Virtual Instrument）中FFT分析仪必备的一项功能。进行频谱细化分析的主要目的在于提高频谱的分辨率，从而得到比一般FFT分析更加精细的频率成分信息，在对窄带信号分析时有重要的实际意义，并成为衡量频谱分析仪器分辨力的一项重要指标。

频谱细化是一项新技术，其主要目的是识别频谱图上的细微结构。从通常的FFT分析方法中我们已经知道，在频谱图上的有效频率分布范围是从0Hz到奈奎斯特频率f_N为止。由式（1-3）可知，谱线间隔Δf决定了频率分辨能力，即Δf越小，谱图的分辨力越高。Δf较大时，由于栅栏效应的影响，将有可能丢掉有用信息。

$$\Delta f = f_s / N \tag{1-3}$$

式中，N表示分析数据点数，f_s表示采样频率，且$f_N = f_s/2$。因此，要获得较高的分辨率可从下面两个方面进行。第一方面：降低采样频率f_s，Δf减小，但这样会降低奈奎斯特频率f_N，从而导致频率分析范围减小；第二方面：提高FFT计算长度N值，但这样要求较大的内存并增加了运算量。在内存和FFT计算长度N有限制的情况下，既要不降低频率分析范围f_N，而又要增加频率分辨率是矛盾的，为此出现了基于不同原理的频谱细化分析方法。

1.4.10 Hilbert-Huang 变换方法

Hilbert-Huang变换（Hilbert-Huang Transform，HHT）包括两个过程：经验模态分解（Empirical Mode Decomposition，EMD）和Hilbert变换。EMD方法基于信号的局部特征时间尺度，能把复杂的信号分解为有限的内禀模态函数（Intrinsic Mode

Function，IMF）之和，每一个 IMF 所包含的频率成分不仅与分析频率有关，而且最重要的是随信号本身变化而变化，因此，EMD 方法是自适应的信号处理方法。更重要的是对信号进行 EMD 分解后，使得瞬时频率具有了物理意义。这样就可以对每一个内禀模态函数进行 Hilbert 变换，从而可以求出每一内禀模态函数随时间变化的瞬时频率和瞬时幅值，这些瞬时频率和瞬时幅值可以揭示信号的内在特征，最后的结果是随时间和频率变化的幅值分布 $H(\omega, t)$，称为 Hilbert 谱。将 EMD 分析方法以及其对应的 Hilbert 变换称为 Hilbert-Huang 变换。这种方法的主要创新点在于提出了内禀模态函数，使得信号的瞬时频率具有了物理意义，从而能得到非平稳信号完整的时频分布。

该方法从根本上摆脱了以傅里叶变换理论为基础的其他时频分析方法的束缚，能很好地解释以傅里叶变换理论为基础的方法所不能解释的现象。但由于该方法近几年才提出，基本上还停留在“经验”阶段，故在故障诊断领域应用时在其理论及算法的完善方面还有很多工作要做。

1.5 本书的主要内容

1）对 AR 模型进行了概述，对真空系统的重要元件——干式真空泵的轴承故障进行了深入的故障机理分析。对频谱估计的几种方法进行了系统的研究，提出了基于 AR 模型最佳阶次选择的功率谱分析方法。通过泵的轴承故障诊断实验分析证明，该方法能有效地提取轴承故障的特征频率。

2）研究了时域和频域分析方法的基本理论，分析了传统频谱分析方法的不足，提出了频谱细化分析的解决方法，对几种常用的频谱细化方法进行了比较。最后通过实验证明，小波变换频谱细化方法以及 FFT-FS 频谱细化方法对真空泵的轴承故障诊断有较高的准确性。

3）对 Hilbert-Huang 变换方法进行了概述，研究了 HHT 的基础理论。归纳总结了 HHT 方法存在的主要问题，针对采样率过低造成的对经验模态分解（EMD）算法的影响，提出了 EMD 的改进算法。提出了基于 Hilbert-Huang 变换的故障特征提取方法。通过干式真空泵的故障诊断实验，对基于 Hilbert-Huang 变换的故障特征提取方法和传统的 Hilbert 变换包络解调方法进行了比较，证实了 Hilbert-Huang 变换在故障特征频率提取方面具有更高的分辨率和准确性。

4）概述了振动监测技术的相关理论，研究了旋转机械故障特征提取技术。基于 Morlet 复解析小波变换的正交性，提出一种基于小波簇的带通滤波和包络解调新方法。通过合理地选择小波参数，用多个单 Morlet 小波组成的小波簇可构成具有零相移、平顶通带及快速衰减过渡带特性的带通滤波器，这种方法将信号高频带通滤波和 Hilbert 变换两个步骤合二为一，用于提取振动信号的高频谐振成分。通过对

干式真空泵故障和轴向柱塞泵的诊断实验，证实了该方法能有效地提取故障特征频率，缩短运算时间，提高故障诊断的实时性。

5）对混沌及分形的性质进行了阐述，对关联维数计算过程中的几个参数的选择问题进行了系统探讨，提出通过利用该理论计算的泵出口压力信号的关联维数进行液压泵故障诊断的方法。最后通过实验测得的压力信号进行关联维数分析发现，故障信号的关联维数低于正常信号，可利用该性质作为故障判定的依据。

6）阐述了 Lyapunov 指数的计算方法（QR 分解法）及其改进算法，计算出了杜芬方程混沌系统的最大 Lyapunov 指数，有效确定了系统阈值。提出了基于最大 Lyapunov 指数分析的故障诊断方法，通过对泵出口压力信号最大 Lyapunov 指数的计算结果作为判断系统是否发生故障的依据。

7）分析了当前油液污染检测方法的不足，通过对油液污染控制理论的研究和油液污染在线监测系统的分析，研制了一套基于 MCGS 组态软件的油液污染度在线监测系统。该系统实现了压差数据的采集、存储、超限报警等功能，并能给出污染度等级检测结果报告。通过利用标准污染度的油液进行标定实验，建立了该系统的污染度数学模型。通过对实际油液进行在线监测实验，验证了该模型的正确性。

8）阐述了小波神经网络的分类、结构及学习算法，并与传统的 BP 网络进行了对比分析。提出了松散型小波神经网络和紧凑型小波神经网络两种故障诊断方法，利用两种方法分别对液压泵进行故障诊断实验，均取得了较好的诊断效果。

9）对信息融合技术的原理和方法进行了系统阐述，重点研究了证据理论方法。针对传统诊断方法存在的缺陷，提出了证据理论和神经网络相结合的智能故障诊断方法，实现了二者的优势互补。利用液压泵典型故障的诊断实验证明，该方法对液压泵常见故障具有良好的诊断效果。

10）在信号处理方面，研究了液压泵多传感器故障信号的采集和处理方法，对几种典型故障的振动和声音信号进行了功率谱分析，找到了故障发生的敏感特征频率成分。在特征提取方面，研究了幅值域和时频域的特征向量提取方法，详细实验分析了各种有量纲和无量纲幅值域特征指标对液压泵几种典型故障的敏感性。为解决特征向量集合维数过高的问题提出了主元分析的特征降维选择方法。为实现液压泵实时故障诊断，又研究了基于主元分析模型的故障检测方法，通过实验验证了该方法的应用效果。

11）阐述了人工免疫系统和支持向量机的原理及应用优势，对免疫机理的实值阴性选择算法以及支持向量机的分类方法进行了系统的研究。为解决典型故障样本严重不足及诊断知识发现困难的问题，又提出了免疫支持向量机复合的故障诊断方法。通过液压泵多故障模式的诊断实验验证了免疫支持向量机复合的故障诊断方法在提高故障诊断确诊率方面的优势。

12）针对特征向量集中存在冗余属性的问题，提出了基于粗糙集理论的启发

式属性约简算法，得到了“最佳属性约简”，有效地去除了冗余属性。以粗糙集理论为基础结合主元分析方法构造了多变量决策树，得到了最小诊断规则信息表。针对现代液压系统故障信息模糊性和不完备性的特点，提出了单传感器多域特征信息融合的贝叶斯网络故障诊断方法以及多源传感器信息融合和贝叶斯网络集成的故障诊断方法，通过液压泵多故障模式的诊断实验验证了这两种方法的有效性，与基于粗糙集理论的故障诊断方法和基于主元分析模型的故障检测方法比较，证实了该类方法更适用于液压泵的故障诊断。

参 考 文 献

[1] 张梅军．机械状态检测与故障诊断［M］．北京：国防工业出版社，2008.

[2] 张玉森．液压设备泄漏的预测及处理［J］．冶金设备，1990，5：47-49.

[3] 郑明．俄舰载机和航母的摇篮［J］．舰船知识，1997（6）：37-40.

[4] 周汝胜，焦宗夏，王少萍．液压系统故障诊断技术的研究现状与发展趋势［J］．机械工程学报，2006，42（9）：6-14.

[5] 姜万录，张淑清，王益群．液压泵故障的小波变换诊断方法［J］．机械工程学报，2001，37（6）：34-37.

[6] 王少萍，苑中魁，杨光琴．液压泵信息融合故障诊断［J］．中国机械工程，2005，16（4）：327-331.

[7] 张永祥，李军，孙云岭，等．基于遗传算法和峰度最佳的滚动轴承故障诊断［J］．振动与冲击，2007，26（8）：122-124.

[8] 吴定海，张培林，任国全，等．基于遗传算法的概率因果模型在液压泵故障诊断中的应用［J］．润滑与密封，2006，（5）：157-159.

[9] 边肇祺，张学工．模式识别［M］．2版．北京：清华大学出版社，2000.

[10] 潘泉，于昕，程咏梅，等．信息融合理论的基本方法与进展［J］．自动化学报，2003，29（4）：600-609.

[11] Forrest S，Per Elson A，Cherukuri R. Self non-self discrimination in a computer［C］//Proceedings of 1994 IEEE Computer Society Symposium on Research in Security and Privacy. Los Alamitos，CA，USA：IEEE Computer Society，1994：202-212.

[12] Pearl J F. propagation and structuring in belief networks［J］. Artificial Intelligence，1986，29（3）：241-288.

[13] Lam Wai. Abstraction in Bayesian Belief Networks and Automatic Discovery from Past Inference Sessions［C］//Proceedings of the 12th National Conference on Artificial Intelligence. Seattle，WA，USA，1994：257-262.

[14] 姜万录，王益群．混沌工程学研究的新进展［J］．液压气动与密封，2002，（2）：15-18.

[15] 姜万录，刘庆平，刘涛．神经网络学习算法存在的问题及对策［J］．机床与液压，2003，（5）：29-32.

[16] 姜万录，张淑清，王益群．基于混沌和小波的故障信息诊断［M］．北京：国防工业出版

社，2005.

[17] 姜万录，程晓盛，陈东宁．远程智能故障诊断技术的现状与展望［J］．机床与液压，2006（3）：237-240.

[18] 姜万录，李冲祥，刘继刚．多传感器数据融合技术的现状及展望［J］．机床与液压，2003（3）：16-18，249.

[19] 姜万录，孔祥东，王益群．系统故障检测与诊断技术的研究动态［J］．燕山大学学报．1999，23（2）：114-119.

[20] 姜万录，王益群，孔祥东，等．液压系统故障检测与诊断技术的新进展［J］．中国机械工程，1998，9（9）：58-60.

[21] Jiang W（姜万录），Spurgeon S K，Twiddle J A，et al. A Wavelet Cluster-based Band-pass Filtering and Envelope Demodulation Approach with Application to Fault Diagnosis in a Dry Vacuum Pump［J］. Journal of Mechanical Engineering Science，2007，221（11）：1279-1286.

[22] 刘思远，姜万录．主元分析方法在多元统计过程控制中的发展综述［J］．东北大学学报（自然科学版），2008，29（s2）：229-232.

第 2 章　基于 AR 模型的功率谱估计及在故障检测中的应用

本章对 AR 模型进行了简单的阐述。以真空系统的重要元件——干式真空泵为研究对象，对其轴承故障机理进行了深入的分析。介绍了几种常用的频谱估计方法，重点阐述了自回归模型分析方法的理论和算法的实现过程。针对旋转机械故障特征提取的问题，提出了基于 AR 模型最佳阶次选择的功率谱分析方法，最后通过实验研究表明该方法能有效地提取轴承故障的特征频率。

2.1　常用频谱估计方法

本节介绍了经典的傅里叶变换频谱估计技术和自回归模型、Prony 复极点模型、Capon 最大似然谱估计法三种现代频谱估计方法。

2.1.1　常用的几种谱估计方法

信号处理的核心，就是保证在信号受到干扰产生失真的情况下，正确恢复原有信号，提取有用信息。而功率谱（简称谱）估计就是信号处理的一个重要分支，它应用范围很广，日益受到各学科和应用领域的极大重视。它是在频率域研究随机信号的统计规律，其目的是为了估计出随机干扰信号并将其去除，提取有用信号，对语音、声呐、雷达等信号处理有着重要的意义，广泛应用于通信、控制、地球物理等领域，它的研究对象主要是零均值平稳高斯过程。

近几年，在信号功率谱密度估计方面出现了许多新的算法，这些新方法连同衍生出的各种改进算法不下几十种，统称为现代谱估计，它是相对经典谱估计方法而言的。其中比较有名的是：Levinson-Durbin 算法、Burg 算法的最大熵分析、正反向线性预测的最小二乘算法、自回归模型、滑动平均模型、自回归-滑动平均模型、Pisarenko 谐波分解法、Prony 复极点法、Prony 谱线分解法以及 Capon 最大似然估计法等。根据算法的基本属性，把这些算法进行归纳，如图 2-1 所示。

2.1.2　傅里叶变换技术

离散傅里叶变换（Discrete Fourier Transform，DFT）认为，有限长的数据段可看做无限长的取样序列进行加窗截断后的结果。不论是数据加窗还是自相关函数加窗，在频率域都会发生“泄露”现象，即功率谱主瓣的能量泄露到旁瓣中去，这

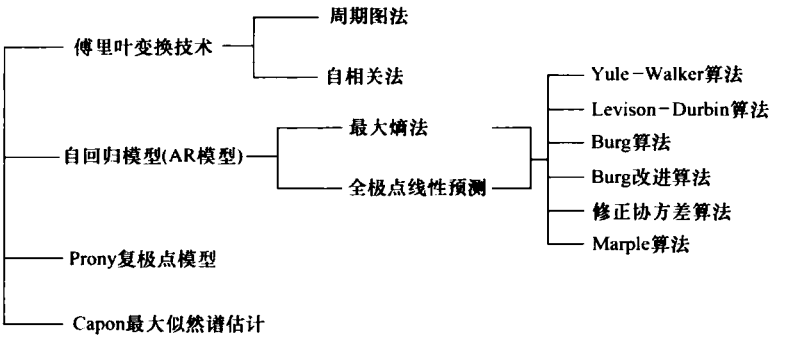

图 2-1　谱分析分类

样，弱信号的主瓣很容易被强信号的旁瓣淹没或畸变，造成谱的模糊与失真。为了降低旁瓣，很多学者在选择窗口函数的形式上和窗口函数处理方法上想办法，但是所有的旁瓣抑制技术都是以损失谱分辨率为代价的。谱分析应用中，谱分辨率和低旁瓣是同样重要的指标，在作 DFT 时，人们常在有效数据后面补一些零，使得补零后的数据长度 N 为 2 的整数次幂，以便于快速傅里叶变换，而那种认为在傅里叶变换之前对数据段补零可以改善周期图的谱分辨率是一种模糊的错误概念，因为补零后，虽然谱线能够增密，但因为补零没有增加任何新的信息，因此不可能提高分辨率。谱分辨率的极限只能由取样数据段的长度决定。

实际应用当中，经常遇到短数据的处理问题，如电子侦察中的瞬时测频、雷达和声呐中目标移动产生的多普勒频移、地物杂波环境的改变以及语言分析等，这些都是缓慢变化的时变谱过程，即非平稳过程，所有这些都需要一种短数据的实时谱估计方法。这就产生了下面的几种现代频谱估计方法。

2.1.3　自回归模型

1. 概述

为了克服经典谱估计的缺点，近年来在实现高分辨率谱估计技术方面取得了很大的进展，提出了许多功率谱估计的参数方法，也就是现代谱估计的基本方法。基本思想是，在进行谱估计的过程中对所观测的有限数据以外的数据不作任何确定性假设。根据一定的先验知识，采取外推或预测的方法，从观测的数据推求 $m \geqslant N$ 以后的数据。显然，在这种情况下，首先必须寻求一个产生随机信号的模型，通过观测数据把模型的参数估计出来，进而求得所需的功率谱。所以参数法是基于模型（信号参数模型）的功率谱估计方法。这种方法既不需要加窗、又不对相关函数做 $R_{xx}(m)=0$，$m>N$ 的假设，从而避免了功率泄漏，提高了分辨率。

系统的信号模型如图 2-2 所示，可认为所观测的数据 $x(n)$ 是由某输入序列

$u(n)$激励线性离散物理模型系统而得到的系统响应输出。

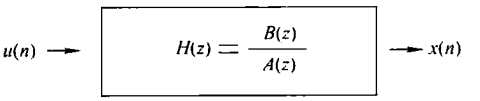

图 2-2 离散随机信号 $x(n)$ 的物理传输模型

离散系统的 z 传递函数可写成为

$$H(z)=\frac{X(z)}{U(z)}=\frac{B(z)}{A(z)}=\frac{\sum_{k=0}^{q}b_k z^{-k}}{1+\sum_{k=1}^{p}a_k z^{-k}} \tag{2-1}$$

式中，b_k是前馈（或滑动平均）支路的系数，称为 MA（Moving Average）系数；a_k是反馈（或自回归）支路的系数，称为 AR（Auto Regressive）系数；系统的输出序列 $x(n)$ 是被建模的离散随机信号。

相应的差分方程为

$$x(n)=-\sum_{k=1}^{p}a_k x(n-k)+\sum_{k=0}^{q}b_k u(n-k) \tag{2-2}$$

在功率谱估计中，若观测的数据 $x(n)$ 是平稳随机过程，则该系统的输入 $u(n)$也可以认为是平稳的，因而观测数据的功率谱为

$$p_x(e^{j\omega})=|H(e^{j\omega})|^2 p_u(e^{j\omega}) \tag{2-3}$$

一般信号模型的输入数据是不能观测到的，在已知模型参数或频响 $|H(e^{j\omega})|$的条件下，为了求得模型输出功率谱的估计值，最简单的方法就是假设输入 $u(n)$ 为零均值、均方差为 σ 的白噪声序列。离散时间白噪声自相关函数与功率谱分别为

$$R_{uu}(m)=\sigma^2\delta(m),\ p_u(e^{j\omega})=\sigma^2 \tag{2-4}$$

故最后求得的观测数据的功率谱为

$$p_x(e^{j\omega})=\sigma^2|H(e^{j\omega})|^2 \tag{2-5}$$

以参数模型为基础的谱估计方法一般按下列三个步骤进行：

① 为被估计的随机过程确定或选择一个合理的模型；

② 根据已知观测数据估计模型的参数；

③ 用估计得到的模型参数计算功率谱。

由式（2-1）可见，信号模型的传递函数是有理函数。当具有 q 个零点和 p 个极点称为自回归滑动平均模型，用 ARMA（p，q）表示。若 $q=0$，$b_0=1$，系统传递函数 $H(z)=1/A(z)$ 只有极点，称为自回归（AR）模型，用 AR(p) 表示。若 $A(z)=1$，则系统传递函数 $H(z)=B(z)$ 只有零点，称为滑动平均（MA）模型，

用MA（q）表示。在这三种模型中，AR模型得到普遍应用，其原因是AR模型的参数计算是线性方程，运算比较简单，它与建立在外推自相关函数时保持原概率空间的熵最大的最大熵法是等价的。同时很适于表示很窄的频谱，在谱估计时，由于递推特性，所以所需的数据很短，而MA模型表示窄谱时一般需要数量很多的参数。ARMA模型虽然所需的参数数量最少，但参数估计的算法是非线性方程组，其运算远比AR模型复杂。任意ARMA（p，q）信号模型可以用无限阶或阶数足够大的AR模型来表示。所以本章重点介绍利用现代谱估计方法中的AR模型进行功率谱估计的理论和算法。

2. 自相关函数和偏自相关函数

自相关函数（Auto-Correlation Function，ACF）是描述随机信号$x(n)$在任意两个不同时刻n_1，n_2的取值之间的相关程度。离散时间序列ACF是对自己的一个延时过程样本的相关。Box和Jenkins自相关规则是：给出时间序列$x(n)=1, 2, \cdots, N$，在k间隔内自相关函数被定义为

$$R_{xx}(k)=\frac{1}{N}\sum_{n=1}^{N-k}\left(x(n)-\overline{x(n)}\right)\left(x(n+k)-\overline{x(n+k)}\right)\ (k=0,1,2,\cdots,m,\ m<N) \tag{2-6}$$

式中，$\overline{x(n)}$是时间序列的平均值。

归一化的自相关函数称为自相关系数函数，由式（2-7）给出

$$\mathrm{ACF}(k)=r_k=\frac{R_{xx}(k)}{R_{xx}(0)} \tag{2-7}$$

这个定义被认为是有偏估计。如果式（2-6）中的分母项N被项$N-k$代替，则自相关函数变得无偏。与无偏估计相比，有偏估计是首选的，因为它趋于最小均方误差，并且能更快地衰减到零。ACF的值位于［-1，1］之间，为1表示完全相关，为-1表示反向完全相关。

1976年，Box和Jenkins曾经提出，对自相关函数ACF和偏自相关函数（Partial Auto-Correlation Function，PACF）时间序列的性质进行分析，可以为正确地选择时间序列模型类型和模型阶次提供信息。自相关函数是区别信号类型的一个非常有效的手段，只要信号中含有周期成分，其自相关函数在k很大时都不衰减，并具有明显的周期性。不包含周期成分的随机信号，当k稍大时自相关函数就将趋近于零。宽带随机噪声的自相关函数很快衰减为零，而窄带随机噪声的自相关函数则有较慢的衰减特性。

Broersen曾经指出AR信号的真实序列不仅取决于AR过程的特性而且依赖于使用的参数估计方法。AR参数估计方法有：Yule-Walker或自相关法，Burg或格型预测误差滤波器方法，无约束的最小二乘法（Least Squares，LS）或变协方差方法。本章选择Yule-Walker方法，然后用Levinson-Durbin递归算法计算AR模型系

数。Yule-Walker 方法将产生一个剩余方差的有偏估计，但已经证实偏差对阶次选择的影响是可以忽略不计的。此外，Yule-Walker 估计方法具有处理速度快的优点。

Yule-Walker 方法是基于一组线性方程，该组方程被称为 Yule-Walker 方程，它是联系自相关序列和 AR 模型参数的方程。可以通过计算含 $p+1$ 阶自相关系数的 Yule-Walker 方程，计算 $p+1$ 阶模型参数。p 被定义为 AR 模型的阶次，σ^2 为噪声方差。

$$R_x(m) = -\sum_{k=1}^{p} a_k R_x(m-k) + \sigma^2 \quad m=0 \tag{2-8}$$

$$R_x(m) = -\sum_{k=1}^{p} a_k R_x(m-k) \quad m \geqslant 1 \tag{2-9}$$

对于真实信号，由自相关函数的偶对称性可知 $R_x(m)=R_x(-m)$。式(2-9)可写成矩阵形式

$$\begin{pmatrix} R_x(0) & R_x(1) & R_x(2) & \cdots & R_x(p) \\ R_x(1) & R_x(0) & R_x(1) & \cdots & R_x(p-1) \\ R_x(2) & R_x(1) & R_x(0) & \cdots & R_x(p-2) \\ \vdots & \vdots & \vdots & & \vdots \\ R_x(p) & R_x(p-1) & R_x(p-2) & \cdots & R_x(0) \end{pmatrix} \begin{pmatrix} 1 \\ a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = \begin{pmatrix} \sigma^2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \tag{2-10}$$

偏自相关函数 PACF，可以看做是在自相关函数滞后 k 时受短滞后（1，2，…，$k-1$）影响并已经回归以后，仍然保持在滞后 k 的标准化自相关。基于AR(p)模型的偏自相关系数的 Yule-Walker 方程是

$$\begin{aligned} R_1 &= \phi_{k1} + \phi_{k2}R_1 + \cdots \phi_{kk}R_{k-1} \\ R_2 &= \phi_{k1}R_1 + \phi_{k2} + \cdots \phi_{kk}R_{k-2} \\ &\vdots \quad\quad \vdots \quad\quad \vdots \\ R_k &= \phi_{k1}R_{k-1} + \phi_{k2}R_{k-2} + \cdots \phi_{kk} \end{aligned} \tag{2-11}$$

式中，ϕ_{kk}是偏自相关函数。

Levinson 和 Durbin 导出了求解 Yule-Walker 方程的一种迭代方法，并且使用 Levinson-Durbin 递归算法可以解出 ϕ_{k1}，ϕ_{k2}，…，ϕ_{kk}的值。

$$\mathrm{PACF}(k) = \phi_{kk} = \begin{cases} R_1 & k=1 \\ \dfrac{R_1 - \sum_{j=1}^{k-1} \phi_{k-1,j} R_{k-j}}{1 - \sum_{j=1}^{k-1} \phi_{k-1,j} R_j} & k=2,3,\cdots,k \end{cases} \tag{2-12}$$

式中，$\phi_{k,j} = \phi_{k-1,j} - \phi_{kk}\phi_{k-1,k-1}$，$j=1$，$2$，…，$k-1$。

偏自相关参数的解法与自回归参数 a_k 的方法是相似的。偏相关系数可以被认

为是反向自回归系数 $-a_k$。偏自相关函数 PACF 可帮助确定 AR 过程的阶次，如果时间序列是 AR(p) 过程，那么比 p 阶更高阶次的信号 PACF 图收敛于零。

2.1.4 Prony 复极点模型

基于线性预测理论，用一个指数衰减线性组合模型来拟合一个等间隔的离散信号，其表达式为

$$x_n = \sum_{i=1}^{N} A_i [\exp(S_i \Delta t)]^n \qquad n = 0, 1, \cdots, M-1 \tag{2-13}$$

式中，x_n是时间序列取样值；$S_i = a_i + \mathrm{j}\omega_i$是复极点，$a_i$是衰减因子，$\omega_i$是自然频率；$A_i$是留数；$\Delta t$ 是取样间隔，M 为取样总数。

式（2-13）为 M 个非线性方程式，有 $2N$ 个（N 个 A_i，N 个 S_i）未知数。当 $M \geqslant 2N$ 时，Mittra 与 Blariculn 引用古老的 Prony 算法求解了这个非线性方程组，具体是将此非线性方程组转化为一个高次代数方程和两个线性方程组来求解，归纳为如下三个方程组：

$$x_n = \sum_{i=1}^{N} A_i Z_i^n \qquad n = 0, 1, \cdots, M-1 \tag{2-14}$$

式中，$Z_i = \exp(S_i \Delta t)$。

$$Z^N - \sum_{k=1}^{N} a_k Z^{N-k} = 0 \tag{2-15}$$

$$x_{N-k} = \sum_{i=1}^{N} a_i x_{N+k-i} \tag{2-16}$$

式中，$k = 0, 1, \cdots, M-N-1$。

式（2-15）、式（2-16）是包括 $M-N$ 个方程的线性递推方程组，含 N 个未知数 a_i，x_n为已知数，因此当 $M = 2N$ 时，利用一般矩阵求逆法，可以求得 a_i值；当 $M > 2N$，则可求得最小二乘法意义下的近似值。将求得的 a_i值代入式（2-15），解此高次方程，可得 N 个根 Z_i，于是被测信号的复极点 $S_i = (\ln Z_i)/\Delta t$ 即可求得。将各 Z_i代入式（2-14），式（2-14）就退化为线性方程组，利用其中任意 N 个方程可求得留数 A_i。最后，对式（2-14）的 $\hat{x}_n$值作傅里叶变换、求模，可得到功率谱密度。

$$P_{\text{Prony}}(f) = |\hat{X}(f)|^2 \tag{2-17}$$

式中，$\hat{X}(f) = \sum_{m=1}^{N} A_m \dfrac{2a_m}{[a_m^2 + (2\pi[f - f_m])^2]}$，$\omega_m = 2\pi f_m$。

从物理概念上说，Prony 技术是一种自适应处理过程，它适时地调整了指数衰减线性组合模型的各个参数与被测信号的拟合。与傅里叶周期图截然不同的是，周期图是以固定频率、固定数目的不衰减正弦波的线性组合来拟合。它的缺点与自回

归模型相同，即必须正确估计模型阶数，对噪声也比较敏感，不适合在低信噪比下工作。

2.1.5 最大似然谱估计法

由 Capon 提出的最大似然谱估计器（Maximum Like-hood Spectral Estimation）实质上是在最小均方意义下的有限时间脉冲响应（Finite Impulse Response，FIR）滤波器组，称为阵列—波数分析，又称Capon谱估计法。

根据信号的谱分布来自适应地更新 FIR 滤波器的权系数 A，以使在待求频率点上滤波器的频率响应为 1（无失真输出）和输出方差为最小，即在约束条件 $\overline{A}^{\mathrm{T}}E=1$ 之下，使 $\sigma^2=\overline{A}^{\mathrm{T}}R_{xx}A$ 为最小。最后导出结果为

$$A_{\mathrm{opt}}=\frac{R_{xx}^{-1}E}{E^{\mathrm{T}}R_{xx}^{-1}E} \tag{2-18}$$

$$\hat{P}_{ML}\approx\sigma_{MN}^{2}\Delta t=\frac{\Delta t}{E^{\mathrm{T}}R_{xx}^{-1}E} \tag{2-19}$$

其中，$E=[1,\ \exp(\mathrm{j}2\pi f_0\Delta t),\ \cdots,\ \exp(\mathrm{j}2\pi\ [p-1]\ f_0\Delta t)]^{\mathrm{T}}$

$A=(a_0,\ a_1,\ \cdots,\ a_{p-1})^{\mathrm{T}}$

R_{xx}为数据 x_n的协方差矩阵。

式（2-18）、式（2-19）两式分别为最佳权系数列向量和最大似然谱密度估值，式（2-19）中只要能求出自相关逆矩阵，就能计算出谱密度估值。最大似然谱估值 $\hat{P}_{ML}$与自回归谱估值 $\hat{P}_{AR}$存在如下的关系式：

$$\frac{1}{\hat{P}_{ML}(f)}=\frac{1}{p}\sum_{m=1}^{p}\frac{1}{\hat{P}_{AR}^{(m)}(f)} \tag{2-20}$$

其中，m 为自回归谱估值的阶数。

上式说明：$m=1,\ 2,\ \cdots,\ p$ 各阶自回归谱倒数的平均等于最大似然的倒数，这意味着：

① 最大似然谱的分辨率低于最大熵谱的分辨率，这是由于具有低分辨率的低阶最大熵谱和具有高分辨率的高阶最大熵谱的联合平均造成的。

② 最大似然谱在统计上具有更好的稳定性。

此外，Banggeroer 证实，在长数据段情况下，最大似然估计要比自回归谱估计具有较小的方差值。

2.2 AR 模型参数的计算方法及阶次选择

本节讨论 AR 模型参数的几种算法，阐述 AR 模型阶次选择的 FPE 准则，最后

用MATLAB仿真来比较不同阶次AR模型的频谱图，选出最佳阶次。

2.2.1　AR模型参数计算方法

1. Yule-Walker算法

用最小平方时间平均准则代替集合平均准则，有

$$\varepsilon = \frac{1}{N}\sum_{n=0}^{N+p-1}(e_p^+(n))^2 = \min \text{ 或 } \varepsilon = \sum_{n=0}^{N+p-1}(e_p^+(n))^2 = \min \tag{2-21}$$

其中，$e_p^+(n)$ 可由长度为 $p+1$ 的预测误差滤波器冲激响应序列 $a=(1, a_{p1}, a_{p2}, \cdots, a_{pp})$ 与长度为 N 的数据序列 $(x(0), x(1), \cdots, x(N-1))$ 进行卷积得到。

将 $e_p^+(n) = \sum_{i=0}^{p} a_{pi}x(n-i)$ 带入式（2-21），得

$$\varepsilon = \frac{1}{N}\sum_{n=0}^{N+p-1}(e_p^+(n))^2 = \sum_{i,j=0}^{p} a_{pi}\hat{R}(i-j)a_{pj} = Na^{\mathrm{T}}\hat{R}a \tag{2-22}$$

其中，$\hat{R}$ 是由取样自相关序列构成的 N 阶取样自相关矩阵，见式（2-23）。

$$\hat{R}(k) = \frac{1}{N}\sum_{k=0}^{N-1-k}x(k)x(n+k),\ 0 \leqslant k \leqslant N-1 \tag{2-23}$$

因此，用时间平均最小化准则同样可以导出Yule-Walker方程组，不过方程组中的 R 要用 $\hat{R}$ 取代。取样自相关矩阵 $\hat{R}$ 是正定的，因而能够保证所得到的预测误差滤波器是最小相位的，因而也能保证反射系数的模值都小于1，这是使滤波器稳定的充分条件。用Yule-Walker算法估计AR模型参数的具体步骤为

1）根据式（2-23）计算自相关函数。

2）用Levinson-Durbin算法求解Yule-Walker方程组

$$\begin{pmatrix} R_x(0) & R_x(1) & R_x(2) & \cdots & R_x(p) \\ R_x(1) & R_x(0) & R_x(1) & \cdots & R_x(p-1) \\ R_x(2) & R_x(1) & R_x(0) & \cdots & R_x(p-2) \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ R_x(p) & R_x(p-1) & R_x(p-2) & \cdots & R_x(0) \end{pmatrix}\begin{pmatrix} 1 \\ a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = \begin{pmatrix} \sigma^2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \tag{2-24}$$

3）用AR参数的估计值，可以计算功率谱

$$\hat{P}_{YW}(\mathrm{e}^{\mathrm{j}\omega}) = \frac{\sigma^2}{\left|1 + \sum_{k=1}^{p}\hat{a}_{pk}\mathrm{e}^{-\mathrm{j}k\omega}\right|^2} \tag{2-25}$$

2. Levinson-Durbin算法

用线性方程组的常用算法（例如高斯消元法）求解式（2-24），需要的运算量数量级为 p^3。但若利用系数矩阵的对称性和Toeplitz性质，则可构成一些高效算

法，Levinson-Durbin 算法是其中最著名、应用最广泛的一种。这种算法的运算量数量级为 p^2。这是一种按阶次进行递推的算法，即首先以 AR(0) 和 AR(1) 模型参数作为初始条件，计算 AR(2) 模型参数，然后根据这些参数计算 AR(3) 模型的参数……一直到计算出 AR(p) 模型参数为止。这样，当整个迭代计算结束后，不仅求得了所需要的 p 阶 AR 模型的参数，而且还得到了所有各低阶模型的参数。

定义 $a_m(k)$ 为 p 阶 AR 模型在阶次为 m 时的第 k 个系数，$k=1, 2, \cdots, m$；$m=1, 2, \cdots, p$；ρ_m为 m 阶时的前向预测的最小误差功率（$\rho_m=\sigma_m^2$）。

由 Yule-Walker 方程，当 $m=1$ 时，有

$$\begin{pmatrix} R_x(0) & R_x(1) \\ R_x(1) & R_x(0) \end{pmatrix} \begin{pmatrix} 1 \\ a_1(1) \end{pmatrix} = \begin{pmatrix} \rho_1 \\ 0 \end{pmatrix} \tag{2-26}$$

解出

$$a_1(1) = -R_x(1)/R_x(0) \tag{2-27}$$

$$\rho_1 = R_x(0) - R_x^2(1)/R_x(0) = R_x(0)[1 - a_1^2(1)] \tag{2-28}$$

定义初始条件 $\rho_0 = R_x(0)$，那么

$$\rho_1 = \rho_0[1 - a_1^2(1)] \tag{2-29}$$

再定义第 m 阶时的第 m 个系数，即 $a_m(m)$ 为 K_m，K_m称为反射系数，那么，由 Toeplitz 矩阵的性质，可得到如下 Levinson-Durbin 递推算法：

$$K_m = -\left[\sum_{k=1}^{m-1} a_{m-1}(k) R_x(m-k) + R_x(m)\right] \Big/ \rho_{m-1} \tag{2-30}$$

$$a_m(k) = a_{m-1}(k) + K_m a_{m-1}(m-k) \tag{2-31}$$

$$\rho_m = \rho_{m-1}[1 - K_m^2] \tag{2-32}$$

Levinson-Durbin 算法从低阶开始递推，直到阶次 p，给出了在每一个阶次时的所有参数，即 $a_m(1)$，$a_m(2)$，$\cdots$，$a_m(m)$，$m=1, 2, \cdots, p$。这一特点特别有利于选择 AR 模型的合适阶次。但由于进行自相关序列估计时，仍采用 0 到$N-1$以外的观测数据为零的假设，必然引入较大误差，尤其对短序列功率谱估计将导致谱线分裂与谱峰频率偏移现象。

3. Burg 算法

为了克服 L-D 算法中因估计相关函数给功率谱带来的影响，Burg 于 1968 年提出一种新的算法，其基本思想是利用线性预测器的前向和后向预测的总均方误差之和为最小的准则，直接从观测的数据中估计预测系数，进而通过 L-D 算法的递推公式求出 AR 模型优化的参数。

前、后向预测误差的定义式分别为

$$e_m^f(n) = x(n) + \sum_{k=1}^{m} a_m(k)x(n-k) \tag{2-33}$$

$$e_m^b(n) = x(n-m) + \sum_{k=1}^{m} a_m(k)y(n+k-m) \tag{2-34}$$

将式（2-31）分别代入以上两式，得

$$e_m^f(n) = e_{m-1}^f(n) + \rho_m e_{m-1}^b(n-1) \tag{2-35}$$

$$e_m^b(n) = e_{m-1}^b(n-1) + \rho_m^* e_{m-1}^f(n) \tag{2-36}$$

其中，$\rho_m = a_m(k)$，表示 m 阶预测器结构模型用格型实现时的反射系数 ρ_m 等于直接实现形式第 m 次预测系数。

按前后向预测误差均方（平方）误差的总和，有

$$E_m = \sum \{[e_m^f(n)]^2 + [e_m^b(n)]^2\} \tag{2-37}$$

将式（2-35）、式（2-36）代入式（2-37）并对反射系数求偏导数，且令 $\partial E_m / \partial \rho_m = 0$ 求得总平方误差为最小时的反射系数为

$$\rho_m = \frac{-2\sum_{n=m}^{N-1} e_{m-1}^f(n) e_{m-1}^{b*}(n-1)}{\sum_{n=m}^{N-1} \{[e_{m-1}^f(n)]^2 + [e_{m-1}^b(n-1)]^2\}}, \quad (m = 1, 2, \cdots, p) \tag{2-38}$$

式（2-38）分母中的两项分别是前向与后向最小平方误差，可以证明总的最小平方误差为

$$E_m = E_m^f + E_m^b \tag{2-39}$$

按 L-D 递推公式可求得

$$E_m = (1 - \rho_m^2) E_{m-1} \tag{2-40}$$

因此，Burg 算法步骤为：

1）根据前、后向预测误差的定义知道

$$e_0^f(n) = e_0^b(n) = x(n), \quad (n = 0, 1, \cdots, N-1) \tag{2-41}$$

这时均方差等于预测器平均输出功率，故有

$$\sigma_{w0}^2 = R(0) = \frac{1}{N}\sum_{n=0}^{N-1} x^2(n), \quad \sigma_{w0}^2 = E[e^2(0)] \tag{2-42}$$

2）按式（2-11）及式（2-38）和式（2-39）递推关系，估计 p 阶预测系数（AR 模型参数）及最小预测误差的均方值，即

$$a_p(p) = \rho_p \tag{2-43}$$

$$a_p(k) = a_{p-1}(k) + \rho_p a_{p-1}(p-k), \quad (k = 1, 2, \cdots, p-1) \tag{2-44}$$

$$E_P = (1 - \rho_p^2) E_{p-1} \quad E_p = \sigma_{wp}^2 \tag{2-45}$$

3）递推高一阶前、后向预测误差，即

$$e_p^f(n) = e_{p-1}^f(n) + \rho_p e_{p-1}^b(n-1) \tag{2-46}$$

$$e_p^b(n) = e_{p-1}^b(n-1) + \rho_p e_{p-1}^f(n) \tag{2-47}$$

4）求得的 AR 模型参数估值，得到功率谱估计

$$\hat{P}_{BU}(e^{j\omega}) = \frac{\hat{E}_p}{\left|1 + \sum_{k=1}^{p} \hat{a}_p(k) e^{-jk\omega}\right|^2} \tag{2-48}$$

4. Burg 算法的改进

众所周知，Burg 算法首先是从低阶开始，根据数据估计反射系数，然后用 Levinson 递推法计算预测误差滤波器（Prediction Error Filter，PEF）的系数，从而避免了直接计算相关值和矩阵求逆。而 Burg 算法中一阶反射系数 $a_1(1)$ 在计算功率谱密度（Power Spectral Density，PSD）中起着关键的作用。这是因为运用递推公式时，各阶 PEF 系数均与其有关。然而，Burg 算法中 $a_1(1)$ 的计算本身就有误差，结果使谱估计的峰值产生偏差，特别是当信号长度为 1/4 信号周期的奇数倍且初相位为 $\pi/4$（或其奇数倍）时最为严重。改进算法不直接计算一阶反射系数，而是通过二阶 PEF 系数再求一阶反射系数，结果使得到的一阶反射系数与初始相位无关，从而使谱峰偏差减小，改善了谱估计的质量。

由于一阶反射系数的误差是引起谱估计偏差的主要原因之一，因此从改进 $a_1(1)$ 的计算入手，将能够改善谱估计的性能。改进算法的基本思想是从二阶误差总功率着手，先计算二阶 PEF 系数 $a_2(1)$，$a_2(2)$，再计算 $a_1(1)$。二阶 PEF 输出误差功率为

$$\begin{aligned} E_2 = \sum_{n=2}^{N-1} \{[e_2^f(n)]^2 + [e_2^b(n)]^2\} = \sum_{n=2}^{N-1} \{&[x(n) + a_2(1)x(n-1) + a_2(2)x(n-2)]^2 \\ &+ [x(n-2) + a_2(1)x(n-1) + a_2(2)x(n)]^2\} \end{aligned} \tag{2-49}$$

同时采用两个使得 E_2 最小的必要条件 $\partial E_2/\partial a_2(1) = 0$，$\partial E_2/\partial a_2(2) = 0$。经推导可得关于 $a_2(1)$，$a_2(2)$ 的方程组

$$\begin{cases} c(1) + b(1)a_2(1) + c(1)a_2(2) = 0 \\ c(2) + c(1)a_2(1) + b(2)a_2(2) = 0 \end{cases} \tag{2-50}$$

其中

$$\begin{cases} c(i) = \sum_{n=2}^{N-1} [x(n+i-2)x(n-2) + x(n-i)x(n)] \\ b(i) = \sum [x^2(n+i-2) + x^2(n-i)] \end{cases} \tag{2-51}$$

由此解得

$$\begin{cases} a_2(1) = -\dfrac{c(1)[b(2) - c(2)]}{b(1)b(2) - c^2(1)} \\ a_2(2) = -\dfrac{b(1)c(2) - c^2(1)}{b(1)b(2) - c^2(1)} \end{cases} \tag{2-52}$$

利用 Levinson 递推公式得

$$a_2(1) = a_1(1) + a_2(2)a_1(1) \tag{2-53}$$

由式（2-53）可求出 $a_1(1)$，再利用式（2-52），得到

$$a_1(1) = \frac{a_2(1)}{1 + a_2(2)} = -\frac{c(1)}{b(1)} \tag{2-54}$$

改进算法计算步骤可归纳为

1）由式（2-51）~式（2-54）计算 $a_2(2)$，$a_2(1)$，$a_1(1)$。

2）当阶数大于 2 时，利用式（2-41）~式（2-47）递推计算反射系数和 PEF 系数，直到达到所需的阶数。

5. 修正协方差算法

确定 AR 模型参数的 Burg 方法，基本上是预测系数满足 Levinson 递推的附加约束的最小二乘算法。由于这一约束的结果，增加 AR 模型的阶次仅需要在各级最优化一个参数。与这种方法相比我们可以利用无约束改进协方差法（最小二乘算法）确定 AR 参数。

该算法的主要思路是为了摆脱因采用递推运算对确定预测系数的约束，让每一预测系数（模型参数）的确定直接与前、后向预测的总的平方误差最小（最小二乘法）联系起来。即总的平方误差：

$$\varepsilon_p = \sum_{n=p}^{N-1}\left[\,|e_p^f(n)|^2 + |e_p^b(n)|^2\right] = \sum_{n=p}^{N-1}\left[\left|x(n) + \sum_{k=1}^{p} a_p(k)x(n-k)\right|^2 + \left|x(n-p) + \sum_{k=1}^{p} a_p^*(k)x(n+k-p)\right|^2\right] \tag{2-55}$$

它与 Burg 方法有相同的性能指标。但是，并不为了求 AR 参数而把 Levinson 递推加入上式。令 $\partial\varepsilon_p/\partial a_p(k) = 0$ 可得到一组线性方程

$$\sum_{k=1}^{p} a_p(k)r_x(l,k) = -r_x(l,0) \quad l = 1,2,\cdots,p \tag{2-56}$$

其中，自相关 $r_x(l,k)$ 定义为

$$r_x(l,k) = \sum_{n=p}^{N-1}[x(n-k)x^*(n-l) + x(n-p+l)x^*(n-p+k)] \tag{2-57}$$

所得到的剩余最小二乘误差为

$$\varepsilon_p^{LS} = r_x(0,0) + \sum_{k=1}^{p} \hat{a}_p(k)r_x(0,k) \tag{2-58}$$

所以，可得改进协方差功率谱估计为

$$P_x^{LS}(f) = \frac{\varepsilon_p^{LS}}{\left|1 + \sum_{k=1}^{p} \hat{a}_p(k)e^{-j2\pi kf}\right|^2} \tag{2-59}$$

元素为 $r_x(l, k)$ 的相关矩阵不是 Toeplitz 阵，因此，不能利用 Levinson 算法求解。但是，相关矩阵的结构足以设计复杂性与 p^2 成正比的有效计算方法。Marple 于 1950 年设计了这样的算法。他的算法具有格型结构，利用了 Levinson 类型的阶递推和另外的时间递推。这种形式的修正协方差（无约束最小二乘法）方法也一直被称为数据未加窗最小二乘方法。

6. Marple 算法

Marple 算法不再利用 Levinson 递推公式，而采用精确的最小平方求解预测误差滤波。让每一预测系数（模型参数）的确定，直接与前、后向预测的总的平方误差最小联系起来。从而摆脱了因采用递推运算对确定预测系数的约束。总的平方误差的平均值是 AR（M）模型的参数的函数，若把它对各预测系数而非单一地对最末项求导数，并令其为零，则可得到一组线性方程。解此方程组得到的预测系数就是以平方误差最小为准则的最优预测系数。但由于方程组的系数矩阵（相关矩阵）不是托布利兹（Toeplitz）型，所以不能利用 L-D 算法求解。但是相关矩阵可以分解为两个 Toeplitz 矩阵乘积之和的形式。正是这种特殊结构，可经过一些公式变换推出类似于 Levinson 公式的一种广义递推算法，使其运算量大大减少而只与 M^2 成正比。

2.2.2 AR 模型阶次选择

模型阶次选择是 AR 功率谱估计中重要的一部分。AR 频谱的阶次是由分辨率和方差之间的折中得到的。阶次太低将会导致平滑的谱估计结果，掩盖好的谱峰，而阶次太高分辨率提高，将产生虚假谱峰，并且估计的方差也会增大。选择标准阶次的方法有 Akaike 信息量准则（Akaike Information Criterion，AIC），最终预测误差准则（Final Prediction Error，FPE），最小描述长度（Minimum Description Length，MDL），判别自回归传递函数准则（Criterion AR Transfer Function，CAT）和限定的信息标准（Finite Information Criterion，FIC）等。

FPE 标准选择 AR 模型阶次的过程是使单步预测误差的方差最小。其基本思想是用模型一步预报误差的方差来判定自回归模型阶数是否适用，如果某个适用的自回归模型是由某一阶次拟合得来的，则利用该模型对该阶次进一步预测，所得的预测误差必定是最小的。因此，预报效果的好坏，可以反过来作为模型拟合优劣的检验标准。一步预报误差的方差愈小，就认为模型拟合愈好。因此称 FPE 准则为最小最终预测误差准则，最佳的阶数就是最终预测误差方差到最小的阶数。

设随机序列$\{X_t, 1 \leqslant t \leqslant N\}$所适合的真实模型为 AR($p$) 模型，即

$$X_t = \varphi_1 x_{t-1} + \varphi_2 x_{t-2} + \cdots + \varphi_p x_{t-p} + a_t \tag{2-60}$$

其中，$E[a_t] = 0$，$E[a_t a_t] = \sigma_a^2$。

设 φ_j 的估计值为 $\hat{\varphi}_j(1\leqslant j\leqslant p)$，用 $\hat{X}_t(1)$ 表示 t 时刻的一步预报值，即对 t 时刻的预报值有

$$\hat{X}_t(1)=\hat{\varphi}_1X_t+\cdots+\hat{\varphi}_pX_{t-p} \tag{2-61}$$

可以证明，一步预报误差的方差为

$$E[X_{t+1}-\hat{X}_t(1)]^2\approx\left(1+\frac{p}{N}\right)\sigma_a^2 \tag{2-62}$$

式中，σ_a^2 是以 $\hat{\varphi}_j(1\leqslant j\leqslant p)$ 为参数的拟合模型残差的方差。

可以证明，当样本总量 N 充分大时有

$$E[\hat{\sigma}_a^2]\approx\left(1-\frac{p}{N}\right)\sigma_a^2 \tag{2-63}$$

式（2-63）表明，$\hat{\sigma}_a^2\Big/\left(1-\frac{p}{N}\right)$ 是 σ_a^2 的无偏估计。在式中用无偏估计来替代 σ_a^2，便可得到

$$E[X_{t+1}-\hat{X}_t(1)]\approx\left(1+\frac{p}{N}\right)\left(1-\frac{p}{N}\right)^{-1}\sigma_a^2 \tag{2-64}$$

对于以 $\hat{\varphi}_j(1\leqslant j\leqslant p)$ 为参数的 AR(p) 模型，应有

$$\hat{\sigma}_a^2=\hat{R}_0-\sum_{j=1}^{p}\hat{\varphi}_j\hat{R}_j \tag{2-65}$$

式中，$\hat{R}_0$，$\hat{R}_1$，…，$\hat{R}_p$ 是数据序列的样本自相关函数在不同滞后时的值。

综上所述，以 $\hat{\varphi}_1$，$\hat{\varphi}_2$，…，$\hat{\varphi}_p$ 为参数的 AR(p) 模型，其最终预报误差定义为

$$\mathrm{FPE}(p)=\left(\frac{1+\frac{p}{N}}{1-\frac{p}{N}}\right)\left(\hat{R}_0-\sum_{j=1}^{p}\hat{\varphi}_j\hat{R}_j\right) \tag{2-66}$$

或

$$\mathrm{FPE}(p)=\left(\frac{N+p}{N-p}\right)\hat{\sigma}_a^2 \tag{2-67}$$

由此可见，系数 $\frac{N+p}{N-p}$ 随着 p 的增大而增大，而模型 AR(p) 残差的方差 $\hat{\sigma}_a^2=\hat{R}_0-\sum_{j=1}^{p}\hat{\varphi}_j\hat{R}_j$ 开始随着 p 的增大而减小，但当 p 超过序列 X_t 的真正模型阶数 p_0 之后，$\hat{\sigma}_a^2$ 不会减小了，这时 $\frac{N+p}{N-p}$ 将起着主导作用。当阶数由低阶至高阶增加时，$\hat{\sigma}_a^2$ 开始随着阶数升高而下降；当 p 超过 p_0 以后，$\hat{\sigma}_a^2$ 值在某种意义上不会再减少。不难想到，使 FPE(p) 取最小值的那个 p 就可以判定为模型的最佳阶数，即

$$\mathrm{FPE}(p)=\min_{0\leqslant p\leqslant L}\mathrm{FPE}(p) \tag{2-68}$$

其中，L 为预先设定的模型阶数上界。在阶数上界范围内，FPE 会存在若干个极小值，其中最小值对应的阶数为 FPE 判阶准则给出的最佳阶数。显然，这样确定的最佳阶数与定阶上界有关，如果定阶上界选得过小，所得最合适阶数将会偏低；如果定阶上界选得过大，将加大计算量。因此，阶数上界的确定非常重要。目前人们只给出了样本长度 N 在 20～200 之间的 AR 模型阶次确定的经验准则（即定阶上界）。沈凤麟在《信号统计分析与处理》中指出，估计阶数的上界 L 与样本长度 N 之间的关系为：$L\approx\frac{N}{3}\sim\frac{N}{2}$或 $L\approx\sqrt{N}$，但文中既没有给出理论推导，也没有给出实际验证。赵联春等通过实验研究表明，将样本长度的平方根值$\sqrt{N}$作为滚动轴承 AR 模型的定阶上界，可以得出满意的 AR 模型分析结果。

综上所述，用最小 FPE 准则进行 AR 模型定阶和参数估计的步骤如下：

① 设定一个合适的模型阶数上限 L，根据经验知：$L\approx\frac{N}{3}\sim\frac{N}{2}$或 $L\approx\sqrt{N}$。

② 求序列$\{X_t,\ 1\leqslant t\leqslant N\}$的样本自协方差函数$\{\hat{R}_0,\ \hat{R}_1,\ \cdots,\ \hat{R}_m\}$。

③ 当 $1\leqslant p\leqslant L$ 时，依次求解最小二乘估计参数 $\hat{\varphi}_1,\ \hat{\varphi}_2,\ \cdots,\ \hat{\varphi}_p$和 $\hat{\sigma}_a^2$，并带入式（2-68）计算 FPE(p)。

④ 取最小 FPE(p) 对应的 p 作为模型的阶数，相应的 $\hat{\varphi}_1,\ \hat{\varphi}_2,\ \cdots,\ \hat{\varphi}_p$就是自回归参数的估计值，相应的 $\hat{\sigma}_a^2$就是一步预报误差。

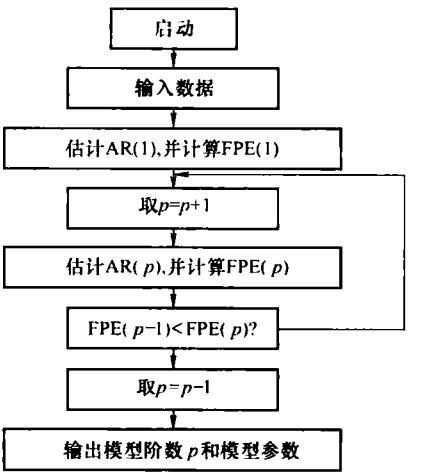

图 2-3 FPE 准则模型定阶流程框图

图 2-3 是 FPE 准则模型定阶的流程框图。

如果 FPE(p) 的数值从 $p=1$ 就开始上升，则可以判定模型阶数 $p=1$。若 FPE(p) 的值随着 p 增加而一直下降，则很可能是由于实际数据序列不宜采用 AR 序列来描述。如果在某一 p 的 FPE(p) 值下降很快，以后又有缓慢地下降，则可以将这个值 p 作为模型的阶。如果随 p 的增加 FPE(p) 的值上、下剧烈跳动，看不出最小值，这很可能是由于样本数据长度太小引起的，可增大样本长度后再进行定阶计算。

其他几种阶数选择准则公式如下

$$\mathrm{AIC}(k)=\ln(\sigma(k)^2)+(2k+1)/N \tag{2-69}$$

$$\mathrm{MDL}(k) = \sigma(k)^2\left(1 + \left(\frac{p+1}{N}\right)\ln(N)\right) \tag{2-70}$$

$$\mathrm{CAT}(k) = \left[\frac{1}{N}\sum_{j=1}^{k}\frac{N-j}{N\sigma(j)^2}\right] - \frac{N-k}{N\sigma(k)^2} \tag{2-71}$$

$$\mathrm{FIC}(k) = \ln(\sigma(k)^2) + \alpha\sum_{i=1}^{p} v_i,\ v_i = (N-i)/\{N(N+2)\} \tag{2-72}$$

式（2-69）~式（2-72）中，N 是采样数据长度；k 是试探模型阶数；σ^2 是预测误差的方差。

最佳模型阶数就是使式（2-69）~式（2-72）为最小值的阶数 k。预测误差的方差定义为

$$\sigma(k)^2 = \frac{1}{N-p}\sum_{n=p+1}^{N}\left\{x(n) + \sum_{i=1}^{p} a_i x(n-i)\right\} \tag{2-73}$$

2.2.3　AR 模型阶次功率谱的仿真算例

下面利用 Yule-Walker 算法对一个计算机仿真信号作基于 AR 模型的功率谱，通过比较不同阶次的基于 AR 模型的功率谱，来选择最佳阶次。分别作信号 $x = \cos(2\pi \cdot 200 \cdot t) + \mathrm{randn}(t)$ 的 10 阶、20 阶、30 阶的基于 AR 模型的功率谱，其频谱图如图 2-4 ~ 图 2-6 所示。

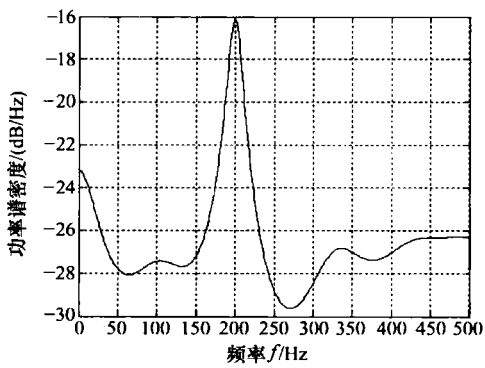

图 2-4　10 阶功率谱估计曲线

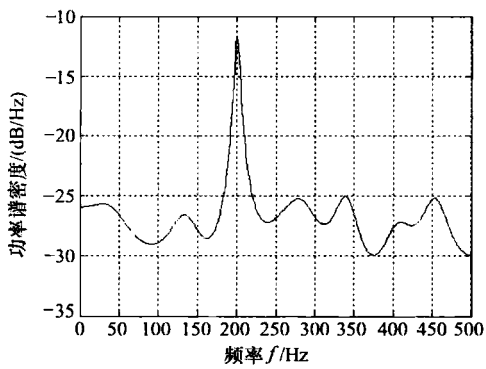

图 2-5　20 阶功率谱估计曲线

由图 2-4 ~ 图 2-6 三个频谱图可以看出，20 阶的基于 AR 模型的功率谱最能反映出信号的中心频率，阶次太低将会导致平滑的谱估计结果，分辨率降低，掩盖感兴趣的谱峰。而阶次太高分辨率提高，但由于谱线分裂将产生虚假谱峰，并且估计的方差也会增大。

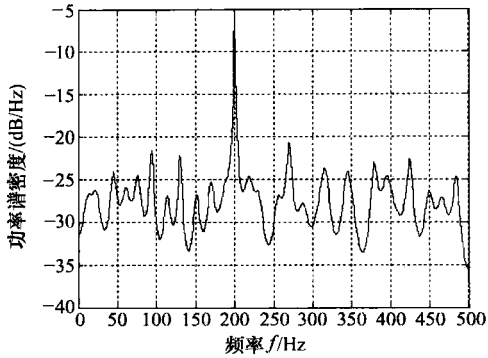

图 2-6 30 阶功率谱估计曲线

2.3 干式真空泵及其常见故障

2.3.1 干式真空泵

1. 干式真空泵的应用领域

在近二三十年来的高真空系统中，由高真空油扩散泵和作为前级泵的油封式机械泵组成的排气系统，在各工业部门得到了普遍应用。在这样的真空系统中不可避免地要发生油蒸气的返流、使真空容器遭到污染，而且在真空容器中进行作业所用的工艺气体会在油中溶解，工艺过程反应生成的颗粒状副产物也会在油中积聚，使油本身变质劣化。

近来，半导体芯片制造产业发展提出的要求，作为高真空泵不能有油蒸气存在，因此无油的涡轮分子泵、复合分子泵在该领域得到了广泛的应用。但是，前级泵还没有真正解决真空系统无油污染的技术难题。1984 年以前研制过一些实验室和专门用途的干式泵。但价格昂贵、运行间隙过小，很难在商业上推广应用。1984 年，日本首先研制了工业上实用的干式泵，将罗茨泵进行六级串联。之后又出现罗茨和爪型转子组合起来的无油泵。总之，相继出现了多种型式的干式泵，主要应用于半导体产业。

干式真空泵也称为无油真空泵。在泵的抽气流道中，不能使用任何油类和液体。排气口与大气相通，能连续向大气中排气。能产生 10^{-2}Pa 压力范围的真空。

2. 干式真空泵的种类

现在市场上提供的干式真空泵种类很多。可分为两类：容积式和动量传输式，如图 2-7 所示。容积式无油真空泵，如多级罗茨泵、爪型泵、往复式活塞泵、螺杆式泵和涡旋式泵等。这种干式泵的极限压力一般为 0.1 ~ 10Pa，抽速为 0.01 ~

0.04m³/s。动量传输式的无油真空泵，如涡轮式无油泵。排气侧与大气相接，在连续流状态下压缩比较高。它是一种粗抽泵，可从标准大气压抽到 10^{-2}Pa。在结构上采用径向和周向流泵的复合式结构，多级串联取气。这种泵的极限压力约为 10^{-2}Pa，抽速为 0.02 ~ 0.15m³/s。

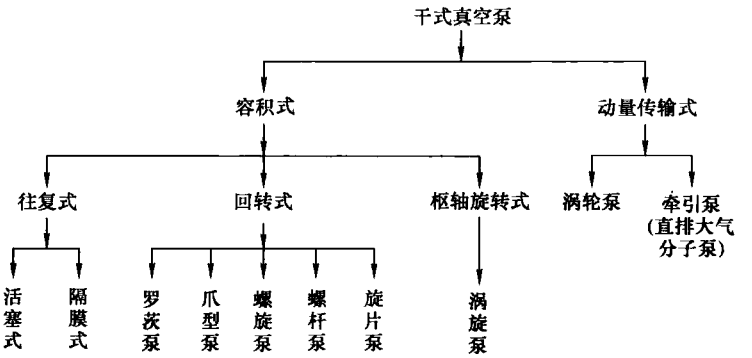

图 2-7　干式真空泵的种类

3. 干式真空泵的特点

各种干式泵的极限压力及其特点见表 2-1。

表 2-1　各种干式泵的极限压力及其特点

型　式	极限压力/Pa	特　点
罗茨泵	0.53	5 ~ 6 级串联，气冷式
多级螺杆泵	0.66	高速 1000r/min，小间隙 0.1mm
涡旋泵	0.133	小间隙 0.2mm
多级活塞泵	1.33	非常清洁
螺杆泵 + 碳旋片泵	0.066	有碳旋片的剥落
罗茨泵 + 爪型泵	0.93	1 级罗茨 + 2 ~ 3 级爪型
爪型泵	0.53	2 ~ 4 级爪型泵
分子牵引泵 + 膜片泵	1.33×10^{-3}	高压时流量低
膜片泵	665	不耐腐蚀，寿命低
涡轮泵	0.133	高速 30000r/min

现将这些泵的构造和抽气特性概略地介绍如下：

（1）多级罗茨真空泵　罗茨式是最早出现的干式真空泵，在设计理念上就是多个罗茨泵的叠加。这种结构使得气体通路长而复杂，导致冷凝物的堆积，同时被化学气体腐蚀的可能性大大增加。由于是多级设计，级与级之间又多采用密封，从

而使得维修工作比较麻烦。

图 2-8a 所示为三级罗茨泵的构造，各级转子由中间壁来隔离，形成各级的泵腔，上一级的排气口连到下一级的进气口，各级串联应用，各级转子的直径和形状是相同的，而各级转子的厚度有时是不同的，向高压侧（低真空端）方向变薄。为了增加压缩比，使用图 2-8b 所示的气冷式三叶转子。为了防止轴承和齿轮的润滑油向泵腔内返流，多级罗茨泵的泵腔和齿轮箱之间隔开或用迷宫式结构加以密封。为了提高无油的程度，齿轮箱也有另外用真空泵排气的情况。

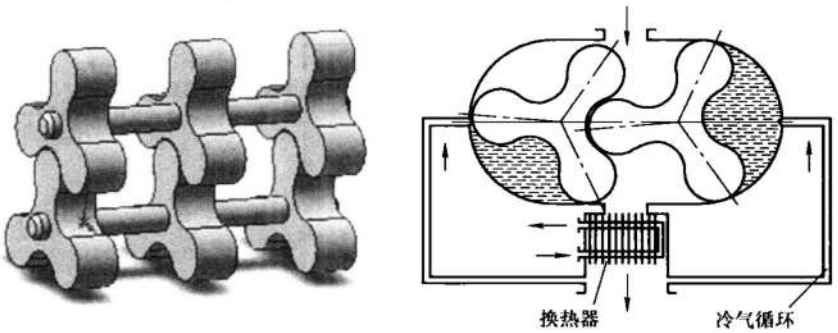

图 2-8 三级罗茨真空泵

（2）多级爪型真空泵 多级爪型真空泵的结构如图 2-9a 所示，它采用了形状复杂的爪型转子。这种泵也类似罗茨泵型式，两个转子与泵体之间形成泵腔的抽气容积，吸气口和排气口是固定在上下端盖的侧面上，由转子旋转过程中自动开关。沿轴向逆流少，如图 2-9b 所示。因此在高压区它的压缩比要比罗茨泵的压缩比高。由于这种泵的吸气口和排气口安置在泵腔的侧壁上，多级连接起来很方便，气道流畅，泵内腔压力变化平缓，有利于防止可凝性气体的凝结。为了防止可凝性气体在泵内的凝结，也要向泵腔内通净化气体。

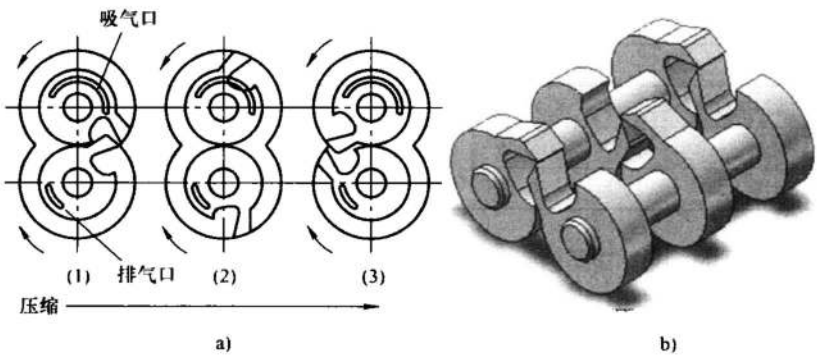

图 2-9 爪型真空泵

（3）螺杆式真空泵　干式螺杆真空泵是20世纪90年代初期出现的一种理想的泵种，其结构紧凑，抽速大，真空度高，可直排大气，工作部件无摩擦，寿命长。在螺杆式压缩机中，螺旋转子的螺旋圈数在一圈以内，而螺杆真空泵的螺旋圈数如图2-10所示那样在2圈以上，这样可减少返流量，提高压缩比。

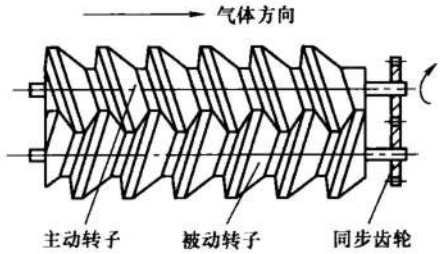

图2-10　螺杆配合工作示意图

干式螺杆真空泵的工作原理是依靠一对逆向旋转的螺杆保持一定间隙，由一对同步齿轮带动工作，所以螺杆不仅要与泵体内腔保持一定间隙，而且一根螺杆的外径与另一根螺杆的牙底径也需要保持一定的间隙配合。

（4）涡旋型真空泵　涡旋型干式真空泵根据其转动方式不同，分为两种型式：一种是一个涡旋固定不动（称为静涡旋），另一个涡旋围绕着它公转平动而不能自转（称为动涡旋）的公转型；另一种是两个涡旋同步同方向各自绕自身轴转动的回转型，它的两个涡旋都是动涡旋。

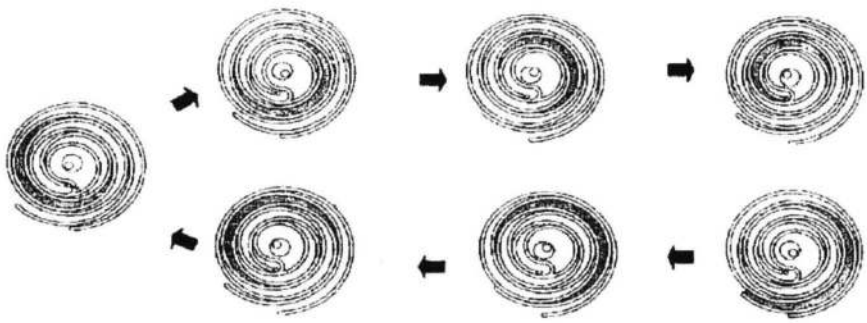

a)

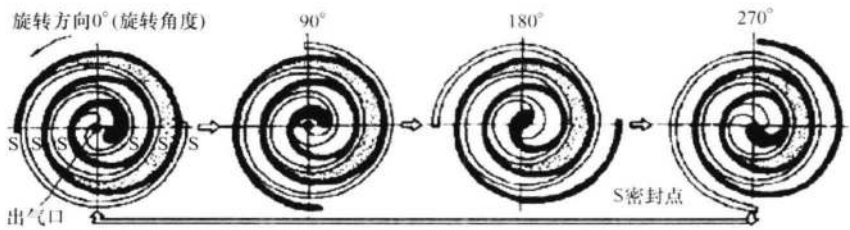

b)

图2-11　涡旋型真空泵的工作原理

a）公转型　b）回转型

涡旋型真空泵的工作原理如图 2-11 所示，气体从周边吸入向中心压缩，由中间排气，实现连续吸气、压缩和排气的整个抽气过程。这种泵压缩平稳、驱动力矩变化小，故振动小、噪声低，相邻的两个月牙腔容积的压差小，故间隙泄漏也小，而且端面有密封，可得到较高的压缩比。

（5）组合式真空泵　组合式真空泵指的是罗茨型干式真空泵和爪型干式真空泵的组合。

组合式（罗茨 + 爪）设计用罗茨来提高在较低压力下的抽气效率，用爪来提高在较高压力下的抽气效率。它的基本原理和气体通路与圆裂片式设计完全相同，如图 2-12 所示。也有些厂家将其最后一级改为星型设计，这样可以在旋转一圈中将气体分为 5 份，就像三圆裂片式设计可以将其分为 3 份。同样，在很多工艺中，组合式设计的每一级都需要较大流量的氮气起到稀释和隔离作用。

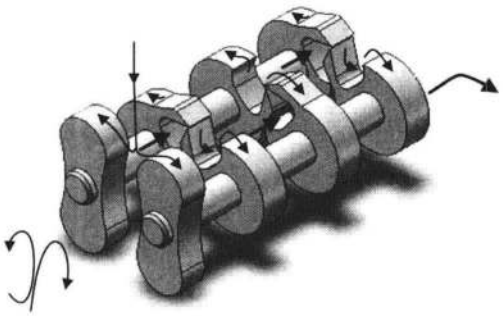

图 2-12　组合式真空泵

2.3.2　干式真空泵常见的故障形式

干式真空泵常见的故障特征包括以下几点：

① 转子不平衡：振动特征频率为 $1\times R$；振动方向为径向；振动超标是常遇到的现象。其中，R 为转子旋转频率。

② 转子不对中、转子弯曲、转子的磨损或腐蚀、转子上异物附着：振动特征频率一般为 $1\times R$，常出现 $2\times R$，有时为 $3\times R$ 和 $4\times R$；振动方向为径向和轴向；属于常见故障，相位比较稳定地变化，相位发生突变，然后稳定。

③ 滚动轴承磨损、表面损伤，包括外环、内环、滚动体、保持架等：振动特征频率同正常轴承的特征频率相同，但是幅值明显高，不宜检测，可以从转速和轴承的几何尺寸求得，同时常发生与轴承共振频率相关的高频（2 ~ 60kHz）振动，振动方向为径向和轴向，详见图 2-13。

外圈通过频率
$$f_o=\frac{z}{2}f_r\left(1-\frac{d}{D}\cos\alpha\right) \tag{2-74}$$

内圈通过频率
$$f_i=\frac{z}{2}f_r\left(1+\frac{d}{D}\cos\alpha\right) \tag{2-75}$$

滚动体通过频率
$$f_b=\frac{D}{d}f_r\left[1-\left(\frac{d}{D}\cos\alpha\right)^2\right] \tag{2-76}$$

保持架通过频率
$$f_c=\frac{1}{2}f_r\left(1-\frac{d}{D}\cos\alpha\right) \tag{2-77}$$

式中，f_r是轴承内圈的回转频率（Hz），$f_r = n/60$；n 是内圈转速（r/min）；d 是滚动体直径（mm）；D 是轴承节圆直径（mm）；z 是滚动体个数；α 是压力角（又称接触角）。

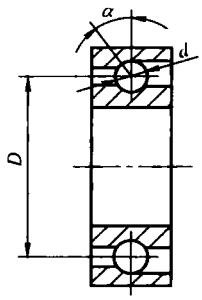

图 2-13　滚动轴承表面损伤故障的特征频率计算

④ 轴颈轴承松动：轴转频 R 的次谐波，为 $R/2$ 或 $R/3$，振动方向主要为径向。可能在运行时发生，或在高温时发生。

⑤ 齿轮安装误差、轮齿损伤或磨损：振动特征频率为 $1 \times R$；振动方向为径向和轴向；发生在齿轮啮合频率前后的边频带，说明有调制发生，边频间距对应于调制频率，需用窄带分析才能发现。

⑥ 部件松动：振动特征频率为 $2 \times R$；对应轴径轴承松动，也是次谐波和中间谐波。

以上介绍了干式真空泵常见的故障特征，其中滚动轴承发生故障的概率最高，下面就介绍一下滚动轴承故障振动诊断方法。

2.3.3　轴承常见故障及其诊断方法

滚动轴承是真空泵中常用的机械零件，也是最易损坏的元件之一。真空泵的许多故障都与滚动轴承有关，轴承性能与工况的好坏直接影响到与之相关联的轴以及安装在转轴上的齿轮乃至整台设备的性能，其缺陷会导致设备产生异常振动和噪声，甚至造成设备损坏。因此，开展对轴承的故障诊断具有重要意义。通过研究滚动轴承的振动可以很好地判断出轴承是否出现故障。下面介绍滚动轴承故障振动诊断方法。

1. *滚动轴承的振动机理*

滚动轴承是由内圈、外圈、滚动体和保持架四种元件组成的，结构如图 2-14 所示。通常，其内圈与机械传动轴的轴颈过盈配合连接，工作时随轴一起转动；而外圈安装在轴承座、箱体或其他支撑物上，工作时一般固定或相对固定。但也有外圈回转、内圈不动或内、外圈分别按不同转速回转的使用情况。滚动体是滚动轴承的核心元件，它使相对运动表面间的滑动摩擦变为滚动摩擦。滚动体的形式有球形、圆柱形、锥柱形、鼓形等。在滚动轴承内、外圈上都有凹槽滚道，它们

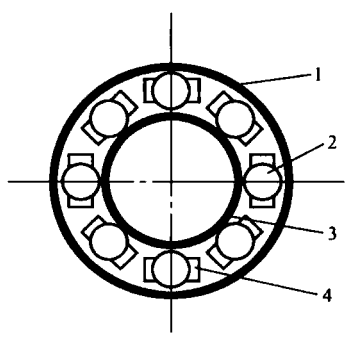

图 2-14　滚动轴承结构示意图
1—外圈　2—滚动体　3—内圈　4—保持架

起着降低接触应力和限制滚动轴承轴向移动的作用。保持架使滚动体等距离分布并减少滚动体间的摩擦和磨损。如果没有保持架，相邻滚动体将直接接触，且相对摩擦速度是表面速度的两倍，发热和磨损都较大。

滚动轴承在工作过程中所产生的振动主要是由轴承本身的结构特点、加工装配误差及运行过程中出现的故障等内部因素以及传动轴上其他零部件的运动和力的作用等外部因素共同作用引起的，原则上分为轴承本身结构特点及加工装配误差引起的振动和轴承运行故障引起的振动两种类型。前者不论轴承正常或异常，振动都要发生，它虽与轴承异常无关，但却决定了振动系统的传递特性；后者则反映了轴承的损伤状况。

（1）轴承本身结构特点及加工装配误差引起的振动　当轴承旋转时，滚动体便在轴承内、外圈滚道上滚动，即使对加工装配毫无误差的轴承来说，由于滚动体在不同位置时所受力的大小不同，同时承载的滚动体的数目也不同，这些轴承本身的结构特点造成承载刚度的变化，引起轴承振动。当轴的转速一定时，这一振动具有确定性质。轴承元件加工时留下的表面波纹度、表面粗糙度及几何误差以及装配误差等原因产生交变激振力使轴承系统振动，虽然这些加工装配因素造成的激振力大都具有周期性的特点，但由于实际构成因素十分复杂，各因素之间也不存在特定的关系，所以，总体上说这些激振力随机性较强，含有多种频率成分。因此轴承系统在这些激振力的作用下所产生的振动当然也具有多种频率成分并具有较强的随机性。

（2）轴承运行故障引起的振动　滚动轴承在运行过程中出现的故障按其振动信号特征不同可分为以下几种：

① 磨损失效：这是滚动轴承常见的一种失效形式，是轴承滚道、滚动体、保持架或座孔由于机械原因引起的表面磨损。一般来说，轴承表面磨损后产生的振动同正常轴承的振动具有相同的性质，即两者的波形都是无规则的，随机性较强。但磨损后的振动幅值明显高于正常轴承，因此对这种故障的诊断方法常常是监测振动信号的有效值和峰值，如果明显高于正常轴承，即判定为磨损。

② 疲劳失效：这是滚动轴承另一种常见的失效形式，滚动轴承的内外滚道和滚动体表面既承受载荷又相对滚动，由于交变载荷的作用，首先在表面下一定深度处（最大剪应力处）形成裂纹，继而扩展到接触表面使表层发生剥落或脱皮。

③ 腐蚀失效：轴承零件表面的腐蚀失效是由下面三种原因造成的：润滑油、水分或湿气的化学腐蚀；轴承表面有较大电流通过造成电腐蚀；轴承内圈在轴颈上，或外圈在座孔中产生微小相对运动而造成的微振腐蚀。

④ 断裂失效：过载运行可能会引起轴承零件断裂。磨削、热处理、装配不当会引起残余应力，工作时热应力过大也会引起轴承零件断裂。另外，装配方法、装配工艺不当，也可能造成轴承套环挡边和滚子倒角处掉块。

⑤ 压痕失效：压痕是在滚道或滚动体表面上产生局部变形而出现的凹坑，它既可能是由过载撞击，也可能是由装配敲击或异物落入滚道而形成的。

⑥ 胶合失效：胶合指滚道和滚动体表面由于受热而局部熔合在一起的现象。常出现在高速、高温、重载、润滑不良、起动加速度过大等情况下。

⑦ 保持架损坏：由于装配或使用不当可能会引起保持架变形，增加它与滚动体之间的摩擦，甚至使某些滚动体卡死不能滚动，也有可能造成保持架与内外圈发生摩擦等。这一损伤会进一步使振动噪声与发热加剧，导致轴承损坏。

2. *滚动轴承振动检测*

滚动轴承产生的振动信号中，含有丰富的有用信息。利用振动信息对滚动轴承进行故障诊断是十分有效的。机械设备及系统在运行过程中的振动特征信息常常反映系统的运行状态和变化规律，利用各种动态测试仪器分别采集、记录和分析设备的振动信号是机械系统状态监测和故障诊断的重要手段。

（1）传感器的选择　测振传感器的选择必须从两个方面考虑：首先要考虑被监测设备的机械方面的因素。由于滚动轴承在轴承与轴颈之间的正常间隙非常小，这样小的间隙，在振动位移的测点上是可以忽略的，所以宜采用电涡流位移传感器。对于那些具有较大绝对运动和一定的轴向相对运动的滚动轴承机器，采用复合式传感器比较理想。另外，某些机器在起动过程中，会出现较大的机壳和轴的振动，或者是共振，这是由于机器起动时，轴承支架的不正常的热膨胀、管道与其他和起动有关的干扰引起的。在这种情况下，选用速度传感器或加速度传感器进行监测是合适的。一般来说，在真空泵中，振动频率越高，其相应的振动位移振幅值也越小，而其振动加速度的幅值却存在一定的量级，此时用速度传感器和涡流位移传感器显得灵敏度不够，但加速度传感器比较能适应这种情况下的测量。

传感器的选择除了考虑被监测系统的机械因素外，还应注意如下几点：

① 用接触式传感器进行振动测量时，应尽量避免对被测试件增加质量负载引起负载效应，即传感器的质量应远小于被测物体或试件的质量，防止或避免因安装传感器造成被测物体或试件动态特性的改变。非接触式传感器无此缺点，但其灵敏度与初始安装间隙有关，使用时应加以注意。

② 测量前应估计出被测量的频率范围，并检查它是否落在传感器的幅频曲线的工作频带范围内，即幅频曲线的平直段内。当测量由多种频率成分组成的复杂波形时，必须选择相移与频率成线性关系的传感器，否则将会产生波形失真。

③ 事先估计被测系统的最大振级，并检查它是否超过所采用传感器最大冲击值的三分之一。一般说来低灵敏度传感器可用于高振动量级测量，反之，低量级振动应采用高灵敏度传感器，以提高信噪比。估计被测点振动方向，以便于正确安装传感器，减小横向灵敏度等带来的测量误差。如不能精确估计，可采用受方向影响较小的传感器。估计测量传感器的工作环境，如温度、湿度、磁场、声场等，并检

查所采用传感器能否满足使用环境的要求，是否要采用必要的防范措施。

（2）测定部位 测定部位选择的基本思路是选择在离轴承最近、最能反映轴承振动的位置上。一般来讲，若轴承座是外露的，测点位置可直接选在轴承座上；若轴承座是非外露的，测点应选择在轴承座刚性较好的部分或基础上。同时，应在测点处做好标记，以保证不会由于测点部位的不同而导致测量值的差异。测点的选择还要考虑环境因素，应避免选择高温、高湿度的地方为监测点，以保证监测的有效性。从信号的频段角度来考虑，对于低频段的确定性振动需同时测量径向的水平和垂直两个方向，有条件时还应增加轴向测量点；而对于高频的随机振动和冲击振动可以只确定一个方向作为测量点。这是因为低频信号的方向性强，而高频信号对方向不敏感的缘故。

（3）测定参数 根据滚动轴承的固有特性、制造条件、使用情况的不同，它所引起的振动可能是频率为1000Hz以下的低频振动，也可能是频率为1000Hz以上，数千赫兹乃至数万赫兹的高频振动，更多的情况是同时包含了上述两种振动成分。因此，通常检测的振动速度和加速度分别覆盖了上述的两个频带，必要时可用滤波器取出需要的频率成分。如果要在较宽的频带上检测振动级，则对于低频振动的轴承检测振动速度，而对于要高频振动的轴承检测振动加速度。

（4）测定周期 滚动轴承的振动检测可分为定期监测和连续在线监测两种。对于定期检测，为了及早发现轴承故障，以免故障迅速发展到更严重的程度，检测的周期应尽可能短一些。但如果检测周期定得过短，则在经济上可能是不合理的。因此，应综合考虑技术上的需要和经济上的合理性来确定合理的检测周期。连续在线监测主要适用于重要场合或由于工况恶劣不易靠近滚动轴承的场合，以及滚动轴承加速劣化的阶段，相应的监测仪器要复杂，成本也要高些。

3. 滚动轴承故障的主要研究方法

滚动轴承故障检测的目的是保证轴承在一定的工作环境（承受一定的载荷，以一定的转速运转等）下和一定的工作期间（一定的寿命）内可靠有效地运行，以保证整个机器的工作精度。与此目的相适应，轴承故障检测就是通过对能够反映轴承工作状态的信号进行采集、分析和处理来识别轴承的状态。所以，从一定程度上说，轴承故障检测就是轴承的状态识别。

传统的滚动轴承故障检测方法有频域分析法和时域分析法，它们对滚动轴承的分布式故障有很好的效果。但是对于局部缺陷，这些检测方法的应用效果不太理想，尤其是在故障发生的初期。近年来，新的检测方法不断涌现，滚动轴承振动信号处理及故障检测的发展趋势是采用时频域分析法。当前许多专家学者正在对小波分析和共振解调分析技术的理论进行更进一步的研究，并逐步应用到工程实践中。

目前研究工作主要集中在以下几个方面：

（1）振动信号分析检测

① 冲击脉冲法：冲击脉冲法（Shock Pulse Method，SPM）是在滚动轴承运转中，当滚动体接触到内外滚道面的缺陷区时会产生低频冲击作用，所产生的冲击脉冲信号会激起SPM传感器的共振，共振波形一般为20～60kHz，包含了低频冲击和随机干扰的幅值调制波，经过窄带滤波器和脉冲形成电路后，得到包含有高频和低频的脉冲序列。SPM方法根据这一反映冲击力大小的脉冲序列来判断轴承状态，目前在检测滚动轴承局部损伤故障方面SPM方法被公认为工程实用性最强。但这种固定中心频率和带宽的方法也有其局限性，因为滚动轴承局部损伤故障所激起的结构共振频率并不是固定不变的。在实际使用中，当背景噪声很强或有其他冲击源时，SPM检测效果很差，失去了实际意义。

② 共振解调法：共振解调技术是把低频重复冲击信号变换为重复出现的高频自由衰减振动，然后再变换成幅值和延续时间均得到放大的低频信号。当轴承某一零件表面出现损伤后，在承载运转过程中损伤点会撞击其他零件表面而产生冲击力，冲击力的强度及持续时间长短与轴承零件的相对运动速度、载荷等因素有关。损伤产生的冲击会激起系统的固有衰减振动。通常，脉冲力的带宽包含了轴承系统的各个固有频率，所以会激起系统的各个固有振动。固有振动的频率段一般很高，噪声影响小，因此在滚动轴承故障检测中经常利用固有振动作为检测的依据。根据具体情况，可选择某一高频固有振动作为研究对象，通过中心频率等于该固有频率的带通滤波器把该固有振动分离出来，然后通过包络检波器检波，去除高频振动的频率成分，得到只包含故障特征信息的低频包络信号，对其进行频谱分析便可检测出轴承故障类型。对包络信号进行谱分析可识别出冲击产生的频率，但是当出现谐波或由于包络信号存在幅值调制而引起和频、差频时，包络谱变得十分复杂，难以识别，而此时，包络谱单一谱峰的峰值也不能用于评价故障的严重程度。

（2）声发射技术检测　利用材料在力的作用下，产生变形或断裂时以弹性波释放应变能的原理进行检测。特点是特性频率明显、预报故障时间早，但需要昂贵的专用设备。

（3）油液分析检测　分析润滑油，了解轴承的润滑与磨损情况，采取措施控制故障。常用手段：理化指标分析、污染度测试、油液中金属含量分析、红外光谱分子结构分析和铁谱分析。通常需用多种方法进行综合判断，以提高检测的准确性。

（4）时域分析法　时域分析法是发展最早的一种检测方法。在时域检测中，普遍采用振动信号的基本数字特征及其概率分布特征来进行分析和检测，如振幅的有效值、峰值和无量纲因子判别方法等。

（5）频域分析法　频域分析方法可以对轴承早期故障进行精密检测。目前，应用比较广泛和成熟的是共振解调法。该方法以轴承系统的共振频带为检测频带，振动信号经放大、滤波和解调，获得脉动冲击的低频信号，以此作为分析的依据。

（6）时频分析法 由于滚动轴承的振动信号是一种时变信号，即随着时间的推移，信号的频率成分也相应地发生变化，采用普通的频谱分析技术（如短时傅里叶变换等）无法获得准确的轴承故障特征信息，对突变信号的探测能力较弱。由于小波分析在处理非平稳信号上表现出极大的优越性，从而使小波分析成为时频分析最为有力的工具，它克服了短时傅里叶变换分辨率不可变的缺陷，在时域和频域同时具有良好的局部化性质，成为轴承故障检测发展的热点。

（7）智能检测方法 近年来，人工智能和计算机技术迅速发展，在机械故障检测中的运用也越来越广泛。如日本东京工业大学的 Pellgchen 将遗传编程的思想引入滚动轴承的故障检测中，由 8 个原始特征选择产生若干复合特征，再根据“差别率”选择出最佳特征，识别出滚动轴承的内圈缺陷、外圈缺陷和滚动体缺陷三种故障，取得了良好的分类效果。专家系统、模糊集合、神经网络、概率计算和遗传算法统称为软计算，将软计算中各种方法集成，可以形成各种类型的混合系统。如用于检测的模糊专家系统、模糊神经网络等，使各种方法互相取长补短，相辅相成。

2.4 AR 模型功率谱估计方法在干式真空泵故障诊断中的应用

本节对干式真空泵的故障，运用 AR 频谱分析方法对故障泵的实验数据进行了分析。结果表明，基于 AR 模型的频谱分析方法对于干式真空泵的故障检测是非常有效的。

2.4.1 干式真空泵信号采集及故障诊断实验

1. 实验原理

本实验采用的干式真空泵为 5 级罗茨 + 爪型干式真空泵，泵体结构示意图如图 2-15 所示。高真空端腔体内是一级两叶罗茨转子结构，低真空端腔体内是四级爪型转子结构。泵的出口与低真空端相连，泵的每个转子都由固定于高真空端和低真空端的一对单列深沟陶瓷轴承来固定。为了防止泵工作温度过高，通过外部冷却水来调节控制泵体的温度。

实验中，用变频调速器控制电动机的转速，起到改变泵的转速的目的。振动传感器安装在靠近轴承的真空泵高真空端和低真空端。振动信号由振动传感器测量，然后经过嵌入式增益放大器适当放大，再通过采样频率为 40kHz 的数据采集卡转换得到数字信号。实验的测试系统图如图 2-16 所示。

2. 实验元件的选用

实验系统选用美国 NI 公司的 PCI-6034E 多功能数据采集卡。

PCI-6034E 主要参数：PCI 总线；单端 16 路模拟输入，分辨率为 16 位，采样

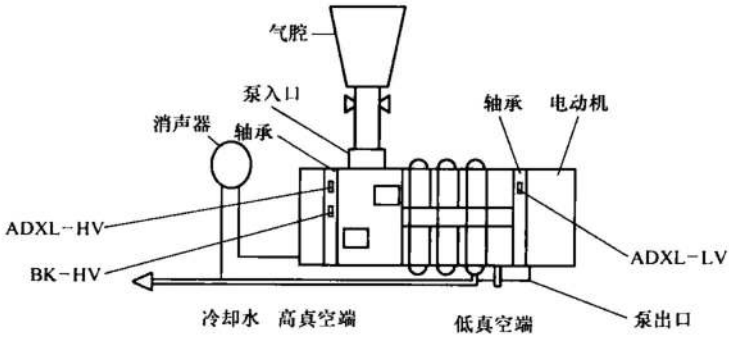

图 2-15　干式真空泵体结构示意图

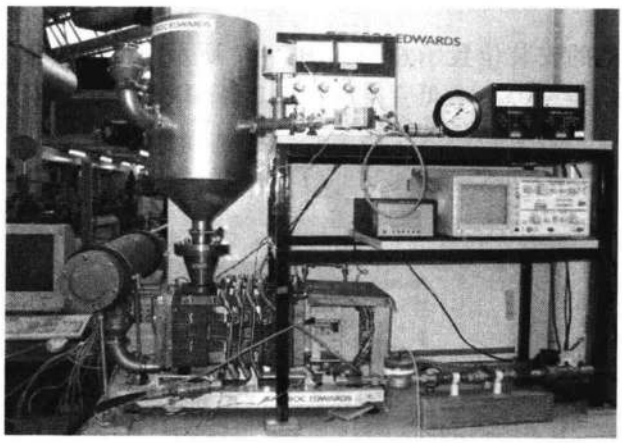

图 2-16　实验的测试系统图

率为 200kS/s，输入范围 ±(0.05 ~ 10)V;模拟输出 4 路，分辨率 16 位，输出电压范围 ±10V；数字 I/O 为 32 路；定时/计数器 2 个。

连接电缆选用 NI 公司的 R6868，此电缆两端各带一个 68 芯的连接器，分别与数据采集卡和端子板连接。I/O 端子板选用 NI 公司的 CB-68LP。传感器输入信号接入端子板输入端子，再经过连接电缆传输到数据采集卡。端子板参数如下：外形尺寸为 14.35cm × 10.74cm；68 个端子。

两种传感器选用的是加速度传感器 ADXL105 和 BK4370V。

加速度传感器 ADXL105 是一个装有微电容传感器和电信号调节电路集成芯片的微型机电装置。传感器带有一个嵌入式放大器，它通过调节外部电阻来改变输出范围，可后接一个一级或两级的有源滤波器。

加速度传感器 BK4370V 属于压电式传感器，装有 Brüel and Kjær 2692 前置放大器，该放大器可以把电荷信号转换为电压信号，且可调整它的增益，其通带范围

为0.1Hz～10kHz。该类型加速度传感器的优点是精确度高、适用于强噪声及高温环境。两个加速度传感器的特性见表2-2。

表2-2 加速度传感器的特性

加速度传感器特性	ADXL105	BK4370
测量范围	±5g	2000g以上
灵敏度	250mV/g	100pC/g
噪声密度	0.0225mg	0.02mg
温度范围	-40～85℃	-74～250℃
频率范围	0～10 000Hz	0.1～4800Hz
共振频率	7kHz	16Hz

加速度传感器的安装位置示意图如图2-17所示。在高真空端分别安装1台ADXL105和1台BK4370V，在低真空端安装1台ADXL105。

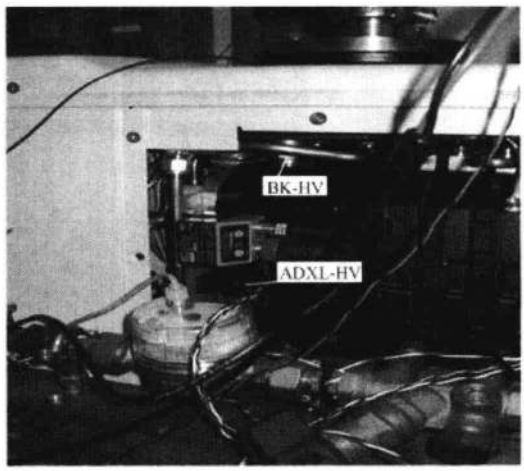

图2-17 传感器的安装位置示意图

2.4.2 基于AR模型的功率谱分析法的干式真空泵故障诊断

已知实验中轴转动频率f_r=105Hz，滚动轴承的参数为：D=46.2mm，d=9.525mm，z=9，α=24.97°。根据式（2-74）～式（2-77）以及各参数可得到：f_i=550Hz；f_o=482Hz；f_b=377Hz；f_c=42Hz。

实验中，采用三种测试工况：正常运行的泵1和泵2，引入轴承故障的泵1。

在一定的气体负载范围内（入口压力0～10000Pa），选用加速度传感器ADXL-HV采集正常泵1高真空端的无故障振动信号得到基于AR模型的功率谱图

如图 2-18 所示，最佳模型阶数为 30。从图中可以看出，无故障振动信号的典型频谱含有谐波振动信号及其倍频的谱峰，其频谱无显著差别。但是当在一个轴承上引入故障以后，其频谱就会有显著的差别。图 2-19 和图 2-20 所示分别为加速度传感器 ADXL-HV 采集泵 1 高真空端的故障振动信号的时域波形图和其功率谱图。在一定的气体负载范围里（入口压力 0～10kPa），真空泵有故障振动信号的基于 AR 模型的功率谱如图 2-21 所示，最佳模型阶数为 30。

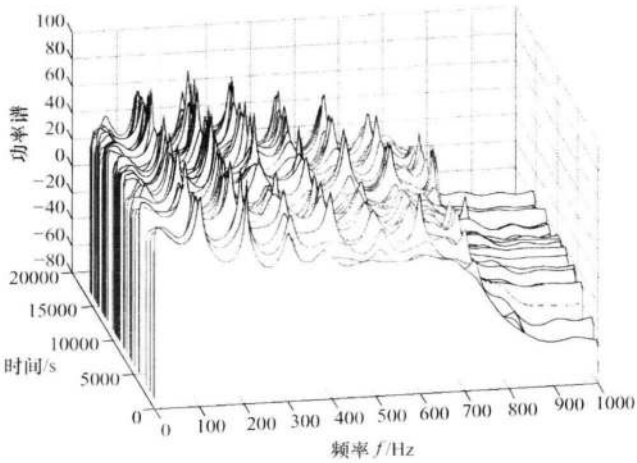

图 2-18　不同入口压力时无故障振动信号的功率谱

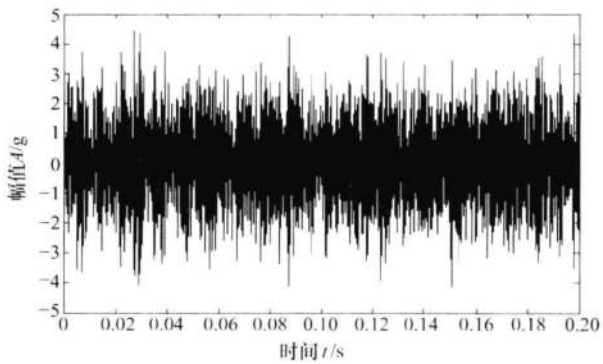

图 2-19　测点 ADXL-HV 原始振动波形

为了对比有故障和无故障的频谱图，我们将图 2-18 和图 2-21 两个三维图叠加形成二维图，如图 2-22 所示。图中下部曲线簇表示无故障，上部曲线簇表示有轴承故障。由图可知，故障特征频率出现在大约 550Hz，可初步判定为轴承内环故障。

同理，采用加速度传感器 ADXL-LV 采集三种工况的低真空端振动信号分析得

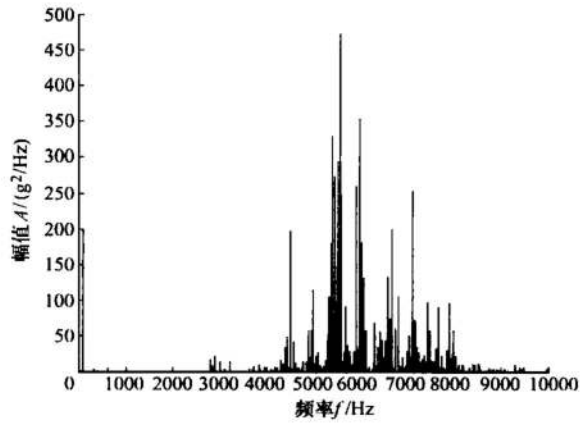

图 2-20 原始振动信号功率谱

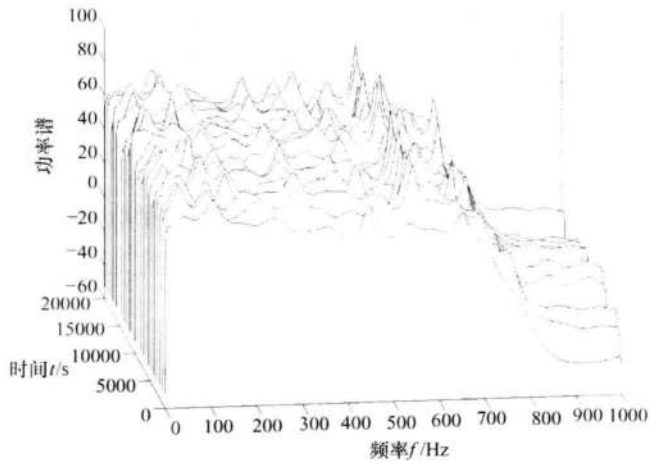

图 2-21 不同入口压力时故障振动信号的功率谱

到功率谱图，叠加后的二维谱图如图 2-23 所示，最佳模型阶数为 30。用加速度传感器 BK-HV 采集三种工况的高真空端的振动信号并作出其功率谱图，叠加后的二维谱图如图 2-24 所示，最佳模型阶数为 30。图 2-24 中，下部曲线簇表示无故障的泵 1 和泵 2，上部曲线簇表示有轴承故障的泵 1。

对比 3 种工况振动信号的基于 AR 模型的功率谱，其故障特征频率都明显出现在 550Hz 处。因此，我们可以进一步判断故障形式为轴承内圈故障。解体轴承，发现轴承内圈存在缺陷，如图 2-25 所示。

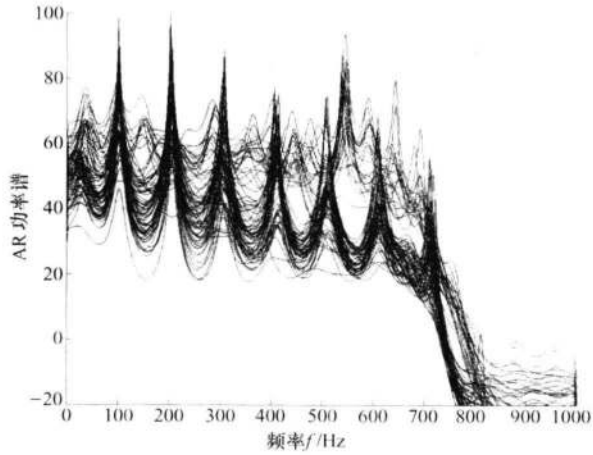

图 2-22　ADXL-HV 传感器检测的有故障
与无故障功率谱的对比

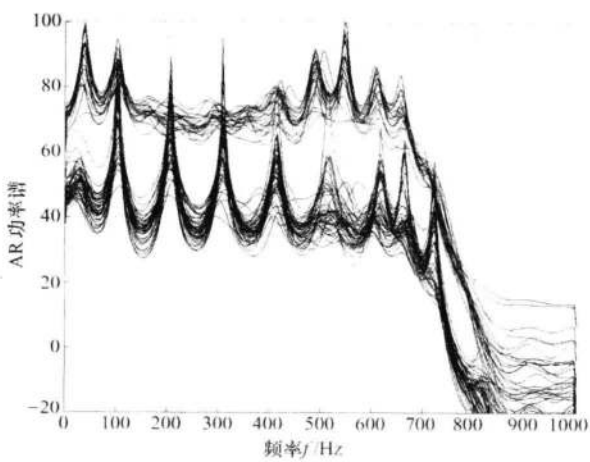

图 2-23　ADXL-LV 传感器检测的有故障
与无故障功率谱的对比

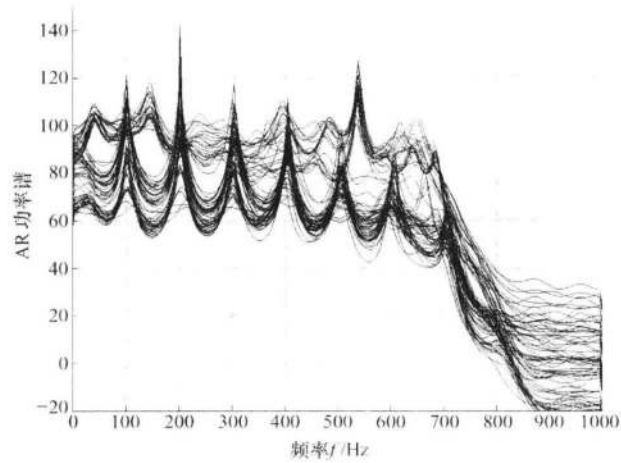

图 2-24 BK-HV 传感器检测的有故障与无故障功率谱的对比

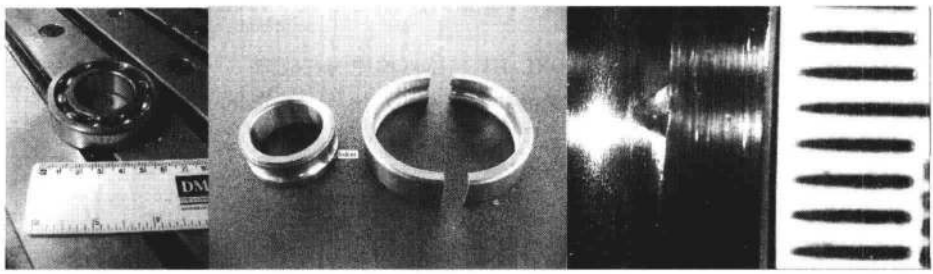

图 2-25 轴承内圈边缘凹陷故障

参 考 文 献

[1] 陈国强，赵俊伟，黄俊杰，等. Matlab 的 AR 模型参数估计 [J]. 工具技术，2005 (04)：87-89.

[2] 张晨罡，郝伟. 基于 AR 模型的滚动轴承故障检测 [J]. 现代制造技术与设备，2006 (5)：35-40.

[3] McFadden P D. Model for the Vibration Produced by a Single Point Defect in a Rolling Element Bearing [J]. Journal of sound and Vibration, 1984, 96: 69-82.

[4] David Brie. Modelling of the Spalled Rolling Element Bearing Vibration Signal: an Overview and Some New Results [J]. Mechanical Systems and Signal, 2003, 12 (5): 63-68.

[5] Chaturvedi G K, Thomas D W. Bearing Fault Detection Using Adaptive Noise Canceling [J]. ASME J Mech Des, 1982, 104: 280-289.

[6] 姚志飞. AR 模型最佳阶次选择及其在故障检测中的应用研究 [D]. 秦皇岛：燕山大学，2008.

[7] Jiang Wanlu（姜万录），Spurgeon K Sarah，Twiddle A John，et al. Wavelet Cluster Based Envelope Demodulation Approach and Its Application to Fault Diagnosis [J]. Chinese Journal of Scientific Instrument，2007，28（6）：973-979.

[8] 沈凤麟，叶中付，钱玉美. 信号统计分析与处理 [M]. 合肥：中国科学技术大学出版社，2002.

[9] 赵联春，马家驹，范树迁，等. 滚动轴承振动分析中的AR模型研究 [J]. 中国机械工程，2004（3）：210-213.

[10] Jiang W（姜万录），Spurgeon K Sarah，Twiddle A John，et al. A Wavelet Cluster-based Band-pass Filtering and Envelope Demodulation Approach with Application to Fault Diagnosis in a Dry Vacuum Pump [J]. Journal of Mechanical Engineering Science，2007，221（11）：1279-1286.

[11] 杨少辉. 频谱细化方法在真空泵轴承故障诊断中的应用研究 [D]. 秦皇岛：燕山大学，2008.

[12] 姚志飞，姜万录，朱勇. AR模型的功率谱估计方法及在故障检测中的应用 [J]. 机床与液压，2013，（5）：177-179.

第 3 章　频谱细化方法及在故障诊断中的应用

本章详细介绍几种常用的频谱细化方法，并进行比较分析。将 FFT-FS 频谱细化方法应用于干式真空泵轴承的故障诊断，实验结果验证了该频谱细化方法具有较高的频率定位准确性。

3.1　时域和频域分析方法

时—频分析是近年来颇为引人关注的信号分析方法，在工程实际中应用广泛。常用的时—频分析方法有短时傅里叶分析、小波分析等。本节介绍短时傅里叶变换和小波变换的基本原理。

3.1.1　傅里叶分析

傅里叶分析的主要缺点是不能反映信号频率随时间变化的规律，也就是常说的没有时间局部化性质。这对现代科学中信号的实时处理和精确分析无疑是一个缺憾。针对傅里叶分析的这个缺陷，人们提出了短时傅里叶分析。不过短时傅里叶分析方法，尽管弥补了傅里叶分析缺乏时间局部化的缺陷，但并没有完全解决实际问题。其原因就是短时傅里叶分析采用的是固定（时域）窗宽的窗函数，因此由窗函数确定的时—频域分辨率也是不变的。对于信号分析来说，总是希望在时、频域同时都有很高的分辨率，然而由 Heisenberg 测不准原理，不可能在时域和频域中同时得到很高的分辨率，要提高频域分辨率则必定是以牺牲时域分辨率为代价的，反之要提高时域分辨率也是以牺牲频域分辨率为代价的。

1. 傅里叶变换

对于非周期信号 $f(t)$，傅里叶正变换（FT）和逆变换（IFT）定义为

$$F(\mathrm{j}\omega) = \int_{-\infty}^{+\infty} f(t)\mathrm{e}^{-\mathrm{j}\omega t}\mathrm{d}t \tag{3-1}$$

$$f(t) = \frac{1}{2\pi}\int_{-\infty}^{+\infty} F(\mathrm{j}\omega)\mathrm{e}^{\mathrm{j}\omega t}\mathrm{d}t \tag{3-2}$$

傅里叶变换 $F(\mathrm{j}\omega)$ 是时域信号 $f(t)$ 在频域的表示方法，具有一些优良的性质，对某些具体问题，比时间函数的表示方法更方便，如调制和解调就是对傅里叶变换频移性质的应用。

为了进行数值计算，将连续时间信号$f(t)$及其频谱$F(j\omega)$分别在时域和频域均经过采样离散化，则N点的离散傅里叶正变换（DFT）和逆变换（IDFT）定义为

$$F(k) = \sum_{n=0}^{N-1} f(n) e^{-j(2\pi/N)nk} = \sum_{n=0}^{N-1} f(n) W_N^{nk} \tag{3-3}$$

$$f(n) = \frac{1}{N} \sum_{n=0}^{N-1} F(k) e^{j(2\pi/N)nk} = \frac{1}{N} \sum_{n=0}^{N-1} F(k) W_N^{-nk} \tag{3-4}$$

其中，$W_N = e^{-j(2\pi/N)}$。

快速傅里叶变换（FFT）是离散傅里叶变换的一种高效算法。其计算方法是将$x(n)$分成偶数序列$x_1(n)$和奇数序列$x_2(n)$，则有

$$X(k) = X_1(k) + W_N^k X_2(k) \quad k = 0, 1, 2, \cdots, \frac{N}{2} - 1 \tag{3-5}$$

$$X(k + \frac{N}{2}) = X_1(k) - W_N^k X_2(k) \quad k = 0, 1, 2, \cdots, \frac{N}{2} - 1 \tag{3-6}$$

计算次数较DFT约减少了一半。如果$N/2$还能被2整除，$x_1(n)$和$x_2(n)$还可以继续进行类似分解，进一步减少计算次数。

2. 短时傅里叶变换

信号$x(t)$的短时傅里叶变换（Short-Time Fourier Transform，STFT）定义为

$$\mathrm{STFT}_x(t, \omega) = \int_{-\infty}^{\infty} x(\tau) h(t - \tau) e^{-j\omega\tau} d\tau \tag{3-7}$$

式中，$h(t)$是窗函数。

一般情况下，$h(t)$为实函数，且其傅里叶变换的能量集中在低频处，因而可以看做是一低通滤波器的脉冲响应。

一方面可以用STFT来分析信号的局部性质；另一方面，一旦窗函数选定，其窗口宽度也随之确定。若要提高时间分辨率，使用窄窗；若要提高频率分辨率，使用宽窗。在信号处理中，对于窗函数$h(t)$提出了很多可行方案，最常用的是有紧支撑的适度光滑函数，通常被选为高斯函数。$h(t)$应具有良好的时—频特性，如果$h(t)$的时窗中心为t_0和其傅里叶变换$H(\omega)$的频窗中心为ω_0，那么$\mathrm{STFT}_x(t, \omega)$将很好地显示出$x(t)$在$t = t_0$和$\omega = \omega_0$附近的成分，因此STFT可以在整个时频平面内描述信号。

3.1.2　小波分析

小波分析是一种新的时—频分析方法，介于纯时域的时间波形分析和纯频域的传统傅里叶分析之间，它在频域同时具有良好的局部化性质。它可以根据信号的不同频率成分，在时域或频域自动调节取样的疏密：频率高时，则密；频率低时，则疏。由于对频率成分采用逐渐精细的频域取样步长，因此可以聚焦到对象（函数、

信号、图像等）的任意细节，并加以分析。从这个意义上讲，小波分析被誉为数学显微镜。因此，它在信号的分解与重构、信号和噪声分离、特征提取、数据压缩等工程领域显示出了巨大的优越性，而这些是傅里叶分析所无法做到的。

1. 连续小波变换

设 $\psi(t) \in L^2(R)$，其傅里叶变换为 $\Psi(\omega)$，则称满足以下允许条件的平方可积函数 $\psi(t)$ 为一个基本小波或小波基函数。

$$C_\psi = \int_{R^*} \frac{|\Psi(\omega)|^2}{|\omega|} d\omega < +\infty \tag{3-8}$$

其中 $R^* = R - \{0\}$ 表示非零实数全体。常用的小波基函数有 Haar 小波、Daubechies 小波、Mexican Hat 小波、Biorthogonal 小波、Coiflet 小波、Meyer 小波、Symlets 小波、Morlet 小波等。

对于一个给定的基本小波 $\psi(t)$，称

$$\psi_{(a,b)}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right) \tag{3-9}$$

为由基本小波 $\psi(t)$ 生成的连续小波。其中 $a \in R - \{0\}$，$b \in R$，a 称为尺度因子，b 称为时间中心因子（或时间平移因子）。

对于 $f(t) \in L^2(R)$（具有有限能量的信号），其连续小波变换（Continuous Wavelet Transform，CWT）定义为

$$W_f(a,b) = \int_R f(t) \overline{\psi}_{(a,b)}(t) dt = \frac{1}{\sqrt{|a|}} \int_R f(t) \overline{\psi}\left(\frac{t-b}{a}\right) dt \quad a \neq 0 \tag{3-10}$$

写成内积形式为

$$W_f(a,b) = <f, \psi_{(a,b)}> \tag{3-11}$$

小波反变换定义为

$$f(t) = \frac{1}{C_\psi} \iint_{R \times R^*} W_f(a,b) \psi_{(a,b)}(t) \frac{da db}{a^2} \tag{3-12}$$

由式（3-10）可以得知，小波变换 $W_f(a, b)$ 是尺度因子 a 和时间中心因子 b 的函数。假定 t^*，ω^* 分别表示 $\psi(t)$ 的时间窗和频率窗的中心，$\Delta\psi$，$\Delta\Psi$ 分别表示 $\psi(t)$ 的时间窗和频率窗的半径，则小波变换 $W_f(a, b)$ 将信号 $f(t)$ 限制在时间窗 $[b + at^* - a\Delta\psi,\ b + at^* + a\Delta\psi]$ 和频率窗 $[a^{-1}\omega^* - a^{-1}\Delta\Psi,\ a^{-1}\omega^* + a^{-1}\Delta\Psi]$ 之内。时间窗的中心在 $b + at^*$，窗宽为 $2a\Delta\psi$；频率窗的中心在 $a^{-1}\omega^*$，窗宽为 $2a^{-1}\Delta\Psi$。频窗宽度正比于其中心频率，即

$$\frac{2a^{-1}\Delta\Psi}{a^{-1}\omega^*} = \frac{2\Delta\Psi}{\omega^*} = C \tag{3-13}$$

其中，C 为常数。即小波变换的频域划分有一相对恒定的带宽，称之为等 Q 结构。小波变换通过 $\psi(t)$ 在尺度上的伸缩和时域上的平移来分析信号。适当地选择

$\psi(t)$，可以使 $\psi(t)$ 及其傅里叶变换 $\Psi(\omega)$具有较好的局部性。因此，小波变换也是一种时间—频率分析工具。尺度 a 增大时，$\psi_{(a,b)}(t)$ 在时域上伸展，小波变换的时域分辨率降低，$\Psi_{(a,b)}(\omega)$ 在频域上收缩，其中心频率降低，变换的频域分辨率升高，适合于提取多成分信号中的低频成分。反之，当 a 减小时，小波变换在时域收缩，小波变换的时域分辨率升高，其中心频率升高，频域分辨率降低，适合于提取多成分信号中的高频成分。因此小波变换即具有时间局部化能力，也具有频率局部化能力。图 3-1 给出了小波变换的时间—频率窗口示意图，图中 $a_2 > a_1$。

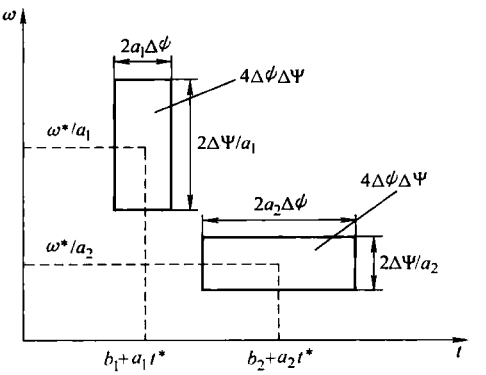

图 3-1　小波变换的时间—频率窗口

小波变换的突出优点是：在高频范围内时间分辨率高，在低频范围内频率分辨率高。连续小波变换具有如下重要性质：

（1）线性性质　一个多分量信号之和的小波变换等于各个分量的小波变换之和。

（2）平移不变性　如果 $f(t)$ 的小波变换为 $W_f(a, b)$，则 $f(t-\tau)$ 的小波变换为 $W_f(a, b-\tau)$。

（3）尺度共变性　如果 $f(t)$ 的小波变换为 $W_f(a, b)$，则 $f(ct)$ 的小波变换为 $W_f(ca, cb)/\sqrt{c}$，其中 $c>0$。

（4）自相似性　对应不同尺度参数 a 和不同时间中心参数 b 的连续小波变换之间是自相似的。

（5）冗余性　连续小波变换中存在信息表述的冗余度。

2. 离散小波变换

对于连续小波变换来说，尺度因子 a、时间 t 和时间平移因子 b 都是连续的。如果利用计算机计算，就必须对它们进行离散化处理，得到离散小波变换。

所谓离散小波变换（Discrete Wavelet Transform，DWT）是指对尺度因子 a 和平移因子 b 进行离散化，而不是通常意义上的时间离散化。离散小波变换的一个重要问题是如何降低计算量和数据量，因为如果对尺度 a 和平移 b 离散的间隔过小，那么计算量和数据量都是惊人的。

对于小波变换而言，将它的参数对（a，b）离散化，分为两步实现，先将尺度因子 a 按二进制方式离散化，得到二进小波和二进小波变换；之后，再将时间中心因子 b 按二进整数倍方式离散化，最后得到正交小波和函数的小波级数，真正实

现小波变换的连续形式和离散形式在普通函数形式上的完全统一。

（1）尺度的离散化　通常将尺度因子按幂级数进行离散，即令 a 取 a_0^0，a_0^1，…，a_0^j…此时离散后的 $\psi_{a,b}(t)$ 变为

$$a_0^{-\frac{j}{2}}\psi[a_0^{-j}(t-b)] \tag{3-14}$$

（2）平移的离散化　为保证信息的不丢失，对于某尺度 j 使平移因子 b 以 $a_0^j b_0$ 作为采样间隔，其中 b_0 为 $j=0$ 时的均匀采样间隔。此时 $\psi_{a,b}(t)$ 变为

$$a_0^{-\frac{j}{2}}\psi(a_0^{-j}t-kb_0) \tag{3-15}$$

实际应用中，通常取 $a_0=2$，$b_0=1$，对尺度因子和平移因子进行二进离散，从而得到如下二进小波

$$\psi_{a,b}(t)=2^{-\frac{j}{2}}\psi(2^{-j}t-k) \tag{3-16}$$

3. 常用的几种小波基函数

与傅里叶分析不同，小波分析的基（基本小波）不是唯一存在的，所有满足小波允许条件的函数都可以作为小波函数。以下是几种在机械故障诊断中常用的小波函数。

（1）Daubechies 小波　Daubechies 小波是著名小波学者 Ingrid Daubechies 对尺度因子取 2 的整数幂（即 $a=2^j$，j 为正整数）条件下的小波变换进行研究提出的，她发明的紧支集正交小波是小波领域的里程碑。

Daubechies 系列小波简写成 *dbN*，其中 N 表示阶数，*db* 是小波名字的前缀。这一族小波在时域上是有限支撑的，即 $\psi(t)$ 长度有限，而且其高阶原点矩 $\int t^p\psi(t)\mathrm{d}t=0$，$p=0\sim N$；$N$ 值越大，$\psi(t)$ 长度越长。$\Psi(\omega)$ 在频域上 $\omega=0$ 处有 N 阶零点。$\psi(t)$ 和它的整数位移正交归一，即 $\int\psi(t)\psi(t-k)\mathrm{d}t=\delta_k$。这个系列的小波扩展性比较好，可以比较灵活地权衡增加支集长度（为了提高能量的集中程度）带来的边界问题。

dbN 小波除了 *db*1 等同于 Haar 小波外，其余的 *db* 系列函数都没有解析形式的表达式，小波函数 $\psi(t)$ 可由尺度函数（Scaling Function）$\varphi(t)$ 求得。$\varphi(t)$ 长度有限，支撑域在 $t=0\sim(2N-1)$ 范围内。$\psi(t)$ 是 $\varphi(2t)$ 的移位加权和。

$$\psi(t)=\sum_k g_k\varphi(2t-k)\qquad k=0\sim 2N-1 \tag{3-17}$$

（2）Morlet 小波　Morlet 小波是高斯包络下的单频率复正弦函数，其解析表达式为

$$\psi(t)=\mathrm{e}^{-\frac{t^2}{2}}\mathrm{e}^{\mathrm{j}\omega_0 t} \tag{3-18}$$

$$\Psi(\omega)=\sqrt{2\pi}\mathrm{e}^{-\frac{(\omega-\omega_0)^2}{2}} \tag{3-19}$$

在时频两域都有比较好的局部性，但它不具有正交性，不满足容许条件，不存在紧支集，实际工作中，如果取 $\omega_0 \geqslant 5$，便近似满足条件。不能作离散小波变换和正交小波变换。由于 $\Psi(\omega)$ 在 $\omega=0$ 处斜率很小，所以 $\Psi(\omega)$ 在 $\omega=0$ 处的一、二阶导数近似为0。

（3）Mexican Hat 小波　Mexican Hat 小波也具有解析表达式，不存在尺度函数，所以不具有正交性。其解析形式为

$$\psi(t)=(1-t^2)\mathrm{e}^{-\frac{t^2}{2}} \tag{3-20}$$

$$\Psi(\omega)=\sqrt{2\pi}\omega^2\mathrm{e}^{-\frac{\omega^2}{2}} \tag{3-21}$$

它是高斯函数的二次导数，所在时域和频域都有很好的局部化性质。其小波系数随 ω 衰减得较快。

（4）Meyer 小波　Meyer 小波是在频域定义的具有解析形式的正交小波，由于不存在紧支集，所以在做离散小波变换时不存在快速算法。在实际应用中，可以用具有有限冲击响应（Finite Impulse Response，FIR）滤波器来模拟 Meyer 小波，构造可逆的滤波器矩阵，使得快速小波变换可以逼近 Meyer 小波变换。其小波函数构造方法如下：

$$\Psi(\omega)=\begin{cases}(2\pi)^{-\frac{1}{2}}\mathrm{e}^{\frac{\mathrm{i}\omega}{2}}\sin\left[\dfrac{\pi}{2}\nu\left(\dfrac{3}{2\pi}|\omega|-1\right)\right] & \dfrac{2\pi}{3}\leqslant|\omega|\leqslant\dfrac{4\pi}{3}\\ (2\pi)^{-\frac{1}{2}}\mathrm{e}^{\frac{\mathrm{i}\omega}{2}}\cos\left[\dfrac{\pi}{2}\nu\left(\dfrac{3}{4\pi}|\omega|-1\right)\right] & \dfrac{4\pi}{3}\leqslant|\omega|\leqslant\dfrac{8\pi}{3}\\ 0 & |\omega|\notin\left[\dfrac{2\pi}{3},\dfrac{8\pi}{3}\right]\end{cases} \tag{3-22}$$

其中，$\nu(a)=a^4(35-84a+70a^2-20a^3)$，$a\in[0,1]$，为辅助构造函数，其尺度函数的形式为

$$\Phi(\omega)=\begin{cases}(2\pi)^{-\frac{1}{2}} & |\omega|\leqslant\dfrac{2\pi}{3}\\ (2\pi)^{-\frac{1}{2}}\cos\left[\dfrac{\pi}{2}\nu\left(\dfrac{3}{2\pi}|\omega|-1\right)\right] & \dfrac{2\pi}{3}\leqslant|\omega|\leqslant\dfrac{4\pi}{3}\\ 0 & |\omega|>\dfrac{4\pi}{3}\end{cases} \tag{3-23}$$

3.2　频谱细化分析的理论方法

频谱的分辨率是频谱性能的一个重要指标，分辨率高则意味着频谱清晰度高，很容易分辨频谱中的间隔较小的频率分量；相反，如果频谱的分辨率不够高，则容易出现频谱模糊，相邻频率分量不能正确分辨等问题。本节主要是分析现有的一些提高频谱分辨率的方法及其特点，并对各种方法的应用效果进行

比较。

3.2.1 频谱细化分析方法

1. 复调制频谱细化分析方法

复调制细化方法的思路是对采样时间序列 $x(n)$ 乘以频移因子 $e^{-j2\pi nf_L/f_s}$，将实序列变为复序列。根据傅里叶变换的频移性质，信号频谱将产生平移，这样就把细化频段 $f_L \sim f_H$ 的 f_L 移到零频率，然后对该信号进行低通滤波，滤掉 $f_L \sim f_H$ 以外的成分，再进行 D 点抽样（重采样），最后作 FFT 计算频谱，频谱则细化了 D 倍，得到了更高的分辨率。

假定要在 f_1 至 f_2 内进行细化，则观测频带中心为 $f_0 = (f_1 + f_2)/2$，对采样时间序列 $x_0(n)$ 以 $e^{-j2\pi nf_0/f_s}$ 进行复调制，得到频移信号。

$$x(n) = x_0(n)e^{-j2\pi nf_0/f_s} = x_0(n)\cos\frac{2\pi nl_0}{N} - jx_0(n)\sin\frac{2\pi nl_0}{N} \tag{3-24}$$

其中，$f_s = N\Delta f$，Δf 是谱线间隔，$l_0 = f_0/\Delta f$ 是在全局频谱显示中所对应中心频率 f_0 的谱线序号。

根据 DFT 的频移性质，$x(n)$ 的 DFT $X(k)$ 同 $x_0(n)$ 的 DFT $X_0(k)$ 应有下列关系：

$$X(k) = X_0(k + l_0) \tag{3-25}$$

即 $X(k)$ 相当于 $X_0(k)$ 左移 l_0 点，f_0 变为零频率点。为了保证重采样不致产生频率混叠，应先进行低通滤波，截止频率应为 $f_s/(2D)$，此时滤波器的输出为

$$Y(k) = X(k)H(k) = X_0(k + l_0) \quad k = 0, 1, \cdots, N-1 \tag{3-26}$$

其中，$H(k)$ 为理想低通滤波器的频率响应。滤波器输出的时间序列为

$$y(n) = \frac{1}{N}\sum_{k=0}^{N-1} Y(k)W_N^{-nk} = \frac{1}{N}\sum_{k=0}^{N-1} X(k)H(k)W_N^{-nk} = \frac{1}{N}\sum_{k=0}^{N-1} X_0(k + l_0)W_N^{-nk} \tag{3-27}$$

以比例因子 D 对 $y(n)$ 进行重采样，得到时间序列：

$$g(m) = y(Dm) \tag{3-28}$$

则有

$$g(m) = \frac{1}{N}\left|\sum_{p=0}^{\frac{N}{2}-1} X_0(p + l_0)W_N^{-pm} + \sum_{p=\frac{N}{2}}^{N-1} X_0(p - N + l_0)W_N^{-pm}\right| \tag{3-29}$$

$$G(k) = \sum_{m=0}^{N-1} g(m)W_N^{mk} = \begin{cases} \dfrac{1}{D}X_0(k + l_0) & k = 0, 1, 2, \cdots, \dfrac{N}{2} - 1 \\ \dfrac{1}{D}X_0(k + l_0 - N) & k = \dfrac{N}{2}, \dfrac{N}{2} + 1, \cdots, N - 1 \end{cases} \tag{3-30}$$

考虑到式（3-25）和式（3-30），利用DFT公式，可求出式$X_0(n)$的频谱为

$$X_0(k)=X(k-l_0)=\begin{cases}D\cdot G(k-l_0) & k=l_0,\ l_0+1,\ \cdots,\ l_0+\dfrac{N}{2}-1\\ D\cdot G(k-l_0+N) & k=l_0-\dfrac{N}{2},\ \cdots,\ l_0-1\end{cases}\tag{3-31}$$

因为直接FFT分析时，频率分辨率$\Delta f=f_s/N$，重采样以后$\Delta f'=f_s/DN=\Delta f/D$，故$D$为细化倍数。

复调制频谱细化方法可分为以下几步进行：

（1）复调制　根据傅里叶变换的频移定理，在时域乘以频移因子$e^{-2j\pi f_0 t}$，在频域有f_0的频移，f_0是欲细化频段的中心，经频移后，f_0已经成为新频谱的零点。

（2）低通数字滤波　将观测频带以外的高频成分滤除，以防止采样频率降低后引起无用频带对有用频带成分的混叠。

（3）重采样　采样的周期为DT_s，D是细化倍数，在频域则按照f_s/D作周期化；

（4）FFT处理　对时域作仍为N点的FFT处理，使频率分辨率提高了D倍，使FFT后在所截取的频段内得到了细化D倍的频谱。

对于复调制频谱细化过程有如下几个结论需要说明：

① 细化处理与非细化处理的基本频带范围保持不变，并且可以细化这一频带中的任何一段。

② 要细化的频率范围为$f_L\sim f_H$，频移后低频点f_L移到原点，则高频点变为f_H-f_L。这时数字低通滤波器的截至频率应大于f_H-f_L，并小于低频重采样频率的一半。并且可以得到最大细化倍数D与细化频率范围之间的关系为：$D<f_s/[2(f_H-f_L)]$，当$f_L=0$时，可以省略频移一步。这给设置细化倍数范围提供了依据。

③ 数字低通滤波器的通带必须平，通带内波动要小，这样原信号的频谱特性细化后在幅值上才不会改变。

复调制细化分析可用硬件或软件的方法实现。硬件实现就是用硬件实现频移、数字滤波、重采样及FFT分析。优点是速度快，最大细化倍数高，可实现实时细化分析；缺点是不保存原始信号，改变中心频率和细化带宽，均需要重复整个过程，因此要求分析信号在分析过程中稳定。该方法也可用软件在微机上实现，但情况和上面正好相反：速度较慢导致最大细化倍数低，若最大细化倍数为D，则至少要保存D倍长度的分析信号数据，只能作离线细化分析。但可保存并使用原始数据，随意改变中心频率和细化带宽，而无需重复过程。

2. 基于小波簇变换的频谱细化分析方法

由于小波具有良好的时频局部化特性，利用小波的频域带通特性，可以把要分

析的信号频带分离出来。

对于任一函数 $x(t)$，其积分小波变换为

$$W_{\psi(a,b)}[x(t)] = (1/\sqrt{a})\int_{-\infty}^{+\infty} x(t)\,\overline{\psi}[(t-b)/a]\,\mathrm{d}t \tag{3-32}$$

式中，b 是平移参数；a 是尺度参数；$\overline{\psi}$是 ψ 的共扼函数。

小波变换的优越性在于，可以通过改变平移参数 b 和尺度参数 a，方便地确定小波的时域位置和频域特性。平移参数 b 对应于小波在时域的位置，尺度参数 a 的变化对应于改变时窗和频窗的宽度，a 变大则频窗变窄，时窗变宽；a 变小时，频窗变宽，时窗变窄。通常需根据分析问题的需要，选择和构造不同的小波，常用的小波有高斯小波、样条小波、二进小波和正交小波等。

为了用小波变换对感兴趣的频段成分进行分析，可以给 $\psi(t)$ 乘以频移因子 $\mathrm{e}^{-\mathrm{j}\omega_0 t/a}$，$\mathrm{e}^{-\mathrm{j}\omega_0 t/a}$的共轭为 $\mathrm{e}^{\mathrm{j}\omega_0 t/a}$，此时小波变换为

$$W_{\psi(a,b)}[x(t)] = (1/\sqrt{a})\int_{-\infty}^{+\infty} x(t)\,\overline{\psi}[(t-b)/a]\mathrm{e}^{\mathrm{j}\omega_0 t/a}\,\mathrm{d}t \tag{3-33}$$

式（3-35）提取了 $x(t)$ 在频带为 $\{[(\omega^*+\omega_0)/a] - \Delta\omega/a,\ [(\omega^*+\omega_0)/a + \Delta\omega/a]\}$ 上的信息，因此，只要选择适当的参数 ω_0和 a，使$(\omega^*+\omega_0)/a$ 为频带中心就可以了。

因此，可利用小波变换这种带通滤波特性，得到足够窄带的信号，以此了解此带宽范围内信号频率的变化情况。如果要得到某频段真实的频谱，可以用多个小波组合，这时就可实现带通滤波特性。

选用频谱具有“钟”形曲线的单个 Morlet 小波，如图 3-2 所示，其频谱两边下降很快，这种特性对于分析单频率时非常有效，但由于振动信号携带着丰富的设备运行状态信息，不同故障的信号有着不同的频率特征，所以需要用多个 Morlet 小波组合，以实现带通特性来提取故障特征频率。

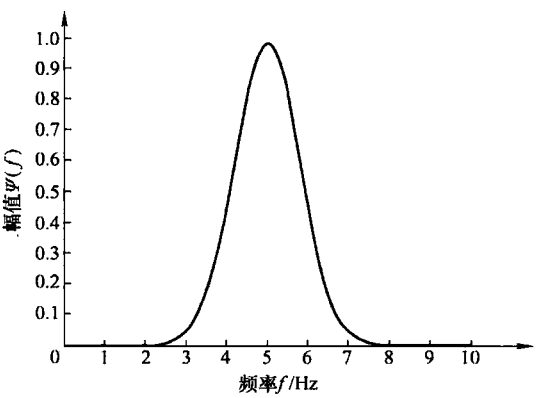

图 3-2 单个 Morlet 小波频谱图

单个 Morlet 小波表达式为$\dfrac{1}{\sqrt{2\pi}a}\exp\left(\dfrac{-t^2}{2a^2}\right)\cdot \mathrm{e}^{\mathrm{j}2\pi f_0 t}$，其中 a 为尺度参数，f_i为中心频率。选择不同的f_i，可得到小波簇：

$$\psi_c(t)=\frac{1}{\sqrt{2\pi}a}\exp\left(\frac{-t^2}{2a^2}\right)\{\exp[\mathrm{j}2\pi f_L t]+\cdots+\exp[\mathrm{j}2\pi(f_L+k\Delta f)t]+\cdots+\exp[\mathrm{j}2\pi f_H t]\}\quad(k=0,1,2,3,\cdots,n;f_H=f_L+n\Delta f)\tag{3-34}$$

式中，f_L、f_H是组合小波的通频带上限和下限频率；Δf是各小波中心频率的间距；$n+1$是Morlet小波的个数。

式（3-34）的频谱实际就是各个小波频谱的叠加。选择适当的Δf就可得平顶的叠加谱，a值的选择将影响通频带上升、下降曲线的斜率，n的选择决定通频带宽度，利用式（3-34）小波簇对信号$x(t)$的变换：

$$W(t)=x(t)*\psi_c(t)\tag{3-35}$$

得到的$W(t)$就是信号$x(t)$在通频带$f_L\sim f_H$中的信号成分。

利用小波簇设计滤波器，在设计和调整上十分方便，可以根据实际需要，调整参数a和Δf的值，就可以得到合适的滤波特性。例如当$a=0.2$，$n=40$，$f_L=30\mathrm{Hz}$，$\Delta f=1\mathrm{Hz}$时，$f_H=70\mathrm{Hz}$，此时Morlet小波簇的频谱图如图3-3所示，可以得知在此参数条件下，组合小波具有平顶频窗，并且满足优良带通滤波器的通频带特性及过渡带特性，还可以通过改变f_L和n的值提取信号不同频率范围的信息。

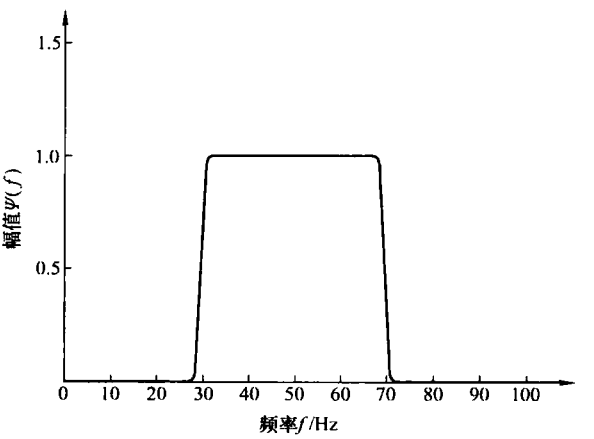

图3-3　Morlet组合小波频谱图

基于小波簇变换的频谱细化方法就是利用小波簇提取感兴趣的信号频带成分，再进行频移，重采样后进行FFT变换，就可得信号的细化频谱，具体步骤如下：

1）滤波：选择需要分析的频带$f_L\sim f_H$，构造小波簇$\psi_c(t)$进行小波变换，通过调节尺度参数a和小波簇各分量中心频率间隔Δf得到满意的滤波特性。

2）频移：滤波后的信号$W(t)$乘以频移因子$\mathrm{e}^{-\mathrm{j}2\pi f_L t}$，使频谱左移$f_L$，信号频谱的下界移到0Hz处，即：$W_1(t)=W(t)\ \mathrm{e}^{-\mathrm{j}2\pi f_L t}$。

3）重采样：经滤波和平移后，再对$W_1(t)$进行采样，此步为细化。采样间隔为$m\Delta t$（m为细化倍数，Δt为原采样间隔），数据长度N不变，但分析信号的长度为原来的m倍。

4）对重采样的信号进行FFT变换，就得到所需频段$f_L\sim f_H$细化了m倍的频谱。

由于要细化的频率范围为$f_L \sim f_H$，所以f_L，f_H为小波簇的通频带上限和下限频率，并且$f_H - f_L$小于低频重采样频率的一半，因此得到最大细化倍数 D 与细化频率范围之间的关系为：$D < f_s / [2(f_H - f_L)]$。当$f_L = 0$时，$f_s/D > 2f_H$时，可省略频移一步。和复调制频谱细化方法一样，这给设置细化倍数范围提供了依据。

3. FFT-FS 频谱细化分析方法

复调制细化和小波簇频谱细化可以在一定程度上提高频率分辨率、但所需要的分析信号数据量也成倍地增加。换句话说，要使频谱细化 D 倍，序列长度也必须是原来的 D 倍。在分析信号数据的长度恒定或对瞬态信号进行细化分析时，如果信号序列的长度有限，上述方法就无能为力了。这里介绍一种离散序列的频谱计算方法。在不增加分析信号数据长度的前提下，利用傅里叶级数的原理能得到连续的频谱曲线，从而可以消除采样点数的限制。

对于采样频率为f_s，采样点数为 N 的时间序列$\{x(n)\}$（$n = 0, 1, 2, \cdots, N-1$），其傅里叶级数为

$$x(n) = \frac{a_0}{2} + \sum_{k=1}^{N-1} \{a_k \cos(2\pi nk/N) + b_k \sin(2\pi nk/N)\} \quad n = 0, 1, \cdots, N-1 \tag{3-36}$$

式（3-36）中的傅里叶系数为

$$a_k = \frac{2}{N} \sum_{n=0}^{N-1} x(n) \cos(2\pi nk/N) \tag{3-37}$$

$$b_k = \frac{2}{N} \sum_{n=0}^{N-1} x(n) \sin(2\pi nk/N) \tag{3-38}$$

$$a_0 = \frac{1}{N} \sum_{n=0}^{N-1} x(n) \tag{3-39}$$

在式（3-37）、式（3-38）两式中，$k = 0, 1, \cdots, \frac{N}{2} - 1$，频率$k\Delta f$处幅值谱矢量表达式为$a_k - jb_k$，即$a_k$，$b_k$分别对应频谱幅值的实部和虚部。

事实上，序列$\{x(n)\}$包含着$0 \sim f_s/2$频段的连续信息，因此，若把式（3-37）、式（3-38）式中的k看作区间$0 \leqslant k \leqslant N/2$内连续变化的实数变量$f(0 \leqslant f \leqslant f_s/2)$，则可将式（3-37）、式（3-38）变成

$$a(f) = \frac{2}{N} \sum_{n=0}^{N-1} x(n) \cos(2\pi nf/f_s) \tag{3-40}$$

$$b(f) = \frac{2}{N} \sum_{n=0}^{N-1} x(n) \sin(2\pi nf/f_s) \tag{3-41}$$

这样，利用式（3-40）、式（3-41）两式便可得到连续的频谱曲线，从而频率分辨力就不再受采样点数的限制了。显然，式（3-40）、式（3-41）直接采用了傅里叶级数（Fourier Series，FS）的原理公式，故所需的运算量较大。因此，在实际

应用中，可以针对 N 点序列先用 FFT 作出 0 ~ $f_s/2$ 频段的基带谱，又称为全景谱。然后再利用式（3-40）、式（3-41）对感兴趣的局部频谱进行细化运算，细化密度可以根据需要确定。为了尽可能提高频谱分析的效率，减少计算时间，具体实施细化分析时，细化的范围可以由大到小，细化密度可以由低到高逐渐进行。这种将 FFT 和 FS 结合起来对频谱进行细化分析的方法被简称为 FFT-FS 频谱细化分析。

下面我们就利用 FFT-FS 频谱细化方法进行仿真分析。对于一个计算机合成的仿真时域信号

$$x(t)=5\cos(2\pi\times52t)+5\sin(2\pi\times63t)+10\sin(2\pi\times88t) \tag{3-42}$$

用 2048Hz 的频率进行采样，采样点数 $N=1024$，分析数据长度为 1024，其全景谱如图 3-4 所示，三处理论上的频率值分别是 52Hz、63Hz、88Hz。但是由图3-4可见，由于频率分辨率低，功率谱图中的三个峰值对应的频率值难以准确辨认。

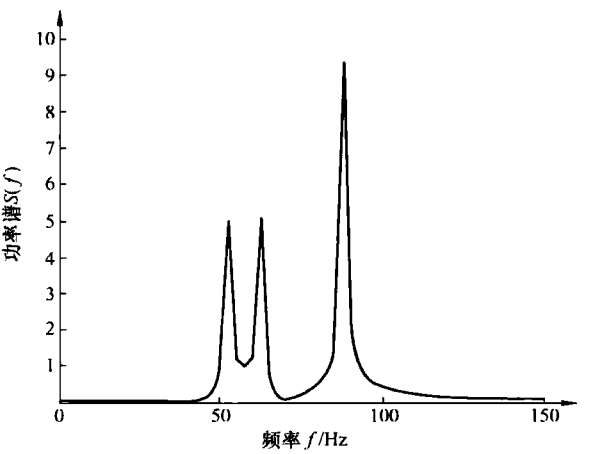

图 3-4　仿真信号功率谱图

在 52Hz 处进行细化，细化倍数为 10，如图 3-5 所示；在 63Hz 处进行细化，细化倍数为 10，如图 3-6 所示；在 88Hz 处进行细化，细化倍数为 10，如图 3-7 所示。

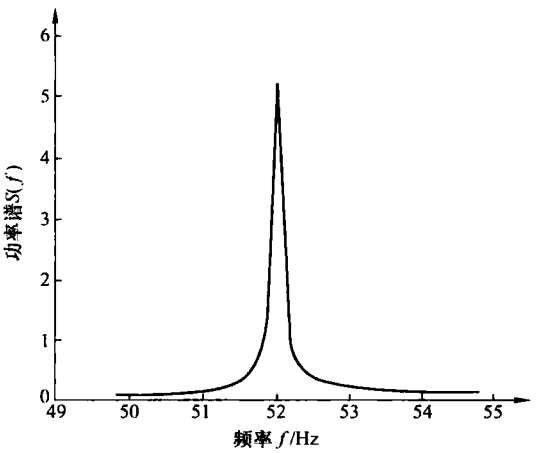

图 3-5　中心频率为 52Hz 的细化谱

从以上的分析可以看出，与传统的功率谱分析法相比，FFT-FS 频谱细化分析所得细化谱更接近实际频率，频率误差更小。而幅值与频率误差有关，频率误差越小，幅值误差也越小，所以 FFT-FS 频谱细化分析所得细化谱幅值精度也很高。

细化谱的频率精度主要取决于采样频率和序列长度，同时与信号的实际频率有关，随着数据长度 N 的增大，因数据截断造成的泄漏误差就越小，因而细化谱的计算精度就越高。

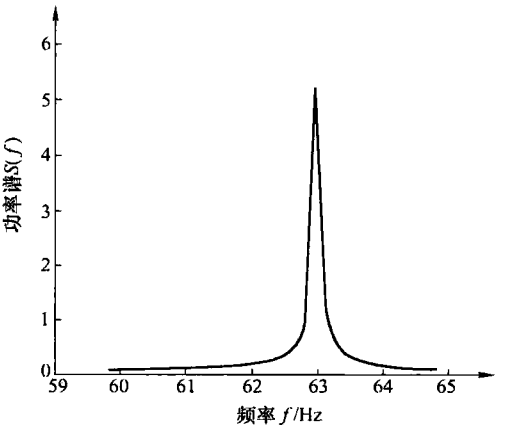

图 3-6 中心频率为 63Hz 的细化谱

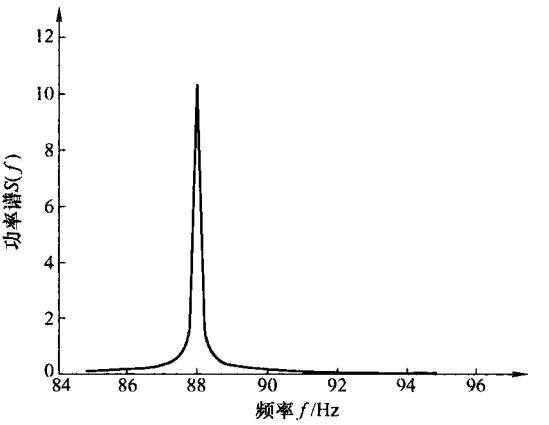

图 3-7 中心频率为 88Hz 的细化谱

3.2.2 几种频谱细化分析方法的比较

对于一个计算机仿真信号：

$$x(t)=\sin(2\pi\times110t)+\sin(2\pi\times111.4t)+\sin(2\pi\times112.3t)+\sin(2\pi\times113.8t)+0.7\sin(2\pi\times114.5t)+0.85\sin(2\pi\times121.5t) \tag{3-43}$$

对其进行采样，采样频率 $f_s=2048$Hz，分析数据长度为 10240 点，采样点数 $N=1024$，其功率谱如图 3-8 所示。由于频率分辨率 $f_s/N=2$Hz，不能分辨信号中频率间隔为小于 2Hz 的成分，所以图 3-8 中各频率成分没有分开，幅值与实际值也不相符。

图 3-9 是利用复调制频谱细化方法得到的 100 ~ 120Hz 频段信号细化 10 倍后的

频谱图，其中复调制后选用的是 32 阶 Kaiser 窗 FIR 滤波器进行抗混叠滤波，截止频率为 20Hz。频谱图将 5 个频率成分分开了，但由于有限阶滤波器的吉布斯效应，滤波后产生频谱泄漏，各频率成分的频谱失真。

图 3-10 是利用小波簇变换频谱细化方法得到的 100 ~ 120Hz 频段信号细化 10 倍后的频谱图，其中小波簇参数选择为 $a=0.2$、$N=20$、$f_L=100\text{Hz}$、$\Delta f=1\text{Hz}$。频谱图不仅将 5 个频率成分全部分开了，而且更真实地反映了细化频段各频率成分的幅值。

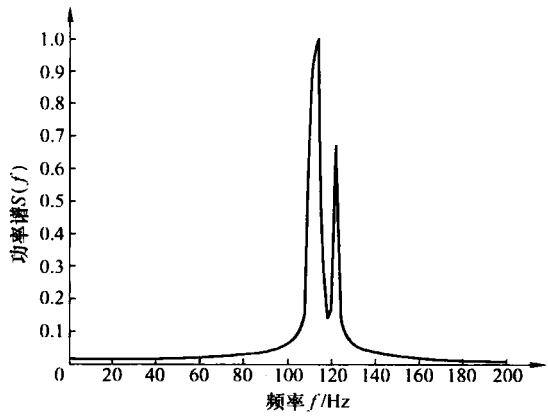

图 3-8　仿真信号功率谱图

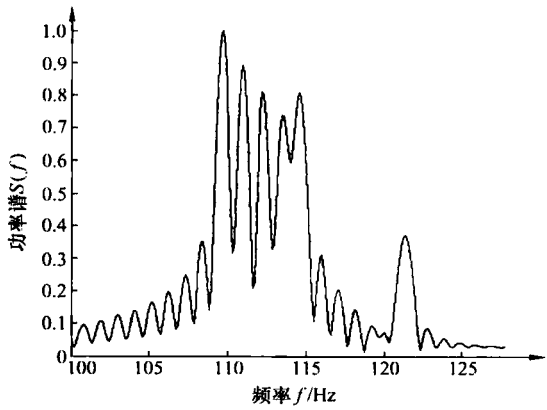

图 3-9　复调制频谱细化图

复调制频谱细化是最早使用的频谱细化分析方法，它解决了传统傅里叶变换为了提高频谱的频率分辨率单独对全频段降低采样频率或者增加数据长度而带来的弊端，既不缩小有效频段，又不增加数据处理的时间，仅仅是提高了所需频段的频率

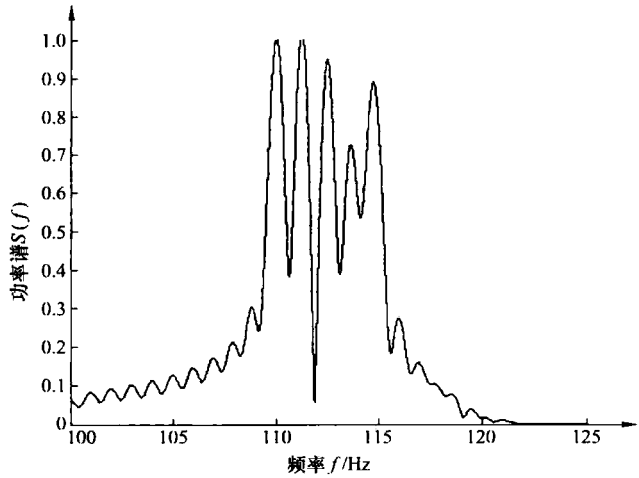

图 3-10 小波簇变换频谱细化图

分辨率。但复调制频谱细化分析法同时存在以下几个方面的局限性：

1）低通滤波器特性限制了精度和最大细化倍数。复调制细化法需要经过频移、低通滤波、重采样几个环节，而实际的低通滤波器都有过渡带，当细化倍数越大时，过渡带的宽度对滤波精度影响越大，会使分析精度大为降低，且容易产生泄露现象。当细化倍数达到一定值时，则整个被选分析频带都会产生很大的分析误差，这种方法实际上已无法应用。

2）频率成分调整较复杂。将 FFT 和频谱分析得到的频率成分调整到所选频带的频率成分是较复杂的过程。

3）复调制细化法不保存原始信号。每当改变分析频带时，均需要重新设计低通滤波器、复调制、低通滤波、重采样等步骤。故障诊断过程中经常需要分析多个频谱范围，使用复调制细化法将会大大降低算法的效率。

4）随着细化倍数的提高，需要的时域采样点数增加，若最大细化倍数为 D，则至少要保存 D 段 FFT 长度的分析信号数据，这在某些情况下是不现实的。

基于小波簇变换的频谱细化方法的思路与复调制频谱细化方法原理一样，不同之处主要在于滤波这一步，在复调制频谱细化方法中，需根据不同需要设计滤波器，如果设计不当，易产生泄漏，使细化后频谱局部失真。利用小波簇进行滤波器设计很方便，可以根据实际工作需要，适当改变参数 a、N、Δf 的值，就可得到合适的滤波特性，滤波效果比普通数字滤波器的效果更好，而且可以减小失真。如果故障诊断过程中经常需要分析多个频谱范围，只需改变 f_L 与 N 的数值就可得到所需频段。与复调制频谱细化方法相比，将其频移和滤波两步骤合二为一，可有效地提高运算速度。

以上两种频谱细化方法都是在不增加数据分析点数的情况下对所需频段进行细化，但有一个共同特点，就是随着细化倍数的提高，需要的时域采样点数增加，即若最大细化倍数为 D，则至少要保存 D 段 FFT 长度的分析信号数据。如果细化倍数太大，计算机的硬件配置不能存储所需分析信号数据的时候，以上两种方法就不能实现了。FFT—FS 频谱细化方法利用傅里叶级数的原理能得到连续的频谱曲线，不仅可以消除存储分析信号数据长度的限制，而且得到的连续谱幅值和频率精度比以上两种方法更高。

3.3　频谱细化方法在真空泵轴承故障诊断中的应用

首先设计基于 Labview 的数据采集系统，利用数据采集卡采集振动信号。经数据处理后，运用频谱细化方法进行真空泵的故障诊断。真空泵中的转子不平衡、不对中、轴弯曲、轴承中各部件及齿轮啮合等特征频率成分均分布在 10Hz ~ 10kHz 范围内，当一些部件的工作表面出现缺陷时，会以一定的特征频率产生一系列的宽带冲击，从而出现调制现象。采集的振动信号的低频段很难反映出特征频率，所以必须要对采集的信号进行解调处理。

3.3.1　小波簇变换频谱细化方法的应用

对采集的振动信号使用小波簇变换频谱细化方法，选用加速度传感器 ADXL105 采集干式真空泵高真空端的振动信号，如图 2-15 所示。调整电动机转速为 103r/s（即转轴频率为 103Hz），干式真空泵入口压力为 2000Pa，振动加速度的采样参数为：采样频率为 40kHz，采样信号数据长度为 40960 点，分析点数为 1024。

由于采集到的故障振动信号具有调制特征（图 3-11），所以经过 Hilbert 变换解调后可得故障信号的功率谱如图 3-12 所示。由于频率分辨率 Δf = 采样频率/数据长度 = 40000Hz/1024 ≈ 40Hz，解调后的功率谱图无法区分轴承内圈的故障频率 550Hz 与转轴频率的 5 阶倍频 515Hz 这两个频率，也无法区分轴承内圈故障频率的 2 阶倍频 1100Hz 与转轴频率的 11

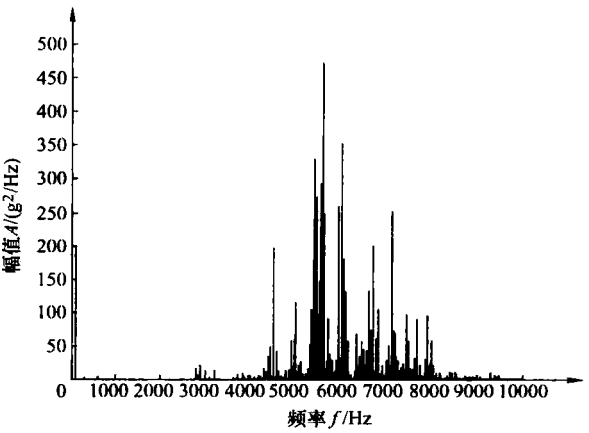

图 3-11　原始信号功率谱图

阶倍频 1133Hz 这两个频率。下面利用基于小波簇变换的频谱细化方法，分别作出以 550Hz 和 1100Hz 为中心的细化谱就可以解决此问题。

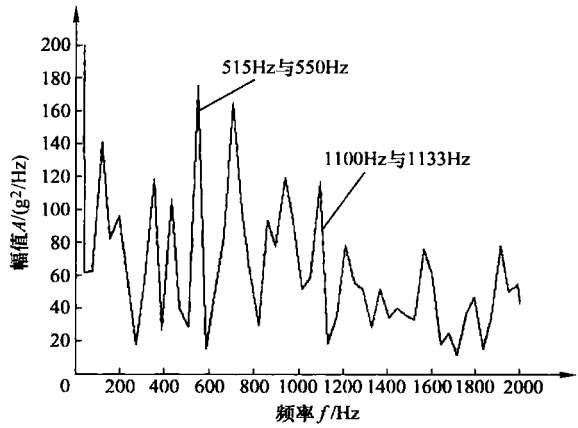

图 3-12 轴承故障信号的功率谱图（解调后）

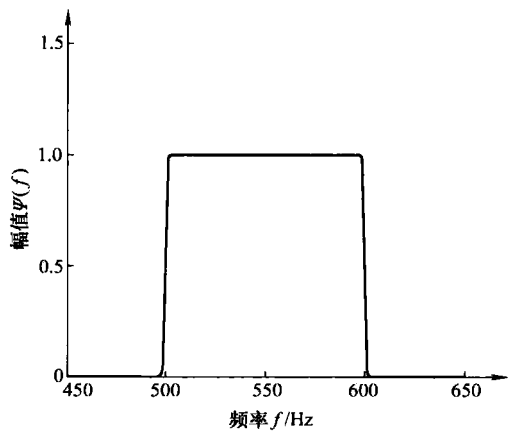

图 3-13 小波簇 1 频谱图

首先做以 550Hz 为中心的细化谱，其中小波簇 1（图 3-13）的参数取为 $a=0.2$、$N=100$、$f_L=500\text{Hz}$，$\Delta f=1\text{Hz}$，细化倍数 D 为 40 倍。所得细化谱如图 3-14 所示，由图可以看出，$f_i=550\text{Hz}$ 为轴承内圈故障频率，细化谱将它与转轴频率的 5 阶倍频 515Hz 区分开。

再做以 1100Hz 为中心的细化谱，其中小波簇 2（图 3-15）的参数选取为 $a=0.2$、$N=100$，$f_L=1050\text{Hz}$、$\Delta f=1\text{Hz}$，细化倍数 D 为 40 倍。所得细化谱如图3-16，由图可以看出，$f_i=1100\text{Hz}$ 为轴承内圈故障频率的 2 阶倍频，细化谱将它与转轴频率的 11 阶倍频 1133Hz 区分开。

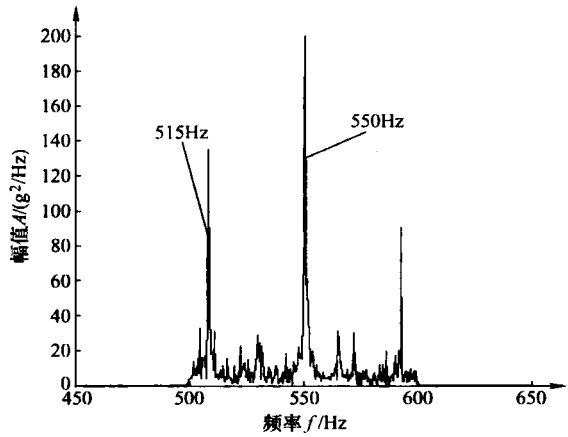

图 3-14　中心频率为 550Hz 的细化谱

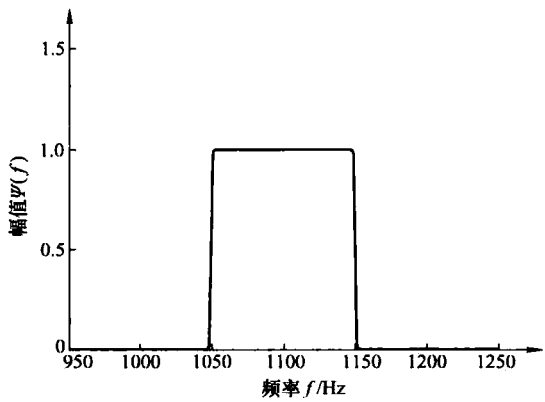

图 3-15　小波簇 2 频谱图

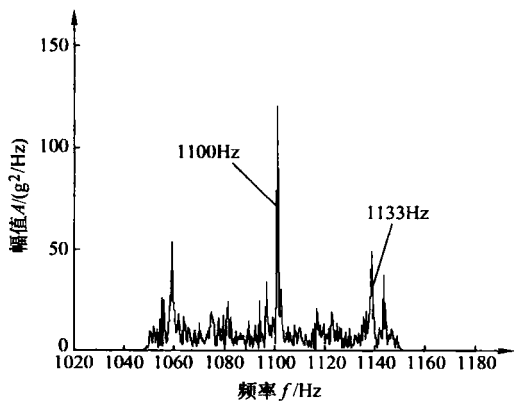

图 3-16　中心频率为 1100Hz 的细化谱

综上所述，可以判定轴承内圈有故障。同理，用此方法诊断外圈，滚动体和保持架，没有发现故障。解体轴承，发现内圈发生磨损存在凹陷，诊断结果与实际吻合，如图 2-24 所示。

3.3.2 FFT-FS 频谱细化方法的应用

改变测试点，用加速度传感器 BK4370V 采集真空泵高真空端的数据，如图 2-15所示。电动机转速不变。干式真空泵入口压力仍为 2000Pa，振动加速度的采样参数同上。再将干式真空泵的入口压力调节到 9000Pa，微调变频器使电动机转速仍为 103r/s。再次用加速度传感器 BK4370V 采集干式真空泵高真空端的数据。振动加速度的采样参数为：采样频率为40kHz，采样点数为 1024，分析信号数据长度为 1024 点。

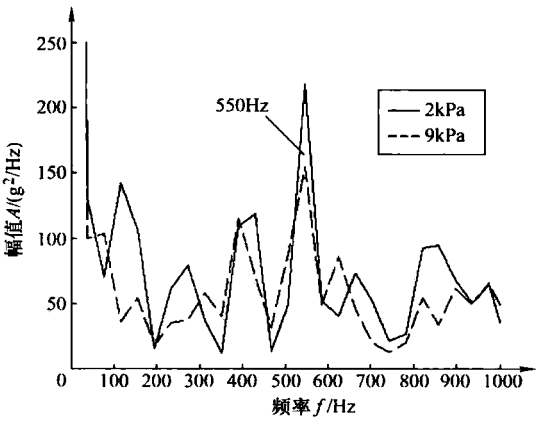

图 3-17 两个功率谱图的叠加

为了验证轴承的内圈故障，将两组数据经过 Hilbert 变换解调后叠加到一个功率谱图，如图 3-17 所示。由于采样频率为 40kHz，采样点数为 1024，频率分辨率 Δf = 采样频率/数据长度 = 40000Hz/1024 ≈ 40Hz，频率分辨率太低。将上图的两个频谱分别运用 FFT-FS 频谱细化方法细化，细化频段均为 536 ~ 558Hz，细化倍数均为 40，所得细化谱如图 3-18。

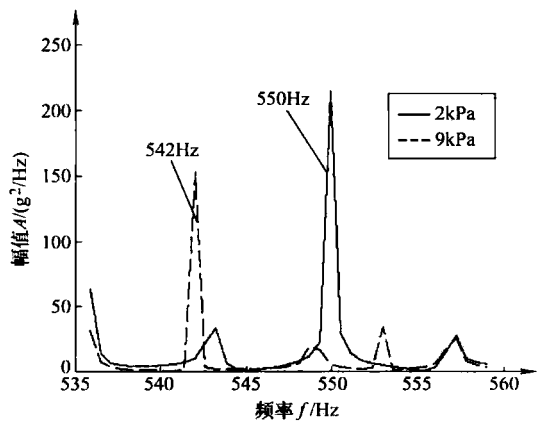

图 3-18 FFT-FS 细化谱

理论上两组信号的故障特征频率应该相同，但由图3-18可以看出，二组轴承内圈的故障特征频率f_{i1}和f_{i2}的值相差8Hz。检查实验设备可知，干式真空泵的入口压力调整到9000Pa后，在微调变频器时产生误差，使电动机实际转速变为101.5r/s，故泵的转轴频率为101.5Hz。由于轴承相同，通过已知的轴承参数计算得轴承内圈的通过频率为f_{i2}=541.6Hz，图3-18与分析结果基本吻合。

3.3.3　结果分析

通过以上两种方法在干式真空泵故障诊断中的应用分析，可以看出频谱细化方法能够区分干式真空泵故障信号中由于分辨率过低而分辨不出来的两个频率。其中小波簇变换的频谱细化方法所得的细化谱清晰，但需要大量的分析信号数据存放在内存，由于细化倍数为40，所以内存需要存放40960点分析数据，所用计算机要求有一定的配置。FFT-FS频谱细化方法在不增加分析信号数据长度的情况下，运用傅里叶级数法求得细化谱，而且所得细化谱的幅值和频率精度都很高。

参考文献

[1] 苗苗，朱秀慧，王海．异步电动机转子故障诊断方法研究［J］．控制工程，2007，14（5）：172-174.

[2] 胡海龙．高精度信号处理技术在激光多普勒测速中的应用研究［D］．成都：电子科技大学，2006：22-33.

[3] 申江云，宁滨．一种实时的交通信息采集处理系统的设计与实现［J］．微计算机信息，2005，21（11）：5.

[4] 田芬，刘开成．现代谱在UM2000信号检测中的探讨［D］．北京：北京交通大学，2004：19.

[5] Brian D Halligan，Ronit Y Slyper，Simon N Twigger，et al. An application for the quantitation of stable isotope labeled peptides［J］. Journal of the American Society for Mass Spectrometry，2005，16（3）：302-306.

[6] Fan Honqqi. Frame-overlapped zoom-FFT optimization in PD radar application［C］//Proceedings of 2006 CIE International Conference on Radar，2006：148-193.

[7] Ding K. Principle and method of multiple modulation Zoom spectrum analysis based on multiple analytical band-pass filter［J］. Journal of Vibration Engineering，2001，14（1）：29-35.

[8] Thomas G Fiske，Louis D Silverstein. 基于傅里叶变换的显示调制算法［J］．现代显示，2007，75（11）：35-36.

[9] 孙志玲．某些周期卷积类的宽度的精确估计［J］．内蒙古师范大学学报，2007，32（4）：428-431.

[10] 曹豫宁，李永丽，梅云，等．基于小波变换的频谱细化方法在电动机故障检测中的应用［J］．继电器，2002，6（30）：1.

[11] 黎民红．利用MATLAB和窗函数法设计FIR数字滤波器［J］．福建电脑，2007，9：

176-177.

[12] 谌乾坤. 干式真空泵的优化选择 [J]. IC 制造技术, 2004, 29 (6): 33-35.

[13] 肖军. 滚动轴承常见故障及诊断 [J]. 工程机械与维修, 2007, 12: 166-167.

[14] 杨少辉. 频谱细化方法在真空泵轴承故障诊断中的应用研究 [D]. 秦皇岛: 燕山大学, 2008.

[15] 姜万录, 杨少辉, 宋丽娜. 频谱细化方法在干式真空泵故障诊断中的应用 [J]. 机床与液压, 2008, 36 (9): 154-156.

[16] Wanlu Jiang (姜万录), Sarah K Spurgeon, John A Twiddle, et al. A Novel Wavelet Cluster-based Envelop Demodulation Approach with Application to Fault Diagnosis [C]//Proceedings of 5th International Symposium on Fluid Power Transmission and Control (ISFP' 2007), June 6-8, 2007, Beidaihe, China: 1021-1027.

第 4 章　Hilbert-Huang 变换在故障诊断中的应用

本章阐述了 Hilbert-Huang 变换（HHT）的基础理论，归纳总结了 HHT 方法存在的主要问题。针对采样率过低造成的对经验模态分解（EMD）算法的影响，提出了 EMD 的改进算法。将 HHT 用于干式真空泵故障诊断中，结果表明 HHT 在故障特征频率提取方面具有更高的分辨率和准确性。

4.1　Hilbert-Huang 变换的基本原理

1807 年，傅里叶提出了傅里叶变换方法，搭建了从时域分析到频域分析的桥梁，使在时间域内难以观测到的信号特征，可以在频域内十分清楚地展显出来。研究表明，许多事物或现象的本质区别就在于频率不同，如可见光和紫外线。因此，信号的频率表示更能够深入地揭示和表征事物的本质。也正因为这样，人们把傅里叶变换的提出看成是信号分析发展史上具有里程碑意义的一件大事。

傅里叶分析理论虽然在信号分析理论的发展过程中起了重要作用，但随着研究的深入，发现傅里叶变换是一种整体积分变换，存在一对基本矛盾：时域和频域的局部化的矛盾，即若想在时域上得到信号足够精确的信息，就得不到信号在频域上的信息，反之亦然。此外，傅里叶变换是典型的线性变换并且是一种稳态变换，因此，傅里叶分析适合分析频率不随时间变化的线性、平稳信号以及适合对信号作全局分析；不适合分析频率随时间变化的非线性、非平稳信号，也不适合对信号作局部分析。不巧的是，在机械故障诊断领域，我们所采集的信号几乎都是非稳态、非线性的时变频率信号。

为解决这个矛盾，不同的学者进行了不同的探索，一部分学者把时间和频率进行联合分析，通过研究时间和频率的联合分布，即通过时频分析以达到研究时变频率的目的，而且研究难度会大为降低。按照这一思路，人们取得了大批研究成果，如提出了像短时傅里叶变换、Winger-Ville 分布和小波分析等卓有成效的信号分析方法，使信号分析理论前进了一大步。但这并不表明上述矛盾已完全解决，因为几乎所有的时频分析方法都以傅里叶变换为最终理论依据，采用积分的分析方法，以至于时频分析方法的基函数是比较固定的，缺乏自适应性，在表示信号时都容易出现多余信号，而且受 Heisenberg 测不准原理的限制，这些时频分析方法不能精确描述频率随时间的变化。

几乎同时，一部分学者着手于瞬时频率及相关理论的研究，这个方向的研究却显得一波三折，因为他们发现给瞬时频率一个满意的定义是一件很难的事情。直到1998年，美籍华裔科学家N E Huang等人才提出了一种真正基于瞬时频率的信号处理方法——经验模态分解方法（Empirical Mode Decomposition，EMD），并在此基础上提出了希尔伯特-黄变换（Hilbert-Huang Transform，HHT），从直观上解决了上述问题。HHT是近几年刚刚兴起的一种非线性、非平稳信号的时频分析方法。

4.1.1 Hilbert-Huang变换中的基本概念

1. 特征时间尺度

描述信号特征的基本参数是时间和频率，频率能够反映信号的本质特征，但不直观。有时直接从时域观察信号的变化过程同样可以获得类似频率的信号特征，这就是特征尺度。尺度与频率是密切相关的，小的尺度对应于高的频率，大的尺度对应于低的频率，通过小波变换可以得到信号的时间-尺度谱，而不是直接的时间-频率谱。通过对信号的观察，很容易得到信号在特定要求的点之间的时间跨度，它被称为时间尺度参数。很显然，时间尺度参数和频率一样，都能够描述信号的本质。在傅里叶变换中，基函数的时间尺度参数与频率具有定量关系，表明了谐波函数的周期长度。而对于非平稳信号，时间尺度参数是基于信号特征点的特征参数，虽然与傅里叶频谱没有定量的关系，但更能够反映非平稳信号的频率特征。

Rice曾用统计的方法对时间尺度进行定义。他假设数据是线性平稳和正态分布的，并计算过零点和极值点的数目。在数学上，对任何数据$x(t)$，时间尺度的定义如下，满足

$$x(t)=0 \tag{4-1}$$

定义了所有t函数过零点的时间位置，连续两个过零点的时间跨度就被定义为过零时间尺度（Zero-crossing Scales）。

如果通过信号的极值点定义，可以得到极值尺度参数的定义，信号的极值点位置为满足式（4-2）的t值，即

$$\dot{x}(t)=0 \tag{4-2}$$

尺度参数如果定义为两个相邻的极值点之间的时间跨度，被称为极值点时间尺度（Extrema Time Scales）。

还有一种时间尺度是曲率极限点时间尺度（Curve Time Scales），即

$$\frac{\ddot{x}(t)}{(1+\dot{x}(t))^{2/3}}=0 \tag{4-3}$$

的极值点间的时间尺度。

Huang等人分析认为，时间尺度代表了信号的局部振荡尺度，并且仅表示一种振荡模式。这种振荡从一个极值点到另一个相同的极值点，因此时间尺度是振荡的

内在隐含尺度，称为特征时间尺度。

对满足线性和正态分布的平稳信号，过零尺度参数和极值尺度是一致的，而对非线性、非平稳信号，采用不同的定义将会得到不同的结果。但是，无论采用哪一种尺度参数，时间跨度都只与相邻的两个特征点有关，因此反映了信号随时间变化的局部特征。在大多数情况下，采用极值尺度参数，因为对基于过零点的时间跨度测量比较困难，对一些信号有可能在两个过零点之间存在多个极值点，同时对一些没有过零点的信号将无法定义它的时间尺度参数。而基于极值点的时间跨度测量法，不管信号是否存在过零点，都能有效地找出信号的所有模态，从某一极大值（或极小值）到另外一个极大值（或极小值），定义了信号的局部波动特征，这个时间跨度被称为特征尺度参数，它反映了信号不同模态的特征。正是由于这些原因，在 HHT 的信号分解方法中，采用了基于极值点的特征尺度参数。

2. 瞬时频率

从物理学的角度来看，信号可分为单分量和多分量信号两大类。单分量信号在任意时刻只有一个频率，该频率称为信号的瞬时频率。多分量信号则在不同时刻具有各自的瞬时频率。瞬时频率最早是由 Carson 与 Fry 和 Gabor 分别定义的，而且两种定义不同。后来，Ville 统一了这两种不同的定义，将信号 $x(t)=a(t)\cos\theta(t)$ 的瞬时频率定义为

$$f_{\mathrm{i}}(t)=\frac{1}{2\pi}\times\frac{\mathrm{d}[\arg z(t)]}{\mathrm{d}t} \tag{4-4}$$

其中，$z(t)$ 为解析信号，$z(t)=x(t)+\mathrm{j}s(t)$；下标 i 代表瞬时（Instantaneous），而 $\arg z(t)$ 表示为 $z(t)$ 的相位角。Ville 进一步注意到：由于瞬时频率是时变的，所以应该存在有与瞬时频率相对应的瞬时谱，并且该瞬时谱的平均频率即为瞬时频率。利用 Gabor 的平均测度，Ville 证明了：信号谱的平均频率等于瞬时频率的平均时间，即 $<f>=<f_{\mathrm{i}}>$，其中：

$$<f>=\frac{\int_{-\infty}^{+\infty}f\mid Z(f)\mid^2\mathrm{d}f}{\int_{-\infty}^{+\infty}\mid Z(f)\mid^2\mathrm{d}f} \tag{4-5}$$

$$<f_{\mathrm{i}}>=\frac{\int_{-\infty}^{+\infty}f_{\mathrm{i}}\mid z(t)\mid^2\mathrm{d}t}{\int_{-\infty}^{+\infty}\mid z(t)\mid^2\mathrm{d}t} \tag{4-6}$$

这就是瞬时频率的传统定义——解析信号相位求导（Derivative of the Phase of the Analytical Signal，DPAS）定义。通过式（4-4）可知瞬时频率定义为解析信号 $z(t)$ 的相位的导数。

3. 固有模态函数

尽管瞬时频率的 DPAS 定义在许多情况下都能导出与人们的直观感知一致的结

论，但对任意一个信号直接按 DPAS 定义求取瞬时频率仍会产生一些“悖论”，对此 Cohen 提出了用单分量信号和多分量信号进行解释的观点：因为式（4-4）是单值函数，所以在用其计算瞬时频率时，对应的信号应有所限制，使其只是一个单分量信号。但遗憾的是，到目前为止，仍没有人给出如何判断一个信号是否是单分量信号的明确定义。基于这个原因，以往在计算信号的瞬时频率时常常约定信号为“窄带”信号，以使其具有物理意义。

关于带宽有两种定义。一种是根据信号的频率特性，若信号是平稳与高斯的，那么带宽可按如下方法定义：信号单位时间内过零点的数目为

$$n_0 = \frac{1}{\pi}\left(\frac{m_2}{m_0}\right)^{1/2} \tag{4-7}$$

同时，单位时间内极值点的数目为

$$n_1 = \frac{1}{\pi}\left(\frac{m_4}{m_2}\right)^{1/2} \tag{4-8}$$

其中，m_i 是第 i 阶谱矩。于是带宽 v 被定义为

$$n_1^2 - n_0^2 = \frac{1}{\pi^2}\frac{m_4 m_0 - m_2^2}{m_2 m_0} = \frac{1}{\pi^2}v^2 \tag{4-9}$$

上式给出了带宽的一个标准测量方法。对于一个窄带信号 $v=0$，则意味着极值点数目和过零点数目相等。

另一个关于带宽的更一般的定义也是基于谱矩的。对于解析信号 $z(t)=a(t)\exp[\mathrm{j}\phi(t)]$，其中 $a(t)$ 和 $\phi(t)$ 都是时间的函数，若该解析信号的频谱为 $Z(\omega)$，那么其平均频率为

$$<\omega> = \int_{-\infty}^{+\infty}\omega \mid Z(\omega)\mid^2 \mathrm{d}\omega \tag{4-10}$$

还可以用式（4-11）给出

$$<\omega> = \int_{-\infty}^{+\infty} z^*(t)\frac{1}{\mathrm{j}}\frac{\mathrm{d}z(t)}{\mathrm{d}t}\mathrm{d}t = \int_{-\infty}^{+\infty}[\dot{\phi}(t) - \mathrm{j}\frac{\dot{a}(t)}{a(t)}]$$

$$a^2(t)\mathrm{d}t = \int_{-\infty}^{+\infty}\dot{\phi}(t)a^2(t)\mathrm{d}t \tag{4-11}$$

根据这个表达式，Cohen（1995）认为 $\dot{\phi}(t)$ 就是瞬时频率。用这种表示法，带宽可以定义为

$$v^2 = \frac{(\omega - <\omega>)^2}{<\omega>^2} = \frac{1}{<\omega>^2}\int_{-\infty}^{+\infty}(\omega - <\omega>)^2 \mid Z(\omega)\mid^2 \mathrm{d}\omega =$$

$$\frac{1}{<\omega>^2}\int_{-\infty}^{+\infty} z^*(t)(\omega - <\omega>)^2 \frac{1}{\mathrm{j}}\frac{\mathrm{d}z(t)}{\mathrm{d}t}\mathrm{d}t =$$

$$\frac{1}{<\omega>^2}\left[\int_{-\infty}^{+\infty}\dot{a}^2(t)\mathrm{d}t + \int_{-\infty}^{+\infty}(\dot{\phi}(t) - <\omega>)^2 a^2(t)\mathrm{d}t\right] \tag{4-12}$$

式（4-12）清楚地表明，带宽是两项的平均值，一项取决于幅度，另一项取决于相位。对于窄带信号，带宽值 v^2 必须很小，这就导致式（4-12）中的 $\phi(t)$ 和 $a(t)$ 必须是渐变函数。

Huang 等人分析认为，式（4-9）和式（4-12）均是在全局意义上定义的带宽，这两种定义都过于严格却又同时缺乏精确性。结果，由于带宽的限制，通过 DPAS 定义获得瞬时频率的方法没有被严格建立起来。对于实际的信号分析，必须把这些条件转换成物理上可实现的步骤，用一个简单的方法加以实现。为此，必须把这些基于信号全局性的限定条件修改为局部的限定条件。

用一个简单的例子来说明这些约束条件。对于一个简单的正弦函数：

$$x(t) = \sin(t) \tag{4-13}$$

其 Hilbert 变换为 $-\cos t$。$x-y$ 的相位图是一个简单的单位圆，如图 4-1a 所示，其相位函数是一条直线，如图 4-1b。图 4-1c 中显示了瞬时频率，为一常数值。如果在 $x(t)$ 上加一常量 α，即

$$x(t) = \alpha + \sin t \tag{4-14}$$

其 $x-y$ 的相位图仍为单位圆，但是圆心偏移了 α 值大小。当 $\alpha<1$ 时，中心在圆内，此时函数破坏了约束条件，因为它的 Fourier 谱含有一个直流分量，其过零点均值频率与 $\alpha=0$ 时一样，但相位函数和瞬时频率有明显不同。当 $\alpha>1$ 时，中心在圆外，此时函数不满足约束条件，其相位函数和瞬时频率都有负值，这是没有意义的。这个简单的例子说明，即使是一个简单的信号，如正弦信号，瞬时频率有意义的条件是函数是局部对称的，并且局部均值为零。

一个内禀模态不再限定为窄带信号，而是幅值和频率可调制的。按这一定义，纯粹的频率和幅值调制函数都可以是内禀模态函数（Intrinsic Mode Function，IMF），即使按传统定义它们也有一定的带宽。图 4-2 是一个 IMF 的例子。

对于一般的数据，叠加波相当于 $\alpha>1$ 的情况；非对称的波形相当于 $\alpha<1$ 的情况。这个局部约束条件可用于代替前面提到的全局约束条件，将信号分解为瞬时频率有意义的各个分量，就可对非线性非平稳信号进行更好的分析，分解出来的函数定义为内禀模态函数，该函数的任何一点瞬时频率都有意义了。

在 HHT 中，为了计算瞬时频率，定义了内禀模态函数 IMF，它是满足单分量信号物理解释的一类信号，在每一时刻只有单一频率成分，从而使得瞬时频率具有了物理意义。一个 IMF 必须满足下面两个条件：

1）在整个数据段内，极值点的个数和过零点的个数必须相等或相差最多不能超过一个。

2）在任意时刻，由局部极大值点形成的上包络线和由局部极小值点形成的下包络线的平均值为零，即上、下包络线相对时间轴局部对称。

第一个条件类似于高斯正态平稳过程的传统窄带要求，而第二个条件是为了保

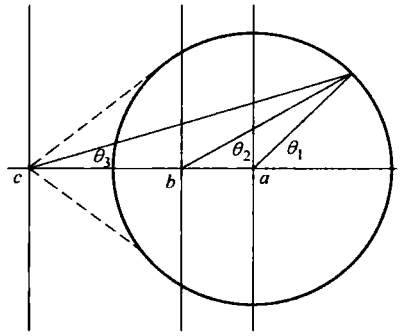

a 为 $\alpha=0$，b 为 $\alpha<1$，c 为 $\alpha>1$

a)

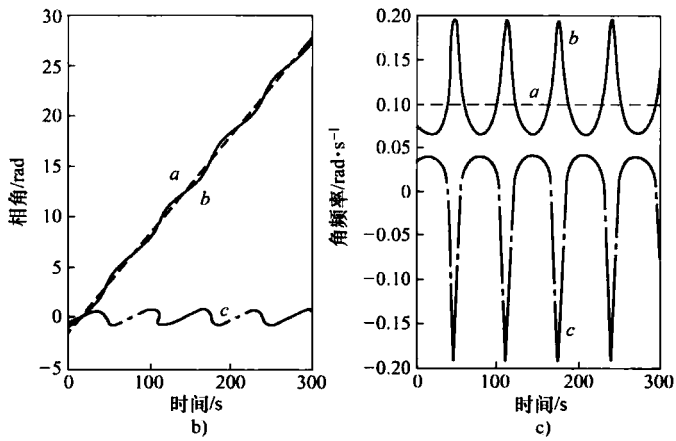

b) c)

图 4-1 瞬时频率的物理解释

a）所分析函数的相平面 b）所分析函数的相位函数

c）式（4-4）中的瞬时频率值

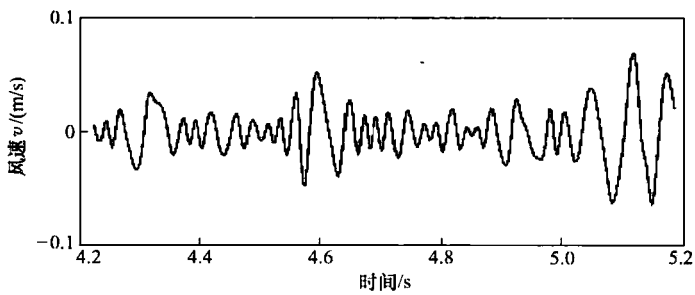

图 4-2 一个 IMF 的例子

证由 IMF 求出的瞬时频率有意义。基于这个定义，IMF 反映了信号内部固有的波动性，在它的每一个周期上，仅仅含有一个波动模态，不存在多个波动模态混叠的现象。Huang 等人认为，对非平稳信号局部均值涉及局部时间尺度，这是不可能定义的，因此用信号极大值和极小值确定的包络线的均值逼近信号的均值，并认为这种逼近效果即使在最坏的情况下，用 DPAS 定义算出的瞬时频率也与物理意义一致。一个 IMF 不再限定为窄带信号，而是幅值和频率可调制的。按这一定义纯粹的频率和幅值调制函数都可以是 IMF，即使按传统定义它们也有一定的带宽。

对每一个 IMF，其瞬时频率可由 DPAS 定义求出。但实际中的信号大多都不是 IMF，任何时候，信号中都可能包含超过一个的振动模态，这就是对一般信号简单地使用 Hilbert 变换不能充分描述其频率内容的原因。因此，为了获得有意义的瞬时频率，需要将信号分解成不同的 IMF 分量。

4.1.2　Hilbert-Huang 变换算法实现过程

1. EMD 方法

对于 IMF，可以用 Hilbert 变换构造解析函数，然后求出瞬时频率。而对于一般的不满足内禀模态函数条件的复杂信号，先要采用 EMD 方法将其进行分解。EMD 方法是基于一个假设：任何复杂信号都是由一些不同的内禀模态函数组成，每一内禀模态函数不论是线性或是非线性、非平稳的，都具有相同数量的极值点和过零点，在相邻的两个过零点之间只有一个极值点，而且上、下包络线关于时间轴局部对称，任何两个模态之间是相互独立的；任何时候，一个信号都可以包含许多 IMF，模态函数的叠加，便形成复杂信号。在此基础上，可以采用 EMD 方法通过以下的步骤对任何信号 $x(t)$ 进行分解：

1）初始化：$r_1(t)=x(t)$，$i=1$。

2）筛选：得到第 i 个 IMF。

① 初始化：$h_{i,1}(t)=r_i(t)$，$j=1$；

② 找出 $h_{i,j-1}(t)$ 的局部极值点；

③ 对 $h_{i,j-1}(t)$ 的极大值和极小值点分别采用三次样条函数拟合为上和下包络线；

④ 计算上、下包络线的平均值 $m_{i,j-1}(t)$；

⑤ $h_{i,j}(t)=h_{i,j-1}(t)-m_{i,j-1}(t)$；

⑥ 若 $\frac{1}{T}\int_0^T \frac{|h_{i,j}(t)-h_{i,j-1}(t)|^2}{h_{i,j-1}(t)^2}\mathrm{d}t \leqslant 0.3$，则 $c_i(t)=h_{i,j}(t)$，其中 T 为信号的总长度；否则，令 $j=j+1$，转到②。

3）差值：$r_i(t)=r_{i-1}(t)-c_i(t)$。

4）结束：若 $r_i(t)$ 极值点数不少于2个，则 $i=i+1$，转到2）；否则，分解结束，$r_i(t)$ 是残余分量。

算法最后可得：

$$x(t)=\sum_{i=1}^{n}c_i(t)+r_n(t) \tag{4-15}$$

即原始信号可表示为 n 个 IMF 分量和一个残余函数的和。

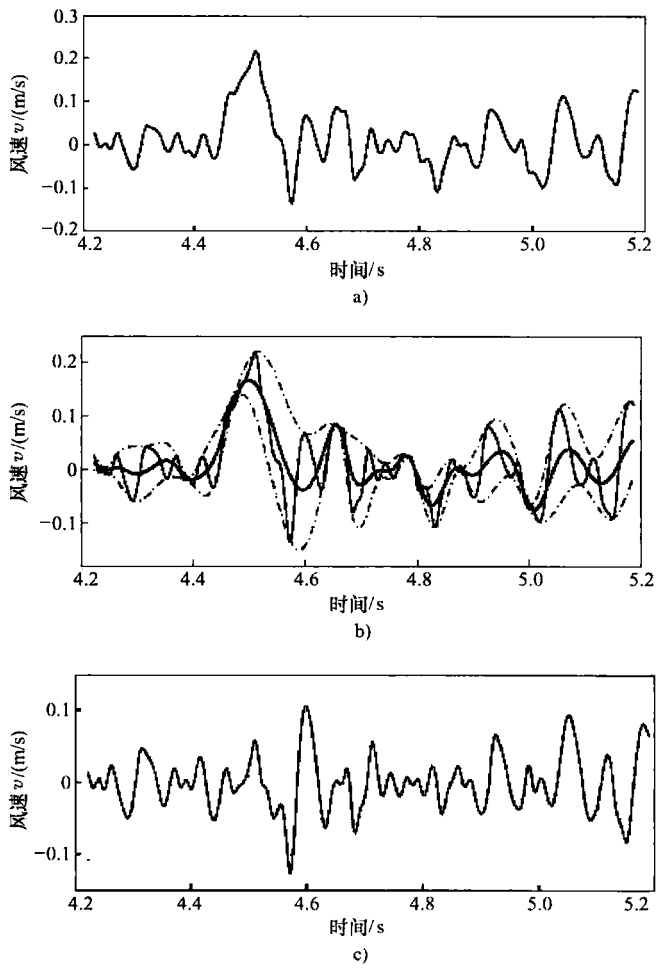

图 4-3 筛法过程图解

a）原信号 b）信号的上、下包络线和均值曲线 c）原信号与均值曲线的差

以上所用的方法就称为经验模态分解（EMD），也称为经验筛法。这一过程如图4-3所示，图4-3a是原信号；图4-3b中实线为原信号，虚线为上、下包络线，

加粗实线为上下包络信号的均值曲线；图 4-3c 即为原信号与均值曲线的差。

2. EMD 分解的完备性和正交性

所谓信号分解方法的完备性，就是把分解后的各个分量相加能获得原信号的性质。Huang 指出，随着 EMD 分解的深入进行得到的 IMF 分量所包含的振荡频率越来越低；而对于重构过程，随着重构的进行，重构信号越来越接近原始信号。最后得到的重构信号与原信号之间只相差一个趋势项和计算误差，计算误差是计算过程中由于舍入误差所引起的，一般该误差很小。式（4-15）表示了信号分解和重构之间的关系，该式表明 EMD 分解方法具有足够的完备性。

EMD 分解的正交性在理论上是不满足的，但在实际物理意义上是满足的，但直到现在未能从理论上进行严格地证明。利用分解，各分量之间是局部正交的，因各分量是由信号与其局部均值得到的，故

$$\overline{(x(t)-\overline{x(t)})\overline{x(t)}}=0 \tag{4-16}$$

然而，式（4-16）不一定严格成立，因为均值是通过求包络求得的，所以它不是真实的均值。另外，每一个 IMF 分量只是信号中的一部分。由于上述的近似，泄漏是不可避免的，但是泄漏是很小的一部分。

同时，EMD 的正交性也可以由后验数值计算进行检验。首先，将式（4-15）改写为

$$x(t)=\sum_{j=1}^{n+1}c_j(t) \tag{4-17}$$

该式把残余量 $r_n(t)$ 作为一个附加的组分 $c_{n+1}(t)$，即 $r_n(t)=c_{n+1}(t)$，对式(4-17)两边进行平方得

$$x^2(t)=\sum_{j=1}^{n+1}c_j^2(t)+2\sum_{i=1}^{n+1}\sum_{j=1,j\neq i}^{n+1}c_i(t)c_j(t) \tag{4-18}$$

若分解是正交的，则式（4-18）右边交叉项应该为零，这样，对于信号 $x(t)$ 的正交性指标（Index of Orthogonality，IO）可定义为

$$\mathrm{IO}=\int_0^T\frac{\sum_{i=1}^{n+1}\sum_{j=1,j\neq i}^{n+1}c_i(t)c_j(t)}{x^2(t)}\mathrm{d}t \tag{4-19}$$

式中　T 是信号的总长度。

大量的数字实验验证表明，一般的数据正交性指标不超过 1%，对于一些很短的数据序列，极限情况下可能达到 5%。

正交性也可定义到任意两个 IMF 分量，如 $c_f(t)$ 和 $c_g(t)$，其正交性测量为

$$\mathrm{IO}_{fg}=\int_0^T\frac{c_f(t)c_g(t)}{c_f^2(t)+c_g^2(t)}\mathrm{d}t \tag{4-20}$$

应当注意这里的正交性都是局部意义上的正交，对于某些特殊数据，相邻的分

量可能在不同的时间段上均有相近的频率成分，因此从全局上并不正交。另外，由于数据是有限长的，即使具有不同频率的纯粹的正弦分量也不是完全正交的。

3. Hilbert 谱及边际谱

在内禀模态和 EMD 方法的基础上，Huang 等人系统地提出了一种分析信号的新理论或新方法，命名为希尔伯特-黄变换（Hilbert-Huang Transform，HHT）。

EMD 方法基于信号的局部特征时间尺度，将信号自适应地分解为若干个 IMF 分量之和，这样使得瞬时频率这一概念具有了实际的物理意义，从而可以计算得到每一个 IMF 分量的瞬时频率和瞬时幅值。

对式（4-15）中的每个内禀模态函数 $c_i(t)$ 作 Hilbert 变换得到

$$\hat{c}_i(t) = c_i(t) * \frac{1}{\pi t} = \frac{1}{\pi}\int_{-\infty}^{\infty} \frac{c_i(\tau)}{t-\tau}\mathrm{d}\tau \tag{4-21}$$

构成解析信号为

$$z_i(t) = c_i(t) + \mathrm{j}\hat{c}_i(t) = a_i(t)\exp[\mathrm{j}\theta_i(t)] \tag{4-22}$$

其中，$a_i(t) = [c_i^2(t) + \hat{c}_i^2(t)]^{1/2}$，$\theta_i(t) = \arctan[\hat{c}_i(t)/c_i(t)]$

式（4-22）是极坐标系中的表达形式，明确表达了瞬时振幅和瞬时相位，很好地反映了数据的瞬时特性。在此基础上定义的瞬时频率为

$$f_i(t) = \frac{1}{2\pi}\omega_i(t) = \frac{1}{2\pi}\frac{\mathrm{d}\theta_i(t)}{\mathrm{d}t} \tag{4-23}$$

这样，就可以把信号 $x(t)$ 展开成如下形式

$$x(t) = \mathrm{Re}\sum_{i=1}^{n} a_i(t)\exp[\mathrm{j}\theta_i(t)] = \mathrm{Re}\sum_{i=1}^{n} a_i(t)\exp\left[\mathrm{j}\int\omega_i(t)\mathrm{d}t\right] \tag{4-24}$$

其中，Re 表示取实部。这里省略了残余量 $r_n(t)$。

式（4-24）的右部称为信号 $x(t)$ 的 Hilbert 谱，记作：

$$H(\omega,t) = \mathrm{Re}\sum_{i=1}^{n} a_i(t)\exp\left[\mathrm{j}\int\omega_i(t)\mathrm{d}t\right] \tag{4-25}$$

再定义 Hilbert 边际谱

$$h(\omega) = \int_0^T H(\omega,t)\mathrm{d}t \tag{4-26}$$

式中，T 是信号的总长度。

$H(\omega, t)$ 精确地表述了信号的幅值在整个时频平面上随时间和频率的变化规律，而 $h(\omega)$ 反映了信号的幅值在整个频率段上随频率的变化情况。

4.1.3 Hilbert-Huang 变换存在的问题

1. 基本理论的不足

纵观 EMD 的提出和现有文献，其理论基础都还有待进一步完善，IMF 还只有

描述性定义，从有限例子和经验中得到的关于IMF对称性的要求还难以让人完全满意；虽然众多例子表明EMD的结果是直观合理的，但理论框架还不成熟。EMD算法还没有建立一个合适的数学模型，缺乏严格的数学基础，很多诸如收敛性、唯一性、正交性等数学问题根本无法进行证明，甚至连“什么信号适合进行EMD分析”目前也无法解释；此外，算法本身是操作性的，到目前为止也是经验的（正如算法的名称一样），在没有找到其理论支撑之前，无从考究。

2. 包络线和均值曲线的拟合

这是HHT的关键问题，它在很大程度上将影响到新理论的成熟和推广应用。现有文献几乎都采用三次样条插值，但是没有理论依据能够证明三次样条插值是最好的插值方法，并且实践中发现三次样条插值容易造成过冲和欠冲现象。研究更合理的插值方法，是发展和完善HHT的一个重要方向。

3. 模态混叠

实验表明在经验筛法筛选过程中时常会遇到模态的混叠问题。虽然Huang等人和谭善文先后独立提出了解决措施，但都还没有对形成这种现象的原因作更进一步地分析。Huang等人虽然指出HHT需用过采样以提高瞬时频率的精度，但也没有对其原因加以理论说明。

HHT的经验筛法按照特征时间尺度对信号进行有效地分解，一般情况下，随着IMF阶次的增大，相应的分解分量IMF的特征尺度也将变大，从而得时间尺度从小到大的IMF信号，表现在频谱上是从高频向低频对信号进行滤波的过程。所以当信号的时间尺度存在跳跃性变化时，就无法根据特征尺度有效地分离出不同的模态成分，使得同一个IMF里，包含着多个模态，不能清晰地反映信号的内在性质。

很明显，这是由于时间尺度特征在某段时间显著变化引起的。模态混叠现象缺乏物理基础，因为任何一个物理意义上的简谐振动所产生的波形在周期上不可能有显著突变。同时由于模态混叠现象的出现影响了它的工程应用。

Huang等人和谭善文均发现了模态混叠现象，并各自提出了类似的解决方法，即在经验筛法时，每次分解规定分解尺度的上限。

Deering R等人提出了一种采用掩模信号解决模态混叠问题的方法。该方法的基本思想如下：

1）利用原始信号$s(n)$的频率信息构成一个掩模信号（Masking Signal）$x(n)$；

2）对信号$x_+(n)=s(n)+x(n)$作EMD处理得到IMF分量$z_+(n)$，对信号$x_-(n)=s(n)-x(n)$作EMD处理得到IMF分量$z_-(n)$；

3）原始信号$s(n)$的IMF分量为$z(n)=[z_+(n)+z_-(n)]/2$。

4. 端点效应

HHT 虽然能有效地分析非平稳信号，但是，在应用 HHT 时存在一个比较严重的问题，即端点效应问题。其表现在两个方面，在运用 EMD 方法对非平稳信号进行分解时，在数据的两端会产生发散现象，并且这种发散的结果会逐渐向内“污染”整个数据序列而使所得分解结果严重失真。另一方面，在对 IMF 分量进行 Hilbert变换时，信号的两端也会出现严重的端点效应。如果这种端点效应得不到有效抑制，那么得到的 Hilbert 谱将不能反映原始信号的特征。对于一个较长的数据序列来说，可以根据极值点的情况不断抛弃两端的数据来保证所得到的包络的失真度达到最小；而对于一个短数据序列来讲，这样的操作就变得完全不可行。Huang 在其介绍 EMD 方法的文章中虽然提到了根据特征波对原有数据序列进行延拓的方法，但是没有给出确定合适的特征波的具体方法。Huang 在提出 EMD 方法的同时已经开发了一种有效的数据延拓方法，并已经将该方法在美国申请了专利，由此可以看出数据延拓方法在 EMD 方法中起到了极为关键的作用。

5. 筛选终止条件问题

EMD 分解过程事实上是一个筛选过程，即首先从原始信号中分离出最好的局部模态分量。但是在应用这一处理过程时，应该特别小心，因为过多地重复该处理过程会导致基本模态分量变成纯粹的频率调制信号，而其幅度变成为恒定的。为了保证基本模态分量保存足够的反映物理实际的幅度与频率调制信息，必须确定一个筛选过程停止的准则。这个筛选过程停止准则可以通过限制两个连续的处理结果之间的标准差的大小来实现。

两个连续的处理结果之间的标准差 SD 可定义为

$$SD = \frac{1}{T}\int_0^T \frac{|h_{k-1}(t) - h_k(t)|^2}{h_{k-1}^2(t)}\mathrm{d}t \tag{4-27}$$

其中，$h_k(t)$、$h_{k-1}(t)$ 是在筛选基本模态分量的过程中，两个连续的处理结果的时间序列，SD 的一个典型值可以在 0.2 ~ 0.3 之间。

分量的终止条件对算法的性能影响很大，它直接关系到 IMF 分量的物理意义和真实性。目前筛选的终止条件只是一个经验值，而没有可靠的理论依据。不同的筛选终止条件，其分解所得内禀模态函数的个数和幅值也不同，因此筛选终止条件直接关系到分解结果是否真实，如果筛法没有可靠的理论依据将会导致分析结果不唯一或者得到错误的结果。

4.2 EMD 算法的改进

本节研究了采样频率对 EMD 算法的影响，针对采样过低造成的对 EMD 算法的影响，采用了一种信号内插式方法对信号进行重构，有效地抑制了分解结果中多余

模态的出现，提高了 EMD 算法的效率和精度。在筛选算法方面，引进了局部筛选算法和筛选终止准则，可提高模态分辨率。研究了基于神经网络预测的数据序列延拓法、镜像闭合延拓法两种算法存在的不足，针对这些不足采用了可变长包络极值镜像延拓法，减少了计算量，提高了 EMD 分解精度。

4.2.1　采样频率对 EMD 分解的影响及其改进

1. 采样频率对 EMD 分解的影响

由于 EMD 算法是通过算法过程定义的，而并非由确定的理论公式定义的，所以对其进行准确的理论分析非常困难，目前只能借助大量的数字仿真手段不断对其性能进行深入研究。

当将一个幅值和频率不变的正弦信号进行 EMD 时，按照我们的期望应该只得到一个 IMF，即信号本身，而不存在其他的余项。但是通过不同的采样频率对同一个幅值和频率不变的正弦信号进行采样，然后将其进行 EMD，得到的结果和想象的并不一样。下面仿真一个幅值和频率不变的正弦信号，其解析表达式为

$$s(t)=6\sin(2\pi\cdot 500\cdot t) \tag{4-28}$$

分别用 2kHz，2.5kHz，3kHz 对该信号进行采样，信号采样时间为 0.15s，然后对其进行 EMD，得到结果如图 4-4、图 4-5 和图 4-6 所示。

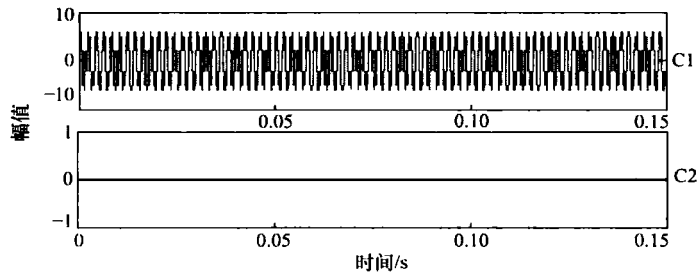

图 4-4　信号在采样频率为 2kHz 时的 EMD 图

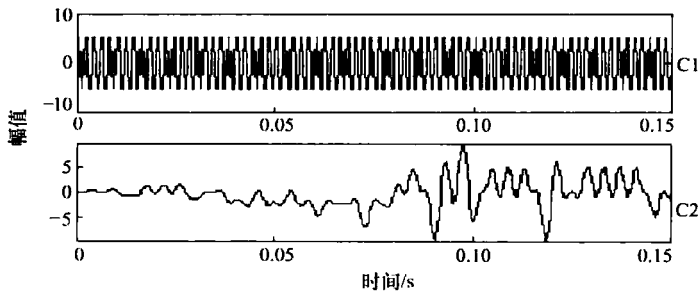

图 4-5　信号在采样频率为 2.5kHz 时的 EMD 图

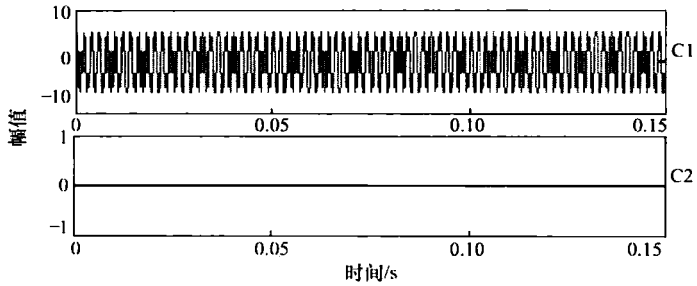

图 4-6 信号在采样频率为 3kHz 时的 EMD 图

通过上面三图，我们可以看到当采样频率为 2kHz 和 3kHz 时，仿真信号只得到一个 IMF c_1（即信号本身），余项 r_1（即 c_2）为零。当采样频率为 2.5kHz 时，除了得到第一个 IMF c_1 以外，还得到了不应该含有的剩余分量 c_2，虽然多余模态的幅值比较小，但是它的产生使得在应用 EMD 时，造成了很多负面影响。直观上可以看出选取不同的采样频率对原始信号进行采样，得到的信号进行 EMD 的效果是不一样的。

法国 INRIA 实验室的学者 Gabriel 等通过仿真发现了采样频率对信号 EMD 的效果影响的规律，具体做法：用同样的采样频率对不同频率相同幅值的信号进行采样，然后用式（4-29）比较发现采样频率对信号经验模式分解效果影响的规律。

$$e(f) = \left[\sum_n [x_f(n) - d_1(n)]^2 \Big/ \sum_n x_f^2(n) \right]^{1/2} \tag{4-29}$$

式中，$x_f = \cos 2\pi ft$ 为仿真信号，f 为信号的频率；n 为仿真信号的点数；$d_1(n)$ 为信号分解的第一个 IMF。在仿真中，取 $n = 257$，为了研究方便，对频率进行了归一化处理，f 按照式（4-30）所示的等比数列取值。

$$f_1 = \frac{1}{2 \times 257},\ q = 257^{1/256},\ f_n = f_1 \times q^{n-1},\ f_{257} = \frac{1}{2} \tag{4-30}$$

这样，分别可以仿真得到采样频率 $f_s = 1$ 的 257 个余弦信号，每个信号的长度均为 256 个点。然后对 257 个仿真信号分别进行 EMD 并按照式（4-29）计算，为了消除端点效应的影响，每个信号与分解出来的第一个 IMF 的差在求和时信号长度 n 从第 64 个点开始到第 192 个点结束，仿真结果如图 4-7 所示。

从图 4-7 中看出，不同频率信号分解结果因信号频率的不同差异明显：

1）当采样频率是信号频率的 2 的整数次幂时，分解得到的第一个 IMF 和原始信号之间的误差非常小。

2）随着采样频率的提高，分解得到的误差总体是逐渐减小的趋势。这种规律和 EMD 方法中三次样条插值包络的拟合过冲和欠冲有关。

上述分析表明，为了减小 EMD 分解的误差，提高分解的精度和效率，在采样

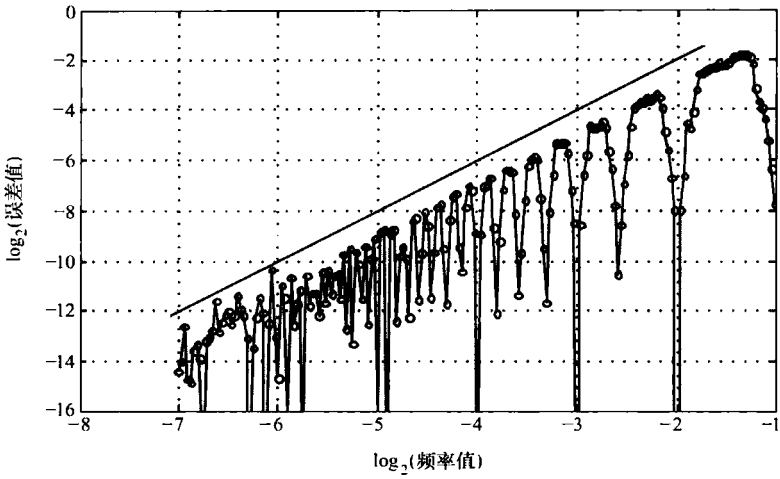

图 4-7　单一频率 EMD 分解误差图

时应尽量使采样频率为信号频率的 2 的整数次幂，而且应该尽可能地提高采样频率，获取信号所有的极值点。在机电设备故障诊断中，振动信号的采集方式主要有两种：一种为整周期等相位采集方式；另一种为等时间间隔采集方式。对于这两种采样方式，为了更适合对振动信号进行基于 EMD 的时频分析，应根据信号的特点和分析的目的选择合适的采样频率，在允许的情况下选择尽量高的采样频率，即采用过采样。

2. 基于对信号内插式重构的 EMD 改进算法

为了满足 EMD 分解对信号的要求，提高采样频率，增加采样点数，必须在 EMD 分解前对信号进行重构，在此采用内插的方式来增加信号的点数，实现对信号的重构，其重构信号为

$$f(t)=T_s\frac{\omega_c}{\pi}\sum_{n=-\infty}^{+\infty}f(nT_s)\operatorname{sinc}\left[\frac{\omega_c}{\pi}(t-n)T_s\right] \tag{4-31}$$

式中，T_s 为采样间隔；ω_c 为滤波器的截止频率，一般取为原始信号带宽的 111 倍；$f(nT_s)$ 为采样信号。重构的实质是通过内插的方式来增加信号的点数，从而达到增加采样频率的目的。

对一模拟仿真信号进行分析，信号如下

$$x(t)=\cos[2\pi x(30+36t)]+\cos(2\pi t) \tag{4-32}$$

信号如图 4-8 所示，对信号进行 2s 长度的采样，采样频率为 200Hz。此时对仿真信号进行 EMD 分解，得到的分解结果如图 4-9 所示。从图 4-9 中可以看出，在分解的结果中出现了原始信号中没有包含的频率成分 C2，这是由于 EMD 算法是一种时域处理方法，其分解的结果依赖于原始数据以及相应的波形，如果对信号的

采样频率没有高到一定程度，就可能没有采集到部分极值点。因此，利用三次样条插值作包络时，所作的包络曲线并不平滑（含有高频成分）。根据前面的 EMD 理论可知，这会使分解的结果出现不应该含有的模态或者模态的物理意义不明显等缺点，还使得得到的瞬时频率的分辨率变低。

利用式（4-31）对上面模拟的信号进行重构，把重构后的信号再进行 EMD 分解，得到的结果如图 4-10 所示。

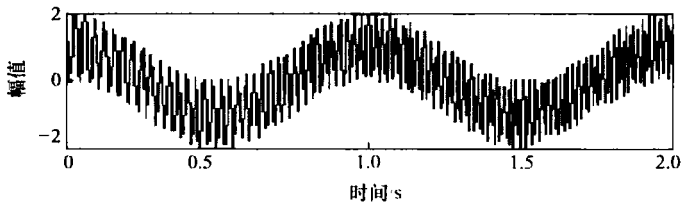

图 4-8 仿真信号时域波形图

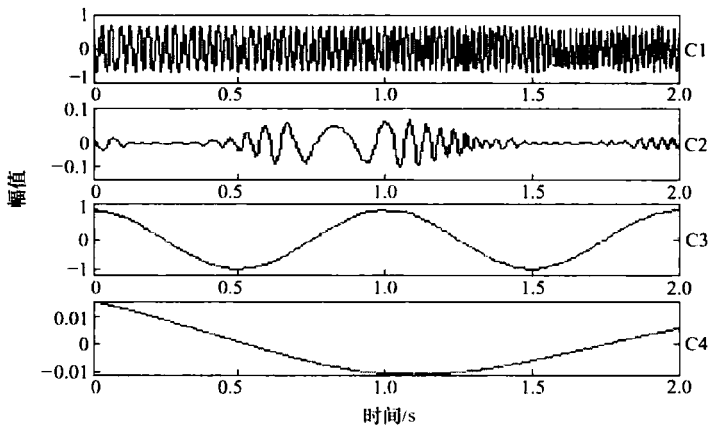

图 4-9 仿真信号 EMD 分解图

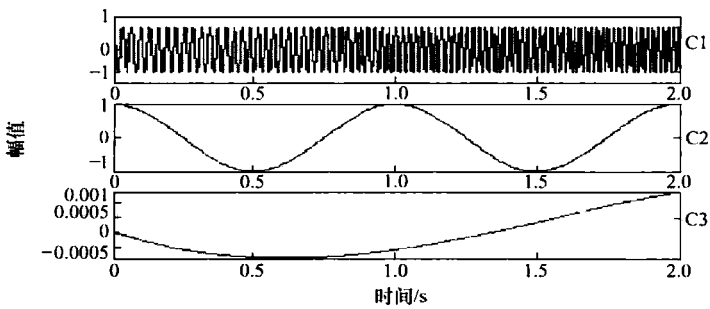

图 4-10 重构信号 EMD 分解图

从图 4-10 中可以看出，C1 为 $f=36$Hz 的 IMF 分量，C2 为 $f=1$Hz 的 IMF 分量，C3 为残余分量，与图 4-9 比较可知，重构信号的 EMD 结果已经有了很大的改善，其结果去掉了多余的模态，使得模态的物理解释更加清晰。因此，在进行 EMD 分解前，利用信号重构的方法可以消除不同采样频率对信号 EMD 结果的影响，依据经验。在进行 EMD 分解时，当重构后的信号采样频率达到原始信号中最高频率的 10 倍以上，就能取得比较满意的效果。

4.2.2　EMD 筛选算法的改进

1. 经典筛选算法

图 4-11 为实现经典筛选算法的程序流程。从该过程可以看出，在经典算法里，重复筛选过程是用于整段信号，直到信号的每一段都达到 IMF 的标准。仔细分析起来，这样做是欠妥当的，因为在筛选过程中，总会出现这样一种局面，即信号一部分已经先达到 IMF 的标准，而另一部分还没有达到，按照上述方法，为了使后一部分达到标准，整段信号都要重复筛选，这样会造成先达到 IMF 标准的部分进行了过多的重复筛选过程，造成过分解。过分解会导致基本模式分量变成纯粹的频率调制信号，而幅度变成恒定的，还会引起模态分辨率降低，从而使 EMD 分解效果降低，因此对经典筛选算法需要进行改进。

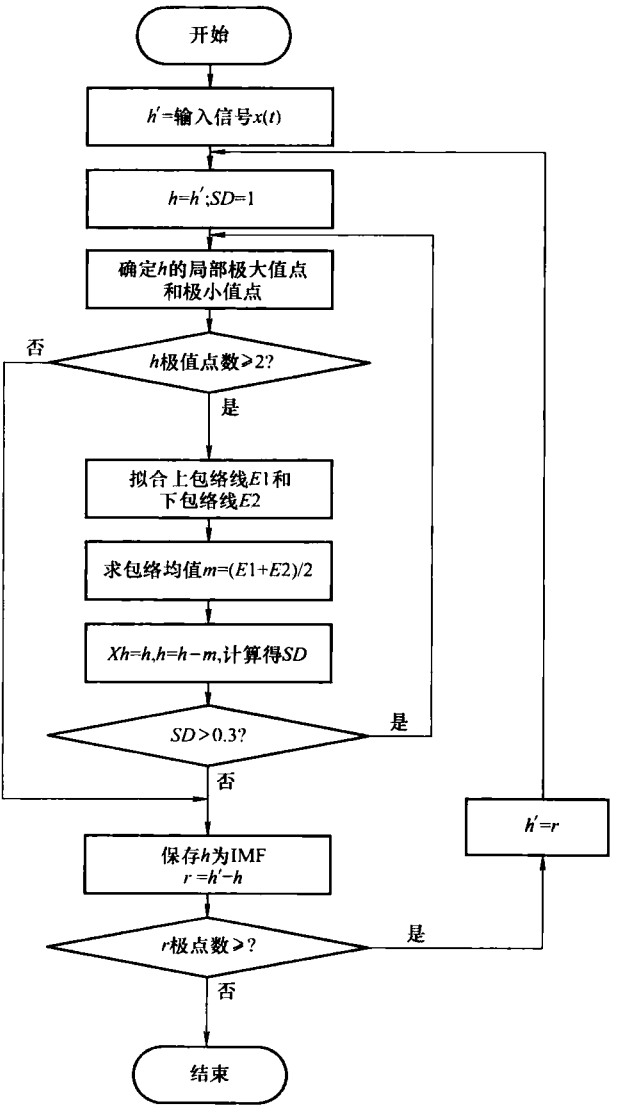

图 4-11　EMD 的算法流程

2. EMD 筛选算法的改进

改进算法的思路就是只让没有达到 IMF 标准的信号参加下一轮的筛选。把经典算法步骤 2 的 $h_j(t)=h_{j-1}(t)-$

$m_{j-1}(t)$改为

$$h_j(t)=h_{j-1}(t)-\lambda(t)m_{j-1}(t),\ 0\leqslant\lambda(t)\leqslant 1 \tag{4-33}$$

$\lambda(t)$ 为一加权系数。在不符合 IMF 的信号段，$\lambda(t)$ 为 1；在该段信号附近 $0\leqslant\lambda(t)\leqslant 1$；在远离该信号段并已经达到 IMF 标准的信号段，$\lambda(t)=0$。这种算法称为局部筛选算法。

实现局部筛选算法关键是建立加权函数 $\lambda(t)$。首先找出不符合 IMF 条件的信号段，然后确定该段信号两端要延拓的长度，最后确定一个函数关系使系数在延拓的长度内从 1 衰减到 0。计算信号段两端延拓长度的方法和衰减的函数关系就像 EMD 分解中的插值算法一样并不是唯一的。具体算法如下：

1）找出不符合要求信号段的左、右端点坐标 L_d、R_d，计算该段信号的长度 $L=R_d-L_d$。

2）以该段信号左端点为基点，分别向左找三个、向右找一个离该段信号最近的极值点，并求出这四个极值点相邻两个之间的数据点数，分别为 nl_1、nl_2、nl_3，求取平均值 $nl=\dfrac{nl_1+nl_2+nl_3}{3}$。

3）以该段信号右端点为基点，分别向左找一个、向右找三个离该段信号最近的极值点，并求出这四个极值点相邻两个之间的数据点数，分别为 nr_1、nr_2、nr_3，求取平均值 $nr=\dfrac{nr_1+nr_2+nr_3}{3}$。

4）为了保证延拓的长度，规定该段信号两端延拓的点数 $n=\max[(nr+nl)/2, L/4, 5]$。

5）规定加权系数在延拓的长度内，线性地从 1 衰减到 0。

当两段不符合 IMF 标准要求的信号离得比较近时，可能会出现在同一坐标点得到不同的加权系数 λ_i。在这种情况下，λ_i 取所有值中最大的一个，这样得到加权系数 $\lambda(t)$。

3. EMD 筛选终止条件的改进

IMF 均值条件的判断是基于下面定义的物理量：

$$\sigma(t)=\frac{e(t)}{a(t)}=\frac{u(t)+v(t)}{u(t)-v(t)} \tag{4-34}$$

式中，$e(t)$ 为上下包络的均值，$e(t)=[u(t)+v(t)]/2$；$u(t)$、$v(t)$ 分别是信号的上包络和下包络；$a(t)=[u(t)-v(t)]/2$。相应的滤波停止条件有两个：其一是满足 $\sigma(t)<\theta_1$ 的时刻个数与全部持续时间之比不小于 $1-\alpha$ 成立，即 $\dfrac{\#\{t\in D\mid \sigma(t)<\theta_1\}}{\#\{t\in D\}}\geqslant 1-\alpha$，其中 D 是信号的持续范围，$\#A$ 表示集合 A 中元素的个数；其二是对每个时刻 t，有 $\sigma(t)<\theta_2$，其中 $\theta_2=10\theta_1$。即设定三个门限值 θ_1、

θ_2、α，规定当 $\sigma(t)$ 里面小于 θ_1 的比率达到 $1-\alpha$，且不存在大于 θ_2 的值时，中止筛选过程。经研究表明，$\theta_1 = 0.05$，$\alpha = 0.05$，$\theta_2 = 10\theta_1$ 时，筛选效果较好。与 Huang 的方法相比，$\sigma(t)$ 更能反映 IMF 的均值特性，且两个条件相互补充，使得信号只能在某些局部出现较大的波动，从而保证了整体均值为零。

4. 仿真效果比较

为了验证改进算法的效果，以如下信号进行仿真比较。

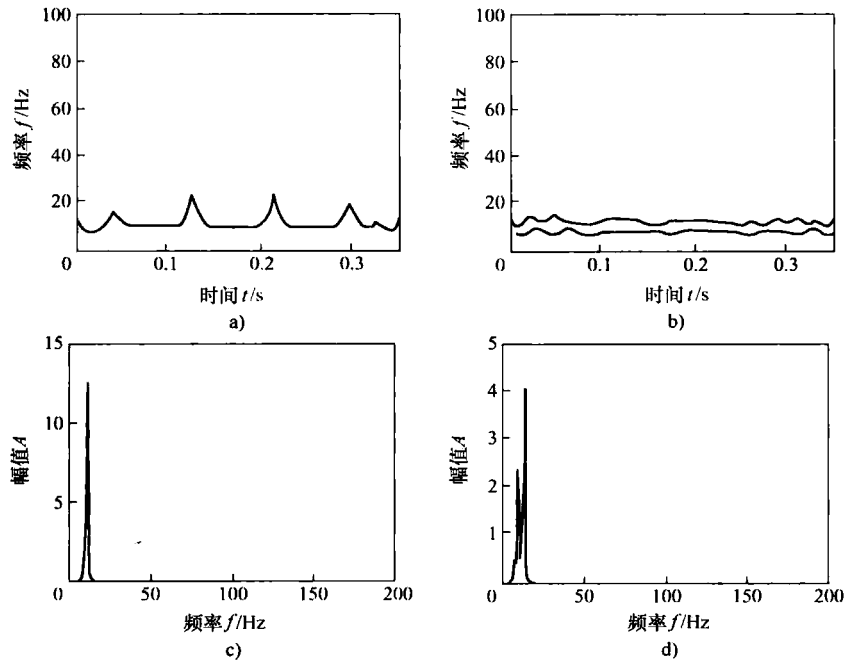

图 4-12　改进算法的仿真效果图

$$y = \sin(2\pi \cdot 10t) + \sin(2\pi \cdot 13t) \tag{4-35}$$

用原算法和改进后的算法对信号进行 EMD 分解，然后进行 Hilbert 变换，图 4-12即是得到的 Hilbert 谱和边际谱图。图 4-12a、c 分别为经原算法分解得到的 Hilbert 谱和边际谱图，可以看出希尔伯特谱图上两条谱线距离很近，基本合为一条谱线，而且谱线形状不规则，边际谱的谱峰只有一个，模态的分辨率比较低。图 4-12b、d 分别为经改进算法分解得到的 Hilbert 谱图和边际谱图，可以看出 Hilbert 谱的谱线分离得很清晰且谱线的形状得到了改善，边际谱上谱峰有两个，分别对应原信号中的 10Hz 和 13Hz，模态的分离清晰。经比较可以看出改进的算法在提高模态分辨率方面有良好的效果。

4.2.3 EMD 的端点效应及其改进方法

1. 三次样条插值产生端点效应的机理

假设插值对象为平面上 $n+1$ 个点(x_i, y_i)，$(i=0, 1, 2, \cdots, n)$，插值点 $x_0<x_1<x_2<\cdots<x_n$，三次样条插值函数 $s(x_i)$ 应满足以下 3 个条件：

1）$s(x_i)=y_i$，$i=0, 1, 2, \cdots, n$；

2）$s(x_i)$ 在每个区间 $[x_{i-1}, x_i](i=0, 1, 2, \cdots, n)$ 上是一个三次多项式；

3）$s(x_i)$ 在整个区间 $[x_0, x_n]$ 上有连续的一阶和二阶导数。

要确定唯一定解，$s(x_i)$ 还应满足下列边界条件之一：

1）已知 $s'(x_0)=y'_0$，$s'(x_n)=y'_n$；

2）已知 $s''(x_0)=y''_0$，$s''(x_n)=y''_n$；

3）当 $y=f(x)$ 是以 x_n-x_0 为周期的周期函数时，则要求 $s(x)$ 也是以 x_n-x_0 为周期的周期函数，则此时的边界条件为：$s(x_0)=s(x_n)$，$s'(x_0)=s'(x_n)$，$s''(x_0)=s''(x_n)$。

满足上述条件的 $s(x_i)$ 存在且唯一，由此可知，对于 $[x_0, x_n]$ 以外的外插值点，三次样条插值方法并未给出明确的规定。一般来说，三次样条插值方法对 $[x_0, x_n]$ 以外的插值点的插值，只是边界点处相邻二点的三次多项式的延伸。事实上，工程技术领域的信号形式是多种多样的，三次样条插值方法很难保证端点外的插值精度，而 Hilbert-Huang 变换恰恰需要对信号的全部极大值和极小值进行插值，其中一定会出现端点外插值的情况，因此出现端点效应是不可避免的。

2. 特征波分析

Huang 等人首先提出并仍在采用的边界处理方法是特征波法，即在信号的边界处加上一个特征波。特征波是指一个正弦信号，其周期和幅值是与边界相邻的三个波的平均周期和幅值，如图 4-13 所示，黑线为特征波，其周期为 $\frac{|t_3-t_1|+|t_5-t_3|+|t_7-t_5|}{3}$，上幅度为 $\frac{e(t_1)+e(t_3)+e(t_5)}{3}$，下幅度为 $\frac{e(t_2)+e(t_4)+e(t_6)}{3}$。

3. 神经网络延拓分析

工程技术领域的信号形式是复杂和多种多样的，对于端点之外的数据进行外插，如果以时间为自变量，就相当于进行前向或反向预测，用人工智能的方法进行信号预测是当前的研究热点，其中利用神经网络技术进行预测是一个重要的方法。

利用神经网络进行预测的基本原理是基于神经网络对于集合间复杂关系的强映射能力。根据理论研究结果，假定 BP 网络中隐含层单元可以根据需要自由设定，那么一个 3 层网络可以实现任意精度的非线性映射，这是将神经网络应用于数据插

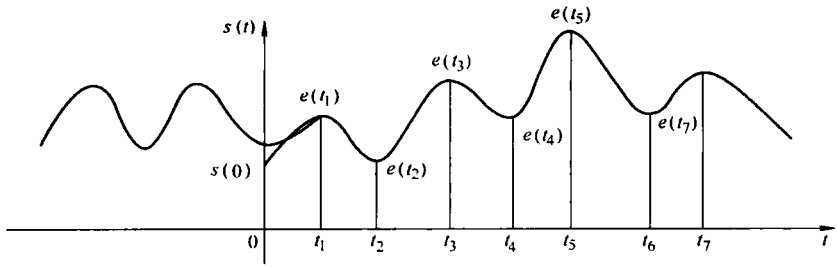

图 4-13　特征波

值问题的理论基础。利用神经网络延拓主要分为两步进行，第一步是学习过程，第二步是延拓过程。

图 4-14 给出了基于神经网络延拓计算上下包络线与实际包络线之间的区别。对于大多数信号而言，神经网络延拓算法可以很好地抑制端点效应，但每次分解的循环过程中都要进行神经网络的训练和延拓计算。当数据量较大时，循环次数较多，计算量过大，导致分析速度较慢。其次对于不同的数据，适合的神经网络的类型也不同，在实际应用过程中如何选取神经网络模型存在一定的困难。

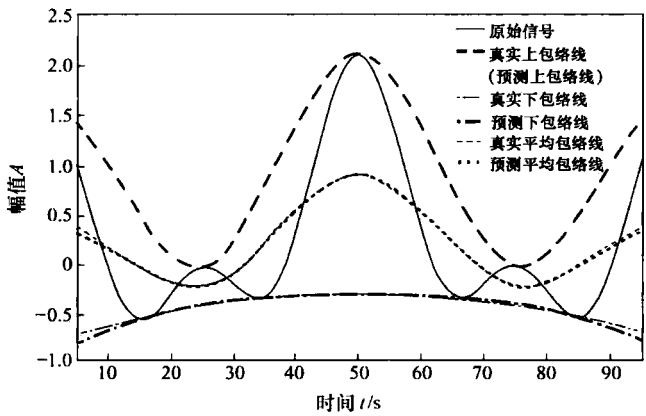

图 4-14　基于神经网络延拓得到的上下包络线与实际包络线的比较

4. 镜像闭合延拓分析

(1) 镜像闭合延拓原理　通过一个具体的例子来解释镜像延拓方法的具体含义，图 4-15a 所示为一非平稳信号，两垂线表示两平面镜；图 4-15b 为延拓后的周期性信号；图 4-15c 为用于分析处理的一个周期信号。根据镜像的对称映射特点，为尽量减少镜像的副作用，应把镜面放置在具有对称性的极值所在的位置，即首先

绘出信号左、右两端的一段曲线及相应的极值（极大值或极小值），根据曲线的分布特征来决定放置镜面的位置。

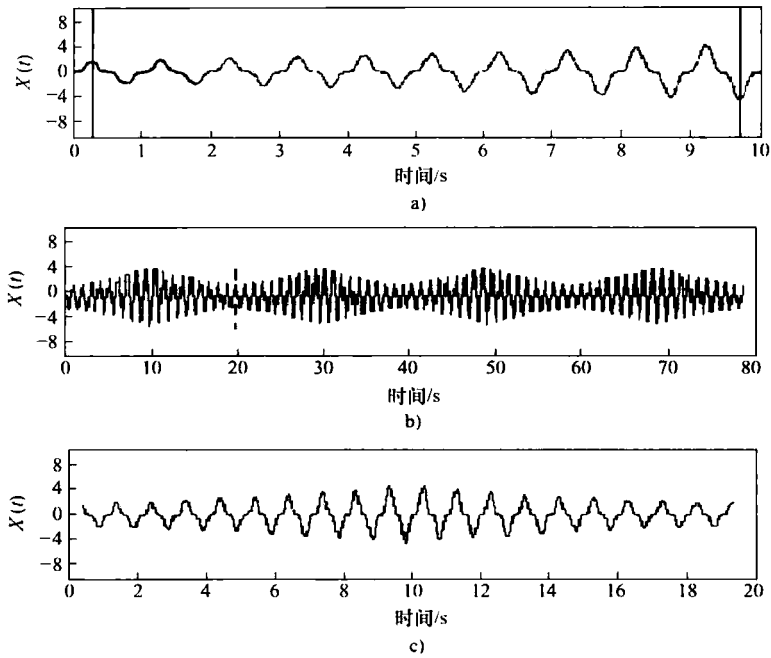

图 4-15 镜像闭合延拓法示意图

如在从信号左边起向右的第 l 个极值处和右起向左的第 r 个极值处分别放置两面平面镜，把镜内的信号向外进行映射，得到序列长度为两倍于镜内信号长度的周期性信号。实际上，我们只取其中一个周期进行分析研究，如图 4-15b、c 所示；把它头尾相结，便构成一个环形的闭合曲线，满足了原信号曲线在其端点处一阶、二阶导数存在的要求。将闭合曲线作为一个整体进行 EMD 分解，最终取上半部分作为分解结果。经镜像延拓后的信号不含端点（具有周期性），为此我们称此方法为信号的镜像闭合延拓。

设离散信号：

$$t \in [t(1), t(2), \cdots, t(n)] = (t_1, t_2, \cdots, t_n)$$
$$X(t) \in [x(t_1), x(t_2), \cdots, x(t_n)] = (x_1, x_2, \cdots, x_n) \tag{4-36}$$

其采样步长为 Δt，$X(t)$ 有 M 个极大值和 N 个极小值，对应的序列下标（I_m，I_n）、时间（T_m，T_n）和函数值（U，V）记为：

$$I_m = [I_m(1), I_m(2), \cdots, I_m(M)]$$
$$I_n = [I_n(1), I_n(2), \cdots, I_n(N)] \tag{4-37}$$

$$T_m(i)=t_{I_m(i)},\ U(i)=x_{I_m(i)}\quad i=1,\ \cdots,\ M$$
$$T_n(i)=t_{I_n(i)},\ V(i)=x_{I_n(i)}\quad i=1,\ \cdots,\ N \tag{4-38}$$

左镜放在信号左起向右的第 l 个极值点处，其相应的序列号为

$$I_1=\begin{cases}I_m(l) & \text{当镜子置于极大值处}\\ I_n(l) & \text{当镜子置于极小值处}\end{cases} \tag{4-39}$$

右镜放在信号右起向左的第 r 个极值点处，其相应的序列号为

$$I_2=\begin{cases}I_m(M+1-r) & \text{当镜子置于极大值处}\\ I_n(N+1-r) & \text{当镜子置于极小值处}\end{cases} \tag{4-40}$$

新的信号序列（t'，x'）

$$t'(i)=\begin{cases}t_{I_1}+(i-1)\Delta t & i=1,\ \cdots,\ J\\ t_{I_2}+(i-J)\Delta t & i=J+1,\ \cdots,\ 2J\end{cases} \tag{4-41}$$

$$x'(i)=\begin{cases}x_{I_1+i-1} & i=1,\ \cdots,\ J\\ x_{I_2+J-i} & i=J+1,\ \cdots,\ 2J\end{cases} \tag{4-42}$$

延拓后的信号序列长度为

$$J=2\times(I_2-I_1+1) \tag{4-43}$$

对新的信号序列（t'，x'），重新搜索其极值，得到与极值相对应的序列下标（I'_m，I'_n）、时间（T'_m，T'_n）和函数值（U'，V'）

$$T'_m(i)=t(I'_m(i)),\ U'(i)=x(I'_m(i))\quad i=1,\ \cdots,\ M'$$
$$T'_n(i)=t(I'_n(i)),\ V'(i)=x(I'_n(i))\quad i=1,\ \cdots,\ N' \tag{4-44}$$

当搜索出环形闭合曲线的极大值点（T'_m，U'）及极小值点（T'_n，V'）后利用三次样条函数对极大值点和极小值点分别进行插值，拟合闭合曲线的上下包络线。由于信号的周期性，可利用三次样条插值中的条件 3 的边界条件来确定样条插值函数。

（2）镜像闭合延拓存在的问题　由以上分析可知，镜像闭合延拓算法对于具有对称性的长数据序列来说，能较理想地抑制端点效应。对于短数据序列，由于镜像延拓要求将镜面放在极值点处，当无法确定端点是否为极值点时，须截去一部分数据以便把镜面放在极值点处。然而，对边界进行延拓的目的不是为了给出准确的端点以外的数据，而是提供一种条件，使得上下包络完全由端点以内的数据确定，因此，短数据序列的截取会使得拟合的上下包络产生较大的失真；并且，若完全忽略端点数据，当端点值比近端点的极大值大或极小值小时，会造成端点处的信号落在包络线之外，严重地影响了信号分解的精度。下面通过仿真实例进行阐明。

通常我们所处理的信号都局限在有限区间内，为此考虑式（4-45）给出信号：

$$x(t)=\cos(2\pi t/50)+\cos(2\pi t/25)+\cos(2\pi t/200),\ t\in[5,\ 95] \tag{4-45}$$

图 4-16a 为镜像闭合延拓后的上下包络，可看出在区间［5，95］内，信号存在 3 个极大值点、4 个极小值点，其中第 15 及第 85 个采样点处为两个对称的极小

值点，分别放置镜面，并向外延拓，延拓的数据用“o”线表示（延拓 15 点）。利用三次样条插值函数对延拓后数据的极值点进行插值，拟合上下包络线，其中“——”代表延拓后的上包络线，“—·—”代表下包络线。

图 4-16b 为镜像闭合延拓所得上下包络与真实样条包络的比较，真实包络的求法如下：首先求出信号 $x(t)$ 在区间［5，95］之外的部分；然后利用三次样条插值分别连接所有的极大值点和极小值点；最后取所得样条曲线在区间［5，95］之内的部分。其中，“+”线代表真实的上包络，“*”线代表真实的下包络。由图可知，镜像闭合延拓后所得的三次样条包络与真实样条包络线相比出现了失真，尤其是上包络线，在信号两端误差很大，而 IMF 分量主要是通过求取上下包络线的均值曲线获取的，此时将会影响 EMD 分解的精度。分析原因主要是端点值比近端点的极大值大，如果直接截去端点值，则造成信号落在包络线之外，影响了分析的精度。

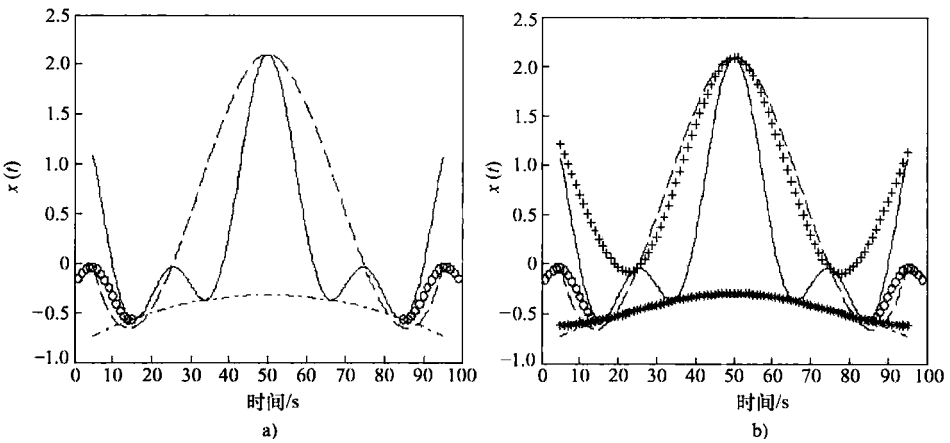

图 4-16 镜像闭合延拓所得上下包络与真实包络比较

从镜像闭合延拓的过程及仿真结果来看，镜像闭合延拓具有如下特点：

① 只要对原始信号进行一次延拓，在随后的 EMD 移动迭代过程中，由于其闭合无端点（周期性），无须对端点进行延拓处理，因而也不再引入人为影响，理论上讲是从本质上解决 EMD 端点问题的方法。

② 延拓后的信号，由于其是闭合的，在拟合上下包络的样条插值过程中，可利用端点的周期性约束条件。对于三次样条插值，同样可用追赶法快速求解。

③ 若信号本身存在较强的对称性，则可先对信号的两端进行浏览，尽可能把镜面放在具有对称性的极值点处，这样处理的效果最佳。

④ 若信号具有较强的不对称性，则无论把镜面放在何处，都不可避免地引入端点影响。

5. 可变长包络极值镜像延拓法

上述信号镜像闭合延拓法虽然能较有效地抑制 HHT 的端点效应，但是该方法将原信号全部镜像，使得数据量是原信号的两倍，从而增加了计算量，计算速度变慢。在瞬态过程的信号分析中，要求分析工具能迅速给出分析结果，这种情况下镜像闭合拓延法就不再适用。研究发现，无论采取什么方法处理端点效应，其目的不是准确还原信号本身，而是获得信号端点处的极值，因为 HHT 要准确处理的是原有的信号而不是拓延信号。

针对这种情况，采用可变长极值镜像延拓法抑制端点效应，具体算法如下：设 x 信号为 $x(t)$，其中

$$t \in [t(1), t(2), \cdots, t(n)] = (t_1, t_2, \cdots, t_n) \tag{4-46}$$

$$x(t) \in [x(t_1), x(t_2), \cdots, x(t_n)] = (x_1, x_2, \cdots, x_n) \tag{4-47}$$

设 $x(t)$ 有 M 个极大值和 N 个极小值，对应的序列下标（I_m，I_n）、时间（T_m，T_n）和函数值（U，V）表示如下：

$$I_m = [I_m(1), I_m(2), \cdots, I_m(M)] \tag{4-48}$$

$$I_n = [I_n(1), I_n(2), \cdots, I_n(N)] \tag{4-49}$$

$$T_m(i) = t_{I_m(i)},\ U(i) = x_{I_m(i)} \quad i = 1, \cdots, M \tag{4-50}$$

$$T_n(i) = t_{I_n(i)},\ V(i) = x_{I_n(i)} \quad i = 1, \cdots, N \tag{4-51}$$

这里引入符号 $[I(k): I(j)]$ 表示 I 中从 $I(k)$ 到 $I(j)$ 的连续取值。如果 $k < j$ 表示递增取值，$k > j$ 则表示递减取值。

在 EMD 分解得到 IMF 分量时，端点延拓的目的是确保上、下包络都与端点相交，以便得到与每一个信号点相对应的局部平均值。而上、下包络是由极大值和极小值连接而成的，因此只要对极大值和极小值进行延拓，而不必对信号本身进行延拓。极大值和极小值是间隔分布的，同时考虑到样条插值的要求，所以只要在信号左、右两端分别根据实际情况拓延有限个极值点即可。

（1）左端极值镜像延拓算法　若第一个极值点是极大值点，后出现极小值，即 $I_m(1) < I_n(1)$，则从左端点到左端第一个极值点部分为增函数，此时按照左端点的值与左端第一个极小值的大小选择对称轴，具体按以下方法进行延拓，延拓长度设定为 NB。

1）计算延拓对称轴的下标 I_{mc}：当端点函数值大于左端第一个极小值时，即 $x(t_1) > x[I_n(1)] = V(1)$，则将第一个极大值对应横坐标作为对称轴，$I_{mc} = I_m(1)$；否则将端点作为对称轴。如式（4-52）所示：

$$I_{mc} = \begin{cases} I_m(1) & x(t_1) > V(1) \\ 1 & x(t_1) < V(1) \end{cases} \tag{4-52}$$

2）求出需要延拓的极值点下标倒序（I_{md}，I_{nd}）

$$I_{md}=\begin{cases}[I_m(NB+1):I_m(2)] & I_{mc}=I_m(1)\\ [I_m(NB):I_m(1)] & I_{mc}=1\end{cases} \tag{4-53}$$

$$I_{nd}=\begin{cases}[I_n(NB):I_n(1)] & I_{mc}=I_m(1)\\ [I_n(NB-1):I_n(1),1] & I_{mc}=1\end{cases} \tag{4-54}$$

若第一个极值点是极小值点，后出现极大值，即 $I_m(1)>I_n(1)$，则从左端点到左端第一个极值点部分为减函数，此时按照左端点的值与左端第一个极大值的大小选择对称轴，具体按以下方法进行延拓，延拓长度设定为 NB。

1）计算延拓对称轴的下标 I_{mc}：当端点函数值小于左端第一个极大值时，即 $x(t_1)<x[I_m(1)]=U(1)$，则将第一个极小值对应横坐标作为对称轴，$I_{mc}=I_n(1)$；否则将端点作为对称轴。如式（4-55）所示：

$$I_{mc}=\begin{cases}I_n(1) & x(t_1)<U(1)\\ 1 & x(t_1)>U(1)\end{cases} \tag{4-55}$$

2）求出需要延拓的极值点下标倒序（I_{md}，I_{nd}）：

$$I_{md}=\begin{cases}[I_m(NB):I_m(1)] & I_{mc}=I_n(1)\\ [I_m(NB-1):I_m(1),1] & I_{mc}=1\end{cases} \tag{4-56}$$

$$I_{nd}=\begin{cases}[I_n(NB+1):I_n(2)] & I_{mc}=I_n(1)\\ [I_n(NB):I_n(1)] & I_{mc}=1\end{cases} \tag{4-57}$$

（2）右端极值镜像延拓算法　若最右端极值点是极大值点，即 $I_m(M)>I_n(N)$，则从最右端极大值点到右端点部分为减函数，此时按照右端点的值与最右端极小值的大小选择对称轴，具体按以下方法进行延拓，延拓长度设定为 NB。

1）计算延拓对称轴的下标 I_{mc}：当端点函数值大于最右端极小值时，即 $x(t_n)>x[I_n(N)]=V(N)$，则将最右端极大值对应横坐标作为对称轴，$I_{mc}=I_m(M)$；否则将端点作为对称轴。如式（4-58）所示：

$$I_{mc}=\begin{cases}I_m(M) & x(t_n)>V(N)\\ n & x(t_n)<V(N)\end{cases} \tag{4-58}$$

2）求出需要延拓的极值点下标倒序（I_{md}，I_{nd}）：

$$I_{md}=\begin{cases}[I_m(M-1):I_m(M-NB)] & I_{mc}=I_m(M)\\ [n,I_m(M):I_m(M-NB+1)] & I_{mc}=n\end{cases} \tag{4-59}$$

$$I_{nd}=\begin{cases}[I_n(N):I_n(N-NB+1)] & I_{mc}=I_m(M)\\ [I_n(N):I_n(N-NB+1)] & I_{mc}=n\end{cases} \tag{4-60}$$

若最右端极值点是极小值点，即 $I_m(M)<I_n(N)$，则从最右端极小值点到右端点部分为增函数，此时按照右端点的值与最右端极大值的大小选择对称轴，具体按以下方法进行延拓，延拓长度设定为 NB。

1）计算延拓对称轴的下标 I_{mc}：当端点函数值小于最右端极大值时，即

$x(t_n) < x[I_m(M)] = U(M)$，则将最右端极小值对应横坐标作为对称轴，$I_{mc} = I_n(N)$；否则将端点作为对称轴。如式（4-61）所示：

$$I_{mc} = \begin{cases} I_n(N) & x(t_n) < U(M) \\ n & x(t_n) > U(M) \end{cases} \tag{4-61}$$

2）求出需要延拓的极值点下标倒序（I_{md}，I_{nd}）：

$$I_{md} = \begin{cases} [I_m(M): I_m(M-NB+1)] & I_{mc} = I_n(N) \\ [I_m(M): I_m(M-NB+1)] & I_{mc} = n \end{cases} \tag{4-62}$$

$$I_{nd} = \begin{cases} [I_n(N-1): I_n(N-NB)] & I_{mc} = I_n(N) \\ [n, I_n(N): I_n(N-NB+1)] & I_{mc} = n \end{cases} \tag{4-63}$$

由上面计算结果可以得到拓延极值点序列的下标（I_{ml}，I_{nl}）及函数值（U_{ml}，V_{nl}）：

$$\begin{cases} I_{ml} = 2I_{mc} - I_{md} \\ I_{nl} = 2I_{mc} - I_{nd} \end{cases}; \quad \begin{cases} U_{ml} = x(t_{I_{md}}) \\ V_{nl} = x(t_{I_{nd}}) \end{cases} \tag{4-64}$$

为了进一步说明该算法的过程，下面给出该算法的流程图，如图4-17所示。

利用可变长包络极值镜像延拓法对端点极值作有限长度的延拓，既克服了镜像闭合延拓法造成数据庞大的缺点，也避免了采用神经网络延拓法时复杂的网络训练过程。

（3）延拓长度的讨论　延拓长度NB即为在信号端点处增加的极值点个数，延拓极值点太多会造成数据庞大计算速度变慢，延拓极值点太少则不能起到抑制端点效应的作用。经过仿真研究发现，延拓极值点个数在2到5之间时分解精度和计算速度都较为理想。

取延拓长度$NB=2$，包络极值镜像延拓的数据模型如图4-18所示。

1）先讨论左延拓第一个极值点是极大值点后出现极小值的情况，即$I_m(1) < I_n(1)$。此时如果左端点的值大于左端第一个极小值，$x(t_1) > V(1)$，选择对称轴为$I_{mc} = I_m(1)$，延拓的结果是增加了两个局部极大值和两个局部极小值，如图4-18a所示。反之如果左端点的值小于左端第一个极小值，$x(t_1) < V(1)$，选择对称轴为$I_{mc} = 1$，延拓的结果是增加了两个局部极大值和三个局部极小值，如图4-18b所示。

2）再讨论左延拓第一个极值点是极小值点后出现极大值的情况，即$I_m(1) > I_n(1)$。此时如果左端点的值小于左端第一个极大值，$x(t_1) < U(1)$，选择对称轴为$I_{mc} = I_n(1)$，如图4-18c所示。反之，如果左端点的值大于左端第一个极大值，$x(t_1) > U(1)$，选择对称轴为$I_{mc} = 1$，如图4-18d所示。

3）同理，再来讨论右延拓时右边向左看第一个极值点是极大值后出现极小值的情况，即$I_m(M) > I_n(N)$。此时，如果右端点的值大于右端第一个极小值，$x(t_n) > V(N)$，选择对称轴为$I_{mc} = I_m(M)$，如图4-18e所示。反之，如果右端点的值小于右端

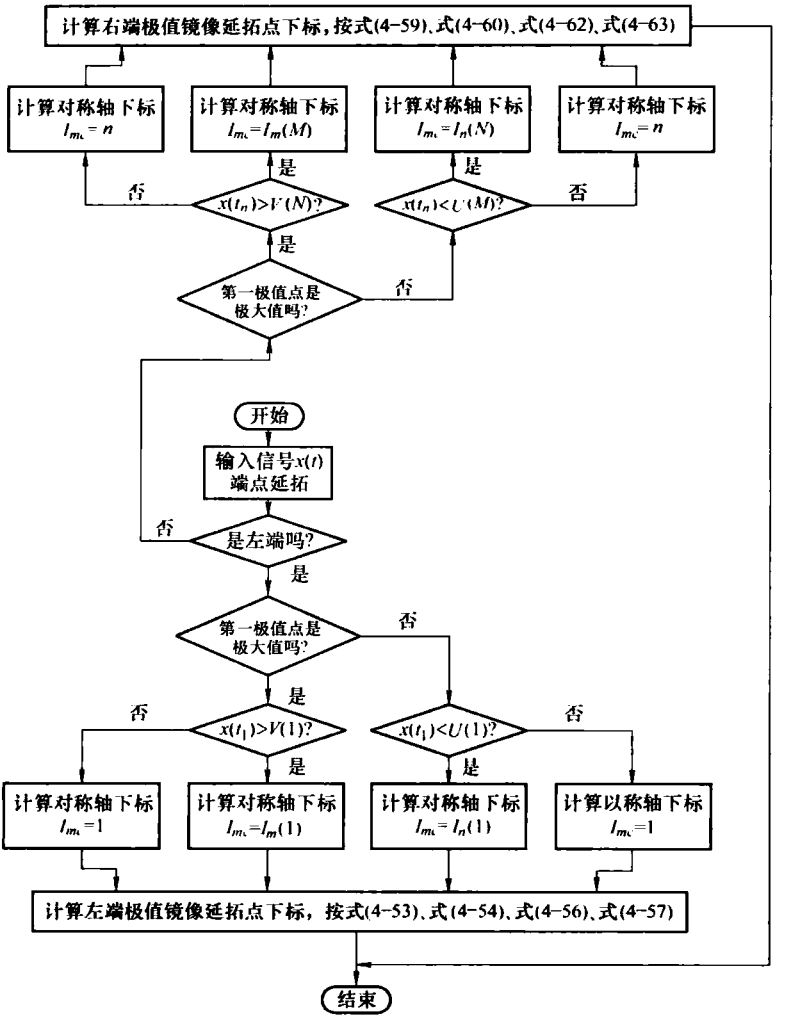

图 4-17 极值延拓算法流程图

第一个极小值，$x(t_n)<V(N)$，则选择对称轴为 $I_{mc}=n$，如图 4-18f 所示。

4）最后是右延拓右边向左向第一个极值点是极小值的情况，即 $I_m(M)<I_n(N)$。此时，如果右端点的值小于右端第一个极大值，$x(t_n)<U(M)$，选择对称轴为 $I_{mc}=I_n(N)$，如图 4-18g 所示。反之，如果右端点的值大于右端第一个极大值，$x(t_n)>U(M)$，则选择对称轴为 $I_{mc}=n$，如图 4-18h 所示。

6. 延拓仿真性能比较

（1）延拓仿真 由上述分析可知，当信号端点值比近端点的极大值大时，为避免信号落在包络线之外，须对端点处进行特殊处理。以端点及近端点的极大值点

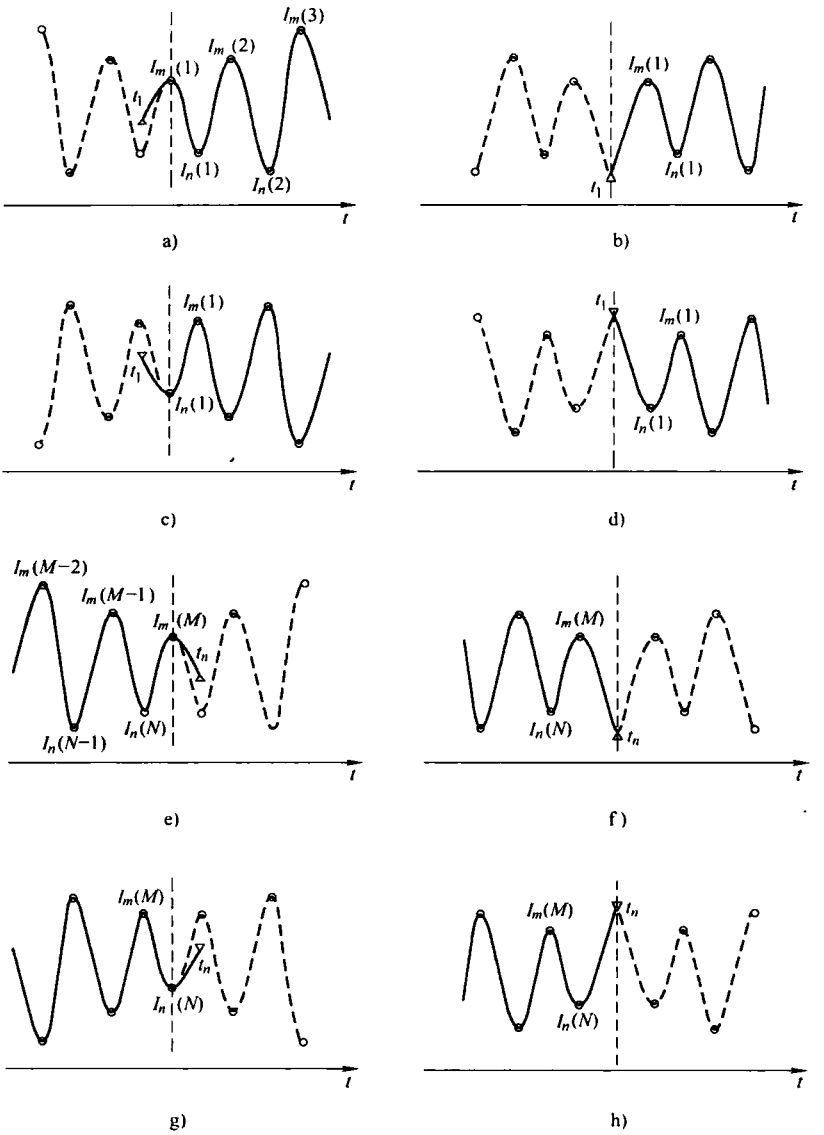

图 4-18　包络极值镜像延拓的数据模型

之间的特征波作为依据，向外进行延拓，在数据两端分别得到两个延拓的极大值点和极小值点的位置及幅值，再利用三次样条函数对延拓后的极大值及极小值序列插值，拟合上下包络线，如图 4-19a 所示，其中“——”代表延拓后的上包络线，“— - —”代表下包络线，“……”为延拓后上下包络的均值曲线；图 4-19b 给出了延拓后的上下包络线及包络均值与真实包络线及均值的比较，“ + ”线表示真实

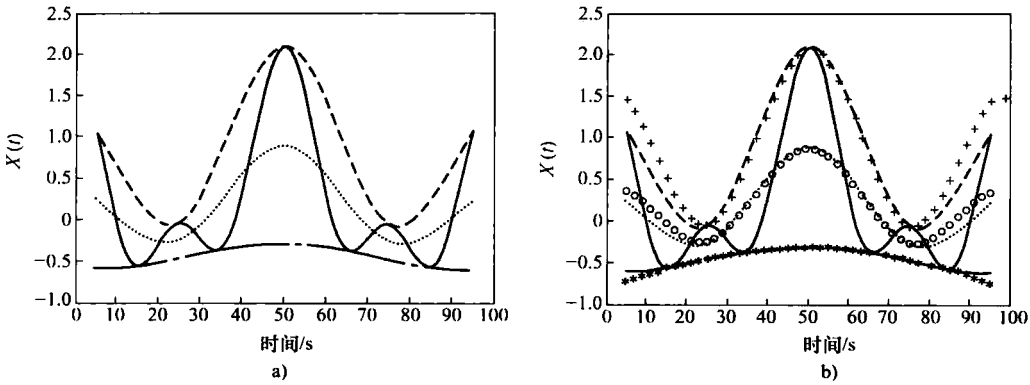

图 4-19 包络极值延拓所得上下包络与真实样条包络比较

上包络，“*”线表示真实下包络，“○”线表示真实的包络均值，“·”线表示延拓后的包络均值。

由图可知，包络极值延拓法得到的上下包络线及包络均值与真实情况的符合程度较理想，由于 EMD 分解是通过包络均值实现的，包络均值求取的准确性决定着 EMD 分解的质量，因此包络极值延拓法是提高 EMD 分解精度的较理想的延拓方法。

利用包络极值延拓方法对式（4-45）所示的正弦叠加信号进行延拓，再 EMD 分解得到各 IMF 分量，如图 4-20a 所示；再对各 IMF 分量分别进行 Hilbert 变换组合得到 Hilbert-Huang 时频谱，图 4-20b 所示。

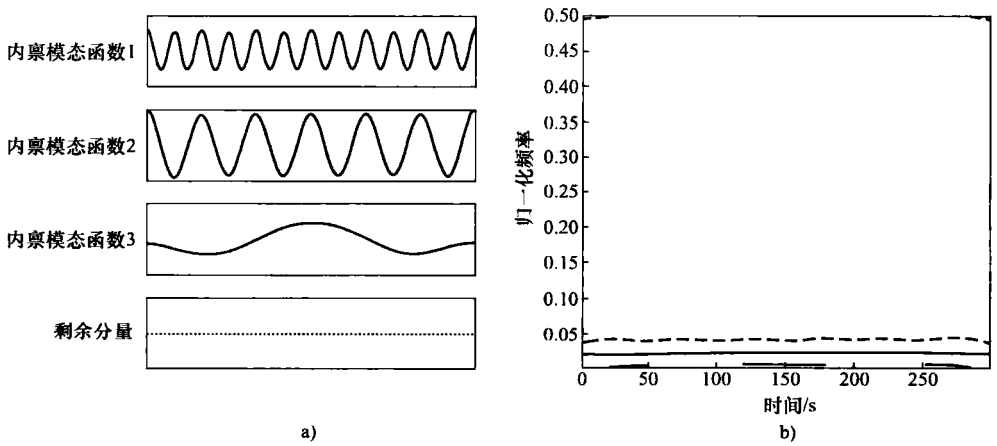

图 4-20 包络极值延拓后的分解图及其 Hilbert 谱

（2）性能比较 神经网络延拓算法最大的不足就是运算速度太慢。EMD 方法

筛出每一个IMF分量都要循环若干次才能满足终止条件，每次循环中都要利用该方法对原数据序列的两端进行延拓。每一端若延拓 N 个点就要循环 N 次，循环次数太多造成速度太慢。其次，对于不同类型的数据序列，最适合的神经网络模型也会有所不同，在实际应用过程中，须根据需要设定不同类型的模型，这给编程带来较大的麻烦。

镜像闭合延拓算法首先把原始数据序列延拓成一环形数据，求各IMF分量时，对环形数据进行一次次筛选，并把镜面以内的数据作为输出，而不必每次对原始数据进行延拓，所以运算速度大大提高。但是该方法使用了原始数据二倍的存储空间，且在求各IMF分量的每次循环过程中都要求出整个环形数据的上下包络，所需时间是求原数据包络时间的二倍。镜像闭合延拓算法要求将镜面放置在具有对称性的极值点处，当无法确定端点是否为极值点时，须抛弃两端的数据，这对于短数据序列不可行，且当端点值比近端点的极大值大或极小值小时，没有进行特殊处理，使得信号落在包络线之外，拟合误差很大。

可变长包络极值镜像延拓法在求各IMF分量的若干次循环过程中，先利用端点处的特征波进行极值点延拓，求出两端添加的极值点的位置和幅值，再拟合数据序列的上下包络。虽然比镜像闭合延拓多了求添加极值点的时间，但是在拟合上下包络时比镜像延拓少用了二分之一的时间，所以在时间方面，包络极值延拓法并不比镜像闭合延拓慢；而在存储空间方面，包络极值延拓算法比镜像闭合延拓节约了约二分之一的空间；且此算法对端点进行了特殊处理，避免了信号落在包络线之外。因此，可变长包络极值镜像延拓算法是一种有效的抑制端点效应的算法。

4.3 Hilbert-Huang变换在真空泵故障诊断中的应用

本节进行实验数据分析，将HHT方法应用于干式真空泵的故障诊断中，通过干式真空泵故障诊断实验，并与传统的Hilbert变换包络解调方法进行比较，结果表明HHT在提取故障频率方面具有更高的分辨率和准确性，验证了HHT方法能更有效地提取故障特征频率。

4.3.1 实验信号采集

本实验采用的干式真空泵为5级罗茨+爪型干式真空泵，如图2-15所示，用振动加速度传感器BK-HV对振动加速度信号进行采样，采样频率为40kHz，采样长度为80000点，转轴频率为103Hz。轴承参数为：滚珠数为9、滚珠直径为9.525mm、轴承节径为46.2mm、接触角为24.97°。由式（2-74）~式（2-77）可得干式真空泵的轴承各通过频率 $f_i=550$Hz、$f_o=482$Hz、$f_b=377$Hz、$f_c=42$Hz。滚动轴承内环有故障时测得的振动加速度时域信号如图4-21所示。

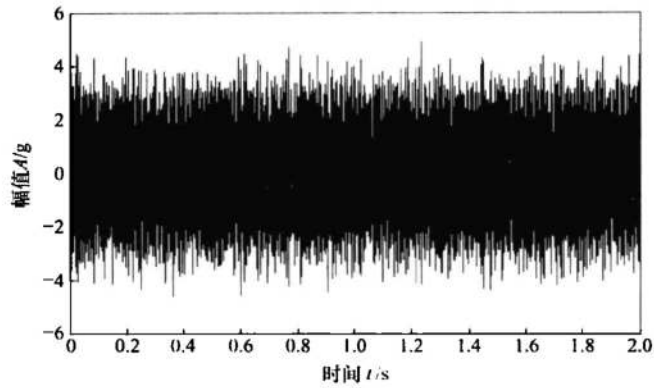

图 4-21 内环有故障的滚动轴承时域信号

4.3.2 传统的 Hilbert 变换包络解调方法在真空泵故障诊断中的应用

采用 Hilbert 包络解调方法，对 BK-HV 测得的信号进行 Hilbert 变换得到原始故障信号的时频包络信号，如图4-22所示。然后再对所得时频包络信号计算功率

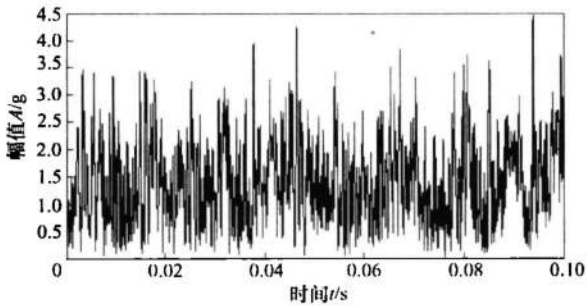

图 4-22 Hilbert 变换时域包络信号图

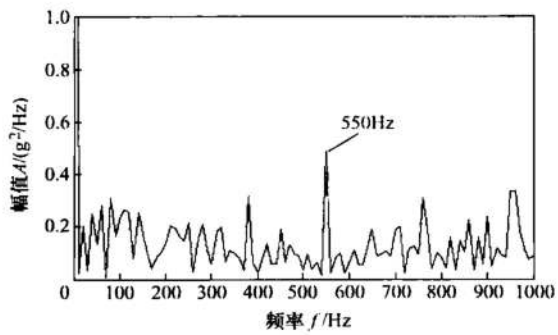

图 4-23 Hilbert 变换包络谱

谱即可得 Hilbert 变换包络谱，如图 4-23 所示。

我们可以通过 Hilbert 变换包络谱判断出 550Hz 为故障频率，与式（2-75）所计算出轴承内环通过频率相同。但是，从图中可以看到，对时变信号 Hilbert 变换方法提取的信号包络不够光滑，影响了提取精度，反映在包络谱上表现为谱峰过多，难以直观展示出故障特征频率。下面将 HHT 应用于真空泵的故障诊断中，以便更为直观地反映出故障特征频率信息。

4.3.3　Hilbert-Huang 变换在真空泵故障诊断中的应用

现采用 HHT 方法分析，由传感器 BK-HV 测得的真空泵高真空端振动信号时间波形如图 4-21 所示，对故障信号进行 EMD 分解，EMD 分解结果如图 4-24 所示，得到 10 个 IMF 分量及 1 个残余量 res。然后对每个 IMF 分量作 Hilbert 变换构成解析信号，根据式（4-23）求出瞬时频率，根据式（4-25）可求出 Hilbert 谱，根据式（4-26）可求出 Hilbert 边际谱，最终得到的故障信号时频幅三维图如图 4-25所示。

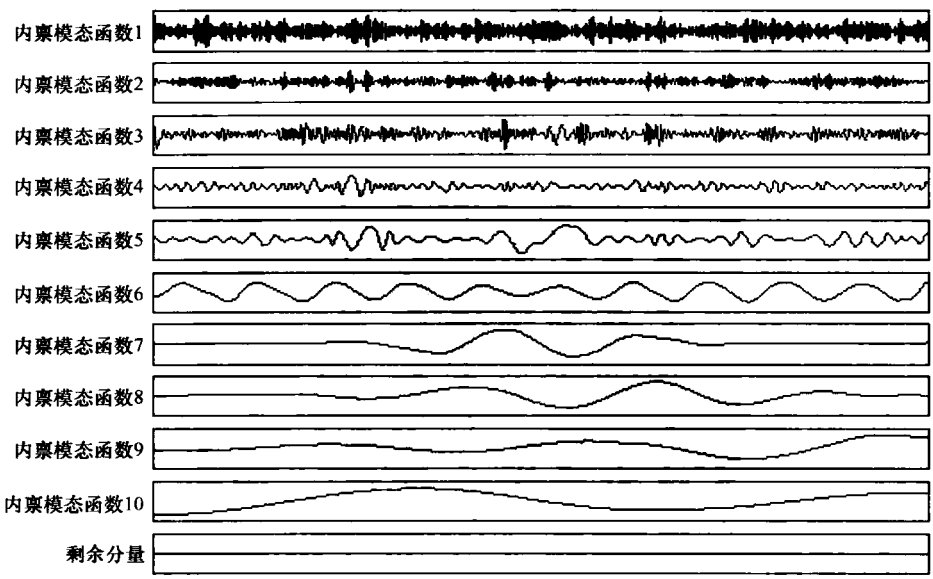

图 4-24　故障信号 EMD 分解图

由时频幅三维图可以看出 550Hz 为故障频率成分，与前文所计算出轴承内环故障的通过频率相吻合。解体轴承发现轴承内环存在凹痕，如图 4-26 所示。

图 4-25 结果表明，与传统的 Hilbert 包络解调方法图 4-23 相比，HHT 方法更能直观有效地反映故障特征频率信息，通过实验分析证明 HHT 在提取故障频率方面具有更高的分辨率和准确性，该方法具有广阔的推广应用前景。

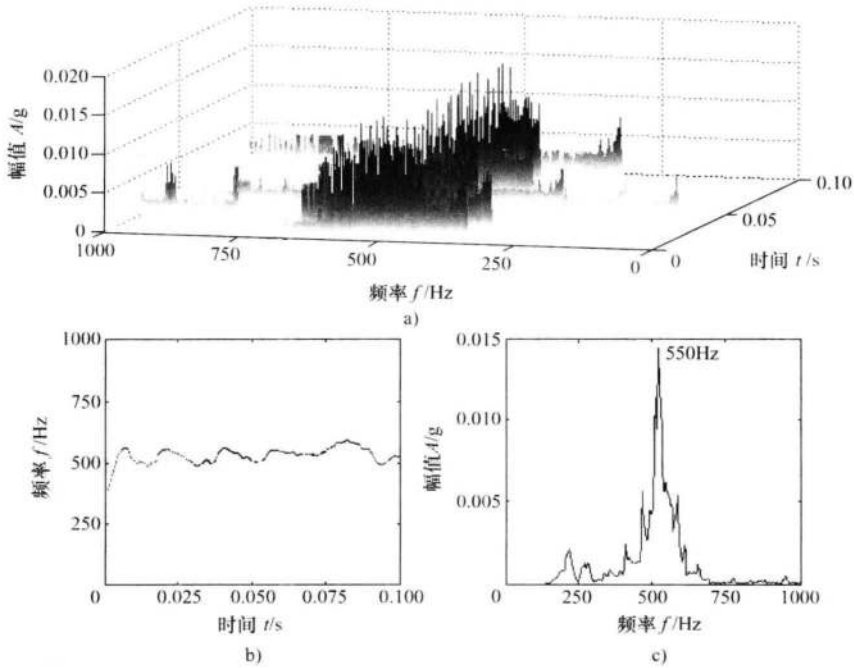

图 4-25 故障信号时频幅三维图

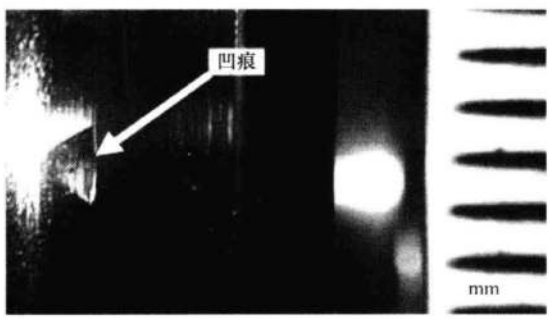

图 4-26 轴承内环边缘凹痕

参 考 文 献

[1] S O Rice. Mathematical Analysis of Random Noise [J]. Bell Syst Tech J, 1994, (23): 21-32.

[2] Norden E Huang, Stever R Long. A New View of Nonlinear Water Waves: The Hilbert Spectrum [J]. Annual Review of Fluid Mechanics, 1999 (31): 417-457.

[3] L Cohen. Time Frequency Analysis [J]. Englewood Cliffs, NJ: Prentice-Hall, 1995: 48-99.

[4] L. 科恩. 时频分析理论与应用 [M]. 白居宪, 译. 西安: 西安交通大学出版社, 2000.

[5] N E Huang, Zheng Shen. The Empirical Mode Decomposition and the Hilbert Spectrum for Nonlinear and Non-stationary Time Series Analysis [J]. Proc. R. Soc, London, A, 1998 (454): 903-995.

[6] Stevenson N, Mesbah M, Boashash B. A Sampling Limit for the Empirical Mode Decomposition [C]//Prodeedings of the Eighth International Symposium on Signal Processing and Its Applications, 2005, 2: 647-650.

[7] Gabriel Rilling, Patrick Flandrin and Paulo Goncalves. On Empirical Mode Decomposition and Its Algirithms [C]//IEEE-EURASIP Workshop on Nonlinear Signal and Image Processing, Grado (I), 2003 (6): 9-11.

[8] 马孝江, 余泊, 张志新. 一种新的时频分析方法—局域波法 [J]. 振动工程学报, 2000, 13 (S): 219-224.

[9] Xiaojie Zou, Xueyao Li, Rubo Zhang. Speech Enhancement Based on Hilbert-Huang Transform Theory [C]//First International Multi-symposiums on Computer and Computational Sciences, 2006: 208-213.

[10] 程军圣, 于德介, 杨宇. 经典模态分解方法中内禀模态函数判据问题研究 [J]. 中国机械工程, 2004, 15: 1861-1864.

[11] 邓拥军, 王伟, 钱成春. EMD 方法及 Hilbert 变换中边界问题的处理 [J]. 科学通报, 2001, 46 (3): 257-263.

[12] Zhong Y M, Qin S R, Tang B P. Research on Theoretic Evidence and Realization of Directly-mean EMD Method [J]. Chinese Journal of Mechanical Engineering, 2004, 17 (3): 399-404.

[13] 李刚. Hilbert-Huang 变换在干式真空泵故障诊断中的应用研究 [D]. 秦皇岛燕山大学工学硕士学位论文, 2008: 60-73.

[14] Jiang Wanlu (姜万录), Li Gang, Wei Yajuan, et al. Hilbert Local-Instantaneous Spectrum Analysis-Based Bearing Fault Diagnosis of Dry Vacuum Pump [C]//Proceedings of the Seventh International Conference on Fluid Power Transmission and Control. Beijing: World Publishing Corporation, 2009: 865-868.

第 5 章　小波簇包络解调方法在故障诊断中的应用

本章基于 Morlet 复解析小波变换的正交性，提出一种基于小波簇的带通滤波和包络解调新方法。通过合理地选择小波参数，用多个单 Morlet 小波组成的小波簇可构成具有零相移、平顶通带及快速衰减过渡带特性的带通滤波器，用于提取振动信号的高频谐振成分。这种方法将信号高频带通滤波和 Hilbert 变换两个步骤合二为一，简化了运算步骤，缩短了运算时间，提高了故障诊断的实时性。

5.1　包络解调方法的研究现状

在设备故障诊断工程领域，很多故障都是以信号调制为特征的，特别是回转机械的故障。对这些信号进行分析处理实际上可以归结为幅值调制或频率调制信号的解调。解调分析能够获得调制信号的包络曲线和包络谱，因此广泛应用于信号处理和故障诊断等诸多领域中。从 20 世纪 80 年代初期，有关学者开始将电学中的解调分析方法引用到机械故障诊断中。在工程中，解调分析方法解决了很多机床、汽车变速器和旋转机械的故障诊断方面的问题，取得了良好的效果，已经成为齿轮和滚动轴承类故障振动信号分析的最有效手段之一，具有其他信号处理方法不可比拟的优势。对于滚动轴承或齿轮的分布型或集中型缺陷，如疲劳、剥落等故障，谱图上会出现在某些特征频率两旁产生的调制边频带。发生故障的部位及程度不同，其边频带不同。例如轴承故障在轴承的振动信号频谱的中高频处出现调制边频带。此时用一般的谱分析方法难于对故障的程度作分析。而用包络解调分析即可求出调制信号，顺利找到故障源。因此在故障诊断，尤其是旋转机械故障诊断中，包络分析技术具有其他故障监测方法不可替代的作用。

在工程故障诊断中常用的解调分析方法有：希尔伯特变换、广义检波滤波、共振解调方法、循环平稳解调方法等。其核心都是把调制在高频带的低频故障信息，解调到低频进行分析处理，从而提取故障信息。在这个过程中提取了低频段的信号，而旋转机械的干扰和噪声的能量一般集中在中高频段，这样就减少了设备振动信号中的中、高频环境振动干扰和噪声的影响。

传统的包络解调方法具有明显的缺点，它在计算中需要确定滤波中心频率和滤波带宽，而这些参数的选择需要有先验知识，并对分析结果有很大影响。随着小波变换的发展，一些学者将其应用在包络解调分析中，如史东锋等提出基于小波包络

分析的轴承诊断方法，采用高斯小波实现了对解析信号的分解，提取出故障特征频率。而何岭松等利用连续复 Morlet 小波变换的优势，在全频带范围内对信号进行包络分析，自动设定滤波中心频率，提高了诊断的效果。

因为在旋转机械故障诊断中，许多振动信号是调制类型的信号，事实上调制信号的包络更集中地携带了故障信息。因此，建立一种行之有效的基于信号包络特征的故障识别方法必将为准确、迅速地判断机械的故障提供充分地依据。本章结合真空泵振动信号的特点提出一种新的基于复解析小波分析的包络解调故障诊断方法，这种方法可以广泛应用于齿轮和滚动轴承的故障诊断中。

5.2　振动监测技术

为保证机组安全运行，旋转机械常采用状态监测与故障诊断技术。采用振动分析法，其测试设备简单，使用便利，更适合应用于生产现场。这对于复杂的机械系统来说，利用振动分析法进行系统故障诊断更具优势。

5.2.1　机械振动监测与分析技术

机械设备运行过程中由于各种力的作用，会产生振动，当机器内部零部件或结构件出现缺陷时，机器的动力学性能就会发生改变，产生的振动也随之发生变化。也就是说，机器的振动信号可以反应机器内部状态变化。因此，我们可以通过对机器外部的振动的测量分析来监测其内部的状态变化，并在此基础上诊断故障原因、部位、程度、性质和发展趋势等。据国内外实际统计资料表明：利用振动信号可以诊断绝大部分机械故障，由此可见在实际工程中推广应用振动监测技术具有重要意义。

1. 振动监测的一般步骤

振动监测就是通过传感器、放大器以及显示或记录仪表，测量运动机械或工程结构在外界激励（包括环境激励）或运行工况中重要部位的位移、速度、加速度等运动量，从而了解机械或结构的工作状态。

振动监测技术在实际应用中需经过如下几个步骤：

（1）振动信号的采集　主要是通过状态监测系统测取设备振动的响应信号（位移、速度或加速度），然后对信号进行存储，以备后续分析。这一过程的关键是信号采集点的选取、传感器的选取和测量方法的选取等问题。

（2）振动特征的提取　这是一个振动信号分析处理的过程，即将采集到的振动信号进行分类加工处理，包括进行滤波消噪数据维数压缩、时频转换、模型转换等，从而去掉冗余数据，提取故障特征信息，形成待检模式。

（3）故障状态的识别　将经过信号处理和特征提取所获得的待检模式与正常

状况的模式按一定的准则和诊断策略进行对比分析，以确定设备当前所处的状态，判别是否存在故障以及故障类型和程度等。

（4）诊断决策　根据对设备状态所作出的判断来决定应当采取的对策和措施，即对机械设备运行进行必要的预测及实施必要的干预措施，所谓预测是指在维持原来运行状态的情况下，暂不采取任何措施，估计设备还可以继续运行多长时间，或估计可能产生的后果。干预措施即通过停机修理彻底治理从而排除故障。

2. 振动监测系统组成

信号的测取是故障诊断的首要环节，正确的测试是获得故障信息的先决条件。为此，必须选择相应的测试仪器。为了在实际工程中经济而有效地开展振动监测，要合理地配置简易仪器和精密仪器。目前，振动监测多采用虚拟仪器系统。

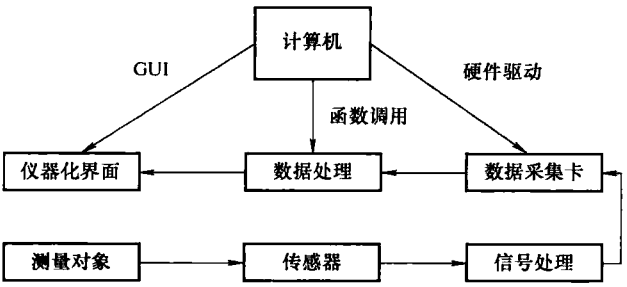

图 5-1　虚拟仪器系统

虚拟仪器系统（图 5-1）是一种全新的概念，体现了“软件就是仪器”的全新理念。用户根据需要选择硬件，在特定的软件平台上编制特定软件和显示界面，并驱动硬件采集数据。因此，同样的硬件系统由于软件编制的不同就可承担不同的任务。

3. 振动监测中的几项选择

振动参数的选择。为了提高振动测试的灵敏度，在测试时应根据振动频率的高低来选用相应的参数测量传感器。对于回转机械，测量参数一般从位移 D，速度 v，加速度 a 三者中选出，总的来说，选择合适的测量参数能使我们更容易地达到诊断目的。从正弦波的位移、速度和加速度的幅值的关系如下

$$D=\frac{v}{\omega}=\frac{a}{\omega^2} \tag{5-1}$$

根据式（5-1），低频振动时一般选用位移，中频振动时一般选用速度，高频振动时往往选用加速度作为测量参数。这是因为频率越低则位移的测量灵敏度高，频率越高则加速度的测量灵敏度高。目前，一般是以振动的加速度作为诊断参数的。

测点位置、数量及方向的确定对诊断效果影响很大。一般测点数量及方向的确

定应考虑能对设备的状态作出全面的描述；而测点位置应尽可能选在振动效应的敏感点上，并且该位置应具有使传感器安装和拆卸方便、测量容易实现、引入干扰最小、所得数据信息丰富及可监测整机状态等特点。

对于旋转机械来说，有测量轴承和轴振动两种方式。非高速旋转体以测定轴承的振动为多，越接近于高速，测定轴的位移者为多。对于低频振动尽可能从三个方向测试，对于随机振动可以只测定一个方向。

5.2.2　振动信号的分析与处理

振动信号处理，就是对采集到的振动信号进行加工处理，抽取与设备状态有关的特征，以便对设备状态实施有效地判断。

信号处理的基本方法包括幅域分析、时域分析、频域分析和相域分析。幅域分析是指对信号在幅值上进行各种处理；时域分析是指对信号在时间域内的分析和变换；频域分析则是确定信号的频率结构，即弄清楚信号中包含有哪些频率成分及各频率成分的幅值大小；相域分析即是进行相位值测量及对相位随时间的变化进行分析。必须指出，不同的信号分析方法只是从不同的角度去观察、分析信号，分析的结果反映了同一个信号的不同侧面，因而更真实、更全面地揭示了信号的本质特征。不论进行何种信号处理，既不能增加也不会减少信号的信息成分。采用多种分析方法比采用单一分析方法所获得的信息更加丰富，为准确判断设备状态提供了必要而充分的依据。

1. 振动信号幅域分析方法

机械设备运行状态的变化会导致振动时间信号的变化，同样会引起信号时域描述的参数变化。机械故障是否存在，或直接通过信号波形的改变来判别，或根据信号时域参数的变化来诊断。前者有时候不易观测分辨，后者比较行之有效。用以诊断机械故障的时域参数很多，但并非每一参数对所有机械故障都敏感，一般来说，应根据具体诊断对象加以选用，作为故障的特征参数。故障诊断常用的时域参数包括有量纲的参数和无量纲的参数两大类。

（1）有量纲的参数　振动信号的瞬时值随着时间在不断地变化，作为表现这种振动变化大小的方法广泛地使用有效值。信号 $x(t)$ 的均方值 $E[x^2(t)]$，或称为平均功率 ψ_x^2，其表达式为

$$\psi_x^2 = E[x^2(t)] = \lim_{T\to\infty}\frac{1}{T}\int_0^T x^2(t)\,\mathrm{d}t \tag{5-2}$$

ψ_x^2 表达了信号的强度，其正平方根称为均方根值，又称为有效值 x_{rms}，也是信号的平均能量的一种表达。

如 $x(t)$ 经采样后得离散数据信号 $x(t_1)$，$x(t_2)$，$x(t_3)$，…，$x(t_N)$，其均方根值表示为

$$\psi_x^2 = \frac{1}{N}\sum_{i=1}^{N} x(t_i)^2 \tag{5-3}$$

式中，N 是样本数据个数。

峰值是在某段时间内振幅的最大值，其表达式为

$$x_p = \max|x(t)| \tag{5-4}$$

对磨损类故障用均方根指标比较有效；冲击类故障，对峰值指标比较敏感。但这些参数的数值大小与所用的测量仪器的频带有关，不同频率范围的仪器所测得的值不尽相同，频率范围宽、阻带衰减特性缓慢的仪器读数偏高。这些参数对监测状态的变化有一定效果，但一般受负载、转速及测试系统变化的影响较大，在要求不高的简单监测情况下可选用，必要时可采用比值参数即无量纲的参数。

（2）无量纲的参数　有波形因子 S、峰值因子 C、脉冲因子 I、裕度因子 L，它们分别定义为

$$S = \frac{x_{rms}}{x_{av}},\quad C = \frac{x_p}{x_{rms}},\quad I = \frac{x_p}{x_{av}},\quad L = \frac{x_p}{x_r} \tag{5-5}$$

其中，x_r 为方根幅值、x_{av} 为平均幅值，即

$$x_{av} = \bar{x} = \int_{-\infty}^{+\infty} |x| p(x)\,\mathrm{d}x \tag{5-6}$$

$$x_r = \left[\int_{-\infty}^{+\infty} |x|^{\frac{1}{2}} p(x)\,\mathrm{d}x\right]^2 \tag{5-7}$$

（3）斜度指标和峭度指标　偏斜度指标用于和正态分布曲线进行比较，定量地确定分布密度偏离正态分布的程度，定义为

$$\alpha = \int_{-\infty}^{+\infty} x^3(x) p(x)\,\mathrm{d}x \tag{5-8}$$

峭度指标是概率密度分布陡峭程度的度量，表示振动波形中是否有冲击或尖峭的值。它的定义为

$$\beta = \int_{-\infty}^{+\infty} x^4(x) p(x)\,\mathrm{d}x \tag{5-9}$$

峭度系数 β 对非平稳信号中的冲击信号变化敏感。当设备出现冲击时，则幅值概率密度函数偏离正态分布，相应峭度系数 β 明显增大，能表征故障早期发展的程度。峭度系数 β 在故障达到一定严重程度以后其量值反而衰减。

一般来说，无量纲的参数对故障很敏感，而对信号的幅值和频率变化并不敏感，即与设备运行的工况无关，仅依赖于幅值分布的形状。实验与分析表明，波形因子 S 和峰值因子 C 对冲击脉冲数的增多和幅值分布形状的变化不太敏感，而脉冲因子 I 和裕度因子 L 则比较敏感，从而可望在设备的振动或噪声信号诊断中加以

应用。

利用幅值域参数指标可以实现简易诊断，只能判断是否有故障，但是要判断到底是什么类型的故障，故障发生在那个元件上以及故障的严重程度就需要对振动信号进行频域分析，根据频谱图中的频率成分以及各有关频率成分幅值的大小进行精确诊断。

2. 振动信号时域分析方法

（1）时域同步平均法

时域同步平均法是从混有噪声干扰的信号中提取周期性分量的有效方法，也称相干检波法。当随机信号中包含有确定性的周期性信号时，如果截取信号的采样时间等于周期性信号的周期，将所截得的信号叠加平均，就能将该周期信号从随机信号、非周期信号中分离出来，而保留指定的周期分量及高频谐波分量，提高周期信号的信噪比。

如果一信号 $x(t)$ 由周期信号 $y(t)$ 和白噪声 $n(t)$ 组成，以 $y(t)$ 的周期去截信号 $x(t)$，共截得 N 段，然后将各段对应点相加，由于白噪声的不相关性，可得到：

$$x(t_i) = Ny(t_i) + \sqrt{N}n(t_i) \tag{5-10}$$

再对 $x(t_i)$ 平均，便得到输出信号 $y_1(t_i)$

$$y_1(t_i) = y(t_i) + \frac{n(t_i)}{\sqrt{N}} \tag{5-11}$$

此时输出白噪声是原来信号 $x(t)$ 中的白噪声的 $1/\sqrt{N}$，因此信噪比将提高。

（2）相关分析

相关函数描述了信号的相关性，揭示了信号波形的结构特征。用互相关函数可以描述两个不同信号的相似程度；自相关函数除了描述信号在不同时刻的相似性，除消除噪声之外，还可以反映信号幅值变化的剧烈程度。设 $x(n)$、$y(n)$ 为采样值，m 为时延拍数，N 为采样点数，则信号的互相关函数为

$$R_{xy}(m) = \frac{1}{N}\sum_{n=0}^{N-1} x(n)y(n+m) \tag{5-12}$$

自相关函数为

$$R_{xx}(m) = \frac{1}{N}\sum_{n=0}^{N-1} x(n)x(n+m) \tag{5-13}$$

设调幅信号为

$$X(t) = Ae^{j\omega' t}e^{j\phi' t} \tag{5-14}$$

把式（5-14）代入式（5-13）得

$$R_{xx}(t) = A^2 e^{j\omega' t}e^{j\phi' t} \tag{5-15}$$

式（5-15）说明相关函数具有降噪特性，同时它还不改变信号的调制特性。

调幅信号的自相关函数仍为调幅信号，调制频率和载波频率均不改变。

3. 振动信号频域分析方法

设备在运转时，各部件都是以一定的频率及幅值振动，即每个部件都有自身的“特征频率”及“特征频率幅值”。当特征频率幅值增大时，表明该部件可能出现故障。因此利用频域进行诊断时，只需分析出某一部件的特征频率，并重点对该特征频率的幅值进行监测，通过与标准特征频率的对比，即可对该部件的运行状态进行诊断。在一般情况下，设备各部件的特征频率是不相同的，通过对不同特征频率的监测，即可实现对不同部件故障的区分，实现故障的定性。

（1）傅里叶变换分析方法　傅里叶变换是进行频率结构分析的重要工具，它可以分辨组成任意波形的一些不同频率的正弦波和它们各自的振幅。对于一个时域信号 $x(t)$ 其傅里叶正变换为

$$X(f) = \int_{-\infty}^{\infty} x(t) e^{-j2\pi ft} dt \tag{5-16}$$

傅里叶逆变换为

$$x(t) = \int_{-\infty}^{\infty} X(f) e^{j2\pi ft} df \tag{5-17}$$

傅里叶变换是从时域到频域，或从频域到时域的信号转换，并无信息丢失。

（2）离散傅里叶变换（DFT）　离散傅里叶变换是在数字计算机上进行的傅里叶变换。在对信号 $x(t)$ 进行傅里叶变换运算，并在计算机上实现时，必要的步骤是把模拟信号 $x(t)$ 和 $X(f)$ 改造为离散数据，并且把计算范围限定在一个有限区间，进而实现正、逆傅里叶变换运算。这样，在时域和频域中都只取有限个离散数据，这些数据分别构成周期性的离散时间函数和频率函数。

离散傅里叶变换（DFT）和离散逆傅里叶变换（IDFT）公式为

$$\text{DFT:}\quad X(k) = \sum_{n=0}^{N-1} x(n) W_N^{nk} \qquad k = 0, 1, \cdots, N-1 \tag{5-18}$$

$$\text{IDFT:}\quad x(n) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) W_N^{-nk} \qquad n = 0, 1, \cdots, N-1 \tag{5-19}$$

其中，$W_N = e^{-j(2\pi/N)}$，N 为采样点数。式（5-18）和式（5-19）将 N 个时域采样点与 N 个频域采样点联系起来。实际信号只要在所关心的处理区间（$0 \leqslant n \leqslant N-1$；$0 \leqslant k \leqslant N-1$）是确定的，则无论其在非处理区间如何，都可以用上式构成 DFT 和 IDFT 的关系。为了减少计算次数，提高运算速度，一般采用基于时间抽取的快速傅里叶变换（FFT）算法。

（3）功率谱分析方法　传统的傅里叶变换能够很好地处理平稳信号。从理论上讲，傅里叶变换不能处理非平稳信号。而故障信号，绝大部分是非平稳信号。在频谱分析中，幅值谱通过信号的傅里叶变换直接求得，而功率谱可通过幅值谱的平方求得，另外也可以通过相关函数的傅里叶变换求得。功率谱在对各种动力学过程

的分析中，具有更加明显的效果，功率谱图中突出了主频率，而且对随机非平稳信号通常只做功率谱分析。

自功率谱分析：自功率分析能够将实测的复杂工程信号分解成简单的谐波分量来研究，描述了信号的频率结构，因此对机器设备的动态信号做功率谱分析相当于给机器“透视”，从而了解机器设备各个部分的工作状况。

用FFT方法可以直接从原始数据计算功率谱密度估计。理论上可以对任意采样长度 N 的数据进行计算，但实际中为了减少运算次数，往往采用的数据长度为 $N=2^m$（m 为正整数）。因此，数据序列必须被截取或者加上零值点，以得到所要求的数据点个数，即对原始数据必须用时间窗进行截断处理或补0。

对于一个测量数据记录样本来说，当采样长度为 T_0 时，其单边连续功率谱密度为：

$$P_s(f)=\frac{2}{T_0}|X(f)|^2 \tag{5-20}$$

若采样周期为 T，采样点数为 N，则 $T_0=NT$。由连续傅里叶变换和离散傅里叶变换关系式得：

$$X(f)=TX(k) \tag{5-21}$$

故其单边离散功率谱密度为：

$$P(k)=\frac{2}{NT}T^2|X(k)|^2=\frac{2}{N}TX^*(k)X(k) \tag{5-22}$$

互功率谱分析：互功率谱分析能够揭示不同信号间的相互关系的规律。设测量数据记录的两个样本 $x(t)$、$y(t)$ 的采样序列分别为 $\{x_n\}$ 和 $\{y_n\}$，其中 $n=0$，1，2，…，N-1。与自功率谱密度推导相类似，互功率谱密度表达式可写为：

$$P_{xy}(k)=\frac{2T}{N}X^*(k)Y(k) \tag{5-23}$$

（4）倒频谱分析方法　倒频谱（Cepstrum）分析可以处理复杂频谱图上的周期结构。倒频谱分析技术早期用于地震的回波分析，近年在机械故障诊断、语音信号分析、雷达及声呐的数据处理等方面得到相当广泛的应用。倒频谱可将输入信号与传递函数区分开来，便于识别。还能区别出因调制引起的功率谱中的周期分量，诊断出调制源。这在齿轮和滚动轴承发生故障、信号中出现调制现象时，对于检测和分析信号十分有效。

倒频谱的数学描述为两类：一类是实倒频谱（Real Cepstrum），简称“R-CEP”；另一类是复倒频谱（Complex Cepstrum），简称“C-CEP”。

实倒频谱：如果时间序列 $x(t)$ 的傅里叶正变换为 $X(f)$，其功率谱为：$P_s(f)=\frac{2}{T_0}|X(f)|^2$，那么：

1）功率倒频谱（Power Cepstrum）

$$C_{xp}(\tau) = |F[\ln P_s(f)]|^2 \tag{5-24}$$

即功率谱的对数谱的模的平方。式中，F [ ] 表示傅里叶正变换。

2）幅值倒频谱（Magnitude Cepstrum） 实际应用较多的是上式的算术平方根定义形式，称为幅值倒频谱，即

$$C_{xa}(\tau) = \sqrt{C_{xp}(\tau)} = |F[\ln P_s(f)]| \tag{5-25}$$

即功率谱的对数谱的模。

复倒频谱 在实倒频谱分析中，丢失了相位信息。复倒频谱是从复谱得来的，因此不损失相位信息。

设时间信号 $x(t)$ 的傅里叶变换为 $X(f)$，即

$$X(f) = \mathrm{Re}[X(f)] + \mathrm{jIm}[X(f)] \tag{5-26}$$

则复倒频谱 $C_{xc}(\tau)$ 为

$$C_{xc}(\tau) = F^{-1}[\ln P_s(f)] \tag{5-27}$$

式中，F^{-1} [ ] 表示傅里叶逆变换。

5.3 基于复解析小波的包络解调方法

本节首先介绍希尔伯特解调方法、广义检波滤波解调方法、共振解调方法等常见的包络解调方法，并在此基础上重点研究基于复解析小波包络解调技术。阐述 Morlet 复解析小波带通滤波器的构造方法以及参数选择原则，归纳小波簇带通滤波器的优点，推导信号复解析小波变换的正交性，提出复解析小波包络解调分析方法。

5.3.1 信号调制技术

1. 调制的定义

调制是指利用某一信号来控制或改变另一高频振荡信号的某个参数（幅值、频率或相位）的过程。当被控制的量是高频振荡信号的幅值时，称为幅值调制或调幅；当被控制的量为高频振荡信号的频率时，称为频率调制或调频；而当被控制的量为高频振荡信号的相位时，则称为相位调制或调相。在调制解调技术中，将控制高频振荡的低频信号称为调制波，载送低频信号的高频振荡信号称为载波，将经过调制过程所得的高频振荡波称为已调制波。根据被控参数（如幅值、频率、相位）的不同已调制波分别有调幅波、调频波、调相波等不同的称谓。

以用调制信号 $s(t) = te^{-t}$ 进行幅值调制的过程为例，若载波频率为 $f_c = 10\mathrm{Hz}$，则已调信号为 $f(t) = s(t) \cdot \cos(2\pi f_c t)$。图 5-2 为调制信号 $s(t)$ 的波形图及其频谱图，图 5-3 为幅值调制后的波形图以及频谱图。可见，从时域上讲，调制过程即是

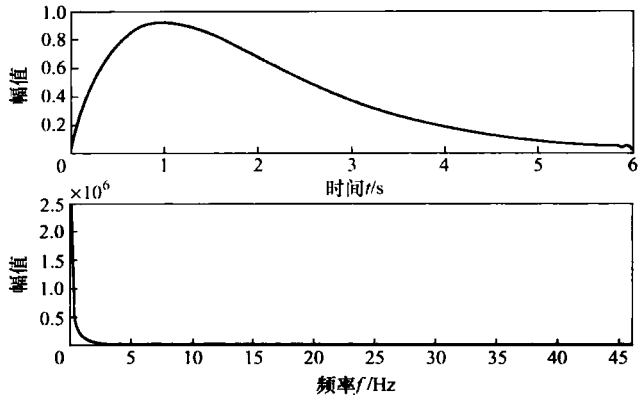

图 5-2　原始信号及其频谱图

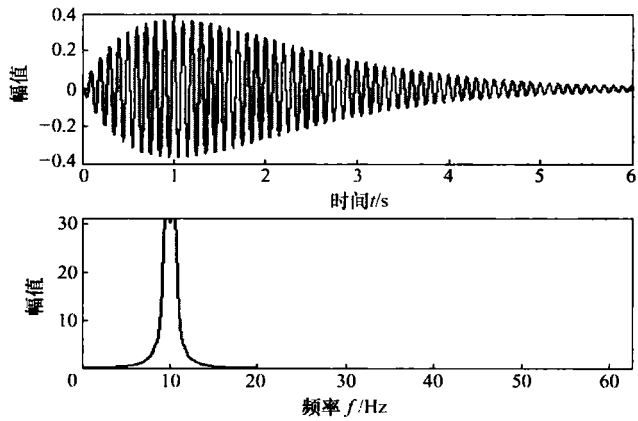

图 5-3　调制信号及其频谱图

使载波的某一参量随调制波的变化而变化；而在频域上，调制过程则是一个移频的过程。

2. 振动信号的调制现象

在旋转机械系统中，周期性的冲击故障信号，常引起系统在其固有频率处的谐振，从而在该固有频率附近形成以故障特征频率为基频的边频，这些边频是由于故障信号调制的结果。旋转机械故障多为旋转元件由于长期运行而导致的表面损伤，如点蚀、剥落、裂纹等。故障发生时的机械振动有如下两个主要特征：

（1）周期性重复冲击　当轴承元件有缺陷时，在工作过程中将对系统产生周期性冲击，这种冲击重复地激发系统的阻尼固有振动。因而，振动信号中通常存在具有一定周期的重复冲击衰减波形。

（2）幅值和频率调制　由于滚动轴承的特有结构，轴承元件缺陷产生的冲击

振动常常受到转轴频率、内圈通过频率、外圈通过频率、滚动体通过频率及保持架通过频率等的调制，因而振动信号中常包含有幅值调制特征。冲击振动发生的间隔频率，称为特征频率，可从元件的转速和零件尺寸求得。

5.3.2 解调原理

解调的目的就是要得到调制信号，即获取包络信号，从而进一步分析时频域特征，达到故障诊断的目的。实际中遇到的许多故障信号是窄带信号，该类信号的频谱集中在相对较高的载波频率f_c附近，在频谱上有较窄的带宽B。在时域中，该类信号表现为慢时变包络函数$f(t)$，包络中是以载波频率f_c的快速振荡，如图 5-4a 所示，图中虚线表示信号的包络，是要提取的有用信息信号，如图 5-4b 所示。

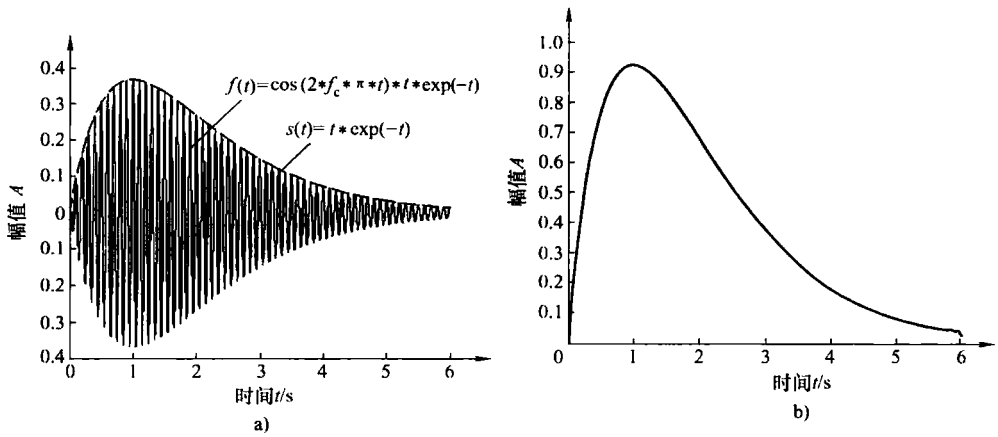

图 5-4 调制解调过程

a）调制信号 b）包络解调信号

包络解调是目前应用最为广泛的解调方法，其实现原理简单，抗低频干扰性好，信噪比高，具有较高的灵敏度和可靠性，因此包络解调在旋转机械诊断中得到了广泛的应用，是目前滚动轴承缺陷诊断中最为成熟的方法。具体实现原理如图 5-5 所示。

包络分析的具体步骤为：

（1）带通滤波 将信号通过适当的带通滤波器，将相应的高频共振信号过滤出来，以提高信噪比。

（2）包络检波 对过滤出来的高频共振信号进行包络检波，即进行 Hilbert 变换，求得包络信号。

（3）频谱分析 对包络信号进行功率谱分析，获取包络信号的频率成分，从而根据此频率成分确定对应的故障形式。

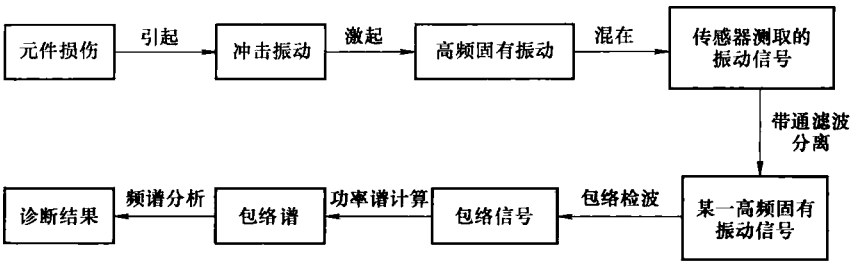

图 5-5　包络解调原理图

5.3.3　包络解调方法

包络解调技术是故障诊断中较常用的一种方法，它可非常有效地识别某些冲击振动，从而找到该冲击振动的振源。目前常用的解调方法包括：共振解调、希尔伯特变换解调、广义检波滤波解调等。其中广义检波滤波解调具体包括：高斯绝对值分析解调、检波滤波解调和平方解调。虽然这五种方法都可以将幅值调制信号中的载波分量分离出去，但对于同一个信号，这五种方法所解调出来的包络信号的幅值并不一致，因此需要根据实际信号的特点选择正确的解调方法。

1. *希尔伯特解调方法*

希尔伯特包络解调方法就是利用希尔伯特变换（HT，Hilbert Transform）获得动态调制信号。一个实信号 $s(t)$ 的 HT 定义为

$$\hat{s}(t) = \frac{1}{\pi}\int_{-\infty}^{+\infty}\frac{s(\tau)}{t-\tau}\mathrm{d}\tau \tag{5-28}$$

令 $h_{\mathrm{ht}}(t)=\dfrac{1}{\pi t}$，则上式可以写成卷积的形式

$$\hat{s}(t) = s(t) * h_{\mathrm{ht}}(t) \tag{5-29}$$

对式（5-29）进行傅里叶变换可得到：

$$\hat{S}(f) = S(f)H_{\mathrm{ht}}(f) \tag{5-30}$$

其中，$S(f)$ 为 $s(t)$ 的傅里叶变换，$H_{\mathrm{ht}}(f)$ 为 $h_{\mathrm{ht}}(t)$ 的傅里叶变换。$\hat{s}(t)$ 可看成是输入为 $s(t)$、频率响应函数为 $H_{\mathrm{ht}}(f)$ 的滤波器的输出。

由傅里叶变换的知识可知，$\mathrm{j}h_{\mathrm{ht}}(t) = \mathrm{j}/\pi t$ 的傅里叶变换为符号函数 $\mathrm{sign}(f)$，因此希尔伯特变换的频率响应函数为

$$H_{\mathrm{ht}}(\mathrm{j}f) = -\mathrm{j}\,\mathrm{sign}(f) = \begin{cases} -\mathrm{j} & f>0 \\ \mathrm{j} & f<0 \end{cases} \tag{5-31}$$

频响函数所对应的幅频、相频特性分别为

$$|H_{\mathrm{ht}}(\mathrm{j}f)| = 1 \tag{5-32}$$

$$\varphi_{ht}(f)=\begin{cases}-\pi/2 & f>0\\ \pi/2 & f<0\end{cases} \tag{5-33}$$

式（5-31）说明希尔伯特变换可看成是全通滤波器，sign（·）为符号函数。式（5-30）说明 $\hat{S}(f)$ 是 $S(f)$ 在频域中作相移，在正频域内延迟 $\pi/2$，在负频域内超前 $\pi/2$，即 Hilbert 变换实际上是一个 90°移相器。同时也说明 $s(t)$ 与其希尔伯特变换 $\hat{s}(t)$ 是正交关系。

于是得到 $s(t)$ 的解析信号：

$$g(t)=s(t)+\mathrm{j}\hat{s}(t) \tag{5-34}$$

$g(t)$ 的幅值 $A(t)=\sqrt{s^2(t)+\hat{s}^2(t)}$ 便是原始信号的包络。由于 Hilbert 变换是一种同域变换方法，抑制噪声的能力较弱，在进行 Hilbert 变换前必须先经带通滤波器将故障调制信号分离出来。图 5-6 是 Hilbert 包络解调的分析过程。

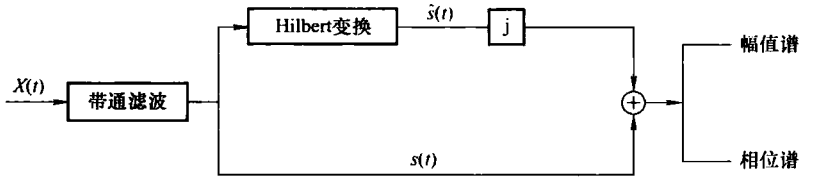

图 5-6 Hilbert 包络解调的分析过程

Hilbert 解调方法简单易实现，因此得到了广泛的应用，但是 Hilbert 变换时频定位能力较差，同时还存在着泄漏误差。对于时变信号 Hilbert 变换方法提取的信号包络不够光滑，毛刺多，影响了提取精度，反映在幅值谱上，表现为谱峰太多，且存在大量的高频成分，难以真正展现故障信号的变化规律。因此，需要对这种解调方法进行改进。

2. 广义检波滤波原理及解调方法

检波滤波解调方法起源于模拟电路中的检波电路，在模拟电路中最简单的调幅检波器为二极管检波电路，电路图如图 5-7 所示，通常用电容器充放电来解释其工作原理。

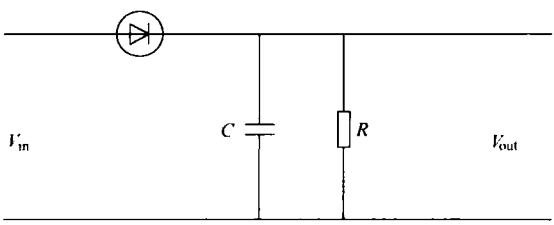

图 5-7 二极管检波电路

可以看出该电路就是半波整流电路，所以可以换个角度来分析工作原理：由于二极管的反向截至作用，通过二极管的信号为半波信号，而并联的电阻 R 和电容 C 的作用类似于低通滤波器，故解调信号可以看做是半波信号通过低通滤波器的结果。将调幅信号截半使之成为半波信号，再将半波信号通过低通滤波器就可以得到解调信号。

设调幅信号为

$$x(t)=A[1+m\cos(2\pi f_t t+\varphi_t)]\cos(2\pi f_z t+\varphi_z) \tag{5-35}$$

式中，m 是调制系数；

通常 $m<1$，若 $m>>1$，则为过调制信号，此时无法将调制信号不失真地解调出来。f_t 是调制频率；f_z 是载波频率；$f_z>>f_t$。

半波信号为

$$g(t)=A[1+m\cos(2\pi f_t t+\varphi_t)]h(t) \tag{5-36}$$

式中，$$h(t)=\begin{cases}\cos(2\pi f_z t+\varphi_z) & \cos(2\pi f_z t+\varphi_z)>0\\ 0 & \cos(2\pi f_z t+\varphi_z)\leqslant 0\end{cases}$$

对于半波信号，滤除掉直流分量与高频分量，便可得到调制信号。

这种解调分析方法的关键在于对载波信号进行检波滤波，使其变成非谐波周期信号，这样在其傅里叶级数中包含直流分量，正是利用该直流分量解调出了调制信号。由此可以得到广义检波滤波解调分析方法的思路为

$$\cos(2\pi f_z t+\varphi_z)\rightarrow h(t)=\begin{cases}\lambda_1\cos(2\pi f_z t+\varphi_z) & \cos(2\pi f_z t+\varphi_z)>0\\ \lambda_2\cos(2\pi f_z t+\varphi_z) & \cos(2\pi f_z t+\varphi_z)\leqslant 0\end{cases} \tag{5-37}$$

式中，$\lambda_1\neq\lambda_2$。

显然信号 $h(t)$ 是频率为 f_z 的非谐波周期信号，在软件解调时对载波信号作的检波滤波相当于对原始调制信号 $x(t)$ 作修正得到修正信号 $g(t)$

$$g(t)=\begin{cases}\lambda_1 x(t) & x(t)>0\\ \lambda_2 x(t) & x(t)\leqslant 0\end{cases} \tag{5-38}$$

由广义检波滤波解调方法解调出的调制信号幅值与真实的调制信号幅值之间相差一个系数，该系数与 λ_1，λ_2 有关，可以事先计算出来，不过在故障诊断中更加关心的还是调制信号的频率。当 $\lambda_1=1$，$\lambda_2=0$ 时，就是检波滤波解调分析。当 $\lambda_1=1$，$\lambda_2=-1$ 时，就是绝对值解调分析。

广义检波滤波解调分析可分为 4 个步骤：

1）对信号进行带通滤波，选出感兴趣的异常振动频带；

2）对异常振动信号按式（5-38）进行修正得修正信号；

3）对修正信号进行低通滤波便可得到调制信号；

4）对调制信号重采样并做功率谱分析。

由于对载波信号采样时采样频率比较高，而调制信号的频率比较低，故其频谱分辨率较低，为了提高频率分辨率，需要先对调制信号进行重采样，再对重采样信号作谱分析，这样可得到调制信号的细化频谱。

3. *共振解调方法*

所谓共振解调技术，也称为冲击脉冲技术、包络检波技术，是对低频（通常在几千赫兹以内）的冲击所激起的高频（数十倍于冲击频率的）共振波进行包络检波和低通滤波，即解调分析，获得一个对应于故障冲击信息的，而又放大并展宽了的共振解调波。该技术广泛应用于轴承、齿轮的故障诊断监控。如用于滚动轴承的故障检测，就是利用运转轴承零件中故障的低频冲击所产生的频域十分宽广、频谱极为丰富的故障冲击波的高频分量，激起高频谐振器的共振，再对高频共振波进行解调处理，获得一个剔除了常规低频振动干扰，但富含故障信息而信噪比大为提高的共振解调波，并凭借对此共振解调波的幅值和频谱分析，实现故障的量值和故障类型的判定，这就是共振解调故障检测诊断技术。

5.3.4 复解析小波的带通滤波特性

从信号分析的角度，小波函数是一个带通滤波器，而复小波对应的则是一个复数滤波器。将复小波应用于故障冲击引起的共振信号的包络解调分析中，具有独特的优势。

下面是复 Morlet 小波的频率特性。由于旋转机械存在故障时，所形成的脉冲冲击信号具有衰减振荡的特性，为了突出缺陷信号的这一特性，并能从混有噪声的振动信号中检测出损伤类缺陷，通常选取 Morlet 基小波函数。

（1）单 Morlet 小波　单个 Morlet 小波的数学表达式如下所示：

$$\psi(t)=\frac{1}{\sqrt{2\pi}a}\mathrm{e}^{\mathrm{j}2\pi f_0 t}\mathrm{e}^{-t^2/2a^2}=\psi_{\mathrm{re}}(t)+\mathrm{j}\psi_{\mathrm{im}}(t)=$$

$$\frac{1}{\sqrt{2\pi}a}\mathrm{e}^{-t^2/2a^2}[\cos(2\pi f_0 t)+\mathrm{j}\sin(2\pi f_0 t)] \tag{5-39}$$

$$\psi_{\mathrm{re}}(t)=\frac{1}{\sqrt{2\pi}a}\mathrm{e}^{-t^2/2a^2}\cos(2\pi f_0 t) \tag{5-40}$$

$$\psi_{\mathrm{im}}(t)=\frac{1}{\sqrt{2\pi}a}\mathrm{e}^{-t^2/2a^2}\sin(2\pi f_0 t) \tag{5-41}$$

其傅里叶变换为

$$\Psi(f)=\mathrm{e}^{\frac{-a^2[2\pi(f-f_0)]^2}{2}} \tag{5-42}$$

式中，a 是尺度参数，f_0是中心频率。

通过改变参数 a，可以改变小波函数的高度和宽度。图 5-8 和图 5-9 分别是

$a=0.2$、$f_0=5$ 时的单个 Morlet 小波的时域波形图和频谱图。图 5-8 中，实线和虚线分别代表 Morlet 小波的实部 $\psi_{re}(t)$ 和虚部 $\psi_{im}(t)$ 波形。

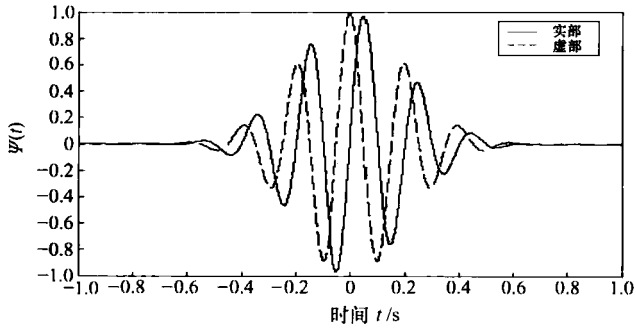

图 5-8　单个 Morlet 小波时域图

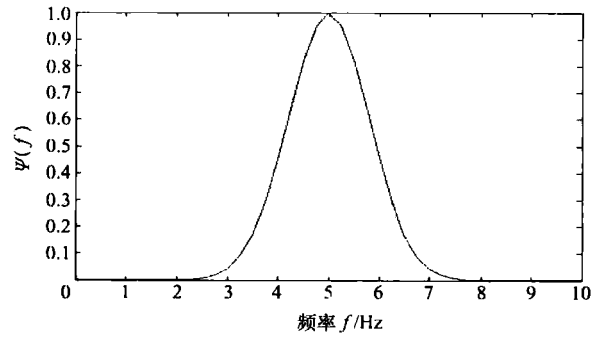

图 5-9　单个 Morlet 小波频谱图

由图 5-9 可知，单个的 Morlet 小波是一个零相移的窄带带通滤波器。由于单个小波的频谱是钟形的，因此单小波不适合提取冲击信号中较宽频率范围的共振频带成分，这方面不足可以通过利用 Morlet 小波簇构造平顶宽带滤波器加以解决。

（2）Morlet 小波簇　所谓小波簇，是指对单个小波进行多次频移和叠加而形成的集合小波。若 Morlet 小波 $\psi(t)=\dfrac{1}{\sqrt{2\pi}a}e^{j2\pi f_L t}e^{-t^2/2a^2}$ 的中心频率为 f_L，小波簇是由 $N+1$ 个频移后的单个小波叠加而得到的。因此，我们可以得到一个带通滤波器：

$$\psi_c(t)=\frac{1}{\sqrt{2\pi}a}\exp\left(\frac{-t^2}{2a^2}\right)\{\exp[j2\pi f_L t]+\cdots+\exp[j2\pi(f_L+k\Delta f)t]+\cdots+\exp[j2\pi f_H t]\} \tag{5-43}$$

式中，$k=0,1,2,\cdots,N$；$f_H=f_L+N\Delta f$。

f_L和f_H分别表示首、末两 Morlet 小波频窗的中心频率；Δf 表示小波簇中相邻两

个小波中心频率的间距。通过选择合适的 a 和 Δf，可以得到具有良好频率特性的小波簇，并且可根据相邻频带的交叠程度，可构造出具有光滑平顶通带和边缘快速衰减的带通滤波器。

当 $a=0.2$，$N=10$，$f_L=10\text{Hz}$，$\Delta f=2\text{Hz}$ 时，则有 $f_H=30\text{Hz}$。根据式（5-42）可得到小波簇的频谱图如图 5-10 所示，从图中可以看出小波簇的频谱并不是平顶的。

当 $a=0.2$，$N=10$，$f_L=10\text{Hz}$，$\Delta f=1\text{Hz}$ 时，则有 $f_H=20\text{Hz}$。此时 11 个单个小波叠加为小波簇的频谱图如图 5-11 所示，可以得知在此参数条件下，小波簇带通滤波器具有平顶通频带及快速衰减的过渡带特性，即小波簇带通滤波器具有优良的带通滤波特性。

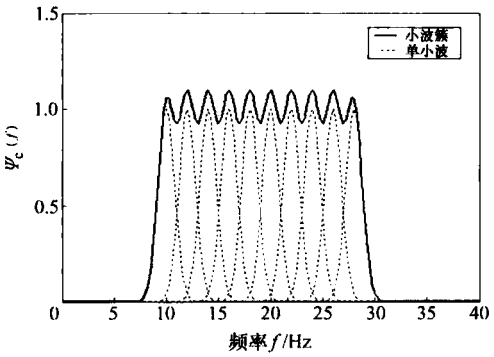

图 5-10 非平顶小波簇带通滤波器频率特性

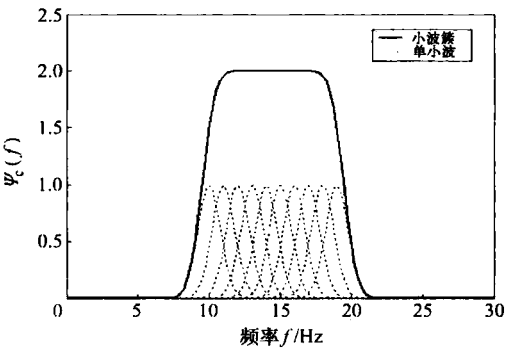

图 5-11 平顶小波簇带通滤波器频率特性

可见，可以通过改变 f_L 和 N 的值提取信号不同频率范围的信息。所以对于 Morlet 小波簇来说，形成平顶通带的带通滤波器应满足的条件为：所有单个 Morlet 小波的尺度参数要相同，相邻两个单个 Morlet 小波的中心频率间距 Δf 应相等，并且 Δf 的取值要合适。

5.3.5 复解析小波簇的包络解调方法

1. Morlet 小波簇的正交性

小波簇函数 $\psi_c(t)$ 的实部为

$$\psi_{cre}(t)=\frac{1}{\sqrt{2\pi}a}\exp\left(\frac{-t^2}{2a^2}\right)[\cos(2\pi f_L t)+\cdots+\cos(2\pi f_k t)+\cdots+\cos(2\pi f_H t)] \tag{5-44}$$

则其相应的傅里叶变换为

$$\Psi_{cre}(f)=\frac{1}{2}\sum_{k=0}^{N}\left\{\exp\left(-\frac{a^2[2\pi(f-f_k)]^2}{2}\right)+\exp\left(-\frac{a^2[2\pi(f+f_k)]^2}{2}\right)\right\} \tag{5-45}$$

小波簇函数 $\psi_c(t)$ 的虚部为

$$\psi_{cim}(t)=\frac{1}{\sqrt{2\pi}a}\exp\left(\frac{-t^2}{2a^2}\right)[\sin(2\pi f_L t)+\cdots+\sin(2\pi f_k t)+\cdots+\sin(2\pi f_H t)] \tag{5-46}$$

其相应的傅里叶变换为

$$\Psi_{cim}(f)=-\frac{j}{2}\sum_{k=0}^{N}\left\{\exp\left(-\frac{a^2[2\pi(f-f_k)]^2}{2}\right)-\exp\left(-\frac{a^2[2\pi(f+f_k)]^2}{2}\right)\right\} \tag{5-47}$$

式中，$f_k=f_L+k\Delta f$。

根据时域卷积相当于频域乘积的性质，可得 $\psi_{cre}(t)$ 的 Hilbert 变换为

$$\Psi_{cre}(f)H_{ht}(f)=-\mathrm{jsign}(f)\Psi_{cre}(f)=$$
$$-\mathrm{j}\frac{1}{2}\sum_{k=0}^{N}\left\{\exp\left(-\frac{a^2[2\pi(f-f_k)]^2}{2}\right)-\exp\left(-\frac{a^2[2\pi(f+f_k)]^2}{2}\right)\right\}=\Psi_{cim}(f) \tag{5-48}$$

上式说明 $\psi_{cim}(t)$ 是 $\psi_{cre}(t)$ 的 Hilbert 变换，因此小波簇函数的实部和虚部是正交关系。

同时又可得：

$$\begin{aligned}s_b(t)&=s(t)*\psi_c(t)=s(t)*\psi_{cre}(t)+\mathrm{j}s(t)*\psi_{cim}(t)\\&=s_{bre}(t)+\mathrm{j}s_{bim}(t)\end{aligned} \tag{5-49}$$

式中，$s_b(t)$ 是原信号 $s(t)$ 在带宽 f_L ~ f_H 范围内的信号成分；

$s_{bre}(t)$ 和 $s_{bim}(t)$ 分别是 $s_b(t)$ 的实部和虚部。

式（5-49）的傅里叶变换为

$$S_b(f)=S(f)\Psi_c(f)=S(f)\Psi_{cre}(f)+\mathrm{j}S(f)\Psi_{cim}(f)=S_{bre}(f)+\mathrm{j}S_{bim}(f) \tag{5-50}$$

综合式（5-48）~式（5-50）可得

$$S_{bim}(f)=-\mathrm{jsign}(f)S_{bre}(f) \tag{5-51}$$

由上式可知：$s_{bim}(t)$ 是 $s_{bre}(t)$ 的 Hilbert 变换形式，因此 $s_{bim}(t)$ 和 $s_{bre}(t)$ 也是正交关系。

以上分析表明，小波簇与信号的卷积运算可同步实现带通滤波和 Hilbert 变换。即利用复小波簇卷积运算，把传统的包络解调中的带通滤波环节和 Hilbert 解调环节结合在一起，实现带通滤波和解调一体化。

2. 小波簇提取包络信号

根据以上分析，振动信号经过小波簇卷积运算后的信号 $s_b(t)$ 其虚部是实部的 Hilbert 变换，所以 $s_b(t)$ 是一个解析信号。因此，可以用解调的方法得到包络信号

$$s_{ben}(t)=\sqrt{[s_{bre}(t)]^2+[s_{bim}(t)]^2} \tag{5-52}$$

其中，$s_{ben}(t)$ 表示包络信号。

如果测试信号存在故障，则我们可以通过分析包络信号 $s_{ben}(t)$ 的功率谱，从而确定信号的故障特征频率。

小波簇包络分析的步骤可概括为：

1）对原始信号 $s(t)$ 进行功率谱分析，根据功率谱图确定共振频带，即带通滤波范围；

2）根据带通滤波范围确定小波簇参数 f_L 和 N，构造复 Morlet 小波簇 $\psi_c(t)$；

3）将原始信号 $s(t)$ 的频谱 $S(f)$ 与 Morlet 小波簇 $\psi_c(t)$ 的频谱 $\Psi_c(f)$ 相乘（即卷积运算），然后对乘积 $S_b(f)$ 进行 IFFT 变换得到带限解析信号 $s_b(t)$；

4）求带限解析信号 $s_b(t)$ 的模得到包络信号 $s_{ben}(t)$；

5）求包络信号 $s_{ben}(t)$ 的功率谱，分析故障特征频率的变化，从而对故障形式作出具体的判断。

3. *小波簇包络解调方法仿真*

（1）调幅调相信号的解调　设有一滚动轴承内环的固有频率为 $f_c=800\text{Hz}$；故障轴承的内环通过频率为 $f_i=50\text{Hz}$，且调幅与调相并存，则设已调信号为

$$x(t)=a(1+m\cos 2\pi f_i t)\cos(2\pi f_c t+\beta\sin 2\pi f_i t) \tag{5-53}$$

式中，$a=1$，$m=0.38$，$\beta=0.98$

取采样频率 $f_s=4096\text{Hz}$，其时域波形和功率谱图分别如图 5-12a、b 所示。从频谱图 5-12b 上可以看到在 f_c（800Hz）周围存在 750Hz、850Hz、900Hz 的调制边频。

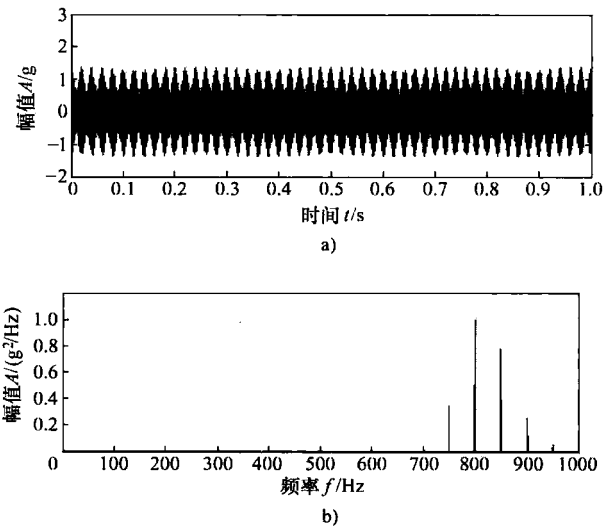

图 5-12　仿真调制信号时域图及其功率谱图

a）已调制信号时域图　b）已调制信号功率谱图

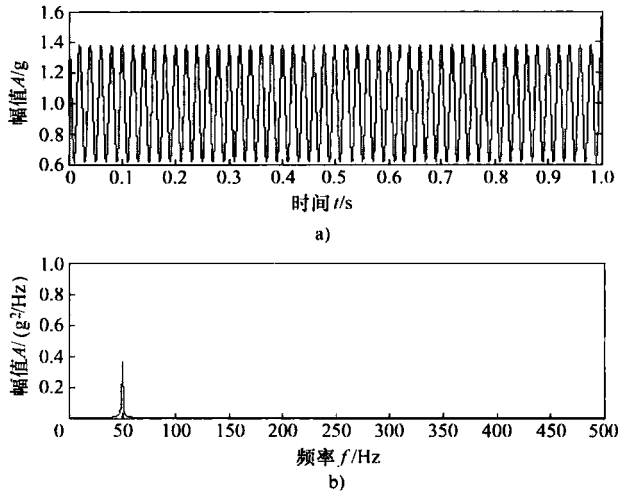

图 5-13　Hilbert 解调信号时域图及其包络功率谱

a）Hilbert 解调信号时域图　b）Hilbert 解调信号包络功率谱

可见，直接对信号进行功率谱分析，不易判断其故障特征频率成分。因此，用传统的 Hilbert 变换进行包络解调分析，包络解调信号及功率谱如图 5-13a、b 所示。

下面通过复解析小波包络解调方法对调制信号进行解调分析。根据功率谱图 5-12b 可知，f_c（800Hz）为中心频率，其共振频段范围大概为 600 ~ 1000Hz，因此，小波簇滤波范围选为 600 ~ 1000Hz。选择参数：$a=0.2$，$N=400$，$f_L=600$Hz，$\Delta f=1$Hz，故 $f_H=1000$Hz，构造了 600 ~ 1000Hz 的平顶带通滤波器，其频率特性如图 5-14 所示。图 5-15a、b 分别为经过小波簇带通滤波器滤波解调后得到的包络信号及其功率谱图。

根据以上分析，可以看出对于一般的调制信号，小波簇包络解调方法与 Hilbert 解调方法相比，解调信号的包络波形完全一样的，这证明了小波簇包络解调理论的正确性。

（2）含噪声调幅调相信号的解调　在相同参数条件下，这里通过对含噪声信号的包络解调分析来检验小波簇包络解调方法的除噪效果。

$$x(t)=a(1+m\cos 2\pi f_i t)\cos(2\pi f_c t+\beta\sin 2\pi f_i t)+\mathrm{rand}(0,1) \tag{5-54}$$

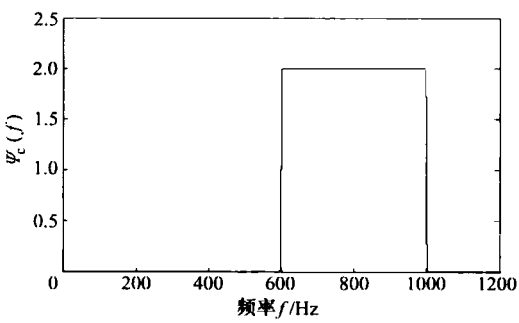

图 5-14　小波簇带通滤波器频率特性图

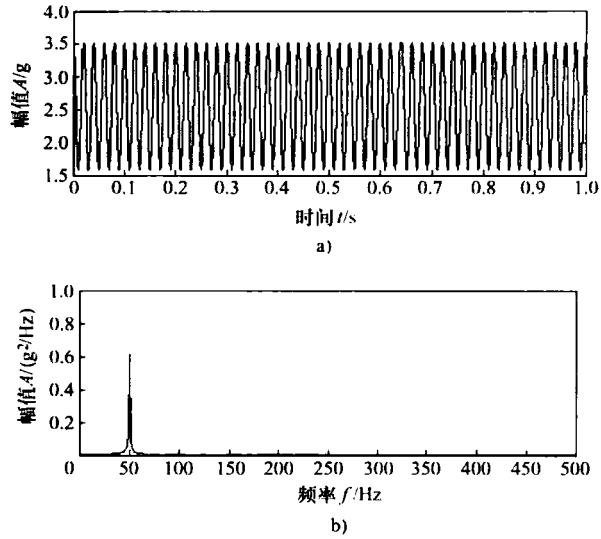

图 5-15 小波簇包络时域信号及其包络功率谱

a）小波簇包络时域信号 b）小波簇包络信号功率谱

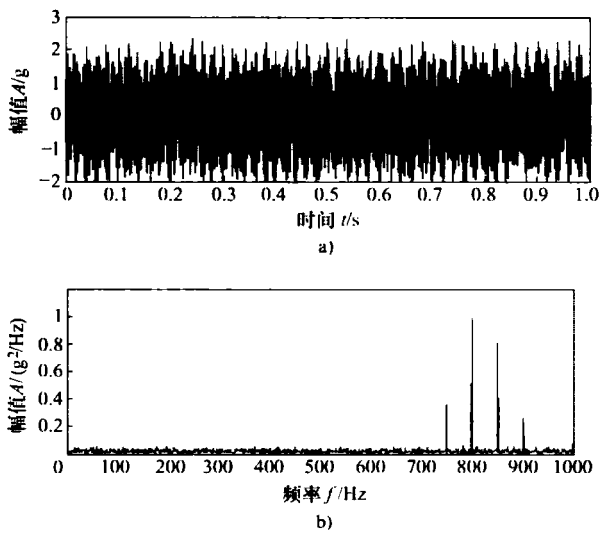

图 5-16 含噪声复杂调制信号及其功率谱图

a）含噪声复杂已调制信号 b）含噪声复杂已调制信号功率谱图

式中，rand(0，1）代表叠加均值为 0、根方差为 1 的高斯白噪声。

图 5-16a、b 分别为仿真信号的时域图及功率谱图，图 5-17a、b 分别为 Hilbert

解调法得到的包络信号时域图及功率谱图，图5-18a、b分别为小波簇包络解调方法得到的时域图及功率谱图。可以看出，小波簇包络解调方法比Hilbert包络解调法降噪效果显著。

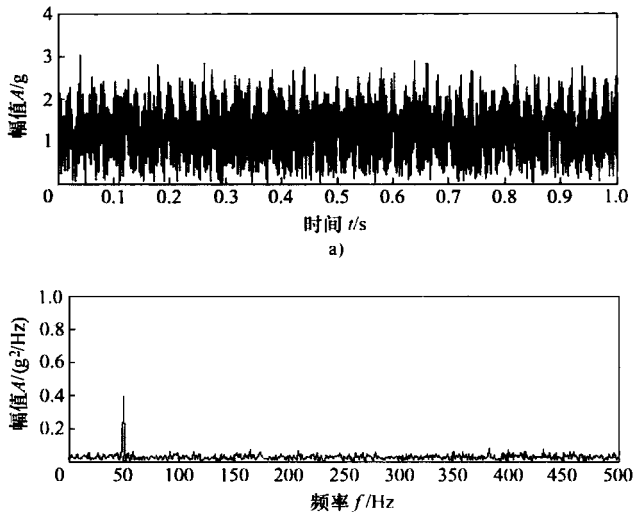

图5-17　Hilbert解调包络信号时域图及其包络功率谱

a）Hilbert解调包络信号时域图　b）Hilbert解调包络信号功率谱

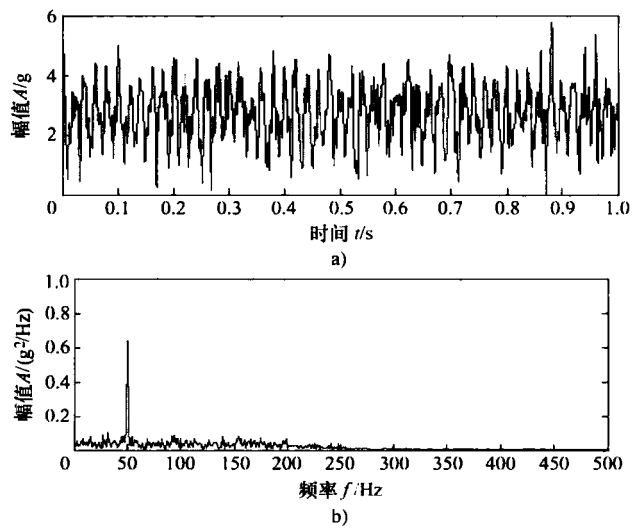

图5-18　小波簇解调包络信号时域图及功率谱

a）小波簇解调包络信号时域图　b）小波簇解调包络信号功率谱

（3）复杂调制信号的解调　在相同参数条件下，下面对含噪并叠加两频率信号的复杂调制信号进行小波簇包络解调分析。设

$$x(t)=a(1+m\cos 2\pi f_i t)\cos(2\pi f_c t+\beta\sin 2\pi f_i t)+z(t)+\mathrm{rand}(0,1) \quad (5\text{-}55)$$

式中，$z(t)=0.2\cos(2\pi 70t)+0.8\cos(2\pi 30t)$

图 5-19a、b 分别为上式复杂信号 $x(t)$ 的时域图和功率谱图。

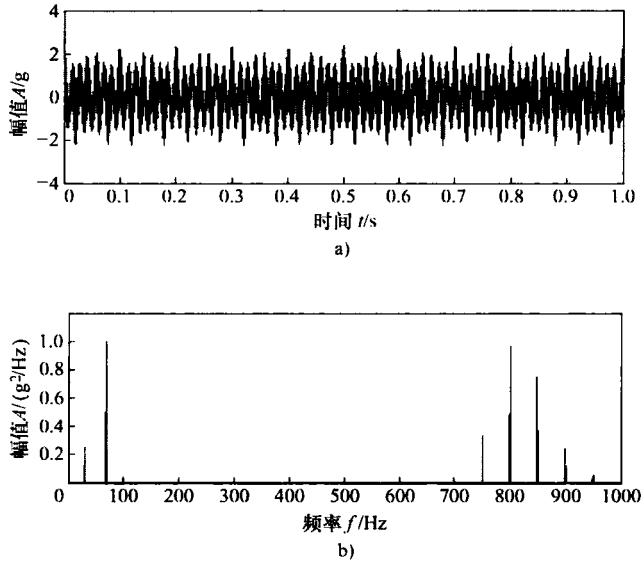

图 5-19　含相加信号的复杂已调制信号及其功率谱图

a）含相加信号的复杂已调制信号　b）含相加信号的复杂已调制信号功率谱图

根据三角函数和差化积的原理：

$$z(t)=A_1\cos(2\pi f_1 t)+A_2\cos(2\pi f_2 t)=$$

$$A_1[\cos(2\pi f_1 t)+\cos(2\pi f_2 t)]+(A_2-A_1)\cos(2\pi f_2 t)=$$

$$2A_1\cos\left(2\pi\frac{f_2+f_1}{2}t\right)\cos\left(2\pi\frac{f_2-f_1}{2}t\right)+(A_2-A_1)\cos(2\pi f_2 t) \quad (5\text{-}56)$$

显然，式（5-56）的第一项是一相乘信号的调制现象，其中载波频率 $(f_2+f_1)/2$，调制频率为 $(f_2-f_1)/2$。为了简化推导，令 $A_1=A_2=A$，式（5-56）变为

$$z(t)=2A\cos\left(2\pi\frac{f_2+f_1}{2}t\right)\cos\left(2\pi\frac{f_2-f_1}{2}t\right) \quad (5\text{-}57)$$

对 $z(t)$ 进行 Hilbert 变换有

$$\hat{z}(t)=2A\sin\left(2\pi\frac{f_2+f_1}{2}t\right)\cos\left(2\pi\frac{f_2-f_1}{2}t\right) \quad (5\text{-}58)$$

取包络并将其进行傅里叶级数展开有

$$y(t)=\sqrt{z^2(t)+\hat{z}^2(t)}=2A\left|\cos\left(2\pi\frac{f_2-f_1}{2}t\right)\right|=$$

$$2A\left\{\frac{2}{\pi}+\frac{4}{3\pi}\cos[2\pi(f_2-f_1)t]-\frac{4}{15\pi}\cos[2\pi 2(f_2-f_1)t]+\frac{4}{35\pi}\cos[2\pi 3(f_2-f_1)t]-\cdots\right\} \tag{5-59}$$

对式（5-59）进行频谱分析就得到以 f_2-f_1 为基频的一簇谐波频率成分，即将两相加信号的频率之差 f_2-f_1 作为调制频率解调出来，这就是 Hilbert 变换在机械设备故障诊断中的局限性。

根据以上推导有：

$$z(t)=0.2\cos(2\pi 70t)+0.8\cos(2\pi 30t)=$$
$$0.4\cos(2\pi 50t)\cos(2\pi 20t)+0.6\cos(2\pi 30t) \tag{5-60}$$

所以对信号 $x(t)$ 进行 Hilbert 变换解调分析时，可发现有 $f=40$Hz 频率成分被解调出来，如图 5-20b 所示。

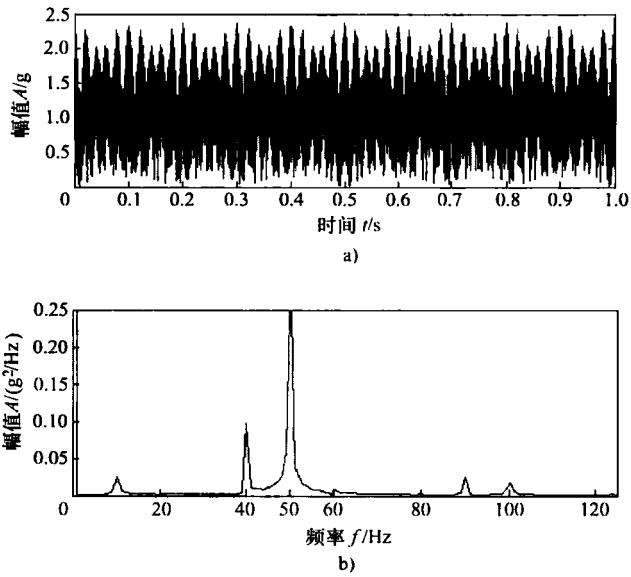

图 5-20　Hilbert 解调信号包络时域图和包络功率谱

a）Hilbert 解调的包络信号时域图　b）Hilbert 解调的包络信号功率谱

下面用小波簇包络解调分析方法对该信号进行分析，图 5-21a、b 为经过600～1000Hz 的小波簇滤波器包络分析后的包络信号时域图和功率谱图，可以看出：小波簇解调分析精确地解调出调制频率 $f_i=50$Hz，克服了 Hilbert 变换的上述局限性。

以上仿真结果表明：

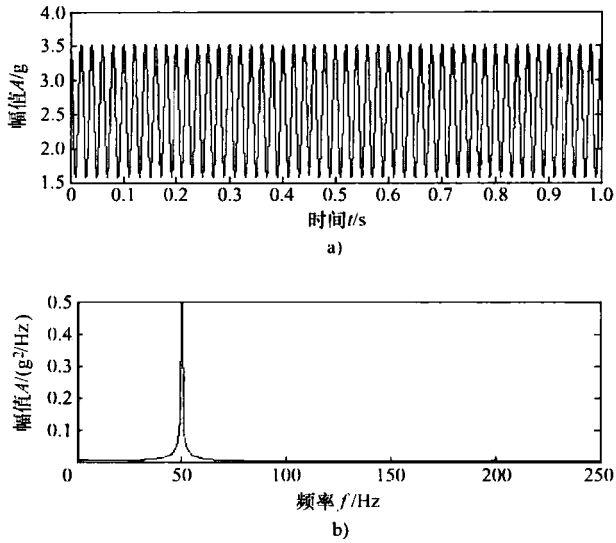

图 5-21 小波簇解调包络信号时域图及功率谱图

a）小波簇解调包络信号时域图 b）小波簇解调包络信号功率谱

1）基于小波簇的带通滤波器具有下列优点：相频特性零相移，幅频特性具有平顶通带，过渡带快速衰减。

2）参数调整直接，可根据实际情况选择合适的f_L和f_H对信号进行分析，同时通过调整参数 a 和 Δf，可得到满足频带范围及带宽要求的带通滤波器。

3）复小波变换，把传统的包络解调中的带通滤波和 Hilbert 解调结合在一起，实现了软件滤波解调一体化。

4）与传统的 Hilbert 解调方法相比较，基于小波簇的带通滤波方法更易于识别故障特征频率，而且对于相加信号和噪声具有很好的免疫能力。

5.4 小波簇包络解调方法在故障诊断中的应用

本节运用小波簇包络解调方法对干式真空泵和液压泵实验数据进行分析。

5.4.1 小波簇包络解调方法在真空泵故障诊断中的应用

参见 2.4.1 节，图 5-22 和图 5-23 所示分别是转轴频率为 105Hz 时，由传感器 BK-HV 测得真空泵高真空端信号时域波形图和其功率谱图。根据图 5-23 可知高频共振峰值大约是 6kHz，因此所需要的带通滤波器通带范围选为 5～7kHz。

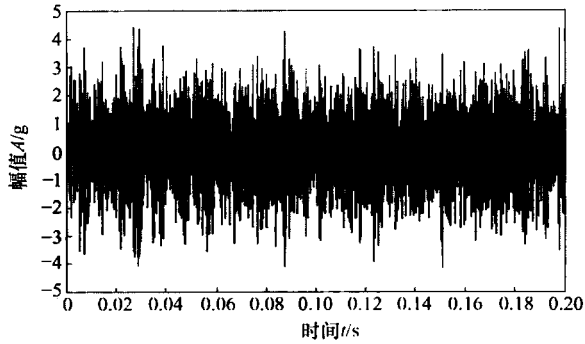

图 5-22　BK-HV 测得的原始振动波形

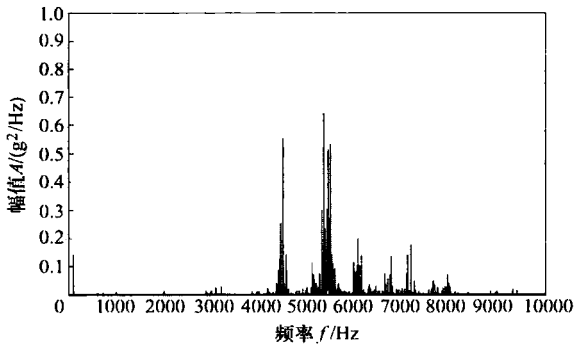

图 5-23　BK-HV 测得的原始振动信号功率谱

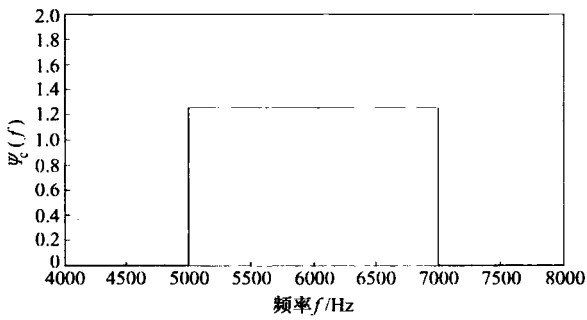

图 5-24　小波簇带通滤波器频率特性

基于小波簇包络分析原理，选择小波簇参数：$a=0.2$，$N=2000$，$f_L=5000\text{Hz}$，$\Delta f=1\text{Hz}$，因此有：$f_H=7000\text{Hz}$。根据以上参数我们构造了 5～7kHz 的平顶带通滤波器，其频率特性如图 5-24 所示。

图 5-25 是在 5～7kHz 范围内应用小波簇带通滤波器滤波解调得到的内环故障

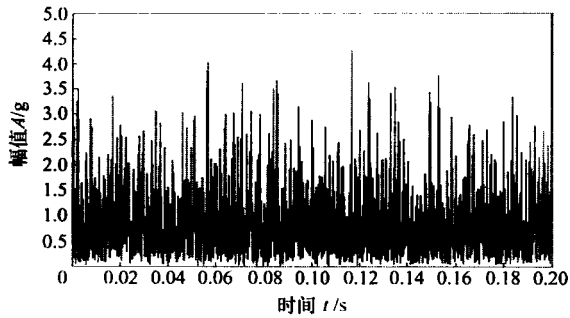

图 5-25 基于小波簇包络分析的时域包络信号

信号包络波形，图 5-25 对应的功率谱如图 5-26 所示，它清晰地解调出轴承的内环故障特征频率成分 550Hz。

同理，我们可以得到 ADXL-HV、ADXL-LV 所测得的信号的包络谱，分别如图 5-27、图 5-28 所示。对比此 3 个不同测点信号包络谱，其频率成分都是明显的 550Hz。因此，我们可以判断轴承故障形式为轴承内环故障，这同 2.4.2 节所得诊断结果一致。

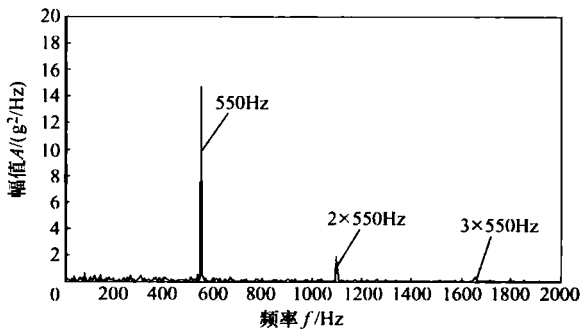

图 5-26 BK-HV 测得信号的包络功率谱

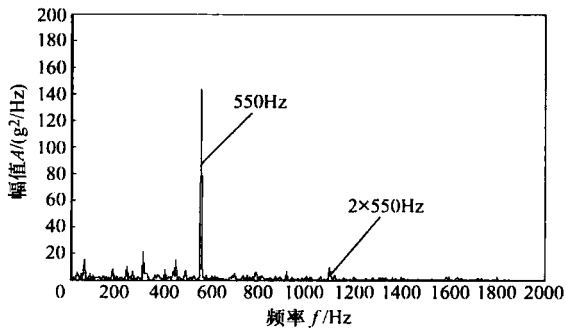

图 5-27 ADXL-HV 测得信号的包络功率谱

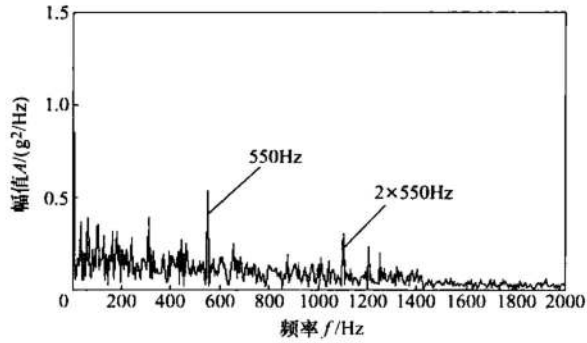

图 5-28　ADXL-LV 测得信号的包络功率谱

5.4.2　小波簇包络解调方法在液压泵故障诊断中的应用

1. 液压泵故障诊断实验简介

对某台材料实验机液压伺服系统中的液压泵进行状态监测与故障诊断。采用破坏性实验，将 MCY14-1B 型斜盘式轴向柱塞泵七柱塞中的一个进行脱靴处理。利用振动加速度传感器对柱塞泵端盖的振动进行监测。传感器输出信号经虚拟仪器 NI-DAQ 卡进行采集，并送计算机进行分析处理。

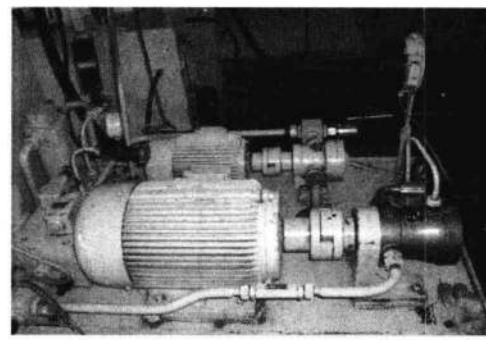

图 5-29　被试泵及电动机

被测试泵及驱动电动机如图 5-29 所示，其中柱塞泵柱塞数为 7，驱动电动机转速 1500r/min，故泵的转轴频率为 1500/60 = 25Hz。采集正常工作状态和单柱塞脱靴故障状态的振动信号，脱靴故障特征频率等于转轴频率。在以上试验参数下，当轴向柱塞泵正常工作时流体冲击振动基频为 2 × 25 × 7Hz = 350Hz，机械振动基频为 25Hz。

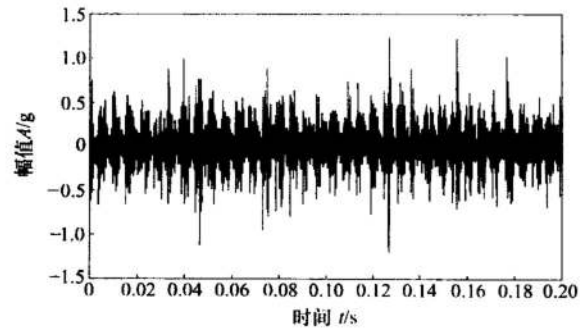

图 5-30　液压泵正常工作状态的时域波形

2. 液压泵实验数据分析

图 5-30 为在系统调定压力 10MPa，采样频率为 20kHz，液压泵正常状态下 0.2s 的振动加速度波形，数据点数为 4000 点。图 5-31 是图 5-30 对应 0～2000Hz 范围内的功率谱图。从图 5-31 可看出，直接对信号进行功率谱分析存在较多的低频干扰，不易提取其故障频率信息。

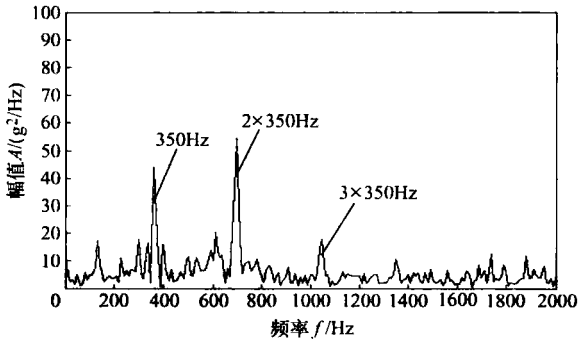

图 5-31 液压泵正常信号的功率谱

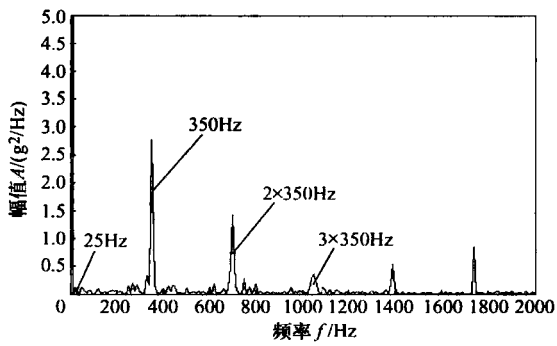

图 5-32 基于小波簇包络分析的正常信号包络功率谱

基于小波簇包络分析原理，在 0～2000Hz 范围内对其进行小波簇滤波包络分析，小波簇参数为：$a=0.2$，$N=2000$，$f_L=0\text{Hz}$，$\Delta f=1\text{Hz}$，则有 $f_H=2000\text{Hz}$。图 5-32 所示为正常信号的包络功率谱，图中明显地突出了轴向柱塞泵正常工作条件下的频率成分 350Hz 及其倍频。

图 5-33 为相同试验条件下存在故障时的振动加速度波形，图 5-34 为对应的功率谱图，图 5-35 所示为 0-1000Hz 低频段功率谱图。根据振动信号分析的幅值域分析方法，对比图 5-30 以及图 5-33 明显可知液压泵确实出现了故障。若要对故障形式进行判断，需进一步分析。

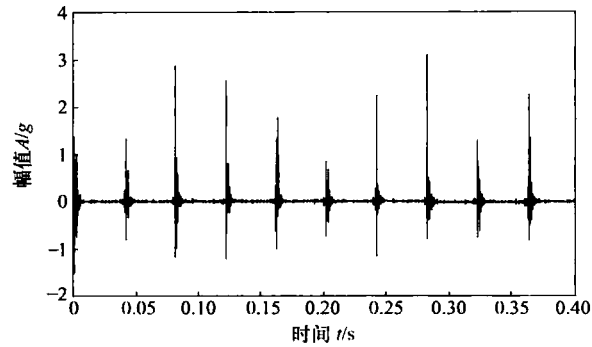

图 5-33　液压泵故障信号的时域波形

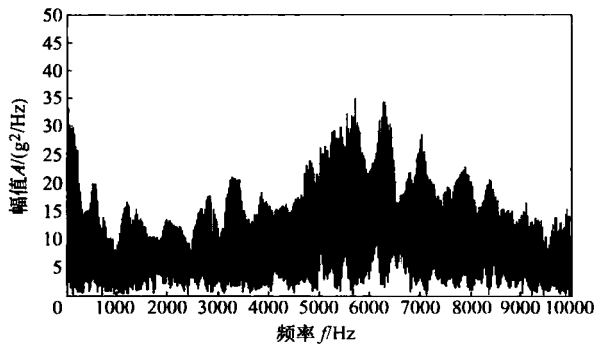

图 5-34　液压泵故障信号的功率谱

根据图 5-34 可知高频共振峰值大约是 6000Hz，因此所需要的带通滤波器通带范围为 5 ~ 7kHz。基于小波簇包络分析原理，选择小波簇参数：$a=0.2$，$N=2000$，$f_L=5000\text{Hz}$，$\Delta f=1\text{Hz}$，因此有 $f_H=7000\text{Hz}$。根据以上参数构造了 5 ~ 7kHz 的平顶带通滤波器，其频率特性如图 5-36 所示。

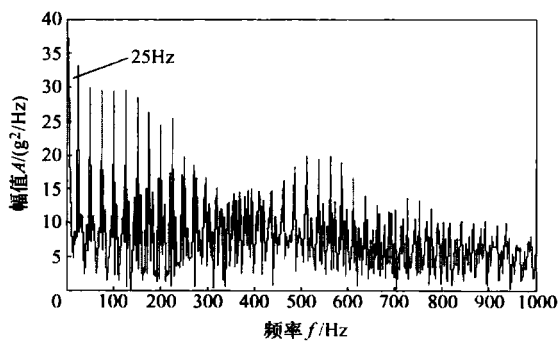

图 5-35　液压泵故障信号的低频段功率谱

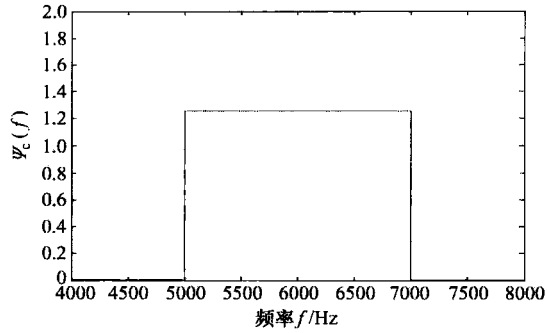

图 5-36 小波簇带通滤波器频率特性

图 5-37 是在 5 ~7kHz 范围内应用小波簇带通滤波器滤波解调得到的故障信号包络功率谱，与图 5-32 正常信号的包络功率谱进行对比，两者频率成分完全不同，由此可判断轴向柱塞泵发生了故障。对比图 5-35，故障特征频率及其谐波频率更清晰且特征频率为 25Hz 及其倍频，因此可判断故障形式为一脱靴故障。显然本章基于小波簇的包络解调方法比传统的功率谱分析在故障特征频率识别方面具有明显优势。

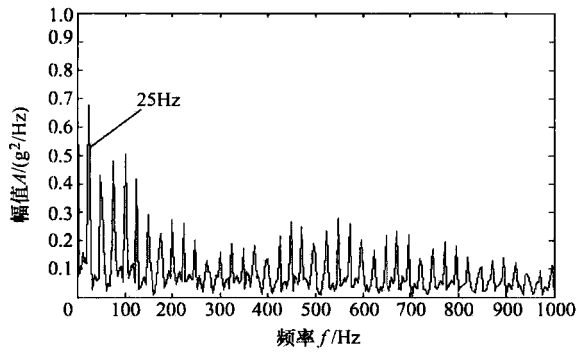

图 5-37 基于小波簇包络分析的故障信号包络功率谱

参 考 文 献

[1] Zhou Feng-xing. Falut Diagnosis Technology Based on Wavelet Analysis and Resonance Demodulation [C]//Fifth World Congress on Intelligent Control and Automation,2004 (7): 15-19, Hangzhou, China.

[2] 丁康，李巍华，朱小勇．齿轮及齿轮箱故障诊断实用技术［M］．北京：机械工业出版社，2006.

[3] 周凤星．机械设备振动信息的共振解调技术与小波分析［J］．武汉科技大学学报，2001，3

(1)：66-67.
[4] 陈新轩，许安主．工程机械状态检测与故障诊断［M］．北京：人民交通出版社，2004.
[5] 何正嘉，赵纪元，高强，等．机械设备非平稳信号的故障诊断原理及应用［M］．北京：高等教育出版社，2001.
[6] 卢文祥，杜润生．工程测试与信息处理［M］．武汉：华中理工大学出版社，1994.
[7] 张来斌，王朝晖，张喜廷．机械设备故障诊断技术及方法［M］．北京：石油工业出版社，2000.
[8] 李建平．小波分析信息传输基础［M］．北京：国防工业出版社，2004.
[9] C Karanikas. The Hausdorff Dimension of Very Weak Self-similar Fractals Described by the Haar Wavelet System［J］. Chaos, Solitons and Fractals, 2000 (11)：275-280.
[10] 杨建国．小波分析及其工程应用［M］．北京：机械工业出版社，2005.
[11] 魏明果．实用小波分析［M］．北京：机械工业出版社，2005.
[12] 胡昌华．基于MATLAB的系统分析与设计——小波分析［M］．西安：西安电子科学技术大学出版社，1999.
[13] 飞思科技产品研发中心．MATLAB6.5小波分析［M］．北京：电子工业出版社，2003.
[14] Arnord J. Mandell, Karen A Selz, Michael F. Shlesinger. Wavelet Transformation of Protein Hydrophobicity Sequences Suggests Their Memberships in Structural Families［J］. Physica, A, 1997 (220)：254-262.
[15] 马建仓，罗磊．基于小波变换的包络分析［J］．西北工业大学学报，1997，15（2）：247-253.
[16] 宋丽娜．小波解调方法在泵类旋转机械故障诊断中的应用研究［D］．秦皇岛：燕山大学，2008：62-78.
[17] 王化祥，张淑英．传感器原理及应用［M］．天津：天津大学出版社，2006.
[18] Jiang W（姜万录），Spurgeon S K, Twiddle J A, et al. A Wavelet Cluster-based Band-pass Filtering and Envelope Demodulation Approach with Application to Fault Diagnosis in a Dry Vacuum Pump［J］. Journal of Mechanical Engineering Science, 2007, 221 (11)：1279-1286.
[19] 姜万录，宋丽娜，杨少辉，等．小波包络新方法在液压泵故障诊断中的应用［J］．测控技术，2008，27（8）：24-27.
[20] Jiang Wanlu（姜万录），Sarah K Spurgeon, John A, et al. Wavelet Cluster based Envelope Demodulation Approach and its Application to Fault Diagnosis［J］．仪器仪表学报，2007，28（6）：973-979.
[21] Wanlu Jiang（姜万录），Sarah K Spurgeon, John A, et al. A Novel Wavelet Cluster-based Envelop Demodulation Approach with Application to Fault Diagnosis［C］. Proceedings of 5th International Symposium on Fluid Power Transmission and Control（ISFP' 2007），June 6-8，2007，Beidaihe，China：1021-1027.

第 6 章　混沌分形理论在故障诊断中的应用

本章利用混沌分形理论，对液压泵的故障诊断问题进行研究。通过对采集的液压泵出口压力信号进行关联维数分析发现，故障压力信号的关联维数低于正常信号的关联维数，可以作为故障是否发生的定量判据。

6.1　混沌及分形

混沌与分形理论成为近年来非线性科学中的研究热点。混沌是联系确定性与随机性的桥梁与纽带，对确定性与随机性之间的第三种状态给了一个很好的解释。对于一个系统而言，确定论认为系统是可知的，对系统预测的结果是确定的；而随机论认为，系统由于动力过程的内在随机性，预测结果是不确定的，只能借助统计学的方法进行预测；混沌动力学则认为，虽然系统是确定的，但就预测而言，在长期看来具有不可知性、不确定性，而在一个小范围内，系统是可知的、确定的。

6.1.1　混沌的特征

混沌运动是确定性非线性动力系统特有的复杂运动形态，出现在某些耗散系统、不可积 Hamilton 保守系统和非线性离散映射系统中。混沌运动是一种不稳定的有限定常运动，即为全局收缩和局部不稳定的运动，或除了平衡、周期和准周期以外的有限定常运动。混沌运动还具有通常确定性运动所没有的几何特征和统计特征，如局部不稳定而整体稳定、连续的功率谱、无限自相似、分维数、奇异吸引子、正的 Lyapunov 指数、正的测度熵等。与其他复杂现象相比，一般认为混沌应具有以下几方面的主要特征，且它们之间有着密切的内在联系：

（1）内随机性　单一频率的输入产生具有连续功率谱的输出，这种遍历性不是由随机性外因引起的，而是由确定性方程（内因）直接得到的。一定条件下，如果系统的某个状态可能出现，也可能不出现，该系统便被认为具有随机性。

（2）整体稳定而局部不稳定　混沌运动是有界的，它的运动轨迹始终局限在一个确定的区域，这个区域称为混沌吸引域。无论混沌系统内部多么不稳定，它的轨线都不会走出混沌吸引域，所以从整体来说混沌系统是稳定的。这意味着混沌运动具有 Lyapunov 意义下的稳定性。所谓局部不稳定性是指系统运动的某些维度上的行为强烈地依赖于初始条件。

（3）对初值的敏感依赖性　初值有微小的变化，经过相当长的时间后，运动

则可能相差甚远。随着时间的推移，任意靠近的各个初始条件将表现出各自独立的时间演化进程，即存在对初始条件的敏感依赖性，如著名的“蝴蝶效应”。表6-1中的Logistic映射可说明这一点。

表6-1　Logistic映射对初值的敏感依赖性

x_n的下标 n	$x_{n+1}=4x_n(1-x_n)$		
1	0.20000000000000	0.20000010000000	0.20000020000000
2	0.64000000000000	0.64000023999996	0.64000047999984
3	0.92160000000000	0.92159973119981	0.92159946239926
…	…	…	…
18	0.06174480848049	0.06986564006485	0.07844828185147
19	0.23172954842480	0.25993772961272	0.28917659570409
20	0.71212385924655	0.76948042534602	0.82221396880433
21	0.82001387335340	0.70952120142131	0.58471263322945
22	0.59036448344542	0.82440346461988	0.97129507908533
23	0.96733704052657	0.57904956857048	0.11152379371981
…	…	…	…

由上表可以看出，迭代次数在19以内时，不同初值的迭代结果还十分接近，此时为短期可预测性。到第20次时，x_{20}的三组值相差很大，以后很难预测x_n（$n>20$）的值，此时为长期不可预测性。所以，初始值的微小波动0.2、0.2000001和0.2000002，就可以使得序列表现出随机特性，此即为对初值的敏感依赖性。

（4）遍历性　混沌运动在混沌吸引域内是各态历经的，即在有限时间内混沌轨道遍历混沌区内的每一个状态点，而又不会逗留在某一状态点上。

（5）轨道不稳定性及分岔　长时间动力学运动的类型在某个参数（或某组参数）发生变化时也随之发生变化。这个参数值（或这组参数值）称作分岔点。在分岔点处参数的微小变化会产生不同定性性质的动力学特性，所以系统在分岔点处是结构不稳定的。

（6）奇异吸引子及其分维性　耗散系统的有效相体积在演化过程中将不断收缩至有限范围内（吸引子），耗散是一种整体性稳定因素，而轨道又是不稳定的，这就使它在相空间的形状不断拉伸、扭曲和折叠，形成具有精细的无穷嵌套的自相似结构（分形）。混沌吸引子具有分维性质。常见的混沌吸引子有Chen's吸引子、Lorenz吸引子、Rossler吸引子、Henon映射等，这些吸引子体现了混沌的各种特征，被广泛研究和应用。

（7）普适性　在混沌的转变中会出现某种标度不变性，代替通常的空间或时间周期性。所谓普适性，是指在趋向混沌时所表现出来的共同特性，它不依具体的

系统运动方程和具体的方程系数而变。普适性是混沌内在规律性的一种体现。

6.1.2 分形理论

为了描述自然界中大量存在的诸如曲折的海岸线、粗糙的地表这些过去被人们认为是“不可名状的”或“病态的”几何物体，1975 年，法国数学家 B. B. Mandelbrot 提出了分形（Fractal）这个术语，并创立了分形几何学。分形几何是用于解决具有自相似现象的理论，是非线性学科的一个重要分支，已被广泛地应用于许多领域。

混沌轨道在相空间内由于无限次的拉伸、压缩和折叠，构成了无穷嵌套的自相似结构，形成混沌吸引子。定量描述吸引子混沌特性的主要手段是分形维数和李雅普诺夫指数。分形维数是定量刻画混沌吸引子奇异程度的一个十分重要的参数，它被广泛地应用于非线性系统行为的刻画中。绝大多数奇异吸引子具有分维数（非整数维），它是识别混沌、定量地表征奇异吸引子这种具有自相似结构特征的指标之一。

常见的分维数的定义有：容积维数、Hausdorff 维数、盒子维数、相似维数、信息维数、关联维数等。典型的分形有：Cantor 三分集、Koch 曲线、Koch 雪花、Sierpinski 垫、Sierpinski 地毯、Sierpinski 海绵、Mandelbrot 集、Julia 集等。图 6-1 为根据 Mandelbrot 混沌方程绘制的分形图。

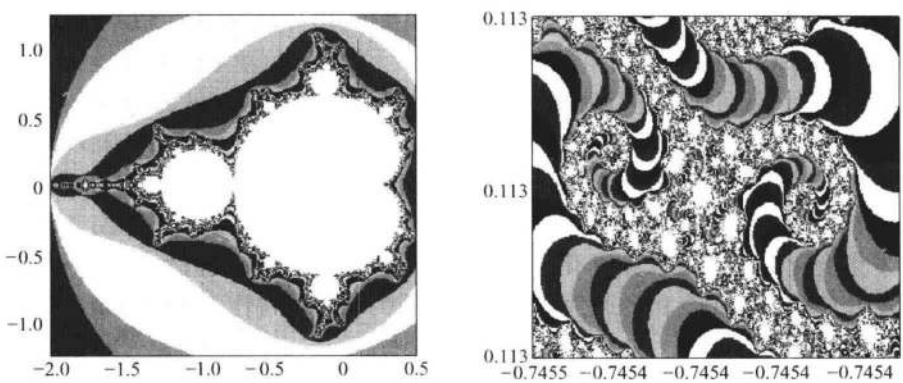

图 6-1 Mandelbrot 集

a）龟图 b）虎尾图

在自然界中，远离平衡的系统、开放的系统、过程不可逆的系统、非线性相互作用的系统、具有涨落和破缺的系统，可能出现混沌分形现象。由于纯粹的混沌和随机都是理想化的极限，在不少实际时间序列中，既有确定性成分，也有随机成分，周期运动、噪声与混沌往往并存。要绝对区别时间序列是确定性的，还是随机

性的，周期的、拟周期的，还是混沌的，有一定困难。时间序列性质的辨识或混沌性识别，主要指从统计意义上在某一置信度下判断时间序列究竟以何种运动为主。对于实际观测的时间序列，往往首先要经过降噪处理。

6.2　关联维数分析

6.2.1　关联维数分析方法

在众多的分维数定义中，关联维数是一种由观测得到的时间序列计算相应动力系统吸引子的方法。关联维数便于从实验数据中直接计算，因而其工程应用十分广泛。

1. 关联维数的定义

关联维（Correlation Dimension）也称相关维，它表示系统在多维空间中的疏密程度，反映系统点与点之间的关联程度，是描述系统的特征量。可用来刻画重构的 m 维（嵌入维）相空间的混沌吸引子的分形复杂性。

一个动力系统处于多自由度空间中，其运动特性是由多变量所决定的。而在实际的物理系统中测量到的往往是单变量。在实际工程问题中，有时只能通过分析实测的一维时间序列数据间接了解非线性动力学系统。为了能够从一维时间序列中得到动力系统相空间的几何结构，Packard 等人采用时间延迟技术重构相空间。Takens 证明该重构系统与原始系统是等价的。由 Takens 重构定理可知，一个动力系统在演化过程中其各个分量之间存在内在的联系，系统中任一分量的演化都是由其他分量相互作用所决定的，任一分量的演化过程中也就隐含了系统其他分量的演化信息。

1983 年，Grassberger 和 Procaccia 根据嵌入理论和重构相空间思想，提出了从时间序列直接计算关联维数 D_2 的算法，即 G-P 算法。

长度为 N 的序列用时延法可以构成长度为 N_m、维数为 m 的相空间。重构相空间的维数 m 称为嵌入维数。设原始信号时间序列为 $\{x_1, x_2, \cdots, x_N\}$，重构的伪相空间轨道为

$$X_i = (x_i, x_{i+\tau}, x_{i+2\tau}, \cdots, x_{i+(m-1)\tau})^{\mathrm{T}} \tag{6-1}$$

其中，τ 是时间延迟；$i = 1, 2, 3, \cdots, N_m$。$N_m = N - (m-1)\tau$ 是重构相空间中向轨迹的长度。吸引子关联维数由下列相关积分导出

$$C(r) = \frac{1}{N_m^2} \sum_{i=1}^{N_m} \sum_{j=1}^{N_m} H(r - \|X_i - X_j\|) \tag{6-2}$$

式中，$i \neq j$，$C(r)$ 为信号的相关积分（关联函数）。$H(x)$ 为 Heaviside 函数，当 $x \geqslant 0$ 时 $H(x) = 1$，当 $x < 0$ 时 $H(x) = 0$；r 为相空间中超球半径。$\|X_i - X_j\|$ 为两矢量

间的范数（欧氏距离），定义为

$$\|X_i - X_j\| = \left[\sum_{l=0}^{m-1}(x_{i+l\tau} - x_{j+l\tau})^2\right]^{1/2} \tag{6-3}$$

相关积分 $C(r)$ 含义是嵌入空间中距离小于或等于 r 的向量对出现的概率。且有

$$C(r) \propto r^{D_2}, \text{ 当 } r \to 0 \tag{6-4}$$

式中 D_2 即为关联维数，D_2 可由式（6-5）求出

$$D_2 = \lim_{r \to 0}[\ln C(r)/\ln r] \tag{6-5}$$

可作为区分混沌和其他运动形式的主要依据之一。

曲线 $\ln r$-$\ln C(r)$ 在 $r \to 0$ 时的渐近线是直线，其斜率就是 D_2。在实际计算中，因为时间抽样率有限，要使 $r \to 0$ 是有困难的。在实践中多采用多点直线拟合来计算 D_2。具体过程是利用，取 M 个较小的 r 值，计算 $x_i = \ln r$、$y_i = \ln C(r)$，然后由 M 个点（x_i，y_i）按最小二乘法拟合出一条直线 $\hat{y} = kx + b$，此直线的斜率 k 即为 D_2 的估算值。残差的平方和为

$$E = \sum_{i=1}^{M}(kx_i + b - y_i)^2 \tag{6-6}$$

令 $\partial E/\partial k = 0$，$\partial E/\partial b = 0$，可解得：

$$D_2 = k = \frac{\left(\sum_{i=1}^{M} x_i y_i\right) - \frac{1}{M}\left(\sum_{i=1}^{M} y_i\right)\left(\sum_{i=1}^{M} x_i\right)}{\sum_{i=1}^{M} x_i^2 - \frac{1}{M}\left(\sum_{i=1}^{M} x_i\right)^2} \tag{6-7}$$

2. 数据长度 N 的选取

N 的取值应考虑信号的类别及采样频率。从理论上讲，采样的时间序列长度越大，所计算的关联维数就越精确。但实际测量中受各种条件的限制，只能获取有限长度的数据，而且长的数据需要较长的计算时间。要保证关联维数计算的精确性还必须有最小的数据长度要求。据文献介绍，在估计离散时间信号的分维值时，序列长度应取为大于 500，且 N 的选取与使用方法、信号模型、信号的真实 Hurst 指数以及信噪比等有关。

3. 延时 τ 的选取

对无限数量的无噪声数据，τ 的选择的原则上不重要，但对于实际的数据，在相空间重构过程中选择恰当的 τ 值很关键。如果 τ 太小，每个坐标相关性太强，导致信息的冗余，失去独立性，而且相空间中轨迹沿同一地方挤压，使得特征信息不易展现。如果 τ 太大，将使延迟坐标之间毫不相关，使数据之间失去原动力系统的本质固有联系，不能代表真实的动力系统。

对时间 τ 的选择，通常有如下的几种方法：

（1）主周期关系　对于低维系统，如果受周期变化的外力或自激励周期力的作用，那么 τ 的最佳值为主周期的四分之一。但对于大多数复杂系统来说，它们不仅只包含一个占支配地位的振动频率。

（2）最小交互信息标准　交互信息函数如下

$$M = \sum_{i=1}^{N-(m-1)\tau} P(x_i, x_{i+\tau}, x_{i+2\tau}, \cdots x_{i+(m-1)\tau}) \lg\left[\frac{P(x_i, x_{i+\tau}, x_{i+2\tau}, \cdots, x_{i+(m-1)\tau})}{P(x_i)P(x_{i+\tau})P(x_{i+2\tau})\cdots P(x_{i+(m-1)\tau})}\right] \tag{6-8}$$

式中，$P(x_i)$ 是时间序列变量 x_i 发生的概率，$P(x_i, x_{i+\tau}, x_{i+2\tau}, \cdots, x_{i+(m-1)\tau})$ 为吸引子的正交变量 $(x_i, x_{i+\tau}, x_{i+2\tau}, \cdots, x_{i+(m-1)\tau})$ 发生的联合概率，M 为相空间重构变量之间统计依赖关系的一个量度。取交互信息函数的第一个最小值所对应的 τ 值作为相空间重构延迟时间。

（3）自相关函数　基于自相关函数的方法比较简单，并且易于计算。自相关函数提供了信号自身 $x(t)$ 与它的时延 $x(t+\tau)$ 之间相似性的度量。当 $\tau=0$ 时，$R_{xx}(\tau)$ 为最大。自相关函数能够合理地提供由冗余到不相关的比较折中的度量。对于时间延迟为 τ 的离散时间序列，其自相关系数可以表示为

$$\rho_{xx}(\tau) = \frac{\sum_{i=1}^{N-\tau}(x_i')(x_{i+\tau}')}{\sum_{i=1}^{N-\tau}(x_i')^2} \tag{6-9}$$

式中，$x_i' = x_i - \bar{x}$，$\bar{x}$ 为时间序列的平均值。大量研究表明，根据以下原则之一选择 τ 值：$R_{xx}(\tau)$ 的值降到初始值的 1/e；$R_{xx}(\tau)$ 第一次为 0；$R_{xx}(\tau)$ 的第一个拐点。

4. 嵌入维数的选取

正确选取嵌入维数是极其重要的。在一般情况下，由于缺乏对系统动力维数的先验知识，选择嵌入维数 m 比较困难。Takens 原理提供了 m 的下限，嵌入维数 $m \geqslant 2d+1$，其中 d 为吸引子的真实维数。

应尽量选择大的嵌入维数，因为 m 选的太小，动力系统的几何结构不能完全打开。而嵌入维数过大又降低了计算的可靠性，因此嵌入维数也不能选择太大。

现有的许多选择 m 的方法，如关联指数饱和法、奇异值分解法、伪邻近法、映象距离法等，各有利弊。本章实验部分采用花费些计算量但比较可靠的方法，即逐渐增大嵌入维数，直至关联维数的值不再变化，此时的 m 即为最小的嵌入维数。

对于确定性系统，一般都收敛到低维的相空间，相关维数不随嵌入维数的增加而增加，而噪声信号没有收敛的相关维数。可以由此区分信号是确定性动力系统产生的，还是随机系统产生的。

5. 超球半径的选取

对于具体的研究对象，超球半径 r 的取值范围首先应满足如下条件

$$l_{\min} \leqslant r \leqslant l_{\max} \tag{6-10}$$

式中，$l_{\min}=\min(d_{ij})$，$l_{\max}=\max(d_{ij})$，$(i, j=1, 2, \cdots, N_m, i \neq j)$，其中 d_{ij} 为重构相空间中两向量间范数（欧氏距离）。

6.2.2 几种典型信号的关联维数

下面应用 G-P 算法计算正弦信号、混沌信号、随机信号这三种不同运动形态信号的关联维数，观察其计算结果的不同之处。

正弦信号关联积分及局部斜率如图 6-2 所示。图中 r/r_0 为归一化的超球半径。由局部斜率图可以看出，局部斜率有明显的水平区域。由最小二乘法拟合该水平区域内局部斜率的值，得到整数 1。正弦信号为周期运动，关联维数为整数 1。

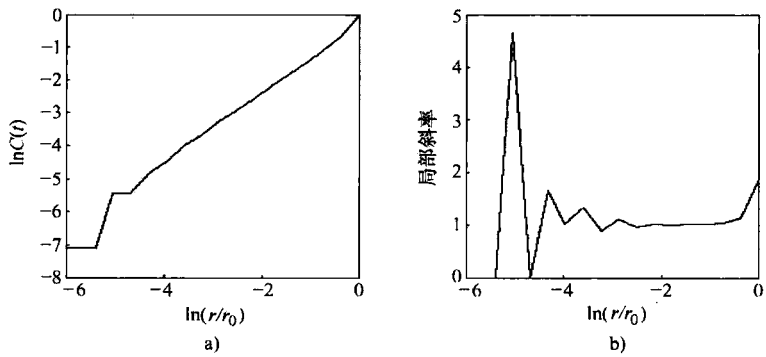

图 6-2 正弦信号的关联积分及局部斜率

a）关联积分 b）局部斜率

杜芬（Duffing）振子信号关联积分及局部斜率如图 6-3 所示。图中信号所用杜芬振子的形式为

$$\ddot{x} + a\dot{x} - bx + cx^3 = f\cos \omega t \tag{6-11}$$

式（6-11）中，取 $a=0.3\text{N}\cdot\text{s/m}$，$b=1\text{N/m}$，$c=1\text{N/m}^3$，外控力振幅 $f=0.32\text{N}$，外控力角速度 $\omega=1.2\text{rad/s}$，在此组参数下，杜芬振子系统处于混沌运动状态。杜芬振子混沌运动信号应用四阶龙格-库塔法由 MATLAB 编程产生。选取局部斜率较为平滑的一段，用最小二乘法拟合直线，得到杜芬振子的关联维数为 1.2。

随机信号的关联积分及局部斜率如图 6-4 所示。随机信号由 MATLAB 中的 rand 函数产生。由图 6-4 可见，局部斜率没有水平区域，不具备无标度区，所以随机信号没有收敛的相关维数。

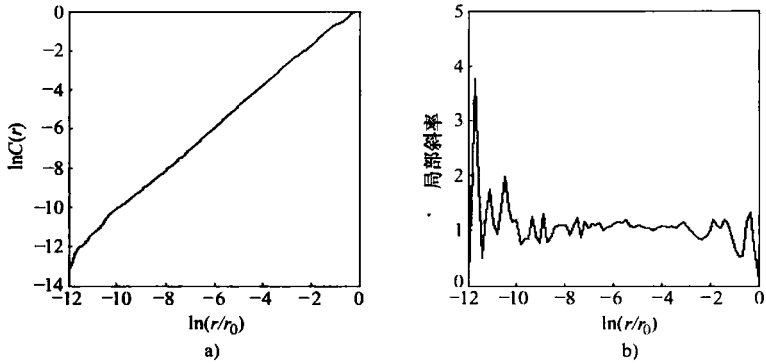

a)　b)

图 6-3　杜芬信号关联积分及局部斜率

a）关联积分　b）局部斜率

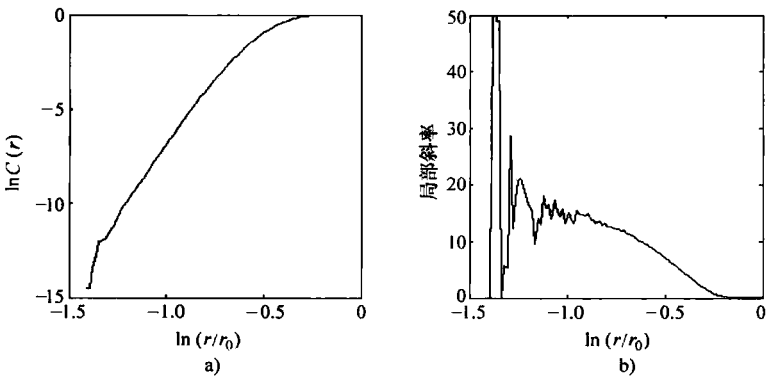

a)　b)

图 6-4　随机信号关联积分及局部斜率

a）关联积分　b）局部斜率

6.3　基于分形理论的液压泵故障诊断的实验研究

本节对轴向柱塞泵出口压力信号进行采集，对柱塞泵正常运转和单柱塞脱靴故障状态的泵出口压力信号进行关联维数计算分析。

6.3.1　实验条件

在轴向柱塞泵的诸多失效形式中，脱靴故障是其主要故障形式之一。本文对某台材料实验机液压伺服系统中的液压泵进行状态监测与故障诊断，材料实验机的整体如图 6-5 所示。采用破坏性实验，将斜轴式柱塞泵的七柱塞中的一个脱靴处理。利用压力传感器对轴向柱塞泵出口压力进行监测。传感器输出信号经虚拟仪器 NI-

DAQ 卡进行采集，并送计算机进行分析处理。本系统的数据采集与处理采用了虚拟仪器平台软件 LabVIEW。

实验数据是用液压泵在正常工作和发生单柱塞脱靴故障时，采集到的液压泵出口压力脉动数据。电动机工作转速为 1 500r/min，采样频率选为 10kHz。轴向柱塞泵型号及参数为：MCY14-B，7 柱塞，理论排量 10ml/r，公称压力 25MPa，驱动电动机 Y132M-4，额定转速 1 500r/min。系统压力调定为 3MPa。

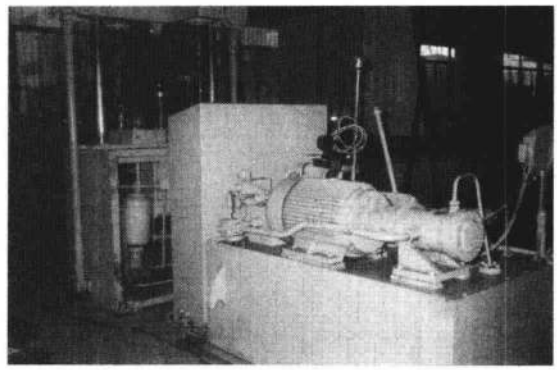

图 6-5 材料实验机

图 6-6 分别为液压泵在正常工作状态和脱靴故障状态下的时域曲线。由图中可以看出，故障状态下的压力信号脉动周期明显大于正常压力信号的脉动周期。下面从关联维数的角度比较两者信号有何不同，计算关联维数之前首先要进行信号的小波消噪预处理。

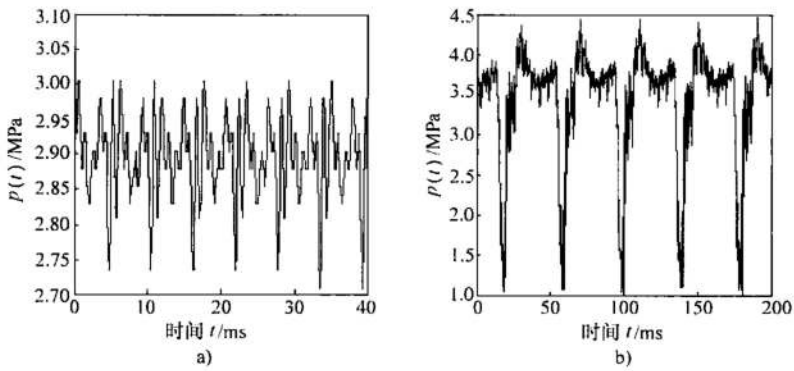

图 6-6 泵出口压力信号

a）正常压力信号 b）故障压力信号

6.3.2 信号的小波消噪与特征提取

泵压力信号的信噪比低、冲击信号丰富，具有非平稳性。需要对其进行小波消噪处理，减少噪声的影响，提取故障特征频率。

为了分析信号的运行频率特征，下面对消噪后的信号进行分解。图 6-7 为正常压力信号的小波分解，小波系数单位均为 MPa。s1 为消噪后的信号，分解层次为 10 层，分解的小波函数采样 Daubechies 5 级小波。

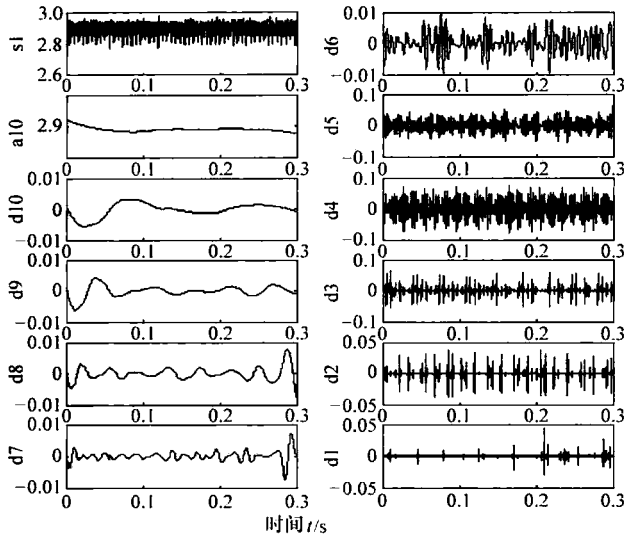

图 6-7　正常压力信号的小波分解

由于该系统柱塞泵的柱塞数为 7，转轴频率为 1 500/60Hz = 25Hz，理论流量脉动频率为转轴频率的 14 倍，即为 350Hz。由小波分解可以看到，在 d8 频段，显示的是泵的基频，在 d4 频段，显示的是泵的流量脉动。经过去噪后的正常压力信号 s1 的脉动频率与理论流量脉动频率相同。

为了对故障信号的突变点进行定位，并提取故障特征频率，下面对故障信号消噪后的信号 s1 进行分解，分解层次为 10 层，分解的小波函数仍采样 Daubechies 5 级小波。图 6-8 为故障信号的分解结果，小波系数单位均为 MPa。由于单柱塞脱靴的影响，泵每转一周，有一次压力突降，造成泵每转一周有一次冲击振动，即单柱塞脱靴故障特征信号为 25Hz。d8 中提取了故障特征频率 25Hz，而 d4 中提取了系统运行信息即流量脉动频率 350Hz。实验结果与理论分析一致。

6.3.3　关联维数计算

为了得到液压泵正常工作状态和发生脱靴故障后信号变化的定量化信息，应用 G-P 算法，分别计算两种状态下信号的关联维数数值。

对于延时 τ 的选取，由于基于自相关函数的方法比较简单，易于计算，并能合理地提供由冗余到不相关的比较折中的度量，故仍采用自相关函数法取得延时 τ 的数值。取经过小波去噪后的长度为 3 000 的信号，应用 MATLAB 软件编制程序，绘制延时 τ 与自相关函数 $R(\tau)$ 关系曲线，取自相关函数第一次为零时的 τ 值作为延时值。图 6-9 为 3MPa 压力下的泵正常和故障状态下压力信号的自相关函数曲线。通过改变 MATLAB 图形显示坐标范围，可以得到正常状态和故障状态的自相关函

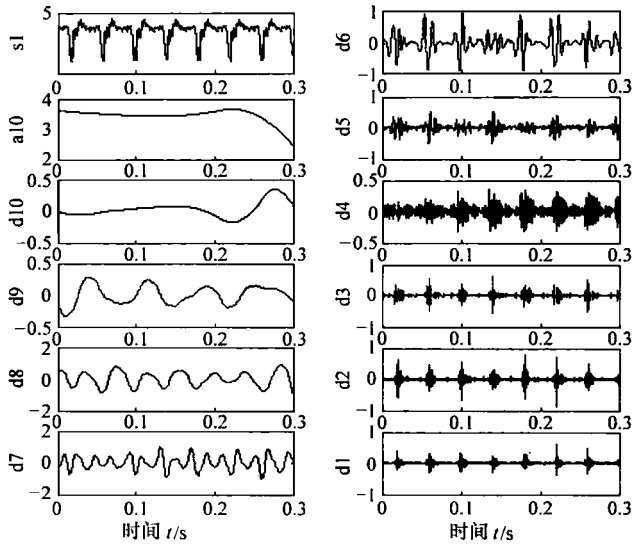

图 6-8 故障压力信号的小波分解

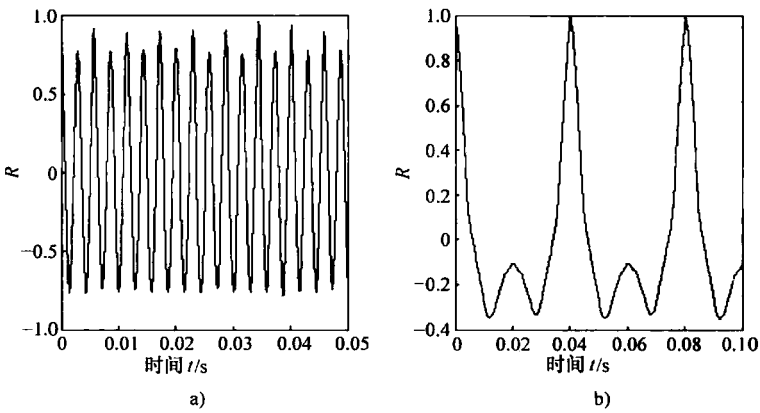

图 6-9 压力信号自相关函数

a）正常压力信号 b）故障压力信号

数第一过零点延迟时间分别为 0.7ms 和 6.1ms。

编写 MATLAB 程序，通过不断增大嵌入维数，得到收敛的关联维数。在饱和嵌入维数为 15 时，得到 3MPa 压力下，液压泵正常工作状态压力信号的关联积分和局部斜率曲线如图 6-10 所示。同样，3MPa 压力下，饱和嵌入维数为 14 时故障状态压力信号的关联积分和局部斜率曲线如图 6-11 所示。

对正常状态和故障状态的局部斜率曲线中平滑的部分进行最小二乘法拟合直线

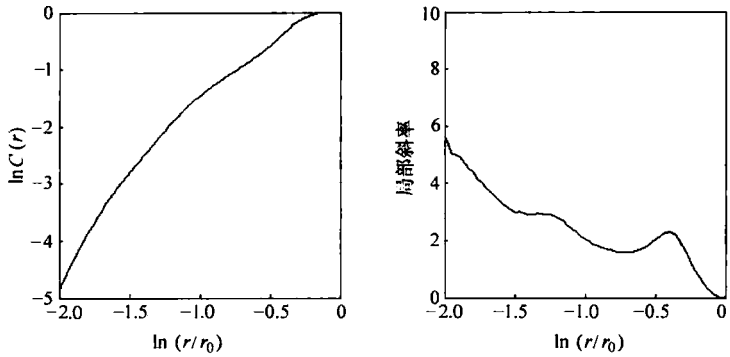

图 6-10　正常状态下关联积分及局部斜率

a）关联积分　b）局部斜率

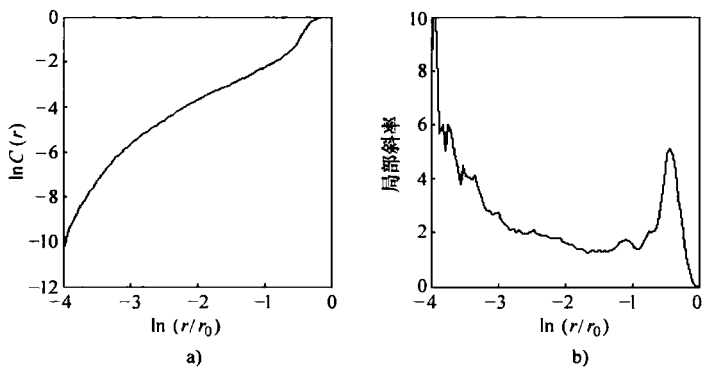

图 6-11　故障状态下关联积分及局部斜率

a）关联积分　b）局部斜率

斜率，得到相应的关联维数。表 6-2 为液压泵正常工作和发生脱靴故障时在不同嵌入维数时关联维数的计算结果。

表 6-2　嵌入维数及关联维数值

嵌入维数	11	12	13	14	15	16	17	18	19	20
正常关联维数	1.42	1.57	1.61	1.65	1.68	1.67	1.66	1.68	1.67	1.66
故障关联维数	1.07	1.23	1.32	1.35	1.34	1.35	1.34	1.35	1.33	1.35

由表 6-2 可以看出正常和故障状态下的饱和嵌入维数分别为 15 和 14。表 6-3 为液压泵正常工作状态和发生脱靴故障状态下的关联维数计算值及其重构参数。

表 6-3 重构参数及维数值

状 态	饱和嵌入维数 m	延迟时间 τ/ms	数据长度 N	饱和关联维数 D_2
正常	15	0.7	3 000	1.68
故障	14	6.1	3 000	1.35

6.3.4 结果分析

由表 6-3 可以看出，故障工作状态下的压力信号的关联维数小于正常状态的关联维数。当柱塞泵发生脱靴故障时，由于单柱塞脱靴的影响，泵每转一周，有一次压力突降，造成泵每转一周有一次冲击振动。压力脉动信号将在相空间趋于某一有限维吸引子，计算得到的关联维数将小于正常状态下的关联维数。分维数计算结果与实验结果分析相一致。

液压泵在不同工作状态下有明显不同的关联维数，通过利用压力信号的关联维数可以有效地监测液压泵的工作状态，诊断故障的发生。将混沌及分形理论用于监测液压设备的工作状态，这方面的深入研究可以为液压设备的工作状态监测拓展思路，有助于提高监测的质量。

参 考 文 献

[1] 赵吉文，孔凡让，谢峰，等．机械动态系统混沌状态特征与判据应用研究［J］．运筹与管理，2003，12（4）：76-80.

[2] G Shukovich. Application of Genetic Algorithms and Systems of Generating Graphs for Creation of Modular Neural Networks［J］. Programming and Computer Software，2002，28（1）：9-14.

[3] Alf Jonsson，Anna Kamont. Piecewise Linear Bases and Besov Spaces on Fractal Sets［J］. Analysis Mathematica，2001（27）：77-117.

[4] Yuan Y. Tang，Yu Tao，et al. New Method for Feature Extraction Based on Fractal Behavior［J］. Pattern Recognition，2002，（35）：1071-1081.

[5] Ronald Marsh. FractalNet A Biologically Inspired Neural Network Approach to Fractal Geometry［J］. Pattern Recognition Letters，2003，（24）：1881-1887.

[6] Grassberger P，Procaccia I. Characterization of Strange Attractors［J］. Phys Revlett，1983（50）：346-349.

[7] Grassberger P，Procaccia I. Measuring the Strangenss of Strange Attractors［J］. Physica D，1983（9）：189-208.

[8] 丁庆海．混沌、分形和小波理论在被动声信号特征提取中的应用［J］．声学学报，1999，24（2）：197-203.

[9] 谢文录，谢维信．几种分形参数估计方法的性能分析和比较［J］．西安电子科技大学学报，1997，24（2）：172-179.

[10] Lai Y C，Lerner D. Effective Scaling Regime for Computing the Correlation Dimension from Chaotic

Time Series［J］. Physica D, 1998,（115）: 1-18.

［11］盛昭瀚，马军海. 管理科学：面对复杂性Ⅲ——经济时序动力系统最佳时序采样间隔分析研究［J］. 管理科学学报，2000，3（1）：100-104.

［12］应怀樵. 虚拟仪器与 PC 技术的现状与发展［J］. 计算机自动测量与控制，2000，8（2）：1-2.

［13］陈东宁. 分形及小波分析在液压泵故障诊断中的应用研究［D］. 秦皇岛：燕山大学. 2004：42-63.

［14］姜万录，张淑清，王益群. 基于混沌和小波的故障信息诊断［M］. 北京：国防工业出版社，2005.

［15］姜万录，陈东宁，姚成玉. 关联维数分析方法及其在液压泵故障诊断中的应用［J］. 传感技术学报，2004，17（1）：62-65.

第 7 章　基于 Lyapunov 指数分析的故障诊断方法

本章介绍 Lyapunov 指数的计算方法（QR 分解法），并计算杜芬方程混沌系统的最大 Lyapunov 指数。提出一种基于最大 Lyapunov 指数分析的故障诊断方法，通过对泵出口压力信号最大 Lyapunov 指数的计算结果作为判断系统是否发生故障的依据。

7.1　混沌运动及 Lyapunov 指数

7.1.1　混沌判别方法

利用混沌系统检测微弱信号的前提是确定该系统是混沌的，这就涉及混沌判别的问题。又由于微弱信号混沌检测的主要依据是系统状态的变化，检测的主要问题是对系统是否处于混沌态进行判别，因此混沌判别问题成为微弱信号混沌检测中的一个重要内容。

尽管混沌有不同的定义，但是根据混沌的定义来判别混沌会有诸多不便。所以，从混沌理论出现以来，便有许多学者致力于研究混沌的判别方法。由于混沌状态的高度复杂性，利用解析的方法来判别是比较困难的。到目前为止，还不存在一个普适性的混沌判别方法。随着计算机技术和数字信号处理技术的飞速发展，使得人们在研究混沌判别问题时，通常采用数值计算方法。目前，混沌判别方法大体上可以分为两类：

第一类：直观方法。所谓直观方法，就是仅通过对被分析信号的时域或频域特征曲线的观察，直观地确定混沌存在与否。该类方法是基于从理论上对混沌的认识，采用实验的手段来观察混沌现象，故相对简单、直观，不需复杂的计算。这类方法包括时间历程法、相轨迹图法、频闪采样法、Poincaré 截面法以及功率谱法。

第二类：定量方法。所谓定量方法，就是通过一定方法计算混沌的某个特征量，根据得到的特征量数值判别混沌是否存在。这些混沌的特征量包括分维数（Fractal Dimension）、Kolmogorov 熵（Kolmogorov Entropy，简称 K 熵）以及 Lyapunov 指数，与此相对应就有三种定量判别混沌的方法。

由于直观法具有简单易行，判别方便等特点，成为判别混沌的最基本手段，但是这类方法最主要的缺点就是判别的不精确性。而定量方法需要经过一定量的计算

过程，根据得到的具体数值判别混沌的存在与否。因此，定量方法较直观法复杂一些。但是，定量方法通过具体的数值而不是直观的图形判别混沌，具有直观法不可比拟的准确性。

7.1.2　Lyapunov 指数

Lyapunov 指数可定量刻画混沌运动，正的 Lyapunov 指数是混沌的主要特征之一。

1. 奇异吸引子

耗散系统的混沌运动，存在着相反的两个过程：一方面耗散作用要使轨道收缩；另一方面，轨道又要相互分离（发散）。由于收缩是由方程自身决定的（存在耗散项），它是对相空间整体来说的，它要使远处的轨道趋向收缩至有限范围内（吸引子）。发散是局部性质的，是对相空间具体点附近的性质来说的，它使已靠近的轨道要相互排斥分开。这样，就使所有轨道最后（不计开始时刻的暂态过程）集中在相空间的有限范围内，靠拢又分开，分开又折叠而靠拢，无数次的来回折叠，才形成复杂的混沌。正因为如此，混沌运动的吸引子才必然具有复杂的无穷层次的自相似结构，人们称这种具有无穷层次自相似结构的吸引子为奇异吸引子，以区别于不动点和极限环之类的简单吸引子。

当系统处于混沌态时，其运动大体上可看成是两种运动所组成：从整体上看，系统是在绕一些大的空洞周而复始地运动，这种运动近似地是周期的并有一平均周期。但实际上系统同时在绕无数大大小小的空洞运动，这种运动自然要具有随机性（但也不是完全随机）。所以在混沌状态中，系统既不是作规则运动，但也不是像噪声那样完全杂乱无章。

混沌毕竟是服从确定性方程的运动状态，其运动自然应该具有一定的规律（有序），这就表现为其吸引子必定具有一定的结构。混沌是有序和无序的矛盾统一体，既可以说混沌是周期的有序运动，也可以说是服从一定规律的无序（随机）运动。

2. Lyapunov 指数

刻画吸引子的特征量，分为“微观”和“宏观”两个层次。“微观”层次是指构成奇异吸引子的骨架的不稳定周期数目、种类和它们的特征值；“宏观”层次是指对整个吸引子或无穷长的轨道平均后得到的特征量，如 Lyapunov 指数、分维数和 K 熵等。自 20 世纪 80 年代中期以来，这两个方面的工作都形成了一套理论框架和方法，也都发展了从实验数据中提取有关信息的技术，并且两者都在高维情形下显示出威力。

混沌运动的基本特点是运动对初值条件极为敏感。两个很靠近的初值所产生的轨道，随时间推移按指数方式分离，Lyapunov 指数就是定量描述这一现象的量。

在一维动力系统 $x_{n+1}=F(x_n)$ 中，初始两点迭代后是互相分离的，还是靠拢的，关键取决于导数 $|\mathrm{d}F/\mathrm{d}x|$ 的值。若 $|\mathrm{d}F/\mathrm{d}x|>1$，则迭代使得两点分开；若 $|\mathrm{d}F/\mathrm{d}x|<1$，则使得两点靠拢。但是在不断地迭代过程中，$|\mathrm{d}F/\mathrm{d}x|$ 的值也随之而变化，使得时而分离时而靠拢。为了表示从整体上看相邻两状态分离的情况，必须对时间（或迭代次数）取平均。因此，不妨设平均每次迭代所引起的指数分离中的指数为 λ，如图 7-1。

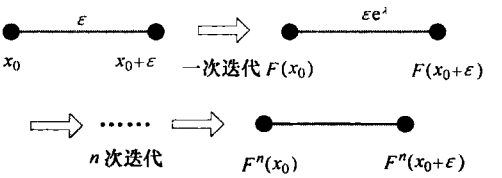

图 7-1 一维离散映射迭代过程轨道的指数分离

从图 7-1 看出，原来相距为 ε 的两点经过 n 次迭代后相距为

$$\varepsilon \mathrm{e}^{n\lambda(x_0)}=|F^n(x_0+\varepsilon)-F^n(x_0)| \tag{7-1}$$

取极限 $\varepsilon\to 0$，$n\to\infty$，式（7-1）变为

$$\lambda(x_0)=\lim_{n\to\infty}\lim_{\varepsilon\to 0}\frac{1}{n}\ln\left|\frac{F^n(x_0+\varepsilon)-F^n(x_0)}{\varepsilon}\right|=\lim_{n\to\infty}\frac{1}{n}\ln\left|\frac{\mathrm{d}F^n(x)}{\mathrm{d}x}\right|_{x=x_0} \tag{7-2}$$

式（7-2）可简化为

$$\lambda=\lim_{n\to\infty}\frac{1}{n}\sum_{i=0}^{n-1}\ln\left|\frac{\mathrm{d}F(x)}{\mathrm{d}x}\right|_{x=x_i} \tag{7-3}$$

式（7-3）中 λ 称为原动力系统的 Lyapunov 指数，它表示系统在多次迭代中平均每次迭代所引起的指数分离中的指数。

对 Logistic 映射 $x_{n+1}=\mu x_n(1-x_n)$，作出 Lyapunov 指数与参数 μ 的关系图，如图 7-2 所示。显然，若 $\mu<\mu_\infty=3.5699456\cdots$，$\lambda<0$，对应周期运动；若 $\mu>\mu_\infty$，$\lambda>0$，对应混沌运动。但是在混沌区（$\mu>\mu_\infty$）中，也有几个很窄的窗口处 $\lambda<0$，这对应混沌区中的 3、5、7 等周期窗口。而在 $\lambda=0$ 各点对应分岔点。

由上面的讨论可知，若 $\lambda<0$，则意味着相邻点最终要靠拢合并成一点，这对应于稳定的不动点和周期运动；若 $\lambda>0$，则意味着相邻点最终要分离，这对应于轨道的局部不稳定，如果轨道还有整体的稳定因素（如整体有界、耗散等），则在此作用下反复折叠并形成混沌吸引子。故 $\lambda>0$ 可作为系统混沌行为的一个判据。

对于一般的 n 维动力系统，定义 Lyapunov 指数如下：

设 F 是 $\mathbf{R}^n\to\mathbf{R}^n$ 上的 n 维映射，决定一个 n 维离散动力系统

$$\boldsymbol{x}_{n+1}=\boldsymbol{F}(\boldsymbol{x}_n) \tag{7-4}$$

将系统的初始条件取为一个半径无穷小的 n 维的超球，由于演变过程中的自然

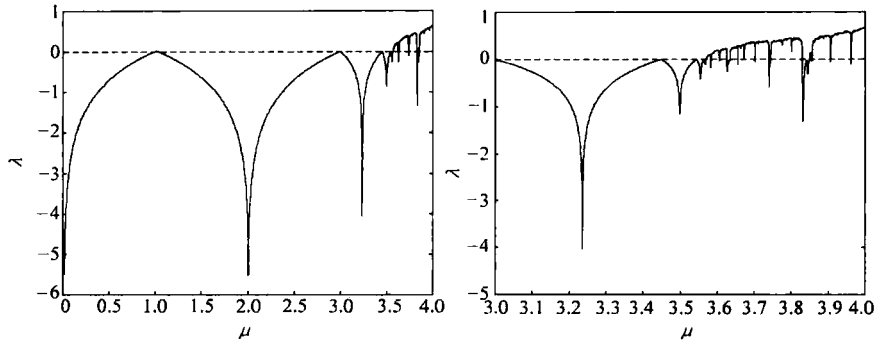

图 7-2　Logistic 映射的 Lyapunov 指数

变形，超球将变为超椭球。将超椭球的所有主轴按其长度顺序排列，那么第 i 个 Lyapunov 指数根据第 i 主轴的长度 $P_i(k)$ 的增加速率定义为

$$\lambda_i = \lim_{k\to\infty}\frac{1}{k}\ln\left[\frac{P_i(k)}{P_i(0)}\right] \quad (i=1,2,\cdots,n) \tag{7-5}$$

这样 Lyapunov 指数是与相空间的轨线收缩或扩张的性质相关联的，在 Lyapunov 指数小于零的方向上轨道收缩，运动稳定，对于初始条件不敏感；而在 Lyapunov 指数为正的方向上，轨道迅速分离，对初值敏感。注意超椭球的主轴长度按 e^{λ_1}增加，由前两个主轴定义的区域面积按 $e^{(\lambda_1+\lambda_2)}$增加，由前三个主轴定义的体积按 $e^{(\lambda_1+\lambda_2+\lambda_3)}$增加……即 Lyapunov 指数的前 j 个指数的和由前 j 个主轴定义的 j 维超立体体积指数增加的长期平均速率确定。

通常将全部的 Lyapunov 指数谱按大小排列为

$$\lambda_1 \geqslant \lambda_2 \geqslant \lambda_3 \geqslant \cdots \geqslant \lambda_n \tag{7-6}$$

λ_1可用做运动随机性或非确定性的定量描述。

一维情形：如果存在吸引子，则它只能是不动点，此时必有 $\lambda_1 < 0$。

二维情形：吸引子为不动点或极限环。对于稳定不动点，任意方向 δx_i都要收敛，故这时两个 Lyapunov 指数都应该是负的，记为（－，－）。对于稳定的极限环，若 δx_2垂直于环线的方向，则要收缩，所以垂直于环线方向的 Lyapunov 指数 λ_2 为负；当 δx_1沿环线切线方向，它既不增大也不缩小，该方向 Lyapunov 指数 λ_1为零，记为（λ_1，λ_2）=（0，－）。

三维四维情形见表 7-1。奇异吸引子是稳定和不稳定（或收缩和分离）两种因素共同作用的结果，因此它的 Lyapunov 指数一定要至少有一个为正的、至少有一个为负的。

表 7-1 吸引子按 Lyapunov 指数的分类

吸引子类型 / 系统模型	奇怪吸引子	环 面	极 限 环	不 动 点
三维系统	(+, 0, −)	(0, 0, −)	(0, −, −)	(−, −, −)
四维系统	(+, +, 0, −) (+, 0, 0, −) (+, 0, −, −)	(0, 0, 0, −) (0, 0, −, −)	(0, −, −, −)	(−, −, −, −)

在 Lyapunov 指数谱中，最小的 Lyapunov 指数，决定轨道收缩的快慢；最大的 Lyapunov 指数则决定轨道发散覆盖整个吸引子的快慢。对于多维动力系统的奇异吸引子，所有的 Lyapunov 指数之和$\sum\lambda_i$应该小于 0，大体上表征轨线总的收缩吸引趋势。

3. Lyapunov 指数的物理涵义

Lyapunov 指数不仅是判定一个体系是否混沌的定量标准，而且其本身具有深刻的物理内涵，同时还体现了有关体系的动力学其他重要特性。包括如下几个方面：

第一，对于哈密顿动力学体系，由于能量守恒，所以当体系随时间演化时，尽管体系的相空间的形状会有所改变，但其相空间体积是固定不变的。这时哈密顿空间中任一点的 Lyapunov 指数是正负成对的，即有 λ_i，必有 $-\lambda_i$。例如一个 6 维自由度的哈密顿体系，由于能量守恒，体系相空间自由度减少一个，成为 5 自由度相空间，由于哈密顿体系的 Lyapunov 指数是正负成对出现的，因此它们只能是 λ_1，λ_2，0，$-\lambda_2$，$-\lambda_1$。其中只有两个独立的指数 λ_1和 λ_2。这个性质大大简化了 Lyapunov 指数的计算量。

第二，所求的 Lyapunov 指数虽然与初始点有关，但是其本质是体系的大范围性质，因为在求取 Lyapunov 指数的过程中是观察次数 $k\to\infty$ 时的极限值。

第三，单从 Lyapunov 指数大于零来判断一个轨迹是否混沌轨迹时，应注意到不稳定的周期轨迹，其 Lyapunov 指数也会大于零，此时周期轨迹会被混沌区所包围。一般地说，Lyapunov 指数大于零的轨迹将敏感地依赖于初始值，我们可以说该轨迹是不稳定的，但不能一定判断说该轨迹就是混沌的。反过来，混沌轨迹一般都是不稳定的，其运动是敏感地依赖于初始值的不规则运动，它的 Lyapunov 指数一定大于零。

第四，Lyapunov 指数与 Kolmogorov 熵（信息量）之间存在确定的关系，即体系在演化过程中所获得的信息量正好等于大于零的 Lyapunov 指数之和。

7.2　Lyapunov 指数算法及其改进

下面阐述求解 Lyapunov 指数的算法——标准 QR 分解法和改进的 QR 分解算法。

7.2.1　标准 QR 分解算法

QR 分解法是求任意方阵全部特征向量的最有效的方法，也是数值代数许多重要算法的基础。对于一个确定的动力学系统，求取它的 Lyapunov 指数一般都基于系统基本解矩阵的 QR 分解。QR 分解的思路是：对于已知的动力系统，它的基本解可以写做 Y = QR，Q 是一个正交矩阵，R 是一个对角线元素都为正数的上三角矩阵，它可以表示成正交矩阵 Q 和系统 Jacobian 矩阵的函数，而 Lyapunov 指数就是由 R 的对角元素求得。

定理 1（QR 分解定理）　设 $\boldsymbol{A}\in R^{m\times n}$（$m\geqslant n$），则 A 有 QR 分解，$\boldsymbol{A}=\boldsymbol{Q}\begin{pmatrix}\boldsymbol{R}\\0\end{pmatrix}$，其中 $\boldsymbol{Q}\in R^{m\times m}$ 是正交矩阵，$\boldsymbol{R}\in R^{n\times n}$ 是具有非负对角元的上三角阵，而且当 $m=n$ 且 A 非奇异时，上述的分解还是唯一的。

考虑常微分方程描述的连续动力学系统

$$\dot{\boldsymbol{Y}}(t)=\boldsymbol{f}(\boldsymbol{Y}(t)),\ \boldsymbol{Y}(0)=\boldsymbol{Y}_0 \tag{7-7}$$

其中，$\boldsymbol{Y}\in R^n$，$t\in R$。该系统的线性变分方程为

$$\dot{\boldsymbol{Y}}(t)=\boldsymbol{J}(t)\boldsymbol{Y}(t),\ \boldsymbol{Y}(0)=\boldsymbol{I}_n \tag{7-8}$$

其中，$\boldsymbol{Y}\in R^{n\times n}$，$\boldsymbol{J}(t)$ 是系统式（7-8）在点（$\boldsymbol{Y}$，t）处的 $n\times n$ 维 Jacobian 矩阵，$\boldsymbol{I}_n$ 为 $n\times n$ 维的单位阵。对于 $t\geqslant 0$，由于 $\boldsymbol{Y}(0)$ 是非奇异的，所以 $\boldsymbol{Y}(t)$ 也是非奇异的。由定理 1 知，$\boldsymbol{Y}(t)$ 可进行 QR 因数分解，记为 $\boldsymbol{Y}(t)=\boldsymbol{Q}(t)\ \boldsymbol{R}(t)$，上三角矩阵 $\boldsymbol{R}(t)$ 的对角元素都是正的。将该 QR 分解式代入方程（7-8），有

$$\dot{\boldsymbol{Q}}(t)\boldsymbol{R}(t)+\boldsymbol{Q}(t)\dot{\boldsymbol{R}}(t)=\boldsymbol{J}(t)\boldsymbol{Q}(t)\boldsymbol{R}(t),\quad \boldsymbol{Q}(0)\boldsymbol{R}(0)=\boldsymbol{I}_n \tag{7-9}$$

将式（7-9）左乘 $\boldsymbol{Q}^{\mathrm{T}}$，右乘 $\boldsymbol{R}^{-1}$，有

$$\boldsymbol{Q}^{\mathrm{T}}(t)\dot{\boldsymbol{Q}}(t)+\dot{\boldsymbol{R}}(t)\boldsymbol{R}^{-1}(t)=\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t),\boldsymbol{Q}(0)=\boldsymbol{I}_n,\boldsymbol{R}(0)=\boldsymbol{I}_n \tag{7-10}$$

由于 $\boldsymbol{Q}^{\mathrm{T}}(t)\ \boldsymbol{Q}(t)=\boldsymbol{I}_n$，矩阵 $\boldsymbol{K}(t)=\boldsymbol{Q}^{\mathrm{T}}(t)\dot{\boldsymbol{Q}}(t)$ 是斜对称矩阵，并且由于矩阵 $\boldsymbol{R}(t)$ 是上三角矩阵，所以 $\dot{\boldsymbol{R}}(t)\boldsymbol{R}^{-1}(t)$ 也是上三角矩阵。因此，定义

$$\boldsymbol{K}_{ij}(t)=\begin{cases}(\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t))_{ij} & i>j\\ 0 & i=j\\ -(\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t))_{ji} & i<j\end{cases} \tag{7-11}$$

从 $\boldsymbol{K}(t)=\boldsymbol{Q}^{\mathrm{T}}(t)\dot{\boldsymbol{Q}}(t)$ 中，可以得到

$$\dot{\boldsymbol{Q}}(t)=\boldsymbol{Q}(t)\boldsymbol{K}(t),\quad \boldsymbol{Q}(0)=\boldsymbol{I}_n \tag{7-12}$$

式（7-11）和式（7-12）就确定了关于矩阵 $\boldsymbol{Q}(t)$ 的微分方程。由于 $\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t)$ 是斜对称的，由方程（7-10）得到

$$\dot{\lambda}_i(t)=\frac{\dot{\boldsymbol{R}}_{ii}(t)}{\boldsymbol{R}_{ii}(t)}=(\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t))_{ii},\ \lambda_i(0)=0\quad i=1,2,\cdots,n \tag{7-13}$$

这里 $\lambda_i(t)=\ln(\boldsymbol{R}_{ii}(t))$，称为 Lyapunov 指数的时间演化式，最终得到 Lyapunov 指数

$$\lambda_i=\lim_{t\to\infty}\frac{\lambda_i(t)}{t}\qquad i=1,2,\cdots,n \tag{7-14}$$

由式（7-12）得知，为了计算 Lyapunov 指数，需要求解 n^2 个微分方程以确定矩阵 $\boldsymbol{Q}$ 中的 n^2 个元素；需要求解式（7-7）给出的 n 个微分方程，以得到系统的运行轨迹，进而确定系统的 Jacobian 矩阵；还需计算式（7-13）给出的 n 个微分方程，以得到 $\lambda_i(t)$。因此，为了得到式（7-7）所有的 Lyapunov 指数值，共需求解 $n(n+2)$ 个微分方程。

7.2.2 改进的 QR 分解算法

1. 算法描述

这里阐述 Rangarajan 等人提出的改进的 QR 分解方法，对于维数是 2 和 3 的动力系统的 Lyapunov 指数计算，该方法较标准 QR 分解方法简单，计算速度较快。仍考虑微分方程描述的连续动力学系统

$$\dot{\boldsymbol{Y}}(t)=\boldsymbol{f}(\boldsymbol{Y}(t)),\ \boldsymbol{Y}(0)=\boldsymbol{Y}_0 \tag{7-15}$$

同 QR 算法一样，将该系统的基本解矩阵进行 QR 分解，然后再代入线性变分方程，得到

$$\dot{\boldsymbol{Q}}(t)\boldsymbol{R}(t)+\boldsymbol{Q}(t)\dot{\boldsymbol{R}}(t)=\boldsymbol{J}(t)\boldsymbol{Q}(t)\boldsymbol{R}(t),\quad \boldsymbol{Q}(0)\boldsymbol{R}(0)=\boldsymbol{I}_n \tag{7-16}$$

同样，再将式（7-16）左乘 $\boldsymbol{Q}^{\mathrm{T}}$，右乘 $\boldsymbol{R}^{-1}$，得

$$\boldsymbol{Q}^{\mathrm{T}}(t)\dot{\boldsymbol{Q}}(t)+\dot{\boldsymbol{R}}(t)\boldsymbol{R}^{-1}(t)=\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t),\ \boldsymbol{Q}(0)=\boldsymbol{I}_n,\ \boldsymbol{R}(0)=\boldsymbol{I}_n \tag{7-17}$$

将矩阵 $\boldsymbol{Q}(t)$ 表示成 $n(n-1)/2$ 个正交矩阵乘积的形式，

$$\boldsymbol{Q}(t)=\boldsymbol{O}^{(1,2)}(t)\boldsymbol{O}^{(1,3)}(t)\boldsymbol{O}^{(1,4)}(t)\cdots\boldsymbol{O}^{(1,n)}(t)\boldsymbol{O}^{(2,3)}(t)\cdots\boldsymbol{O}^{(n-2,n)}(t)\boldsymbol{O}^{(n-1,n)}(t) \tag{7-18}$$

这里每个正交矩阵 $\boldsymbol{O}^{(i,j)}(t)$ 对应着在第 $i-j$ 个平面（$i<j$）旋转角度 $\theta_{ij}(t)$，具体可以写成

$$\boldsymbol{O}_{kl}^{(ij)}(t)=\begin{cases}1 & k=l\neq i,j\\ \cos\theta_{ij} & k=l=i\text{ 或 }j\\ \sin\theta_{ij} & k=i,\ l=j\\ -\sin\theta_{ij} & k=j,\ l=i\\ 0 & \text{其他}\end{cases} \tag{7-19}$$

因此矩阵 $\boldsymbol{Q}(t)$ 被 $n(n-1)/2$ 个角度参数化。

由于上三角矩阵 $\boldsymbol{R}(t)$ 具有正的对角元素，它可以写成如下形式

$$\boldsymbol{R}(t)=\begin{pmatrix} e^{\lambda_1(t)} & r_{12}(t) & \cdots & \cdots & r_{1n}(t) \\ 0 & e^{\lambda_2(t)} & r_{23}(t) & \cdots & r_{2n}(t) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & e^{\lambda_n(t)} \end{pmatrix} \tag{7-20}$$

其中 $\lambda_i(t)$ 和 Lyapunov 指数有密切关系。利用式（7-19）和式（7-20），可以得到

$$\boldsymbol{Q}^{\mathrm{T}}(t)\dot{\boldsymbol{Q}}(t)=\begin{pmatrix} 0 & -f_1(\dot{\theta}(t)) & \cdots & -f_{n-1}(\dot{\theta}(t)) \\ f_1(\dot{\theta}(t)) & 0 & \cdots & -f_{2n-3}(\dot{\theta}(t)) \\ \vdots & \vdots & \vdots & \vdots \\ f_{n-1}(\dot{\theta}(t)) & \cdots & -f_{n(n-1)/2}(\dot{\theta}(t)) & 0 \end{pmatrix} \tag{7-21}$$

$$\dot{\boldsymbol{R}}(t)\boldsymbol{R}^{-1}(t)=\begin{pmatrix} \dot{\lambda}_1(t) & s_{12}(t) & \cdots & \cdots & s_{1n}(t) \\ 0 & \dot{\lambda}_2(t) & s_{23}(t) & \cdots & s_{2n}(t) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dot{\lambda}_n(t) \end{pmatrix} \tag{7-22}$$

再将式（7-21）和式（7-22）代入方程式（7-17）

$$\begin{pmatrix} \dot{\lambda}_1(t) & u_{12}(t) & \cdots & \cdots & u_{1n}(t) \\ 0 & \dot{\lambda}_2(t) & u_{23}(t) & \cdots & u_{2n}(t) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ f_{n-1}(\dot{\theta}(t)) & \cdots & \cdots & -f_{n(n-1)/2}(\dot{\theta}(t)) & \dot{\lambda}_n(t) \end{pmatrix}=\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t) \tag{7-23}$$

上面表达式中的 $r_{ij}(t)$、$s_{ij}(t)$ 和 $u_{ij}(t)$ 都不出现在最终求解 Lyapunov 指数的表达式中，所以对于它们的值不用求解。对角线元素对应相等，得到

$$\dot{\lambda}_i(t)=(\boldsymbol{Q}^{\mathrm{T}}(t)\boldsymbol{J}(t)\boldsymbol{Q}(t))_{ii}\quad i=1,\ 2,\ \cdots,\ n \tag{7-24}$$

次对角线元素对应相等，可以得到 $n(n-1)/2$ 个关于 $\theta(t)$ 的微分方程，记为：

$$\dot{\theta}_i(t)=g_i(\theta)\quad i=1,\ 2,\ \cdots,\ n\ (n-1)/2 \tag{7-25}$$

式（7-24）和式（7-25）联立就可以确定 Lyapunov 指数为

$$\lambda_i=\lim_{t\to\infty}\frac{\lambda_i(t)}{t}\qquad i=1,\ 2,\ \cdots,\ n \tag{7-26}$$

改进的 QR 算法的特点是给出了正交矩阵 $\boldsymbol{Q}(t)$ 和上三角矩阵 $\boldsymbol{R}(t)$ 的明确表达式，求解 Lyapunov 指数的式（7-24）和式（7-25）是关于角度的微分方程，避

免了直接求解正交矩阵 $\boldsymbol{Q}(t)$ 中的元素，数值误差不会导致矩阵 $\boldsymbol{Q}(t)$ 逐渐失去正交性，从而避免了重复正交化的缺点。该方法为了计算出 n 个 Lyapunov 指数，需要求解的微分方程数目为 $n+n(n-1)/2=n(n+1)/2$，比标准 QR 分解算法的数目要少。

2. 杜芬方程的 Lyapunov 指数计算

受迫 Duffing 方程形式如下

$$\ddot{x}+a\dot{x}+bx+cx^3=F\cos(\omega t) \tag{7-27}$$

这是一个二维非自治系统，记 $f(x,\dot{x},t)=a\dot{x}+bx+cx^3$，$g(t)=F\cos(\omega t)$，利用代换 $y_1=x$，$y_2=\dot{x}$ 和 $y_3=t(t\in R)$，将方程式（7-27）改写为三维自治系统

$$\begin{cases}\dot{y}_1=y_2\\ \dot{y}_2=-f(y_1,y_2,y_3)+g(y_3)\\ \dot{y}_3=1\end{cases}\text{，初始条件}\begin{cases}y_1(0)=y_{10}\\ y_2(0)=y_{20}\\ y_3(0)=0\end{cases} \tag{7-28}$$

现在考虑系统式（7-28）的线性变分方程为：$\dot{\boldsymbol{Y}}(t)=\boldsymbol{J}(t)\boldsymbol{Y}(t)$，$\boldsymbol{Y}(0)=\boldsymbol{I}_3$，$\boldsymbol{I}_3$是 3×3 的单位矩阵，$\boldsymbol{J}(t)$ 为三维自治的 Jacobian 矩阵。明显的 Jacobian 矩阵第三行元素都为 0，所以它是奇异的，也就是说 $\boldsymbol{Y}(t)$ 的第三行元素都是常量，即 $y_{31}=0,y_{32}=0$ 和 $y_{33}=1$。可对奇异矩阵 $\boldsymbol{Y}$ 进行 QR 分解，表示成

$$\begin{pmatrix}y_{11}&y_{12}&y_{13}\\ y_{21}&y_{22}&y_{23}\\ 0&0&1\end{pmatrix}=\begin{pmatrix}q_{11}&q_{12}&0\\ q_{21}&q_{22}&0\\ 0&0&1\end{pmatrix}\begin{pmatrix}r_{11}&r_{12}&r_{13}\\ 0&r_{22}&r_{23}\\ 0&0&1\end{pmatrix} \tag{7-29}$$

因为非自治系统的前 n 个 Lyapunov 指数等于其相应自治系统的 n 个 Lyapunov 指数，该非自治系统的第 $n+1$ 个 Lyapunov 指数等于零，所以该系统有一个 Lyapunov指数为0。要求得另两个指数，就要确定 $r_{11}(t)$ 和 $r_{22}(t)$。现在只要考虑系统式（7-27）的如下二维子系统就可以了：

$$\dot{\tilde{\boldsymbol{Y}}}(t)=\tilde{\boldsymbol{J}}(t)\tilde{\boldsymbol{Y}}(t),\ \tilde{\boldsymbol{Y}}(0)=\boldsymbol{I}_2 \tag{7-30}$$

$\tilde{\boldsymbol{J}}(t)$ 为 Jacobian 矩阵，形式为

$$\tilde{\boldsymbol{J}}(t)=\begin{pmatrix}0&1\\ -\dfrac{\partial f(y_1,y_2,y_3)}{\partial y_1}&-\dfrac{\partial f(y_1,y_2,y_3)}{\partial y_2}\end{pmatrix}=\begin{pmatrix}J_{11}&J_{12}\\ J_{21}&J_{22}\end{pmatrix} \tag{7-31}$$

用改进的 QR 分解方法得到

$$\tilde{\boldsymbol{Q}}^{\mathrm{T}}(t)\dot{\tilde{\boldsymbol{Q}}}(t)+\dot{\tilde{\boldsymbol{R}}}(t)\tilde{\boldsymbol{R}}^{-1}(t)=\tilde{\boldsymbol{Q}}^{\mathrm{T}}(t)\tilde{\boldsymbol{J}}(t)\tilde{\boldsymbol{Q}}(t),\ \tilde{\boldsymbol{Q}}(0)=\boldsymbol{I}_2,\ \tilde{\boldsymbol{R}}(0)=\boldsymbol{I}_2 \tag{7-32}$$

对于二维系统，$\tilde{\boldsymbol{Q}}(t)$ 只有一个夹角，所以有

$$\tilde{\boldsymbol{Q}}(t)=\begin{pmatrix}\cos\theta(t)&\sin\theta(t)\\ -\sin\theta(t)&\cos\theta(t)\end{pmatrix}\quad\tilde{\boldsymbol{R}}(t)=\begin{pmatrix}\mathrm{e}^{\lambda_1(t)}&r_{11}\\ 0&\mathrm{e}^{\lambda_2(t)}\end{pmatrix} \tag{7-33}$$

其中 r_{11} 不参与 Lyapunov 指数的计算，可以忽略其影响。联立式（7-32）和式（7-33），可以得到方程组

$$\begin{cases} \dfrac{\mathrm{d}\lambda_1(t)}{\mathrm{d}t} = J_{11}\cos^2\theta + J_{22}\sin^2\theta - \dfrac{1}{2}(J_{12}+J_{21})\sin 2\theta \\ \dfrac{\mathrm{d}\lambda_2(t)}{\mathrm{d}t} = J_{11}\sin^2\theta + J_{22}\cos^2\theta + \dfrac{1}{2}(J_{12}+J_{21})\sin 2\theta \\ \dfrac{\mathrm{d}\theta(t)}{\mathrm{d}t} = -\dfrac{1}{2}(J_{11}-J_{22})\sin 2\theta + J_{12}\sin^2\theta - J_{21}\cos^2\theta \end{cases} \tag{7-34}$$

将方程组式（7-34）的前两个方程式相加减，得到新的方程组为

$$\begin{cases} \dfrac{\mathrm{d}v_1(t)}{\mathrm{d}t} = J_{11} + J_{22} \\ \dfrac{\mathrm{d}v_2(t)}{\mathrm{d}t} = (J_{11}-J_{22})\cos 2\theta - (J_{12}+J_{21})\sin 2\theta \\ \dfrac{\mathrm{d}\theta(t)}{\mathrm{d}t} = -\dfrac{1}{2}(J_{11}-J_{22})\sin 2\theta + J_{12}\sin^2\theta - J_{21}\cos^2\theta \end{cases} \tag{7-35}$$

这里

$$\begin{cases} \dfrac{\mathrm{d}v_1(t)}{\mathrm{d}t} = \dfrac{\mathrm{d}\lambda_1(t)}{\mathrm{d}t} + \dfrac{\mathrm{d}\lambda_2(t)}{\mathrm{d}t} \\ \dfrac{\mathrm{d}v_2(t)}{\mathrm{d}t} = \dfrac{\mathrm{d}\lambda_1(t)}{\mathrm{d}t} - \dfrac{\mathrm{d}\lambda_2(t)}{\mathrm{d}t} \end{cases} \tag{7-36}$$

联立式（7-31）和式（7-35）中，得

$$\begin{cases} \dfrac{\mathrm{d}v_1(t)}{\mathrm{d}t} = -\dfrac{\partial f}{\partial y_2} \\ \dfrac{\mathrm{d}v_2(t)}{\mathrm{d}t} = \dfrac{\partial f}{\partial y_2}\cos 2\theta - \left(1 - \dfrac{\partial f}{\partial y_1}\right)\sin 2\theta \\ \dfrac{\mathrm{d}\theta(t)}{\mathrm{d}t} = -\dfrac{1}{2}\dfrac{\partial f}{\partial y_2}\sin 2\theta + \sin^2\theta + \dfrac{\partial f}{\partial y_1}\cos^2\theta \end{cases} \tag{7-37}$$

求解方程组式（7-37）得 $v_1(t)$ 和 $v_2(t)$，并将它们代入方程式（7-36）中，有

$$\begin{cases} \lambda_1(t) = \dfrac{1}{2}(v_1(t) + v_2(t)) \\ \lambda_2(t) = \dfrac{1}{2}(v_1(t) - v_2(t)) \end{cases} \tag{7-38}$$

进而得到

$$\begin{cases} \lambda_1 = \lim\limits_{t\to\infty}\dfrac{\lambda_1(t)}{t} \\ \lambda_2 = \lim\limits_{t\to\infty}\dfrac{\lambda_2(t)}{t} \end{cases} \tag{7-39}$$

λ_1 和 λ_2 就是受迫 Duffing 方程的两个 Lyapunov 指数。从上面计算可以看出

$$\frac{\mathrm{d}\lambda_1(t)}{\mathrm{d}t}+\frac{\mathrm{d}\lambda_2(t)}{\mathrm{d}t}=J_{11}+J_{22} \tag{7-40}$$

其中 $J_{11}\equiv 0$，J_{22} 一般是常数，令 $J_{22}=c$（c 为常数）。积分式（7-40）得到 $\lambda_1(t)+\lambda_2(t)=ct+c'$（$c'$ 为任意常数）。由式（7-39）得 $\lambda_1+\lambda_2=c$，说明 Duffing 方程的两个 Lyapunov 指数和为常数。

7.2.3 Lyapunov 指数算法的实现

1. 算法流程

如图 7-3 所示的算法流程。首先初始化一系列参数，然后设置迭代次数，再求解微分方程，每迭代一次，就计算一次 Jacobian 矩阵，对 Jacobian 矩阵进行 QR 分解，计算出 Lyapunov 指数，同时，还可根据容量维的定义式 $D_c=j+\sum_{i=1}^{j}\frac{\lambda_i}{1-\lambda_i}$，计算系统的分数维 D_c。其中 j 满足：$\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_j\geqslant 0\geqslant\lambda_{j+1}\geqslant\cdots\geqslant\lambda_n$。

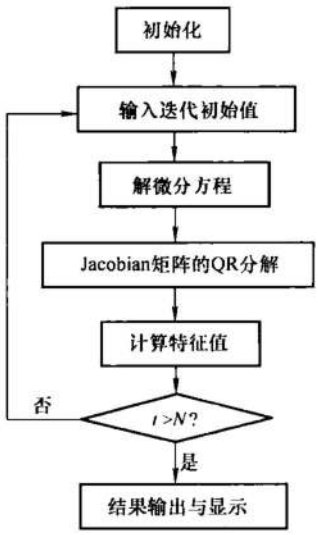

图 7-3 基于 Matlab 的算法流程图

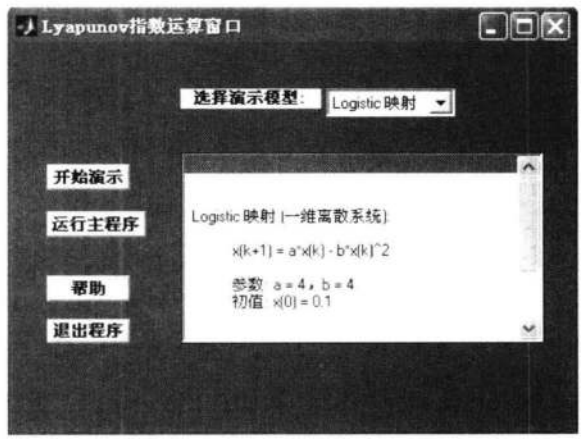

图 7-4 Lyapunov 指数工具箱主界面

2. Lyapunov 指数计算工具

基于 Matlab 语言和 GUI 编程，根据以上算法流程开发了一个计算 Lyapunov 指数的计算工具。Lyapunov 指数计算工具能够求解非线性动力学系统的 Lyapunov 指数和分数维，为混沌系统的理论分析与应用研究提供可靠的实验数据。计算数据和结果还能以文件形式输出，以便保存和处理。计算过程如图 7-4 ~ 图 7-7 所示。

3. 几种典型系统的 Lyapunov 指数

用改进的 QR 分解算法在计算工具上计算几种典型混沌吸引子的 Lyapunov 指数

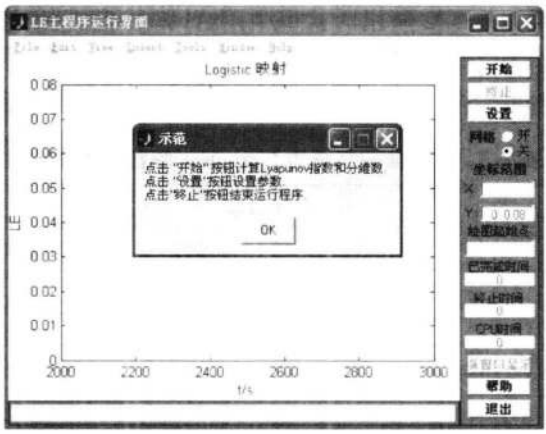

图 7-5　Lyapunov 指数计算工具程序运行界面

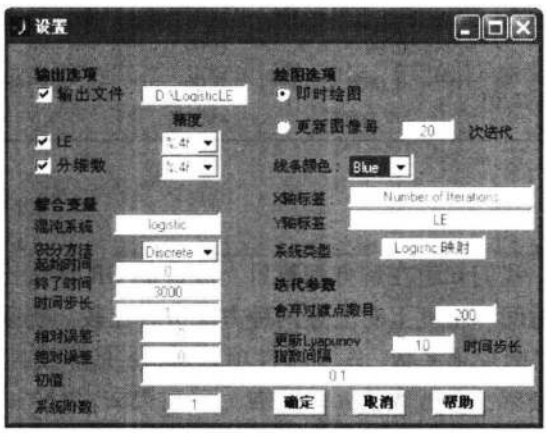

图 7-6　Lyapunov 指数计算工具参数设置界面

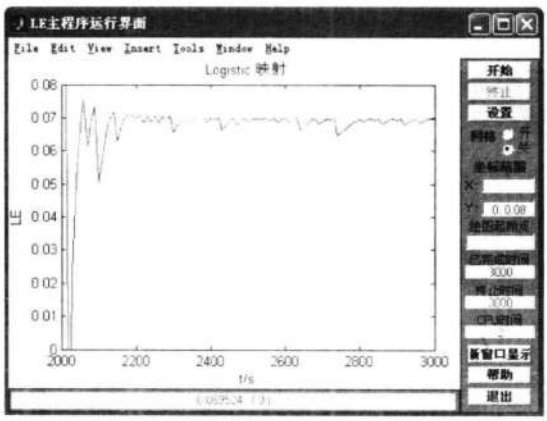

图 7-7　Lyapunov 指数计算工具结果显示界面

及其关联维数，结果如表7-2所示。这里引用A. Wolf发表的论文中的Lyapunov指数和分维数数值作为参考值。从表中看出最大Lyapunov指数计算值和参考值相差甚小，从而验证了所开发的Lyapunov指数计算工具计算结果的准确性。

表7-2 几种典型系统的Lyapunov指数和关联维数

系统（参数）	Lyapunov指数		分维数	
	计算值	参考值	计算值	理论值
Henon ($a=1.4$, $b=0.3$)	0.4194 -1.6234	0.418 -1.621	1.2583	1.26
Logistic ($a=b=4$)	0.6947	0.693	0	0
Lorenz ($\sigma=16$, $\alpha=45.92$, $\beta=4$)	1.5034 -0.0053 -22.4981	1.497 0.00 -22.46	2.0666	2.07
Rossler ($a=0.15$, $b=0.20$, $c=10.0$)	0.0833 0.0651 -9.9982	0.09 0.00 -9.77	2.0148	2.01

7.2.4 算法的比较

通过上述分析，我们知道在解方程数目上改进的QR算法比标准QR分解算法更少。下面在计算时间和精度上对上述两种方法进行比较。仍采用受迫杜芬方程式(7-27)，其中，a是阻尼项系数，b是线性项系数，c是非线性项系数，F和ω是周期驱动力幅值和频率，参数取值$a=0.3\text{N}\cdot\text{s/m}$，$b=-1\text{N/m}$，$c=1\text{N/m}^3$，初始条件$(x, \dot{x})=(0, 0)$，$\omega=1.2\text{rad/s}$。可由相轨迹图知：当$F=0.729\text{N}$时系统处于混沌状态，当$F=0.730\text{N}$时系统处于周期状态，如图7-8所示。

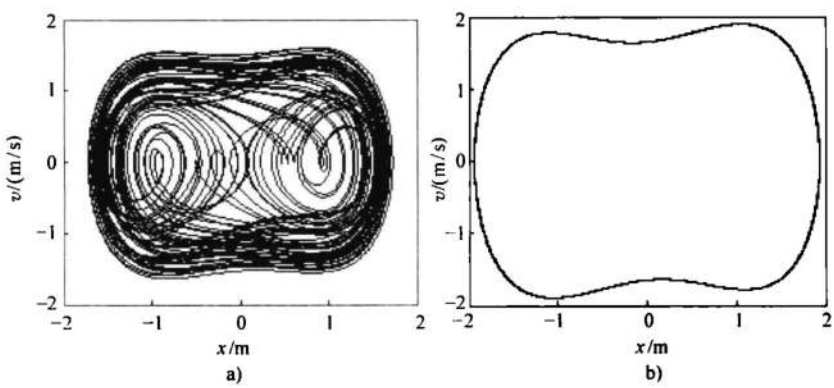

图7-8 系统相轨迹图

a) $F=0.729\text{N}$ b) $F=0.730\text{N}$

用上述标准 QR 算法和改进的 QR 算法分别计算 $F=0.729$N（混沌）和 $F=0.760$N（周期）两种状态下 Duffing 方程的 Lyapunov 指数。步长取 0.01s，初始状态 $(x, \dot{x})=(0, 0)$，得到的 Lyapunov 指数（Lyapunov Exponents，LE）与时间关系的曲线如图 7-9 和图 7-10 所示。

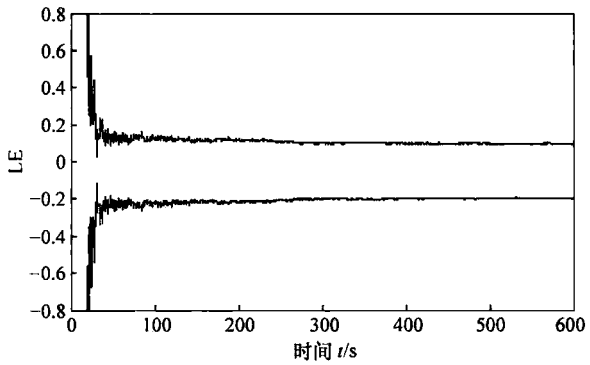

图 7-9　用标准 QR 算法计算 Duffing 方程的 LE 曲线

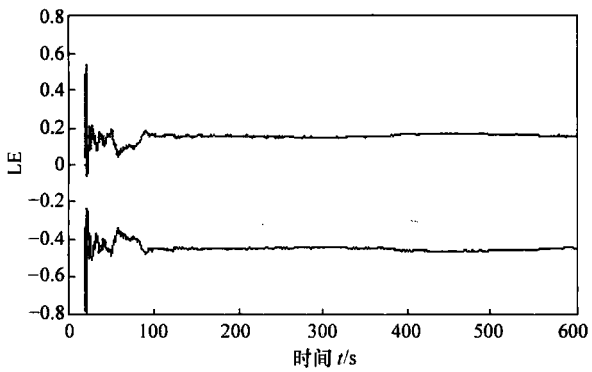

图 7-10　用改进的 QR 算法计算 Duffing 方程的 LE 曲线

在与前面所给参数和初始条件相同的情况下分别运行两种算法程序，以 $t=600$s作为时间长度，并将 $t=600$s 时的 Lyapunov 指数进行对比，记录下各自运行的 CPU 时间和对应的分维数，如表 7-3、表 7-4 所示。因为 Duffing 系统对应的状态方程的 Jacobian 矩阵为

$$\boldsymbol{J}=\begin{pmatrix} 0 & 1 \\ -1-3x^2 & -0.3 \end{pmatrix}$$

根据 $\lambda_1+\lambda_2=$常数，这里该常数是 -0.3，用 $\dfrac{|\lambda_1+\dot{\lambda}_2+0.3|}{0.3}$ 的值定义计算误差来比较这两种方法的计算精度。见表 7-3、表 7-4。

表 7-3 $F=0.729$ 时两种算法得到 Lyapunov 指数

算 法	λ_1	λ_2	计算时间/s	分维数	误差
标准 QR 算法	0.083473	-0.364954	437	2.281	6.173e-2
改进 QR 法	0.135963	-0.435958	284	2.342	1.667e-5

表 7-4 $F=0.760$ 时两种算法得到 Lyapunov 指数

算 法	λ_1	λ_2	计算时间/s	误 差
标准 QR 算法	-0.143209	-0.146783	579	3.336e-2
改进 QR 算法	-0.127387	-0.172603	212	3.333e-5

图 7-9 和图 7-10 所示的 Lyapunov 指数时间演化曲线表明，两种算法都有较好的收敛性，但是从表 7-3 和表 7-4 看出，QR 算法的计算时间比改进的 QR 算法时间要长得多，而且误差也要比改进算法大。这说明改进的 QR 算法要比标准的 QR 算法优越。

7.3 基于 Lyapunov 指数的混沌检测

弱信号检测一直是检测理论与应用研究领域的难点之一。微弱信号幅值小，测量时又易受传感器和测量仪器本身噪声的影响，表现出来的总体现象一般是有用的被测信号被强噪声信号所淹没。

近年来，利用混沌振子检测微弱信号开始受到广泛关注。但研究表明这种方法设定的阈值精度低，不能满足弱信号测量的要求。由于混沌态时系统的最大 Lyapunov 指数大于零，而当系统处于周期态时，最大 Lyapunov 指数小于零，利用这一特性可以确定系统的阈值：最大 Lyapunov 指数的符号从大于零变为小于零的时刻，所对应的参数值就是阈值。所以，Lyapunov 指数不仅是判别混沌存在与否的重要指标，也可以用来求取系统从混沌态跃变到周期态的阈值。

7.3.1 杜芬方程的混沌特性

1. Duffing 方程的基本混沌特性

考察带有阻尼项且受外部周期激励的 Duffing 系统，其一般形式为：

$$\ddot{x}+a\dot{x}-x+x^3=f_r\cos\omega t \tag{7-41}$$

式中，a 是阻尼系数；$f_r\cos\omega t$ 是角频率为 ω 的周期激励（参考信号）。

可将式（7-41）转化为状态方程组：

$$\begin{cases}\dot{x}=y\\ \dot{y}=-ay+x-x^3+f_r\cos\omega t\end{cases} \tag{7-42}$$

为观察 Duffing 系统的混沌特性，取 $a=0.3\text{N}\cdot\text{s/m}$，$\omega=1.2\text{rad/s}$，$f_r=0.33\text{N}$，在 Matlab 软件上使用四阶龙格—库塔法进行数值分析，方程初值分别取为 $x_0=0.1$，$y_0=0$ 和 $x_0=0.1$，$y_0=0.02$。如图 7-11 和图 7-12 所示，分别为 Duffing 方程的解 $x(t)$随时间 t 变化和其在相平面$(x,\ \dot{x})$上的轨迹。

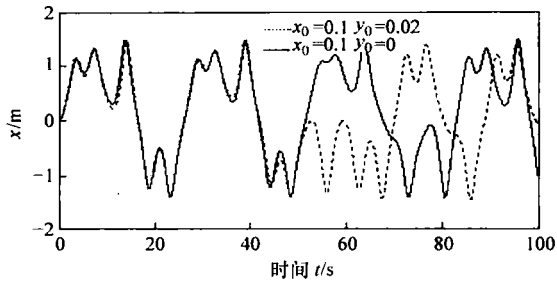

图 7-11　Duffing 方程两个邻近初始条件的 x-t 曲线

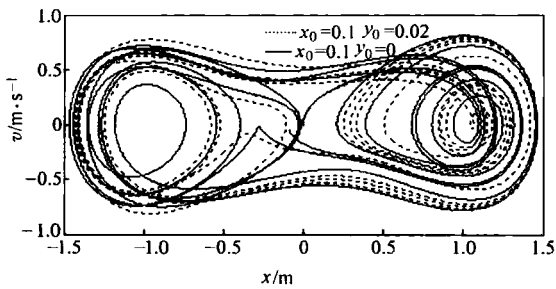

图 7-12　不同初始状态 Duffing 方程的相轨迹

图 7-11 和图 7-12 清楚地显示，Duffing 系统表现出了明显的混沌特性。在演化初期，两个解差别极小，甚至不能分开；但随着演化时间的增长，两个解的差别越来越大，而且很快变得完全不同。洛伦兹称这种现象为“蝴蝶效应”。这个比喻形象地说明了混沌运动对初始条件的敏感依赖性。

2. Duffing 方程的间歇混沌特性

间歇混沌又称为阵发混沌，是非线性系统在时间和空间上表现出的有序和无序交替出现的特殊动力学形态。在某些时空段，运动十分接近规则的周期运动；而在规则的运动段落之间，又夹杂着看起来很随机的跳跃。通常人们把这里的规则运动称为层流相（Laminar Flow Phase），而把随机跳跃称为湍流相（Turbulent Flow Phase）。

考虑如下形式的 Duffing 系统：

$$\ddot{x}+a\dot{x}-x+x^3=f_r\cos\omega t+d\cos((\omega+\Delta\omega)t+\phi) \tag{7-43}$$

式中，$f_r\cos\omega t + d\cos((\omega+\Delta\omega)t+\phi)$ 为总驱动力；$f_r\cos\omega t$ 为内驱动信号；$d\cos((\omega+\Delta\omega)t+\phi)$ 为外界小幅值的摄动信号（又称小信号、微弱信号），是对内驱动信号的摄动，$\Delta\omega$ 为外摄动信号与内驱动力间角频率之差。

取 $a=0.3\text{N}\cdot\text{s/m}$，$\omega=1\text{rad/s}$，经过反复仿真实验，初步估计得到系统出现周期 1 外轨的临界值 f_c 在 0.538N 和 0.54N 之间。如果将内驱动信号的幅值 f_r 取在 Duffing 系统由混沌运动到周期运动的阈值 f_c 附近（稍小于 f_c），而取 d 的幅值较小，且保证 $f_r+d>f_c$，那么在 $\Delta\omega$ 较小的情况下，方程右端函数的幅值总和 $F(t)$ 将会缓慢地周而复始地在 f_c 两边进行摆动，如图 7-13 所示。

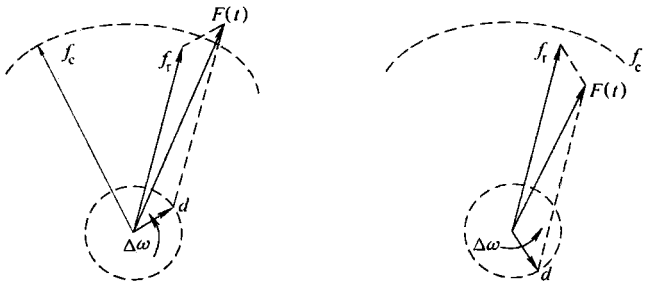

图 7-13 参考信号和输入信号矢量合成示意图

如果将内驱动信号矢径 $\boldsymbol{f}_r$ 看作不动，那么外界信号矢径将以 $\Delta\omega$ 的角频率极其缓慢地绕之旋转。当二者的方向趋于一致时，矢径合成的结果导致总驱动力的幅值 $F(t)$ 大于 f_c，系统因此过渡到周期状态；当它们的方向趋于背离时，合成的结果导致总驱动力的幅值 $F(t)$ 小于 f_c，因此系统因为激励不够而退化到以前的混沌状态。这样，系统就表现出时而周期、时而混沌的间歇混沌现象。

取 $\Delta\omega$ 很小的原因是：由于 $\Delta\omega$ 很小，因此 $F(t)$ 变化极其缓慢，可以远远慢于相变的过程。一般相变所需的时间为一到两个周期，而系统维持稳定的周期状态或稳定的混沌状态的时间是几十个周期。也就是说，系统对于驱动力的缓慢变化能够很好地响应，周期或混沌的出现是泾渭分明的。大量的仿真结果表明，$\Delta\omega\leqslant 0.03\text{rad/s}$，即周期摄动信号与内驱动力间角频率差不大于 0.03rad/s 时，能保证可以十分明显地观察出系统的间歇混沌现象。取 $f_r=0.51\text{N}$，得到的间歇混沌时间历程如图 7-14 所示。

数值仿真表明，在 $\Delta\omega>0.04\text{rad/s}$ 时，有规律的间歇混沌现象难以分辨出来，如图 7-14a 所示。这是由于完成相变过程的必要条件是足够长的激励时间，$\Delta\omega$ 很大时，$F(t)$ 变化得过快以至于系统不能很好地响应。在 $F(t)$ 大于 f_c 期间，激励衰减得太快而不能使周期运动持续；在 $F(t)$ 小于 f_c 期间，激励增加得太快而不能使系统保持稳定的混沌运动。

7.3.2　基于最大 Lyapunov 指数的微弱信号检测方法

最大 Lyapunov 指数是系统混沌特性的度量特征量，利用最大 Lyapunov 指数对系统的混沌或周期状态进行识别，从而确定相变的阈值。本节介绍一种微弱信号检测的新方法：利用混沌振子对噪声的免疫力和间歇混沌特性，将待测信号加入到杜芬混沌系统中去，通过观察最大 Lyapunov 指数的符号变化，进而判断出是否有微弱信号的加入。

1. Lyapunov 指数法确定系统相变的阈值

Melnikov 函数是一种传统的求解混沌系统阈值的解析方法，利用 Melnikov 函数可以精确求解出系统进入混沌态和离开混沌态的阈值。Melnikov 方法可以求出 Duffing 振子在微扰的情况下能稳定在某一次谐轨道的 f_r/a 的临界值。

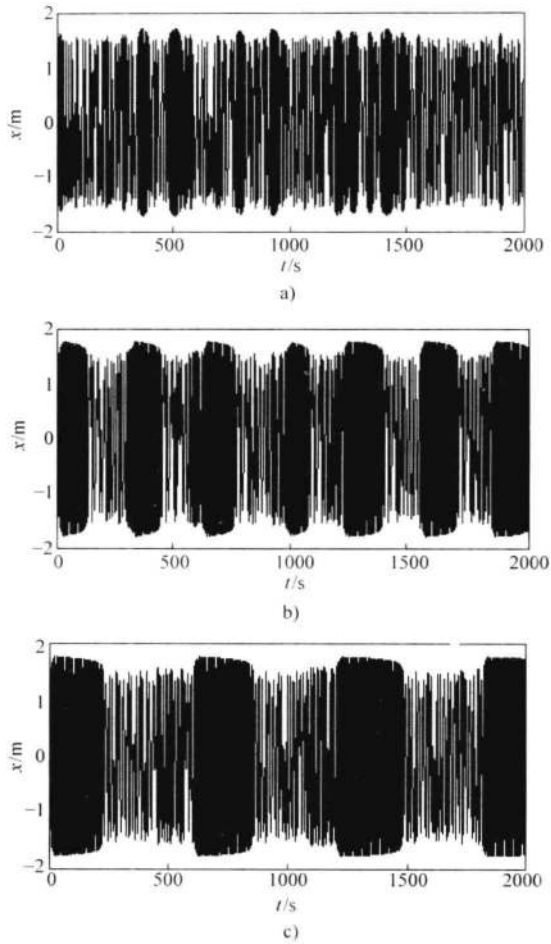

图 7-14　间歇混沌的时间历程

a）$\Delta\omega = 0.04\text{rad/s}$，$d = 0.05\text{N}$　b）$\Delta\omega = 0.02\text{rad/s}$，$d = 0.05\text{N}$　c）$\Delta\omega = 0.01\text{rad/s}$，$d = 0.05\text{N}$

采用 Lyapunov 指数法来确定阈值，通过计算系统的最大 Lyapunov 指数，根据它的符号变换（由正变负），来确定系统由混沌状态变为周期状态的临界阈值。这里首先固定步长 h 和阻尼系数 a 的值，通过大量仿真确定系统由混沌向有序转变的临界值 f_c。分别取 $h = 0.02\text{s}$、0.01s、0.005s，$a = 0.3\text{N}\cdot\text{s/m}$、$0.4\text{N}\cdot\text{s/m}$、$0.5\text{N}\cdot\text{s/m}$、$0.6\text{N}\cdot\text{s/m}$、$0.7\text{N}\cdot\text{s/m}$，初始状态为（0.1，0.1），临界值 f_c 与 a 的关系见表 7-5 ~ 表 7-7。

表 7-5 $h=0.02s$ 时临界值 f_c 与 a 之间的关系

$a/(N\cdot s/m)$	0.3	0.4	0.5	0.6	0.7
f_c/N	0.516	0.670	0.821	0.981	1.142
$\hat{R}^1=f_c/a$	1.720	1.675	1.642	1.635	1.631
平均值 $\overline{R}$	1.6606				

表 7-6 $h=0.01s$ 时临界值 f_c 与 a 之间的关系

$a/(N\cdot s/m)$	0.3	0.4	0.5	0.6	0.7
f_c/N	0.529	0.676	0.825	0.983	1.200
$\hat{R}^1=f_c/a$	1.763	1.690	1.6500	1.638	1.714
平均值 $\overline{R}$	1.6910				

表 7-7 $h=0.005s$ 时临界值 f_c 与 a 之间的关系

$a/(N\cdot s/m)$	0.3	0.4	0.5	0.6	0.7
f_c/N	0.525	0.672	0.825	0.983	1.143
$\hat{R}^1=f_c/a$	1.750	1.677	1.650	1.638	1.633
平均值 $\overline{R}$	1.6696				

表中得到的结果与用 Melnikov 方法求出的 f_c/a 的临界值 1.67689 比较接近，尤其是当 $h=0.005s$ 时，$\overline{R}$ 更接近 $\hat{R}^1$，$\hat{R}^1-\overline{R}=0.0072$，误差约为 0.429%。因此说明 Lyapunov 指数判别方法可以准确地确定阈值 f_c。

下面介绍如何利用 Lyapunov 指数确定 Duffing 系统由混沌到周期的阈值。考虑式（7-41）是未加入微扰的 Duffing 系统，初始状态 $(x_0, y_0)=(0.1, 0.1)$，$a=0.4N\cdot s/m$，$h=0.005s$，$\omega=1rad/s$。f_r从 0 开始以 0.001 为阶梯递增至 1N，计算出每个 f_r 对应的最大 Lyapunov 指数，如图 7-15 所示。从图中可以看出在 $f_r=0.6723N$ 时，最大 Lyapunov 指数符号发生了变化（由正变负），即 $f_r=0.6723N$ 时系统由混沌状态过渡到了周期状态。

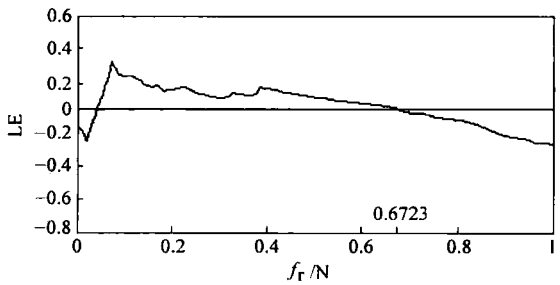

图 7-15 驱动力 f_r 与最大 Lyapunov 指数之间的关系图

图 7-16 和图 7-17 为分别取 $f_r = 0.672\text{N}$ 和 $f_r = 0.673\text{N}$ 时计算的 Lyapunov 指数曲线。

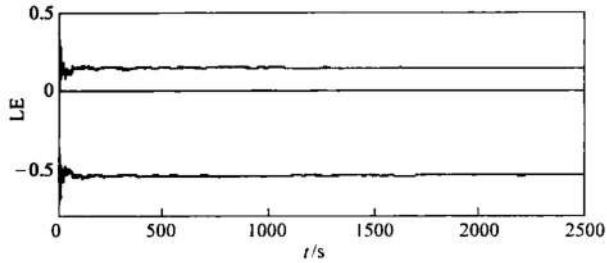

图 7-16　$f_r = 0.672\text{N}$ 时的 Lyapunov 指数

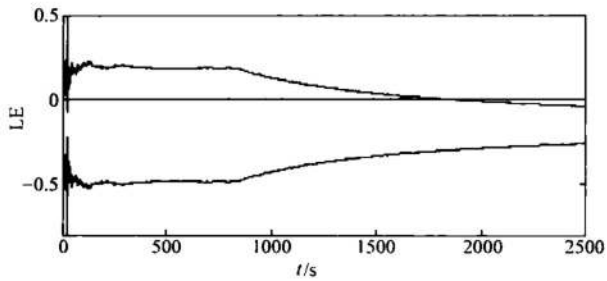

图 7-17　$f_r = 0.673\text{N}$ 时的 Lyapunov 指数

从图 7-16 和图 7-17 中看到，当 $f_r = 0.672\text{N}$ 时，经过很长时间（2500s）最大 Lyapunov 指数仍大于零，在 $t = 2500\text{s}$ 时刻，$\lambda_1 = 0.17303$，维数 $D = 2.3658$，系统为混沌状态。当 $f_r = 0.673\text{N}$ 时，在经过一段时间后最大 Lyapunov 指数变为小于零，在 $t = 2500\text{s}$ 时刻，$\lambda_1 = -0.05897$，系统进入了周期状态。所以此时 $f_c = 0.672 \sim 0.673\text{N}$ 为系统由混沌跃变为周期态的临界值。对于上面用 Lyapunov 指数法确定的系统阈值，可以由下面的系统相轨和时间历程图 7-18、图 7-19 验证它的正确性。

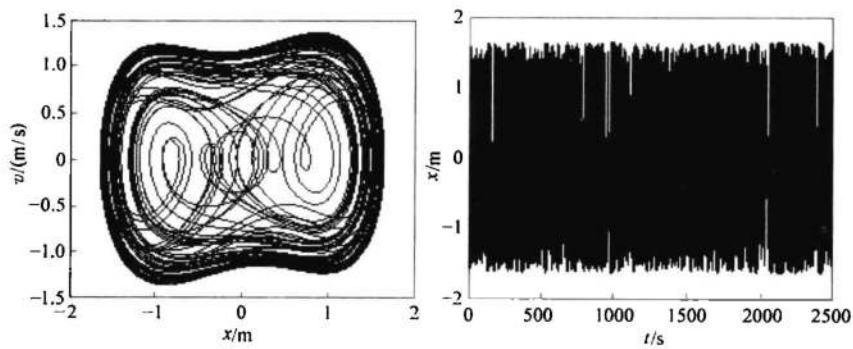

图 7-18　$f_r = 0.672\text{N}$ 时系统的相轨和时间历程图

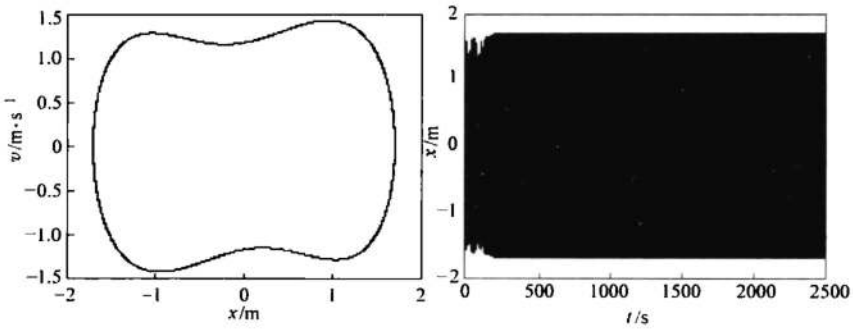

图 7-19 $f_r = 0.673\text{N}$ 时系统的相轨和时间历程图

2. 最大 Lyapunov 指数法的弱信号检测方法

要进行弱信号检测首先要确定系统由混沌状态跃变为周期状态的阈值。根据上面的分析，系统式（7-41）在初始状态（x_0，y_0）=（0.1，0.1），$a = 0.4\text{N}\cdot\text{s/m}$，$h = 0.005\text{s}$，$\omega = 1\text{rad/s}$ 时，Duffing 振子在微扰的情况下能稳定在周期外轨 $\hat{R}^1$ 的临界值为 $f_c = 0.672 \sim 0.673\text{N}$，取 $f_r = 0.670\text{N}$ 稍小于 f_c。计算时长 3 000s 的 Lyapunov 指数如图 7-20 所示，在 $t = 3\,000\text{s}$ 时 $\lambda_1 = 0.1497$，维数 $D = 2.2723$，系统处于混沌状态。

对系统式（7-41）加入微扰 $d\cos((\omega + \Delta\omega)t + \phi)$ 后，系统形式为式（7-43）。取 $\Delta\omega = 0.01\text{rad/s}$，$d = 0.03\text{N}$，计算出的 Lyapunov 指数曲线如图 7-21。在终了时间 $t = 3\,000\text{s}$ 时 $\lambda_1 = 0.030261$，维数 $D = 2.0703$。图 7-22 是图 7-21 的时序图，表现了明显的间歇混沌。由于计算误差的累积，图 7-21 与理论值有偏差。

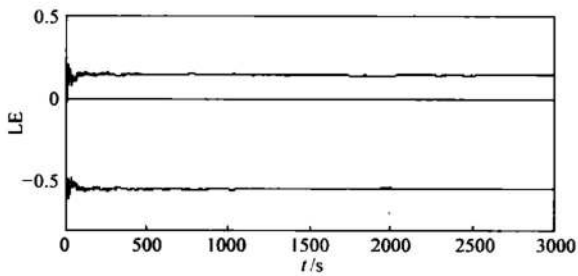

图 7-20 混沌系统 Lyapunov 指数曲线

将上面所求解的混沌状态和间歇混沌状态的 Lyapunov 指数曲线在同一个图形窗口中进行比较，如图 7-23，曲线 1 和 2 分别是没有微扰和加入微扰时系统的最大 Lyapunov 指数曲线。撇开过渡阶段，特别是在 60s 以后两种状态下的系统均逐渐稳定，能够观察到不同状态下的最大 Lyapunov 指数明显不同。

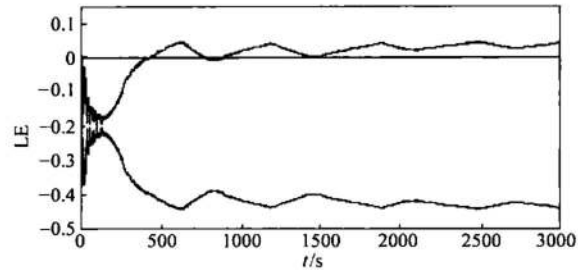

图 7-21　混沌系统在微扰下的 Lyapunov 指数曲线

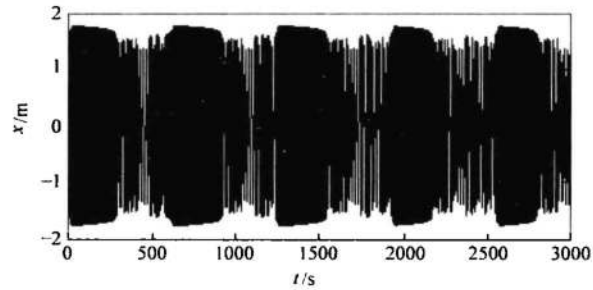

图 7-22　图 7-21 的 t-x 图

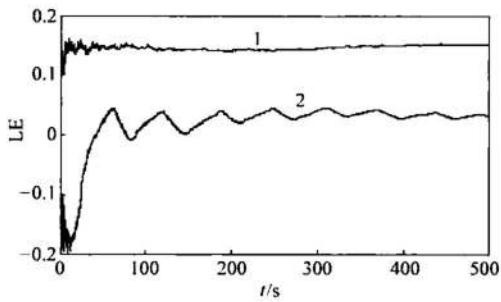

图 7-23　两种不同状态下的系统最大 Lyapunov 指数图

给出确定的混沌 Duffing 系统，先计算出它的最大 Lyapunov 指数，以此为参照，计算出有信号加入时的最大 Lyapunov 指数并与前者做比较，就能直观地判断出是否有微弱信号的输入。这是本章最大 Lyapunov 指数法用于弱信号检测的核心思想。

改变初始状态和步长，再观察弱信号对系统式（7-41）的最大 Lyapunov 指数的影响。取初始状态（0，0），$a=0.4\text{N}\cdot\text{s/m}$，$h=0.01\text{s}$，$t=5000\text{s}$。此时的 Lyapunov 指数如图 7-24 所示。当 $f_r=0.671\text{N}$ 时，$\lambda_1=0.15368$，$D=2.2776$；当 $f_r=$

0.672N 时，$\lambda_1 = -0.032344$，并且从图 7-24b 中可以看出，经过较长时间跃变到了周期状态。可求出系统从混沌状态跃变到周期状态的阈值为 f_c 在 0.671 ~ 0.672N 之间。

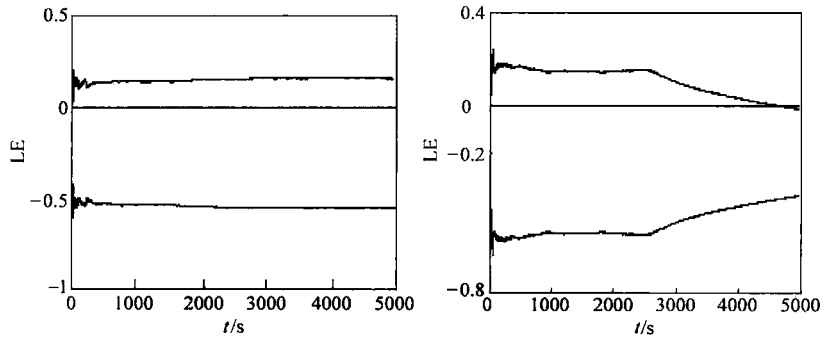

图 7-24 基于 Lyapunov 指数确定相变阈值

a) $f_r = 0.671$N b) $f_r = 0.672$N

确定了阈值后再进一步来检测微弱信号。取 $f_r = 0.668$N 稍小于 f_c，让系统处于混沌状态。当 $t = 5000$s，得到 $\lambda_1 = 0.15571$，$D = 2.2802$，如图 7-25 所示。

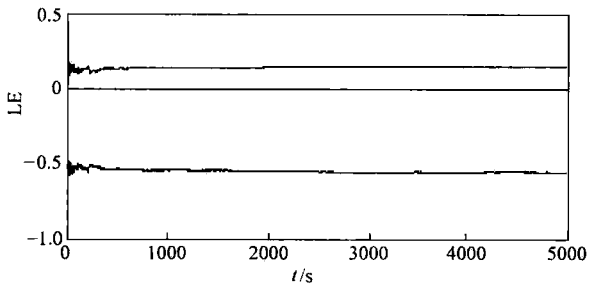

图 7-25 $f_r = 0.668$N 时系统的 Lyapunov 指数曲线

加入微扰信号 $d\cos((\omega + \Delta\omega)t + \phi)$，其中 $d = 0.03$N，$\Delta\omega = 0.03$rad/s，$\phi = 0$，$t = 5000$s，计算得到 Lyapunov 指数曲线如图 7-26，$\lambda_1 = 0.007796$，$D = 2.0191$。图 7-26 的右图是对左图最大 Lyapunov 指数的局部放大，图中可以看出最大 Lyapunov 指数在正负值间周期变化，表现为间隙混沌运动的典型特征。

为了将初值为（0，0）、$h = 0.01$s 时和初值为（0.1，0.1）、$h = 0.005$s 时的 Lyapunov 指数曲线作比较，分别将不同初值和步长下的混沌与微扰的 Lyapunov 指数曲线计算出来绘于同一幅图中，如图 7-27 所示。图中，曲线 1 和 2 分别是初值为（0.1，0.1）、$h = 0.005$s 时没有微扰和加入微扰时系统的最大 Lyapunov 指数曲

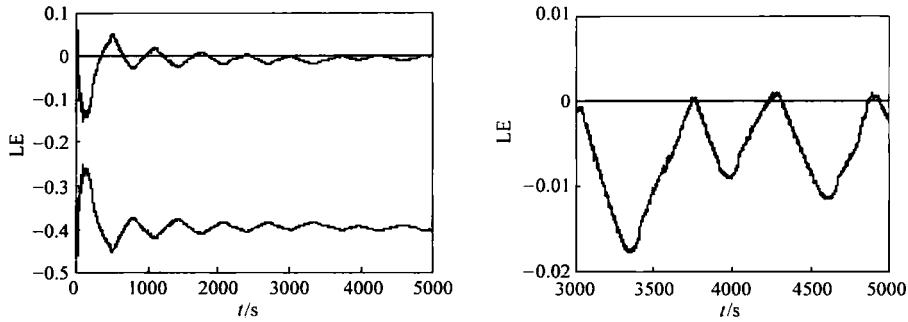

图 7-26　微扰状态下的 Lyapunov 指数曲线

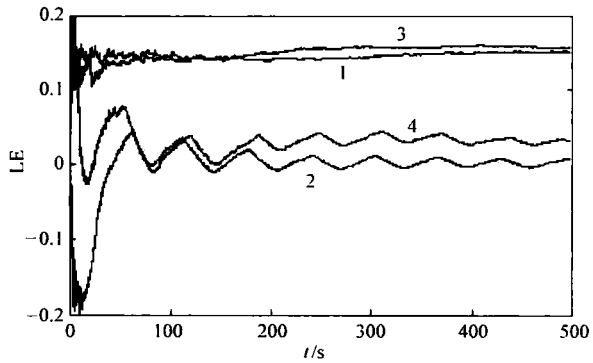

图 7-27　不同初值和步长条件下最大 Lyapunov 指数法对比图

线；曲线 3 和 4 分别是初值为（0，0）、$h=0.01$s 时没有微扰和加入弱信号时的最大 Lyapunov 指数曲线。

经过仿真可以看出，改变初值和步长对 Lyapunov 指数法判断系统状态没有影响，混沌状态和加入微弱信号后的 Lyapunov 指数曲线明显不同，验证了 Lyapunov 指数法进行微弱信号检测的正确性与可行性。

7.4　基于最大 Lyapunov 指数法的液压泵故障诊断实验

本节对某材料实验机液压伺服系统中的液压泵进行状态监测与故障诊断实验研究。人为模拟故障，将斜轴式柱塞泵的七柱塞中的一个进行脱靴处理。轴向柱塞泵型号及参数为：MCY14-B，7 柱塞，理论排量 10mL/r，公称压力 25MPa，驱动电动机 Y132M-4，额定转速 1500r/min。油压传感器为 ACY5-7F，测量范围 0 ~ 25MPa。对柱塞泵正常运转和单柱塞脱靴故障状态的泵出口压力信号进行采集和分析，计算出最大 Lyapunov 指数，进行故障诊断。

7.4.1 基于杜芬方程的最大 Lyapunov 指数故障诊断

人为模拟单柱塞脱靴故障，将主溢流阀压力调为 2MPa、3MPa，电机调至额定转速 1500r/min，对系统中轴向柱塞泵出口油压信号进行了采集。

（1）阈值确定　本文处理的数据是液压泵在正常工作和发生单柱塞脱靴故障时，采集到的液压泵出口压力脉动信号。电动机工作转速为 1500r/min，采样频率选为 10kHz。采用式（7-41）的杜芬方程对柱塞泵进行状态检测，取 $a=0.3\text{N}\cdot\text{s/m}$。由于柱塞泵的脱靴故障特征频率为 $f_e=25\text{Hz}$，取 $\Delta\omega=\dfrac{\omega_e-\omega_0}{\omega_0}=\dfrac{f_e-f_0}{f_0}=\dfrac{25-f_0}{f_0}=0.015$，满足 $\Delta\omega=0.015<0.03$，从而求出 $f_0=24.6\text{Hz}$。对假想内驱动信号进行时标扩展 ω_0 倍，就变成与内驱动信号 $f_r\cos t$，具有微小频差的摄动信号变为 $d\cos[(1+\Delta\omega)t+\phi]$。时标的扩展是通过调节算法步长 h 来实现的。下面通过计算算法步长 h 来对时标进行扩展。

从式（7-41）中看出，$\omega=1\text{rad/s}$，频率 $f=1/(2\pi)\text{Hz}$。采集信号的 A/D 卡的采样频率 f_s 为 10kHz，所以在角频率为 ω_0 的外界信号的一周内采样点数为 $n=f_s/f_0$，在 n 和 h 之间有：$n\cdot h=2\pi/\omega=1/f=2\pi$。所以在内驱动信号 $f_r\cos t$ 的一个周期（2π）内，Runge-Kutta 算法步长为

$$h=2\pi/n=2\pi f_0/f_s=0.0154\text{s}$$

用 Lyapunov 指数法，求得在初始状态（0，0），$a=0.3\text{N}\cdot\text{s/m}$，$h=0.0154\text{s}$ 时系统相变阈值 f_c 为 0.528N～0.529N 之间。

（2）信号检测与故障诊断　取 $f_r=0.520\text{N}$，稍小于 f_c。A/D 采集卡采样频率 f_s 为 10kHz，将采集到的主溢流阀调定压力为 2MPa、3MPa 工况下的柱塞泵出口压力信号分别加入方程，用改进 QR 分解算法求出系统的最大 Lyapunov 指数曲线。

图 7-28 和图 7-29 分别为采集到的正常压力信号和故障压力信号的原信号，故障信号经平移压缩后如图 7-30 所示。

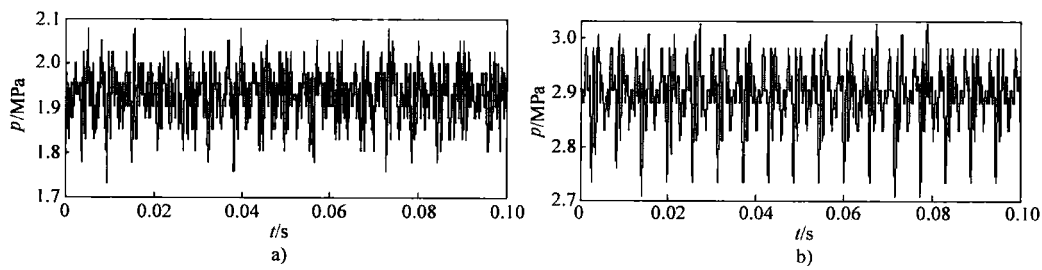

图 7-28　正常压力信号

a）$p=2\text{MPa}$　b）$p=3\text{MPa}$

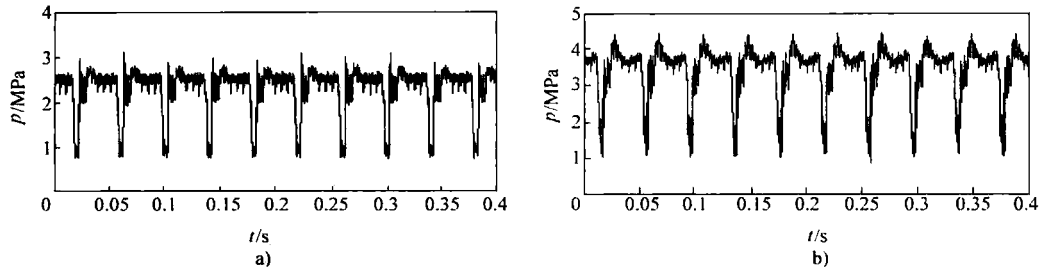

图 7-29　故障压力信号

a）$p=2$MPa　b）$p=3$MPa

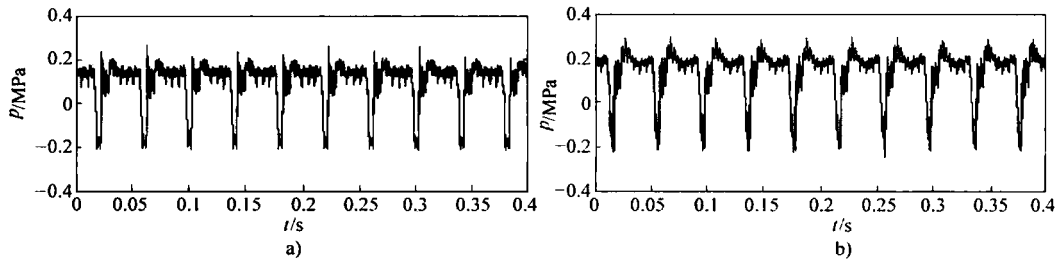

图 7-30　平移压缩后的故障信号

a）$p=2$MPa　b）$p=3$MPa

将平移压缩后的故障信号加入到 Duffing 方程系统式（7-41）中，计算出 Lyapunov 指数。图 7-31 所示为 2MPa 下的正常信号与故障信号的最大 Lyapunov 指数曲线。

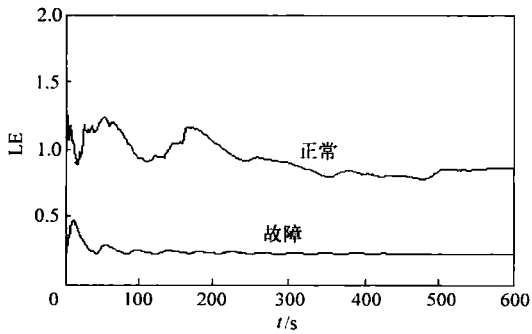

图 7-31　$p=2$MPa 时的正常信号与故障信号的最大 LE 曲线

如图 7-32 为正常工作、故障发生时压力信号的最大 Lyapunov 指数对比图。从图中可以看出，在采样频率相同情况下，正常信号对应的最大 Lyapunov 指数没有

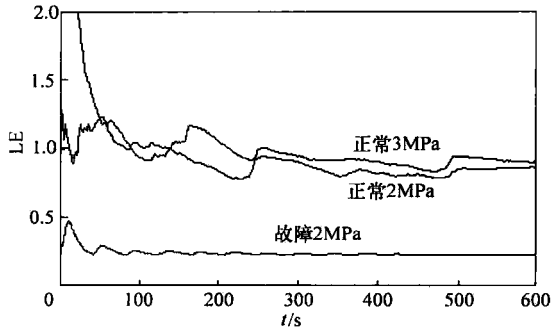

图 7-32 正常状态与
故障状态最大 Lyapunov 指数对比

大区别，但是却和故障信号对应的最大 Lyapunov 指数有较大区别。

7.4.2 结果分析

由图 7-31、图 7-32 能看出，相同采样频率时，柱塞泵在不同运行状态下，其最大 Lyapunov 指数表现出明显的不同。当柱塞泵发生脱靴故障时，由于单柱塞脱靴的影响，泵每转一周，有一次压力突降，造成泵每转一周有一次冲击振动。压力脉动信号将在相空间趋于某一有限维吸引子，计算得到的最大 Lyapunov 指数将小于正常状态下的最大 Lyapunov 指数。

因此，将最大 Lyapunov 指数作为识别柱塞泵运行状态的特征量，是一个有效可靠的新方法。该方法的研究也为其他复杂旋转机械故障诊断与监测提供了新途径。

参 考 文 献

[1] 韦岗，陆以勤，欧阳景正．混沌、分形理论与语音信号处理［J］．电子学报，1996，24（1）：34-39.

[2] 张培琨，张纪岳．三次谐波系统动态行为的 Lyapunov 指数分析［J］．量子电子学报，1997，14（6）：487-492.

[3] 李英，刘豹，马寿峰．交通流时间序列中混沌特性判定的替代数据方法［J］．系统工程，2000，18（6）：54-58.

[4] 李开富，李立．双杆摆机构中混沌现象的数值分析［J］．机械科学与技术，2002，21（4）：596-599.

[5] F E Udwadia，H F Bremen. Computation of Lyapunov characteristic exponents for continuous dynamical systems［J］. Math Phys，2001，53：123-146.

[6] T A Bartler. Lyapunov exponents and chaos investigation［D］. Cincinnti：University of Cincinnati，1999：24-35.

[7] A Wolf, J B Swift, H L Swinney and et al. Determining Lyapunov Exponents from a Time Series [J]. Physica D, 1985, 16: 285-317.

[8] Guanyu Wang, Dajun Chen, Jianya Lin. The application of chaotic oscillators to weak signal detection [J]. IEEE Transaction on Industrial Electrons, 1999, 46 (2): 440-444.

[9] 张焰明. 基于 Lyapunov 指数分析的液压泵故障诊断方法及实验研究 [D]. 秦皇岛: 燕山大学, 2007: 49-67.

[10] 姜万录, 张淑清, 王益群. 基于混沌和小波的故障信息诊断 [M]. 北京: 国防工业出版社, 2005.

[11] 姜万录, 张焰明, 王海军. 基于 Lyapunov 指数分析的液压泵故障诊断方法研究 [J]. 机床与液压, 2008, 36 (3): 183-184.

第 8 章　液压油污染度在线监测系统

本章介绍所研制的油液污染在线监测系统。该系统以特制滤膜为敏感元件，以恒功率淤积法为技术原理，结合计算机技术在测量与监测方面的应用，研制出一套基于 MCGS 工控组态软件的油液污染度在线监测系统。利用设计的监测平台实现了压差数据的采集和存储以及超限报警等功能，给出了污染度等级检测结果报告。通过对标准污染度的油液进行标定实验，建立了本系统的污染度数学模型，对实际油液进行在线监测实验，验证了该模型的正确性。

8.1　油液污染监测技术

8.1.1　油液污染问题概述

从 20 世纪 50 年代以来，液压技术因其具有传动装置体积小、重量轻、结构紧凑、响应速度快，便于实现自动化，无级调速范围大等优点，广泛应用于航空、航天、航海、国防、军事及钢铁、工程机械等工业领域，而且仍在继续拓展其应用范围。然而，在液压技术发展过程中，始终受到两个难题的困扰：一是泄漏，二是污染。尤其是液压系统的污染问题，几乎每套液压系统都存在。特别是对于精度要求非常高的液压伺服控制系统来讲，污染控制显得更为重要。

随着液压工业的发展，现代液压系统日趋复杂、精密和高性能，同时对液压油液的清洁度要求也越来越高。由于液压油的污染而引起的液压系统发生故障和寿命降低的比例很高。现有文献资料表明，由于液压油的污染而造成的故障占液压系统故障的 80% 以上，其中 75% 以上是固体颗粒的污染。液压系统油液污染已成为发展高质量液压元件和液压系统的主要障碍。因此，对液压系统的油液污染控制问题进行广泛而深入的研究，具有重要的理论和工程实际意义。

液压系统油液中存在着各种各样的污染物，如固体颗粒、空气、不相容液体、水、微生物、化学制品、腐蚀、辐射、静电等，其中固体颗粒是最主要的。这些污染物的存在严重影响着液压系统和元件的性能、使用寿命和工作可靠性。因油液污染使液压系统产生故障或损坏的形式可概括为三种：性能不稳定、元件损坏和性能劣化。前两种故障瞬时呈现，是污染直接影响的结果；后一种形式往往不引人注意，它是污染物作为媒介产生恶性磨损过程的结果。英国流体动力协会就清洁度与液压泵可靠性的关系进行过调查，结果发现，当油液清洁度等级高于 NAS9 级时，

液压泵基本不出现故障；当油液清洁度为 NAS10～11 级时，泵偶尔出现故障；当油液清洁度低于 NAS12 级时，泵则需要经常维修。日本学者曾对液压系统的故障进行了调查，结论是：因液压油的污染而造成的故障占 82%，机械故障占 15%，电气故障占 3%。类似的研究表明，100 起飞行事故中，有 20 起是由于油液污染引起的。

由此可见，液压系统油液污染对液压系统及液压元件的使用寿命和工作可靠性所造成的影响及其危害是相当严重的。因此，如何减少、控制和在线监测油液的污染程度，对于延长液压元件的使用寿命、提高液压系统的工作可靠性具有十分重要的意义。

8.1.2　油液污染度的评定与测定方法

1. 评定方法

油液中的污染物根据其物理状态可分为固态、液态和气态三种类型。固态污染物通常以颗粒状态存在于系统中；液态污染物主要是外界侵入系统的水；气态污染物主要是空气。在以上的各类污染物中，固态污染物是液压和润滑系统中最普遍、危害最大的污染物。固态污染物会导致泵、阀等元件的磨损和堵塞，使控制元件动作失灵而引起液压故障。美国麻省理工学院的 Rabinowicz 博士经过研究发现，设备的功能失效有 70% 是由于表面损坏所导致的。在液压及润滑系统中，功能失效的 50% 是源于机械磨损，其中的磨粒磨损、疲劳磨损和冲刷磨损都是由于固体颗粒引起的。因此，采取有效的措施减少油液中的固体污染物，成为污染控制的重要方面，而对固体污染物的检测也成为液压系统油液污染程度检测的主要内容。

就固体颗粒污染物而言，首先要确定反映污染物特征的要素，如颗粒尺寸大小、尺寸分布、颗粒状况、组成成分、破碎强度、硬度、浓度、团聚性、堆积性、沉降性、悬浮度和漂移度等，然后针对这些要素进行检测。然而，由于液压系统的油液是封闭在管路中的，看不见，摸不着，运动状态也相当复杂；而且在不同系统类型、不同工况条件下，液压系统中的污染物成分相差很大，可以说要将上述描述污染物特性的参数全部真实地检测出来，至少在目前的技术条件下是困难的，而且在某种意义上来说也是没有必要的。因此，选择其中能够代表油液污染状况并对液压元件的污染故障起最主要作用、具有代表性的某些指标进行检测，可使检测工序简化。根据掌握的资料，目前国际上比较公认的是采用污染物的质量浓度和颗粒浓度作为油液污染度的评定方法，即用称重法和颗粒记数法来反映污染物对系统和元件的危害程度。

所谓称重法是测量单位容积油液中所含颗粒的重量。颗粒记数法是测定油液中各种尺寸的颗粒污染物的颗粒数，准确反映了颗粒尺寸和颗粒分布。与颗粒记数法相比，称重法所需测试装置简单，操作简便，但实验时间过长，环节多，只能反映

出油液中颗粒污染物的总量，不能反映颗粒的大小和尺寸分布。

2. 测定方法

20 世纪 50 年代以前，国际上还没有很好的办法来测定油液的污染度。自 60 年代以来，世界上一些主要工业发达国家，如美、日、英、德、法等先后开展了对液压系统油液污染与控制这一领域内的有关问题的研究。在污染颗粒检测与分析方面，国内虽然起步较晚，但也取得了很大的成绩，研制了各种形式、性能各异的污染分析检测仪器，对污染物进行了数量、尺寸及危害等特性进行了较深入的研究，出现了各种污染物检测分析方法，主要包括：

称重法——精密天平；

颗粒记数法——手动显微镜（光学显微镜法），
自动颗粒记数法（遮光原理、光散射原理、电阻原理），
自动显微镜法（计算机图像分析法）；

光测法——透射光检测，
透射光、反射光共同检测，
浊度法（透射光、散射光共同检测）；

电测法——电阻法（电导率变化），
电容法（介电常数变化）；

超声波法——超声波发生器（超声波的反射能量变化）；

淤积法——滤膜孔隙法（恒压差、恒流量），
机械缝隙法；

分析比较法——油液物理、化学分析与观察对比；

目测法——滤纸油斑试验法。

8.1.3 油液污染检测技术的研究现状和发展趋势

近年来，由于液压传动一直面临着其他能量传动形式的激烈竞争，液压行业不断努力提高产品质量和完善污染控制技术，以提高液压系统的工作可靠性。在此期间，国外液压设备油液的平均污染度等级降低了约 5 级（ISO4406），相当于油液中的污染物含量减小到原来的 1/32，液压系统污染得到了有效地控制，工作可靠性显著提高，从而进一步促进了液压技术的发展和应用。

我国从 20 世纪 80 年代初在各个工业部门逐步推行液压污染控制技术和管理措施，在机械、煤炭、航空和船舶等工业部门相继开展了液压系统污染控制方面的应用研究，并取得了一定的成效。但目前我国的液压污染控制技术和管理水平与国外主要发达国家相比还有相当大的差距。液压设备的油液污染度一般比国外高 3～4 倍，从而使得设备故障率高，元件寿命短，严重影响设备效能的充分发挥。由此可见，我国液压污染控制方面的研究仍是一个薄弱环节，亟待加强和完善。

通过对部分国内外现有的研究成果的分析，现有的油液污染分析检测方法和技术具有以下一些特点：

检测原理、方法多样，检测仪器性能各异，结构形式繁多，在各种不同的场合有一定的适用性，但多数的检测仪器都属于离线检测，设备复杂、成本高、测定方法繁琐，过分依赖人来获得数据和进行信息处理，检测周期长，对于远离实验室的现场液压设备，不能做到实时在线监测。而在线式的自动颗粒计数器由于价格高而不能普遍应用于现场液压系统中。

可以预计，在研究新型检测原理和方法的同时，研究和开发新型的在线检测仪，并把计算机技术应用于油液污染检测系统，将成为今后油液污染检测的研发热点，这对于实现仪器的多功能、自动化和在线检测，达到快速检测，减少操作者的重复劳动，提高检测精度，扩大应用范围等将具有十分重要的意义。

8.2　油液污染控制技术

8.2.1　油液污染度的等级标准

油液污染度是评定油液污染程度的一项重要指标。油液污染度是指单位体积油液中固体颗粒物的含量，即油液中固体颗粒污染物的浓度。对于其他污染物，如水和空气，则用水含量和空气含量表述。

目前油液污染度主要采用以下两种表示方法：

（1）质量污染度　单位体积油液中所含固体颗粒污染物的质量，一般用 mg/L 表示。

（2）颗粒污染度　单位体积油液中所含各种尺寸的颗粒数。颗粒尺寸范围可用区间表示，如 5 ~ 15μm，15 ~ 25μm 等；也可用大于某一尺寸表示，如 >5μm，>15μm 等。此外，油液污染度也可以用百万分率（10^{-6}）表示，如质量百万分率或体积百万分率。

质量污染度表示方法虽然比较简单，但不能反映颗粒污染物的尺寸和分布，而颗粒污染物对元件和系统的危害作用与其颗粒尺寸分布及数量密切相关。因此，随着颗粒计数技术的发展，目前已普遍采用颗粒污染度的表示方法。

为了定量评定油液的污染程度，世界各主要工业国都制定有各自的油液污染度等级标准，近年来已趋向采用统一的国际标准。目前，国内外广泛采用的油液污染度等级标准有 ISO4406 国际污染度等级标准、美国 NAS1638 污染度等级标准及美国 SAE749D 污染度等级标准等。

1. NAS1638 污染度等级标准

NAS1638 是美国航天工业部门 1964 年提出的，目前在世界各国仍广泛采用。

它以颗粒浓度为基础，按照 100mL 油液中在 5～15μm、15～25μm、25～50μm、50～100μm 和 >100μm 这五个尺寸区间内最大允许颗粒数划分为 14 个污染度等级，见表 8-1。从表中可以看出，相邻两个等级的颗粒浓度比为 2，因此，当油液污染浓度超过表中最大的 12 级时，可用外推法确定其污染度等级。

表 8-1 NAS1638 污染度等级（100mL 中的颗粒数）

等 级	等级颗粒尺寸/μm				
	5～15	15～25	25～50	50～100	>100
00	125	22	4	1	0
0	250	44	8	2	0
1	500	89	16	3	1
2	1 000	178	32	6	1
3	2 000	356	63	11	2
4	4 000	712	126	22	4
5	8 000	1 425	253	45	8
6	16 000	2 850	506	90	16
7	32 000	5 700	1 012	180	32
8	64 000	11 400	2 025	360	64
9	128 000	22 800	4 050	720	128
10	256 000	45 600	8 100	1 440	256
11	512 000	91 200	16 200	2 880	512
12	1 024 000	182 400	32 400	5 760	1 024

2. ISO4406 污染度等级标准

ISO4406 污染度国际标准采用两个数码表示油液的污染度等级，前面的数码表示 1mL 油液中尺寸大于 5μm 的颗粒数的等级，后面的数码表示 1mL 油液中尺寸大于 15μm 的颗粒数的等级，两个数码之间用斜线分隔。例如，污染度等级 18/13 表示油液中大于 5μm 的颗粒数等级为 18，每毫升颗粒数在 1300～2500 之间；大于 15μm 的颗粒数等级为 13，每毫升颗粒数在 40～80 之间。

表 8-2 为 ISO4406 污染度等级和相应的颗粒浓度。根据颗粒浓度的大小共分 26 个等级，颗粒浓度愈大，代表等级的数码愈大。

ISO4406 污染度等级标准选择具有特征性的两个尺寸：5μm 和 15μm。一般认为，5μm 左右微小颗粒的浓度是引起液压系统淤积和堵塞故障的主要因素，而大于 15μm 的颗粒浓度对元件的污染磨损起着主导的作用。因而以这两个尺寸的颗粒浓度作为制定等级的标准，可以比较全面地反映不同大小的颗粒对系统的影响。

表 8-2　ISO4406：1987 污染度等级

等　级	颗粒浓度（颗粒/mL）	等　级	颗粒浓度（颗粒/mL）
0.8	0.005	12	40
0.9	0.01	13	80
1	0.02	14	160
2	0.04	15	320
3	0.08	16	640
4	0.16	17	1 300
5	0.32	18	2 500
6	0.64	19	5 000
7	1.3	20	10 000
8	2.5	21	20 000
9	5	22	40 000
10	10	23	80 000
11	20	24	160 000

3. SAE749D 污染度等级标准

SAE749D 污染度等级标准是由美国汽车工程师协会于 1963 年提出的，它以颗粒为基础，按照 100mL 油液中 5～10μm、10～25μm、25～50μm、50～100μm 和大于 100μm 五个尺寸范围内的最大允许颗粒数划分为 7 个等级，见表 8-3。

表 8-3　SAE749D 污染度等级（100mL 中的颗粒数）

污染度等级	颗粒尺寸范围/μm				
	5～10	10～25	25～50	50～100	>100
0	2 700	670	93	16	1
1	4 600	1 340	210	26	3
2	9 700	2 680	350	56	5
3	24 000	5 360	780	110	11
4	32 000	10 700	1 510	225	21
5	87 000	21 400	3 130	430	41
6	128 000	42 000	6 500	1 000	92

目前采用的 NAS1638 和 ISO4406：1987 污染度等级标准的最小颗粒尺寸范围为 5μm。遗憾的是，ISO4406：1987 标准未报告小于 5μm 的记数，它反映了非常细小的淤泥尺寸的颗粒的明显聚集。随着现代液压技术的发展，对油液污染控制的要求进一步提高，绝对精度 1～3μm 的高精度滤油器已应用于清洁度要求高的液压

系统。因此，对 ISO4406：1987 提出修改意见，建议增加一个反映大于 2μm 颗粒污染等级的数码，采用 3 个数码表示油液污染度。例如，22/18/13，以上数码分别表示 >2μm，>5μm 和 >15μm 的颗粒浓度。目前已有一些国外厂家（如 Pall 和 Vickers 公司）在自己的污染度等级代码中增加了对大于 2μm 颗粒数目的描述，这样对油液中的微粒污染物（1～5μm）的含量亦可有所了解。

最近对 ISO4402“液体自动颗粒计数器的校准”进行了修改。新的校准方法（ISO11171）已制定，采用新的校准方法提高了颗粒分析的准确性，但同时带来了颗粒尺寸重新定义的问题。过去用 ISO4402 校准方法测定的颗粒尺寸 2μm，5μm 和 15μm，而用新的校准方法则为 4.6μm，6μm 和 13.6μm。为此，最近对 ISO4406 进行了修改和完善，修改后的 ISO4406：1999 规定：对于自动颗粒计数器记数的污染度等级采用 >4μm，>6μm 和 >14μm 三个尺寸范围的颗粒浓度等级来表示。对于显微镜记数法，仍用 >5μm 和 >15μm 的颗粒浓度等级来表示。

8.2.2 油液的污染分析

1. 污染物种类与特性

（1）污染物种类　液压系统油液中的污染物是指油液中不希望有的并对系统有危害的物质。从广义上来说，可分为物质型的污染物和能量形式的污染物两大类。

实际液压系统油液中的物质型污染物主要有固体颗粒、水、空气、化学物质和微生物等。物质型污染物以气体、液体和固体三种物理状态存在于油中。气体污染物可以呈溶解状态，或者作为气泡或气团的形式混杂于油液中。液体污染物根据它的密度和它与基础液体相溶性的不同，可以是游离状态、溶解于基础油或使基础油成为乳化液三种形式。液体本身和所有没有一定形状的凝聚性物质，如黏胶、沥青和所有的微生物残骸之类的沉淀物都属于液体污染物这个范畴。固体污染物通常以微粒状态出现，通称为颗粒。

在液压系统中存在的辐射、静电、腐蚀、磁场和热能等是一类属于能量形式的污染物。静电可以对元件造成电流腐蚀，并且可能引起矿物油的挥发物碳氢化合物燃烧而造成火灾。磁场的吸力可使铁磁性磨屑吸附在零件表面或间隙内，引起元件的污染磨损和堵塞卡紧等故障。系统中过多的热能使油温升高，引起油液润滑性能下降和元件泄漏增大，并加速油液变质和密封老化失效。

（2）固体颗粒污染物的特性　表征液压油中固体颗粒污染物特性的主要参数为：污染物的密度、硬度、形状、尺寸及尺寸分布等。这些特性与元件的污染磨损和工作可靠性有密切的关系。特别是颗粒的形状、尺寸和尺寸分布是与污染控制有关的重要因素。

1）颗粒形状和尺寸：固体颗粒的形状是多种多样的，如多面体状、球状、片

状、针状和纤维状等，一般都是不规则的。为了定量描述固体颗粒污染物的大小，一般用代表其形状特征的尺寸来表示。形状规则的颗粒（球形体、正方体等），可用球体的直径、正方体的边长描述。形状不规则的颗粒，则可以根据不同的测量方法及所需反映的形状特征用不同特征尺寸来表示。例如，用显微镜测量颗粒大小时，一般以颗粒的最大长度作为颗粒的尺寸；用光电装置测量颗粒尺寸时，以与投影面积相等的圆的直径（导出直径）表示颗粒的尺寸等。

2）颗粒尺寸分布：常见的固体颗粒物一般是由不同尺寸颗粒组成的颗粒群。颗粒群中各种尺寸颗粒的数量即称之为颗粒尺寸分布。在分析研究颗粒尺寸分布时，通常采用频率分布函数。分布函数可用作矩形图的方法求得。常见的颗粒尺寸分布规律有正态分布、对数正态分布和罗辛-拉姆勒尔（Rosin-Rammler）分布。

自然界中的粉尘或实际液压系统油液中的颗粒污染物尺寸很少呈正态分布。特别是在液压系统中，由于小颗粒生成率高，数量多，因而分布曲线向小颗粒尺寸方向偏斜。图 8-1 是用普通坐标表示的正态分布与实际系统中的颗粒尺寸分布。当液压系统在最初的使用阶段，即污染物开始生成阶段，一般呈常规的尺寸分布状态（正态尺寸分布）：但当污染颗粒使液压元件运动表面不断地磨损时，颗粒分布曲线呈非对称分布，小尺寸颗粒的比例增加，这是由于小尺寸粒子不断增加的缘故。

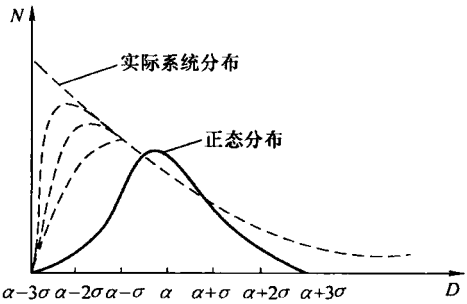

图 8-1　正态分布与实际系统颗粒尺寸分布

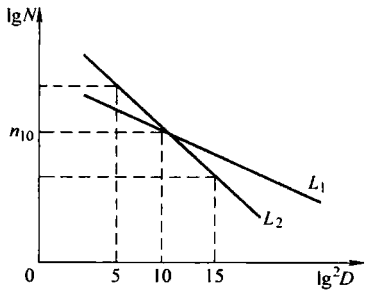

图 8-2　lgN-lg^2D 颗粒尺寸分布

研究表明，实际液压系统中颗粒污染物的尺寸分布比较接近对数正态分布。目前在液压系统污染控制中普遍采用修正的对数正态分布。这种分布具体表示如下：将颗粒计数得到的大于某一尺寸的累计颗粒数绘在 lg-lg^2 坐标纸上，横坐标为颗粒尺寸的对数平方（lg^2D），纵坐标为累计颗粒数的对数（lgN）。采用这种表示方法的主要优点是可以直接读出不同尺寸范围的颗粒数，而尺寸分布基本上符合线性规律。

图 8-2 是根据 lg-lg^2 坐标绘制的颗粒尺寸分布，它广泛应用于液压系统污染控制中描述颗粒污染物的尺寸分布。图 8-2 中 L_1 和 L_2 为两个油样中颗粒污染物的尺寸分布，它们具有相同的污染物质量浓度，但颗粒尺寸分布不同。油样 L_1 中颗粒

尺寸分布宽，大颗粒数量多，而油样 L_2 中小颗粒较多。

2. 油液污染的原因

液压油的污染是由外部原因和内部原因共同造成的。外部原因主要是固体杂质、水分、其他油类及空气等进入系统；内部原因是在使用过程中相对运动零件的磨损和液压油理化性能的变化等。由于导致污染杂质侵入的各种因素的影响，液压油液可能受到不同程度的污染。根据杂质的侵入方式不同，污染可分为三种类型，即潜在污染、侵入污染及再生污染。污染类型及造成污染的具体原因如表 8-4 所示。

表 8-4 液压系统油液污染类型及原因

污染类型	污染原因
潜在污染	自制件中残存污染物 外购件中潜伏污染物
侵入污染	装配时侵入污染物 使用过程侵入污染物 液压油带入污染物 修理时侵入污染物
再生污染	零件磨损产生的污染物 液压油发生物理和化学变化的生成物及衍生物

3. 油液污染的危害

油液污染直接影响液压系统的工作可靠性和元件的使用寿命。国内外资料表明，液压系统的故障大约有 80% 是由于油液污染引起的。液压油的污染防治主要应控制固体颗粒污染物、水分和空气的混入。

4. 污染物成分分析

液压系统在工作中，从外界环境不断侵入各种污染物，并且由于元件磨损和油液劣化，从内部不断生成各种污染物。通过对油液中污染物的检测和成分分析，可以获得有关污染侵入、元件内部磨损和油液衰变的信息，为设备维护和油质管理提供依据。目前用于油液中污染物成分分析的方法主要有：光谱分析、铁谱分析和红外光谱分析等。

8.2.3 油液的污染控制

液压元件的工作寿命和可靠性主要决定于元件的污染耐受度和油液的污染度。为了确保元件的寿命和可靠性，可以通过污染控制措施使系统油液的污染度与关键液压元件的污染耐受度达到合理的平衡，这就是污染控制的基本内容和目的。

提高元件工作寿命和可靠性主要有两个途径：一是研制耐污染的元件，从改进元件的设计参数、结构和材质等方面以提高元件耐污染性能；二是采取控制污染的

措施，降低油液的污染度。经验表明，后者是一条更为经济而有效的途径。

为了有效地控制液压系统的污染，主要采取以下几个方面的措施：

1）对元件和系统进行清洗，清除加工和组装过程中残留的污染物。

2）采取防止污染物侵入系统的措施，控制从外界侵入的污染物。

3）在液压系统中采用高效能的滤油器，在工作中不断滤除内部产生的和外界侵入的污染物。

8.2.4　油液的净化

延长油液的使用寿命不仅可以节省更换油液的费用，而且更重要的是可以节约油料资源。目前有的工业现场由于污染控制措施不完善，液压系统油液污染严重以致影响设备正常工作，因而不得不采取频繁换油的办法，而实际上换下的脏油往往只是污染超限，而理化性能并没有达到劣化的程度。这类油液只需经过适当处理仍可继续使用。经验表明，通过污染控制提高油液清洁度，可以显著延缓油液性能劣化，油液的使用寿命可延长 3 ~ 5 倍。日本工业界提出，通过油液净化措施，可望使油液的使用寿命延长到 10 年。

1. *油液的净化方法*

油液中常见的污染物主要有固体颗粒、水、空气以及油液氧化和分解的产物，根据不同的污染物和对油液净化的不同要求，可采用不同的净化方法。这些方法包括：过滤、离心、惯性、磁性、静电、真空、聚结和吸附等，各种净化的原理和应用见表 8-5。

表 8-5　油液的净化方法

净化方法	原　理	应　用
过滤	利用多空隙可透性介质滤除油液中的不溶性物质	分离固体颗粒
离心	通过机械能使油液作环行运动，利用产生的径向加速度分离与油液密度不同的不溶性物质	分离固体颗粒和游离水（离心机）
惯性	通过液压能使油液作环形运动，利用产生的径向加速度分离与油液密度不同的不溶性物质	分离固体和游离水（旋流器）
磁性	利用磁场力吸附油液中的铁磁性颗粒物	分离铁磁性颗粒和磨屑
静电	利用静电场力使绝缘油液中的不溶性污染物吸附在静电场内的集尘体上	分离固体颗粒和胶状物质
真空	用在负压下饱和蒸气压的差别，从油液中分离其他液体和气体	分离游离水和溶解水，空气和其他挥发性物质
聚结	利用液体对某一多空隙介质润湿性（或亲和作用）的差异，使两种不溶性液体的混合液分离	从油液中分离游离水和乳化水
吸附	利用分子附着力分离油液中的可溶性和不溶性物质	分离固体颗粒，各种状态的水，胶状物质

2. 油液中水的分离

从油液中分离水可采用以下方法：

（1）沉积法　利用水和油液密度的差别，使油有足够长的静止时间，游离状态的水可缓缓沉积在油箱底部或排放点。根据经验，对于深度为 1m 的油箱，大约需要 50min 的静止时间。对于大多数液压系统，停止运转的时间不足以使水沉降分离出来。沉积法一般用于具有大油箱的液压系统。

（2）真空法　真空法的原理是利用油和水的饱和蒸气压的差别使水从油液中分离出来。在温度 70℃的情况下，水大约在 3×10^4Pa 压力下沸腾，而油则在大约 5Pa 的低压下才能沸腾。在此温度下，油的饱和蒸气压比水要低得多。因此，通过抽真空将油液液面的压力降低到水的饱和蒸气压以下时，则油液中的水将发生激烈的汽化，并以蒸汽的形式从油中溢出。

真空法能够有效去除油液中 100% 的游离水和 80% 的溶解水，并能去除油液中的空气和各种挥发性物质，但这种装置较复杂，处理效率较低，而且不适合于装设在液压系统内。

（3）聚结法　聚结法除水是利用水和油亲和作用的差异，将油液中的游离水、乳化状微小水珠从油中分离出来。聚结分离法设备简单，脱水效率高，处理能力大。这种方法的机理是乳化水的聚结，即从纤维层捕集极小的乳化水珠（1 ~ 5μm）到合并形成大颗粒水珠（1mm 以上）的过程。

聚结法对于粘度低和不含表面活性剂的石油基油液具有很好的除水效果。然而，对于粘度高和含有添加剂的液压油和润滑油，其除水效果目前还不够理想。

（4）吸附法　这种方法采用高吸水材料吸收油液中的游离水和乳化水。在实际使用中可将高吸水聚合物掺入并分散在过滤材料中或制成吸水纤维滤材，用这种滤材做成滤芯，用于滤油器中。在使用过程中，吸水聚合物与油液中的水相互作用形成凝胶体，体积随之增大，从而使滤芯压差增加。当压差增大到一定值时，需要更换滤芯。吸水滤芯虽然对大颗粒污染物也有滤除作用，但不应作为一般滤油器的滤芯使用。

（5）离心法　离心法利用水与油的密度的不同，在高速旋转下产生的离心力的差异，使水从油中分离出来。离心法用于分离油液中的游离水，一般只适用于水分含量较高和油液粘度较低的场合，并且脱水效果较差。

3. 油液中不溶性污染物的排除

不溶性污染物对液压系统的工作可靠性和性能影响非常大，有效去除不溶性污染物的方法主要有：机械过滤法和静电净油法。与机械过滤相比，静电净油法具有以下特点：能够有效去除油液中的微小颗粒污染物和胶状污染物，压差小，纳污容量大。经验表明，经过静电净化的油液，不仅清洁度显著提高，而且油液的其他指

标，如酸值、色度等也有所改善。

静电净油的原理是利用静电场力使油液中的不溶性污染物被吸附在静电场内的集尘体上，从而达到净化油液的目的。油液中的不溶性污染物有的带电，有的不带电。带电污染物在均匀电场中受库仑力作用，带正电荷的污染物向负极运动，带负电荷的污染物向正极运动。中性污染物在均匀电场中不向电极运动。但在非均匀电场中它受两端大小不等的作用力的作用而运动。因而在集尘体间建立足够的非均匀电场，则所有带电和不带电的污染物均有可能被集尘体吸附。

目前使用的平行板折褶集尘体静电净油机一次通过的净油效率低，液流速度受到限制。因此，这种形式的静电净油机不能适应液压系统内油液净化的要求。目前一般用于系统外，对油液进行连续循环净化。此外，静电净油法对油液的含水量有较严格的限制，一般不得超过（500～800）$\times 10^{-6}$。含水量过高将降低油液的绝缘性能，功率消耗增大。

将静电净油与深层过滤相结合，可以显著提高静电净油的效率。在电极之间充填松散或成型的疏松纤维材料，形成高梯度非均匀电场。油液从纤维介质迂回曲折的缝隙中通过，由于液流中的颗粒与集尘介质之间的距离很小，因而增大了颗粒被吸附的几率，有些颗粒甚至被纤维直接拦截。

8.3　在线监测装置研制

8.3.1　过滤的基本原理

采用滤膜截留油液中污染颗粒的测量装置的基本原理是建立在过滤理论的基础上的。过滤可定义为：含有悬浮固体颗粒的液体通过一个多孔介质时，去除悬浮液的部分或全部的微粒的过程。为使油液顺利通过过滤介质，应该在过滤介质两侧保持一定的压降。从原理上来说，这个压降是怎样得到的并不重要。重力、真空、正压力和离心力都可以作为获得压降的主推动力。过滤的基本原理如图 8-3 所示。

从过滤机理上过滤过程可分为三类：

（1）表面型过滤　用表面型过滤介质进行过滤时，由于颗粒大于过滤介质的微孔，它们就被截留在过滤介质表面。

（2）深层过滤　分离过程只发生在介质的“内部”。微粒一般都小于介质的微孔，因此这些颗粒可进入较长而弯曲的孔隙，在重力、扩散力和惯性力的作用下被收集于其中，并在分子力和重力的作用下附着在过滤介质中。

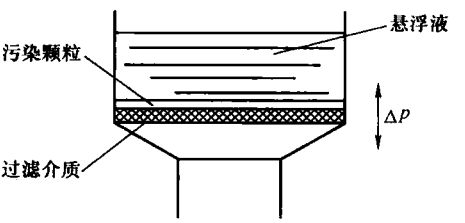

图 8-3　过滤的基本原理

（3）滤饼过滤　采用滤饼过滤时，固体物质积聚在介质的表面，经过一个很短的初始期，油液就通过沉积的固体层进行过滤。

实际过滤过程是复合式的，即若干或全部的过滤机理同时或相继发生的。例如，在表面过滤时，当多孔物质表面的滤饼形成后，就开始滤饼过滤，而深度过滤时，介质中的微孔不断缩小，直至出现表面过滤，相继也就开始滤饼过滤。本章所讲装置的过滤机理要尽量采用表面过滤过程，不允许发生深层过滤的现象，这样可以使反向冲洗后的滤膜性质与新滤膜的性质相同，而且介质的微孔性质也好控制。

选择过滤方案要考虑以下因素：要去除的固体颗粒的性质，即微粒的大小、形状和分布以及聚积的状态；流体的性质，即粘度、密度和同结构材料的互相作用等；处理物质的量；过滤过程是断续的、连续的或两者兼有；固体颗粒在悬浮液中的密集度；处理的目的；截留的是固体、液体，还是两者兼有；生成物是否要冲洗；设计用的各种材料是否能得到等。

8.3.2 过滤介质的选择

1. 过滤介质的主要特性

一般用于过滤器的介质，其主要作用是产生清洁的滤出液，并能有效地阻挡微粒物质。本章所要用的过滤介质实际是一个敏感元件。对于这种用于测量的过滤介质，根据设计方案的要求需要有以下一些主要特性：

1）微孔的孔径及微孔密度分布要均匀一致。

2）清洗性能要好，反向冲洗后要求性能不变。

3）厚度要尽可能薄，孔的形状要光滑、规整，尽量是完全表面性滤膜，以免微粒滞留在微孔内。

4）有一定的机械强度和耐化学腐蚀性能。

5）性能要稳定，即如果更换了新的滤膜，新滤膜的性能要和原滤膜的性能一致。

2. 过滤介质的选材

根据以上对过滤介质的要求，在选择过滤介质的过程中，主要对以下几种国内现有的滤材进行分析：

（1）混合纤维素酯微孔滤膜　该种滤膜存在以下问题：滤膜总体过滤精度虽然稳定，但在同一个滤膜的各个位置上的过滤精度却不同；滤膜的机械强度太低无法实现反向冲洗，不能重复使用；该种滤膜的微孔形状非常不规则，甚至接近于深层过滤介质。因此，混合纤维素酯微孔滤膜不适合用于测量装置。

（2）795#不锈钢编织网　该种滤材为金属丝斜纹编制网。编制金属丝直径为0.05mm×0.032mm（经丝×纬丝），通过粒度的参考值为11μm。这种滤网虽然有高的机械强度，反向冲洗性能亦比混合纤维素酯微孔滤膜较好，但仍存在微孔形状

不规则，容易滞留颗粒等问题。

（3）1250#不锈钢编织网　钢丝材料为：1Cr18Ni13，钢丝直径为 0.036mm × 0.025mm（经丝 × 纬丝），通过粒度参考值为 5μm。这种滤网虽然机械强度较高，但它仍是斜纹编织结构，在同一块滤材的不同位置过滤精度仍有差别。在压力较高、堵塞严重的情况下，微孔的形状及尺寸有较大的变化。

（4）特殊加工的金属滤膜　经过综合考虑，决定采用经过特殊工艺加工的金属滤膜。网孔成圆形，不会变形。检测结果表明，此种滤膜孔径的尺寸密集度较高，孔径精确度稳定，厚度均匀，可满足敏感元件的需要。过滤面积对测量结果的影响很大，要严格控制每个滤膜组件的有效过滤面积以减小过滤面积对测量结果的影响。面积差越大，测量的重现性越差。其滤膜组件的结构原理如图 8-4 所示。

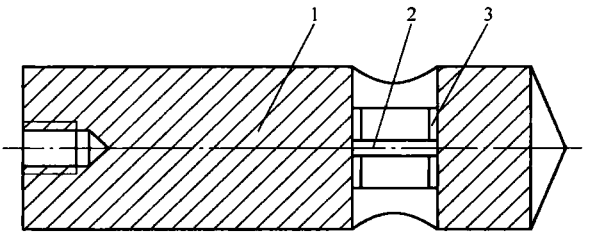

图 8-4　滤膜组件的结构原理图

1—旋转测头　2—特制滤膜　3—压紧装置

8.3.3　淤积法测量原理

污染油液流经微小间隙或滤网时，固体颗粒逐渐淤积，甚至堵塞滤网而引起压差或流量的变化，污染度不同，其变化量也不同。这就是用淤积法对油液污染进行测量的基本原理。用滤网作为敏感元件时，测量方法可分为恒压差测量和恒流量测量两种。

1. 恒压差测量法

恒压差测量是指在测量过程中保持滤网前后的压差恒定，测量某一时刻流经滤网的流量瞬时值，或测量滤网堵塞时流经滤网的流体总体积，其原理如图 8-5 所示。

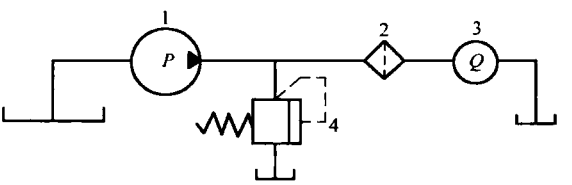

图 8-5　恒压差测量原理图

1—恒流源　2—标准滤膜　3—流量传感器　4—安全阀

美国俄克拉荷马州立大学 E. C. Fitch 教授在其论文中提出了恒压条件下，滤网平均孔径已知时的堵塞指标的详细表达式，实际上是一些经验公式，见式（8-1）。

$$S_p = \frac{(\Delta p)^{C_1}\left(\frac{u}{\phi}\right)^{Q_T}}{\left[\frac{V_T}{AX_d(Q_T+1)}\right]^{C_2}} \tag{8-1}$$

式中 S_P——平均孔径（P）已知的滤网的堵塞指标，即油液的污染度；

X_d——孔密度，即滤网单位面积上的平均孔数；

ϕ——可透性，滤网阻力 R_S 的倒数；

C_1——用对数表达的压力影响常数；

C_2——调整不同滤网结构的常数，如孔形、孔深、表面特性等；

Q_T——最终流量，即实验完成时通过滤网的最终流量；

V_T——过滤体积。

E. C. Fitch 对式（8-1）的理论组成作了如下解释：

$(\Delta p)^{C_1}$项——因通过滤网的压力降不同而产生的堵塞指标读数的差别，这一变化随压力的增加按对数减少，常数 C_1 表示对压力修正的变化率。经验数据表明，对于 10μm 的滤网，污染物为 AC 粉尘的情况下，C_1 大约为 0.3。

$(u/\phi)^{Q_T}$项——此项用于修正流体粘度和滤网可透性不同而引起的差别。最终流量越大，这些差别越显著。不过当 Q_T 达到零时粘度和可透性的影响均可消失。根据是，两种具有同一堵塞指标（污染度）的流体，但流体 A 的粘度比流体 B 的高，当最终流量达到零时，两种流体的过滤体积相等（$V_A \approx V_B$）。

$\left[\frac{V_T}{AX_d(Q_T+1)}\right]^{C_2}$ 项—过滤体积、滤网面积、孔密度和最终流量之间的影响关系，此比率通过常数 C_2 表达滤网结构和表面特性的不同。

对于 10μm 的滤网，通过实验得出了如下表达式：

$$CL_{10} = 0.985 \cdot p^{0.3} \cdot X^{-1.19} \tag{8-2}$$

式中 CL_{10}——10μm（平均孔径）滤网以 AC 细试验粉尘 mg/L 为单位的污染水平读数；

X——活塞位移（读数）以 in 为单位，表示过滤体积；

p——系统压力（psi，1psi = 6895Pa）。

美国 Dzaghetics 公司和日本国际兴业公司的便携式油液污染分析仪就是根据上述原理研制而成的。其敏感元件为精致标准网，用行程表测量活塞的位移（反映滤网堵塞时的累计过滤体积），并根据压力值一起查诺模图，即可求出油液的污染浓度、ISO 等级或 NAS 等级。该仪器即可在线检测也可独立检测，可不用电源，无

需专门清洗。之后，美国 Dzaghetics 公司对原仪器进行了改进，用单片机进行采样和数据处理。首先在计算机屏幕上显示出通过滤网的流量衰减曲线，再用工业流体等级分析法（IFDA）的数学模型将流量衰减曲线转换成正确的颗粒浓度水平，并可显示出颗粒数、ISO 等级、SAE 等级或 NAS 等级。实验表明此仪器的测试效果可以和自动颗粒计数器的平均水平媲美。

2. 恒流量测量法

恒流量测量是指检测过程中通过滤网的流量恒定，测量压差（或比值 $p_{终}/p_{始}$）达到某一预定值时的时间或测量达到某一预定时间的压差（或比值 $p_{终}/p_{始}$）。英国巴斯大学（Bath University）流体动力研究中心从事这方面的研究较早，并研制出污染水平检测装置。利用巴斯大学的研究成果，美国库尔特电子公司研制出 COULTER LCM Ⅱ型油液污染度测定仪，其工作原理如图 8-6 所示。此仪器能自动打印出油样中大于 5μm、15μm、和 25μm 的颗粒数及 ISO 等级；同时，也能打印出油液的粘度、温度等指标。换向阀换位即可实现滤网的反向冲洗，操作方便。其测量范围如下：

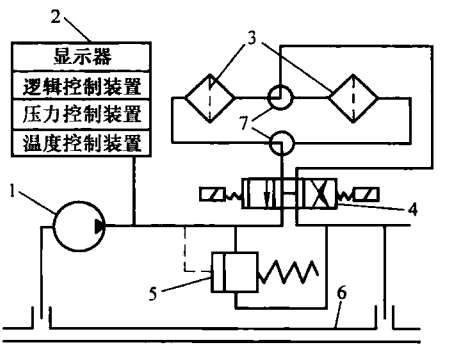

图 8-6　恒流量油液污染检测器原理图

1—定量泵　2—程控装置　3—过滤器　4—换向阀　5—溢流阀　6—主回路　7—三通阀

粒子浓度范围：5μm 以上，$10^3 \sim 10^7$ 个/100mL；

15μm 以上，$10^2 \sim 10^6$ 个/100mL；

25μm 以上，$50 \sim 5 \times 10^5$ 个/100mL；

油样温度：5 ~ 50℃；

油样粘度：10 ~ 500cSt；

最小油样量：300mL；

管路压力：在线压力 50psi（1psi = 6895Pa）以下，相当于 3.45kgf/cm^2（1kgf/cm^2 ≈ 0.1MPa）。

此仪器质量轻（仅为 12.7kg），测量精度不受油液浓度、颜色、气泡、乳剂粒子等因素的影响，且可实现在线检测。但是此仪器价格昂贵，每台约 1 万 ~ 2 万美元。在高压管路中需设专用的减压装置。标准滤膜的成本较高且使用一段时间后需要更换。油液中颗粒尺寸分布和系统中压力的波动对测量结果影响很大。

8.3.4　恒功率淤积法测量原理

下面阐述一种新颖的淤积法测量原理——恒功率测量。假设一定体积的油液在恒定功率 P 的推动下，通过一端装有滤网的特制液压缸，设滤网前的压力为 p_1，

滤网后的压力为 p_2，如图 8-7 所示。

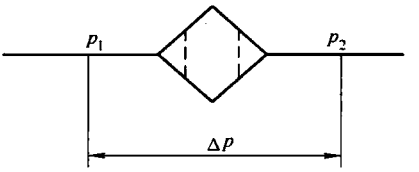

图 8-7 恒功率测量原理图

液压油液通过滤网时，由于滤网对油液的阻力而产生一定的压力损失，这样在滤网前后产生一定的压差，如果忽略活塞和活塞杆与液压缸之间的粘性摩擦力，忽略活塞和活塞杆的惯性力，则根据流体力学知识可知

$$\Delta p(t) = p_1(t) - p_2(t) = \frac{\delta \mu Q(t)}{\alpha A(t)} \tag{8-3}$$

由功率 P 与压差 $\Delta p(t)$ 和流量 $Q(t)$ 的关系式

$$P = \Delta p(t) \times Q(t) \tag{8-4}$$

由式（8-3）和式（8-4）可得

$$\Delta p(t) = \sqrt{\frac{\delta \mu P}{\alpha A(t)}} \tag{8-5}$$

和

$$Q(t) = \sqrt{\frac{\alpha A(t) P}{\delta \mu}} \tag{8-6}$$

式中 $\Delta p(t)$ ——滤网前后的压差；

δ——滤网厚度；

μ——流体动力粘度；

α——滤网的透气性；

$Q(t)$ ——油液在功率 P 推动下的瞬时体积流量；

P——恒定功率；

$A(t)$ ——滤网的瞬时有效过滤面积。

若功率 P 和待测油液的种类一定；且对于某一特定滤网，δ 为常数；假设滤网介质的透气性 α 也为常数；当油液温度一定时，μ 也为一定值。由式（8-5）与式（8-6）可知，当油液在功率 P 的推动下通过滤网时，滤网逐渐堵塞，其有效过滤面积逐渐减小。滤网前后的压差、通过滤网的流量仅与滤网的有效过滤面积有关。滤网前后的压差随着通过体积的增加而增大，如图 8-8 所示。通过滤网的流量随着通过体积的增加而减小，如图 8-9 所示。对污染程度不同的同种油液，若通过的油液体积相同时，由于被堵塞的程度不同，污染程度高的油液其压差将比污染程度低的油液的压差高，其流量将比污染程度低的油液的流量低。当油液温度变化时，μ 也变化，但式（8-5）与式（8-6）仍然成立。

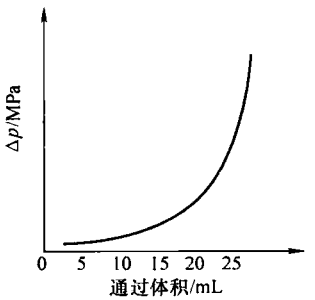

图8-8　压差与通过油液体积的关系曲线

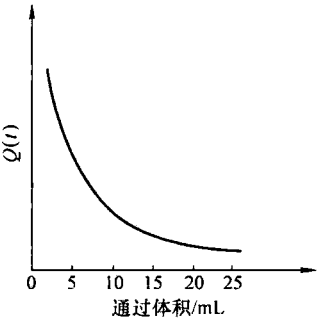

图 8-9　流量与通过油液体积的关系曲线

实际上，滤网的透气性 α 是一变数，现场油液的温度也不是一定值，但这并不影响测试的准确性。通过做大量实验，对不同温度、不同种类的污染油，当通过相同的油液体积时，测出对应不同污染等级油液的压差和流量，做一个数据库。测试时，让污染油液在恒定功率推动下通过一定有效过滤面积的特制滤网，当通过相同体积的油液时，测出滤网前后的压差或通过滤网的瞬时流量，通过查询数据库，就可以确定油液的污染等级。这就是恒功率淤积法测量油液污染度的原理。

8.3.5　利用阀用直流电磁铁作为动力元件的可行性

由过滤机理可以知道，为使油液通过过滤介质，应该在过滤介质两侧保持一定的压降。从原理上来说，这个压降是怎样得到的并不重要。重力、真空、正压力和离心力都可以作为获得压降的主推动力。因此，用阀用直流电磁铁也可以获得产生压降的主推动力，而且它换向时间短，动作迅速，能在较短时间内完成测试过程。虽然阀用直流电磁铁的额定行程比较小，一般只有几毫米，但是我们可以通过机械机构把它的行程进行放大，以满足我们的要求。

虽然它在额定行程过程中产生的推动力是变化的，其吸力与行程的关系如上图 8-10 曲线所示，而且活塞和活塞杆与液压缸之间有粘性摩擦力，在整个行程中活塞和活塞杆有惯性力，不能保证是恒压或是恒流测量。但是，如果我们通过测量从电磁铁开始通电到某一给定时间终了时的压差，就可以知道油液的污染程度。这是因为在同样的测试条件下，对不同污染程度的油液，在给定的时间间隔内，其通过的油液体积是不同的，即阀用直流电磁铁的行程不同，也就是阀用直流电磁铁产生的推力不同，因此在滤网上的压降也就不同。对污染严重的油液，由于堵塞程度大，在给定时间间隔内其通过的油液体积就少，压差也就大；同理，对污染不太严重的油液，其通过的油液体积就多，其压差也就小。根据压差的大小，通过查表，就可以确定油液的污染等级。这就是所研制的在线监测系统的测试原理。

8.3.6 颗粒尺寸分布对测量的影响

固体颗粒污染物的特性包括密度、硬度、颗粒形状与尺寸以及颗粒尺寸分布等。而颗粒的形状、尺寸以及尺寸分布是污染控制的重要因素，但它们之间的关系又是非常复杂的。下面着重分析颗粒尺寸分布对污染度测量的影响。

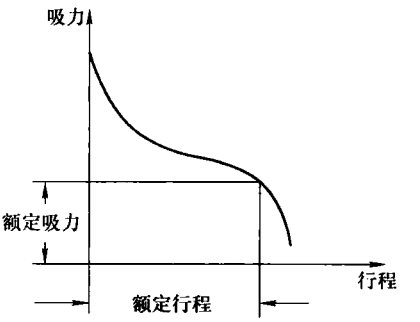

图 8-10 电磁铁的吸力特性

以标准滤膜为敏感元件进行油液污染检测时，每个敏感元件相当于一个单通道颗粒计数器，例如网孔直径为 10μm 的滤网只能检测尺寸大于 10μm 的颗粒数。而不同的油液污染等级标准往往涉及不同的尺寸范围，因此油液污染等级的转换必须考虑油液中污染物的颗粒尺寸分布。一般情况下可以把油液污染颗粒尺寸分布划为两种情况，即对数正态分布和非对数正态分布。

1. 对数正态分布

对数正态分布的污染颗粒的尺寸 D 和累计颗粒数 N（大于尺寸 D 的颗粒数）表示在 $\lg^2 D - \lg N$ 坐标系中为一条直线，如图 8-11 所示。因此，当已知污染颗粒的尺寸分布时（例如图中直线 L_1）只需作单点测量，如测 n_{10}，然后在 $\lg^2 D - \lg N$ 坐标系中找出 n_{10}点并过此点作 L_1的平行线即可得知不同尺寸范围的颗粒数。并以此为根据转换成不同的油液污染等级标准。

若污染物颗粒尺寸分布未知，那么单点测量就无法推知不同尺寸范围的颗粒数，例如图 8-12 中如果只测出 n_{10}，那么颗粒尺寸分布线即可能是 L_1也可能是 L_2或

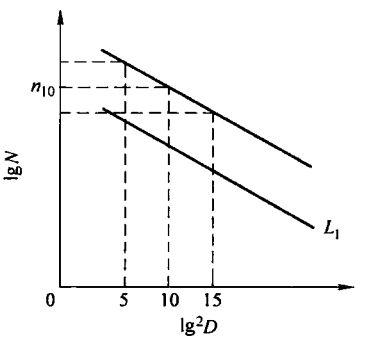

图 8-11 单点测量颗粒数的外推

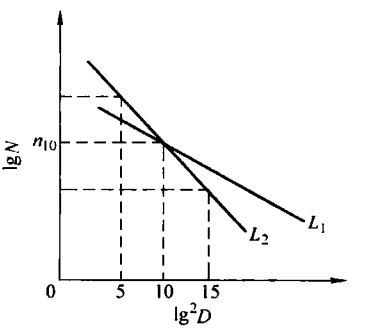

图 8-12 两点测量颗粒数的外推

其他直线，这种情况下可用两点测量法，例如测出 n_5 和 n_{15}，在坐标系中确定两点并用直线连接起来即可得到其他尺寸范围的颗粒数。

2. 非对数正态分布

对于颗粒尺寸分布与对数正态分布相差较大的情况，例如滤油器过滤后的油液的污染颗粒分布。分布曲线在 $\lg^2 D - \lg N$ 坐标系中不是一条直线，此时只有根据要求选用相应的敏感元件检测出所需尺寸范围颗粒浓度，并转换成相应的污染等级标准。

3. 实际颗粒尺寸分布与 ACFTD 的颗粒尺寸分布关系

研究表明，尽管液压（或润滑）系统油液中污染颗粒的形状、尺寸及特性千差万别，但实际液压系统中的污染颗粒尺寸分布基本上接近对数正态分布，即每毫升油液中颗粒尺寸大于某一尺寸 D 的累计颗粒数 N 在 $\lg^2 D - \lg N$ 坐标系中呈一直线。这种分布的具体确定方法如下：将颗粒计数器所得到的累计颗粒数（即大于某一尺寸范围的颗粒数）画在 $\lg^2 D - \lg N$ 坐标纸上，纵坐标为累计颗粒数的对数（$\lg N$），横坐标为颗粒尺寸对数的平方（$\lg^2 D$）。采用这种分布后，污染物的颗粒尺寸分布基本上符合线性规律，并可直接读出不同尺寸范围的颗粒数。美国俄克拉荷马州立大学流体动力研究中心得出的液压油污染水平分析图，由图可以看出各类设备的液压油中污染颗粒的尺寸分布很接近对数正态分布规律，即曲线接近线性。ACFTD 标准试验粉尘的颗粒尺寸分布与各曲线大致平行，说明各类设备液压油中污染物的颗粒尺寸分布与 ACFTD 标准试验粉尘的颗粒尺寸分布接近。这些统计规律为油液污染度的定量分析打下了基础，可以较方便地根据传感器测量值的大小，确定油液的污染度等级值。

国内有关学者对现场油液的污染状况也作过大量的分析研究，得出了如下结论：

1）煤矿机械液压油液污染颗粒尺寸分布多数情况下接近对数正态分布。

2）各曲线与 ACFTD 标准粉尘的颗粒尺寸分布曲线趋于平行。这样就为单点测量和以 ACFTD 试验粉尘为基础进行不同尺寸段颗粒数的估算及不同污染等级标准之间的换算提供了依据。

3）实际应用中，颗粒尺寸的分布毕竟与 ACFTD 粉尘的颗粒尺寸分布有一定差距，有时甚至相差很大。若通过单点测量法并按 ACFTD 分布外推将会引起较大的误差。这时若需了解污染颗粒的尺寸分布或准确地进行污染等级标准的转换，只有通过多点检测来实现。

4）同是 ACFTD 粉尘，生产年度不同，其分布也有误差，加上颗粒计数器的测量误差，这些因素都将对污染检测仪器的标定产生影响。

8.4 在线监测系统的硬件与软件实现

8.4.1 在线监测系统的方案

综合考虑上述分析，油液污染在线监测系统采用如下方案：

1）采用阀用直流电磁铁作为产生动力的元件。

2）用表面型滤膜截留油液中的污染物。

3）尽量使之产生表面型过滤过程。

4）假设油液中的固体颗粒污染物的性质是固定不变的。

5）手动旋转测头来实现吸油和滤膜的反向冲洗。

6）通过测量给定时间后的滤膜压差来间接测量油液中的污染物颗粒浓度。

8.4.2 在线监测系统的功能及原理

1. 在线监测系统的主要功能

油液污染在线监测系统所要实现的主要功能有如下几点：

1）该系统能实时监测系统中油液的污染程度，实时记录、随时调用、打印输出，显示记录数据，超限报警，有较强的现场抗干扰性。

2）能给出相应的 ISO 和 NAS 油液清洁度等级。

3）标准化和通用化后有较强的整体性和通用性。

4）在单个测点实验成功后，可将系统进行推广，可对多个测点同时进行油液污染度在线监测，实现对整个系统的集中污染监控。

2. 在线监测系统的工作原理

油液污染在线监测系统是在淤积法的恒功率测量法原理的基础上研制而成的。其原理是以阀用直流电磁铁的主推动力获得压降，通过测量从电磁铁开始通电到某一给定时间内的通过特制滤网油液产生的压差，从而确定油液的污染度等级。

在线监测系统由微型计算机、压差传感器、温度传感器、数据采集与控制卡、阀用直流电磁铁、24V 直流恒压源、特制液压缸等组成，如图 8-13 所示。

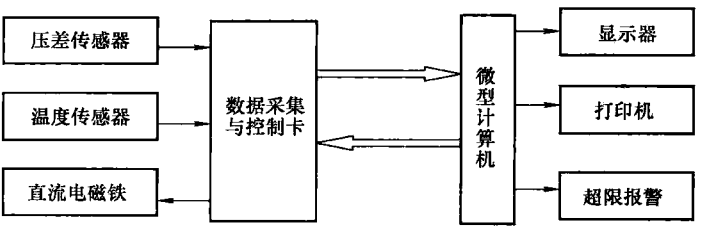

图 8-13 在线监测系统原理图

系统工作时，装于滤网前的温度传感器首先检测油液的温度，当油温过低或过高时，系统都不工作。①当油温在设定温度范围内时，阀用直流电磁铁失电，特制液压缸吸油；②旋转测头顺时针转动 90°，为测试作准备；③直流阀用电磁铁得电，特制液压缸排油；④延时一定时间，数据采集与控制卡采集装于滤网前后的压差传感器转换来的电信号，通过滤波、运算处理，得出滤网前后的压差，并查表找出对应的油液污染度值，然后将油液污染度值送显示器显示，并可打印输出；⑤旋转测头顺时针转动 90°，密封液压缸；⑥阀用直流电磁铁失电，特制液压缸再次吸油，为反向冲洗滤膜作准备；⑦旋转测头顺时针转动 90°；⑧直流阀用电磁铁得电，反向冲洗滤膜；⑨旋转测头顺时针转动 90°，恢复原位。若油液污染度值不符合所在系统的要求时，在线监测系统将发出报警信号。

8.4.3　硬件系统

1. 关键部件的设计

（1）滤膜的设计　为了使测量装置紧凑和减小测量误差，经过综合考虑，决定取滤膜的直径为 10mm，待测油液体积为 25mL。

（2）旋转测头的设计　旋转测头的结构如图 8-14 所示。为了密封良好，旋转测头的直径为 32mm，其中间有一通孔，在装有滤膜的一侧直径为 12mm，另一侧直径为 10mm，滤膜用压紧装置压紧。旋转测头的左边 M8 × 1.5 螺纹孔是为了与旋转手柄连接和使结构紧凑。

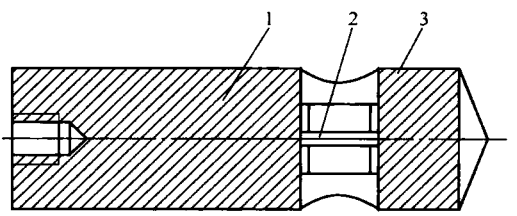

图 8-14　旋转测头结构示意图

1—旋转测头　2—特制滤膜　3—压紧装置

（3）特制液压缸的设计　当待测油液体积、旋转测头结构尺寸确定以后，若其内径确定，则其结构也就基本确定。为了使结构紧凑，取其内径为 70mm（活塞套壁厚 5mm），长、宽、高分别为 200mm、120mm、130mm，其结构如图 8-15 所示。

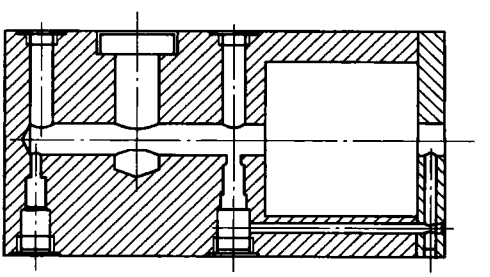

图 8-15　特制液压缸结构示意图

（4）活塞组件的设计　在活塞组

件与特制液压缸的活塞套之间采用间隙密封。为了提高间隙密封的工作性能，在活塞上开了4道三角形沟槽，槽宽0.4mm，槽深0.5mm，槽距4mm。这些环槽有两个作用：一是在油液从高压腔流入低压腔过程中，它的间隙截面发生几次骤变，从而增加了油液泄漏的流动阻力，提高了密封性能；二是可以防止出现径向不平衡力，以免出现液压卡紧现象。活塞杆外径为10mm，活塞外径为70mm，内径为60mm，活塞组件全长为90mm，活塞套和活塞组件的结构如图8-16所示。

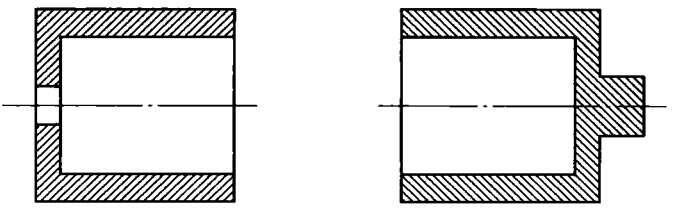

图8-16 活塞套及活塞组件结构示意图

a）活塞套 b）活塞组件

2. 主要元件的选择

（1）直流阀用电磁铁的选择 上海第三机床电器厂生产的MFZ1-YC系列直流湿式阀用电磁铁为装甲螺管直动式结构，本身没有复位装置，靠阀杆的复位弹簧复位。在未接通电源时，衔铁被阀杆推出到额定行程距离，在接通电源后，产生电磁力推动阀杆移动。为了使在线监测系统紧凑，并能得到大的推力，决定选用MFZ1-7YC型，其额定电压为直流24V，额定行程为7mm，额定吸力为70N，最大行程为10mm，安装尺寸为60mm×60mm－4×ϕ6.5mm。

（2）压差传感器的选择 通过计算，当待测油液为NAS8级时，在线监测系统的压差约为0.05MPa，所以选用ATOS公司生产的E-ATR-5型压差传感器。其技术参数为：供电电压为24V DC；输出信号为0～10V；测量精度为±0.1%FS；工作温度为－25～85℃。

（3）温度传感器的选择 TE系列连续式平均温度传感器利用标准铂电阻组成连续式传感元件，将管道内油液分层测量，最后取各测量值的平均值。选用PT1000传感元件感应温度，并提供4～20mA、0～5V DC或0～10V DC输出信号，按比例地对应测定的温度范围。该传感器精度高，稳定性好，测温范围广，且具有低滞后和感应灵敏等特点。探针最大测温范围－40～100 ℃。可提供0.1%或更高的满量程精度和优良的稳定性，可有效地抵制射频干扰，且不受电源供电和输入电压干扰的影响。

油液在线监测系统设定的检测温度为30～80℃，所以选用TE500DC-12H31E3

型温度传感器。其技术参数为：供电电压为 24V DC；输出信号为 0 ~ 10V DC；测量精度为满量程 ±0.1%；工作温度为 0 ~ 100℃。

（4）数据采集与控制卡的选择　研华公司（Advantech Co.，Ltd.）的数据采集与控制卡支持模拟量、数字量和脉冲量等信号的输入与输出，其自带的动态链接库使我们不必使用与硬件有关的命令，而可以用其支持的多种编程环境和语言编写出满足要求的、界面友好的应用程序。其支持的编程环境有 Windows，编程语言有 Microsoft Visual C ++ 、Microsoft Visual Basic、Borland Delphi、Borland C ++ 、C ++ Build 等。由于要控制的信号有模拟量的输入、模拟量的输出等，所以选用该公司的 PCI-1710HG 数据采集与控制卡。

3. 在线监测系统的装配图与工作过程

在线监测系统的装配图如图 8-17 所示，其外形尺寸长、宽、高分别为 300mm、240mm、160mm。它不同工况的动作过程见表 8-6。

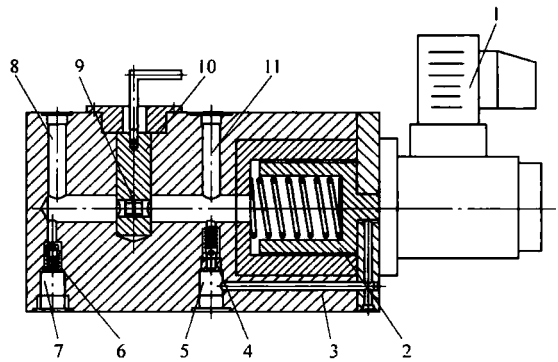

图 8-17　在线监测系统装配图

1—阀用直流电磁铁　2—活塞组件　3—特制液压缸　4、6—单向阀
5—进油口　7—出油口　8、11—压差传感器　9—滤膜组件　10—旋转测头

表 8-6　电磁铁动作和旋转测头动作

作　用	电　磁　铁	旋 转 测 头
吸油	-	不动
测试准备	-	顺时针旋转 90°
测试	+	不动
吸油准备	+	顺时针旋转 90°
吸油	-	不动
反向冲洗准备	-	顺时针旋转 90°
反向冲洗	+	不动
结束	+	顺时针旋转 90°

8.4.4 在线监测系统的软件实现

1. 基于 MCGS 的软件编制与流程框图

为了实现对油液污染程度的在线监测，而且尽量使界面简单友好、画面生动直观、操作方便灵活，实现显示、存储、打印、超限报警等功能，采用了 MCGS 工业

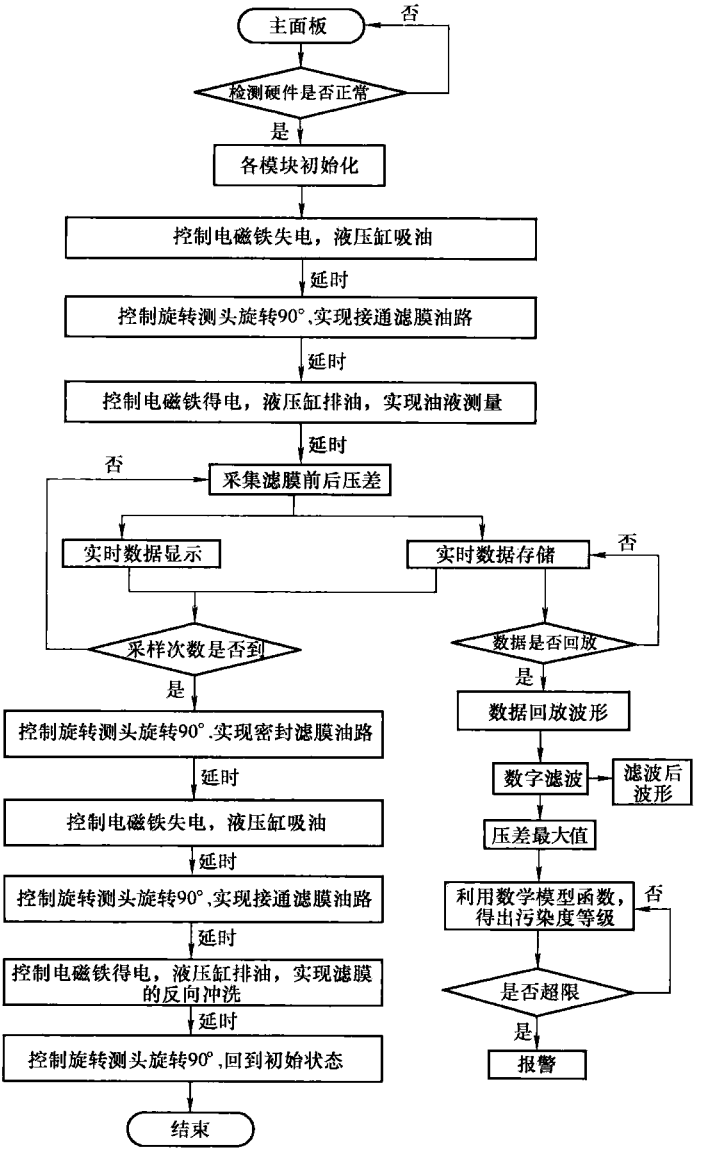

图 8-18 油液污染监测系统总流程图

组态控制软件。利用 MCGS 自带的设备驱动构件直接驱动数据采集与控制卡来完成模拟量的采集输入、模拟量的输出控制等功能。为了实现所要求的功能，油液污染在线监测系统的总流程框图如图 8-18 所示。数据采集系统主要用于精确测量油液污染在线监测过程中滤膜前后的压差，数据采集流程框图如图 8-19 所示。

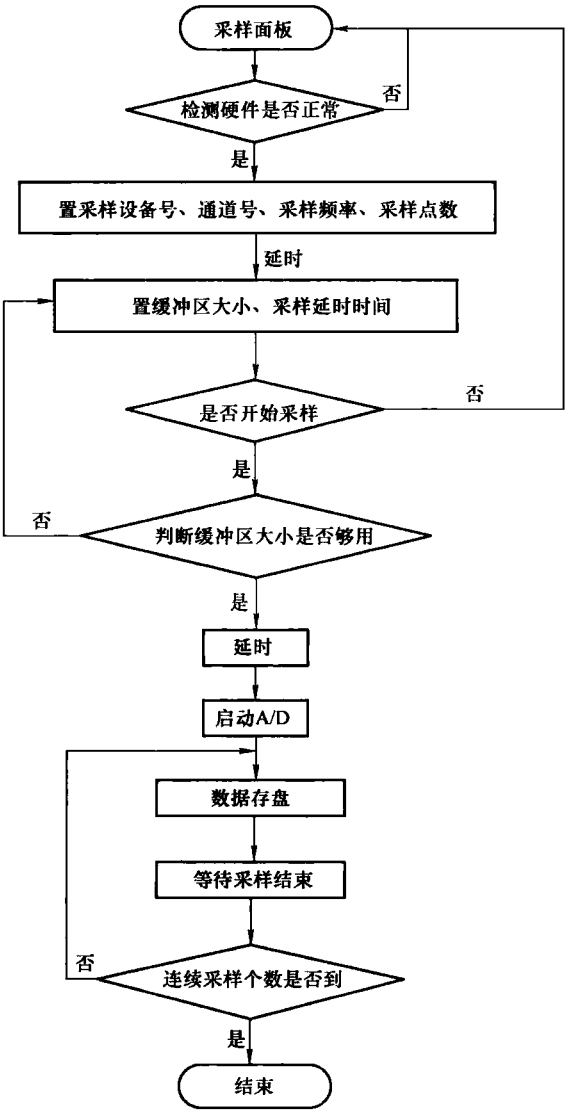

图 8-19　油液污染监测系统数据采集流程图

2. 基于 MCGS 的软件编程

MCGS 生成的用户应用系统，由主控窗口、设备窗口、用户窗口、实时数据库和运行策略 5 个部分构成，分别对每一部分进行组态操作，实现所要求的动能，完成整个软件的编制。下面是软件各个组成部分组态示意图，图 8-20 为主控窗口组态，图 8-21 为用户窗口组态，图 8-22 为实时数据库组态，图 8-23 为设备窗口组态，图 8-24 为策略窗口组态。

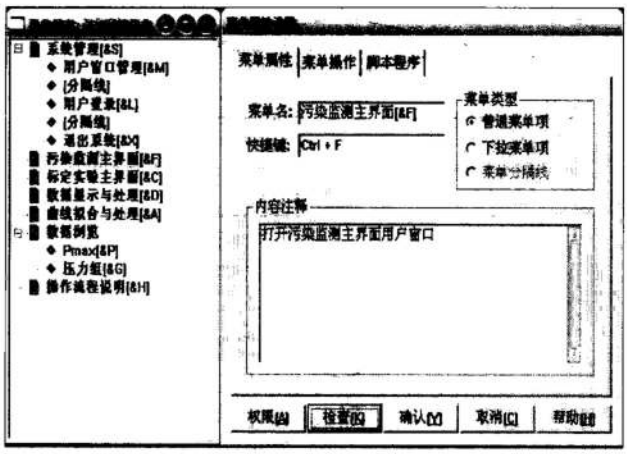

图 8-20 主控窗口组态

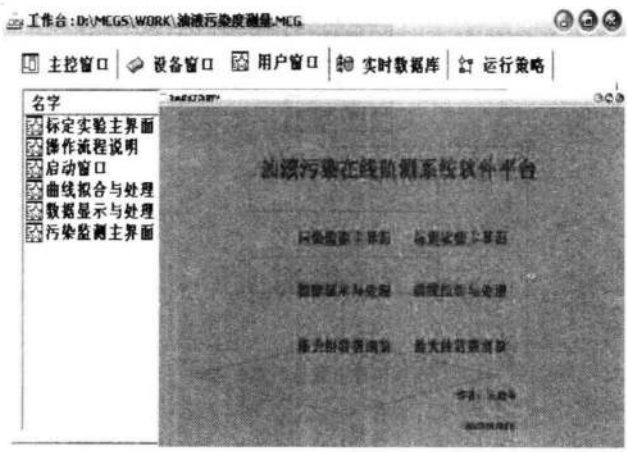

图 8-21 用户窗口组态

图 8-22　实时数据库组态

图 8-23　设备窗口组态

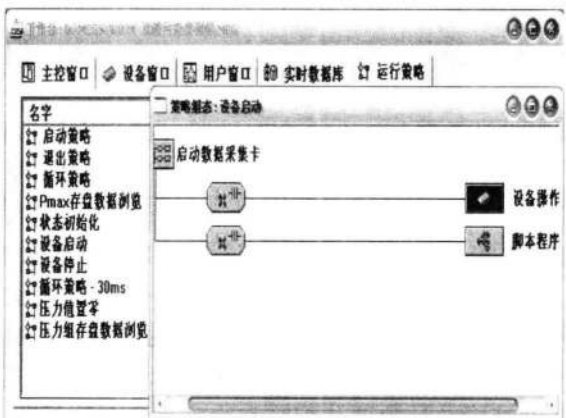

图 8-24　策略窗口组态

8.5 在线监测系统的调试与实验

8.5.1 实验油样的配制

为了对研制出的油液污染在线监测系统进行标定，需要配制污染度已知的油样。本系统选用10#红油作为基准油，采用ACFTD作为校准物质。因为ACFTD标准试验粉尘的颗粒分布比较稳定，加之现场各种污染颗粒的尺寸分布与ACFTD分布接近，所以本试验过程中选用ACFTD粉尘作为标准试验粉尘是可行的。

用精密天平称得不同污染等级所需的ACFTD粉尘，倒入清洗好的容器中，再用量筒量取所需清洁油倒入容器中，盖上容器口，进行处理，确保充分均匀扩散，然后把容器接在Parker公司生产的PLC-3000油液颗粒计数器上进行检验，PLC-3000油液颗粒计数器如图8-25所示。

图8-25 PLC-3000油液颗粒计数器

PLC-3000油液颗粒计数器是一台由自取样器（既有在线取样，又有瓶取样）、传感器和计数器等集成的，使用实验分析技术的先进的现场用便携式油液颗粒计数器。由于采用激光技术，有高准确性、精密性和可重复性等优点，激光技术使得该装置在2μm颗粒范围内实现高准确度计数。该装置工作原理如图8-26所示。随着油样流过该传感器，油样中的颗粒暂时阻挡激光。一个固态光敏二极管探测光的暂时减弱并产生一个与该颗粒尺寸成比例的相应宽度的电脉冲。油液中的颗粒被逐个确定尺寸和计数。总数被存储，然后显示并转换成ISO和NAS等级。

利用PLC-3000油液颗粒计数器共配制和检验得到5种NAS等级分别为NAS8、NAS9、NAS10、NAS11、NAS12的测试油样，为实验提供了工作介质。

8.5.2　在线监测系统的调试

液压系统油液污染在线监测系统如图 8-27 所示。本油液污染在线监测系统要在下列特定的实验条件进行调试：

1）实验环境条件：环境温度为 20℃ ±5℃，无尘，无强电磁干扰。

2）实验的硬件条件：油液污染在线监测装置、直流稳压电源、示波器、端子板、数据采集卡、PC。

3）实验软件环境：Windows XP、MCGS 6.2。

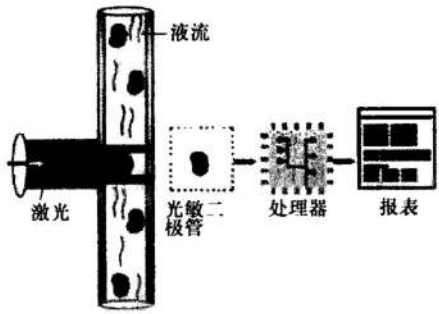

图 8-26　PLC-3000 油液颗粒计数器的工作原理

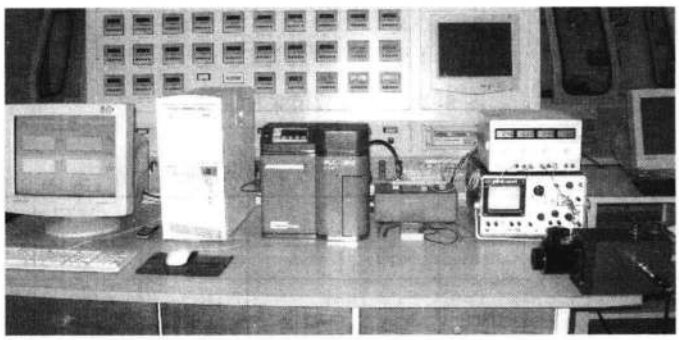

图 8-27　油液污染在线监测系统

在油液污染在线监测系统的调试过程中，根据对 MCGS 用户应用系统的各个用户窗口所实现的各种功能的调试情况来验证主控组态、设备组态、实时数据库组态、运行策略组态以及用户窗口组态 5 个部分的组态情况以及仪器设备的连接设置状况。对于输入信号的调试，采用信号发生器给出标准信号，检测采样数据是否符合标准信号的波形和数据以及干扰信号的幅值和频率范围；对于输出信号的调试，采用示波器来检测输出信号的波形、幅值、频率等参数，判断是否能够达到驱动设备的要求。如果某个特性不能满足要求，必须修改系统使其满足要求。具体调试内容如下：

（1）压力传感器零漂的调整　压力传感器是一种电子装置，在不同的工作条件下，必定有一定的零漂，在采集实际压力信号前必须检测出零漂数值，并且利用软件调零。压力传感器的零漂数值采集曲线如图 8-28 所示，由图可以得出零漂 0.01V，即对应的零漂压力为 0.4bar（1bar = 0.1MPa）。从曲线可以得出干扰信号

的范围为 ±0.0016V，即对应的干扰信号的压力显示值为 0.064bar。

（2）系统的参数设置　数据采集要完成信号测量，应该设置设备名、通道号、IO 基地址、采样周期、采样数据存盘属性等参数。历史数据回放参数的设置包括数据源位置、起始位置、数据长度。其他的参数设置根据具体条件进行相应的设置。考虑到用户需求的多样化，用户也可以自己手动修改参数设置，本系统常用参数设置见表 8-7。

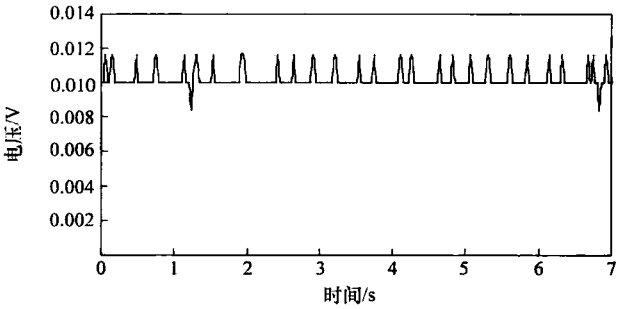

图 8-28　零漂数值采样曲线

表 8-7　系统常用参数设置

参数	数据采集设备	采集通道号		IO 基地址	采样周期	回放路径	回放位置	回放长度	截止频率/Hz	滤波阶数
设置值	1710 HG	1	3	D800	30ms	指定	0	1M	50	1

（3）在线监测系统的软件调试　在完成系统参数基本设置后，可以对标准信号进行数据采集，并且对信号进行分析和处理。对信号的处理包括波形显示、低通滤波、数据存储、数据回放、计算最大值等。通过设置各种参数和输入标准信号，系统对得到的信号都能进行正确的分析和处理，软件即达到了系统设计的基本要求。

（4）在线监测系统的调试　在硬件和软件分别调试通过以后，就要进行系统的调试。系统的调试就是对已知的标准量进行采集、处理和对比，以验证系统设计是否正确和合理，必要时修改和完善程序，直至系统调试达到要求时为止。

（5）各种油液污染度等级标准关系的确定　本油液污染在线监测系统能够给出不同污染度等级标准的油液污染度等级结果报告，因此必须确定各种污染度标准之间的关系。利用污染度等级对照表，确定 NAS、ISO、SAE 三种污染度标准之间的关系函数。因采用 NAS 作为标定标准，故对应关系表达为 NAS ~ ISO 和 NAS ~ SAE。NAS 标准与 ISO 标准之间的对应关系见表 8-8，NAS 标准与 SAE 标准之间的

对应关系见表 8-9。

表 8-8　NAS 与 ISO 标准污染度等级对应关系

标　准	等级对应关系									
NAS	00	0	1	2	3	4	5	6	7	8
ISO	3	7	8	9	10	11	12	13	14	15
NAS	9	10	11	12	13	14	15	16	17	
ISO	16	17	18	19	20	21	22	23	24	

表 8-9　NAS 与 SAE 标准污染度等级对应关系

标　准	等级对应关系									
NAS	00	0	1	2	3	4	5	6	7	8
SAE	0	0	0	0	0	1	2	3	4	5
NAS	9	10	11	12	13	14	15	16	17	
SAE	6	6	6	6	6	6	6	6	6	

8.5.3　在线监测系统的实验

1. 在线监测系统的标定实验

标定不仅可以把 A/D 转换的数字量变换成带有工程单位的数字量，而且使测量系统的固定系统误差与某些干扰因素，如温度、电源电压波动等引起的可变系统误差得以排除，提高系统的精度与稳定性。另外，标定还可以消除整个测试系统的非线性系统误差。采用标定方法，可以实现即便是低精度、低重复性、低稳定性的测量系统仍然可以获得高精度的测量结果。只要获得较高精度、较高稳定性的参考模型，就可以满足系统的要求了。即使测量系统中测量环节具有严重的非线性，只要输入与输出特性具有重复性，就可以把非线性误差控制在要求的范围内。

为了对油液污染度在线监测系统进行标定，准备了 5 种标准污染度的油样对其进行实验，由实验结果可以得出一个多项式数学模型函数，它作为本油液污染度在线监测系统的依据，来实现对各种油液的污染度测量。油液污染度在线监测系统标定实验的流程如下：

1）取某等级标准油样，倒入清洗好的取样容器中，接入监测系统。

2）确定检测系统硬件连接正确，打开电源，打开油液污染监测软件平台标定实验面板，确定硬件工作正常。

3）在软件平台标定实验面板上设置系统的各种初始化参数。

4）控制电磁铁失电，液压缸吸油。

5）旋转测头旋转90°，接通滤膜油路。

6）控制采集卡开始数据采集，并且控制电磁铁得电，液压缸排油，同时处理数据获得压差最大值。

7）旋转测头旋转90°，密封油路。

8）控制电磁铁失电，液压缸吸油。

9）旋转测头旋转90°，接通滤膜油路。

10）控制电磁铁得电，液压缸排油，实现滤膜的反向冲洗。

11）旋转测头旋转90°，回到初始状态。

12）重复上述流程，直到获取足够数据，将最大压差值处理后取其平均值，完成此污染度等级标准油样的实验。

标定实验采用了5种NAS等级分别为NAS8、NAS9、NAS10、NAS11、NAS12的标准油样对油液污染在线监测系统进行标定，分别进行10次实验，实验结果在软件界面上显示，包括压力数据的实时值显示、波形显示、滤波后的波形显示以及利用算法求出的最大压差结果显示，并可以选择是否存盘。由实验结果可以发现采集到的压差信号的重复精度误差<1%，即标定实验能够满足标定精度要求。各污染度等级对应的某一有代表性的压差曲线见图8-29。根据数据处理程序算法计算处理后，得到每次实验的压差最大值，最后取10次实验所得到的压差最大值的平均值。5种NAS污染度等级的最大压差平均值数据见表8-10。

表8-10 5种NAS污染度等级的最大压差平均值

污染度等级	NAS8	NAS9	NAS10	NAS11	NAS12
最大压差平均值/bar	0.4736	0.4757	0.5331	0.6582	0.7010

注：1bar=0.1MPa。

利用最大压差平均值和对应NAS污染度等级关系，调用曲线拟合处理程序，获得曲线拟合参数，得到本油液污染度监测系统的多项式数学模型函数，多项式数学模型函数曲线如图8-30所示。

$$y_{NAS} = -262.29 + 1306.46\Delta p_m - 2108.52\Delta p_m^2 + 1142.62\Delta p_m^3 \tag{8-7}$$

式中 y_{NAS}——油液的NAS污染度等级；

Δp_m——滤网前后的最大压差平均值。

2. 在线监测系统的监测实验

以标定实验建立的系统数学模型函数为依据，对一种现场实际液压系统油液进行污染度鉴定，通过此实验来验证系统工作稳定性、数学模型函数的正确性以及软件工作的可靠性。

油液污染度在线监测系统监测实验流程与标定实验流程基本相同，其流程如下：

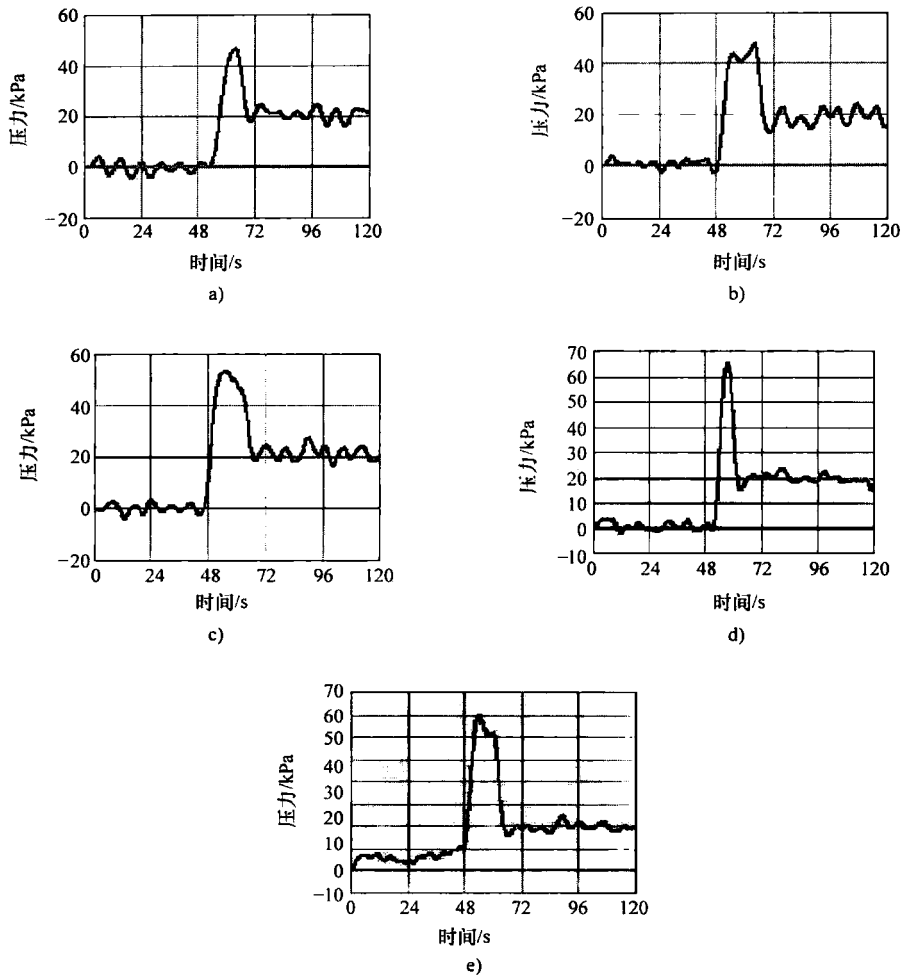

图 8-29　5 种 NAS 污染度等级的压差曲线

a）NAS8 级压差曲线　b）NAS9 级压差曲线　c）NAS10 级压差曲线

d）NAS11 级压差曲线　e）NAS12 级压差曲线

1）从实际液压系统获取油样，倒入清洗好的取样容器，接入监测系统。

2）确定硬件正确连接后，打开油液污染度在线监测软件监测面板。

3）在软件监测面板上设置各种初始化参数。

4）控制电磁铁失电，液压缸吸油。

5）旋转测头旋转 90°，接通滤膜油路。

6）控制采集卡开始数据采集，并且控制电磁铁得电，液压缸排油，同时采集

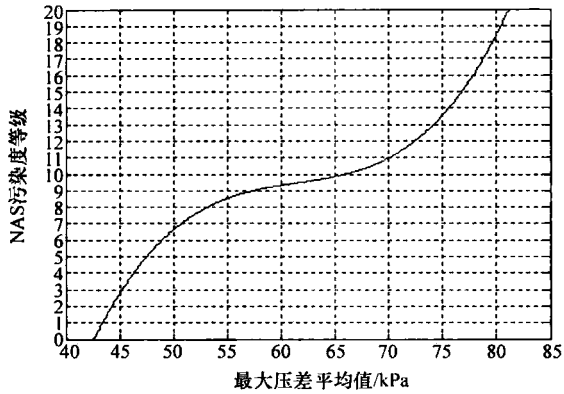

图 8-30 模型函数曲线

压差信号进行数据处理，获得压差最大值。

7）旋转测头旋转 90°，密封油路。

8）控制电磁铁失电，液压缸吸油。

9）旋转测头旋转 90°，接通滤膜油路。

10）控制电磁铁得电，液压缸排油，实现滤膜的反向冲洗。

11）旋转测头旋转 90°，回到初始状态。

12）重复上述流程，将最大压差值处理后取均值，利用建立的数学模型函数，显示污染度结果报告，实现对实际液压系统油液污染的监测。

监测实验采用实际油样进行监测，输入报警限值，油液污染监测软件采集并处理得到的压差最大值，实验程序自动调用系统的数学模型函数，实验结果在软件面板上显示。显示功能包括：压力数据的数值显示、波形显示，以及滤波后的波形显示、最大压差结果显示、NAS/ISO/SAE 污染度等级显示、超限报警显示等。一组实际油样数据曲线见图 8-31。

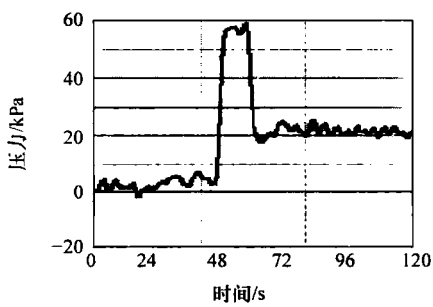

图 8-31 实际油样压差曲线

如果监测油液的污染度超过报警限值，会出现报警，即报警灯亮、警报声响，显示报警提示窗口，提醒液压系统维护人员及时更换符合系统要求的液压油。

8.5.4　实验结果分析

1. 标定实验结果分析

从标定实验数据和曲线可以看出，系统产生的压差和压力传感器的量程相比较小，高频干扰信号对采样结果的干扰较大，但通过数字滤波后的曲线的去噪效果较明显，故实验数据可信。

从 NAS 污染度等级与最大压差平均值之间的对应关系图 8-30 可以看出，油液污染度在线监测系统对高于 NAS 污染度 8 级的油液不是很敏感，这主要是由于本系统滤膜的固有特性决定的。当有一定压力和流量的油液通过滤膜时，必定有一定的压力损失，而当油液的污染度没有达到一定程度时，油液的污染颗粒对压差的影响不是很大。也就是说当污染度很小的油液通过滤膜时，油液压差改变的大小已经不能被仪器所分辨，这也和本油液污染监测系统的压力传感器的分辨率有直接关系。如果能够采用孔径更细微的滤膜以及分辨率更高的压力传感器，本系统会有更理想的监测效果。

2. 监测实验结果分析

从实际油液实验结果可以看出，系统工作正常，所建立的数学模型函数正确且有效，报告内容丰富，界面友好，软件平台基本满足了鉴定实际油液污染等级的要求。

3. 实验误差分析

测量误差是由多种因素的影响而产生的。在测量中，测量仪器的不准确、测量手段不完善、测量条件发生变化及测量工作中的疏忽或错误等原因，都可能引起误差。本油液污染监测系统产生误差的原因主要有以下几个方面。

（1）系统硬件产生的误差　本系统的硬件有许多元件组成，每种元件都可能产生一定的误差。包括动力传递产生的误差；电源波动产生的误差；电磁铁产生的电磁干扰；压力传感器的非线性误差、零漂、温漂、灵敏度漂移；PC 内部产生的电磁干扰等。其中压力传感器的误差是最主要的，也是最难去除的。

（2）环境干扰产生的误差　油液污染监测环境比较恶劣，各种工作设备将产生干扰和噪声信号。

（3）数据采集和处理系统的误差　数据采集系统产生的量化误差、数据转换产生的误差、数据处理产生的误差、软件自身运行产生的算法误差等。

（4）标定过程误差　标定过程也是实验的过程，必定会产生一定的标定误差，比如曲线拟合的过程就是一个近似的过程，但只要产生的误差符合重复精度要求，是能够满足系统要求的。

（5）油液影响测量结果准确性的因素　颗粒污染物的分布、油液的粘度、所含水分、气泡等。

（6）不可预测的误差。

4. 用户软件可靠性分析

通过对油液污染监测系统的多次调试和实验，验证了用户软件的可维护性、灵活性、测试性、可移植性、重复性都较好，能够满足系统的要求，且运行比较平稳，因此用户软件基本满足了可靠性的要求。

参 考 文 献

[1] 宋琦，卢吉洲．现场油液污染检测技术分析［J］．液压与气动，1990（2）：1-8.

[2] 涂群章，龚烈航，王强．液压（或润滑）油液污染度在线监测的发展状况［J］．矿山机械，2000（7）：54-56.

[3] 赵大庆．液压泵污染磨损与控制［M］．北京：煤炭工业出版社，1993.

[4] 李新德．浅析液压油的污染及危害［J］．农机机械，2004（6）：80-81.

[5] 刘金华，明兴祖，液压油的污染与控制［J］．矿山机械，2005，33（8）：149-151.

[6] Tian Qian. The measurement of pollution degree of hydraulic system with dark automatic grain counter［J］. Sci/Tech information development and economy，2003，13（5）：109-110.

[7] 彭西伟．难燃液压油的性能与应用［J］．液压与气动，2002（3）：206-208.

[8] 卢继霞，贾瑞清，夏志新. ISO4406 新旧标准简介及修订原因说明［J］．机床与液压，2006（5）：115-118.

[9] 卢继霞，王炉平，王乾．油液污染度的测定及相关国际（国家）标准的应用［J］．液压与气动，2006（10）：45-48.

[10] 颜容华．现代工程机械液压与液力系统［M］．北京：人民交通出版社，1997.

[11] 张自强．基于匹配滤波的液压流体颗粒污染度检测［J］．机械工程学报，2003，39（5）：65-70.

[12] 夏志新．液压系统污染控制［M］．北京：机械工业出版社，1995.

[13] 黄宪曾．液压系统污染控制［M］．北京：机械工业出版社，1999.

[14] 王海军．液压油污染度在线监测系统研制及实验研究［D］．秦皇岛：燕山大学，2007：47-78.

[15] 王海军，张齐生，董彩云．液压油污染度在线监测系统研制及实验研究［J］．液压与气动，2009（2）：11-14.

第 9 章　基于小波神经网络的故障诊断方法

本章对 BP 神经网络、松散型和紧凑型小波神经网络的结构及学习算法进行系统地阐述，利用 BP 神经网络和小波神经网络的函数逼近性能，对液压泵进行故障诊断实验，取得了很好的诊断效果。

9.1　人工神经网络

9.1.1　人工神经元模型应具备的要素

人工神经网络是由大量神经元广泛互连而成的网络。神经元模型应具备三个要素：①具有一组突触或连接，连接强度由各连接上的权值表示，权值为正表示激活，为负表示抑制。②具有一个求和单元，用于求取各输入信号的加权和。③具有一个非线性传递函数，起非线性映射作用并将神经元输出幅度限制在一定范围内，通常限制在［0，1］或［－1，1］闭区间。

9.1.2　神经元之间的连接形式

神经网络是一个复杂的互联系统，单神经元之间的互联模式对网络的性质和功能产生重要影响。神经元之间的连接可以有任意形式，但最常见的结构是前向神经网络和反馈神经网络。

1. 前向神经网络

前向神经网络的拓扑结构如图 9-1 所示。网络中的神经元是分层排列的，由输入层、隐含层和输出层组成，其中隐含层可以是一层或多层。每个神经元只与前一层和后一层神经元单向相连接，各神经元之间没有反馈。每个神经元可以从前一层接收多个输入，并只有一个输出送给下一层的各神经元。

2. 反馈神经网络

典型的反馈神经网络如图 9-2 所示，每个节点都表示一个计算单元，同时接受外加输入和其他各节点的反馈输入，每个节点也都直接向外部输出。在某些反馈网络中，各神经元除接受外加输入与其他各节点反馈输入之外，还包括自身反馈。

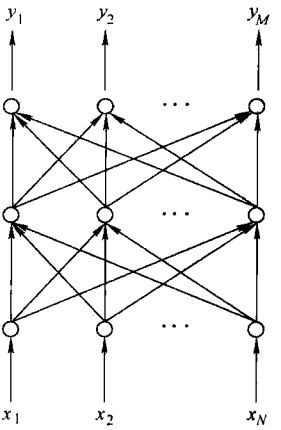

图 9-1 前向神经网络图

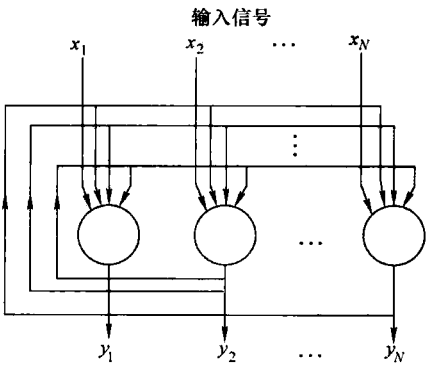

图 9-2 反馈神经网络

9.1.3 BP 网络学习算法及隐层的设计

1. BP 网络学习算法

BP 网络是多层前向网络，由输入层、隐含层（一层或者多层）和输出层构成。下面以单隐层 BP 网络为例，介绍 BP 学习算法，其结构如图 9-3 所示。

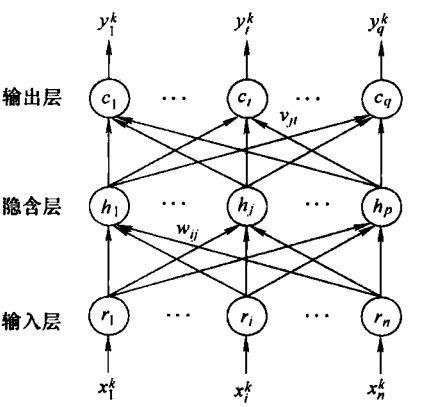

图 9-3 三层 BP 神经网络结构

设输入模式向量 $\boldsymbol{X}_k = (x_1^k, x_2^k, \cdots, x_i^k, \cdots, x_n^k)$，网络希望输出向量 $\boldsymbol{D}_k = (d_1^k, d_2^k, \cdots, d_t^k, \cdots, d_q^k)$，中间隐层神经元的输入向量 $\boldsymbol{S}_k = (s_1^k, s_2^k, \cdots, s_j^k, \cdots, s_p^k)$，输出向量 $\boldsymbol{B}_k = (b_1^k, b_2^k, \cdots, b_j^k, \cdots, b_p^k)$，输出层神经元的输入向量 $\boldsymbol{C}_k = (c_1^k, c_2^k, \cdots, c_t^k, \cdots, c_q^k)$，输出向量 $\boldsymbol{Y}_k = (y_1^k, y_2^k, \cdots, y_t^k, \cdots, y_q^k)$，输入层至隐层的连接权为 $\{w_{ij} \mid i = 1, 2, \cdots, n;\ j = 1, 2, \cdots, p\}$，隐层至输出层的连接权为 $\{v_{jt} \mid j = 1, 2, \cdots, p;\ t = 1, 2, \cdots, q\}$，中间各层神经元阈值为 $\{\theta_j \mid j = 1, 2, \cdots, p\}$，输出层各神经元阈值为 $\{r_t \mid t = 1, 2, \cdots, q\}$。输入模式向量 m 个，即 $k = 1, 2, \cdots, m$。当第 k 个模式作用时，输出层的误差函数为

$$E^k = \sum_{t=1}^{q} (d_t^k - y_t^k)^2 / 2 \tag{9-1}$$

神经元的传递函数一般取 Sigmoid 函数

$$f(x)=\frac{1}{1+e^{-x}} \tag{9-2}$$

隐含层第 j 个神经元的净输入和实际输出值分别为

$$s_j^k=\sum_{i=1}^{n} w_{ij}x_i^k-\theta_j \quad j=1,2,\cdots,p \tag{9-3}$$

$$b_j^k=f(s_j^k) \quad j=1,2,\cdots,p \tag{9-4}$$

输出层第 t 个神经元的净输入和实际输出值分别为

$$c_t^k=\sum_{j=1}^{p} v_{jt}b_j^k-r_t \quad t=1,2,\cdots,q \tag{9-5}$$

$$y_t^k=f(c_t^k) \quad t=1,2,\cdots,q \tag{9-6}$$

将 E^k 分别对网络的实际输出 $\{y_t\}$、输出层神经元的输入 $\{c_t\}$、隐层至输出层的连接权 $\{v_{jt}\}$ 及输入层至隐层的连接权 $\{w_{ij}\}$ 求偏导，得

$$\partial E^k/\partial y_t^k=-(d_t^k-y_t^k)=-\delta_t^k \tag{9-7}$$

$$\begin{aligned}\partial E^k/\partial c_t^k&=(\partial E_k/\partial y_t^k)\cdot(\partial y_t^k/\partial c_t^k)=-(d_t^k-y_t^k)f'(c_t^k)=\\&-\delta_t^k y_t^k(1-y_t^k)=-\rho_t^k\end{aligned} \tag{9-8}$$

$$\begin{aligned}\partial E^k/\partial v_{jt}&=(\partial E_k/\partial y_t^k)\cdot(\partial y_t^k/\partial c_t^k)\cdot(\partial c_t^k/\partial v_{jt})=\\&-\delta_t^k f'(c_t^k)b_j^k=-\delta_t^k y_t^k(1-y_t^k)b_j^k\end{aligned} \tag{9-9}$$

$$\begin{aligned}\partial E^k/\partial w_{ij}&=(\partial E_k/\partial b_j^k)\cdot(\partial b_j^k/\partial s_j^k)\cdot(\partial s_j^k/w_{ij})=\\&\left[\sum_{t=1}^{q}(-\rho_t^k v_{jt})\right]\cdot b_j^k(1-b_j^k)\cdot x_i^k\end{aligned} \tag{9-10}$$

式中，$\delta_t^k=d_t^k-y_t^k$，$\rho_t^k=\delta_t^k y_t^k(1-y_t^k)$。

采用梯度下降法修正连接权，有

$$\begin{aligned}\Delta v_{jt}&=-\lambda[\partial E^k/\partial v_{jt}]=\lambda\delta_t^k y_t^k(1-y_t^k)b_j^k=\lambda\rho_t^k b_j^k,\\&t=1,2,\cdots,q;j=1,2,\cdots,p\end{aligned} \tag{9-11}$$

$$\Delta w_{ij}=-\beta[\partial E^k/\partial w_{ij}]=\beta\left[\sum_{t=1}^{q}\rho_t^k v_{jt}\right]\cdot b_j^k(1-b_j^k)\cdot x_i^k \tag{9-12}$$

令 $\varphi_j^k=\left[\sum_{t=1}^{q}\rho_t^k v_{jt}\right]\cdot b_j^k(1-b_j^k)$ 得

$$\Delta w_{ij}=\beta\varphi_j^k\cdot x_i^k,\ i=1,2,\cdots,n;\ j=1,2,\cdots,p \tag{9-13}$$

式中，λ、β 是学习系数。同理，输出层阈值为 $\{r_t\}$ 和隐含层阈值 $\{\theta_j\}$ 的修正值分别为

$$\begin{cases}\Delta r_t = \lambda \rho_t^k & t = 1,2,\cdots,q \\ \Delta \theta_j = \beta \varphi_j^k & j = 1,2,\cdots,p\end{cases} \tag{9-14}$$

BP 学习算法的步骤如下：

1）预置权值和阈值的初始值。赋给权值和阈值一个较小的随机非零量。

2）输入训练样本。

3）前向传播过程。对输入样本，前向计算 BP 网络各层神经元的输入信号和输出信号。

4）后向传播过程。计算误差对各层权值及各单元阈值的修正值。

5）按如下修正公式修正各层的权值或阈值。

$$v_{jt}(n+1) = v_{jt}(n) + \lambda \rho_t^k b_j^k \tag{9-15}$$

$$r_t(n+1) = r_t(n) + \lambda \rho_t^k \tag{9-16}$$

$$w_{ij}(n+1) = w_{ij}(n) + \beta \varphi_j^k x_i^k \tag{9-17}$$

$$\theta_j(n+1) = \theta_j(n) + \beta \varphi_j^k \tag{9-18}$$

6）随机选取下一个训练样本，转至步骤 3）循环，直至 m 个训练样本全部训练完毕。

7）判断误差是否满足要求，若满足，则停止训练，否则转至步骤 3）循环。

2. BP 网络隐层的设计

对于 BP 网络，有一个非常重要的定理。即对于任何在闭区间的一个连续函数都可以用单隐层的 BP 网络逼近，因而一个三层 BP 网络就可以完成任意的 n 维到 m 维的映射。

隐层的神经元数目选择是一个十分复杂的问题，往往需要根据设计者的经验和多次实验来确定，不存在一个理想的解析式来表示。隐层神经元的数目与问题的要求、输入、输出神经元的数目都有着直接关系。隐层神经元数目太多会导致学习时间过长，误差不一定最佳，也会导致容错性差，不能识别以前没有学习过的样本；如果隐层神经元数太少，则网络可能根本无法训练。因此一定存在一个最佳的隐层神经元数。以下是几个确定隐层神经元数目 p 的经验参考公式：

1）$p \geqslant \sqrt{n+q} + a$，其中，$n$ 为输入单元数，q 为输出神经元数目，a 为 [1，10] 之间的常数。

2）$\sum_{i=0}^{n} C_p^i > k$，其中，k 为样本数，n 为输入单元数，如果 $i > p$，$C_p^i = 0$。

3）$p \geqslant \log_2 n$，其中，n 为输入单元数。

9.1.4 BP 神经网络应用实例

因为三层 BP 神经网络可以逼近任意的非线性映射，在实际应用中，一般采用

三层的 BP 网络就足够了。因此本例利用一单隐层 BP 网络对函数 $y=\sin(8\pi x)+\cos(6\pi x)$ 进行逼近。

该网络的训练样本为 $\{0, 0.01, \cdots, 0.3\}$，输入层神经元个数为 1，输出层的神经元个数为 1，根据以上的隐含层设计经验公式以及本例的实际情况，网络的隐层神经元个数选为 8。

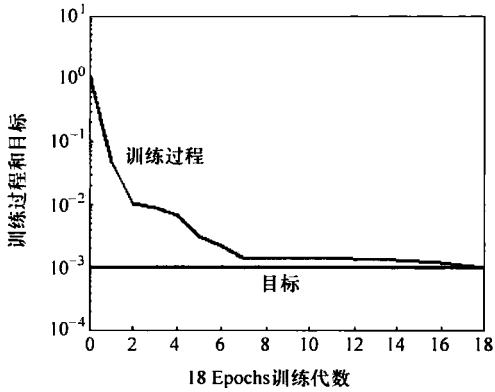

图 9-4　训练误差曲线

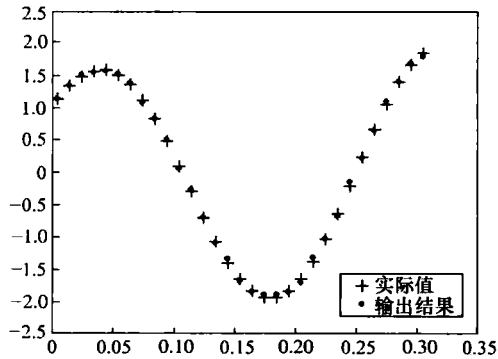

图 9-5　函数逼近结果

网络的隐含层神经元的传递函数选为双曲正切 S 型函数，输出层神经元的传递函数选为 S 型函数。采用函数trainlm对网络进行训练，其学习算法为 Levenberg-Marquadt 反传算法，该函数的优点在于收敛速度很快。由图 9-4 所示，经过 18 次训练后，网络的误差就达到了 0.001。

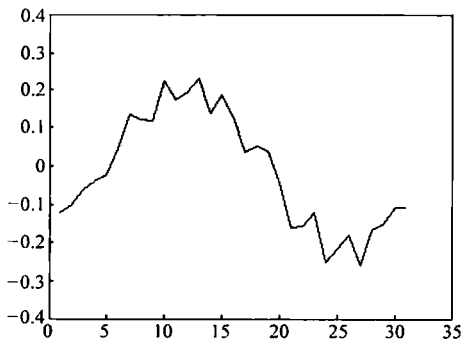

图 9-6　网络的误差曲线

对训练好的网络进行测试，测试样本为 $\{0.005, 0.015, \cdots, 0.305\}$。可以得到网络对函数的逼近情况，如图 9-5 所示。其中“+”表示函数的实际值，“·”表示网络的输出结果。网络的误差曲线如图 9-6 所示。

由图 9-5 和图 9-6 可以看出，BP 网络用于函数逼近取得了较好的效果。

9.2　小波神经网络

小波神经网络也属于前馈神经网络，是建立在小波分析理论基础上的一种新型

神经网络。它结合了小波变换良好的时频局域化性质及神经网络的自学习功能，因而具有较强的逼近、容错能力，又具有自学习、自适应、时频特性好、建模能力强等特性，因此在非线性系统建模和识别、控制、故障诊断等方面都获得了广泛的应用。

9.2.1 小波神经网络原理

小波神经网络是小波分析理论与神经网络理论相结合的产物。目前，其结构形式可以分为两大类：

（1）松散型结合　即用小波分析作为神经网络的前置处理手段，通过小波分析来实现信号的特征提取，将提取的特征向量送入神经网络处理，其结构如图 9-7 所示。

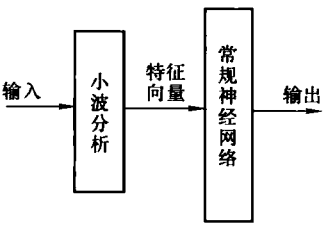

图 9-7　松散型小波神经网络的结构

（2）紧致型结合　从结构形式看是把小波分解和前馈神经网络直接融合。一般是将常规单隐层神经网络的隐节点函数由小波函数代替，相应的输入层到隐层的权值及隐层阈值分别由小波函数的尺度与平移参数所代替。即传递函数为已定位的小波函数基，通过仿射变换建立起小波变换与神经网络的连接，其结构如图 9-8 所示。

小波和神经网络通过上述两种结合途径，形成了广义上的小波神经网络。而狭义上的小波神经网络则是专指二者的紧致型结合。

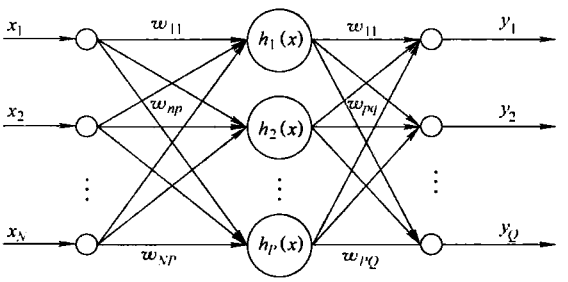

图 9-8　紧致型小波神经网络结构

9.2.2 紧致型小波神经网络的结构

小波基函数有许多优于其他基函数的优点。小波的正交基易于构造，因而网络的权值可独立进行计算；小波可提供区别函数的多分辨近似，提供空间和频率的局部特征；另外，小波基函数有可变平移与膨胀系数，因而可把小波函数作为基函数，构成新的神经网络，使其具有更灵活和更有效的函数逼近能力。经过学习的各

个参数，通过较少的级数项组成的小波神经网络就能达到优良的逼近效果。小波的紧支性使小波神经网络在对含有急剧变化和不连续函数的学习方面具有优越性，不仅非线性映射能力更强，而且还具有提取信号细节分量的能力。常用的母小波为 Morlet 小波函数。

紧致型小波神经网络结构如图 9-8 所示，其学习样本经输入层作用于小波神经网络。输入端有 N 个节点，隐层有 P 个节点，输出层有 Q 个节点，给定 K 组输入输出样本，$X_k=(x_1^k, x_2^k, \cdots, x_N^k)$ 为网络输入，$Y_k=(y_1^k, y_2^k, \cdots, y_Q^k)$ 为网络输出。隐层选取 Morlet 小波 $h(t)=\cos(1.75t)\mathrm{e}^{(-t^2/2)}$ 为传输函数。网络的输出层的传输函数为 Sigmoid 函数式 (9-2)，先对网络隐层小波节点的输出加权求和，经 Sigmoid 函数变换后，得到最终的网络输出。这样有利于处理分类问题，同时减少训练过程中发散的可能性。

9.2.3　紧致型小波神经网络的学习算法

下面对紧致型小波神经网络的训练算法进行阐述。

取代价函数为

$$E=\sum_{k=1}^{K}E^k=\frac{1}{2}\sum_{k=1}^{K}\sum_{q=1}^{Q}(d_q^k-y_q^k)^2 \tag{9-19}$$

式中　d_q^k——输出层第 q 个神经元的期望输出；

y_q^k——其对应的实际输出。

隐层各神经元的输入和实际输出值分别为

$$I_p^k=\sum_{n=1}^{N}w_{np}x_n^k \tag{9-20}$$

$$O_p^k=h\left(\frac{I_p^k-b_p}{a_p}\right) \tag{9-21}$$

输出层各神经元的输入和实际输出值分别为

$$I_q^k=\sum_{p=1}^{P}w_{pq}O_p^k \tag{9-22}$$

$$y_q^k=f(I_q^k) \tag{9-23}$$

小波神经网络训练算法逐步更新神经元间的连接权值及小波的伸缩因子和平移因子

令 $t=\dfrac{I_p^k-b_p}{a_p}$，则有

$$\frac{\partial O_p^k}{\partial I_p^k}=-1.75\sin(1.75t)\mathrm{e}^{(-t^2/2)}\cdot\frac{1}{a_p}-\cos(1.75t)\mathrm{e}^{(-t^2/2)}\cdot\frac{t}{a_p} \tag{9-24}$$

$$\frac{\partial O_p^k}{\partial a_p}=1.75\sin(1.75t)\,e^{(-t^2/2)}\cdot\frac{t}{a_p}+\cos(1.75t)\,e^{(-t^2/2)}\cdot\frac{t^2}{a_p} \tag{9-25}$$

$$\frac{\partial O_p^k}{\partial b_p}=1.75\sin(1.75t)\,e^{(-t^2/2)}\cdot\frac{1}{a_p}+\cos(1.75t)\,e^{(-t^2/2)}\cdot\frac{t}{a_p} \tag{9-26}$$

将 E_q^k 分别对各参数求偏导得

$$\frac{\partial E_q^k}{\partial w_{pq}}=(Y_q^k-y_q^k)\cdot y_q^k\cdot(1-y_q^k)=\delta_{pq} \tag{9-27}$$

$$\frac{\partial E_q^k}{\partial w_{np}}=\sum_{q=1}^{Q}(\delta_{pq}w_{pq})\cdot\frac{\partial O_p^k}{\partial I_p^k}\cdot x_n^k=\delta_{np} \tag{9-28}$$

$$\frac{\partial E_q^k}{\partial a_p}=\sum_{q=1}^{Q}(\delta_{pq}w_{pq})\cdot\frac{\partial O_p^k}{\partial a_p}=\delta_{a_p} \tag{9-29}$$

$$\frac{\partial E_q^k}{\partial b_p}=\sum_{q=1}^{Q}(\delta_{pq}w_{pq})\cdot\frac{\partial O_p^k}{\partial b_p}=\delta_{b_p} \tag{9-30}$$

修正各参数：

$$w_{pq}^{new}=w_{pq}^{old}+\eta\sum_{k=1}^{k}\delta_{pq}+\lambda\Delta w_{pq}^{old} \tag{9-31}$$

$$w_{np}^{new}=w_{np}^{old}+\eta\sum_{k=1}^{K}\delta_{np}+\lambda\Delta w_{np}^{old} \tag{9-32}$$

$$a_p^{new}=a_p^{old}+\eta\sum_{k=1}^{K}\delta_{a_p}+\lambda\Delta a_p^{old} \tag{9-33}$$

$$b_p^{new}=b_p^{old}+\eta\sum_{k=1}^{K}\delta_{b_p}+\lambda\Delta b_p^{old} \tag{9-34}$$

式中 η——学习率；

λ——动量因子；

a_p、b_p——小波函数的伸缩因子和平移因子。

此算法的具体步骤为：

1）网络及学习参数的初始化。即将小波的伸缩因子 a_p，平移因子 b_p，网络连接权值 w_{np}、w_{pq} 以及学习率 $\eta(\eta>0)$ 和动量因子 $\lambda(0<\lambda<1)$ 赋予初始值，并令输入样本计数器 $k=1$。

2）提供训练数据集。即输入学习样本 $\{(x_1^k, x_2^k, \cdots, x_N^k)\mid k=1, 2, \cdots, K\}$ 及相应的期望输出 $\{(d_1^k, d_2^k, \cdots, d_Q^k)\mid k=1, 2, \cdots, K\}$。

3）前向传播过程。对给定模式训练对，计算网络的实际输出及隐单元的输出，按式（9-20）~式（9-23）进行计算。

4）反向传播过程。用式（9-19）计算误差 E_q^k，用式（9-27）~式（9-30）

计算梯度向量。

5）用式（9-31）~式（9-34）修正网络参数。

6）随机选取下一个训练样本给网络。令 $k=k+1$，如果 $k<K$，则转至步骤 3）循环，直至 K 个模式全部训练完毕。

7）计算代价函数 E 是否满足要求，若满足 $E<\varepsilon$，则训练结束；若不满足，则转至步骤 3）循环。

9.2.4　小波神经网络与传统的 BP 网络比较

小波神经网络是一种前馈网络，这里我们以最常见的前馈神经网络中单隐层 BP 网络为例作一比较。由于小波神经网络具有快速衰减性，它属于局部逼近网络，而 BP 网络则是一种全局逼近网络，局部网络与全局网络相比，具有收敛速度快、易适应新数据、可以避免有较大的外推误差等特点。

从结构上看，这两种网络没有本质的区别，有所不同的是：小波神经网的隐层节点的传递函数为小波函数，同时输入层到隐层的权值和阈值分别对应小波的伸缩和平移参数。

从可调参数的数目来看，对于同样的 n 个输入、p 个隐节点、q 个输出的网络结构，当利用先验知识确定了小波元之后，小波神经网络的可调参数为 $p\times q$ 个权系数。而 BP 网络则需要有 $n\times p+p\times q$ 个输入、输出权值及 $p+q$ 阈值需调整。可见小波神经网络的可调参数少，有利于缩短网络的训练时间。

从参数学习和训练算法上来看，小波神经网络权系数与网络输出呈线性关系，可用线性优化方法获得，特别对于正交小波神经网络，其权值有唯一解；而对于 BP 网络，由于其可调参数与网络输出是非线性关系，参数估计和优化必须基于非线性优化技术，学习时间长、收敛速度慢，尤其是在运用梯度下降法训练时很容易陷入局部极小。

小波神经网络是将小波分析引入到神经网络中而形成的一种新型前馈网络，它较常规前馈神经网络具有如下优点：

1）可借助小波的时频域分析理论，使网络结构的确定有一定的理论指导，避免网络结构设计上的盲目性。

2）网络中的某些参数可以借助信号的物理意义来确定（如平移参数 b 和伸缩参数 a，可根据信号时频域特性来确定），这样就能通过减少网络的训练参数，大大缩短网络的训练时间。

3）网络权值学习算法较常规神经网络简单，并且误差函数关于权值是一个凸函数，不存在局部极小点，收敛速度较快。

9.2.5 小波神经网络应用实例

利用紧致型小波神经网络对函数 $y=\sin(8\pi x)+\cos(6\pi x)$ 进行逼近。输入层、输出层及隐含层的神经元数目分别为 1，1，8。网络的训练样本集为 {0，0.01，…，0.3}，隐含层的传递函数为 morlet 小波函数。经过 9 次训练后，网络的误差达到了 0.001。

对训练好的网络进行测试，测试样本为 {0.005，0.015，…，0.305}。可以得到网络对函数的逼近情况，如图 9-9 所示。其中“+”表示函数的实际值，“·”表示网络的输出结果。网络的误差曲线如图 9-10 所示。由图 9-9 及图 9-10 可知，小波神经网络具有很好的非线性逼近性能，同时具有快速的收敛能力。

将图 9-9 和图 9-10 与图 9-5 和图 9-6 相比较可见，小波神经网络应用于函数逼近与 BP 神经网络应用于函数逼近相比，其训练次数更少，误差曲线更平直，收敛效果更好，函数逼近效果更明显。因此，小波神经网络的函数逼近性能优于 BP 神经网络。

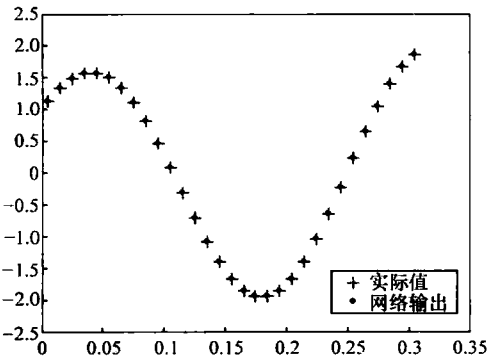

图 9-9 函数逼近结果

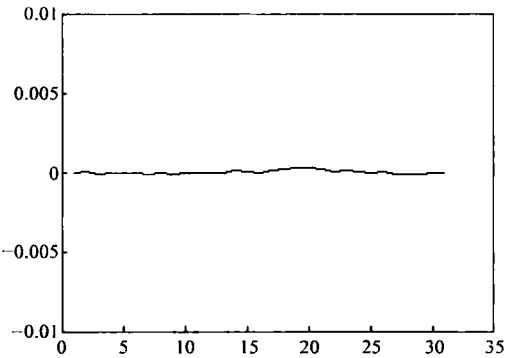

图 9-10 网络的误差曲线

9.3 基于小波神经网络的液压泵故障诊断实验

9.3.1 实验条件及数据采集

系统主溢流阀调定压力为 5MPa，采集液压泵在正常工作状态和脱靴故障状态时的泵壳振动信号和泵出口压力脉动信号，采样频率为 20kHz 条件下。由于电机转速为 1500r/min，故泵的转轴频率为 25Hz，泵每转一周的时间为 0.04s。

分别选取液压泵在正常工作状态和脱靴故障状态时的泵壳振动信号和泵出口压力脉动信号各 3 组数据作为小波神经网络的训练样本，再选取泵在两种运行状态下

的振动信号和压力信号另外各 2 组数据作为小波神经网络的测试样本。共得到 12 组训练样本和 8 组测试样本。

9.3.2　基于松散型小波神经网络的液压泵故障诊断

1. 松散型小波神经网络的构造

1）对原始信号采样序列进行 N 层正交小波包分解，共得到 2^N 个子带的小波包分解系数序列。

2）分别对各子带的展开系数运用小波包重构算法进行重构，得到 2^N 个重构信号 $\{s_j | j=1, 2, \cdots, 2^N\}$。

3）求各子带重构信号的能量。设 E_j 为小波包分解列第 j 个子带重构信号的能量，则有

$$E_j = \sum_{k=1}^{n} |s_{j,k}|^2 \qquad j = 1,2,\cdots,2^N \tag{9-35}$$

式中　n——各子带重构信号离散点的个数。

4）构造特征向量。以小波包分解各子带重构信号的能量为元素构造一个特征向量，即 $\boldsymbol{E} = (E_1, E_2, \cdots, E_{2^N})$，之后对向量作归一化处理，令 $E = \left(\sum_{j=1}^{N} |E_j|^2\right)^{1/2}$，则 $\boldsymbol{T} = (E_1/E, E_2/E, \cdots, E_{2^N}/E)$ 为归一化后的特征向量。

5）将向量 $\boldsymbol{T}$ 作为神经网络的输入向量，再根据经验确定采用何种神经网络及隐层数和隐层神经元数等。

6）利用试验样本对神经网络进行训练，调整权值和阈值，从而建立起所需的小波神经网络。

松散型小波神经网络用于故障诊断的流程如图 9-11 所示。

图 9-11　故障诊断流程图

2. 基于松散型小波神经网络的液压泵故障诊断

采用的信号仍然是在主溢流阀调定压力为 5MPa，采样频率为 20kHz 条件下，液压泵在正常工作状态和脱靴故障状态时的泵壳振动信号和泵出口压力脉动信号。

本文利用 Daubechies 3 小波对信号进行 3 层小波包分解，把信号分解成 8 个频率段。利用分解后各个频段上重构信号的能量计算得到神经网络的归一化特征输入向量。

神经网络采用 3 层 BP 网络，输入节点数目为 8，即对应小波包分解后 8 个

频段内的归一化能量值；输出神经元为2个，有两种情况，液压泵正常状态期望输出为（1，0），脱靴故障状态期望输出为（0，1）；隐层节点可由经验公式确定为6个。

将采集到的两种状态下的压力信号和振动信号各3组数据作为训练样本，剩余的各2组数据作为测试样本。网络的训练样本和测试样本分别如表9-1和表9-2所示。

表9-1 训练样本

状 态	C1	C2	C3	C4	C5	C6	C7	C8
正常压力信号（$\times10^{-4}$）	9990	1.5590	1.6448	1.2408	1.2644	1.4185	1.5745	1.1522
	9991	1.7506	1.5285	8.9876	1.2896	1.0780	1.2104	1.0097
	9990	1.7103	1.8328	1.2079	1.2917	1.3059	1.2129	1.0969
正常振动信号（$\times10^{-4}$）	580	302	2353	871	1062	2009	1925	897
	502	276	3309	590	725	1663	2140	795
	474	295	1771	729	873	2565	1977	1316
故障压力信号（$\times10^{-4}$）	9987	8.0063	0.3882	1.8494	0.2018	0.2203	0.1705	0.2061
	9990	7.3366	0.3216	0.3501	0.1968	0.2420	0.2102	0.2457
	9988	8.4557	0.3590	2.0453	0.1709	0.1879	0.1773	0.2158
故障振动信号（$\times10^{-4}$）	266	130	2293	253	1945	666	3207	1238
	180	1209	2945	450	688	1968	1338	1221
	307	373	788	374	721	3609	2404	1423

表9-2 测试样本

状 态	C1	C2	C3	C4	C5	C6	C7	C8
正常压力信号（$\times10^{-4}$）	92	1.8962	1.2338	1.0189	9.1623	1.0749	1.0331	1.0721
	9992	1.4829	1.2884	1.1274	1.0196	1.2920	1.2984	7.6897
正常振动信号（$\times10^{-4}$）	350	215	2729	425	1273	1789	2087	1132
	408	279	3830	535	472	1507	1546	1425
故障压力信号（$\times10^{-4}$）	9988	8.5370	0.3549	2.1816	0.1811	0.2204	0.1393	0.2120
	9987	9.2946	0.2946	2.2499	0.1630	0.2049	0.1930	0.2095
故障振动信号（$\times10^{-4}$）	81	23	1971	842	1115	750	542	4676
	517	266	1274	2417	395	392	2085	2654

表 9-3　诊断结果

状　态	S1	S2	S3	S4	S5	S6	S7	S8
液压泵状态	正常	正常	正常	正常	故障	故障	故障	故障
期望输出	(1,0)	(1,0)	(1,0)	(1,0)	(0,1)	(0,1)	(0,1)	(0,1)
实际输出	(0.9290,0)	(0.9506,0)	(1,0)	(1,0)	(0.0232,1)	(0.0116,1)	(0,1)	(0,1)
诊断结果	正常	正常	正常	正常	故障	故障	故障	故障

对这 12 组训练样本进行训练，网络训练误差曲线如图 9-12 所示。可见，经过 10 次训练后，网络的性能就达到了要求。再用训练好的网络对 8 组测试样本进行测试，诊断结果如表 9-3 所示。比较表 9-3 中的期望值和识别结果，可见二者是一致的，能对脱靴故障进行正确诊断，试验取得了较理想的效果。

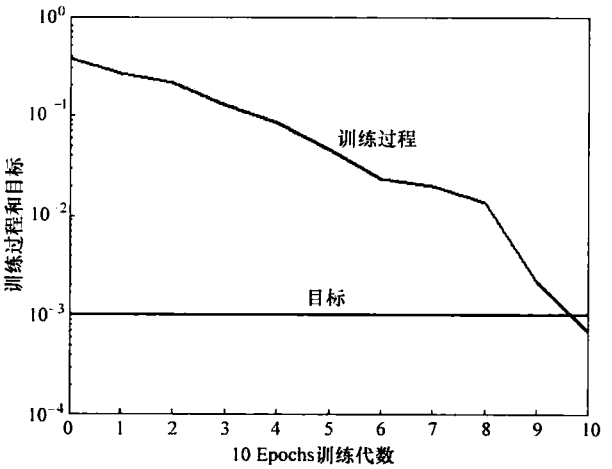

图 9-12　网络训练误差曲线

由以上分析可以得出如下结论：

1）根据小波包分解的频带划分特性，准确地提取了液压泵脱靴故障的特征，可保证不丢失故障的特征信息。

2）只要选择足够多的实际故障样本训练 BP 神经网络，网络就能具有较好的容错性和稳定性。

3）用小波包分解得到的归一化能量值作为神经网络输入特征向量，减小了神经网络的规模及计算量，提高了诊断的准确性。

4）在用小波包分解对信号进行预处理的基础上，采用 BP 神经网络对信号进行故障诊断。通过理论分析和试验数据表明，基于小波分解得到的归一化能量特征向量，可以作为故障特征向量对液压泵进行故障诊断，并达到较好的效果。此方法可以推广到其他旋转机械的故障诊断中。

9.3.3 基于紧致型小波神经网络的液压泵故障诊断

1. 紧致型小波神经网络的构造

在主溢流阀调定压力为5MPa，采样频率为20kHz条件下，采集液压泵在正常工作状态和脱靴故障状态时的泵壳振动信号和泵出口压力脉动信号。

利用Daubechies 3小波对原始信号进行3层小波分解，把分解后8个频段上的均值作为神经网络的特征输入向量。因此输入神经元数目选为8。

小波神经网络采用3层网络。隐层传递函数选取Morlet小波 $h(t)=\cos 1.75t\cdot e^{-t^2/2}$，隐层神经元个数可由经验公式确定为6个。网络的输出层传递函数选为Sigmoid函数。先对网络隐层小波神经元的输出加权求和，经Sigmoid函数变换后，得到最终的网络输出。输出神经元选为2个，有两种情况：液压泵正常状态期望输出为（1，0），脱靴故障状态期望输出为（0，1）。紧致型小波神经网络结构如图9-8所示。

2. 基于紧致型小波神经网络的液压泵故障诊断

将采集到的两种状态下的压力信号和振动信号各3组数据作为训练样本，剩余的各2组数据作为测试样本。对这12组训练样本进行训练，再用训练好的网络对8组测试样本进行测试，网络的训练样本和测试样本分别如表9-4和表9-5所示。诊断结果如表9-6所示，由该表可见紧致型小波神经网络能够对脱靴故障进行正确诊断，取得了较理想的实验效果。

表9-4 训练样本

状　态	C1	C2	C3	C4	C5	C6	C7	C8
正常压力信号	0.0001	-0.0001	-0.0007	0.0008	-0.0004	-0.0005	0.0010	1.8913
	-0.0002	0.0007	0.0004	-0.0003	0.0016	-0.0013	0.0004	1.9143
	0.0002	0	-0.0002	-0.0008	-0.0007	-0.0008	-0.0007	0.8858
正常振动信号	-0.0128	0.0076	0.0149	0.0034	0.0205	0.0230	0.0336	-0.3991
	0.0010	-0.0313	0.0026	0.0005	-0.0022	0.0102	0.0306	-0.0672
	0.0029	-0.0171	-0.0074	0.0015	-0.0021	0.0279	-0.0003	-0.0864
故障压力信号	-0.0001	0.0005	0.0002	-0.0082	0.0035	-0.0510	0.0783	5.5277
	-0.0001	0.0002	-0.0008	0.0037	0.0055	-0.0556	0.0846	5.4367
	0	0.0003	0.0007	0.0081	0.0075	-0.0538	0.0876	5.3163
故障振动信号	0.0015	0.0289	-0.0040	0.0119	0.0096	-0.0121	-0.0010	0.0587
	-0.0009	0.0159	-0.0126	0.0004	-0.0162	0.0150	-0.0072	0.0629
	-0.0044	-0.0058	0.0040	-0.0131	0.0052	-0.0082	-0.0014	0.0538

表 9-5　测试样本

状　态	C1	C2	C3	C4	C5	C6	C7	C8
正常压力信号	0 -0.0001	0.0001 -0.0002	-0.0007 -0.0004	-0.0006 0.0004	-0.0008 -0.0009	-0.0025 -0.0023	-0.0005 0.0004	1.8708 1.8670
正常振动信号	-0.0019 -0.0067	-0.0061 -0.0230	0.0036 -0.0027	0.0047 0.0138	0.0167 0	0.0237 -0.0128	0.0350 0.0148	-0.0787 -0.2286
故障压力信号	0.0002 0.0003	-0.0001 -0.0002	-0.0005 0	0.0048 -0.0007	0.0064 0.0027	-0.0496 -0.0375	0.0896 0.0949	5.2521 5.3907
故障振动信号	0.0084 0.0008	0.0006 0.0059	0.0017 0.0053	0.0135 0.0090	-0.0036 -0.0200	0.0131 -0.0078	-0.0034 -0.0306	0.0439 0.0209

表 9-6　诊断结果

状　态	S1	S2	S3	S4	S5	S6	S7	S8
液压泵状态	正常	正常	正常	正常	故障	故障	故障	故障
期望输出	(1, 0)	(1, 0)	(1, 0)	(1, 0)	(0, 1)	(0, 1)	(0, 1)	(0, 1)
实际输出	(0.9935, 0.0027)	(0.9934, 0.0027)	(0.9242, 0.0664)	(0.9583, 0.1000)	(0.0497, 0.9565)	(0.0494, 0.9568)	(0.0040, 0.9947)	(0.8015, 0.0769)
诊断结果	正常	正常	正常	正常	故障	故障	故障	故障

由于松散型小波神经网络在进行数据预处理和网络训练与诊断时，分别使用了 MATLAB 小波工具箱和 MATLAB 神经网络工具箱，因此训练时间较短。而在 MATLAB 里没有专门的小波神经网络工具箱，因此在使用紧致型小波神经网络进行故障诊断时，需要编制较为复杂的 MATLAB 程序，因此小波神经网络的学习训练时间较长。紧致型小波神经网络与松散型小波神经网络与相比，二者的故障诊断准确性都很高。

参 考 文 献

[1] Y C Pati, P S Krishnaprasad. Analysis and Syntasis of Feedforward Neural Net-working Discrete Affine Wavelet [J]. IEEE Trans on NN, 1993, 4 (1): 73-75.

[2] Q H Zhang, Albert Benveniste. Wavelet Network [J]. IEEE Transactions on Neural Network, 1992, 3 (6): 889-898.

[3] 郑海波，陈心昭，李志远，等. 小波神经网络故障诊断系统的设计与应用[J]. 农业机械学报，2002，33 (1)：73-76.

[4] 张新红，郑丕谔. 正交小波网络及其在经济预测中的应用 [J]. 系统工程学报，2006，21 (2)：196-200.

[5] 高隽. 人工神经网络原理及仿真实例 [M]. 北京：机械工业出版社，2003.

[6] 王洪元，史国栋．人工神经网络技术及其应用［M］．北京：中国石化出版社，2002.

[7] 罗晓署．人工神经网络理论·模型·算法与应用［M］．桂林：广西师范大学出版社，2005.

[8] 陆景丽．基于小波神经网络的液压泵故障诊断方法及实验研究［D］．秦皇岛：燕山大学，2007：42-63.

[9] Jiang Wanlu（姜万录），Lu Jingli. Study on Fault Diagnosis Based on Wavelet Neural Network for Hydraulic Pump［C］// Proceedings of 5th International Symposium on Fluid Power Transmission and Control（ISFP' 2007），June 6-8，2007，Beidaihe，China：1085-1089.

第 10 章　证据理论和神经网络集成的信息融合故障诊断方法

本章对证据理论方法进行了深入的研究，提出了一种证据理论和神经网络相结合的智能故障诊断方法。基于该方法建立了液压泵的智能故障诊断模型，通过液压泵脱靶故障的诊断实验证明，该方法对此故障有良好的诊断效果。

10.1　数据融合技术

仪器科学与技术的发展使传感器的性能大大提高，在多传感器系统中，信息表现形式的多样性、信息容量以及信息处理速度等都已大大超出了传统信息处理方法的处理能力，便产生了一种新的信息综合处理方法——数据融合技术。一般说来，数据融合是针对一个系统中使用多个或多种传感器这一特定问题而采取的新的信息处理方法，因此数据融合又称为多传感器信息融合（Multi-sensor Information Fusion），本章将不加区分地使用数据融合和信息融合这两个术语。

10.1.1　数据融合的基本原理

多传感器信息融合是人类和其他生物系统中普遍存在的一种基本功能。人类能非常自然地运用人体的各个感觉器官，如眼、口、耳、鼻、肢体等将外部世界的信息包括图像、味道、声音、气味、触觉组合起来，并使用先验知识去分析、理解、推测和判定周围环境的变化和正在发生的事件。由于人类感官具有不同的度量特征，因而可测出不同空间范围内的各种物理现象，这一过程说起来简单，其实是极为复杂的。人类对事物的综合认识、判断与处理过程具有自适应性，但人类把各种信息或数据转换成对环境的有价值的准确解释，不仅需要大量不同的高智能化处理，而且需要足够丰富的适用于解释组合信息含义的知识，也称先验知识。因此，人的先验知识越丰富，综合信息处理能力越强。

智能化的检测系统要想获得对周围环境的认识，必须应用传感器技术。因此，传感器是智能系统感知外部世界信息的“感官”，具有数据融合能力的智能系统，是对人类高智能化信息处理能力的一种模仿。

多传感器信息融合实际上是对人脑综合处理复杂问题的一种功能模拟。在多传感器系统中，各种传感器提供的信息可能具有不同的特征：时变的或非时变的、实时的或非实时的、快变的或缓变的、模糊的或确定的、精确的或不精确的、可靠的

或非可靠的、互补的或矛盾的、相容的或冲突的。多传感器信息融合的基本原理就像人脑综合处理信息的过程一样，它充分地利用多个传感器资源，通过对各种传感器及其观测信息的合理支配与使用，将各种传感器在空间和时间上的互补与冗余信息依据某种优化准则组合起来，产生对观测对象的一致性解释和描述。数据融合的目的是通过数据组合推导出更多的信息，得到最佳协同作用的结果，即利用多个传感器共同或联合操作的优势，提高传感器系统的有效性，消除单个或少量传感器的局限性。

多传感器数据融合系统与所有单传感器信号处理或低层次的多传感器数据处理方式相比，后者是对人脑信息处理的一种低水平模仿，它们不能像多传感器数据融合系统那样有效地利用多传感器资源。多传感器数据融合系统可以更大程度地获得被探测目标和环境的信息量。多传感器数据融合与经典信号处理方法之间也存在本质的区别，其关键在于数据融合所处理的多传感器信息具有更复杂的形式，而且可以在不同的信息层次上出现，这些抽象的信息层包括数据层、特征层和决策层。

10.1.2 数据融合的定义

自从海湾战争以来，致力于数据融合研究的人数和这一领域论著的数量有了显著的增加，每年都有大量新的研究成果发布，这使得这门学科的内容变得越来越丰富。但是，由于所研究内容的广泛性和多样性，目前要给出数据融合的准确概念还是比较困难的。美国国防部 JDL（Joint Directors of Laboratories）从军事应用的角度将数据融合定义为这样的一种过程：把来自多个传感器和信息源的数据和信息加以联合（Association）、相关（Correlation）和组合（Combination），以获得精确的位置估计（Position Estimation）、身份估计（Identity Estimation）、对战场情况和威胁及其重要程度进行适时完整的评价。这一定义基本上是对数据融合技术所期望达到的功能描述，包括低层次上的位置估计和身份估计，以及高层次上的态势评估（Situation Assessment）和威胁评估（Threat Assessment）。

随着电子信息技术的迅猛发展，数据融合技术作为消除不确定因素、提供准确观测结果与新的观测信息的智能化处理技术也被引入民用工程领域，如：智能检测系统、工业过程监视、机器人、空中交通管制、疾病诊断等。目前，普遍认同的数据融合定义为：充分利用不同时间与空间的多传感器信息资源，采用计算机技术，对按时序获得的多传感器观测信息在一定准则下加以自动分析、综合、支配和使用，获得对被测对象的一致性解释与描述，以完成所需的决策和估计任务，使系统获得比它的各组成部分更优越的性能。因此，多传感器系统是数据融合的硬件基础，多源信息是数据融合的加工对象，协调优化和综合处理是数据融合的核心。

10.1.3　数据融合的层次

在军事领域，数据融合层次划分为：检测级、位置级、属性级（目标识别）、态势评估和威胁估计级。在工程领域，数据融合划分为数据层、特征层、决策层，这种划分更加合理。

（1）数据层融合　数据层融合是直接在采集到的原始数据的层次上进行的融合。由于数据并未经过处理，所以是最低层次的融合，同时也决定融合的数据必须来源于同质或相同量级的传感器。有了融合的原始数据就可以完成类似于单传感器一样的数据处理过程。

此层次融合的优点是直接融合现场数据，失真小，能提供其他融合层次所不能提供的全面信息，信息量损失小。但所需处理的传感器的数据量大，处理代价高、时间长、实时性差，原始数据易受噪声污染，需融合系统具有较好的容错能力。

（2）特征层融合　先对各传感器采集到的原始数据进行数据层信息的表示量或统计量提取，然后对提取的特征层信息进行综合分析和处理。特征层融合实现了对原始数据的压缩，减少了大量干扰数据，易于实现实时处理，并具有较高的精确度。目前大多数 C^3I 系统（Communication，Command，Control and Intelligence systems）及其他领域应用的数据融合的研究都是在该层次上展开。

（3）决策层融合　根据观测数据各个传感器或局部处理系统可得到局部判决，然后融合中心对来自每个传感器的判决结果进行融合得到全局判决，所以需要的通信量小，对传输带宽的要求低，容错能力比较强。对传感器类型的要求比较低，可以是异质也可以是同质的传感器。但是判决精度降低，误判决率上升，同时数据处理的代价比较高。

10.1.4　融合系统的模型结构

由于数据融合理论尚不成熟，而应用领域又非常广泛，目前还没有形成对所有应用环境普适性的具体融合结构。一般来说，融合结构类型要求既能对给定任务具有优良的检测和识别的性能，也要受技术能力制约，同时又不与传感器的质量、数据传输的带宽有关。融合模型的结构大体可分为集中式结构、分布式结构两种基本形式及其二者的混合结构形式。

集中式结构中各个局部传感器直接把底层数据或经简单预处理的数据传入融合中心，因此需要融合系统有足够的带宽和强大的数据处理能力，如图 10-1 所示。

分布式结构接受各传感器的局部判决，而不是底层数据，大大减轻了系统内部的通信压力，提高了系统的可靠性及实时性，如图 10-2 所示。

同时还有由两种结构组成的混合结构，混合结构是根据应用的需要折中了集中式和分布式的优缺点的结构，具有灵活性和结构复杂性。

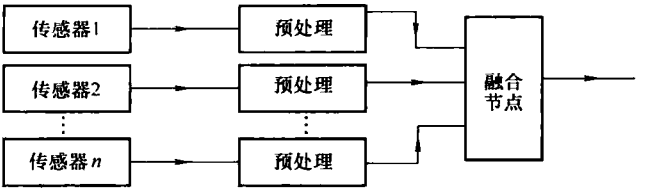

图 10-1 集中式融合结构

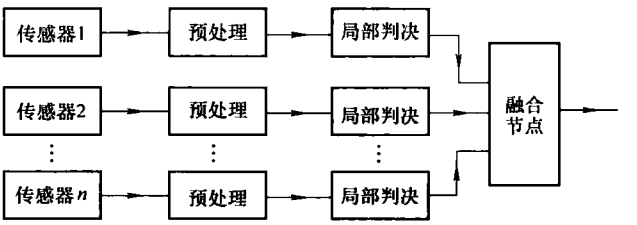

图 10-2 分布式融合结构

10.1.5 多传感器融合算法

数据融合涉及检测技术、信号处理、通信、模式识别、决策论、不确定性理论、估计理论、最优化理论等众多科学领域。下面介绍几种比较成熟的融合算法。

1. 基于统计和估计的融合算法

（1）卡尔曼（Kalman）滤波 卡尔曼滤波是一种线性递推滤波算法，将状态变量引入滤波理论，用信息干扰的状态空间模型代替通常滤波采用的协方差函数，并把状态空间描述与离散时间联系起来。它是利用测得的新的数据加上前一时刻的估值，由系统本身的状态转移方程和一套递推公式求得新检测量的估值。

考虑无控制项的离散动态方程

$$\boldsymbol{X}_k = \boldsymbol{\Phi}_{k,k-1}\boldsymbol{X}_{k-1} + \boldsymbol{\Gamma}_{k,k-1}\boldsymbol{W}_{k-1} \tag{10-1}$$

$$\boldsymbol{Y}_k = \boldsymbol{C}_k\boldsymbol{X}_k + \boldsymbol{V}_k \tag{10-2}$$

式（10-1）为系统状态方程，式（10-2）为观测方程。其中，$\boldsymbol{X}_k \in \boldsymbol{R}^n$是 k 时刻目标的状态向量；$\boldsymbol{\Phi}_{k,k-1} \in \boldsymbol{R}^{n\times n}$为一步状态转移矩阵，把 k-1 时刻的状态转移到 k 时刻的状态；$\boldsymbol{W}_{k-1} \in \boldsymbol{R}^p$为过程噪声；$\boldsymbol{\Gamma}_{k,k-1} \in \boldsymbol{R}^{n\times p}$为过程噪声一步转移矩阵；$\boldsymbol{V}_{k-1} \in \boldsymbol{R}^m$为观测噪声；$\boldsymbol{Y}_k \in \boldsymbol{R}^m$是 k 时刻目标的观测向量；$\boldsymbol{C}_k \in \boldsymbol{R}^{m\times n}$为观测矩阵。

在基本卡尔曼滤波算法中，状态的一步预测估计

$$\hat{\boldsymbol{X}}_{k,k-1} = \boldsymbol{\Phi}_{k,k-1}\hat{\boldsymbol{X}}_{k-1} \tag{10-3}$$

校正预测估计得到的状态估计值

$$\hat{\boldsymbol{X}}_k = \hat{\boldsymbol{X}}_{k,k-1} + \boldsymbol{K}_k(\boldsymbol{Y}_k - \boldsymbol{C}_k\hat{\boldsymbol{X}}_{k,k-1}) \tag{10-4}$$

其中，$\boldsymbol{Y}_k - \boldsymbol{C}_k\hat{\boldsymbol{X}}_{k,k-1}$为预估误差，称为新息。$\boldsymbol{K}_k$为待定的校正系数，又称为滤波增益

$$\boldsymbol{K}_k = \boldsymbol{P}_{k,k-1}\boldsymbol{C}_k^{\mathrm{T}}[\boldsymbol{C}_k\boldsymbol{P}_{k,k-1}\boldsymbol{C}_k^{\mathrm{T}} + \boldsymbol{R}_k]^{-1} \tag{10-5}$$

式中，$\boldsymbol{P}_{k,k-1}$为预报误差方差矩阵，$\boldsymbol{P}_k$为滤波估计误差方差矩阵，有

$$\boldsymbol{P}_{k,k-1} = \boldsymbol{\Phi}_{k,k-1}\boldsymbol{P}_{k-1}\boldsymbol{\Phi}_{k,k-1}^{\mathrm{T}} + \boldsymbol{\Gamma}_{k,k-1}\boldsymbol{Q}_{k-1}\boldsymbol{\Gamma}_{k,k-1}^{\mathrm{T}} \tag{10-6}$$

$$\boldsymbol{P}_k = [\boldsymbol{I} - \boldsymbol{K}_k\boldsymbol{C}_k]\boldsymbol{P}_{k,k-1} \tag{10-7}$$

式中，$\boldsymbol{Q}_k$是具有零均值高斯过程噪声 $\boldsymbol{W}_k \in \boldsymbol{R}^p$的对称非负定协方差矩阵；$\boldsymbol{R}_k$是具有零均值高斯过程噪声 $\boldsymbol{V}_k \in \boldsymbol{R}^m$的对称正定协方差矩阵。

卡尔曼滤波是基于最小二乘估计的一种信息优化方法，它的运算量较小，适于实时处理。卡尔曼滤波在目标跟踪、状态估计领域得到了有效的应用。

（2）贝叶斯（Bayes）法　贝叶斯准则是多传感器融合技术应用中最早被采用的融合算法。贝叶斯基本公式为

$$P(h|e) = \frac{P(e|h)P(h)}{P(e)} \tag{10-8}$$

式中　h——假设变量；

e——证据随机变量。

贝叶斯方法在利用样本提供的信息时也充分利用了先验的信息 $P(h)$，以先验分布为基础点和出发点，克服了古典统计中精度和信度是前定的（即在采样之前就确定下来）而不依赖于样本的不合理性。但主观贝叶斯方法要求所有概率都是独立的，这在实际系统不易实现；并要求给出先验概率和条件概率这在实际中也是比较困难的；而且不能区分“不确定”和“不知道”这两类信息。

（3）D-S 证据理论　D-S 证据理论由 Dempster 于 1967 年提出的，后由 Shafer 加以扩充和发展。D-S 证据理论针对事件发生后的结果（证据）探求事件发生的主要原因（假设），分别通过各证据对所有的假设进行独立判断，得到各证据下各种假设的基本信度分配即 mass 函数，mass 函数是人们主观给出或凭经验和感觉给出的，也可以结合其他方法如以神经网络方法得到相对客观的 mass 函数值，然后把某假设在各证据下的判断信息进行融合，进而形成“综合”证据下该假设发生的融合概率。概率最大的假设即为判决结果。若令 $m_1 \sim m_n$表示 n 个信息的信度分配，如果它们是由独立的信息推得的，则信度的合成公式为

$$m(A) = \frac{\sum\limits_{\cap A_i = A}\prod\limits_{i=1}^{n} m_i(A_i)}{1 - \sum\limits_{\cap A_i = \phi}\prod\limits_{i=1}^{n} m_i(A_i)} \tag{10-9}$$

证据理论是概率论的推广，它满足更弱的公理系统。证据理论采用信任度

$Bel(A)=\sum_{B\subseteq A}m(B)$ 而不是概率表示不确定性，能区分“不知道”和“不确定”，同时也不需要先验概率和条件概率密度。并且证据理论可以实现对证据的组合，而主观贝叶斯方法则不能。但是证据理论在推理链较长时，合成公式使用很不方便，而且它需要各证据之间是彼此独立的，实际上有时难以满足要求。

随着推理过程的增加，识别框架变得很复杂，而且计算量也大大增加。同时，组合规则的组合灵敏度高，即基本概率赋值的很小变化都可以导致结果的很大变化。但证据理论以其优良的性能使其在数据融合中得到了广泛地应用。

2. 基于信息论的融合算法

（1）聚类分析法　聚类分析就是在一定条件下，按照目标间相似性把目标空间划分为若干子集，划分的结果应使表示聚类质量的准则函数为最大。当用距离来表示目标间的相似性时，其结果是将判别空间划分若干区域，每一区域相当于一个类别。常用的距离函数有明氏（Minkovsky）距离、欧式（Euclidean）距离、曼氏（Manhattan）距离、类块距离。判别聚类好坏的聚类准则，一种是凭经验，根据分类问题选择一种准则；另一种是确定一个函数，当函数取最值时认为是最佳分类。

聚类方法有很大的主观倾向性，因此在使用聚类分析方法时应对其有效性和可重复性进行分析，以形成有意义的属性聚类结果。

（2）表决法　表决法类似于生活中的民主选举，融合节点根据各个传感器提供的目标对象的局部判决，算法对这些判决进行综合判断。若超过阈值个数的传感器“同意”某个判决，准则判决结果即为此判决。表决法处理简洁，特别适合于实时融合，但融合误差也较大。为了提高算法精度可引入加权方法，门限技术以及其他方法。

（3）神经网络法　人工神经网络是一种模仿人脑信息处理机制的网络系统，它是由大量简单的人工神经元广泛连接而成的。它不需建立系统的物理模型，具有很强的非线性处理、自学习、自组织能力，并具有并行性和容错性，可对多传感器传递来的经特征提取得的各种数据进行判断。神经网络数据融合技术及其与其他融合方法的结合受到了广泛的关注。

神经网络连接权值的调整需要训练样本，同时网络学习的速度提高以及网络模型、网络层次和节点数的选择等问题有待进一步解决。

3. 基于认知模型的融合算法

（1）模糊逻辑法　由于数据融合系统的各种不确定性，难以用传统的二值逻辑进行判断。由 L. A. Zadeh 提出的模糊集合论是一种处理不精确、不完全信息的方法。利用模糊逻辑理论，通过模糊概率的计算实现数据融合判断。模糊逻辑的关键在于确立隶属度函数 μ_A，其类似于用 0 到 1 之间的值进行概率分布，即 $\mu_A: U\rightarrow$

[0，1]。隶属度函数μ_A可根据具体情况选取，如正态函数、三角函数、梯形函数、S 形函数等。隶属度是主观确定，它的评定没有形式化过程，但是隶属度函数形状对模糊推理的影响并不大。

（2）逻辑模板法　模板法是将一个预先确定的模式与观测数据进行匹配，根据条件被满足情况进行推理。融合系统利用多传感器的观测数据与预先规定的条件进行比较，从而得到观测是否匹配于一个预定模板的判决。

（3）专家系统　专家系统开始于 20 世纪 70 年代中期，它能够以人类专家的水平完成特别困难的某一专业领域的任务。它实质上是计算机程序，将人类专家的知识和经验以知识库的形式存入计算机，并模仿人类专家解决问题的推理方式和思维过程，运用人类的知识和经验对现实中的问题作出判断和决策。专家系统采用类似自然语言的方式表达，具有易于理解和维护，能对系统的结论作出解释等优点。但同时专家系统缺乏自学习和自我完善能力；随着问题复杂程度的提高，推理规则会出现组合爆炸的问题；专家系统的容错能力和处理不确定知识能力差；而且知识的存储容量与运行速度相互矛盾，实时数据处理困难。为了在充分发挥专家系统优势的同时克服其缺点，出现了模糊专家系统、神经网络专家系统等集成方法，取得了比较满意的结果。

10.2　证据理论和神经网络结合的诊断方法

证据理论是一种尚未成熟的方法，对它的研究方兴未艾，虽然存在一些缺点，但是其在不确定性推理方面的优良性能，使其在模式识别、故障诊断等许多方面得到了越来越广泛的应用。本节阐述 Dempster-Shafer 证据理论的基本原理、两个证据和多个证据的合成方法、基于证据理论的三种决策方法。最后在分析神经网络和证据理论优缺点的基础上，提出了神经网络和证据理论集成的数据融合故障诊断方法。

10.2.1　信度函数

1. 识别框架

证据理论讨论一个辨识框架 Θ（Frame of Discernment），它是关于命题的相互独立和可穷举的可能答案或假设的一个集合，一般为有限集合。

Θ 的选取依赖于我们的知识和认识水平。当一个命题对应于该框架的一个子集时，称框架能够识别该命题。按传统方法可以把 Θ 的幂集表示为 2^Θ，它是 Θ 的所有子集的集合（如果 Θ 有 N 个元素，那么 2^Θ 就有 2^N 个元素）。

2. 基本信度分配与信度函数

在识别框架 Θ 上，定义了一个集函数 m：$2^\theta \rightarrow [0, 1]$，满足

$$\begin{cases} m(\phi) = 0 \\ \sum_{A \subseteq \Theta} m(A) = 1 \end{cases} \tag{10-10}$$

称 m 为识别框架 Θ 上的基本信度分配（Basic Probability Assignment，BPA）。假如有 A 属于识别框架 Θ，则设 $m(A)$ 称为 A 的基本可信度，基本可信度反映了对 A 本身的信度大小。

设 Θ 为识别框架，m：$2^{\theta} \rightarrow [0, 1]$ 为框架 Θ 上的基本信度分配，则称由

$$Bel(A) = \sum_{B \subseteq A} m(B), \forall A \subseteq \Theta \tag{10-11}$$

所定义的函数 Bel：$2^{\theta} \rightarrow [0, 1]$ 为 Θ 上的信度函数（Belief Function）。

当基本信度分配 $m(A) = \begin{cases} 1 & A = \Theta \\ 0 & A \neq \Theta \end{cases}$ 时，信度函数的结构是最简单的，此时

$$Bel(A) = \begin{cases} 1 & A = \Theta \\ 0 & A \neq \Theta \end{cases} \tag{10-12}$$

该信度函数称为空信度函数。

设 Θ 是识别框架。集函数 Bel：$2^{\theta} \rightarrow [0, 1]$ 是信度函数当且仅当它满足：

（1）$Bel(\phi) = 0$

（2）$Bel(\Theta) = 1$

（3）$\forall A_1, A_2, \cdots, A_n \subseteq \Theta$，$n$ 为任意自然数

$$Bel\left(\bigcup_{i=1}^{n} A_i\right) \geqslant \sum_{i=1}^{n} Bel(A_i) - \sum_{i \neq j} Bel(A_i \cap A_j) + \cdots + (-1)^{n+1} Bel\left(\bigcap_{i=1}^{n} A_i\right) \tag{10-13}$$

证据理论还规定：如果 $m(A) > 0$，则称 A 为信度函数 Bel 的焦元（Focal Element），所有焦元并称为它的核心（Core）。

3. *似真度函数*

关于一个命题 A 的信任单用信度函数来描述还是不够的，因为 $Bel(A)$ 不能反映出我们怀疑 A 的程度即我们相信的非为真的程度，所以引入了似真度（Plausibility）的概念。

设 Bel：$2^{\theta} \rightarrow [0, 1]$ 是 Θ 上的一个信度函数，则定义 Pl：$2^{\theta} \rightarrow [0, 1]$ 如下

$$\forall A \subset \Theta, Pl(A) = 1 - Bel(\overline{A}) \tag{10-14}$$

称 Pl 为似然函数（Plausibility Function），也可以表示为

$$Pl(A) = \sum_{A \cap B \neq \phi} m(B) \tag{10-15}$$

信度函数 $Bel(A)$ 和似然函数 $Pl(A)$ 就是 Dempster 所说的上限概率和下限概率，因此置信区间 $[Bel(A), Pl(A)]$ 就是集合 A 的概率变化范围。实际上 $[Bel(A), Pl(A)]$ 表示命题 A 的不确定区间；$[0, Bel(A)]$ 表示命题 A 完全可信的

区间；而［0，$Pl(A)$］则表示对命题“A 为真”的不怀疑区间。$Pl(A)-Bel(A)$ 表示既不信任 A，也不信任 $\overline{A}$ 的程度，即对于 A 是真是假不知道的程度，如图 10-3 所示。

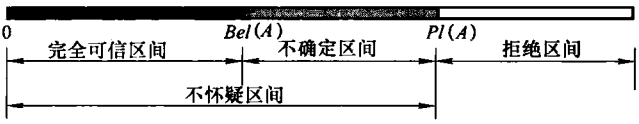

图 10-3　信息的不确定性

在证据理论中，下列几个信任度区间具有特别的含义：［1，1］表示 A 为真；［0，0］表示 A 为伪；［0，1］表示对 A 一无所知。

D-S 证据理论最吸引人的地方是它能够很好地表示信息的未知程度。当 D-S 证据理论把一个置信度赋给一个子集的同时，并不要求把剩余的置信度赋给子集的补集，即 $Bel(A)+Bel(\overline{A})\leqslant 1$，而 $1-Bel(A)-Pl(A)\geqslant 0$ 就表示了未知的程度。

10.2.2　Dempster 合成法则

1. 两个信度函数的合成

设 Bel_1 和 Bel_2 是同一识别框架 Θ 上的两个信度函数，m_1 和 m_2 分别是其对应的基本信度分配，焦元分别为 A_1，…，A_k 和 B_1，…，B_n，可表示为图 10-4。

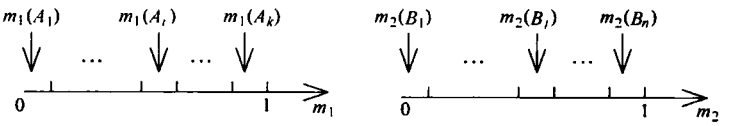

图 10-4　基本信度分配

在图 10-4 中，［0，1］中的某一段表示由各自的基本信度分配决定某一焦元上的信度，并不表示整个的识别框架。将图 10-4 中的两种信度分配综合起来，可得图 10-5。

将整个大矩形看做我们的总的信度，那么，一个一个的竖条就表示 m_1 分配到它的焦元 A_1，…，A_k 上的信度。同理，一个一个横条就表示 m_2 分配到它的焦元 B_1，…，B_n 上的信度。如图 10-5 所示，一个横条与一个竖条的交集是一个小矩形，该矩形具有测度 $m_1(A_i)\cap m_2(B_j)$。因为它是同时分配到

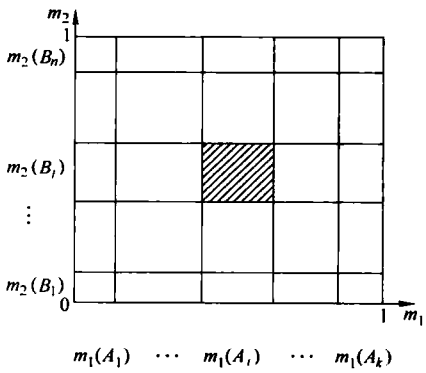

图 10-5　合成信度分配

$m_1(A_i)$和 $m_2(B_j)$上的，所以我们可以说 Bel_1和 Bel_2的联合作用就是将 $m_1(A_i)$和 $m_2(B_j)$确切地分配到$A_i \cap B_j$上。

但当 $A_i \cap B_j = \varnothing$时，如按上面的理解，将有一部分信度 $\sum_{A_i \cap B_j = \varnothing} m_1(A_i) m_2(B_j)$ 分配到空集上。所以必须丢弃这部分信度，但丢弃这部分信度以后，我们的总信度就要小于 1，为此还需在每一信度上乘一归一化因子

$$\left(1 - \sum_{A_i \cap B_j = \varnothing} m_1(A_i) \cap m_2(B_j)\right)^{-1} \tag{10-16}$$

我们可得到两个信度函数合成的公式为：

设 Bel_1和 Bel_2是同一识别框架 Θ 上的两个信度函数，m_1和 m_2分别是其对应的基本信度分配，焦元分别为 A_1，…，A_k和 B_1，…，B_n，若 $\sum_{A_i \cap B_j = \varnothing} m_1(A_i) m_2(B_j) < 1$，那么，由式(10- 17) 定义的函数 $m: 2^\theta \to [0, 1]$ 是基本信度分配

$$(m_1 \oplus m_2)(A) = \begin{cases} 0 & A = \varnothing \\ \dfrac{\sum_{A_i \cap B_j = A} m_1(A_i) m_2(B_j)}{1 - \sum_{A_i \cap B_j = \varnothing} m_1(A_i) m_2(B_j)} & A \neq \varnothing \end{cases} \tag{10-17}$$

由 m 所给定的信度函数的核心等于 Bel_1和 Bel_2的核心的交。由 m 给定的信度函数称为 Bel_1和 Bel_2的直和，记为 $Bel_1 \oplus Bel_2$。

2. 多个信度函数的合成

设 Bel_1，Bel_2，…，Bel_n是同一识别框架 Θ 上的 n 个置信度函数。若 Bel_1与 Bel_2是可以合成的，那么 Bel_1，Bel_2也是一个置信度函数；若该置信度函数与 Bel_3也是可以合成的，那么 $(Bel_1 \oplus Bel_2) \oplus Bel_3$仍是一个置信度函数。由此可依次类推定义 $Bel_1 \oplus \cdots \oplus Bel_n$若其存在，那么在构造它的过程中计算顺序是无关紧要的，多个置信度函数的直和可以表示这多个置信度函数对应证据联合作用的结果。

Bel_1，Bel_2，…，Bel_n可以一个一个地依次计算，也可以直接根据 Bel_1，Bel_2，…，Bel_n所对应的 m_1，…，m_n由下式直接计算

$$\forall A \subset \Theta, A \neq \varnothing$$

$$(m_1 \oplus m_2 \oplus \cdots \oplus m_n)(A) = K \sum_{\substack{A_1, A_2, \cdots, A_n \subseteq \Theta \\ A_1 \cap A_2 \cap \cdots \cap A_n = A}} m_1(A_1) m_2(A_2) \cdots m_n(A_n) \tag{10-18}$$

其中

$$K = \left(\sum_{\substack{A_1, A_2, \cdots, A_n \subseteq \Theta \\ A_1 \cap A_2 \cap \cdots \cap A_n \neq \varnothing}} m_1(A_1) m_2(A_2) \cdots m_n(A_n) \right)^{-1} \tag{10-19}$$

由式（10-19）可以对信度函数进行合成，信度函数可合成的条件是：

设 Bel_1，Bel_2，…，Bel_n是同一识别框架 Θ 上的信度函数，ξ_1，ξ_2，…ξ_n分别是其对应的核心，若 $\xi_1 \cap \xi_2 \cap \cdots \cap \xi_n \neq \varnothing$，那么 Bel_1，Bel_2，…，Bel_n就是可以合成的。

Dempster 合成法则的性质有：

（1）结合律　$(Bel_1 \oplus Bel_2) \oplus Bel_3 = Bel_1 \oplus (Bel_2 \oplus Bel_3)$

（2）交换律　$Bel_1 \oplus Bel_2 = Bel_2 \oplus Bel_1$

由于 Dempster 合成法则满足结合律和交换律，故在多证据合成时，可由 Bel_1，Bel_2，…，Bel_n的递归组合得到总的 Bel。

3. 证据的折扣

若对整个证据只有一个 $1-\alpha$ 的确信度，其中 $\alpha \in [0, 1]$，则可把 α 作为折扣率。在对证据打折扣的情况下，信度函数和基本概率赋值的变化如下：

设 Bel：$2^{\Theta} \rightarrow [0, 1]$是一个信任函数，$0 < \alpha < 1$，又设 Bel：$2^{\Theta} \rightarrow [0, 1]$满足

$$\begin{cases} Bel^{\alpha}(\Theta) = 1 \\ Bel^{\alpha}(A) = (1-\alpha) Bel(A), \forall A \subset \Theta \text{ 且 } A \neq \varnothing \end{cases} \tag{10-20}$$

则 Bel^{α}是一个信度函数。且

$$m^{\alpha}(\Theta) = (1-\alpha) m(\Theta) + \alpha \tag{10-21}$$

$$m^{\alpha}(A) = (1-\alpha) m(A), \forall A \subset \Theta \text{ 且 } A \neq \varnothing \tag{10-22}$$

10.2.3　基于证据理论的决策

信度合成后进行决策是与应用密切相关的问题。设 Θ 是识别框架，m 是基于 Dempster 合成规则得到的合成后的基本概率赋值，决策方法可有如下几种。

1. 基于信度函数的决策

1）根据合成后的 m，求出信度函数 Bel，则该信度函数就是我们的判决结果，这实际上是一种软判决。

2）若希望缩小真值的范围，则可以采用“最小点”原则求出真值。所谓“最小点”原则是指对于集合 A，信度函数为 Bel（A）。若在集合 A 中，去掉某个元素后的集合为 B_1，信度为 Bel（B_1），且 $|Bel(A) - Bel(B_1)| < \varepsilon$，则认为可去掉该元素，其中 ε 为预先设定的一个阈值。重复这个过程，直到某个子集 B_k不能再按“最小点”原则去掉元素为止，则 B_k即为判决结果。

2. 基于基本信度分配的决策

设 $\exists A_1$，$A_2 \subset \Theta$，满足

$$\begin{cases} m(A_1) = \max\{m(A_i), A_i \subset \Theta\} \\ m(A_2) = \max\{m(A_i), A_i \subset \Theta \text{ 且 } A_i \neq A_1\} \end{cases} \tag{10-23}$$

若有

$$\begin{cases} m(A_1) - m(A_2) > \varepsilon_1 \\ m(\Theta) < \varepsilon_2 \\ m(A_1) > m(\Theta) \end{cases} \tag{10-24}$$

则 A_1 即为判决结果，其中 ε_1，ε_2 为预先设定的阈值。

3. 基于最小风险的决策

设有状态集 $S=\{x_1, \cdots, x_q\}$，决策集 $\Omega=\{a_1, \cdots, a_p\}$，在状态为 x_l 时作出决策 a_i 的风险函数为 $r(a_i, x_l)$，$i=1, 2, \cdots, p$，$l=1, 2, \cdots, q$。又设有一批证据 E 在 S 上产生了一个基本信度分配，焦元为 $A_1, \cdots, A_n$，基本信度分配函数为 $m(A_1), \cdots, m(A_n)$，令

$$\bar{r}(a_i, A_j) = \frac{1}{|A_j|} \sum_{x_k \in A_j} r(a_i, x_k) \quad i = 1, \cdots, p; j = 1, \cdots, n \tag{10-25}$$

$$R(a_i) = \sum_{j=1}^{n} \bar{r}(a_i, A_j) m(A_j) \tag{10-26}$$

若 $\exists a_k \in \Omega$，使得 $a_k = \text{argmin}\{R(a_1), \cdots, R(a_p)\}$，则 a_k 即为所求的最优决策。

10.2.4 证据理论的优缺点

证据理论具有以下一些优点：

1）证据理论具有比较强的理论基础，既能处理随机性所导致的不确定性，又能处理模糊性所导致的不确定性。

2）证据理论可以依靠证据的积累，不断缩小假设集。

3）证据理论能将“不知道”和“不确定”区分开。

4）证据理论可以不需要先验概率和条件概率。而主观贝叶斯方法却需要假设的先验概率和条件概率。

5）证据理论能在不同层次上组合证据，而贝叶斯方法要求有统一的识别框架。

证据理论的主要缺点是：

1）证据理论具有潜在的指数复杂度。若假设集 $\Theta=\{\theta_1, \theta_2, \cdots, \theta_n\}$，有 n 个假设，有 k 个证据，则基本信度分配为 $m_j(A_{jl})$，$j=1, 2, \cdots, k$；$l=1, 2, \cdots, m$。极端情况下，每组证据有 $m=2^n$ 个基本信度分配值，即 $m_j(\{\phi\})$，$m_j(\{\theta_1\})$，$m_j(\{\theta_2\})$，$\cdots$，$m_j(\{\theta_1, \theta_2\})$，$\cdots$，$m_j(\{\Theta\})$，此时信息复杂度为 $k \cdot 2^n$。

组合两个证据主要要作 $m \times m$ 次相乘，所以计算复杂度为 $2^n \times 2^n$，组合 k 个证据的计算复杂度为 $k \times 2^n \times 2^n$。可见，利用 D-S 公式合成证据的计算复杂度与证据个数 k 呈线性关系，与假设集的模 n 成指数关系。

2）在推理链较长时，使用证据理论很不方便。这是因为在应用证据理论时，必须首先把相应于每个步骤和证据的信度函数变换成一个一般的识别框架，然后再

应用 Dempster 组合规则。当推理步骤增加时，由于最后结果的信度函数的焦元结构的复杂性也相应增加，所以 Dempster 规则的递归应用就会十分困难。

3）Dempster 组合规则具有组合灵敏性。有时，给基本信度分配一个很小的变化都可能导致结果很大的变化。此外，使用 Dempster 组合规则，要求证据是独立的，这个要求有时使用起来很不方便。

10.2.5　证据理论和神经网络集成的数据融合诊断方法

人工神经网络是模仿大脑神经元结构特性而建立的一种非线性动力学系统，它由大量的简单的非线性处理单元高度并联、互连而成，具有很强的数学模拟能力。它以分布存储、并行处理性、容错性、自学习、自组织和自适应性，避免了复杂的建模过程，在故障诊断领域也得到越来越广泛的研究。它在诊断领域的应用主要集中在三个方面：一是从模式识别的角度应用神经网络作为分类器进行故障诊断；二是从预测角度应用神经网络作为动态预测模型进行故障预测；三是从知识处理的角度建立基于神经网络的诊断专家系统。在所有应用的神经网络中，BP 网络应用最为广泛，也取得了良好的效果。证据理论以其对不确定性推理的优良特性，也已经在各种故障诊断中被广泛应用，并且与模糊技术等得到了结合运用。

但 BP 神经网络诊断存在着其固有的缺陷。首先，正确的诊断需要大量的样本训练集，而实际中神经网络训练的大量样本获得是困难的，由此造成了神经网络记忆的诊断知识存在先天性缺陷；其次广泛用于 BP 神经网络训练的梯度下降训练算法，存在训练速度慢的缺陷，并且随着网络结构复杂度的增加训练时间显著增加；再次由于网络结构的各项参数都是根据经验进行选择，所以很难保证选取的得当，网络的学习和泛化能力难以保障；再者当系统的诊断参数较多，征兆信息量很大时，采用的样本不可避免地存在矛盾性和随机性，此时若将高维的征兆信息同时输入到同一网络处理，不但训练时间长，而且训练效果差，有时甚至导致网络不收敛，这些都极大影响了神经网络的诊断效果。

为了克服神经网络的缺陷，可以如同人脑中不同区域处理不同的信息一样，不同的信号也应由各自的神经网络来诊断，这样就能将高维的征兆空间分解为较低维的征兆空间。将复杂的网络变成简单的网络，由不同的神经网络处理不同的低维征兆空间得到诊断结果，因此简化了网络结构，提高了网络训练的速度。因为简单的网络，只处理问题的某一方面，样本容易获得、结构容易确定，训练的速度可以提高，网络的泛化能力增强，诊断效果有保证。可是这样并没有充分利用不同征兆空间（在证据理论中成为证据空间）的信息。因此为了充分利用这些信息，可以对各子网络的诊断结果利用证据理论进行故障信息的融合处理。

而且证据理论的基本信度分配，是专家在所获证据的基础上，根据个人的经验

对识别框架中不同命题的支持程度的数字化表示，主观性很强。因此，对同一个证据对同一个命题不同的专家会给出不同的信度分配，有时差别很大。为了更客观地得到一证据对不同的命题的支持度的大小，可以将各个独立的低维的神经网络作为证据理论的一个证据，并把低维神经网络的输出值转化作为辨识框架上命题的基本可信度。经过证据理论的再次融合，类似于神经网络对信号层面数据的特征提取后的特征值再加以融合，充分利用证据源的信息，将大大提高识别的准确率，消除单一传感器包含信息的不全面和模糊性，因为证据理论可以对多个证据都支持的判断进行加强。

根据监测系统的情况把传感器分成独立的组，对每个测点的传感器或传感器组，对应一个局部神经网络进行局部诊断。这样可以简化各个网络，网络更小更简单，避免了单一诊断神经网络复杂的结构形式，以及某一传感器故障或数据源的错误对整个诊断系统带来的不良影响，诊断系统的容错性能增强，其原理如图 10-6 所示。

若诊断系统的诊断故障域为 q 个故障状态，对应证据理论的识别框架 Θ 就包括 q 个故障状态及系统的正常状态。同时，若系统共有 p 个局部诊断神经网络，每个网络对应的输出同样为 $q+1$ 个，分别对应 q 个故障状态及系统的正常状态。每个神经网络作为证据理论的一个独立证据，将神经网络的输出值经过变换，成为此证据下各种状态的可信度分配，为证据合成奠定基础。每个诊断网络诊断的能力是不同的，因此每个网络存在一个可靠性系数 α（即证据的折扣），表示了对判定结果的信任程度。

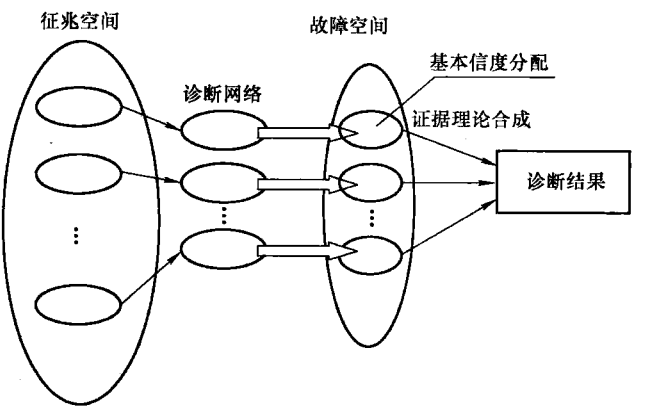

图 10-6 神经网络证据理论诊断模型

设第 i 个网络的第 j 个输出值为 $O_i(j)$，那么它对应的在本证据的基础上的对状态 j 的信度分配为

$$m_i(j) = \frac{O_i(j)}{\sum_{j=1}^{q} O_i(j)}\alpha_i \tag{10-27}$$

$$m_i(\Theta) = 1 - \alpha_i, \quad i = 1,2,\cdots,p \tag{10-28}$$

其中　$m_i(j)$ ——第 i 个证据对 j 状态的信度分配；

$m_i(\Theta)$——专家根据第 i 个证据不能确定的信度分配。

然后，根据多证据合成公式

$$m(A) = K \sum_{\substack{A_1,\cdots,A_n \subseteq \Theta \\ A_1 \cap \cdots \cap A_n = A}} m_1(A_1)\cdots m_n(A_n) \tag{10-29}$$

其中　$K = \left(\sum_{\substack{A_1,\cdots,A_n \subseteq \Theta \\ A_1 \cap \cdots \cap A_n \neq \varnothing}} m_1(A_1)\cdots m_2(A_n) \right)^{-1}$，可得到合成后的各状态的基本信度分配。

可由式(10- 11) 求得状态 x 的下限概率为

$$Bel(x) = \sum_{B \subseteq x} m(B), \forall X \subseteq \Theta \tag{10-30}$$

由式 (10-15) 可得 x 的上限概率为

$$Pl(x) = \sum_{x \cap B \neq \varnothing} m(B) \tag{10-31}$$

所以经过证据合成后各状态的置信区间 $[Bel, Pl]$，并由此进行诊断状态判断。这里采用以下判决原则：

若 $\exists x, y, z \subset \Theta$，满足

$$\begin{cases} Bel(x) \geqslant \varepsilon_1 \\ Bel(x) - Bel(y) > \varepsilon_2 \\ Pl(x) - Bel(x) < \varepsilon_3 \end{cases} \tag{10-32}$$

其中

$$Bel(y) = \max\{Bel(z) < \varepsilon_1\} \tag{10-33}$$

则 x 即为判决结果，其中 ε_1，ε_2，ε_3为预先设定的阈值。

证据理论可以使多个证据都支持的命题合成后的信度提高，减小未知信度，从而减小判断的模糊性，达到提高诊断准确率的目的。

将证据理论和神经网络相结合应用于故障诊断系统中就可以实现优势互补、扬长避短。神经网络和证据理论集成方法除具有一般神经网络的性质和特点外，还具有一些特殊性质。比如，由于采用了证据理论中的不确定性推理方法，避免了贝叶斯推理无法区分“不知道”和“不确定”信息，也不需要明确先验概率和条件概率。同时克服了证据理论基本信度分配主观性过强的缺陷，这使得系统的诊断能力

得到明显加强。

10.3 轴向柱塞泵的故障诊断实验

本节通过采集轴向柱塞泵脱靴故障和正常状态的数据，运用神经网络和证据理论集成方法进行诊断，并对诊断结果进行分析，验证神经网络和证据理论集成的数据融合诊断方法的有效性。

10.3.1 液压泵的常见故障机理分析

对轴向柱塞泵诊断域的选择上，假设为正常使用情况下，经过磨合期后出现的故障作为诊断的故障域。在这种情况下，液压泵以流量降低、压力无法调节到正常使用的压力、泵的振动噪声变大、内部结构元件的失效为最常见的故障表现形式。柱塞泵常见的故障类型如下：

（1）滑靴脱落　由于制造误差或液压泵在工作中压力冲击使柱塞球头与球窝变形，从而引起柱塞球头的松动或脱落。随缸体的转动柱塞在不断与吸排油口相通时给液压泵带来冲击。

（2）缸体与配流盘间磨损　缸体与泵进出油口的连接要靠缸体与配油盘的精密配合实现，柱塞腔容积减小时，必须与出油口相通，才能达到压油的目的。同样，柱塞腔容积增大时，必须与进油口相通，才能达到吸油的目的。当缸体与配油盘的磨损加大，会发生高压腔与低压腔的密封不严而导致压力性能下降。机械配合面的摩擦加大，泵振动亦增加。

（3）轴承表面损伤　轴承的长期运转容易产生由于材料疲劳引起微孔状点蚀损伤，或滚道面和滚动体发生鳞片状剥落现象，以及其他破损和伤痕。当滚柱滚过轴承表面损伤点时易产生冲击脉冲，引起液压泵的振动。

（4）柱塞与缸体间的磨损　柱塞在缸体内的往复运动完成缸体内容积的变化实现柱塞泵吸排油，当柱塞退回时缸体内柱塞腔容积变大压力降低，液压泵吸油；当柱塞推进时缸体内柱塞腔容积变小，压力增大，液压泵排油。柱塞的长时间高速往复运动容易造成柱塞和缸体内配合面的磨损，从而造成柱塞与缸体间的间隙变大，液压泵的振动加剧，内泄增大，输出压力降低，达不到额定压力值。

10.3.2 常用信号数据源

（1）泵壳振动　泵壳的振动包含了丰富的液压泵故障信息，目前对液压泵诊断大多采用测量泵壳振动进行处理的方法。轴向柱塞泵的振动源由机械振动与流体引起的振动两部分组成。机械振动正常情况下主要由柱塞缸体旋转带动大轴承产生。故障发生时，液压泵会表现出异常振动。流体振动一部分为缸体的柱塞腔从低

压区到高压区，又从高压区到低压区时产生的冲击而引起的周期性振动。该冲击振动基频为柱塞数与转速的乘积，频率主要在 0 ~ 2kHz 以内。流体振动的另一部分是泵吸油时，由于困油或吸空产生的空穴现象，空穴产生的气泡在高压腔胀破而“爆破”产生高频振动，频率可达 20kHz。现在液压泵站的油箱设计时一般油面高于液压泵吸油口或采用供油泵，并保持合适的油温，所以一般油泵吸空现象不容易发生。

（2）压力脉动　泵处于承载状态下的液流脉动会引起压力的波动，它同排送量之间的关系，可以根据水力冲击理论推导出的公式表示，即

$$\mathrm{d}p = \rho v \mathrm{d}q / A \tag{10-34}$$

式中　$\mathrm{d}p$、$\mathrm{d}q$——管道中某一点的压力和排送量的变化；

ρ——液体的密度；

A——管道的截面积；

v——声音在充满液体的管道中的传播速度，$v = \sqrt{E_{np}/\rho}$；

E_{np}——液体和管道的折算体积模量。分段压力脉冲的相对值通常大于液流脉动的相对值。波动压力的曲线是一种复杂的非谐波曲线。曲线的形状取决于泵的类型，但是，对于同一种类型的泵，曲线的形状也可能会有很大的差异。通过对脉动压力曲线的形状所作的分析，可以获得有关泵的状态的信息。基于这个原因，可以实现对液压泵的诊断。

（3）温度的变化　液压设备中在发生故障时，一定伴随着运动配合表面的摩擦带来的机械能损失以及由于阻尼孔的堵塞、内部的泄漏等带来的压力能的异常损失，根据能量转化和守恒定律这些能量就会转化为别的能量的形式，而一般情况下大都会以热量的形式表现出来。因此，通过对液压泵温度变化的大小、方位的检测，就可以对泵的状态进行判定。

（4）噪声　液压泵的噪声信号实质上是振源信号经过液压泵振动产生的压力波，压力波是在空气中传播产生的，所以它一定含有振源的信息。在液压泵正常工作时，它有一定的噪声级。当故障发生时，液压泵发出的噪声信号必然出现变化，因此可以通过对液压泵附近噪声信号的检测，并进行有效的处理和分析，就能提取到与液压泵故障有关的特征量，实现对液压泵故障原因的诊断。在特殊的工况下，无法对液压泵本身进行直接监测时，可以通过对噪声的监测达到诊断的目的。

以上几种数据源是现在液压泵诊断最经常采用的信号来源，通过对这些原始信号在时域或频域上进行处理，用于液压泵故障诊断，可以取得良好的诊断结果。

10.3.3　神经网络证据理论液压泵诊断模型结构

选用了液压泵脱靴故障为诊断的故障类型，采用对故障较为敏感的液压泵泵壳

振动加速度信号和液压泵出口压力脉动信号作为检测的信号源，利用神经网络和证据理论集成的数据融合方法对某轴向柱塞泵进行故障诊断。液压泵的故障诊断模型结构如图 10-7 所示。

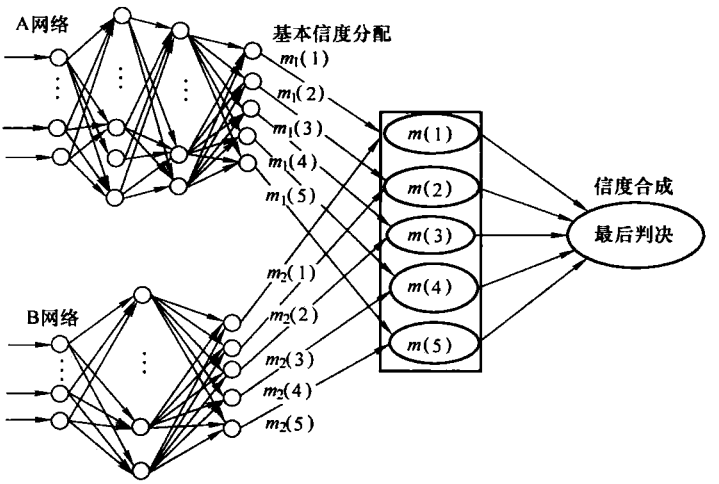

图 10-7 液压泵故障诊断模型结构

泵壳振动和泵出口压力脉动信号对液压泵故障互相独立，组成两个局部诊断网络。经过特征提取的特征信号分别成为两个独立的局部诊断网络的输入，得出的局部诊断网络输出数据进行处理成为证据理论的基本信度分配，然后将基本信度经过证据理论合成，最后得到诊断结论。该诊断模型结构属于特征层数据融合。

10.3.4 局部诊断神经网络结构设计

由于 BP 网络以其误差反向传播算法所具有的良好性能而得到至今最为广泛的应用，因此我们采用 BP 网络作为局部诊断神经网络的结构，经过实验验证取得了良好的效果。

1. 局部网络的个数确定

对液压泵的故障诊断采用液压泵端盖振动以及液压泵出口压力脉动作为检测的信号源，采用神经网络证据理论方法进行故障诊断。这两个位置分别组成两个神经网络进行局部诊断，在此泵端盖振动诊断网络称为 A 网络，泵出口压力脉动诊断网络称为 B 网络。

2. 输入层输出层节点数的确定

对采样来的数据进行幅值域上的分析，采用了有量纲幅域参数峰值 X_{max}、峰峰值 X_{pp} 以及均方根值 X_{rms}。而且由于有量纲幅域参数的值常因负载、转速等条件的

变化而变化，实际中很难加以区分，为此又引入无量纲的幅域参数，它们对信号幅值和频率的变化不敏感，即和机器工作条件关系不大，而对故障足够敏感。采用的无量纲的幅域参数为：波形指标 $S_f = X_{rms}/|\overline{X}|$ 、峰值指标 $C_f = X_{\max}/X_{rms}$、脉冲指标 $I_f = X_{\max}/|\overline{X}|$ 、裕度指标 $CL_f = X_{\max}/X_r$、峭度指标 $K_v = \beta/X_{rms}^4$。其中 $\overline{X}$ 为均值，X_r 为方根幅值，$\beta = \frac{1}{N}\sum_{i=1}^{N} X_i^4$ 。峭度指标、裕度指标和脉冲指标对于脉冲类故障比较敏感，特别是对早期故障有较高的敏感性，但稳定性不好。均方根值的稳定性比较好，但对早期故障信号不敏感。所以，为了取得较好的结果，将它们同时使用作为局部网络的输入。

选择两种信号的幅值域的峰值、峰峰值、均方根值、波形指标、峰值指标、脉冲指标、裕度指标和峭度指标 8 个特征参数可以很好地反映振动的特征，所以选取这 8 个参数作为神经网络的输入。因此，网络输入层就可以确定为这 8 个参数，即输入层的神经元数为 8。同样选取液压泵常见的 4 种故障（脱靴故障、缸体与配流盘磨损、轴承表面损伤、柱塞与缸体间磨损），加上正常状态共 5 种状态作为证据理论的判决目标，可以确定神经网络的输出层的神经元数为 5 个。

3. 网络层数和隐层节点数的确定

根据训练发现泵壳振动的幅值变化比较大而且有噪声的影响，A 网络采用一个隐层网络难以收敛，所以确定为两个隐层。A 网络根据上章的经验公式并结合训练的效果，选择了第一隐层为 25 个节点，第二隐层为 10 个节点的网络，该网络易收敛而且收敛速度比较快。如图 10-8 为该网络期望误差选择为 0.001 时的训练过程误差收敛曲线。

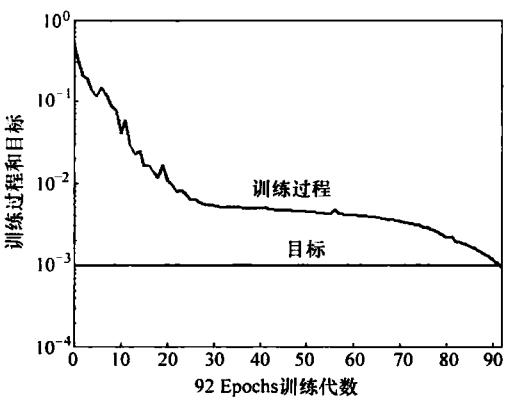

图 10-8　A 网络训练误差曲线

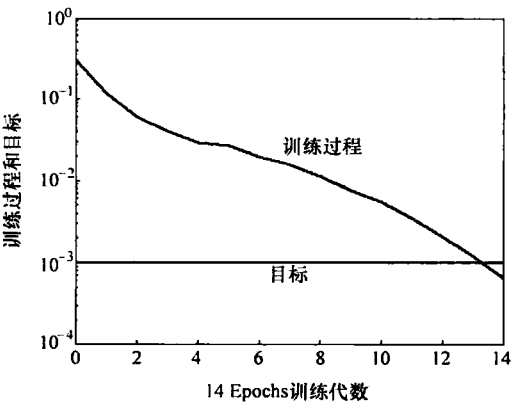

图 10-9　B 网络训练误差曲线

而压力脉动幅度比较小，采用单隐层就可以实现诊断。B 网络选择一个隐层，

隐层神经元数根据训练优化选择为 10 个节点。如图 10-9 即为 B 网络期望误差为 0.001 时的训练误差收敛曲线。

4. 初始权值和训练误差的选择

因为权重的初始值、学习率等的选取对网络最终收敛与否影响很大。初始权值选择由计算机产生的［-1，+1］区间的随机数，设计的网络偶尔会出现不收敛或收敛效果不好的现象，因此经过反复训练选择性能最好的误差曲线作为最后的训练结果。本网络的训练误差根据训练的情况采用了 0.001，既能满足故障诊断的判决精度要求，又能使训练的时间不太长。

10.3.5 神经网络证据理论液压泵诊断决策方法

根据神经网络证据理论诊断方法的原理，由于两个网络诊断的参数不同，每个诊断证据在整个证据中的可靠性系数是不同的，也就是每个证据对诊断结果的推断能力是不同的。由于泵壳振动易受到其他噪声振动的影响，因此取 A 网络的可靠性系数 $\alpha_1 = 0.8$，也就是 A 网络对不确定结果的信度分配为 $m_1(\Theta) = 1 - \alpha_1 = 0.2$。压力脉动诊断能力较强，取 B 网络的可靠性系数为 $\alpha_2 = 0.94$，也就表示 B 网络对不确定结果的信度分配为 $m_2(\Theta) = 1 - \alpha_2 = 0.06$。

液压泵状态的证据理论判决是根据各故障的信度区间［Bel，Pl］来进行判决。判决方法是：

若 $\exists x, y, z \subset \Theta$，满足

$$\begin{cases} Bel(x) \geqslant 0.5 \\ Bel(x) - Bel(y) > 0.2 \\ Pl(x) - Bel(x) < 0.25 \end{cases} \tag{10-35}$$

式中 $Bel(y) = \max\{Bel(z) < 0.5\}$，则状态 x 就是判决的液压泵所处的状态。

10.3.6 基于神经网络和证据理论集成方法的液压泵诊断实验

1. 数据的采集和数据特征的获得

下面对某液压轴向柱塞泵在正常工作和发生脱靴故障时采集的泵壳振动和泵出口压力脉动数据，采用神经网络和证据理论集成诊断方法进行故障诊断的验证。

本实验采用 LabView 编程对泵壳振动信号和泵出口压力脉动信号进行采集，数据采集时将泵出口主溢流阀压力分别调定为 1MPa、2MPa、3MPa、4MPa、5MPa。在每一个压力下，按以下的采样频率进行采样：1kHz、2kHz、3kHz、4kHz、5kHz、6kHz、7kHz、8kHz、9kHz、10kHz、20kHz、30kHz、40kHz、50kHz、60kHz、70kHz、80kHz、90kHz、100kHz、200kHz。对试验泵的泵壳振动分别在泵故障和正常情况下进行采样，各得到 100 组数据。对泵出口压力脉动分别在泵故障和正常情况下进行采样，也各得到 100 组数据。

对各组采集的数据进行了处理，提取各压力和采样频率下的波形的峰值、峰峰值、均方根值、波形指标、峰值指标、脉冲指标、裕度指标、峭度指标值。

分别选取泵出口压力调定为 3MPa 时故障情况和正常情况下泵壳振动波形特征数据组 200 组，故障情况和正常情况下泵出口压力脉动特征数据组 200 组。对泵壳振动诊断网络 A，取 160 组数据作为诊断网络训练数据，其余 40 组数据作为诊断数据。表 10-1 列出了泵壳振动诊断网络 A 的部分训练样本数据。同样，对泵出口压力脉动诊断网络 B，取 160 组数据作为诊断网络训练数据，其余 40 组数据作为诊断数据。表 10-2 列出了泵出口压力脉动诊断网络 B 的部分训练样本数据。

表 10-1　泵壳振动诊断网络 A 部分训练样本数据

样　本	峰值 /ms^{-2}	峰峰值 /ms^{-2}	均方根值 /ms^{-2}	波形指标	峰值指标	脉冲指标	裕度指标	峭度指标
样本 1	2.39	3.54	0.20	22.87	11.79	269.69	22.11	22.12
样本 2	2.83	4.54	0.15	30.47	19.19	584.69	50.61	54.91
样本 3	5.42	7.70	0.24	7.33	23.67	173.60	56.93	60.55
样本 4	4.55	7.84	0.24	9.94	19.16	190.35	40.90	48.52
样本 5	3.87	6.46	0.23	7.12	16.69	118.77	39.15	27.08
样本 6	1.53	2.07	0.19	8.35	8.07	67.45	12.54	10.31
样本 7	3.65	6.41	0.22	25.41	16.89	429.03	29.53	27.67
样本 8	5.68	9.41	0.29	6.67	19.51	130.11	80.34	84.68
样本 9	4.82	8.76	0.21	9.66	22.80	220.24	66.70	94.50
样本 10	5.09	8.55	0.24	60.87	21.61	1315.41	81.36	46.93
样本 11	1.83	3.53	0.20	40.25	9.23	371.66	22.15	14.69
样本 12	2.33	3.67	0.18	39.08	13.15	513.79	29.87	17.29
样本 13	1.42	2.51	0.16	67.20	8.63	579.78	18.29	11.44
样本 14	1.23	2.46	0.16	29.67	7.84	232.71	16.35	11.14
样本 15	1.35	2.28	0.15	24.51	9.27	227.23	18.15	10.38
样本 16	1.14	1.99	0.15	29.03	7.49	217.47	14.46	8.55
样本 17	1.07	1.94	0.15	45.63	7.20	328.60	13.87	9.26
样本 18	1.25	2.18	0.16	34.29	8.08	276.94	16.65	9.51
样本 19	1.13	2.05	0.16	90.91	6.90	627.43	13.42	8.79
样本 20	1.30	2.49	0.16	47.17	8.12	383.06	15.78	9.95

表 10-2 泵出口压力脉动诊断网络 B 的部分训练样本数据

样 本	峰值 /MPa	峰峰值 /MPa	均方根值 /MPa	波形指标	峰值指标	脉冲指标	裕度指标	峭度指标
样本 1	1.14	0.91	0.96	1.02	1.18	1.2	1.21	1.1
样本 2	1.13	0.89	0.95	1.02	1.19	1.22	1.23	1.12
样本 3	1.14	0.88	0.96	1.02	1.19	1.21	1.23	1.11
样本 4	1.14	0.88	0.95	1.02	1.19	1.22	1.23	1.12
样本 5	1.15	0.92	0.96	1.02	1.21	1.23	1.25	1.11
样本 6	1.13	0.86	0.96	1.02	1.18	1.21	1.22	1.11
样本 7	1.14	0.87	0.95	1.02	1.2	1.22	1.24	1.11
样本 8	1.14	0.87	0.95	1.02	1.2	1.22	1.24	1.11
样本 9	1.14	0.91	0.96	1.02	1.19	1.22	1.23	1.11
样本 10	1.14	0.93	0.96	1.02	1.18	1.21	1.22	1.11
样本 11	0.19	0.05	0.16	1.08	1.16	1.16	1.16	1.01
样本 12	0.19	0.05	0.16	1	1.16	1.16	1.16	1.01
样本 13	0.2	0.08	0.16	1	1.22	1.22	1.22	1.01
样本 14	0.19	0.05	0.16	1	1.16	1.16	1.16	1.01
样本 15	0.19	0.06	0.16	1	1.16	1.16	1.16	1.01
样本 16	0.19	0.06	0.16	1	1.16	1.16	1.16	1.01
样本 17	0.2	0.07	0.16	1	1.25	1.25	1.25	1.01
样本 18	0.19	0.06	0.16	1	1.19	1.19	1.19	1.01
样本 19	0.19	0.05	0.16	1	1.16	1.16	1.16	1.01
样本 20	0.19	0.06	0.16	1	1.19	1.19	1.19	1.01

2. 单一诊断网络的故障诊断与结果分析

利用得到的训练样本数据对 A、B 诊断网络分别进行了训练，然后选取泵壳振动和泵出口压力脉动的诊断数据中的各 5 组数据进行故障诊断方法验证。

首先从脱靴故障时泵壳振动的 40 组诊断数据中取 5 组数据，进行神经网络和证据理论集成故障诊断方法验证分析。表 10-3 即为泵工作在 3MPa 压力下发生脱靴故障时泵壳振动的诊断数据。表 10-3 中的 5 组数据输入训练完的诊断网络 A，得到网络 A 的诊断输出值见表 10-4。

可通过计算得到分别采用各组数据诊断时，对泵不同状态的基本信度分配见表 10-5。由所获得基本信度，计算出 5 组数据各种状态出现的置信区间（*Bel*，*Pl*），由此，可以采用证据理论判决方法得到诊断网络 A 独立诊断得到的结果，见表 10-6。

表 10-3　泵工作在 3MPa 下发生脱靴故障时泵壳振动诊断数据

数据	峰值 /ms^{-2}	峰峰值 /ms^{-2}	均方根值 /ms^{-2}	峰值指标	波形指标	脉冲指标	裕度指标	峭度指标
1	5.89	11.10	0.29	1481	20.11	29782.72	164.22	115.47
2	9.99	15.47	0.34	67.49	29.63	1999.90	243.51	138.37
3	9.99	15.97	0.33	134.29	30.17	4051.97	262.91	146.46
4	7.94	13.37	0.28	105.55	28.11	2966.54	224.11	112.63
5	7.37	13.02	0.31	103.92	23.65	2457.95	199.27	119.09

表 10-4　诊断 A 网络的输出值

数据	脱 靴 故 障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　　常
1	0.636240	0.0078579	0.0078637	0.0078591	0.3645771
2	0.986070	0.0076415	0.0076498	0.0076447	0.0140698
3	0.5535271	0.0077424	0.0077372	0.0077369	0.467340
4	0.980200	0.0076089	0.0076137	0.0076092	0.019931
5	0.996901	0.0078279	0.0078339	0.0078302	0.0031201

表 10-5　A 网络对各故障基本信度分配

数据	脱 靴 故 障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　　常	未　　知
1	0.4968695	0.0061366	0.0061379	0.0061375	0.355894	0.2
2	0.7710631	0.0059753	0.0059818	0.0059778	0.011002	0.2
3	0.4241247	0.0059324	0.0059284	0.0059282	0.358086	0.2
4	0.7665577	0.00595048	0.0059542	0.0059507	0.1558688	0.2
5	0.7791994	0.00611846	0.00612314	0.0061202	0.0024387	0.2

表 10-6　诊断网络 A 对脱靴故障诊断结果

数据	脱 靴 故 障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　　常	未知	结论
1	(0.4968695, 0.6968695)	(0.0061366, 0.2061366)	(0.0061379, 0.2061379)	(0.0061375, 0.2061375)	(0.355894, 0.555894)	0.2	不确定
2	(0.7710631, 0.97710631)	(0.0059753, 0.2059573)	(0.0059818, 0.2059818)	(0.0059778, 0.2059778)	(0.011002, 0.211002)	0.2	故障 1

（续）

数据	脱靴故障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正常	未知	结论
3	(0.4241247, 0.6241247)	(0.0059324, 0.2059324)	(0.0059284, 0.2059284)	(0.0059282, 0.2059282)	(0.358086, 0.538086)	0.2	不确定
4	(0.7665577, 0.9665577)	(0.00595048, 0.2059048)	(0.0059542, 0.2059542)	(0.0059507, 0.2059507)	(0.1558688, 0.3558688)	0.2	故障1
5	(0.7791994, 0.9791994)	(0.00611846, 0.20611846)	(0.00612314, 0.20612314)	(0.0061202, 0.2061202)	(0.0024387, 0.2024387)	0.2	故障1

分析表10-6所示的诊断样本的诊断结果。利用诊断样本1诊断得到，泵处于脱靴故障状态的置信区间为（0.4968695，0.6968695）和泵处于正常状态的置信区间为（0.355894，0.555894），根据诊断判决方法无法确定泵的状态。同样，利用诊断样本3诊断得到，泵处于脱靴故障状态的置信区间为（0.4241247，0.6241247）和泵处于正常状态的置信区间为（0.358086，0.538086）根据诊断判决方法也无法确定泵的状态。通过分析可知，纯粹依靠诊断网络A诊断的精确度不高，有时出现无法判决的情况。

从3MPa下脱靴故障时与表10-3所示泵壳振动数据通过采集卡同时采集到的泵出口压力脉动40组的诊断数据中，选取泵出口压力脉动的5组数据（列于表10-7），进行神经网络证据理论集成故障诊断方法验证分析。利用训练完的诊断网络B对表10-7中的5组数据进行诊断，得到网络B的诊断输出值，见表10-8。

计算得到诊断时各组数据对泵不同状态的基本信度分配见表10-9。由所获得基本信度分配值，计算出5组数据各种状态出现的置信区间（*Bel*，*Pl*），采用证据理论判决方法得到独立诊断结果，见表10-10。

表10-7 泵工作在3MPa下发生脱靴故障时压力脉动诊断数据

数据	峰值/MPa	峰峰值/MPa	均方根值/MPa	峰值指标	波形指标	脉冲指标	裕度指标	峭度指标
1	0.9	0.73	0.7	1.02	1.27	1.3	1.32	1.1
2	0.89	0.72	0.7	1.02	1.27	1.3	1.32	1.1
3	0.9	0.74	0.71	1.02	1.27	1.3	1.32	1.1
4	0.89	0.72	0.71	1.02	1.26	1.29	1.31	1.1
5	0.89	0.72	0.7	1.02	1.27	1.29	1.31	1.1

表 10-8　诊断 B 网络的输出值

数据	脱靴故障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　常
1	0.998070	0.0053115	0.0052992	0.0052601	0.0019273
2	0.99800	0.0052002	0.0052900	0.005251	0.0019905
3	0.99815	0.005312	0.0052996	0.0052603	0.001845
4	0.9979	0.0053296	0.0053175	0.0052785	0.0020929
5	0.99793	0.0053237	0.0053115	0.0052725	0.0020643

表 10-9　诊断 B 网络对各故障基本信度分配

数据	脱靴故障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　常	未　知
1	0.9235311	0.0049148	0.0049034	0.0048672	0.0017834	0.06
2	0.9235904	0.0048123	0.0048954	0.0048595	0.0018421	0.06
3	0.9236062	0.0049153	0.0049045	0.0048681	0.0017072	0.06
4	0.9233280	0.0049313	0.0052342	0.0048840	0.0019365	0.06
5	0.9228449	0.0049231	0.0049119	0.0048758	0.0019089	0.06

表 10-10　诊断网络 B 对脱靴故障诊断诊断结果

数据	脱靴故障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正　常	未　知	结　论
1	(0.9235311, 0.9835311)	(0.0049148, 0.0649148)	(0.0049034, 0.0649304)	(0.0048672, 0.0648672)	(0.0017834, 0.0617834)	0.06	故障 1
2	(0.9235904, 0.9835904)	(0.0048123, 0.0648123)	(0.0048954, 0.0648954)	(0.0048595, 0.0648595)	(0.0018421, 0.0618421)	0.06	故障 1
3	(0.9236062, 0.9836062)	(0.0049153, 0.0649513)	(0.0049045, 0.0649045)	(0.0048681, 0.0648681)	(0.0017072, 0.0617072)	0.06	故障 1
4	(0.9233280, 0.9833280)	(0.0049313, 0.0649313)	(0.0052342, 0.0652342)	(0.0048840, 0.0648840)	(0.0019365, 0.0619365)	0.06	故障 1
5	(0.9228449, 0.9828449)	(0.0049231, 0.0649231)	(0.0049119, 0.0649119)	(0.0048758, 0.0648758)	(0.0019089, 0.0619089)	0.06	故障 1

分析表 10-10 独立诊断结果，由于在此实验状态下，脱靴故障对液压泵流量变化影响比较明显，导致压力脉动变化比较大，因此获得的诊断结果很好地实现了诊

断。同时这也说明了神经网络良好的故障诊断能力。但不同的诊断网络对不同的故障敏感性是不同的，可以推知如果其他故障发生或多个故障同时发生的状态下同样会出现网络 A 难以判断的情况。由于传感器安放位置的不同和自身监测性能的差别，不同传感器采集的不同故障的数据蕴涵的故障信息有很大的差异，所以任何诊断网络都可能存在诊断不确定的情况。

3. 证据合成的故障诊断与结果分析

综上所述，通过同时采样到的泵壳振动和压力脉动在液压泵脱靴故障下的各 5 组数据分别通过两个诊断网络独立诊断结果分析发现：网络 A 诊断的数据组 1 和 3 由于信度小，难以正确判断泵的实际状态，而且不确定性信度也比较大；网络 B 虽然没有出现不确定的状态，但不确定性信度也比较高，达到了 0.06。同时，因为网络 A 和网络 B 诊断原理的相似性，可推知在液压泵其他故障的情况下诊断网络 B 同样会出现无法诊断的状态。因此需要运用数据融合技术，充分利用网络 A 和网络 B 诊断信息，将两者分别作为证据理论融合方法的两个证据，进行信度合成，合成信度见表 10-11。

表 10-11 诊断 A、B 网络合成信度

数据	脱靴故障	缸体与配流盘磨损	轴承表面损伤	柱塞与缸体间磨损	正常	未知	结论
1	(0.6446, 0.66146148)	(0.000042368, 0.016899383)	(0.000042278, 0.016899293)	(0.000041963, 0.016898979)	(0.0008916, 0.01774861)	0.016857	故障 1
2	(0.74162, 0.75411989)	(0.000029945, 0.012526641)	(0.000030495, 0.012527192)	(0.000030252, 0.012526948)	(0.00002110, 0.01251780)	0.02497	故障 1
3	(0.61166, 0.63040254)	(0.000045532, 0.018783151)	(0.000045401, 0.018783021)	(0.000045063, 0.018782682)	(0.00094556, 0.01969218)	0.018738	故障 1
4	(0.73372, 0.74615687)	(0.000030419, 0.012470095)	(0.000032307, 0.0124719838)	(0.000030128, 0.012469805)	(0.00031290, 0.01275258)	0.012440	故障 1
5	(0.74357, 0.75597615)	(0.000031148, 0.012439791)	(0.0000311, 0.012439744)	(0.000030857, 0.012439501)	(0.00000481, 0.01241346)	0.012409	故障 1

通过合成信度表 10-11，可以发现，由于充分利用了不同证据的互补故障信息，实现了泵状态的精确识别。同时可看到，未知信度明显减小，最大的未知信度仅有 0.02497，A、B 网络支持度均高的状态信度相对上升，支持度均低的状态信度相对降低，诊断的能力明显增强。

通过上述数据的分析得到了神经网络和证据理论集成的数据融合方法对液压泵

故障诊断的良好的诊断性能，表明这种方法对液压泵进行故障诊断是有效的，这也充分体现了数据融合技术通过充分利用多源数据的冗余和互补信息提高决策准确率的优良特性。同时，也可看到证据 A 对脱靴故障支持低的信度影响了证据 B 的高信度，使合成信度比证据 B 的信度降低，这也是融合的结果，符合人正常的对不确定性知识的推理规律。

参 考 文 献

[1] 康耀红．数据融合原理与应用［M］．西安：西安电子科技大学出版社，1997.

[2] 刘同明，夏祖勋．数据融合技术［M］．北京：国防工业出版社，1998.

[3] Biao Chen, Pramod K Varshney. A Bayesian Sampling Approach to Decision Fusion Using Hierarchical Models［J］. IEEE Transactions on Signal Processing. 2002, 50 (8): 1809-1818.

[4] Behzad Moshiri, Mohammad Reza Asharif, Reza HoseinNezhad. Pseudo Information Measure: a New Concept for Extension of Bayesian Fusion in Robotic Map Building［J］. Information Fusion, 2002, (3): 51-68.

[5] 蓝金辉，马宝华，蓝天，等. D-S 证据理论数据融合方法在目标识别中的应用［J］．清华大学学报：自然科学版，2001，41 (2)：53-55，59.

[6] 韩静，陶云刚．基于 D-S 证据理论和模糊数学的多传感器数据融合算法［J］．仪器仪表学报. 2000，21 (6)：644-647.

[7] 刘怀国，吴陈，张冰. D-S 证据理论在多传感器融合中的应用［J］．华东船舶工业学院学报：自然科学版，2001，15 (3)：20-24.

[8] 黄瑛，陶云刚，周洁民. D-S 证据理论在多传感器数据融合中的应用［J］．南京航空航天大学学报. 1999，31 (4)：172-177.

[9] 倪国强，梁好臣．基于 Dempster-Shafer 证据理论的数据融合技术研究［J］．北京理工大学学报. 2001，21 (5)：603-609.

[10] 罗志增，蒋静坪．相关证据的融合及其在机器人多感觉信息融合中的应用［J］．传感器学报，2000 (3)：177-182.

[11] 涂嘉文，徐守时．贝斯方法与 Dempster-Shafer 证据理论的讨论［J］．红外与激光工程. 2001，30 (4)：139-142.

[12] 赵方，武震．机器磨损状态中的证据理论方法［J］．润滑与密封，2001 (4)：7-9，12.

[13] 王鸿飞．基于 Dempster-Shafer 证据理论的柴油机故障诊断［J］．内燃机学报，2000，18 (1)：20-23.

[14] Chang Norman H, Spanos Costas J. Continuous Equipment Diagnosis Using Evidence Integration: an LPCVD Application［J］. IEEE Transactions on Semiconductor Manufacturing, 1991, 4 (1): 43-51.

[15] He Y, Chu F, Zhong B. A Study on Group Decision-making Based Fault Multi-system-domain Consensus［J］. Reliability Engineering and System Safety, 2001, 74 (1): 43-52.

[16] 李冲祥．神经网络和证据理论集成的数据融合故障诊断方法研究［D］．秦皇岛：燕山大学，2003：47-64.

[17] 丁玉兰，石来德．机械设备故障诊断技术［M］．上海：上海科学技术文献出版社，1994.

[18] Morgun E V. On Problems of Functional Diagnosis of Hydraulic Machines on the Basis of the Thermodynamic Measurement Method［J］. Soviet Engineering Research. 1990，10（3）：23-28.

[19] 姜万录，李冲祥．神经网络和证据理论融合的故障诊断方法研究［J］．中国机械工程，2004，15（9）：760-764.

第 11 章　液压泵的故障特征提取及特征降维

本章研究了液压泵多传感器故障信号的采集和处理方法，对几种典型故障的振动和声音信号进行了分析，找到了故障发生的敏感特征频率成分。实验分析了各种有量纲和无量纲幅值域特征指标对液压泵几种典型故障的敏感性。为增加单一信号的完备性，研究了幅值域和时频域的特征向量提取方法，通过实例分析验证了方法的有效性。针对特征向量集合维数较高的问题，提出了主元分析的特征降维选择方法。

11.1　液压泵的振动和声音信号处理

采集液压泵故障发生时的振动信号和声音信号，并进行包络谱分析。从振动信号和声音信号两个方面分别对轴向柱塞泵的单柱塞松靴、滑靴磨损以及中心弹簧失效三种常见故障模式进行分析。得到相同模式、不同程度故障的变化趋势，为液压泵的故障特征提取提供依据。

11.1.1　故障信号的采集方法

1. 振动信号的采集

泵端盖振动信号采集时，通过在端盖 3 个垂直方向安置振动加速度传感器来完成，如图 11-1 所示。采集过程所使用的硬件设备和软件平台如下：

1）选用测量频率范围为 1～18kHz 的 YD72D 型压电式加速度传感器，与液压泵进行刚性连接。

2）使用频率范围为 0.3～100kHz 的 DHF-10 型和 DHF-6A 型电荷放大器分别与 3 个加速度传感器相匹配，对采集的电荷信号进行放大。

3）通过采样频率为 250kS/s 的 NI-USB-6221 型数据采集卡进行数据采集，并利用 LabView 编辑的虚拟仪器平台监视和保存数据信息。

2. 声音信号的采集

声音是机械运转过程中不可避免的产物，即使是良好的机械，运转过程中也会发出声音。声音信号实质上是振源信号经过机械设备壳体振动产生的压力波，压力波在空气中传播，它一定含有振源信号的信息。泵发生故障时，它的声压级必然有所变化，声音的增强和频率成分的改变意味着机械性能的降低或故障的发生。所以对声音信号进行有效地分析和处理，即可从声音信号中提取到与特定故障相关的敏

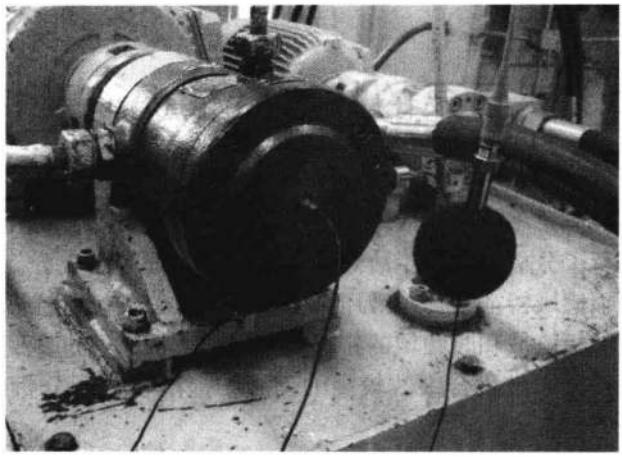

图 11-1 信号采集系统

感特征量，通过对特征量的监测，即可实现对液压泵故障原因的判定。

声音是机械振动通过弹性介质传播的，它主要来源于机械的振动，所以振动信号与声音信号具有相同的产生机理。虽然声音信号的产生机理与振动信号相同，但是它们的传播途径有较大区别。声音信号以空气为介质向外传播，而振动信号则表现为壳体共振，所以监测方式有所不同。振动信号是接触式测量方式，直接使加速度传感器刚性连接在被测设备表面，振动信号只与被测物的振幅有关。而声音信号属于非接触式测量，测量方法采用近声场测量法，这种测量方法不仅能测到被测设备的声音信息，而且能测到近声场内所有机器设备的声音信息，所以测得的声音信号受外界环境干扰的背景噪声很大。对声音信号进行分析时，其频率成分比振动信号的频率成分复杂得多。

本章声音信号的采集选用国产的 AWA5661 型精密脉冲声级计。此声级计是一种测量指数时间计权声级的通用声级计，它使用灵敏度为 40mV/Pa，频率范围为 10～16000Hz 的电容传声器。底部具有交流信号输出接口，可输出交流电压信号，便于使用采集卡进行信号采集。在实际测试中，由于声音存在动力噪声和传动噪声的干扰，距离声源远时，被测的摩擦声音因混响作用而被淹没，所以采用近声场测量法，以获取强的声音信号。采用如图 11-1 所示的方式放置传声器，将传声器放置在距泵 0.5m 以内或更近，距地面高度 0.75m 的地方，在围绕泵几个不同位置处进行测量，找出声压级最大的点作为测点，将传声器自然悬挂于测点处并在传声器端部安装风罩以降低环境风噪声的影响。最后通过信号采集设备 NI-USB-6221 和虚拟仪器平台对声音信号进行采集。

11.1.2　基于 Hilbert 变换的包络解调法

包络解调实现的具体原理如图 11-2 所示。

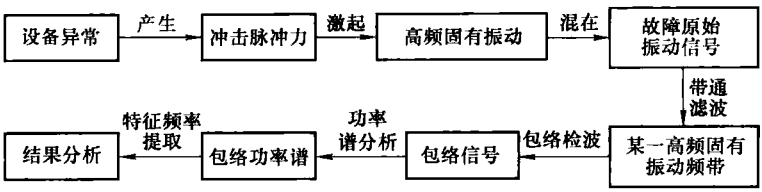

图 11-2　包络解调原理图

1. Hilbert 变换

给定一连续的时间信号 $f(t)$，其 Hilbert 变换为 $\hat{f}(t)$，构造 $f(t)$ 的解析信号：

$$z(t)=f(t)+\mathrm{j}\hat{f}(t) \tag{11-1}$$

$z(t)$ 的幅值 $|z(t)|=\sqrt{f^2(t)+\hat{f}^2(t)}$ 便是原始信号的包络，用 $A(t)$ 表示。解析信号的相位就是实际波形的相位 $Q(t)=\arctan[\hat{f}(t)/f(t)]$。

图 11-3 是 Hilbert 包络解调的分析过程。

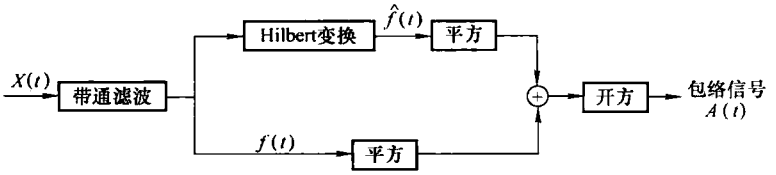

图 11-3　Hilbert 包络解调的分析过程

2. Hilbert 变换解调的实现过程

由以上分析可知，Hilbert 变换是一种将时域实信号变为时域解析信号的分析方法，其幅值即为实信号 $f(t)$ 的包络。在实际使用时，一般求 $f(t)$ 的包络解调谱 $A(f)$ 步骤为：

1）求信号 $f(t)$ 的傅里叶变换 $F(f)$。

2）求解析信号 $z(t)$ 的傅里叶变换 $Z(f)$。

3）求 $Z(f)$ 的逆傅里叶变换得到解析信号 $z(t)$

$$z(t)=\int_{-\infty}^{+\infty}Z(f)\mathrm{e}^{\mathrm{j}2\pi ft}\mathrm{d}f \tag{11-2}$$

则实信号 $f(t)$ 的包络 $A(t)=|z(t)|$。

4）对 $A(t)$ 进行幅值频谱分析即可得到包络解调幅值谱 $A(f)$。

以上过程并没有用 Hilbert 变换先构造解析信号，因为 Hilbert 变换用到了卷积，

卷积计算过程很复杂，计算时间长，而利用傅里叶变换来求解，则大大简化了计算过程并缩短了计算时间。

详细的包络解调分析过程可参见第 5 章。

11.1.3 基于小波包带通滤波消噪的包络分析信号处理

在故障发生早期阶段，由于故障信息非常微弱，信噪比低，故障信号几乎在每个频段都被噪声淹没，所以直接进行小波分析无法提取出早期故障特征信息。通过小波包带通滤波消噪处理后得到的高频频带对应的小波系数不仅能将机械设备故障的突变振动信号分离出来，更为重要的是，它保留了突变信号的时间信息，这些时间信息反映了突变信号的重要频率及它们的变化规律，包含着设备故障模式的信息。为有效地提取这些故障信息，对高频频带对应的小波系数进行包络检波，然后对包络信号进行包络频谱分析。小波包带通滤波消噪的包络分析流程如图 11-4 所示。

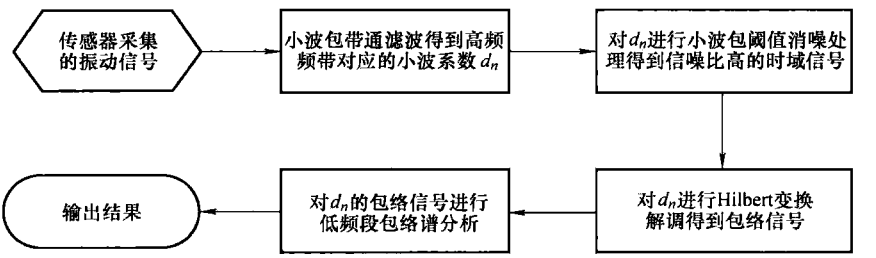

图 11-4 小波包带通滤波消噪的包络分析流程图

具体步骤如下：

1）对原始信号进行小波包分解得到高频共振频段的小波系数，通过小波包阈值消噪和重构算法得到高频共振对应频带的时域信号，达到带通滤波和消噪的目的。

2）利用 Hilbert 变换的包络解调方法对滤波消噪后的高频频段重构时间信号进行包络解调得到包络信号。

3）对包络信号进行低频段包络谱分析，得到故障的特征频率。

11.1.4 柱塞泵松靴故障的信号处理

以斜盘式轴向柱塞泵为试验对象，型号为 10MCY14-1B，7 柱塞，驱动电动机额定转速为 1480r/min，工作压力设定为 15MPa。3 个振动加速度传感器和传声器安装位置如图 11-1 所示，此处用 1 台压力传感器安装在泵出口处负责压力信号检测。用数据采集卡进行五通道信号采集，采样频率为 50kHz，截取监测结果中时间

长度为 0.8s 的一段，以泵端盖振动信号和声音信号为例对柱塞泵单柱塞松靴故障进行分析。

1. 松靴故障的振动信号分析

图 11-5 是正常状态下 0 ~ 10kHz 频段的功率谱密度。3kHz 以下的低频振动是由 24.6Hz 为基频的谐波簇构成，即往复回转元件激励引起的受迫振动。

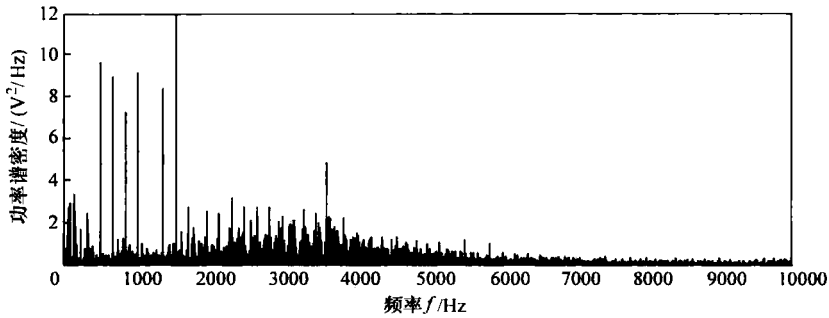

图 11-5　正常状态振动信号的功率谱密度

取各柱塞依次进入高压腔位置的间隔时间 1/(24.6×7)s = 0.0058s，对某一松靴故障的柱塞引起的振动进行短时最大熵谱分析，如图 11-6b 所示。与正常状态下的熵谱图 11-6a 相比，谱形状发生了很大变化，谱峰所在频率与回程盘第一阶共振频率相近。由此可以证明，松靴故障振动的能量主要以 3.75kHz 左右的共振形式向外传递。据此，在研究滑靴松动程度时可以对 3.75kHz 频率所在频段的信号进行处理，计算出频带对应的能量值，通过能量值的大小来判断松靴的程度。

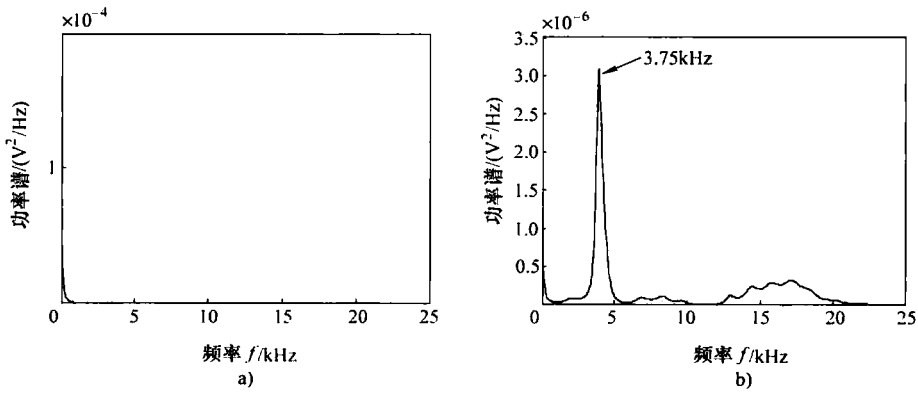

图 11-6　短时最大熵谱分析

a）正常状态　b）松靴故障

取 3 个松靴程度未知的松靴故障柱塞分别进行故障信号采集。对 3 个柱塞进行编号分别为：松靴柱塞 1、松靴柱塞 2 和松靴柱塞 3。以松靴柱塞 1 为例，根据

11.1.3 节的信号处理方法进行分析。选用 Daubechies1 小波包进行信号分解，分解层数为 4。在尺度 4 上形成了 16 个子频带，各子频段分解系数对应的频带见表 11-1。

表 11-1 分解系数对应的频带

系数	频带/Hz	系数	频带/Hz	系数	频带/Hz	系数	频带/Hz
$d(4,0)$	0 ~ 1562.5	$d(4,4)$	6250 ~ 7812.5	$d(4,8)$	12500 ~ 14062.5	$d(4,12)$	18750 ~ 20312.5
$d(4,1)$	1562.5 ~ 3125	$d(4,5)$	7812.5 ~ 9375	$d(4,9)$	14062.5 ~ 15625	$d(4,13)$	20312.5 ~ 21875
$d(4,2)$	3125 ~ 4687.5	$d(4,6)$	9375 ~ 10937.5	$d(4,10)$	15625 ~ 17187.5	$d(4,14)$	21875 ~ 23437.5
$d(4,3)$	4687.5 ~ 6250	$d(4,7)$	10937.5 ~ 12500	$d(4,11)$	17187.5 ~ 18750	$d(4,15)$	23437.5 ~ 25000

从表 11-1 中可以看出 $d(4, 2)$ 系数对应的频带包含松靴故障引起的 3.75kHz 的共振频率，所以选取此频带进行分析，可以滤去不需要的频率成分。由于该系数对应频带的信号存在明显的噪声干扰，对故障的区分和故障特征频率的提取产生了较大影响，所以必须对信号进行消噪处理。采用 Daubechies 1 小波包进行信号 4 层分解阈值消噪，并对 $d(4, 2)$ 小波包系数进行重构，保留该频带的数据信息，使信号恢复到原来的时域分辨率。消噪信号和未经消噪的 $d(4, 2)$ 重构信号之间的对比，如图11-7所示。从图 11-7b 和图 11-7a 的比较中可以看出，消噪信号的信噪比明显提高了，同时较完整地保留了信号的特征波形以及尖峰成分。

对消噪后的 $d(4, 2)$ 重构信号进行 Hilbert 变换的包络解调，得到松靴柱塞 1 的包络解调谱，如图 11-8 所示。从图 11-8 可以看出，液压泵的振动尤其以 172.5Hz 为基波的谐波簇能量最为显著。当发生松靴故障时 172.5Hz 基频以及倍频处的幅值相对于正常状态有明显的提高。

由于泵轴实际转速为 1480r/min，则转轴频率为 1480/60 = 24.6Hz，柱塞泵有 7 个柱塞，所以滑靴撞击斜盘的冲击振动基频为 24.6 × 7Hz = 172.2Hz，实际分析结果与液压泵的振动机理相一致。

发生松靴故障时会使液压泵的振动能量增大，而松靴的程度越大振动的能量就越大。对三种不同松靴程度的 $d(4, 2)$ 系数对应的频带能量进行计算，结果比较如图 11-9 所示。按计算结果由大到小的顺序排列依次是松靴柱塞 1、松靴柱塞 2、松靴柱塞 3 和正常状态。由此可以得出结论，松靴柱塞 1 的松靴程度最大，其次是松靴柱塞 2，再次是松靴柱塞 3。

2. *松靴故障的声音信号分析*

声音信号中包含着大量的故障信息。虽然与振动信号产生的机理相同，但是对声音信号的分析能够提取出振动信号未表现的特征信息。根据声音信号的特点，信号的处理过程不同于振动信号。该过程首先通过小波分解带通滤波的方法提取声音信号高频段时间域的小波系数 d_1，然后对 d_1 进行消噪处理后进行 Hilbert 包络解调。

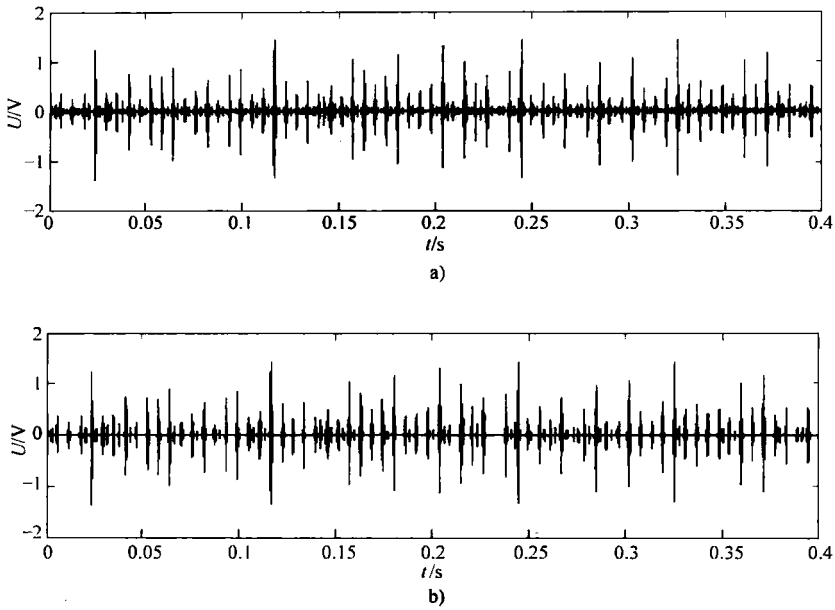

图 11-7　松靴故障的带通滤波和消噪

a）$d(4, 2)$ 的重构信号　b）消噪后的 $d(4, 2)$ 重构信号

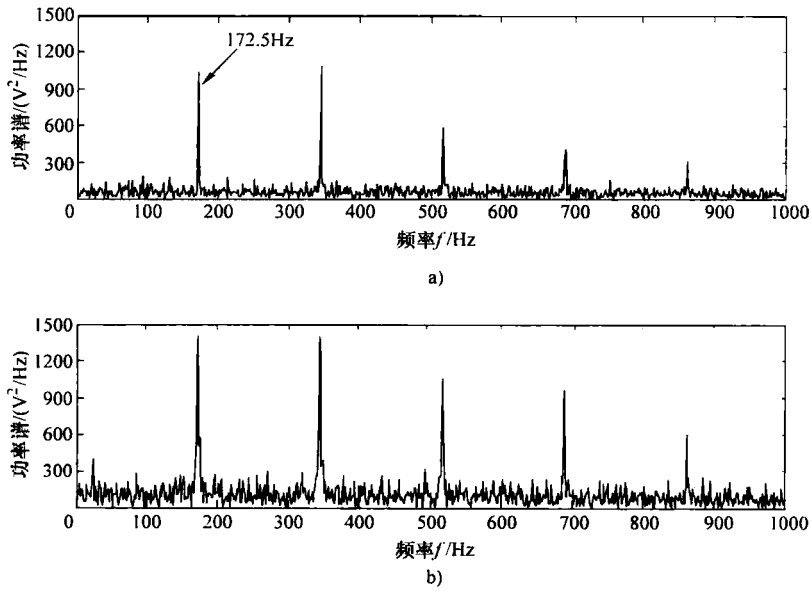

图 11-8　单柱塞松靴故障包络解调信号功率谱

a）正常状态　b）松靴柱塞 1

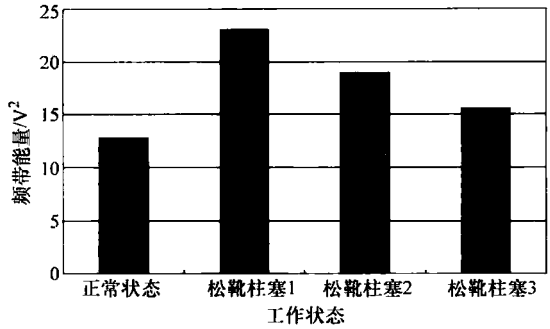

图 11-9 不同故障程度的 d（4，2）系数对应的频带能量

设置采样频率为 20kHz，截取监测结果中时间长度为 2s 的一段。图 11-10 是松靴故障声音信号的时域波形图。

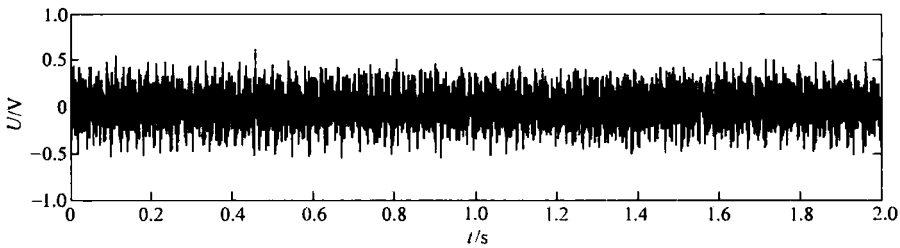

图 11-10 松靴故障的声音信号时域波形

图 11-11 是图 11-10 的功率谱图，从图 11-11 中可以看出，存在多个半倍频的谐波成分，且谱图杂乱，很难从中提取出有用的特征信息，所以必须对原始的时域信号进行处理，提取出表现故障特征的有用信号再进行频谱分析。

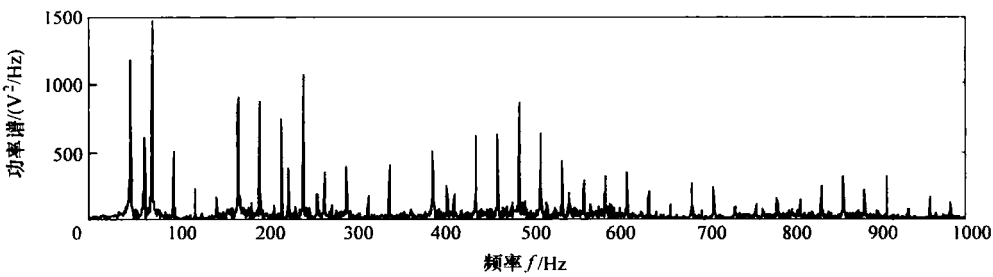

图 11-11 松靴故障的声音信号功率谱

采用 Daubechies 5 小波对松靴故障的声音信号进行 4 层小波分解。其分解系数对应的频带如表 11-2 所示。提取高频系数 d_1 进行小波重构，得到 d_1 对应频带的时域信号，达到高通滤波的目的。

表 11-2　分解系数对应的频带

系　数	频带/Hz	系　数	频带/Hz
d_1	5000 ~ 10000	d_4	625 ~ 1250
d_2	2500 ~ 5000	a_4	0 ~ 625
d_3	1250 ~ 2500	—	—

对滤波后的时域信号进行阈值消噪后利用 Hilbert 包络解调算法得到包络信号的频谱图。用同样的方法分别得到泵正常状态和三个不同松靴柱塞的声音信号的包络谱，如图 11-12 所示。

从图 11-12a 可以看出，在 172.5Hz 和 345Hz 的位置出现了谐振峰值，这与泵的振动机理分析结果一致。图中可见，泵声音信号的包络谱对松靴故障有明显的反应。松靴故障发生时，24.6Hz 频率位置的幅值有明显的增加。由此可以判断此频率位置一定是松靴故障特征的敏感点。从 3 种不同程度的松靴故障声音信号包络谱中可以看出，24.6Hz 频率下的幅值按由大到小的顺序排列，依次是松靴柱塞 1、松靴柱塞 2 和松靴柱塞 3。由此可以得出结论，松靴柱塞 1 的故障程度最大，其次是柱塞 2，再次是柱塞 3，这个结果与振动信号的分析结果是一致。由此证明，用声音信号来分析轴向柱塞泵的松靴故障是有效的。

11.1.5　柱塞泵滑靴磨损故障的信号处理

与松靴故障的实验条件相同，人为设置滑靴磨损柱塞并替换正常柱塞来模拟滑靴磨损故障。磨损程度小的滑靴编号为滑靴磨损 1，磨损程度大的滑靴编号为滑靴磨损 2。下面对磨损程度不同的两种滑靴磨损故障进行信号处理和分析。

1. 滑靴磨损故障的振动信号分析

有文献指出，滑靴和斜盘诱发的振动主要以 8 ~ 12kHz 的共振传递出来。当滑靴磨损故障发生时，滑靴和斜盘摩擦诱发的振动产生的能量主要集中在 10kHz 附近。所以分析 10kHz 所在频率段的振动信号就能找到滑靴磨损故障的变化规律。

利用 Daubechies 1 小波包对信号进行 2 层分解，提取出 6.25 ~ 12.5kHz 频带对应的系数 $d(2, 1)$，并进行小波包重构。对重构后的信号进行消噪后再进行 Hilbert 变换的包络解调处理，得到滑靴磨损故障的包络信号。对此包络信号作 0 ~ 1000Hz 频率段的包络谱分析，如图 11-13 所示。

从图 11-13 中可以看出，当滑靴磨损故障发生时在 172.5Hz 以及 2、3、4 倍频位置的能量都有所增加。由于滑靴磨损 2 的故障程度大于滑靴磨损 1，所以从图 11-13b 和图 11-13c 的比较可以看出，磨损程度越大，172.5Hz 及 2、3、4 倍频处的能量值增加得越多。

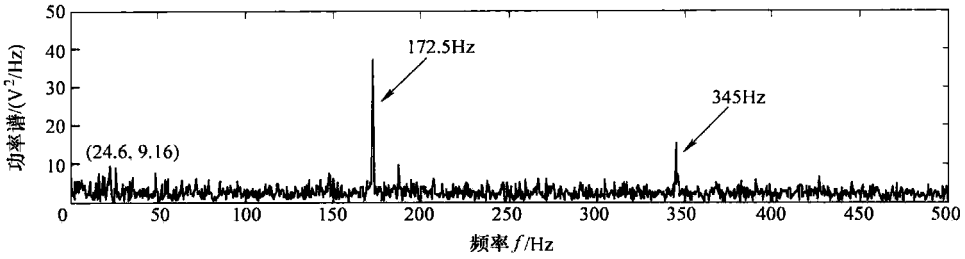

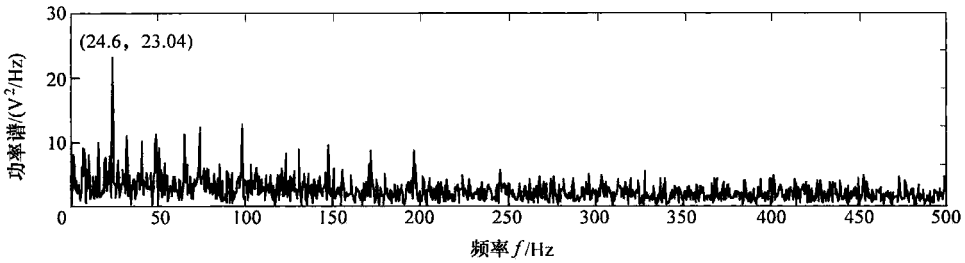

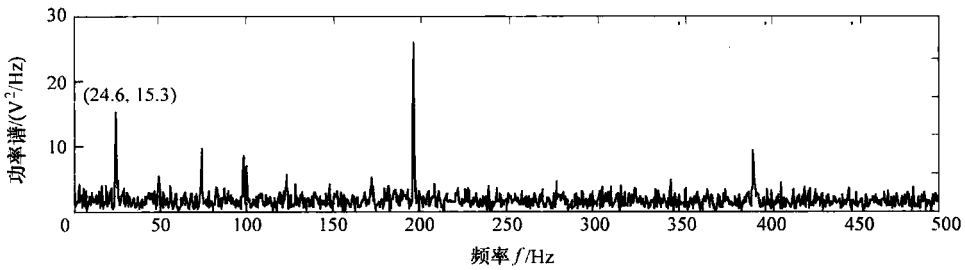

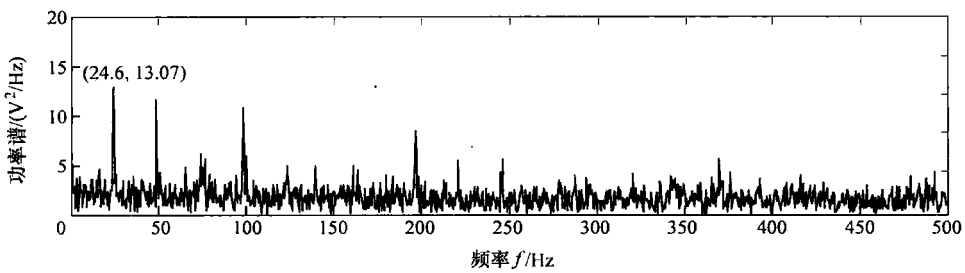

图 11-12 松靴故障的声音信号包络谱

a）正常状态 b）松靴柱塞 1 c）松靴柱塞 2 d）松靴柱塞 3

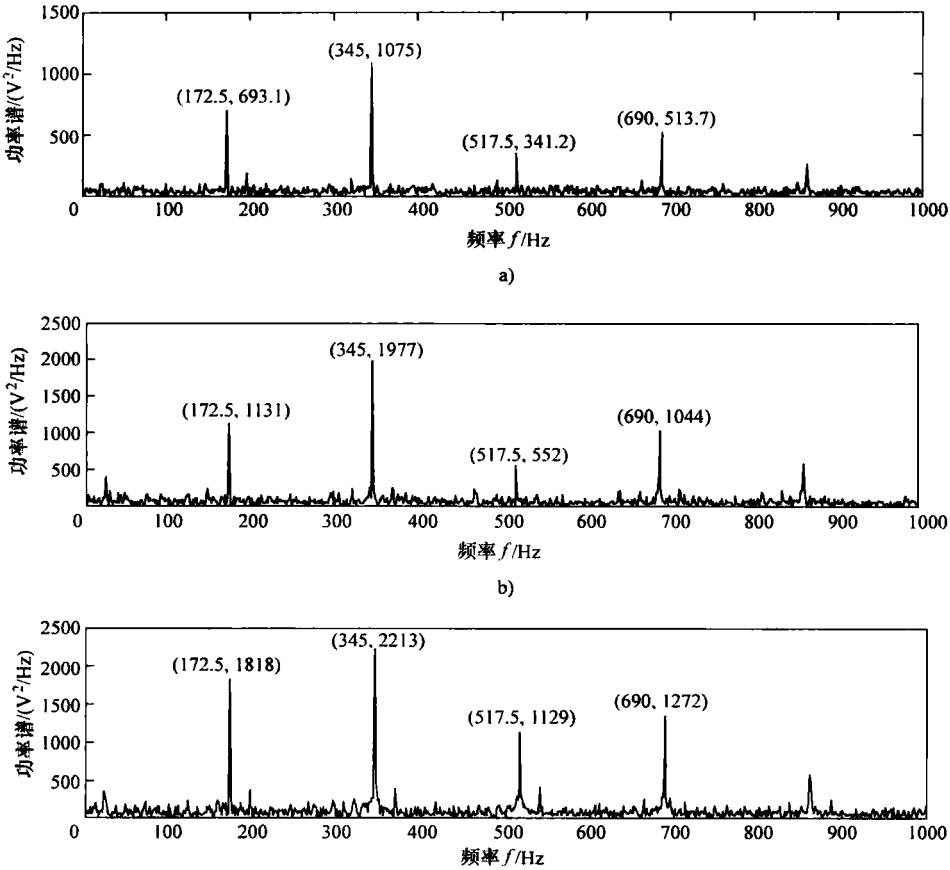

图 11-13　不同程度滑靴磨损的包络解调谱

a）正常状态　b）滑靴磨损 1　c）滑靴磨损 2

2. *滑靴磨损故障的声音信号分析*

图 11-14 为滑靴磨损故障原始声音信号的功率谱。

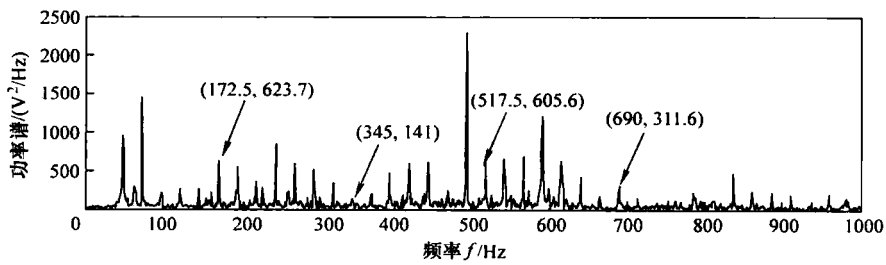

图 11-14　滑靴磨损的声音信号功率谱

从图中可以找到振动信号中表现最突出的四个频率成分，但是在滑靴磨损故障的声音信号功率谱中这几个频率成分对故障并不敏感。故障的微弱信号完全被高频声音信号所掩盖，所以必须对原始信号进行包络解调处理。

设置采样频率为 20kHz，截取监测结果中时间长度为 2s 的一段。利用松靴故障声音信号相同的处理方法对滑靴磨损故障进行分析，得到如图 11-15 所示的包络谱图。从图中可以看出，当发生滑靴磨损故障时 24.6Hz 及倍频处的幅值有明显的增加，在 24.6Hz 处幅值增加的最大，故障的特征频率应该在 24.6Hz 位置。如果用 24.6Hz 频率的幅值变化来判断故障的程度，那么从理论上讲图 11-15c 中 24.6Hz 对应的幅值应该比 11-15b 中的大。但是，图中显示的结果与理论分析正好相反，由此看来通过声音信号的包络谱来判断滑靴磨损故障的程度不是很有效的。

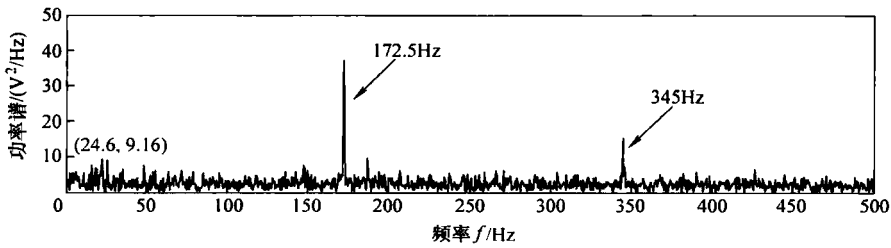

a)

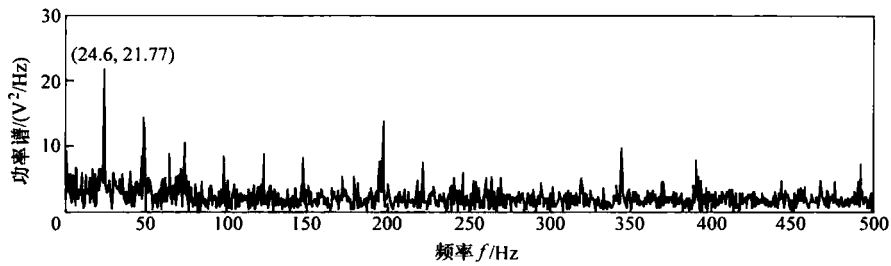

b)

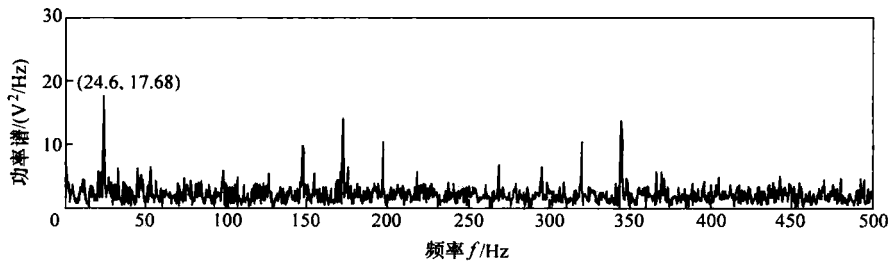

c)

图 11-15 滑靴磨损故障的声音信号包络谱

a）正常状态 b）滑靴磨损 1 c）滑靴磨损 2

11.1.6　柱塞泵中心弹簧失效故障的信号处理

轴向柱塞泵中心弹簧的作用是使缸体和配流盘之间保持预封，弹簧的预压力还同时压紧回程盘使柱塞和滑靴回程。它的缺点是要求弹簧的结构尺寸小而预压力大，即弹簧的刚度大，故设计比较困难。一旦出现弹簧加工质量的问题，弹簧达不到刚度要求或太短，就会使柱塞不能回程，缸体与配流盘之间失去其密封性能，泵的容积效率下降，工作效率降低。所以中心弹簧失效故障也是液压泵故障诊断过程中不可忽略的故障形式之一。

采用对中心弹簧端部进行不同程度的磨损，来模拟刚度不满足要求的各类弹簧。弹簧刚度的计算公式为

$$P=\frac{Gd^4}{8D^3n} \tag{11-3}$$

式中　G——切变模量（MPa）；

D——弹簧中径（mm）；

d——材料直径（mm）；

n——有效圈数。

经过对弹簧各参数的测量，得到正常弹簧的刚度约为 $P=19.75\text{N/mm}$。

弹簧力的计算公式为

$$F=Kx \tag{11-4}$$

式中　K——中心弹簧失效故障的弹簧刚度；

x——弹簧的压缩或拉伸的长度。

定义弹簧的一次磨损量为 Δx。通过式（11-4）可以确定弹簧刚度 K 和 Δx 的关系

$$K=\frac{P(x-\Delta x)}{x} \tag{11-5}$$

由此弹簧的失效程度可由式（11-3）和式（11-5）得出

$$\gamma=\frac{P-K}{P}\times 100\% \tag{11-6}$$

通过式（11-5）、式（11-6）模拟出三种故障程度分别为弹簧磨损量 1.0mm、1.2mm 和 1.4mm，失效程度分别为 28.6%、34.3% 和 40.0%。

截取监测结果中时间长度为 1.2s 的一段时域信号进行分析。

1. 中心弹簧失效故障的振动信号分析

首先利用 Daubechies 5 小波对中心弹簧失效故障的振动信号进行 4 层小波分解，带通滤波，然后对滤波后的高频系数 d_1 进行重构。对重构后的 d_1 再进行小波包阈值消噪处理。最后利用基于 Hilbert 变换的包络解调法对消噪后的 d_1 信号进行

包络谱分析，得到的包络谱如图 11-16 所示。

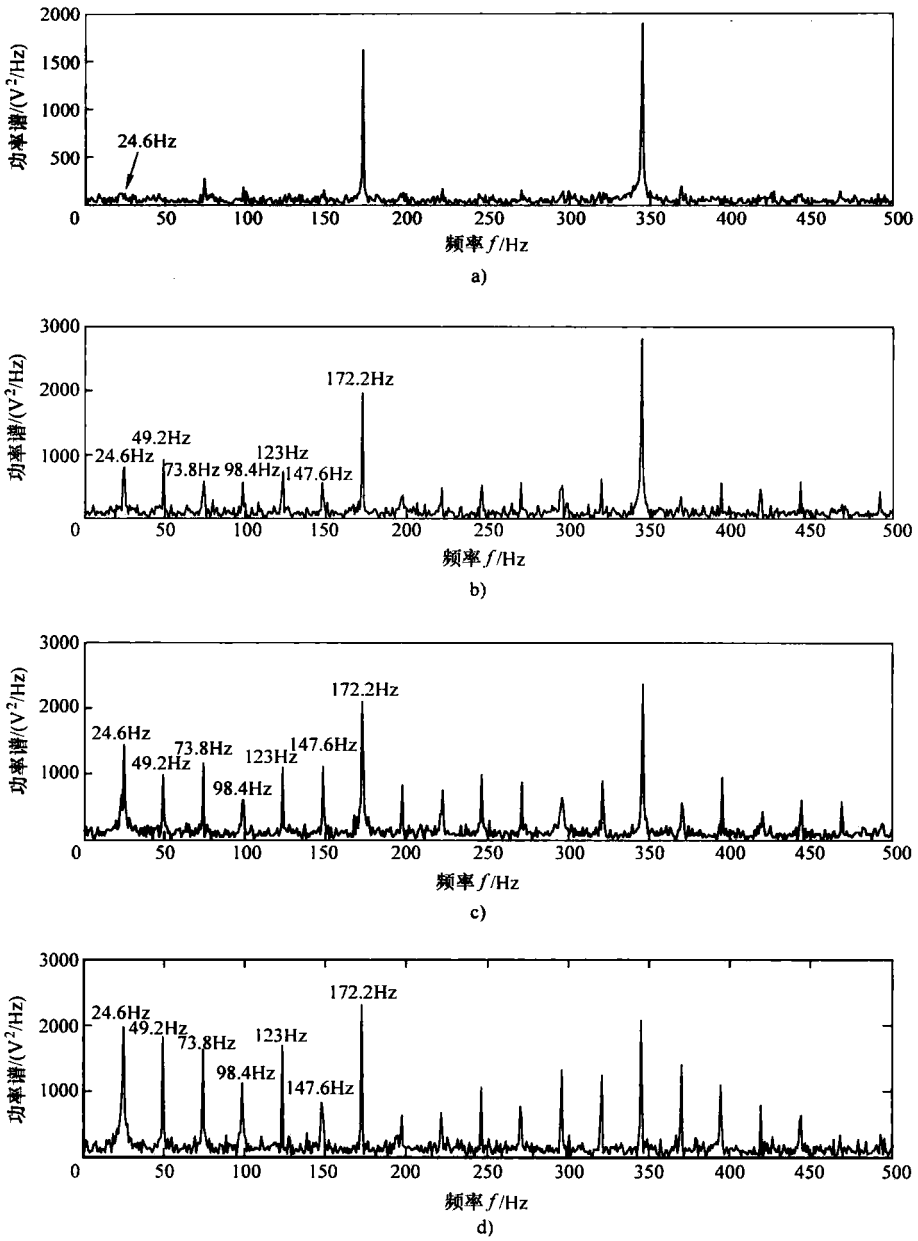

图 11-16 中心弹簧失效故障的振动信号包络谱

a）正常状态 b）磨损量为 1.0mm c）磨损量为 1.2mm d）磨损量为 1.4mm

从图 11-16 中正常状态与中心弹簧故障状态的包络谱比较可以看出，发生故障时的谱峰幅值与正常状态相比有明显的增加，而且故障程度不同的频谱图也相差很大。图 11-16 可见，24.6Hz 及倍频处都有明显的峰值变化，其中 24.6Hz 处峰值变化最大，而且随着弹簧磨损量的增加峰值逐渐增大。故 24.6Hz 是中心弹簧故障反映最敏感的特征频率。

2. 中心弹簧失效故障的声音信号分析

设置采样频率为 20kHz，截取监测结果中时间长度为 1s 的一段，用与振动信号相同的处理方法对声音信号进行分析处理，得到的包络谱如图 11-17 所示。

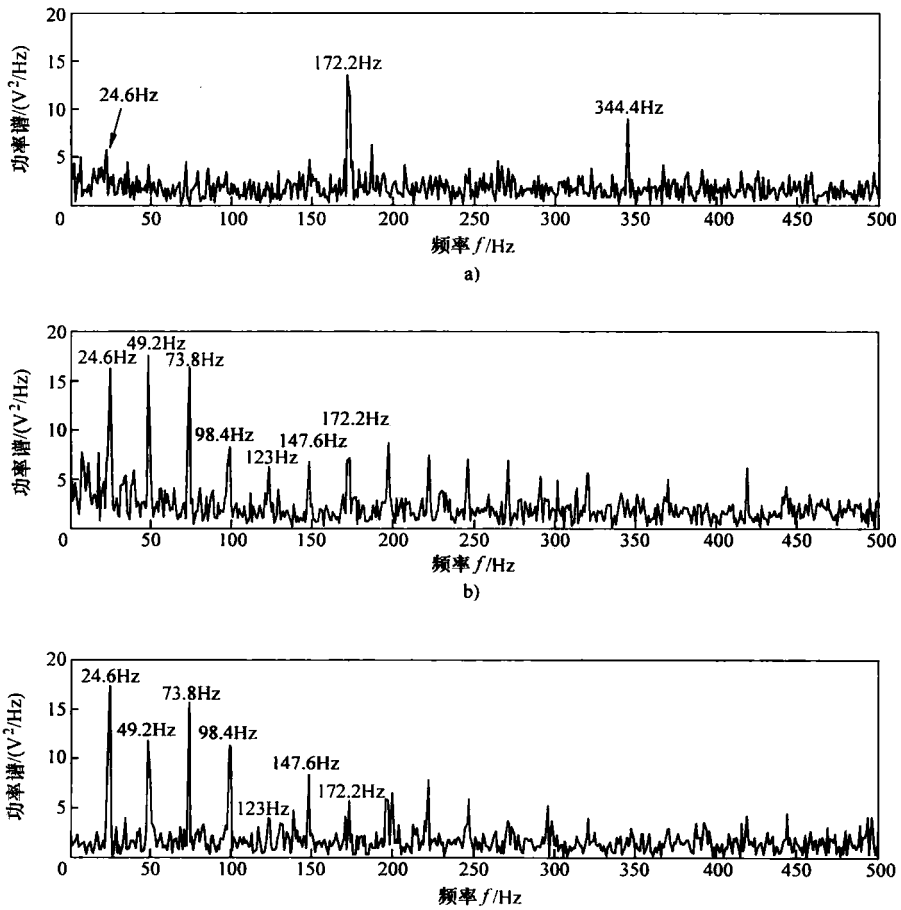

图 11-17　中心弹簧失效故障的声音信号包络谱

a）正常状态　b）磨损量为 1.0mm　c）磨损量为 1.2mm

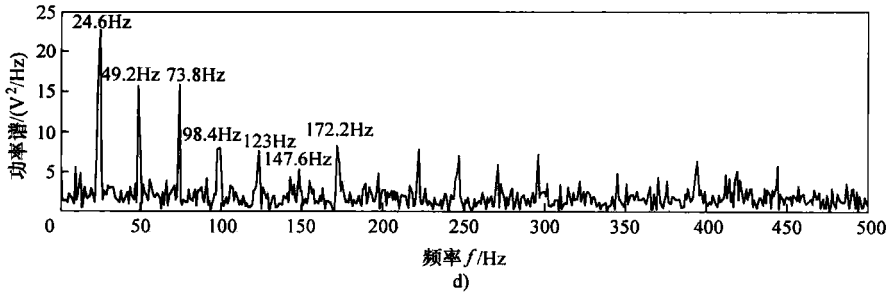

图 11-17 中心弹簧失效故障的声音信号包络谱（续）

d）磨损量为 1.4mm

比较图 11-16 和图 11-17 可以看出，声音信号和振动信号有相同的变化规律。图 11-17 可见，当发生中心弹簧失效故障时，24.6Hz 及其倍频处幅值都有明显地增加，其中 24.6Hz 处幅值增加得最大。而且弹簧磨损量越大，谱图上 24.6Hz 对应的峰值越高。由此可以判断 24.6Hz 是中心弹簧失效故障的敏感特征频率，此敏感频率在声音信号包络谱中的表现比在振动信号包络谱中更加明显。

11.2 故障特征向量提取方法

由于液压泵故障的复杂性和多样性，导致不同的故障表现出相同的频率特征，所以只通过分析故障特征频率是无法实现故障识别的。为此，本节提出了从多信号域获取故障特征向量的思想，通过多特征参数的变化来描述故障发生的类型和程度。本节重点研究信号幅值域中无量纲参数和时频域中基于小波包分解的频带能量分析的特征提取方法。

11.2.1 信号的幅值域特征提取

在信号幅值上进行的各种处理称为幅值域分析。信号的简单幅值域参数包括均值、最大值、最小值、均方根值等。对信号 $x_s(t)$ 采样所得的一组离散数据 x_1，x_2，…，x_N，则这些参数的计算式为

$$\overline{X} = \frac{1}{N}\sum_{i=1}^{N} x_i \tag{11-7}$$

$$X_{\max} = \max\{|x_i|\} \quad i = 1, 2, \cdots, N \tag{11-8}$$

$$X_{\min} = \min\{x_i\} \quad i = 1, 2, \cdots, N \tag{11-9}$$

$$X_{\text{rms}} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} x_i^2} \tag{11-10}$$

$$D_x = \frac{1}{N-1}\sum_{i=1}^{N}(x_i - \overline{X})^2 \tag{11-11}$$

上述各式中，$\overline{X}$ 为均值，X_{max} 为最大值，X_{min} 为最小值，X_{rms} 为均方根值，D_x 为方差。均方根值反映信号的能量大小，方差表示数据的分离程度，它们之间有如下关系：

$$D_x = X_{rms}^2 - \overline{X}^2 \tag{11-12}$$

若 $x(t)$ 为一采样长度为 T 的模拟信号，则

$$\overline{X} = \frac{1}{T}\int_0^T x(t)\,\mathrm{d}t \tag{11-13}$$

$$X_{rms} = \sqrt{\frac{1}{T}\int_0^T x^2(t)\,\mathrm{d}t} \tag{11-14}$$

$$D_x = \frac{1}{T}\int_0^T [x(t) - \overline{X}]^2\,\mathrm{d}t \tag{11-15}$$

这些幅值域参数计算简单，对故障有一定的敏感性。在旋转设备的振动监测中，还常使用峰峰值 X_{P-P} 来观察信号强度的变化。事实上，各种幅值域参数本质上取决于随机信号的概率密度函数。

1. 随机信号的幅值概率密度

随机信号的概率密度函数表示幅值 $x(t)$ 落在某一个指定范围内的概率大小。如图 11-18 所示，$x(t)$ 落在 $(x, x+\Delta x)$ 范围内的总时间为 T_x，当时间趋于无穷时，T_x/T 将趋于确定的概率。因此，概率密度函数可定义为

$$p(x) = \lim_{\Delta x \to 0}\frac{P[x < x(t) \leqslant x + \Delta x]}{\Delta x} = \lim_{\Delta x \to 0}\frac{1}{\Delta x}[\lim_{T \to \infty} T_x/T] \tag{11-16}$$

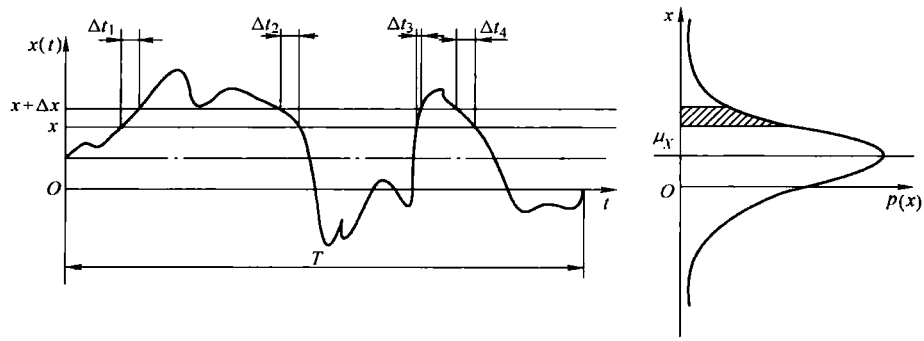

图 11-18　概率密度

幅值概率分布函数 $P(x)$ 定义为

$$P(x) = P[x(t) \leqslant x] = \int_{-\infty}^{x} p(x)\,\mathrm{d}x \tag{11-17}$$

它表示了 $x(t)$ 瞬时值小于或等于某一值 x 的概率，又称累积概率分布函数。图 11-19 中信号 $x(t)$ 振幅小于或等于 x 的概率密度函数曲线部分所围的面积等于 x 处的概率分布函数值。

根据定义有如下性质

$$\int_{x_1}^{x_2} p(x)\,\mathrm{d}x = P(x_2) - P(x_1) \tag{11-18}$$

$$\int_{-\infty}^{\infty} p(x)\,\mathrm{d}x = P(\infty) = 1 \tag{11-19}$$

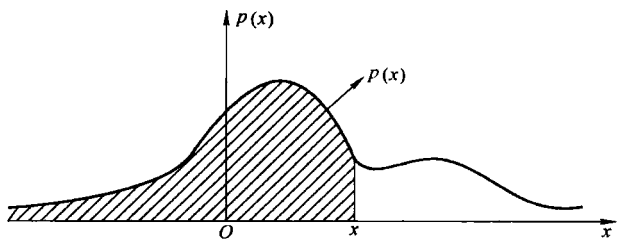

图 11-19 概率分布函数

2. 有量纲幅值域诊断参数

随机信号 $x(t)$ 的幅值域参数与幅值概率密度函数 $p(x)$ 有密切关系，它们可以通过 $p(x)$ 而获得

$$\overline{X} = \int_{-\infty}^{\infty} xp(x)\,\mathrm{d}x \tag{11-20}$$

$$X_{\mathrm{rms}} = \sqrt{\int_{-\infty}^{\infty} x^2 p(x)\,\mathrm{d}x} \tag{11-21}$$

$$X_r = \left[\int_{-\infty}^{\infty} \sqrt{|x|}\,p(x)\,\mathrm{d}x\right]^2 \tag{11-22}$$

$$|\overline{X}| = \int_{-\infty}^{\infty} |x|p(x)\,\mathrm{d}x \tag{11-23}$$

$$\alpha = \int_{-\infty}^{\infty} x^3 p(x)\,\mathrm{d}x \tag{11-24}$$

$$\beta = \int_{-\infty}^{\infty} x^4 p(x)\,\mathrm{d}x \tag{11-25}$$

其中 X_r 为方根幅值，$|\overline{X}|$ 为平均幅值，α 为斜度，β 为峭度。

斜度 α 反映 $p(x)$ 对于纵坐标的不对称性，不对称越厉害，α 越大。一般说来，随着故障的发生和发展，均方根值 X_{rms}、方根幅值 X_r、平均幅值 $|\overline{X}|$ 以及峭度 β 均会逐渐增大。其中，峭度 β 对大幅值非常敏感，当其概率密度增加时，β 值将迅速增大，这有利于探测信号中含有脉冲的故障。

在实际应用中，对于各态历经的平稳随机过程 $\{x_n(t)\}$，可以用任一样本曲线来计算。对于离散的时序数据 x_1，x_2，…，x_N，可以用以下式子进行计算

$$X_r = \left[\frac{1}{N}\sum_{i=1}^{N}\sqrt{|x_i|}\right]^2 \tag{11-26}$$

$$|\overline{X}| = \frac{1}{N}\sum_{i=1}^{N}|x_i| \tag{11-27}$$

$$\alpha = \frac{1}{N}\sum_{i=1}^{N}x_i^3 \tag{11-28}$$

$$\beta = \frac{1}{N}\sum_{i=1}^{N}x_i^4 \tag{11-29}$$

上述参数在进行计算时应做零均值处理，即从原始数据中减去其均值，只保留信号的动态部分进行计算。在不存在摩擦碰撞的情况下，以加速度、速度为测量传感器的系统，其平均值反映了测量系统的温漂、时漂等参数变化。使用涡流传感器的故障诊断系统的平均值则与磨损量有关。

3. 无量纲幅值域诊断参数

有量纲幅值域诊断参数的值常因负载、转速等条件的变化而改变，实际中很难找到变化规律。改善的办法是引入无量纲的幅值域参数，它们对信号的幅值和频率的变化不敏感，即和机器工作条件关系不大，而对故障足够敏感。

通常定义的峰值 X_{max} 是指振动波形的单峰最大值。由于它是一个时不稳参数，不同的时刻变动很大。因此，在机械故障诊断系统中采取如下方式提高峰值指标的稳定性：在一个信号样本的总长中，找出绝对值最大的 10 个数的算术平均值作为峰值 X_{max}。

$$C_f = \frac{X_{max}}{X_{rms}} \tag{11-30}$$

其中 C_f 为峰值指标。

脉冲指标为

$$I_f = \frac{X_{max}}{|\overline{X}|} \tag{11-31}$$

脉冲指标 I_f 和峰值指标 C_f 都是用来检测信号中是否存在冲击的统计指标。

波形指标为

$$S_f = \frac{X_{rms}}{|\overline{X}|} \tag{11-32}$$

裕度指标 CL_f 用于检测机械设备的磨损情况。

$$CL_f = \frac{X_{max}}{X_r} \tag{11-33}$$

峭度指标 K_v 反映振动信号中的冲击特征。

$$K_v = \frac{\beta}{X_{\text{rms}}^4} \tag{11-34}$$

峭度指标 K_v对信号中的冲击特征很敏感，正常情况下其值应该在 3 左右，如果这个值接近 4 或超过 4，则说明机械的运动状况存在冲击性振动。一般情况下是间隙过大、滑动副表面存在破碎等原因。表 11-3 给出了各幅值域参数对故障的敏感性和稳定性比较。

表 11-3 幅值域参数对故障敏感性和稳定性比较

幅值域参数	敏感性	稳定性	幅值域参数	敏感性	稳定性
峰值指标 C_f	一般	一般	裕度指标 CL_f	好	一般
脉冲指标 I_f	一般	一般	峭度指标 K_v	好	差
波形指标 S_f	差	好	均方根值 X_{rms}	较差	较好

峭度指标、裕度指标和脉冲指标对早期故障比较敏感。当机器发生异常时，它们有明显的增加。但上升到一定程度后，随故障的逐渐发展，反而会下降，表明它们对早期故障有较高的敏感性，但稳定性不好。均方根值的稳定性较好，但对早期故障信号不敏感。所以，为了取得较好的诊断效果，常将它们同时应用，以兼顾敏感性和稳定性。

11.2.2 基于小波包的时频域特征提取

时域统计特征指标只能反映机械设备的总体运转状态是否正常，因而在机械设备故障诊断系统中常用于故障监测，趋势预报。要确定故障的部位、故障的类型就需要作进一步的精密分析。频域分析是最重要、最常用的分析方法之一。对多源信号进行处理时，主要运用的就是频域中频谱分析的方法，目的是提取故障的特征频率，找到故障发生源。但是只对频谱图进行分析，无法找到各故障模式间的区别。小波包分析提出一种全新的时频分析方法。它先利用小波包分解将原始信号分解成在不同频带上的投影，再对这些频带内的信号进行分析，在整个频域内全面地反映故障特征的变化趋势，找到各故障潜在的规律。由此，可以利用小波包分解的频带能量对液压泵故障信号进行特征提取。

11.2.3 液压泵振动信号的幅值域特征提取

采用采样频率为 50kHz 的液压泵正常状态、单柱塞松靴故障、滑靴磨损故障、中心弹簧失效故障和斜盘磨损故障五种状态的泵端盖振动信号原始数据，分别进行幅值域无量纲参数指标分析。

每 0.8s 计算一次指标，作为一个样本。首先通过信号处理得到故障的包络解调信号；然后利用隔点采样的方法将包络信号的采样频率降至 2kHz，此时数据长

度为 1600 点；最后利用该数据计算一组幅值域指标。这样重复采样得到每种故障 50 组样本。其中一组样本中计算得到的各指标见表 11-4。

表 11-4　液压泵五种状态的幅值域指标

状　态	S_f	C_f	CL_f	I_f	K_v	状　态	S_f	C_f	CL_f	I_f	K_v
正常	1.66	8.43	17.75	13.95	19.05	中心弹簧失效	8.30	48.68	12641.09	403.87	569.71
松靴	1.87	12.38	29.72	23.14	46.34	斜盘磨损	1.62	10.00	20.24	16.22	24.19
滑靴磨损	1.89	11.94	29.49	22.56	35.83						

1. 波形指标

图 11-20 表示的是故障状态和正常状态波形指标的对比分析。

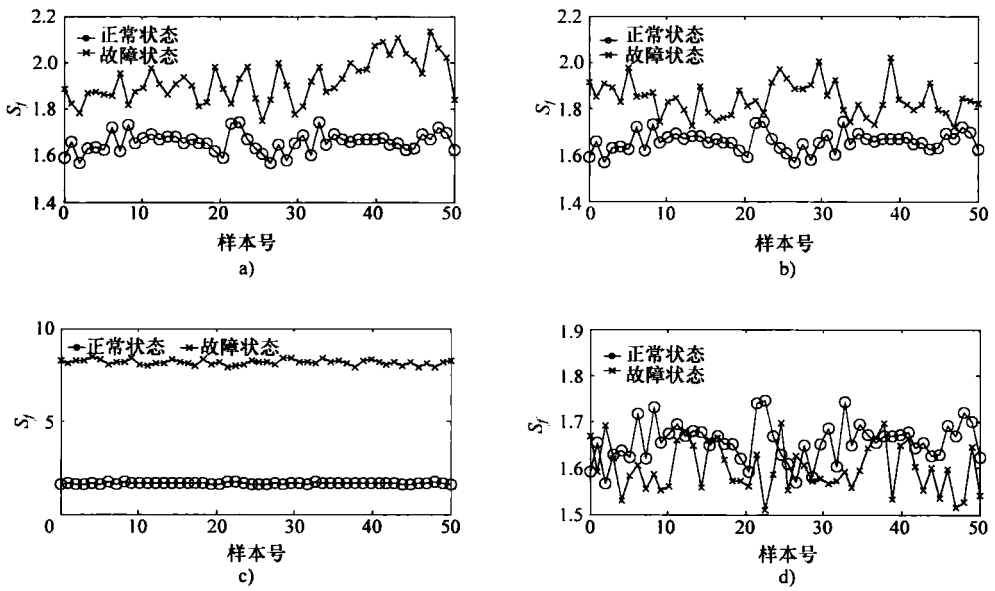

图 11-20　各故障类型的波形指标

a）单柱塞松靴　b）滑靴磨损　c）中心弹簧失效　d）斜盘磨损

从图中可以看出，波形指标对这四种故障都有敏感性，但敏感程度不同。单柱塞松靴故障、滑靴磨损故障或中心弹簧失效故障发生时其波形指标可以明显高于正常状态，其中以中心弹簧失效故障的指标变化最为显著。这说明波形指标对这三类故障有很好的敏感性。而斜盘磨损故障发生时从整体变化趋势来看，其波形指标低于正常状态，但变化不明显。这说明波形指标对斜盘磨损故障的敏感性一般。

2. 峰值指标

图 11-21 所示的是故障状态和正常状态的峰值指标对比分析。

从图中可以看出，四种故障的峰值指标与正常状态相比有明显的增大。其中以中心弹簧失效故障变化最为显著，所以可以判断，峰值指标对此故障有很好的敏感性。其他三种故障的峰值指标大部分样本相对正常状态有所增加，从图中可以判断峰值指标对单柱塞松靴和滑靴磨损故障敏感性较好，而对斜盘磨损的敏感性较差。

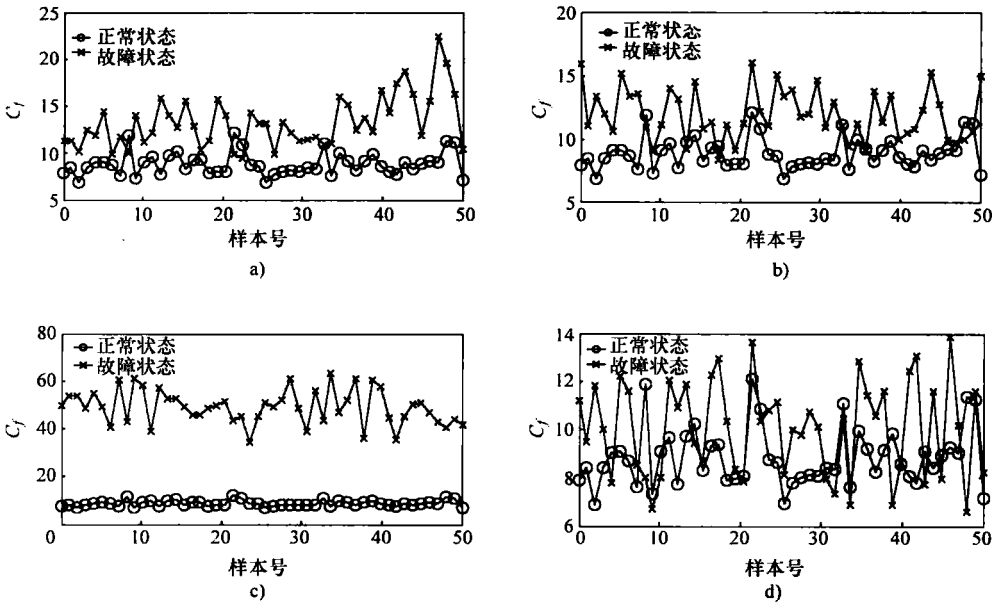

图 11-21 各故障类型的峰值指标

a）单柱塞松靴 b）滑靴磨损 c）中心弹簧失效 d）斜盘磨损

3. 裕度指标

图 11-22 所示的是故障状态和正常状态裕度指标的对比分析。

图 11-22 说明，中心弹簧失效故障发生时裕度指标明显高于正常状态，由此可以看出裕度指标对此故障的敏感性很好。单柱塞松靴和滑靴磨损故障发生时大部分样本的裕度指标高于正常状态，只有少数样本指标相对正常状态有所降低。所以可以断定，该指标对这两种故障的敏感性较好。而斜盘磨损故障看不出明显的变化趋势，所以不能用该指标来判断是否发生斜盘磨损故障。

4. 脉冲指标

图 11-23 所示的是故障状态和正常状态脉冲指标的对比分析。从图中故障状态的脉冲指标分布来看，脉冲指标对中心弹簧失效故障的敏感性最好，对单柱塞松靴和滑靴磨损两种故障的敏感性较好，而对斜盘磨损故障的敏感性最差。脉冲指标和峰值指标都是用来检测信号中是否存在冲击的统计指标，所以在液压泵发生故障时判断是否存在冲击，可以通过对这两个指标的判断来完成。

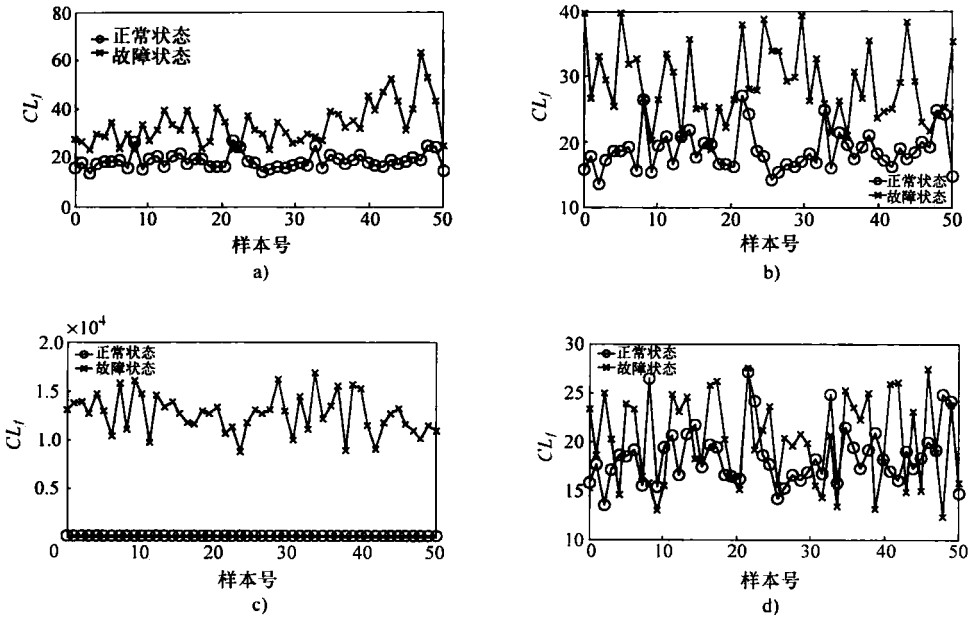

图 11-22　各故障类型的裕度指标

a）单柱塞松靴　b）滑靴磨损　c）中心弹簧失效　d）斜盘磨损

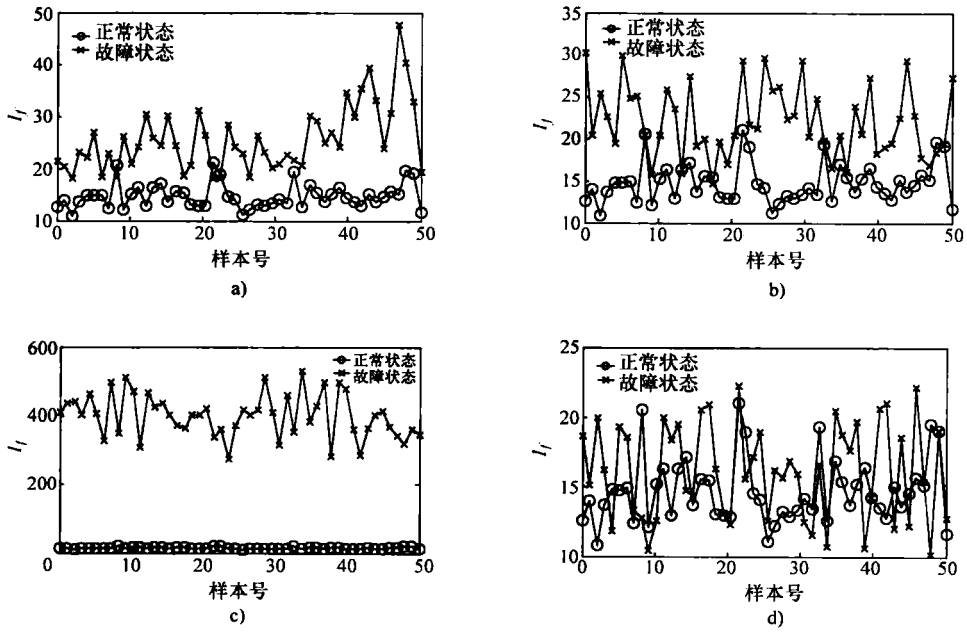

图 11-23　各故障类型的脉冲指标

a）单柱塞松靴　b）滑靴磨损　c）中心弹簧失效　d）斜盘磨损

5. 峭度指标

图 11-24 表示的是故障状态和正常状态峭度指标的对比分析图。从图中可以看出，发生中心弹簧失效故障时峭度指标明显升高；发生单柱塞松靴和滑靴磨损故障时指标有增加的趋势，但显著程度一般；发生斜盘磨损故障时大部分的峭度指标高于正常状态，而少数数据点相对正常状态有所降低。由此可以判断，峭度指标对中心弹簧失效故障的敏感性很好，对单柱塞松靴和滑靴磨损故障的敏感性较好，对斜盘磨损故障的敏感性一般。

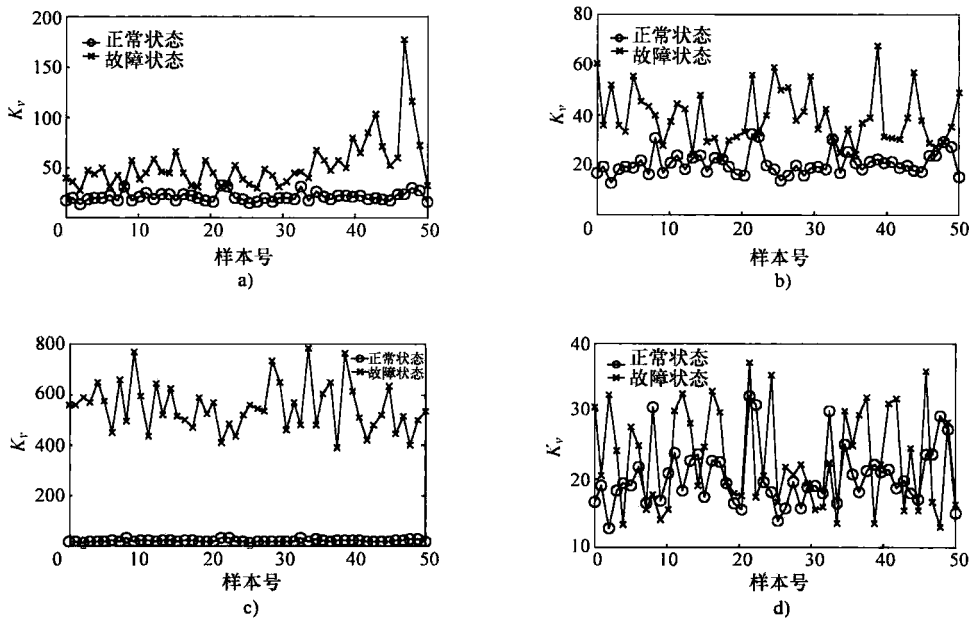

图 11-24 各故障类型的峭度指标

a）单柱塞松靴 b）滑靴磨损 c）中心弹簧失效 d）斜盘磨损

对以上 5 种无量纲指标的分析结果进行归纳，如表 11-5 所示。通过无量纲指标对故障的敏感性实验对比分析证明，从幅值域进行无量纲指标的特征提取是有效的。由于各指标对不同故障的敏感性不同，所以为了取得较好的诊断效果，常将它们同时应用，以增强特征信息的完备性。

表 11-5 各指标对不同故障的敏感性

故障 / 指标	松靴	滑靴磨损	中心弹簧失效	斜盘磨损
S_f	好	好	好	一般
C_f	较好	较好	好	较差

（续）

故障 / 指标	松　靴	滑靴磨损	中心弹簧失效	斜盘磨损
CL_f	较好	较好	好	最差
I_f	较好	较好	好	较差
K_v	较好	较好	好	一般

11.2.4　液压泵振动信号的时频域特征提取

当用一个含有丰富频率成分的信号作为输入对系统进行激励时，系统故障对各频率成分的抑制和增强作用不同，通常它会明显地对某些频率成分起到抑制作用，而对另外一些频率成分起到增强作用。它会使某些频带内信号能量减小，而使另外一些频带内信号能量增大。因此，其输出与正常系统输出相比，相同频带内信号的能量会有较大的差别。在各频率成分信号的能量分布中，包含着丰富的故障信息，某种或几种频率成分能量的改变即可代表一种故障的发生。

从以上分析可知，利用信号的频率成分能量的变化作为特征，可以建立能量分布与故障类型间的映射关系。选择合适的能量特征化向量对故障进行特征化，可以得到每种故障的特征向量。基于上述思想，给出了一种基于小波包分解的频带能量特征提取方法。该方法首先利用小波包分解提取包络信号各频带的系数，通过小波包重构算法对各分解系数进行信号重构。然后根据信号能量的定义计算各频带信号的能量。最后用各频带信号的能量占总能量的百分比作为特征构造特征向量。下面以滑靴磨损故障为例来说明小波包分解频带能量的特征提取过程。

首先通过 11.1 节所述的信号处理方法得到了滑靴磨损故障的包络解调信号，由于感兴趣的频段是 0 ~ 1000Hz，所以将包络信号的采样频率降至 2kHz，这样分析频率（Nyquist 频率）的上限为 1kHz，数据长度为 1600 点。特征向量提取的具体步骤如下：

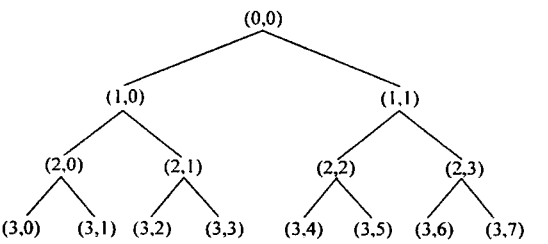

图 11-25　小波包三层分解树结构

步骤 1：首先对包络信号利用 Daubechies1 小波包进行 3 层分解，分别提取第 3 层从低频到高频 8 个子带的信号特征，其分解结构如图 11-25 所示。

图中，(i, j) 表示第 i 层的第 j 个子带，其中，$i=0, 1, 2, 3$；$j=0, 1, \cdots, 7$，每个子带都对应一定的信号特征。其中，(0，0) 子带对应原始信号 S，(1，0) 子带对应小波包分解的第一层低频系数 d_{10}，(1，1) 子带对应小波包分解第一层高频系数 d_{11}。其他依此类推。

步骤 2：对小波包分解系数重构，提取各频带范围的信号。以 S_{30} 表示 d_{30} 的重构信号，S_{31} 表示 d_{31} 的重构信号，其他依此类推。利用第三层所有子带的对应信号来表示总信号 S 为

$$S = S_{30} + S_{31} + S_{32} + S_{33} + S_{34} + S_{35} + S_{36} + S_{37} \tag{11-35}$$

由于分析频率是 1000Hz，所以第三层信号对应的 8 个频带所对应的频率范围如表 11-6 所示。

表 11-6 各频带对应的频率范围

信　号	S_{30}	S_{31}	S_{32}	S_{33}
频率范围（Hz）	0～125	125～250	250～375	375～500
信　号	S_{34}	S_{35}	S_{36}	S_{37}
频率范围（Hz）	500～625	625～750	750～875	875～1000

步骤 3：计算各频带信号的总能量。设 $S_{3k}(k=0, 1, \cdots, 7)$ 对应的能量为 E_{3k}，则有

$$E_{3k} = \int |S_{3k}(t)|^2 \mathrm{d}t = \sum_{m=1}^{N} |x_{km}|^2 \tag{11-36}$$

其中，$x_{km}(k=0, 1, \cdots, 7; m=1, 2, \cdots, N)$ 表示重构信号 S_{3k} 的离散点幅值。

步骤 4：构造特征向量。以能量为元素构造一个特征向量

$$(E_{30}, E_{31}, E_{32}, E_{33}, E_{34}, E_{35}, E_{36}, E_{37})$$

当能量较大时，$E_{3k}(k=0, 1, \cdots, 7)$ 通常是一个较大的数值，在数据分析上会带来不便。所以，需要对特征向量进行归一化处理，令

$$E = \sum_{k=0}^{7} |E_{3k}| \tag{11-37}$$

则归一化处理后的特征表示为

$$W_{3k} = E_{3k}/E \tag{11-38}$$

通过以上特征向量提取方法，可以得到液压泵滑靴磨损故障的 8 维特征向量，建立出特征向量与系统状态的对应关系。表 11-7 为用小波包归一化频带能量特征向量表示的正常状态和滑靴磨损故障的各两组样本。

表 11-7　归一化频带能量表示的特征向量样本

样本	W_{30}	W_{31}	W_{32}	W_{33}	W_{34}	W_{35}	W_{36}	W_{37}	状态
1	0.1116	0.1630	0.1262	0.1824	0.0946	0.0924	0.1055	0.1243	正常
2	0.1085	0.1504	0.1180	0.1815	0.1002	0.1037	0.1136	0.1241	正常
3	0.1167	0.1530	0.1345	0.1572	0.1052	0.0907	0.1100	0.1326	滑靴磨损
4	0.1064	0.1537	0.1258	0.1629	0.1107	0.0920	0.1136	0.1349	滑靴磨损

11.3　主元分析在特征降维中的应用

本节介绍基于主元分析的特征降维方法。针对液压泵的故障特征维数多和特征间相关性的问题，采用主元分析方法对故障特征进行降维和解耦处理，完成故障信号的特征提取。为实现液压泵实时故障诊断，11.4 节将提出了利用主元分析 Q 统计中平方预报误差的变化进行故障检测的方法，并通过对轴向柱塞泵中心弹簧失效（磨损量为 1.4mm）、单柱塞脱靴、滑靴磨损以及单柱塞松靴四种状态的故障诊断，来验证该方法的应用效果。

11.3.1　主元分析方法

主元分析（Principal Component Analysis，PCA）方法由 Pearson 于 1901 年提出，这种方法作为一种有效数学工具被归类于标准的多元统计方法中。是基于原始数据空间，通过构造一组新的潜隐变量以降低原始数据空间的维数，再从新的映射空间抽取主要变化信息，提取统计特征，从而构成对原始数据空间特性的理解。新的映射空间中的变量由原始数据变量的线性组合构成，使投影数据空间维数大大降低。由于投影空间统计变量彼此正交，多元统计分析方法消除了变量间互相关联问题，简化了原始投影空间中主元个数。采用多元统计方法能够成功地监视生产过程的操作运行情况，检测异常事件的发生，找出引起异常事件发生的原因。

假设有数据矩阵 $\boldsymbol{X}(n\times m)$，$n$ 代表测量采样次数，m 代表测量变量个数，这些数据可能存在较强的相关性，于是造成协方差阵接近奇异矩阵，不能用一般的数值方法分析。主元分析的目的就是要建立 $k(k<m)$ 个新的变量，使其尽可能多地保持原有 m 个变量的信息，这 k 个变量就称为主元素，它们是两两互不相关的。

在工程上，测量变量的取值范围变化很大，量纲也不尽相同，因而在主元分析前一般应首先将变量 $\boldsymbol{X}$ 规范化。相应的标准化向量为 $\boldsymbol{X}=(\boldsymbol{x}_1,\ \boldsymbol{x}_2,\ \cdots,\ \boldsymbol{x}_m)$，$\boldsymbol{x}_i=(\boldsymbol{x}_i-\mu_i)/\sigma_i(i=1,\ 2,\ \cdots,\ m)$，$\mu_i$和 σ_i分别为 $\boldsymbol{x}_i$的均值和标准差。经过标准化之后，$\boldsymbol{X}$ 可以分解为 m 个向量外积之和，即

$$\boldsymbol{x}=\boldsymbol{t}_1\boldsymbol{p}_1'+\boldsymbol{t}_2\boldsymbol{p}_2'+\cdots+\boldsymbol{t}_m\boldsymbol{p}_m' \tag{11-39}$$

式中，t_1，t_2，…，t_m分别称为第一主元，第二主元，……，第 m 主元，它们均为随机变量。p_i称为负荷向量。

式（11-39）也可以写为下列矩阵形式

$$\boldsymbol{X}=\boldsymbol{TP}' \tag{11-40}$$

其中 $\boldsymbol{T}=(t_1, t_2, \cdots, t_m)$ 为得分矩阵，$\boldsymbol{P}=(\boldsymbol{p}_1, \boldsymbol{p}_2, \cdots, \boldsymbol{p}_m)$ 为负荷矩阵。

各个得分向量之间是正交的，即对任何 i 和 j，当 $i\neq j$ 时，满足 $\boldsymbol{t}_i'\boldsymbol{t}_j=0$。各个负荷向量之间也是互相正交的，同时每个负荷向量的长度都为 1，即

$$\boldsymbol{p}_i'\boldsymbol{p}_j=0 \qquad i\neq j \tag{11-41}$$

$$\boldsymbol{p}_i'\boldsymbol{p}_j=1 \qquad i=j \tag{11-42}$$

将式（11-39）两侧同时右乘 $\boldsymbol{p}_i$，可以得到

$$\boldsymbol{X}\boldsymbol{p}_i=t_1\boldsymbol{p}_1'\boldsymbol{p}_i+t_2\boldsymbol{p}_2'\boldsymbol{p}_i+\cdots+t_i\boldsymbol{p}_i'\boldsymbol{p}_i+\cdots+t_m\boldsymbol{p}_m'\boldsymbol{p}_i \tag{11-43}$$

将式（11-41）和式（11-42）代入式（11-43），可以得到

$$t_i=\boldsymbol{X}\boldsymbol{p}_i \tag{11-44}$$

式（11-44）说明每一个得分向量实际上是数据矩阵 $\boldsymbol{X}$ 在这个得分向量相对应的负荷向量方向上的投影。向量 t_i的长度反映了数据矩阵 $\boldsymbol{X}$ 在 $\boldsymbol{p}_i$方向上的覆盖程度。它的长度越大，$\boldsymbol{X}$ 在 $\boldsymbol{p}_i$方向上的覆盖程度或变化范围越大。如果将得分向量按其长度做以下排列

$$\|t_1\|>\|t_2\|>\cdots>\|t_m\| \tag{11-45}$$

那么负荷向量 $\boldsymbol{p}_1$将代表数据 $\boldsymbol{X}$ 变化最大的方向，$\boldsymbol{p}_2$与 $\boldsymbol{p}_1$垂直并代表数据 $\boldsymbol{x}$ 变化第二大方向，$\boldsymbol{p}_m$将代表数据 $\boldsymbol{X}$ 变化最小的方向。

当矩阵 $\boldsymbol{X}$ 中的变量间存在一定程度的线性相关时，$\boldsymbol{X}$ 的变化将主要体现在最前面的几个负荷向量方向上，$\boldsymbol{X}$ 在最后面的几个负荷向量上的投影将会很小，它们主要是由于测量噪声引起的。这样就可以将矩阵 $\boldsymbol{X}$ 进行主元分解后写成下式

$$\boldsymbol{X}=t_1\boldsymbol{p}_1'+t_2\boldsymbol{p}_2'+\cdots+t_k\boldsymbol{p}_k'+\boldsymbol{E} \tag{11-46}$$

其中，$\boldsymbol{E}$ 是误差矩阵，代表 $\boldsymbol{X}$ 在 $\boldsymbol{p}_{k+1}$到 $\boldsymbol{p}_m$等负荷向量方向上的变化。在很多实际应用中，k 往往要比 m 小得多。由于 $\boldsymbol{E}$ 主要是由于测量噪声引起的，将 $\boldsymbol{E}$ 忽略掉往往会起到清除测量噪声的效果，不会引起数据中有用信息的明显损失。因而 $\boldsymbol{x}$ 可以近似地表示为

$$\boldsymbol{X}\approx t_1\boldsymbol{p}_1'+t_2\boldsymbol{p}_2'+\cdots+t_k\boldsymbol{p}_k' \tag{11-47}$$

对矩阵 $\boldsymbol{X}$ 进行主元分析实际上等效于对 $\boldsymbol{X}$ 的协方差矩阵 $\boldsymbol{X}'\boldsymbol{X}$ 进行向量分析。矩阵 $\boldsymbol{X}$ 的负荷向量实际上是 $\boldsymbol{X}'\boldsymbol{X}$ 的特征向量。如果将 $\boldsymbol{X}'\boldsymbol{X}$ 的特征值作如下排列：$\lambda_1\geqslant\lambda_2\geqslant\cdots\geqslant\lambda_m$，那么与这些特征值相对应的特征向量 $\boldsymbol{p}_1$，$\boldsymbol{p}_2$，…，$\boldsymbol{p}_m$即为矩阵 $\boldsymbol{X}$ 的负荷向量。

主元分析中的前 k 个主元所提供的信息只占原 m 个变量所提供信息的一部分，为了定量地描述主元所提供的信息量的大小，定义主元 t_i的方差贡献率 a_i和前 k 个

主元的累计贡献率 η_k 如下：

$$a_i = \frac{\lambda_i}{\sum_{i=1}^{n} \lambda_i} \tag{11-48}$$

$$\eta_k = \sum_{i=1}^{k} a_i = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{i=1}^{n} \lambda_i} \tag{11-49}$$

η_k 可用来衡量前 k 个主元所含有的信息量占总信息量的份额。一般情况下，可取 k 个主元，以使其累计方差贡献率 $\eta_k \geqslant 85\%$。这样，既能使损失信息不太多，又达到减少变量、简化问题的目的。

11.3.2　基于主元分析的故障检测方法

为将主元分析方法用于状态监测与故障诊断，首先需要建立一个反映系统正常运行过程的主元模型，即将正常状态的历史数据收集起来，利用主元分析方法建立主元模型。假设 $\boldsymbol{X} \in \boldsymbol{R}^{n \times m}$ 为收集到的正常状态的历史数据，对 $\boldsymbol{X}$ 进行标准化处理后得 $\overline{\boldsymbol{X}}$ 进行主元分析建立主元模型。其中 $\boldsymbol{T}_A$ 为得分矩阵，$\boldsymbol{P}_A$ 为负荷向量矩阵，$\boldsymbol{T}_e$ 为随机误差的得分矩阵，$\boldsymbol{P}_e$ 为相应的负荷向量矩阵。其数学描述为

$$\overline{\boldsymbol{X}} = \boldsymbol{T}_A \boldsymbol{P}_A' + \boldsymbol{T}_e \boldsymbol{P}_e' = \sum_{i=1}^{k} \boldsymbol{t}_i \boldsymbol{p}_i' + \sum_{j=k+1}^{m} \boldsymbol{t}_j \boldsymbol{p}_j' \tag{11-50}$$

当主元模型建好以后，可以利用它对新的测量样本 $\boldsymbol{X}_{\text{new}}$ 进行故障检测。首先计算出样本主元值 $\boldsymbol{t}_{\text{new}}$ 及 $\boldsymbol{X}_{\text{new}}$ 的估计值 $\hat{\boldsymbol{X}}_{\text{new}}$ 和残差 $\boldsymbol{E}_{\text{new}}$。

$$\boldsymbol{t}_{\text{new}} = \boldsymbol{X}_{\text{new}} \boldsymbol{P}_A \tag{11-51}$$

$$\hat{\boldsymbol{X}}_{\text{new}} = \boldsymbol{t}_{\text{new}} \boldsymbol{P}_A' = \boldsymbol{X}_{\text{new}} \boldsymbol{P}_A \boldsymbol{P}_A' \tag{11-52}$$

$$\boldsymbol{E}_{\text{new}} = \boldsymbol{X}_{\text{new}} - \hat{\boldsymbol{X}}_{\text{new}} = \boldsymbol{X}_{\text{new}} (\boldsymbol{I} - \boldsymbol{P}_A \boldsymbol{P}_A') \tag{11-53}$$

利用得到的 $\boldsymbol{t}_{\text{new}}$、$\hat{\boldsymbol{X}}_{\text{new}}$ 和 $\boldsymbol{E}_{\text{new}}$ 进行统计假设检验，根据检验结果，可以判断过程是否发生故障。常用的统计有 Hotelling T^2 统计和 Q 统计两种，如果过程正常运行下的测量数据 $\boldsymbol{X}$ 满足正态分布，则主元 $\boldsymbol{t}_i$ 应满足

$$T^2 < UCL \tag{11-54}$$

$$T^2 = \sum_{i=1}^{k} \frac{t_i^2}{s_{t_i}^2} \tag{11-55}$$

式中，$s_{t_i}^2$ 为 $\boldsymbol{t}_i$ 的估计方差。

$$UCL = \frac{k(n^2 - k)}{n(n-k)} F_\alpha(k, n-k) \tag{11-56}$$

式中，UCL 为 Hotelling T^2 统计量的上限；$F_\alpha(k,\ n-k)$ 为置信度为 α、自由度分别

为 k 和 $n-k$ 的 F 分布的上限值。

基于 HotellingT^2统计方法的假设检验只能检验主元子空间中某些变量的变动，如果某一测量变量没有被很好地体现在主元模型中，那么这种变量的故障也就无法通过该方法进行检测。这种情况下通常使用 Q 统计方法通过分析新的测量数据的残差进行故障检测。由于 PCA 是用于过程相关变量分析的工具，因此，主要采用平方预报误差 SPE（Squared Prediction Error）来监测特征的相关性。

$$SPE = \boldsymbol{EE}' = (\boldsymbol{X}_{\text{new}} - \hat{\boldsymbol{X}}_{\text{new}})(\boldsymbol{X}_{\text{new}} - \hat{\boldsymbol{X}}_{\text{new}})' \tag{11-57}$$

根据 PCA 残差的判定准则，在正常工况下 SPE 应满足下式

$$SPE \leqslant Q_\alpha \tag{11-58}$$

式中，SPE 为新观测的数据中没有被主元模型所解释的变化。Q_α表示检验水平为 α 时的判断控制限。

$$Q_\alpha = \theta_1 \left[\frac{C_\alpha (2\theta_2 h_0^2)^{1/2}}{\theta_1} + 1 + \frac{\theta_2 h_0 (h_0 - 1)}{\theta_1^2} \right]^{\frac{1}{h_0}} \tag{11-59}$$

式中，$\theta_1 = \sum_{j=k+1}^{m} \lambda_j$，$\theta_2 = \sum_{j=k+1}^{m} \lambda_j^2$，$\theta_3 = \sum_{j=k+1}^{m} \lambda_j^3$，$h_0 = 1 - \frac{2\theta_1\theta_3}{3\theta_2^2}$，$C_\alpha$ 是一个高斯分布的 $(1-\alpha)\%$ 的置信极限。

在正常工作状态下应满足式（11-58）的要求。如果出现异常有 $SPE > Q_\alpha$，则说明当前数据与主元模型数据不符，此时有故障发生。

当 $SPE > Q_\alpha$时，可以判断此时发生了故障，但是不能确定该故障引起了哪些特征变量变化。而利用贡献图能帮助描述特征变量变化的规律。第 j 个变量对第 i 时刻的 Q 统计值的贡献为

$$Q_{ij} = \boldsymbol{e}_{ij}^2 = (\boldsymbol{x}_{ij} - \tilde{\boldsymbol{x}}_{ij})^2 \tag{11-60}$$

通过对特征变量的贡献图的分析，可以找出哪些变量引起了 Q 统计量超出控制限。将得到的分析结果与先验知识相结合，将会比较容易地找出引起故障的原因。

11.3.3 主元分析特征提取及降维实例分析

液压泵故障种类很多，每种故障类型都反映出不同的故障状态特征，使得在故障诊断中必须提取大量的特征变量才能确切地描述故障类型，使诊断准确可靠。但是，提取的特征变量维数越高，特征集合中的冗余属性及存在相关性的特征就越多。粗糙集理论的属性约简算法虽然能够去除集合中的冗余属性并降低特征空间维数，但是却不能解除集合中特征间的相关性。由此看来，属性约简后的特征集合不是最小属性集合，从这个集合中很难直接抓住它们的主要信息，因此还需要进一步降维处理。这就需要一种简化数据的方法，使高维数据降维，来获得数据的主要信

息，而且在低维空间将信息分解为互不相关的部分以获得更有意义的解释。主元分析是一种能够有效实现降维解耦的多元统计方法。

传统的故障诊断方法在处理维数少的特征信息时效果明显，而对于维数较多的数据信息则很难适应，不仅增加了计算的复杂性，同时也影响了故障识别的准确性。而利用主元分析方法对多维数据信息进行处理就会很容易解决这一问题。使用主元分析方法进行特征提取的目的是将含在原始特征中有用的信息投影到几个负荷特征变量上并忽略多余信息。主元的求解可转化为求样本总体的协方差矩阵的特征值和标准正交特征向量的问题，具体归纳如下：

1）原始数据标准化。

2）求解协方差矩阵。

3）求解协方差矩阵的特征值和特征向量。

4）计算变量的主元贡献率。

5）选择累计贡献率大于 85% 的 k 个主元组成新的特征集合。

6）利用训练样本建立主元变量表达的数据样本集。

从液压泵的故障诊断实验中选取泵的 4 种工作状态共 14 个样本进行实例分析，4 种状态分别是正常状态、脱靴故障，松靴故障，配流盘磨损。按 11.1 节的方法对采集的振动信号经信号处理后得到 2kHz 采样频率的包络信号，分析频率为 1kHz，数据长度为 1600 点。下面从时频域的角度提取小波包归一化频带能量信息作为特征变量来说明主元分析方法的降维解耦过程。首先采用 db5 小波对包络信号进行 3 层小波包分解，分解系数对应的子频带见表 11-8。用提取的归一化频带能量信息作为特征向量组成原始数据特征样本集，表 11-9 所示为各种状态下的部分原始数据特征样本。

表 11-8　分解系数对应的子频带

系　数	子频带/Hz	系　数	子频带/Hz
d_{30}	0 ~ 125	d_{34}	500 ~ 625
d_{31}	125 ~ 250	d_{35}	625 ~ 750
d_{32}	250 ~ 375	d_{36}	750 ~ 875
d_{33}	375 ~ 500	d_{37}	875 ~ 1000

表 11-9　原始样本数据

样　本	特征向量								故障类型
	d_{30}	d_{31}	d_{32}	d_{33}	d_{34}	d_{35}	d_{36}	d_{37}	
1	0.2433	0.1289	0.1017	0.1562	0.0832	0.0929	0.0950	0.0989	正常状态
2	0.2598	0.1279	0.1014	0.1523	0.0863	0.0881	0.0893	0.0949	
3	0.2447	0.1253	0.0986	0.1537	0.0889	0.0935	0.0954	0.0999	

（续）

样 本	特征向量								故障类型
	d_{30}	d_{31}	d_{32}	d_{33}	d_{34}	d_{35}	d_{36}	d_{37}	
4	0.1857	0.1369	0.1375	0.1505	0.0949	0.1115	0.0926	0.0904	脱靴故障
5	0.1922	0.1546	0.1385	0.1433	0.0901	0.1053	0.0967	0.0793	
6	0.1993	0.1409	0.1205	0.1467	0.0969	0.1107	0.1038	0.0812	
7	0.1691	0.1400	0.1222	0.1356	0.1115	0.1276	0.0948	0.0993	
8	0.3383	0.1078	0.1031	0.1069	0.0865	0.0950	0.0876	0.0747	松靴故障
9	0.3258	0.1005	0.1073	0.1127	0.0960	0.0913	0.0880	0.0784	
10	0.3271	0.1023	0.1107	0.1152	0.0976	0.0820	0.0900	0.0751	
11	0.3261	0.0926	0.1104	0.1263	0.0961	0.0838	0.0901	0.0747	
12	0.2696	0.1735	0.1065	0.1171	0.0702	0.0843	0.0970	0.0818	配流盘磨损
13	0.2849	0.1593	0.0954	0.1307	0.0729	0.0732	0.0973	0.0862	
14	0.2678	0.1737	0.1026	0.1183	0.0728	0.0851	0.0955	0.0843	

经主成分变换之后的三维数据见表 11-10，得到的矩阵特征值与特征向量见表 11-11。表 11-11 列出了经过主元分析后的主元特征向量列表，可见前三个特征值占整个特征总量的 88.78%，按照主元要保留的信息量必须达到 85% 以上的原则，可以选用前三个主元作为故障特征向量。

表 11-10 主元变量表示的三维数据

样 本	第一主元	第二主元	第三主元	样 本	第一主元	第二主元	第三主元
1	-19.0795	-4.1480	-0.2189	8	-15.7339	-2.0870	-2.3186
2	-18.1975	-3.5006	-0.1405	9	-16.2243	-1.5734	-1.9257
3	-19.0787	-3.8734	-0.0593	10	-16.1535	-1.7684	-2.2644
4	-20.6971	-2.1666	-2.2026	11	-16.3486	-1.6780	-1.9081
5	-20.3024	-2.9792	-3.6125	12	-17.5382	-5.4300	-3.1859
6	-20.6002	-3.2696	-3.0538	13	-17.2092	-5.6540	-1.9042
7	-21.3619	-1.6441	-1.6772	14	-17.5321	-5.2990	-2.7587

表 11-11 主元的特征向量与特征值

特征值	特征向量	贡献率（%）
3.6395	0.5193,0.0543,0.0563,-0.1037,-0.0764,-0.0993,0.1685,0.8181	45.4934
2.2024	-0.2172,-0.5283,-0.3254,0.4019,0.0672,0.2828,-0.4261,0.3746	27.5297
1.2605	-0.3340,0.3077,-0.4576,-0.0627,0.5496,0.1801,0.4563,0.1943	15.7565

（续）

特征值	特 征 向 量	贡献率(%)
0.4269	-0.3925, -0.0890, 0.4388, -0.5288, 0.3831, -0.1708, -0.3592, 0.2468	5.3359
0.3752	-0.1903, 0.5934, 0.0708, -0.0813, -0.3883, 0.5729, -0.3075, 0.1629	4.6899
0.0765	-0.4239, 0.3139, -0.1047, 0.3508, -0.2669, -0.6839, -0.0758, 0.2076	0.9564
0.0191	-0.3181, -0.369, -0.2767, -0.521, -0.5599, 0.0063, 0.3115, 0.0637	0.2382
0.0000	-0.3169, -0.1689, 0.6297, 0.3784, -0.0728, 0.2295, 0.5055, 0.1339	0

图 11-26 表示三维主元特征空间的模式向量投影。

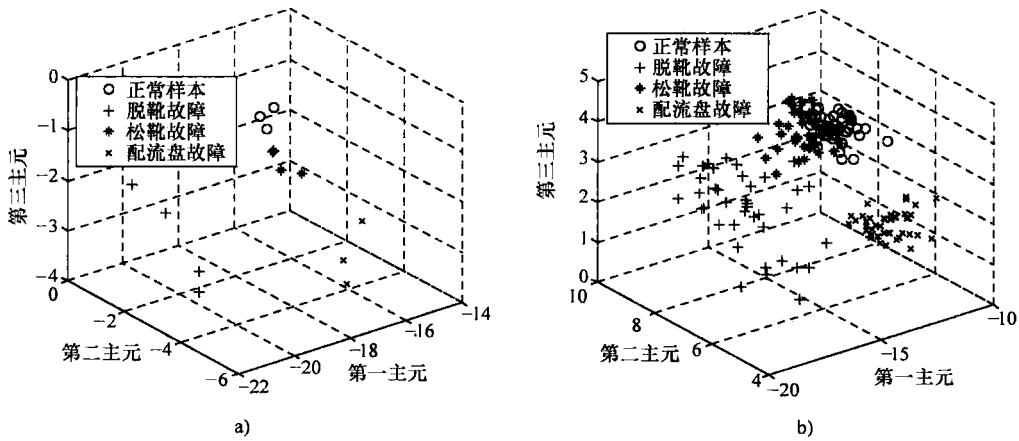

图 11-26　三维主元空间的特征向量投影

a）14 个样本　b）160 个样本

图 11-26a 可见，样本数量较少时各状态区分明显，因此可以选用三维主元特征替代原始特征。同理，对 4 组故障共 160 个样本进行分析，样本经主元分析变换后得到的三维主元特征向量空间的投影如图 11-26b 所示。从图中可以看出 4 种状态，只有少数几组样本互有重叠，绝大多数样本都能得到很好的区分，完全可以利用这三个主元变量区分液压泵的这 4 种故障类别。主元分析变换后特征向量的维数从原来的 8 降到了 3，且 3 个主元变量互不相关。由此证明，在液压泵的故障诊断实验中利用主元分析方法能够有效地对特征进行降维和解耦。

11.4　主元分析方法在故障检测中的应用

多元统计过程控制（Multivariate Statistical Process Control，MSPC）是近年来发展起来的一种有效的过程控制和故障诊断方法。主元分析方法是多元统计过程控制

中应用最多的方法之一，在过程监控与故障诊断领域有着广泛地应用，对实现生产过程中的在线故障检测与诊断具有重要的理论价值。该方法的基本思想是：在正常的连续生产中，过程变量的运行状态将保持稳定，运行轨迹应处于正常波动范围之内。当故障发生时，过程运行状态将发生变化，运行轨迹超出正常波动范围，由此可以判断故障发生的时间，准确及时地把握过程运行状态，检测故障。

为实现液压泵的实时在线故障检测，对主元分析方法在多元统计过程控制中的应用进行深入研究的基础上，本节提出了基于主元分析的液压泵故障监测与诊断方法。该方法利用 Q 统计量进行故障检测，通过贡献图来描述故障的特征变化。最后通过轴向柱塞泵四种故障的实验数据，分析该方法的应用效果。

11.4.1 故障检测方法的实现过程

根据采集的轴向柱塞泵振动信号的特点和主元分析的理论方法设计的故障检测过程如下：

1）在泵端盖位置安置振动加速度传感器，采集泵在正常工作状态和故障状态的振动信号。

2）通过带通滤波消噪和包络解调过程得到反映液压泵真实状态的包络信号。

3）对 0～1000Hz 频段内的包络信号进行小波包分解，提取出各子频带的能量信息构成故障特征向量。利用此特征提取方法提取 100 组正常状态样本。

4）将这 100 组样本进行标准化处理，利用主元分析方法建立正常过程的主元模型。

5）用同样的方法再提取正常状态样本 60 组和四种故障状态样本各 40 组，分别组成四种故障状态的测试数据，每种测试数据由 60 组正常样本和 40 组故障样本顺序排列组成，相当于 100 个样本点，以此来模拟泵在第 61 个样本时刻发生故障。

6）通过 Q 统计方法将测试数据与主元模型进行对比，一旦过程数据与建立的主元模型不符，就可以判断柱塞泵在工作过程中发生了故障。

7）通过第 j 个变量对第 i 时刻 Q 统计量贡献图的分析，找出哪些变量的贡献最大。

基于主元分析的故障检测方法流程图如图 11-27 所示。

11.4.2 故障检测实例分析

将型号为 10MCY14-1B 的轴向柱塞泵作为被诊对象，采样频率为 50kHz，对工作压力为 15MPa 的正常状态、中心弹簧失效、单柱塞脱靴、滑靴磨损以及单柱塞松靴故障的振动信号进行分析。每截取 0.8s 的数据做一组样本，根据 11.4.1 节介绍的样本制作方法，共制作正常状态样本 160 组，四种故障状态样本各 40 组。取其中 100 组正常样本用于建立主元模型，其他样本用于故障检测。

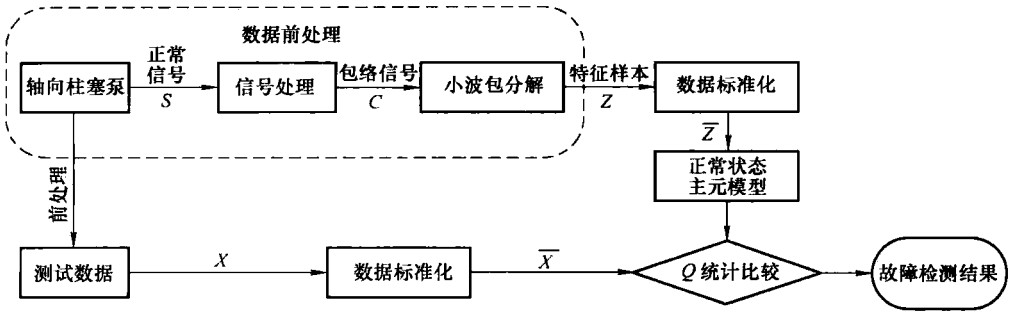

图 11-27　故障检测流程图

为了改善测得信号的信噪比，首先利用 db5 小波对原始振动信号进行 3 层分解并进行阈值消噪处理。按小波分析理论，消噪过程分为：分解、去噪和重构三个阶段。d1、d2、d3 分别为第 1 层、第 2 层和第 3 层的高频细节，a3 为第 3 层的低频逼近。由于采样频率为 50kHz，所以分析频率为 25kHz。d3、d2、d1 对应的频带分别为 3.125 ~ 6.25kHz，6.25 ~ 12.5kHz，12.5 ~ 25kHz。对 d1、d2、d3 进行阈值去噪，这种去噪方法既能提高信噪比又不损失故障特征信息和系统运行信息。消噪完成后再对信号进行重构。图 11-28 以正常状态和脱靴故障状态振动信号说明了消噪的结果。

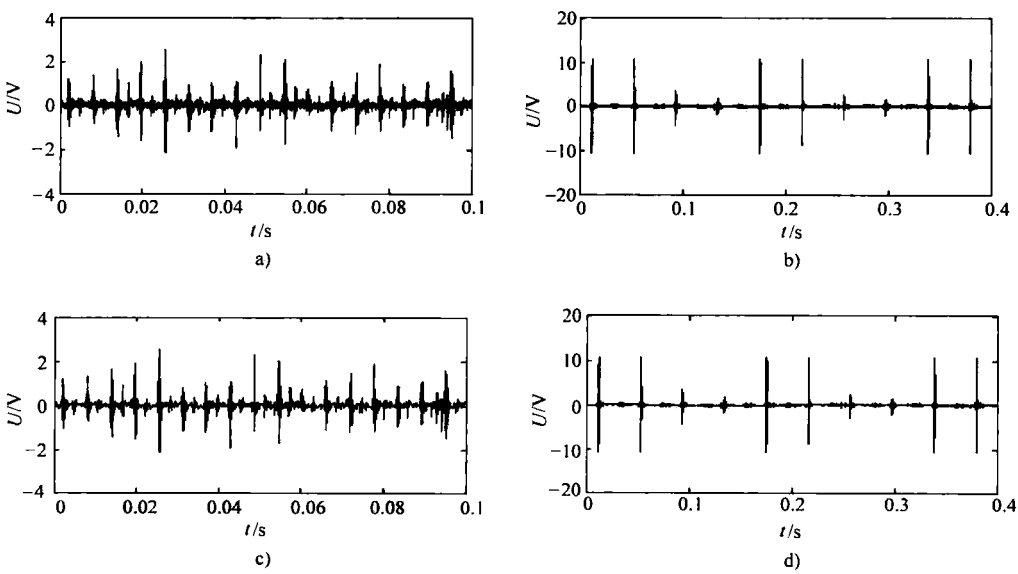

图 11-28　小波消噪处理

a）原始正常振动信号　b）原始脱靴故障振动信号

c）消噪后的正常振动信号　d）消噪后的脱靴故障振动信号

从图中可以看出消噪后的信号明显消除了干扰信号的影响得到了反映故障真实状况的有用信号。利用 db5 小波对信号进行 3 层分解-重构，信号的高次谐波信息稍有损失，但对故障特征信息和系统运行信息影响不大。

对消噪后信号进行带通滤波和包络解调处理，得到 2kHz 采样频率的包络信号。利用 db5 小波对包络信号进行 3 层小波包分解和重构，提取出各频带的能量信息表示的故障特征向量集。各分解系数对应频带的具体解释如表 11-8 所示。利用此故障特征集合制作特征样本数据。

利用 100 组正常样本建立正常工作状态下的主元模型，选取 $C_\alpha = 0.95$ 得到判断控制限为 $Q_\alpha = 1.0208$。以中心弹簧失效故障为例，来说明故障检测的整个过程。用 60 组正常样本和 40 组中心弹簧失效故障样本组成测试数据。此测试数据可看作共有 100 个采样点，每组样本对应一个采样点。前 60 个是正常状态数据采样点，后 40 个是中心弹簧失效故障数据的采样点。利用这样的测试数据来模拟采样到 61 点处发生中心弹簧失效故障，并对该采样点处对应的特征向量，利用主元模型计算 Q 统计量。通过对 SPE 值的监测和各特征向量 Q 统计量贡献的计算得到检测结果如图 11-29 所示。

从图 11-29a 中可以看出，在采样 61 点处的 SPE 值超过了控制限 Q_α，而且在 61 ~ 100 采样点区间内的 SPE（平方预报误差）值均在控制限上方变化，即 $SPE > Q_\alpha$。根据 PCA 残差的判定准则，可以断定此时刻发生了故障，并与人为制造的故障时刻相符。可以借助于贡献图来分析泵发生故障后引起的各特征向量的变化。图 11-29b为各特征向量在 61 采样点时对 Q 统计量的贡献。从该图可以看出，d_{30} 特征向量对 Q 统计量的贡献最大。由此可知，当中心弹簧失效故障发生时 d_{30}所在频带对应的能量有显著的增加。用频谱分析来说明上述分析过程的正确性。对采样频率为 2kHz 的正常状态和中心弹簧失效故障状态的包络信号进行 0 ~

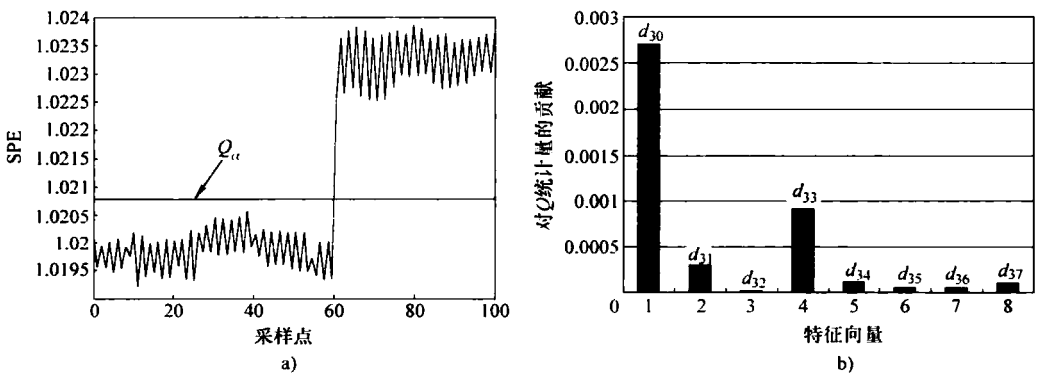

图 11-29 中心弹簧失效故障检测

a）SPE 图 b）第 61 点的 Q 统计量贡献图

1000Hz 频段的功率谱分析。从图 11-33a 和图 11-33b 两个包络谱图的比较可以看出，当发生中心弹簧失效故障时 0～125Hz 频段的频率成分对应的谱线幅值有明显的增大，尤其以 24.6Hz 频率及其倍频位置幅值变化最为显著。所以可断定，0～125Hz 频段的能量相对于正常状态有显著的增加，这与 Q 统计量贡献图的分析结果相吻合。由此证明，利用主元分析方法可以有效地检测轴向柱塞泵中心弹簧失效故障。

利用上述同样的方法和分析过程对单柱塞脱靴、滑靴磨损以及松靴故障分别进行检测。检测结果如图 11-30、图 11-31 和图 11-32 所示。

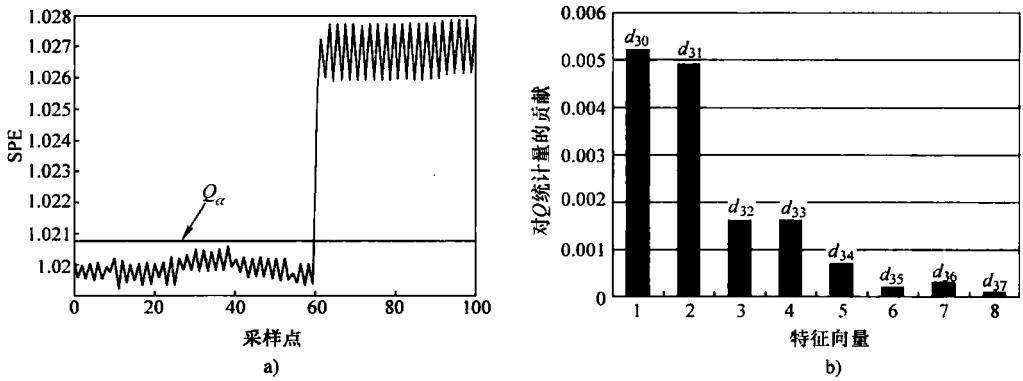

图 11-30　脱靴故障检测

a）*SPE* 图　b）第 61 点的 Q 统计量贡献图

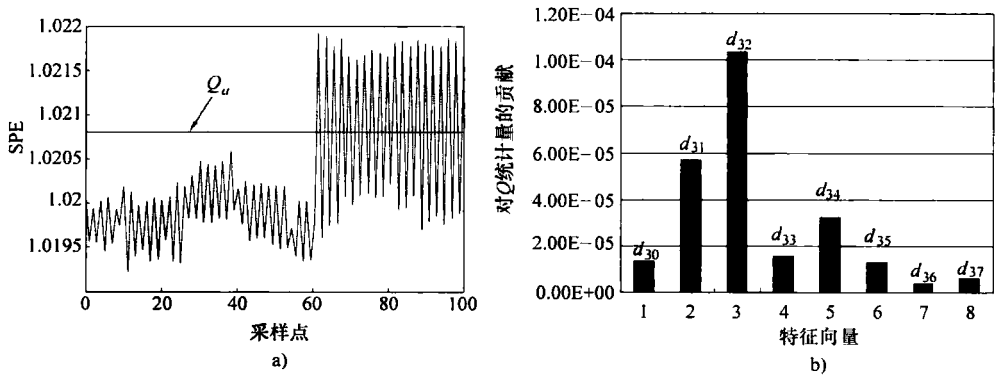

图 11-31　滑靴磨损故障检测

a）*SPE* 图　b）第 61 点的 Q 统计量贡献图

从图 11-30 中可以看出，在 61 采样点位置一定发生了故障。从第 61 点的 Q 统计量贡献图来看，d_{30} 和 d_{31} 两个特征向量对 Q 统计量的贡献最大。从图 11-33a 和

图 11-33c 两个包络谱图的比较可以看出，d_{30}和 d_{31}对应的频带能量增加的幅度最大，这与 Q 统计量贡献图的分析结果相一致。由此证明，主元分析方法对轴向柱塞泵脱靴故障的检测是有效的。

从图 11-31 中可以看出，虽然在第 61 采样点位置 *SPE* 值超出了控制限 Q_α，但是在 61 ~ 100 采样点之间的 *SPE* 值却围绕控制限上下波动变化，不能确定 *SPE* 值与 Q_α的大小关系。所以根据 PCA 残差的判定准则，通过图 11-31a 中 *SPE* 值的变化规律不能判断 61 采样点时刻是否发生故障。通过对图 11-31b 的分析发现，d_{31}和 d_{32}特征向量对 Q 统计量的贡献最大，d_{34}的贡献大于 d_{33}，所以 d_{31}和 d_{32}对应的频带能量增加最多，d_{34}对应的频带能量增加的幅度大于 d_{33}。而图 11-33d 中却显示，d_{34}所在频带的能量增加的幅度应该小于 d_{33}，所以可以断定，贡献图的方法对滑靴磨损故障特征向量变化的分析无效。由此证明，主元分析方法不能检测泵的滑靴磨损故障。

图 11-32 是松靴故障的检测结果图。图 11-32a 中 61 ~ 100 之间采样点的 *SPE* 值都没有超出控制限 Q_α，所以通过 *SPE* 值不能判断此时是否发生故障。然而，图 11-32b 中虽然显示 d_{32}、d_{33}和 d_{34}这 3 个特征向量对 Q 统计量贡献最大，对应的频带（172.5Hz 的倍频所在频带）能量相对于正常状态时增加最多，但是 d_{31}却对 Q 统计量贡献最小，对应的频带（172.5Hz 所在频带）能量也增加最少，这显然与实际相违背。在对松靴故障振动信号的分析结果已经证实，当松靴故障发生时振动信号的包络谱 172.5Hz 基频以及倍频是故障特征的敏感频率，其所在频带能量有显著增加，如图 11-33e 所示。d_{31}所在频带包含松靴故障特征的敏感频率，所以在发生故障时它所在频带的能量不可能是增加最少的。由此证明，通过主元分析方法不能检测松靴故障。

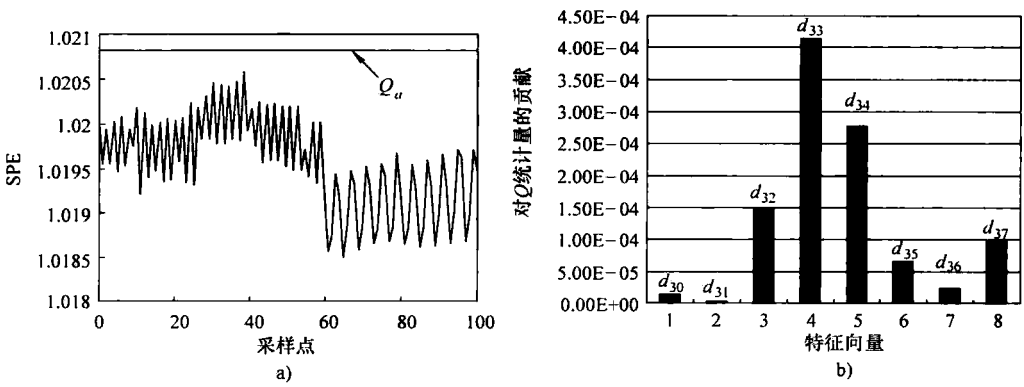

图 11-32 松靴故障检测

a) *SPE* 图 b) 第 61 点的 Q 统计量贡献图

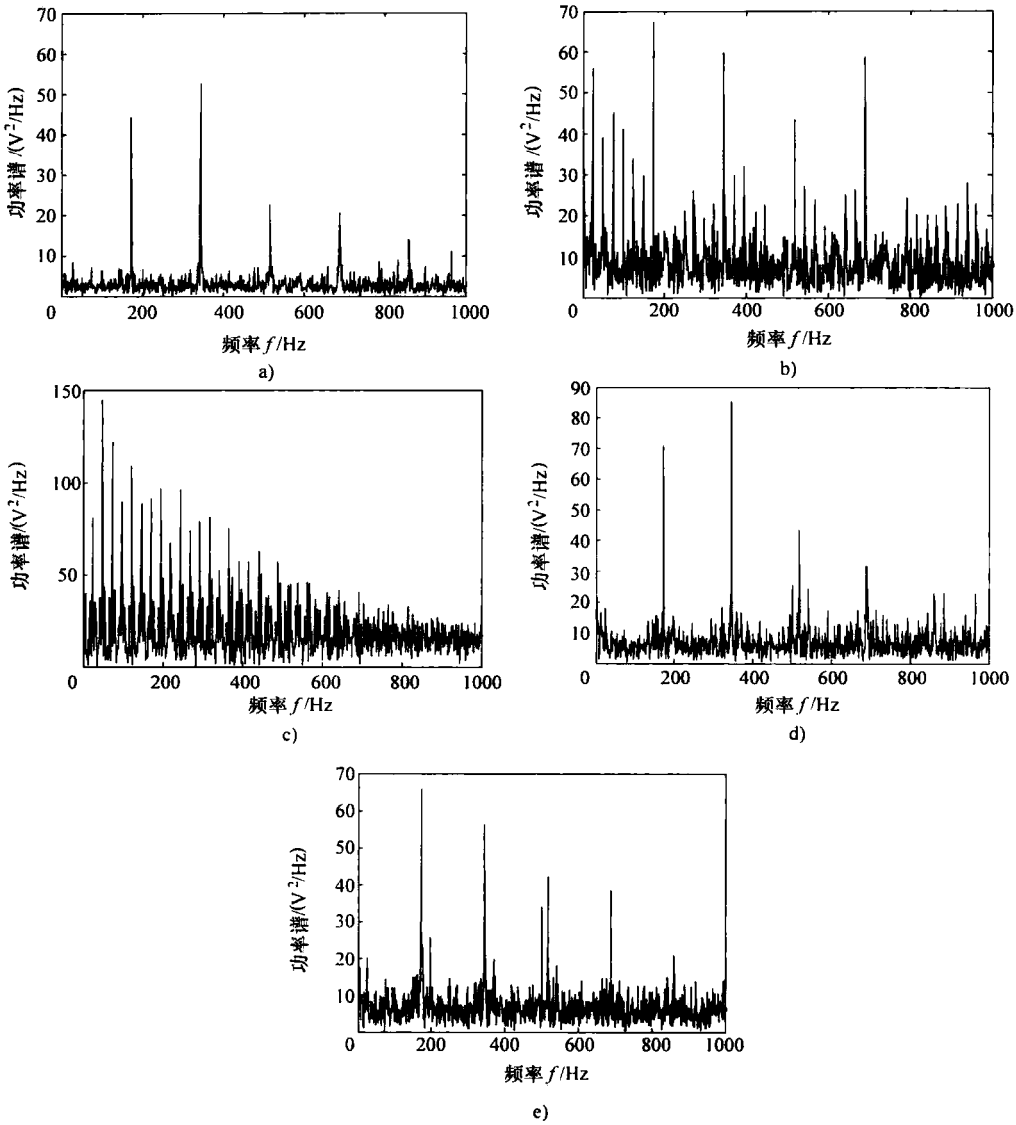

图 11-33　包络信号的功率谱

a）正常状态　b）中心弹簧失效故障　c）脱靴故障　d）滑靴磨损故障　e）松靴故障

综上所述，主元分析方法对中心弹簧失效和脱靴故障能有效地进行检测和分析故障的特征变化。而对于滑靴磨损和松靴故障则无能为力。

参 考 文 献

[1] 陈长征，杨璐．基于小波分析技术的通风机振动故障诊断研究［J］．风机技术，1999（6）：

34-36.

[2] 诸葛起，路甬祥．用振动信号检测柱塞泵松靴故障［J］．振动、测试与诊断，1989，9（3）：11-15.

[3] Potamianos Alexandros，Maragos Petros. Comparison of the energy operator and the Hilbert transform approach to signal and speech demodulation［J］. Signal Processing，1994，37（1）：95-120.

[4] Liu Hui，Liu Guohai，Shen Yue. Novel method for non-integer harmonics measurement using Hilbert vibration decomposition［J］. High Voltage Engineering，2009，35（7）：1758-1764.

[5] 成大先．机械设计手册：弹簧·起重运输件·五金件［M］．北京：化学工业出版社，2004.

[6] 韩捷，张瑞林．旋转机械故障机理及诊断技术［M］．北京：机械工业出版社，1997.

[7] 李宏坤，鞠培刚，张志新，等．基于小波包频带能量分布的往复机故障诊断方法研究[J]．机械工程师，2008（3）：35-37.

[8] Kourti T，MacGregor J F. Multivariate SPC methods for process and product monitoring［J］. J Qual Technol，1996，28：409.

[9] Jackson J E. A User's Guide to Principle Components［M］. New York：Wiley-Inter-Science，1991.

[10] Dasarathy B V. Sensor fusion potential exploitation-innovative architecture and illustrative application［C］// Proceedings of the IEEE，1997，85（1）：24-38.

[11] 滕召胜，罗隆福，童调生．智能检测系统与数据融合［M］．北京：机械工业出版社，2000.

[12] 牛慧峰．免疫机理与支持向量机复合的故障诊断理论及试验研究［D］．秦皇岛：燕山大学，2009：15-97.

[13] 刘思远．信息融合和贝叶斯网络集成的故障诊断理论方法及实验研究［D］．秦皇岛：燕山大学，2010：16-118.

[14] 姜万录，吴胜强，刘思远．指数加权动态核主元分析法及其在故障诊断中应用［J］．机械工程学报，2011，47（3）：63-68.

[15] 姜万录，刘思远．幅值域无量纲指标对液压泵故障敏感性的实验研究［J］．燕山大学学报，2010，34（5）：383-389.

[16] 姜万录，张淑清，王益群．基于混沌和小波的故障信息诊断［M］．北京：国防工业出版社，2005.

[17] 姜万录，宋丽娜，杨少辉，等．小波包络新方法在液压泵故障诊断中的应用［J］．测控技术，2008，27（8）：24-27.

第 12 章　免疫机理与支持向量机复合的故障诊断方法

本章阐述人工免疫系统和支持向量机的基本原理，对免疫机理的实值阴性选择算法以及支持向量机分类方法进行了系统的研究。为解决智能故障诊断领域典型故障样本严重不足及诊断知识发现困难的问题，提出了免疫支持向量机复合的故障诊断方法。通过液压泵多故障模式的诊断实验验证了此方法在提高故障诊断确诊率方面的独特优势。

12.1　人工免疫机理

本节阐述人工免疫学习机理，重点研究阴性选择机理及其算法实现，以及各种改进算法。

12.1.1　生物免疫系统

生物免疫系统是一个复杂的自适应系统，可保护人体不受外部病原体侵害，并把体内所有的细胞或分子分成两类——属于自己的种类（自体细胞）或属于外部来源的非自体种类。人体的免疫系统最为复杂，它由免疫效应分子、有关的基因及具有免疫功能的细胞、组织、器官等组成，可以保护肌体，抗拒病原体和有害异物等致病因素的侵害。免疫系统的主要功能是：免疫防御、免疫稳定和免疫监督，其基本元素包括吞噬细胞、淋巴细胞及抗体，抗体识别特定抗原并清除抗原。生物系统具有大量发达的抗体系统，能够处理不断变化的环境。

12.1.2　人工免疫系统的阴性选择算法

计算机的安全问题与生物免疫系统所遇到的问题具有惊人的相似性，两者都要在不断变化的环境中维持系统的稳定性。生物免疫系统分布的、灵活的、自适应和鲁棒的解决问题方式，正是计算机安全领域所期望得到的。Forrest 等根据免疫系统的自己/非己的区别原则，研究了一种检测计算机环境变化的阴性选择算法。该算法与 T 细胞成熟过程中经历的“阴性选择”过程有着相似的原理：随机产生检测器，删除那些能检测到自己的检测器，以使那些能检测到非己的检测器保留下来。算法简述如下：

1）定义自己为需要被保护或检测的有限串集合 S，其中的串可以是程序、数

据文件及正常模式等。

2）产生一个检测器的集合 R，每一个都不能与 S 集合中的任一元素相匹配。采用部分匹配的原则，而不是精确或完美匹配，即 2 个串至少在 r 个位置上能区分出来，这里 r 是可选择的参数。

3）监视，即不断地将检测器 R 与受监视集合 S 进行匹配，一旦发生匹配，就表示已发生一个变化，检测器是按照不能与 S 中的任一串相匹配设计的。

阴性选择算法为免疫机理在计算机网络安全领域的应用奠定了理论基础。近年来，随着计算机网络的飞速发展，安全问题也从简单的计算机病毒检测，扩展到基于主机的入侵检测和网络安全，这些都可以从免疫系统的信息处理机制中获得启示。

目前，在应用免疫机制的一些故障检测方法中，基于阴性选择（Negative Selection，NS）机理的阴性选择算法应用最为广泛。

1. 免疫系统的阴性选择机理

免疫系统是生物，特别是脊椎动物和人类所必备的防御机理，它由具有免疫功能的器官、组织、细胞、免疫效应分子及有关的基因等组成，可以保护肌体（自己）防御病原体、有害的异物以及癌细胞等致病因子（非己）的侵害。所以免疫系统的实质是生物体内的在线自主异常检测及健康监控系统。对于脊椎动物，骨髓是最为重要的免疫器官之一，是“多能干细胞”的发源地，这些干细胞最终分化成具有不同功能的免疫细胞。在免疫细胞中，主要有 B 和 T 两类淋巴细胞，它们产生于骨髓的干细胞，分布于全身，在免疫系统中起着重要作用。

由骨髓产生的 T 细胞需要进入胸腺进行检查，T 细胞来自于胸腺（Thymus）英文的第一个字母。在胚胎阶段，由骨髓中的一部分干细胞发展成的 T 祖细胞，迁移到另一中枢免疫器官——胸腺，在胸腺皮质区发育成为 T 前体细胞，并继续分化发育为 T 细胞。每个要成为 T 细胞的 T 前体细胞，必须经过与遗传有关的主要组织相容性复合物（Major Histocompatibility Complex，MHC）的“检查”。每个人都有自己独特的 MHC，MHC 具有多样性，可以说它是肌体在生理上的身份证。MHC 是与细胞染色体紧密联系的基因群，其中包含有控制免疫反应或免疫应答的基因。

T 细胞的成熟需要经历一个重要的阴性选择过程：当未成熟 T 细胞表面的检测器能够识别 MHC 分子和自己抗体片断（又称肽）的复合物时，未成熟 T 细胞会发生凋亡（凋亡是指由基因负责调节控制的细胞主动死亡或自杀的过程），即对自己组织有反应的不成熟 T 细胞发生凋亡；那些不能识别 MHC 分子和自己抗体片断复合物的未成熟 T 细胞，则存活和增殖，完成了 T 细胞的选择和成熟过程。随后，这些成熟的 T 细胞在体内进行循环，它能检测出任何非己物质，执行免疫功能，保护肌体免受抗原的侵袭。

经过阴性选择后，T 细胞的检测器能够准确识别非己，这被称为免疫系统的自己/非己识别。免疫系统能够通过对自己的学习，对非己产生记忆，并通过有限数量的检测器，能够准确识别和杀伤无限数量的非己，体现了免疫系统独特的智能机理和极具鲁棒性的处理问题方法。

2. 阴性选择算法原理

受免疫系统自己/非己识别机理的启发，Forrest 等提出了用于异常检测的编码阴性选择算法。阴性选择算法模拟了免疫细胞的成熟过程，经历耐受的检测器模拟成熟的免疫细胞。当给定一个特定问题时，算法可以具体描述为两个阶段：耐受和检测。耐受阶段主要负责产生成熟的检测器；检测阶段，检测器对受保护的系统进行检测，以发现变化。该算法与免疫系统的阴性选择过程类似，通过随机产生检测器，并删除那些能检测出自己的检测器，以便使保留的检测器能检测出任何非己。

（1）耐受过程　根据生物免疫系统的阴性选择机理，产生有效检测器集合，记为 D。有效检测器集合产生的过程为：首先随机产生大量的候选检测器，再把其中不与自己集 S 中的任何一个样本相匹配的候选检测器设置为有效检测器，而发生了匹配的候选检测器将被清除掉。由此而产生的集合 D 中的元素不会与集合 S 中任何元素发生匹配，即 D 与 S 互补，这一过程模拟了 T 细胞在胸腺的检查过程。有效检测器产生过程如图 12-1 所示。

（2）检测过程　检测器集产生以后，即可用来检测“自己”集合是否发生变化。如图 12-2 所示，将待检测样本与检测器集合中各元素进行比较，如果出现匹配，则证明“自己”集合中元素发生了变化。这个过程模拟了生物免疫系统 T 细胞的非己识别过程。

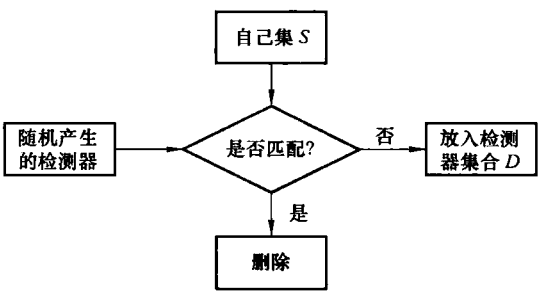

图 12-1　产生有效检测器的过程

根据检测器的表示方式，可以把现有的阴性选择算法分为两类：编码阴性选择算法与实值阴性选择算法。顾名思义，编码阴性选择算法就是把数据样本映射成二进制数字串或其他数字字符串，每个检测器和自己样本都用这些数字串表示；而实值阴性选择算法中，每个检测器和自己样本则直接使用实数值来表示。由于对检测器和自己表示方法的不同，导致匹配规则的不同，从而使得两种算法之间在细节上

产生很大的差别。

3. 编码二进制阴性选择算法

Forrest 提出的阴性选择算法中，最早使用二进制编码方式表示检测器与自己样本，而且在计算机系统的病毒检测中成功应用。二进制编码方式使用二进制串来表示检测器集和自己样本。检测器是一些简单的、固定长度的二进制字符串。通过一个简单的规则来比较两个字符串，判断是否发生了匹配。

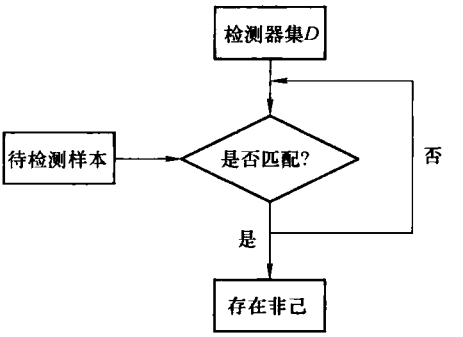

图 12-2 异常检测过程

在检测器产生阶段，匹配规则用于判断检测器是否合格；在进行异常检测阶段，匹配规则用于识别是否有异常变化发生。可见匹配规则是阴性选择算法的关键部分，下面对二进制匹配规则进行说明。

（1）匹配规则 匹配分为完全匹配和部分匹配，如果两个相等长度字符串的每个对应位上的字符都相等，这样的匹配称为完全匹配。然而，在生物免疫系统中，抗体与抗原结合时，更多地表现出不完全匹配特性，完全匹配只是其中的一个特例，因此人们更关心部分匹配规则。有许多部分匹配规则，如海明（Hamming）规则、连续 r 位的匹配（R Continuous Bits，RCB）规则和 r-chunk（RCH）规则等。

海明规则：是通过设定阈值大小，来确定两字符串是否发生匹配。当两字符串之间的海明距离小于等于阈值时，称这两个串是匹配的，反之则不匹配。

连续 r 位的匹配规则：需要根据连续匹配的位数来确定两个字符串是否匹配。当连续匹配的位数大于等于 r 值时，认为两串匹配，否则不匹配。

这两种匹配都是部分匹配，规则中的阈值或 r 值，类似于生物免疫系统中免疫细胞的激活门限。每一个淋巴细胞表面都有许多相同的受体，当有足够多的受体被抗原结合，即细胞表面结合的抗原数量超过某个值时，该免疫细胞被激活，这个值就是免疫细胞的激活门限。在连续 r 位的匹配规则中，r 表示当检测器（受体）与“非己”字符串（抗原）至少有 r 个对应位取值相同，才能检测出“非己”字符串。连续 r 位的部分匹配规则，似乎更接近于生物免疫系统的匹配过程和特性。如果一个检测器能够检测到的“非己”字符串数目越多，则它的专一性越差，反之，一个检测器能够检测到的“非己”字符串数目越少，则其专一性越强。例如当 $r = l$（l 为字符串长度）时，检测器只能检测到一个“非己”字符串，它的专一性最强。在检测器产生算法中，利用连续 r 位的匹配规则，可实现以较小的检测器集合，检测到较大的范围的“非己”行为。

RCH 检测规则：字符串长度相等，要求 X 与 Y 从任意位置开始的连续 r 位相

同即可。如果对 r 连续位子串的起始位置进行限定，要求 X 与 Y 从相同位置开始的连续 r 位相同，就得到另外的一种匹配规则，称为 RCH 规则。

吴作顺等人曾对这三种匹配规则进行了仿真实验，通过计算匹配值的分布情况以及计算平均信噪比（Signal-to-Noise Ratio，SNR）来比较。信噪比描述了匹配规则准确地将信号从其他非匹配信号（噪声）中识别出来的能力。如图 12-3 所示，给出三种规则的 SNR 值。

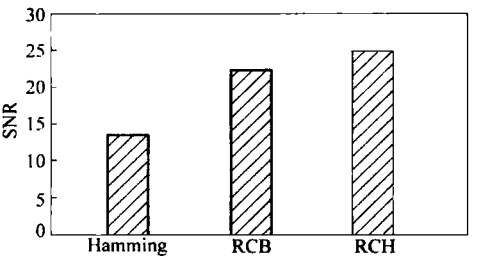

图 12-3　三种匹配规则信噪比

（2）孔洞分析　针对编码阴性选择算法中的孔洞作以下几点说明：

①“孔洞”的多少与匹配长度相关。如果减小 r，每个检测器将匹配更多的串，这意味着所需要的检测器数量减少。同时，每个“自己”集合的字符串也将匹配更多的检测器，从而使“孔洞”的数量增加。极限情况下，如果 $r=0$，则产生的有效检测器个数为 0，所有的“非己”元素都是“孔洞”。反之，如果 $r=l$（l 为字符串长度），则每个检测器仅匹配唯一的一个“非己”字符串（即与其自身相同），此时不存在“孔洞”，但所需要的检测器数量巨大。

②“孔洞”的数量与“自己”集合中字符串的相似程度（即“自己”的结构）相关。在实际中，“自己”集合中的字符串不是随机分布的，这就意味着它们有可能出现堆积或重叠，存在一定的相似性。当“自己”集合中字符串的相似性增加时，如果不改变匹配长度 r，则产生“孔洞”的概率可能会增加。

③“孔洞”是通过许多“自己”字符串之间的相互作用而产生的，在自己/非己状态空间中，“孔洞”更趋于靠近“自己”字符串，它们不易被检测到，可以利用“孔洞”效应实现某种程度的抗噪声干扰。

（3）编码阴性选择算法的局限性　尽管编码阴性选择算法已经成功地应用于一些领域，但是编码二进制表示方法仍存在一些不足，阻碍了其更广泛的应用，具体如下：

① 编码二进制阴性选择算法在一些复杂的自己/非己空间的定义方面存在不足。这主要是由于其编码方式本身和匹配规则决定了其很难表示复杂的检测空间。

② 二进制编码检测器和连续 r 位的匹配规则缺乏实际物理意义，导致知识表达能力差。在实际的异常检测过程中，r 位的匹配不能较好地反映出各检测点的变化。即使检测出有异常发生，也很难分析产生异常的原因。

③ 难以实现数据融合。因为在其他一些免疫算法以及智能算法中，数据样本都是高维数据表示形式，所以很难把一个低维数据表示的阴性选择算法与其他一些高维表示的智能算法融合应用。

④ 该方法能检测正常数据以外的任何微小异常现象，无法设定阈值。

⑤ 正常和异常存在明显的不同。这就把空间分成两个子集：自己（正常）和非己（异常）。如果一个元素与一个检测器匹配，则其所在的空间就是异常的。然而，在实际应用中，异常并不是一个绝对的概念。一种自然的表示自己空间的方式是定义异常度。

4. 实值阴性选择算法

针对编码阴性选择算法的不足，发展出了实值阴性选择（Real-valued Negative Selection，RNS）算法，检测器用向量表示，扩大了阴性选择算法的应用范围。与编码二进制阴性选择算法一样，整个检测过程包括：数据的预处理、检测器的产生和异常检测三个部分。

RNS 算法简单阐述为：把自己/非己空间作为 $\boldsymbol{R}^n$ 的一个子集，可以归一化为空间 $[0, 1]^n$。检测器（非己）由一个 n 维向量和一个实数构成，用 n 维向量表示其中心，实数表示对应的半径。因此，检测器可以看作 $\boldsymbol{R}^n$ 空间内的一个超球。匹配规则由检测器与自己间的欧氏（Euclidean）距离和检测半径组成。算法的输入是自己样本 $\boldsymbol{S}$（表示为 n 维向量的点），通过算法产生检测器 $\boldsymbol{d}$ 让它覆盖非己空间。

检测器具有只与非己空间匹配、不与自己空间匹配的特性。向量检测器具有与自己向量相同的维数，但其分布在非己空间内，向量检测器 $\boldsymbol{d}$ 需满足以下不等式：

$$E(\boldsymbol{d}, \boldsymbol{S}) > r \qquad (12\text{-}1)$$

其中，$E(\cdot)$ 是 $\boldsymbol{d}$ 与 $\boldsymbol{S}$ 的欧氏距离；$\boldsymbol{S}$ 是自己空间的任意样本向量；r 是阈值。

标准实值阴性选择算法产生检测器的流程如图 12-4所示。

算法的输入参数为：自己样本集 $\boldsymbol{S}$、预期的检测器数量 m、自己半径 r_s 和检测半径 r_d。这 4 个参数设定的好坏，对整个算法的效果会产生很大的影响。所以需要根据实际的应用来对每个参数进行设定。而其中，对于 m 的设定又相对更复杂一些，因为需要根据非己空间的大小，对需要的检测器数量进行估计。

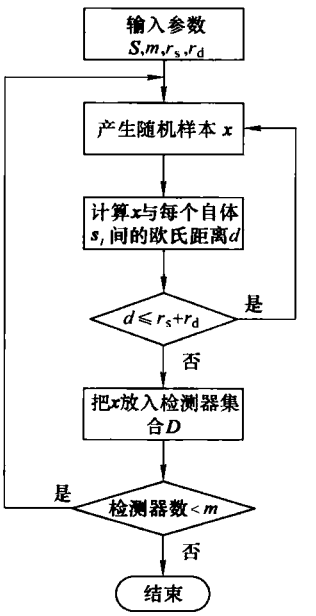

图 12-4 标准实值阴性选择算法产生检测器的流程

最后是检测过程，成熟检测器不断地检测新的测试数据集样本。因为成熟检测器不与任何一个自己（正常）样本相匹配，所以如果测试样本模式中的点与任何一个检测器的中心

的距离小于它们半径之和，则相应检测器被激活，意味着有可能出现了故障。

5. 可变半径检测器的实值阴性选择算法

图 12-5 直观地表示了二维检测空间的实值检测器与自己集。图中，阴影部分为自己空间（正常数据集），阴影部分以外的区域为非己空间。白色圆球为检测器所表示的区域（二维的超球面），它们覆盖了非己空间，检测器没有覆盖到的非己空间为“孔洞”。

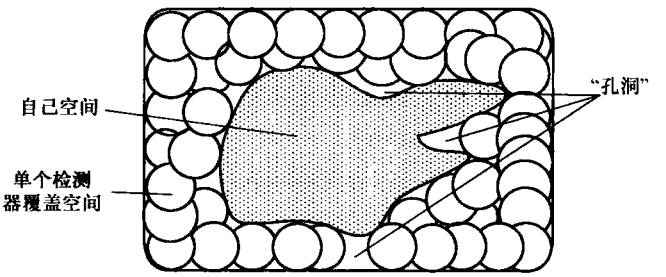

图 12-5　自己和固定半径检测器对检测空间的覆盖示意图

通过对图 12-5 研究我们可以发现，在右下角的一片非己区域，其实可以通过一个半径更大的检测器来代替。而对于孔洞来说，是由于检测器的半径限制，导致很多孔洞的产生。要覆盖这些孔洞，只能把检测器的半径减小，这样的话又会导致要覆盖相同区域的非己空间需要更多的检测器。所以只能通过对两个指标的折中来对参数进行调整。由于算法把检测器的数量作为输入参数，因此必须预先估计检测器对非己空间的覆盖，考虑到检测器之间还有相互覆盖的情况，这些估计是很难令人满意的。

针对以上的一些缺点，人们又提出了可变半径检测器的实值阴性选择算法。而之前的实值阴性选择算法则可以称为固定半径检测器的实值阴性选择算法。

可变半径检测器的阴性选择算法中的检测器的半径需要经过计算才能得到，它的计算过程是：如果随机生成的点不在自己空间和已有检测器覆盖空间内，则说明产生的是一个有效的检测器，并且把该检测器与其最近的自己样

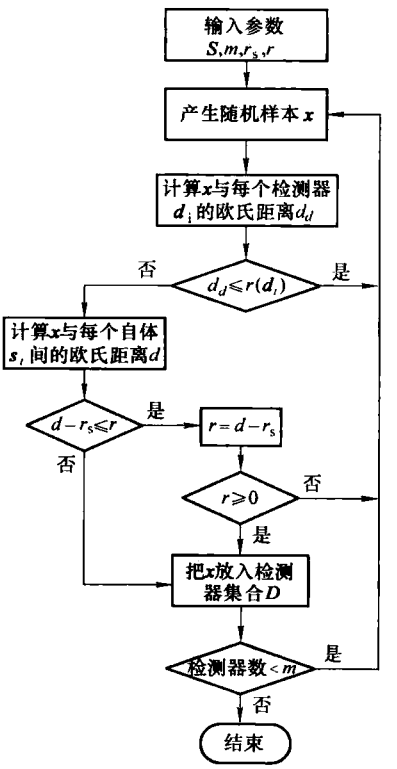

图 12-6　可变半径检测器的实值阴性选择算法的检测器产生过程

本的距离减去自己半径 r_s 的差，设置为该检测器的半径。

可变半径检测器的实值阴性选择算法的检测器产生过程如图 12-6 所示。自己和可变半径的检测器对检测空间的覆盖的情况如图 12-7 所示，通过与图 12-5 自己和固定半径检测器对空间覆盖的情况进行比较可以发现，要覆盖差不多大小的非己空间，需要更多的固定半径检测器来覆盖。而且因为可以产生很小半径的检测器，所以可变半径检测器在减少孔洞方面具有很大的优势。

通过对两种不同检测器半径表示的实值阴性选择算法进行比较，可以总结出可变半径检测器相对于固定半径检测器所具有的优点：

1）通过使用更少数量的检测器来节省产生检测器和检测新样本所需要的时间，也节省了存储检测器所需要的空间。

2）孔洞更容易覆盖，并且用较少的检测器就能覆盖很大的非己区域。

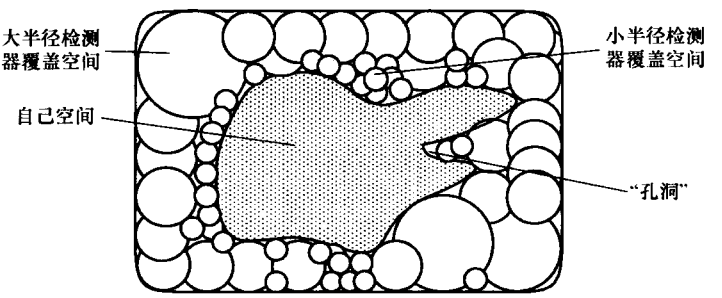

图 12-7 自己和可变半径检测器对检测空间的覆盖情况

12.2 支持向量机

本节将对支持向量机的基本原理及特点进行较为详尽的阐述，并对支持向量机的部分核函数参数选择进行研究。由于样本缺乏一直是困扰液压系统故障诊断的难点之一，而支持向量机对解决小样本模式分类问题有独特优势，所以将支持向量机引入液压系统故障诊断领域中，并详细阐述诊断的基本步骤，编写支持向量机应用软件。最后，用支持向量机方法对轴向柱塞泵松靴故障进行诊断，验证其有效性。

12.2.1 支持向量机的基本原理

支持向量机（Support Vector Machine，SVM）方法是从两类模式识别问题中线性可分情况下的最优分类面提出的。其基本思想可用图 12-8 的两维情况说明。图中，圆圈和方块代表两类样本，H 为分类线，H_1，H_2 分别为过各类中离分类线最近的样本且平行于分类线的直线，它们之间的距离称为分类间隔（margin）。所谓

最优分类线就是要求分类线不但能将两类正确分开（训练错误率为 0），而且使分类间隔最大。前者是保证经验风险最小，而后者实际上就是使推广性的界中的置信范围最小，从而使真实风险最小。推广到高维空间，最优分类线就成为最优分类面。

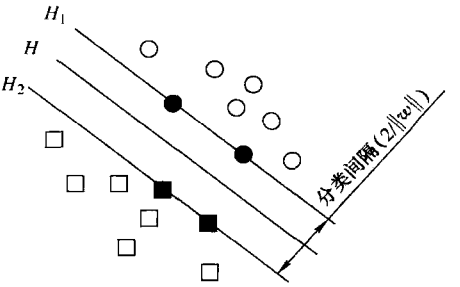

图 12-8　最优分类线示意图

1. 线性可分

线性可分的样本集为 $(\boldsymbol{x}_i, y_i)$，$i=1, 2, \cdots, n$，$\boldsymbol{x} \in R^d$，$y_i \in \{+1, -1\}$是类别标号。d 维空间中线性判别函数的一般形式为 $g(\boldsymbol{x}) = \boldsymbol{w} \cdot \boldsymbol{x} + b$，分类面方程为

$$\boldsymbol{w} \cdot \boldsymbol{x} + b = 0 \tag{12-2}$$

对判别函数进行归一化，使两类中离分类面最近的样本的 $|g(\boldsymbol{x})| = 1$，这样分类间隔就等于 $2/\|\boldsymbol{w}\|$，因此使间隔最大就是使 $\|\boldsymbol{w}\|$（或 $\|\boldsymbol{w}\|^2$）最小；要求分类线对所有样本正确分类，就是要求它满足

$$y_i(\boldsymbol{w} \cdot \boldsymbol{x}_i + b) - 1 \geqslant 0 \quad i = 1, 2, \cdots, n \tag{12-3}$$

使式（12-3）等式成立即位于超平面 H_1，H_2 上的样本（涂黑）称为支持向量（Support Vectors）。

这样最优分类面问题就可以表示为式（12-3）的约束下求函数

$$\phi(\boldsymbol{w}) = \frac{1}{2}\|\boldsymbol{w}\|^2 = \frac{1}{2}(\boldsymbol{w} \cdot \boldsymbol{w}) \tag{12-4}$$

的最小值。为此，可以定义如下的 Lagrange 函数

$$L(\boldsymbol{w}, b, a) = \frac{1}{2}(\boldsymbol{w} \cdot \boldsymbol{w}) - \sum_{i=1}^{n} a_i \{y_i[(\boldsymbol{w} \cdot \boldsymbol{x}_i) + b] - 1\} \tag{12-5}$$

其中，$a_i > 0$ 为 Lagrange 乘子。问题是对 $\boldsymbol{w}$ 和 b 求 Lagrange 函数的极小值。把这个问题转化为如下的对偶问题：即在约束条件

$$\sum_{i=1}^{n} y_i a_i = 0 \quad a_i \geqslant 0, \ i = 1, \cdots, n \tag{12-6}$$

之下对 a_i 求下列函数的最大值

$$Q(a) = \sum_{i=1}^{n} a_i - \frac{1}{2}\sum_{i,j=1}^{n} a_i a_j y_i y_j (\boldsymbol{x}_i \cdot \boldsymbol{x}_j) \tag{12-7}$$

这是一个不等式约束下二次函数极值问题，存在唯一解 a_i^*。且根据约束最优化问题的 KKT（Karush-Kuhn-Tucker）条件可知上述问题的解须满足

$$a_i[y_i(\boldsymbol{w} \cdot \boldsymbol{x}_i) + b] - 1 = 0 \quad i = 1, 2, \cdots, n \tag{12-8}$$

即大多数样本对应的 a_i^* 将为零，只有支持向量对应的 a_i^* 不为零。求解上述问题

得到的最优分类函数为

$$F(x) = \text{sign}\{(\boldsymbol{w}^* \cdot \boldsymbol{x}) + b^*\} = \text{sign}\left\{\sum_{i=1}^{n} a_i^* y_i (\boldsymbol{x}_i \cdot \boldsymbol{x}) + b^*\right\} \quad (12\text{-}9)$$

其中，sign 为符号函数。由于非支持向量对应的 a_i^* 均为零，因此式（12-9）中求和实际上只是对支持向量进行。而 b^* 为分类的阈值，可由任意一个支持向量用式（12-3）等号成立求得，或者通过两类中任意一对支持向量取平均值得到。

2. 线性不可分

在线性不可分的情况下，可以在条件式（12-3）中加入一个松弛变量 $\xi_i \geqslant 0$，变成

$$y_i[(\boldsymbol{w} \cdot \boldsymbol{x}_i) + b] - 1 + \xi_i \geqslant 0 \quad i = 1, 2, \cdots, n \quad (12\text{-}10)$$

将目标改为使

$$\phi(\boldsymbol{w}, \xi) = \frac{1}{2}(\boldsymbol{w} \cdot \boldsymbol{w}) + C\left(\sum_{i=1}^{n} \xi_i\right) \quad (12\text{-}11)$$

最小。即折中考虑分类误差和最大分类间隔，就得到广义最优分类面。其中，$C > 0$为一个常数，用来控制分类误差与推广性能的折中。用与求解最优分类面时同样的方法求解这一优化问题，同样得到一个二次函数极值问题，其结果与可分情况下得到的式（12-6）~式（12-9）几乎完全相同，只是约束条件式（12-6）中的 a_i 应满足

$$\sum_{i=1}^{n} y_i a_i = 0, \text{和} 0 \leqslant a_i \leqslant C \quad i = 1, \cdots, n \quad (12\text{-}12)$$

3. 非线性情况

在模式识别时，对于非线性可分的样本分类问题，一种很自然的方法就是通过非线性变换方法（形式如 $z = \varphi(x)$）把原来的低维特征空间映射到高维空间，使得在高维空间样本是可分的，因此可用线性判别函数实现分类。但是这往往是以牺牲计算量为代价的，当映射后的空间维数很高时，在实际上是不可实现的。

当要解决高维特征空间的广义分类问题时，也只需知道高维空间的内积运算即可，根本不需要知道把低维空间映射到高维空间的具体变换形式。并且只要变换空间的内积运算可以用原空间中的变量直接计算，则即使变换空间的维数增加很多，在其中求解最优分类面的问题也不会增加多少计算复杂度。

定理 12.1（Mercer 条件） 对于任意的对称函数 $K(\boldsymbol{x}, \boldsymbol{x}')$，它是某个特征空间中的内积运算的充分必要条件是，对于任意的 $\varphi(\boldsymbol{x}) \neq 0$ 且 $\int \varphi^2(\boldsymbol{x}) \mathrm{d}\boldsymbol{x} < \infty$，有

$$\iint K(\boldsymbol{x}, \boldsymbol{x}') \varphi(\boldsymbol{x}) \varphi(\boldsymbol{x}') \mathrm{d}\boldsymbol{x} \mathrm{d}\boldsymbol{x}' > 0 \quad (12\text{-}13)$$

其中 $\boldsymbol{x}'$ 表示特征向量 $\boldsymbol{x}$ 的转置。

统计学习理论指出，根据 Hilbert-Schmidt 原理，如果核函数 $K(\boldsymbol{x}, \boldsymbol{x}')$（或称

内积函数）满足 Mercer 条件，就可以代替最优分类面中的点积，就相对于把原特征空间变换到了某一新的特征空间，而不必进行这种变换。此时式（12-7）的优化函数就变为

$$Q(a) = \sum_{i=1}^{n} a_i - \frac{1}{2}\sum_{i,j=1}^{n} a_i a_j y_i y_j K(\boldsymbol{x}_i, \boldsymbol{x}_j) \tag{12-14}$$

而相应的判别函数式（12-9）也变为

$$F(\boldsymbol{x}) = \text{sign}\left(\sum_{i=1}^{n} a_i^* y_i K(\boldsymbol{x}_i, \boldsymbol{x}) + b^*\right) \tag{12-15}$$

算法的其他条件式（12-12）不变，这就是支持向量机。

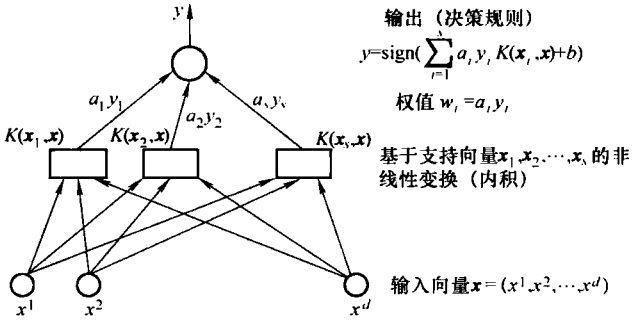

图 12-9　支持向量机示意图

分类问题的求解，依赖于对相似性和相似程度的估价，而在支持向量机中，相似性和相似程度是用内积进行估价的。选择不同的核函数或映射及其相应的 Hilbert 空间，相当于选择不同的内积，意味着采取不同的标准对相似性和相似程度进行估价，改变了样本数据在高维特征空间分布的复杂程度，从而影响了最优分类超平面所能得到的最小经验误差，因而在应用支持向量机时要选择合适的核函数及其参数。支持向量分类机求得的分类函数形式上类似于一个神经网络，其输出是若干中间层节点的线性组合，而每个中间层节点对应于输入样本与一个支持向量的内积，因此也被叫做支持向量网络，如图 12-9 所示，图中的 s 为支持向量的个数，$a_i(i = 1, \cdots, s)$ 是通过求式（12-14）最大值得到的。

12.2.2　支持向量机的特点

支持向量机有以下几个显著的特点：

1）支持向量机以统计学习理论为基础，以结构风险最小化为归纳原则，是寻求经验风险和置信范围之和最小的学习机器。从而更好地适应小样本情况，得到现有信息条件下的最优解，而不仅仅是样本趋于无穷大时的最优解。

2）算法最终转化为一个二次寻优问题，从理论上讲，得到的将是全局最优

解，克服了其他方法所无法避免的易陷入局部极值的问题。

3）利用支持向量机解决非线性分类问题时，巧妙地解决了维数问题，其算法复杂度与样本维数无关，也就是映射后的特征空间维数可以很高，但是这并不增加网络的复杂性。我们知道在 q 维空间中的线性判别函数的 VC 维是 $q+1$。但是如果所有 n 个样本都在一个超球体范围内（这可通过样本归一化等方法很容易地实现），即样本集为

$$\boldsymbol{X}=\{\boldsymbol{x}_1,\boldsymbol{x}_2,\cdots,\boldsymbol{x}_n\},\quad |\boldsymbol{x}_i-\boldsymbol{v}|\leqslant R \tag{12-16}$$

其中 $\boldsymbol{v}$ 为包含所有样本在内的最小超球的中心。则满足 $\|\boldsymbol{w}\|^2\leqslant c$ 的规范化超平面形成的分类面的 VC 维满足下面的界：

$$h\leqslant\min([R^2c],q)+1 \tag{12-17}$$

可见利用支持向量机的方法，即使在维数很高的空间中也能得到较小 VC 维的函数集，从而得到较好的推广能力。

4）支持向量机的推广性与变换空间的维数无关，从而避免了过拟合现象。如果一组训练样本能够被一个最优分类面或广义最优分类面分开，就对于测试样本分类错误率的期望的上界是

$$E(\text{error})\leqslant\frac{E[\text{支持向量数}]}{\text{训练样本总数}-1} \tag{12-18}$$

可见，只要能够适当地选择一种内积定义，构造一个支持向量数相对较少的最优或广义最优分类面，就可以得到较好的推广性。

5）采用不同的核函数，构成不同的支持向量机算法，将实际问题通过非线性变换映射到高维特征空间，并在其中构造线性判别函数来实现原空间中的非线性判别函数。因此支持向量机可以将神经网络等学习机器纳入其中。目前采用的内积函数形式主要有三类，它们都与已有的方法有对应关系。

第一类，如果采用多项式型内积函数，称其为 d 阶多项式（Polynomial）核函数，即

$$K(\boldsymbol{x}_i,\boldsymbol{x})=[(\boldsymbol{x}_i\cdot\boldsymbol{x})+1]^d \tag{12-19}$$

此时得到的支持向量机为一个 d 阶多项式分类机。

第二类，如果采用高斯函数型内积函数，称其为径向基（RBF）核函数，即

$$K(\boldsymbol{x}_i,\boldsymbol{x})=\exp\left\{-\frac{|\boldsymbol{x}_i-\boldsymbol{x}|}{\sigma^2}\right\} \tag{12-20}$$

得到的支持向量机为一种径向基函数分类机。它与传统径向基函数方法的基本区别是，每一个基函数的中心对应于一个支持向量，它们及输出权值都是由算法自动确定的。

第三类，如果采用 S 型函数作为内积函数，称为双曲正切（Sigmoid）核函数，即

$$K(\boldsymbol{x}_i,\boldsymbol{x}) = \tanh[v(\boldsymbol{x}_i \cdot \boldsymbol{x}) + c] \tag{12-21}$$

则支持向量机实现的是一个两层感知器神经网络，只是这里不仅网络的权值，还有网络的隐层节点数目也是由算法自动确定的。但是 S 型函数并不是都满足 Mercer 条件，只有对于特殊的 v 和 c 它才可以作为核函数。因此采用双曲正切核函数时，其参数须慎重选取。

12.2.3　基于支持向量机故障诊断的基本步骤

在支持向量机技术的运用中，支持向量分类机的训练是至关重要的，按训练算法中利用工作集的大小以及它们被提出的时间顺序可将其分为以下三类：

1）Vapnik 等人首先提出的 Chunking 算法。

2）Osuna 等人提出的分解算法（Decomposition Algorithm）。

3）Platt 等提出的序贯最小优化（Sequential Minimal Optimization，SMO）算法。

当前应用于支持向量机训练较多的软件包主要是以台湾大学的林智仁编制的 libsvm 和美国康奈尔大学的 Thorsten Joachims 开发的软件包 $\text{SVM}^{\text{light}}$。

根据支持向量机的基本原理和算法，并结合设备故障诊断的特点，一般情况下，基于支持向量机的故障诊断分为两个阶段：首先是训练阶段，也就是通过已知的正常状态和故障状态的各种特征样本对支持向量机进行训练，找到训练样本的支持向量，从而确定最优分类超平面；其次是故障诊断阶段，也就是装入训练阶段的有关数据，根据最优分类超平面，对测试样本集做出分类决策。

训练阶段的具体步骤如下：

1）通过已知的正常状态和故障状态下的特征数据样本建立训练样本集 $\{\boldsymbol{x}_i, y_i\}$。

2）根据 Mercer 定理，选择合适的核函数 $K(\boldsymbol{x}_i, \boldsymbol{x})$ 及核参数，并根据核函数的要求，对样本进行规范化。

3）在约束条件式（12-12）下最大化式（12-14），以求取 Lagrange 系数 a_i。

4）找出支持向量 SV，通过式（12-3）求出阈值 b。

5）建立训练数据样本的最优分类超平面，训练结束。

故障诊断阶段的具体步骤如下：

1）装入支持向量机学习阶段的相关数据，包括训练样本集 $\{\boldsymbol{x}_i, y_i\}$、Lagrange乘子 a_i、阈值 b 和支持向量 SV。

2）利用决策函数式（12-15）计算待测数据样本的指示函数决策输出值，根据输出值做出分类决策。

12.2.4　支持向量机建立及分析

1. 支持向量机建立

在 Matlab 环境下，运用 Matlab 图形用户界面 GUI 制作了一个两类问题的支持

向量分类机应用软件。其主要功能包括完成支持向量分类机的训练和决策，从而完成支持向量机的建立；能够完成对于已训练支持向量分类机的测试；对于多项式核函数的阶次 d、径向基核函数参数 σ 及双曲正切核函数参数 v 的取值与训练分类精度关系的分析，有利于核函数参数的选择。此软件界面如图 12-10 所示。

在训练过程中，此软件能够将支持向量的个数、占训练样本的比例、训练时间以及训练获得的 Lagrange 乘子 a_i 及阈值 b 显示出来。在测试过程中，能够将测试分类精度及测试时间显示出来。在分析过程中，能够显示多项式核函数的阶次 d、径向基核函数参数 σ 及双曲正切核函数参数 v 与训练分类精度关系曲线。并能应用已训练的支持向量分类机对未知样本进行分类决策。

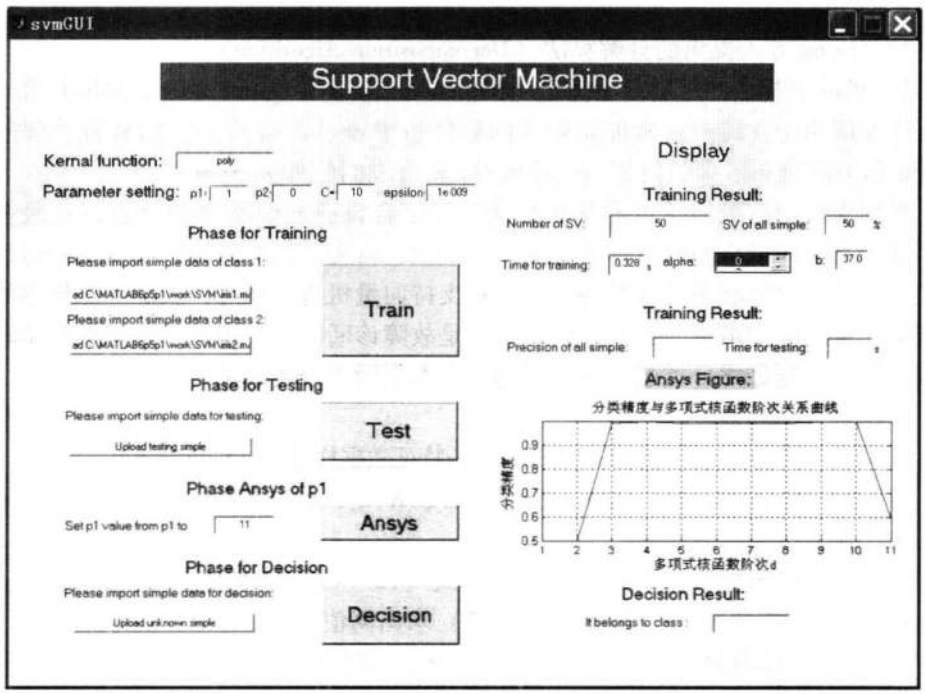

图 12-10 支持向量分类机界面

2. *典型核函数参数选择分析*

鸢尾属植物数据集 Iris 是最常用的机器学习及测试分类机性能的数据集之一，数据集中包含 Iris 的三种不同的类型，分别是 setosa、versicolor 和 virginica。每组数据包含其四个属性分别是：萼片长度、萼片宽度、花瓣长度和花瓣宽度。三种类型的花各有 50 组数据。

将 setosa、versicolor 两种类型的数据各 50 组作为训练样本，从而构成包含 100 组数据的训练集。采用此训练集对核函数为多项式核函数和径向基核函数的支持向

量机进行训练，运用前面编写的支持向量机应用软件对其主要参数进行分析。

（1）多项式核函数参数分析　其主要参数为核函数多项式的阶次 d。在惩罚因子 $C=10$ 的情况下，对支持向量机中多项式核函数阶次 d 在［1，11］的不同取值下，获得训练分类精度与其对应的多项式核函数的阶次 d 之间的关系如图 12-11 所示。由图可知，在低阶次阶段［1，2］的情况下，训练分类精度并不理想，保持在50%；阶次 d 在［3，10］时，训练分类精度相对较好，达到99%，并在很小的范围内有所波动；阶次 d 在 10 之后，其对应的训练分类精度迅速下降，训练分类精度始终维持在50%以上。

因而，选用多项式核函数构造支持向量分类机时，考虑到计算的复杂程度以及资源的占用情况，一般选择 3～5 阶多项式核函数。

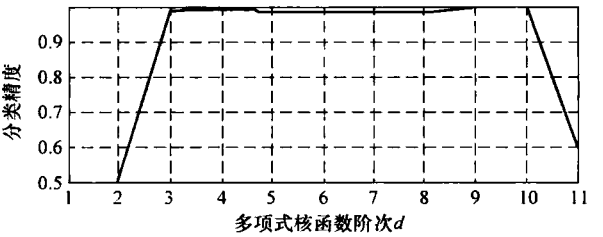

图 12-11　训练分类精度与 d 的关系

（2）径向基核函数参数分析　径向基核函数其主要参数为 σ。在设定惩罚因子 C 为 10 的情况下，对支持向量机中径向基核函数参数 σ 在区间［0.1，5］的不同取值下，获得训练分类精度与其对应的径向基核函数参数 σ 之间的关系，如图 12-12 所示。

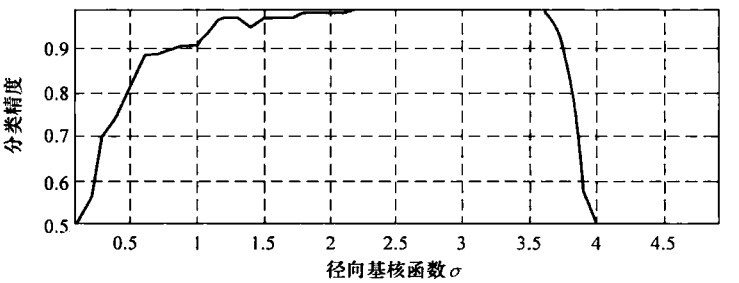

图 12-12　训练分类精度与 σ 的关系

可看出 σ 在（0，1］区间，训练分类精度逐渐提高；在（1，1.5］区间，训练分类精度出现波动，但一直保持较高的分类精度；在（1.5，2.3］的区间，训练分类精度持续上升并达到最高值100%；在（2.3，3.6］区间，支持向量分类机保持最高的训练分类精度100%；在（3.6，4］区间，训练分类精度迅速下降，最

终在 $\sigma=4$ 时，训练分类精度达到最低点 50%，此后维持在 50%。

因此，选用径向基核函数构造支持向量分类机时，σ 应该在［2.3，3.6］区间内取值。

12.2.5 基于支持向量机的液压泵故障诊断分析

现选用多项式核函数构造两类支持向量分类机，以型号为 MCY14-1B 的轴向柱塞泵的正常样本和一个柱塞松靴故障样本为例，对构造的支持向量分类机性能进行分析。将样本空间分为训练集（包含正常、松靴故障样本各 25 组）与测试集（包含正常、松靴故障样本各 25 组），将其分别用于训练和测试支持向量分类机。此样本空间中部分正常、松靴故障样本见表 12-1、表 12-2，表中子带 1～子带 8 表示用小波包分解子带特征能量法对采集的信号进行特征提取得到的归一化的各子带能量占总能量的百分比。

在构造支持向量分类机过程中，根据前面关于多项式核函数阶次与训练和测试分类精度关系的分析，选择多项式核函数阶次 $d=3$，同时为了控制对错分样本惩罚的程度，设定惩罚因子 $C=10$。在支持向量分类机应用软件中进行训练和测试，从而获得训练和测试过程的统计信息，见表 12-3。

表 12-1 部分正常状态样本

样本	子带 1	子带 2	子带 3	子带 4	子带 5	子带 6	子带 7	子带 8
1	0.0789	0.3951	0.1819	0.0489	0.1396	0.0944	0.0278	0.0334
2	0.0835	0.3688	0.1853	0.0469	0.1458	0.1025	0.0289	0.0383
3	0.0795	0.3935	0.2089	0.0523	0.1168	0.1027	0.0154	0.0309
4	0.0832	0.4024	0.1646	0.0526	0.1219	0.0914	0.0287	0.0552
5	0.0903	0.3989	0.1726	0.0493	0.1341	0.0935	0.0215	0.0398
6	0.0873	0.3892	0.1428	0.0549	0.1361	0.1152	0.0318	0.0427
7	0.0758	0.4398	0.1632	0.0601	0.1412	0.0752	0.0226	0.0221
8	0.0859	0.4019	0.1598	0.0445	0.1328	0.0958	0.0385	0.0408
9	0.0869	0.3796	0.1861	0.0426	0.1455	0.0908	0.0297	0.0388
10	0.0832	0.3894	0.1696	0.0501	0.1496	0.0935	0.0238	0.0408

表 12-2 部分松靴故障状态样本

样本	子带 1	子带 2	子带 3	子带 4	子带 5	子带 6	子带 7	子带 8
1	0.0733	0.4851	0.2028	0.0539	0.0856	0.0875	0.0035	0.0083
2	0.0598	0.4987	0.2173	0.0483	0.0901	0.0684	0.0038	0.0126
3	0.0459	0.5189	0.2186	0.0435	0.0802	0.0648	0.0045	0.0236

（续）

样本	子带 1	子带 2	子带 3	子带 4	子带 5	子带 6	子带 7	子带 8
4	0.0712	0.4364	0.2643	0.0426	0.0954	0.0726	0.0021	0.0155
5	0.0686	0.4763	0.2287	0.0547	0.0775	0.0689	0.0033	0.0219
6	0.0587	0.5104	0.2128	0.0489	0.1076	0.0458	0.0039	0.0118
7	0.0674	0.4796	0.2557	0.0313	0.1157	0.0354	0.0034	0.0114
8	0.0425	0.5216	0.2026	0.0313	0.0897	0.0556	0.0028	0.0538
9	0.0679	0.4589	0.2865	0.0418	0.0907	0.0228	0.0027	0.0286
10	0.0768	0.4226	0.2826	0.0315	0.1081	0.0418	0.0038	0.0328

表 12-3　训练和测试过程的统计信息

训练阶段		测试阶段	
训练时间	0.452s	测试时间	0.116s
支持向量（SV）个数	18	正确分类个数	47
SV 占总训练样本	36%	准确率为	94%

由表 12-3 可知，训练阶段得到的支持向量个数为 18（36%），测试阶段的正确分类个数为 47（94%）。可见，选择多项式核函数阶次 $d=3$，惩罚因子 $C=10$ 构造的支持向量分类机对轴向柱塞泵松靴故障进行故障检测，具有很高的故障确诊率。

12.3　基于 NS 机理和 SVM 复合的故障诊断方法

本节把阴性选择算法与支持向量机分类算法融合，提出一种新的基于免疫机理与支持向量机复合的故障诊断方法。由于在工程实际中，设备不可能在故障状态下长期运行，所以采集到的故障样本有限，新方法可以解决传统分类算法由于缺少故障样本而欠学习导致的算法无效问题。最后利用 Iris 数据进行分类测试来验证新方法的有效性。

12.3.1　传统分类算法的局限性

目前，智能故障诊断理论和方法的研究虽然已经取得了很大的进展，但由于机器学习瓶颈问题的制约，对于有限故障样本和诊断知识不完备的诊断对象，仍难以达到很高的确诊率，在实际应用中无法获得理想的效果。也就是说，传统的基于数据学习的故障诊断方法存在局限性。

传统的基于数据学习的故障诊断方法对数据样本要求较高。首先，要求样本的

数量多，即需要大量的典型故障数据样本，样本数据的分布要能覆盖所有故障模式；其次，要求样本的质量比较高，即训练样本必须包含尽可能多的故障模式，而且故障模式样本之间不能存在矛盾或冲突。

然而对于液压系统，尤其是大型液压系统，获取大量的典型故障数据样本非常困难。主要原因有：大型液压系统一般都是企业的关键设备，其运行状态直接影响到企业的整个生产工艺过程，一旦发生故障，就会造成巨大的经济损失，因此不可能让其长时间带故障运行；现场设备故障的发生有其一定的突然性，而且一般不可重复或模拟，因此往往是可遇而不可求；故障与征兆之间不存在简单的一一对应关系，不同的故障可以有相同的征兆，同一故障在不同的条件下表现出来的征兆也不完全相同。即使是同样的设备，在不同的安装和使用条件下，设备的故障模式样本也会相差很大。显然，针对具体设备的故障模式样本必定非常有限。因此，在故障诊断中，我们面临的是小样本或样本贫乏问题，它们在数量和质量上都不能满足神经网络等传统故障诊断方法对学习样本的要求。

12.3.2 支持向量机的不足

支持向量机基于结构风险最小化理论，兼顾了经验风险和推广能力，对解决小样本的模式分类问题具有独特的优势，特别适合于液压系统智能故障诊断，有望发展成为智能故障诊断的主要方法之一。

基于支持向量机的故障诊断可以视为一个学习任务，通过训练样本产生一个分类函数来区分正常或异常种类样本。然而，在许多故障诊断问题中，在训练阶段只能获得正常以及少数故障类样本，甚至有时只能得到正常样本。这样，解决小样本问题占优势的支持向量机方法也无能为力了。意味着不能直接用支持向量机方法进行分类。

12.3.3 NS 与 SVM 复合故障诊断方法

针对传统分类算法以及支持向量机所面临的上述不足，本节融合人工免疫系统中的实值阴性选择算法与传统的 SVM 分类算法，实现二者的优势互补，提出了一种新的故障诊断方法。在新方法中 RNS 算法不是直接用来执行检测的，而是通过自体与检测器来刻画正常和异常类的边界。用这种方法来对正常空间、已知故障和未知故障的边界进行刻画。这些数据再作为分类算法的输入，这样就能有效解决分类算法所面临的训练样本不足的难题。

1. *复合故障诊断方法原理*

如图 12-13 所示，描述了本节提出的复合故障诊断方法的原理，整个方法分为训练和诊断两个阶段。在训练阶段，正常样本以及已知故障样本作为实值阴性选择算法的输入（自己）来产生未知故障样本（检测器）。可用样本集和通过算法产生

的未知故障样本就可以对整个检测空间进行更详细的描述。然后把这些样本作为分类算法的输入，通过训练产生分类器。分类器相当于故障决策函数，在诊断阶段用来对新的样本进行分类，即使是在只有正常样本集可用的时候，也可以对系统进行故障检测。此时，由阴性选择算法产生的样本作为异常样本，把整个检测空间描述为正常/异常两类，解决了缺乏故障样本时，故障诊断无法进行的难题。

在训练阶段，主要就是产生足够分散的样本点覆盖非己空间，对整个检测空间进行最大可能的完全表述，这样才能给分类算法一个良好的输入集对分类函数进行训练，这就是复合故障诊断方法的核心思想所在。当训练阶段只有正常样本可用时，可以通过阴性选择算法产生异常样本，然后再把正常样本与产生的异常样本作为分类算法的输入进行训练，这样就把问题变为了二类问题。当训练阶段有正常以及一些故障样本可用时，也可以通过阴性选择算法对现有样本的补空间进行覆盖，把产生的样本作为未知故障样本类。总之，通过阴性选择算法，能够把原有问题转变为比可用样本类多一类的分类问题。而这一处理方法在实际应用中往往是非常有效的。

2. RNS 与 SVM 复合算法

（1）RNS 算法　在复合诊断算法中，由阴性选择算法产生的检测器能否对非己空间进行良好的覆盖将会对整个算法的效果产生非常大的影响。下面对复合方法中使用的 RNS 算法进行阐述。整个 RNS 算法产生检测器的过程如图 12-14 所示。

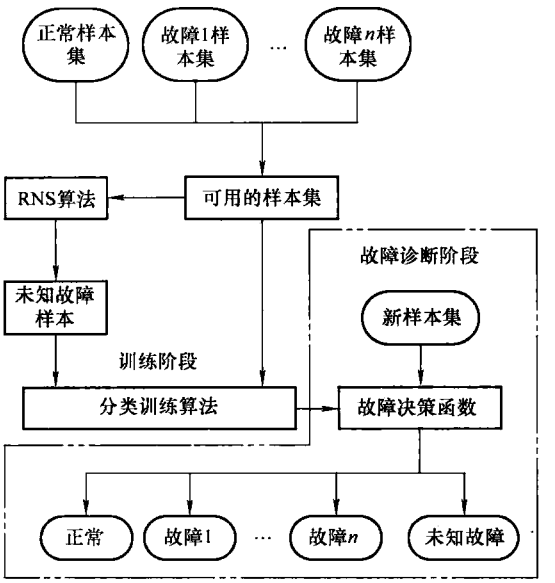

图 12-13　基于 RNS 的复合故障诊断方法流程图

首先，输入参数：$\boldsymbol{S}$——自体样本，N_{max}——最大检测器数，r_s——自体半径，r_d——检测半径。将自体样本用式（12-22）归一化到 n 维空间 $[0, 1]^n$。

$$s(i)=\frac{\boldsymbol{S}(i)-\boldsymbol{B}\cdot\min[\boldsymbol{S}(i)]}{\max[\boldsymbol{S}(i)]-\min[\boldsymbol{S}(i)]}\quad i=1,2,\cdots,n \tag{12-22}$$

式中，$\boldsymbol{S}(i)$ 是自体样本集 $\boldsymbol{S}$ 中的第 i 个；$\min[\boldsymbol{S}(i)]$ 是 $\boldsymbol{S}(i)$ 中所有元素的最小元素；$\max[\boldsymbol{S}(i)]$ 是 $\boldsymbol{S}(i)$ 中所有元素的最大元素，$\boldsymbol{B}'=(1, 1, \cdots, 1)_{1\times n}$，$n$ 为样本的维数，$s(i)$ 为归一化后的自体样本集 $\boldsymbol{s}$ 中的第 i 个。

再从 $[0, 1]^n$ 空间中随机产生样本 $\boldsymbol{x}$，计算 $\boldsymbol{x}$ 与检测器集合 $\boldsymbol{D}$ 中的每个检测器 $\boldsymbol{D}_j$ 的欧氏距离 d_d 和 $\boldsymbol{x}$ 与每个自体样本 $\boldsymbol{s}_j$ 的欧氏距离 d。$\boldsymbol{D}_j$，$\boldsymbol{s}_j$ 和 $\boldsymbol{x}$ 分别为 n 维向量，是空间 $[0, 1]^n$ 中的一个点。

$$d_d = \|\boldsymbol{x}-\boldsymbol{D}_j\| = \sqrt{\sum_{i=1}^{n}(x_i-D_{ij})^2} \tag{12-23}$$

$$d = \|\boldsymbol{x}-\boldsymbol{s}_j\| = \sqrt{\sum_{i=1}^{n}(x_i-s_{ij})^2} \tag{12-24}$$

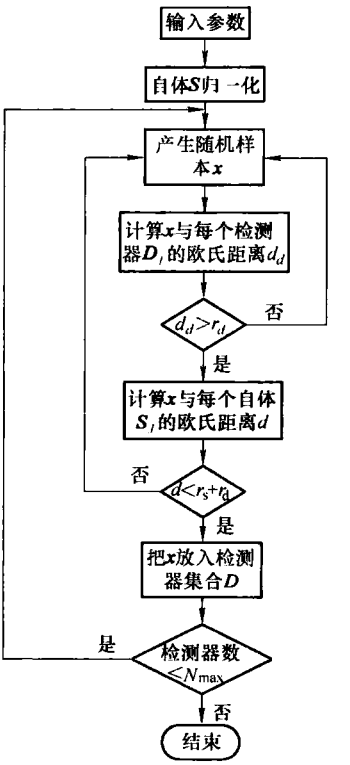

图 12-14 阴性选择算法检测器产生流程图

最后，满足条件 $d_d > r_d$ 且 $d > r_s + r_d$ 的 $\boldsymbol{x}$ 为非己，将其放入检测器集合 $\boldsymbol{D}$ 中直到检测器个数满足要求。条件 $d_d > r_d$ 用来保证 $\boldsymbol{x}$ 与检测器集合 $\boldsymbol{D}$ 中已有的每个检测器的欧氏距离大于 r_d，防止检测器过度聚集，使其更均匀地覆盖非己空间；条件 $d > r_s + r_d$ 用来保证检测器落在非己空间。

（2）分类算法的选择　提出的复合故障诊断方法并不依靠任何特定的分类算法，为了验证复合诊断方法的有效性，现将解决小样本问题占优势的支持向量机方法应用到复合诊断方法中。

（3）复合算法的实现　整个故障诊断过程分为三个阶段：未知故障样本的产生、训练阶段和诊断阶段。

① 未知故障样本的产生：将正常样本集和已知故障样本集合并为可用样本集，作为 RNS 算法的输入（自己），按图 12-14 的流程产生未知故障样本（检测器集），可以对整个检测空间进行更详细的描述，用于下一步的训练。

② 训练阶段：将正常样本、已知故障样本和产生的未知故障样本，作为 SVM 分类算法的输入，通过训练产生分类器。

③ 诊断阶段：用训练产生的分类器对新样本进行诊断分类。可以将新样本分为正常类、已知故障类、未知故障类。即使在只有正常样本集可用的情况下，由 RNS 算法产生的样本作为异常样本，把检测空间描述为正常/异常两类，也可以使系统故障诊断正常进行。

12.3.4　诊断实例及分析

1. 测试数据

为了验证方法的有效性，以标准样本鸢尾属植物数据集 Iris 数据为例进行仿真实验。Iris 数据集是检验模式识别方法有效性的国际公认标准样本之一。数据集中包含 Iris 的三种不同的类型，分别是 Setosa、Versicolor 和 Virginica。每组数据包含其四个属性分别是：萼片长度、萼片宽度、花瓣长度和花瓣宽度。每种类型的花各有 50 个样本，三种类型共 150 个样本。其中，Virginica 和 Versicolor 线性相关。考虑到以下叙述的方便性，将该样本称为标准样本，将 Setosa、Versicolor 和 Virginica 三类植物分别称为 Iris1、Iris2 和 Iris3。Iris 数据集示意图如图 12-15 所示。

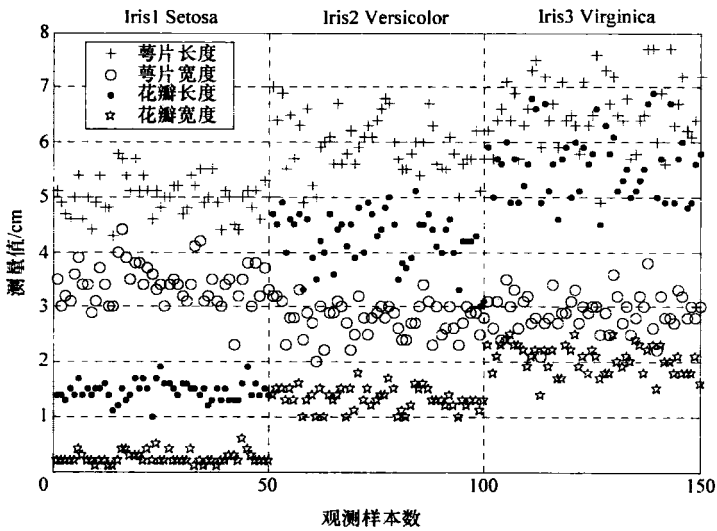

图 12-15　Iris 数据集示意图

2. 测试过程

首先分别指定三类样本为正常（iris1）、已知故障（iris2）和待测故障（iris3）。类比到实际情况，假设可用训练样本只有正常样本集和一个已知故障样本集，待测故障样本集用来对诊断方法有效性进行验证。下面分别用 SVM 诊断方法

和复合诊断方法对待测故障（iris3）样本集进行诊断测试，并对诊断结果进行比较。

（1）SVM 诊断方法　这是已知正常和故障样本，对未知样本进行分类的问题，未知样本可能被分为正常，也可能被分为故障，训练和诊断过程如下：

① 训练阶段：从正常（iris1）样本集和已知故障（iris2）样本集中各随机抽取 35 个样本，作为两类样本输入 SVM 分类软件，采用 d 阶多项式核函数，取 $d=3$，惩罚因子 $C=10$，进行训练，产生故障决策函数。

② 诊断阶段：将剩余的 iris1 样本和 iris2 样本各 15 个，同 iris3 样本（50 个）用故障决策函数分别进行诊断测试，被测试样本若被分到 iris1 类，说明该样本为正常；若被分到 iris2 类，说明该样本为故障。诊断结果 1 见表 12-4。

（2）复合诊断方法　首先，根据图 12-13 所示的复合诊断方法原理，将正常（iris1）样本集和已知故障（iris2）样本集组合为可用样本集；然后，将可用样本集输入 RNS 算法，设定参数为：$N_{max}=100/1000$，$r_s=0.1$，$r_d=0.08$，按照图 12-14所示的流程图分别产生 100/1000 个检测器，作为未知故障样本集用于下一步的训练。训练和诊断过程如下：

① 训练阶段：SVM 算法采用 d 阶多项式核函数，取 $d=3$，惩罚因子 $C=10$。把可用样本集（iris1 + iris2）和 RNS 产生的未知故障样本集作为两类样本输入 SVM 分类软件进行训练，产生故障决策函数 1（SVM1）；把 iris1 和 iris2 作为两类样本输入 SVM 分类软件进行训练，产生故障决策函数 2（SVM2）。这种情况要用 2 个两类支持向量分类机完成三类情况的分类任务，分类器结构如图 12-16 所示。

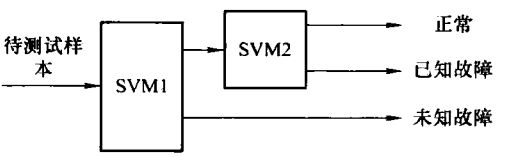

图 12-16　三类故障分类器结构示意图

② 诊断阶段：分别随机抽取 iris1 样本和 iris2 样本各 15 个，同待测样本 iris3（50 个）用故障决策函数 1 分别进行诊断测试。若 iris1/iris2 样本被分到可用样本类，则分类正确，否则分类错误；若 iris3 样本被分到未知故障样本类，则分类正确，否则分类错误。将分类正确的 iris1/iris2 样本用故障决策函数 2 再分类，就能确定 iris1 样本或 iris2 样本最终属于哪一类（正常或已知故障）。诊断结果 1 见表 12-4。

综上所述，对于 SVM 诊断方法来说，只能把待测故障（iris3）样本分为与它最近似的一类，有可能被分为正常（iris1）类，也有可能被分为故障（iris2）类。若 iris3 样本被分为正常类，与实际情况不符，分类错误；若 iris3 样本被分为故障

类，与实际情况相符，分类正确。而对于本章提出了复合诊断方法来说，待测样本可能被分为正常类、已知故障类和未知故障类，这样就能够在只提供两类样本的情况下，实现三类情况的分类。在上例中，若 iris3 样本被分为未知故障类，与实际情况相符，分类正确；若 iris3 样本被分为正常类或已知故障类，均与实际情况不符，分类错误。

表 12-4　诊断结果 1

样本类型	测试样本数	正确分类率		
		复合诊断方法		SVM 诊断方法
		$N_{max}=100$	$N_{max}=1000$	
正常（iris1）	15	100%	100%	100%
已知故障（iris2）	15	100%	100%	100%
待测故障（iris3）	50	40%	90%	100%

为了对复合诊断方法和 SVM 诊断方法进行进一步比较，把 iris2 作为正常样本，iris1 作为已知故障样本，iris3 作为待测故障样本，按照上面的过程再测试一遍，结果 2 见表 12-5。

表 12-5　诊断结果 2

样本类型	测试样本数	正确分类率		
		复合诊断方法		SVM 诊断方法
		$N_{max}=100$	$N_{max}=1000$	
正常（iris2）	15	100%	100%	100%
已知故障（iris1）	15	100%	100%	100%
待测故障（iris3）	50	36%	92%	0%

（3）结果分析　上面的测试过程是把三类 Iris 样本分为两种假设进行的，第一种假设，分别指定三类样本为正常（iris1）、已知故障（iris2）和待测故障（iris3），诊断结果 1 见表 12-4；第二种假设，分别指定三类样本为正常（iris2）、已知故障（iris1）和待测故障（iris3），诊断结果 2 见表 12-5。结果分析如下：

① 分类结果 1：如表 12-4 所示，直接用 SVM 诊断方法分类，完成的是 2 类分类问题，被测试的 iris1 样本全部被分为正常类，被测试的 iris2 样本全部被分为故障类，被测试的 iris3 样本也全部被分为故障类，与实际情况相符，三类样本的正确分类率都为 100%。

而用复合诊断方法进行的是三类分类问题，把 15 个 iris1 样本分为正常，15 个 iris2 样本分为已知故障，正确率为 100%，与 N_{max} 取值无关。对于 50 个待测故障样

本（iris3），当 $N_{max}=100$ 时，有 20 个被分为未知故障类，正确分类率 40%；当 $N_{max}=1000$ 时，有 45 个被分为未知故障类，正确分类率 90%。可以看出对 N_{max} 设置不同值时，影响复合诊断方法最后的正确分类率。

② 分类结果 2：如表 12-5 所示，直接用 SVM 诊断方法分类，被测试的 iris2 样本全部被分为正常类，被测试的 iris1 样本全部被分为故障类，与实际情况相符，正确分类率都为 100%；而被测试的 iris3 样本由于与 iris2 样本线性相关，全部分为正常类，与实际情况不符，正确分类率为 0%。

用复合诊断方法进行分类，把 15 个 iris2 样本分为正常，15 个 iris1 样本分为已知故障，与实际情况相符，分类正确率 100%，与 N_{max} 取值无关。对于 50 个待测故障样本（iris3），当 $N_{max}=100$ 时，有 18 个被分为未知故障类，正确分类率 36%；当 $N_{max}=1000$ 时，有 46 个被分为未知故障类，正确分类率 92%。可以看出对 N_{max} 设置不同值时，影响复合诊断方法最后的正确分类率。

由表 12-4 和表 12-5 的测试结果可以看出，单独使用 SVM 诊断方法进行分类时，对于第一种假设，能够对待测样本（iris3）进行正确的正常/故障分类，但对于第二种假设，得出的结果完全错误。这主要是因为，当对 iris3 样本进行诊断时，到底被分为正常还是故障主要看它与哪类样本相似程度更高。因为 iris2 和 iris3 是线性相关的，所以在没有更多学习知识的情况下，针对第二种假设，SVM 诊断方法分类完全错误。这也正是现有的智能分类算法在实际故障诊断应用中常见的问题。

而对于复合诊断方法，当 RNS 算法产生的检测器（未知故障样本）的数量足够多时，如 $N_{max}=1000$，这时产生的未知故障样本尽可能大地覆盖了未知故障空间，不管使用哪类样本（iris1 或 iris2）作为正常样本进行训练，最后的正确诊断率都在 90% 以上，这样的诊断效果比较令人满意。

12.4 基于复合故障诊断方法的液压泵诊断实验及结果分析

本节基于传统的油膜理论，分析滑靴在运动过程中对斜盘的冲击，以及滑靴松动时冲击的加强，通过实验验证理论分析的正确性。组建基于虚拟仪器的试验系统，选择泵端盖振动信号和泵出口压力信号作为监测信号，通过将从维修部门得到的松靴柱塞和磨损的配流盘替换正常元件来模拟多个松靴故障和配流盘磨损故障这两类常见的轴向柱塞液压泵失效形式，并采集大量各种故障模式的样本数据。将采集的数据进行功率谱密度分析，发现滑靴对斜盘冲击产生的振动信号被高频谐振信号调制，因此通过小波簇包络解调方法将调制信号解调出来，包络信号中包含了丰富的故障信息。

将包络信号用小波包分解子带特征能量法特征提取后，构成正常和各类故障的

样本集，并用核主元分析方法对样本集做降维处理，最后用免疫支持向量机复合故障诊断方法进行诊断，验证该方法的有效性。

12.4.1　基于虚拟仪器的液压泵故障诊断实验系统

本监控系统主要完成柱塞泵端盖振动信号和出口压力信号的监测，及后期数据处理和故障诊断，图 12-17 为虚拟仪器状态监控系统照片。

图 12-17　虚拟仪器状态监控系统

12.4.2　斜盘式轴向柱塞泵典型故障分析

滑靴松动是斜盘式轴向柱塞泵最易发生的机械故障之一，诸葛起在上海液压件三厂和上海高压油泵厂调查，了解到滑靴松动故障占返修泵故障的 70% ~80%。运行过程中的液压泵产生滑靴松动，轻则振动、噪声增加，降低寿命；重则滑靴脱节或活塞颈部扭断，发生严重事故。配流盘磨损也是易发故障之一，配流盘磨损后将引起泵的容积效率下降。

本节重点研究滑靴松动和配流盘磨损这两种故障形式，松靴柱塞和磨损的配流盘是由泵维修部门提供的，在实验时，将故障元件替换正常元件，采集泵端盖的振动信号和泵出口压力信号用于泵的故障分析诊断。

1. 松靴故障机理分析

斜盘式轴向柱塞泵是通过柱塞不断地吸油、排油实现高压油的供给，一般设计柱塞头和滑靴的间隙小于 70μm，在这个间隙下，柱塞球头能在滑靴球窝里自由地转动，且在液压油膜的支承下，二者因碰撞产生的冲击很小。

滑靴松动故障大多数是在柱塞泵的长期运行中逐渐形成的。柱塞泵每运转一周，每个柱塞在缸体内往复运动一次。柱塞泵连续运转时，柱塞频繁吸油和排油，

在交变载荷下长期工作很容易造成柱塞球头和滑靴球窝的沉凹变形。另外，如果油液污染度得不到合理控制，柱塞球头与滑靴球窝之间受到大量污染颗粒的磨损，也使得它们之间的间隙增大，造成松靴故障。当柱塞由吸油腔进入压油腔时，作用在柱塞上的压力突然升高，柱塞球头先对滑靴产生冲击，接着滑靴再对斜盘冲击，使回程盘产生较强烈的共振，这样导致泵端盖的振动信号能量加强。早期的松靴故障并不影响泵的正常工作，泵的外部主要特征如流量和压力没有明显变化；松靴严重时，将使泵的容积效率下降，最后柱塞球头和滑靴可能突然拉脱，会在一瞬间破坏整个泵源系统，这将对整个液压系统将造成严重影响。因此，对斜盘式轴向柱塞泵松靴故障进行早期诊断具有重要意义。

2. 配流盘磨损故障机理分析

在斜盘式轴向柱塞泵中，旋转的缸体和配流盘所构成的配流机构是一对摩擦副，它们之间形成油膜，起密封和润滑作用。如果油液被污染的话，在柱塞泵长期工作过程中，配流盘的通油小孔可能堵塞，导致缸体和配流盘间的油膜不能满足要求，这会使配流盘磨损，将导致泵的容积效率下降。严重时，会出现“烧盘”现象，使泵无法工作。

12.4.3 液压泵监测信号的采集与处理

首先对泵正常工作时的泵端盖振动信号和泵出口压力信号进行采集，将主溢流阀分别调定为 10MPa、12MPa、15MPa 和 17MPa，在每一压力下，按不同的采样频率 100kHz、200kHz、300kHz、500kHz 多次采集，采样时间为 10s；然后将松靴柱塞和磨损的配流盘分别与泵的正常元件替换，模拟一个柱塞松靴、二个柱塞松靴、三个柱塞松靴、四个柱塞松靴和配流盘磨损等故障形式，分别采集各压力和各采样频率下的故障信号；最后对采集的信号进行分析处理。

1. 泵端盖振动加速度信号

图 12-18 所示为系统压力 17MPa、采样频率 100kHz 时，正常与各故障状态时的泵端盖振动加速度信号。由于电动机同步转速为 1500r/min，故泵的转轴频率约为 25Hz，泵每转一周的时间为约 40ms，从图中可以看出，各种状态下一个周期内 7 个柱塞依次对斜盘冲击，振幅略有变化，看不出明显的故障特征。

2. 泵出口压力信号

图 12-19 所示为系统压力调定为 17MPa、采样率 100kHz 时，正常与各故障状态的泵出口压力信号。截取的信号长度为 80ms，泵刚好工作 2 个周期，从图中可以看出压力信号在 17MPa 附近脉动，前 4 种状态压力波形略有差异，4 个柱塞松靴时压力脉动非常明显，配流盘磨损时压力脉动不但明显并且振幅较大。

3. 监测信号的频谱分析

把工作压力 17MPa，采样频率 100kHz 条件的泵正常工作时的端盖振动信号做

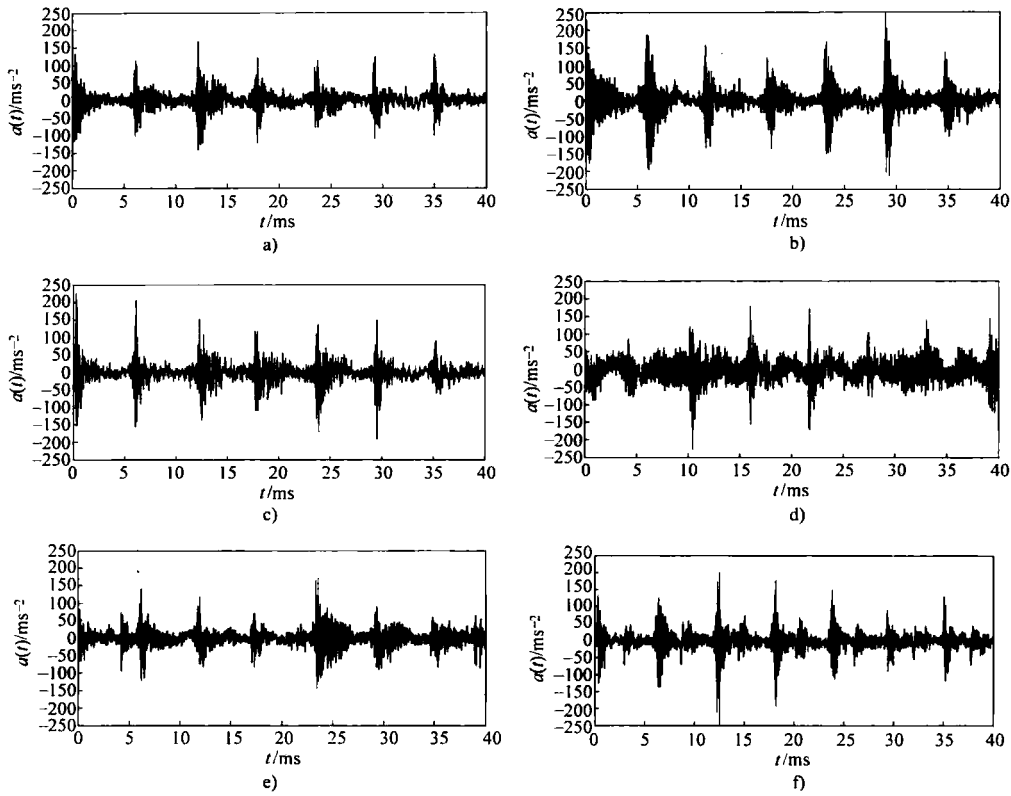

图 12-18　正常与各故障时的泵端盖振动信号

a）正常振动信号　b）一个柱塞松靴时振动信号　c）二个柱塞松靴时振动信号
d）三个柱塞松靴时振动信号　e）四个柱塞松靴时振动信号　f）配流盘磨损时振动信号

功率谱分析，如图 12-20 所示为 0 ~ 10kHz 频段的功率谱密度图。李国华等在《机械故障诊断》中指出，柱塞泵壳振动信号中 3kHz 以下的低频振动主要由回转元件激励的受迫振动构成，滑靴与斜盘撞击诱发的振动主要以共振形式传递出来。由图 12-20 可看出，3 ~ 5kHz 频段能量集中，高频谐振峰值大约在 3.8kHz 左右。可以判断，滑靴与斜盘撞击的微弱信号被高频振荡信号调制，然后以共振的形式传递出来，所以将 3 ~ 5kHz 频段的信号包络解调，就可得到所需要的信息，解调后信号包含丰富的故障信息，对分析松靴故障十分有用。

4. 泵端盖振动信号的小波簇包络解调

小波簇包络解调方法可将带通滤波操作与包络解调操作一步完成。通过选择合理的参数：$a = 0.2$，$f_L = 3000\text{Hz}$，$\Delta f = 1\text{Hz}$，$N = 2000$，得 $f_H = 5000\text{Hz}$，构造 3 ~ 5kHz 的平顶带通滤波器，其幅频特性如图 12-21 所示。

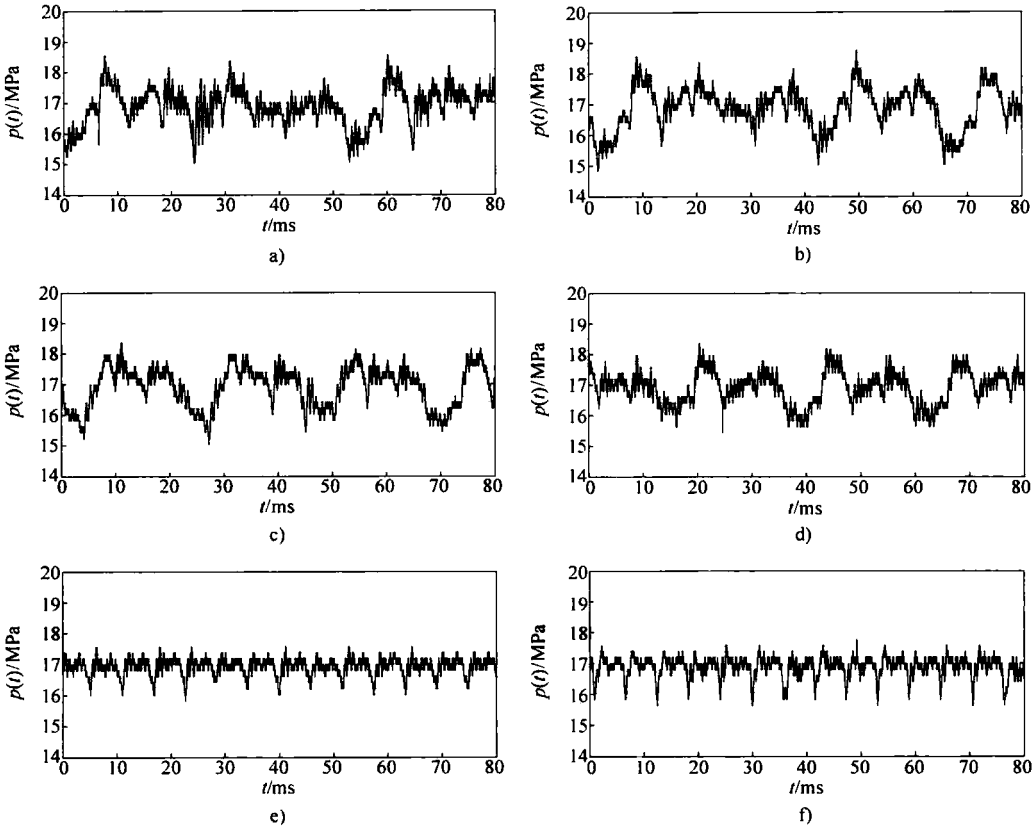

图 12-19 正常与各故障时的泵出口压力信号

a）正常压力信号 b）一个柱塞松靴时压力信号 c）二个柱塞松靴时压力信号
d）三个柱塞松靴时压力信号 e）四个柱塞松靴时压力信号 f）配流盘磨损时压力信号

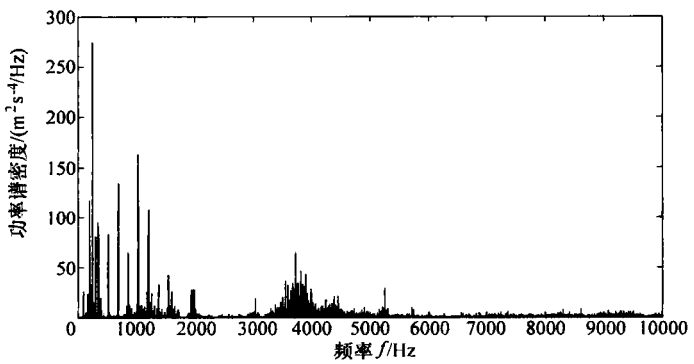

图 12-20 正常振动信号 0～10kHz 频段的功率谱密度图

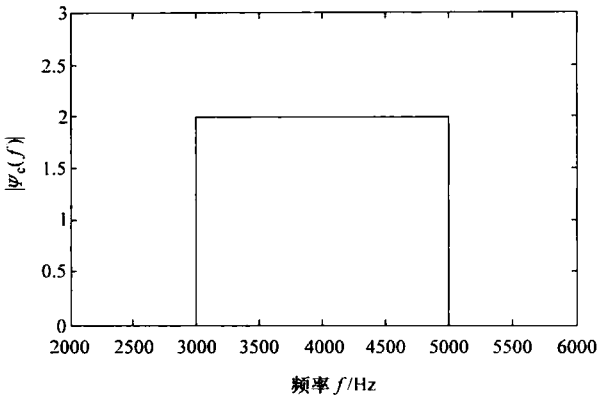

图 12-21　小波簇带通滤波器幅频特性

对正常和各故障状态时的端盖振动信号的 3 ~ 5kHz 频段内的成分包络解调，对所得各包络信号进行功率谱密度分析，结果如图 12-22 所示。由于泵轴实际转速为 1480r/min，则转轴频率为 1480/60Hz = 24.6Hz，柱塞泵有 7 个柱塞，所以滑靴撞击斜盘的冲击振动基频为 24.6 × 7Hz ≈ 172Hz。从图 12-22 中可以看出，频率成分集中在 172Hz 及其倍频上，与正常状态的各频率成分功率谱密度幅值比较，随着松靴柱塞个数的增加，幅值也相应增加；配流盘磨损时，相应的功率谱密度幅值比正常状态也有所增加。说明柱塞泵发生故障时，各频段的能量将发生变化，其对应的能量值包含了大量的非平稳非线性故障信息。将包络信号进小波包分解，用各子频带的能量占总能量的百分比构造特征向量，这个特征向量就能反应柱塞泵的运行状态。

5. 包络信号的小波包分解及特征提取

旋转机械发生故障时，故障振动信号经常被高频振动信号调制，小波簇包络解调方法是分析这种故障特征非常有效的方法之一。但针对斜盘式轴向柱塞泵松靴故障来说，不能通过分析故障特征频率来判断是否发生了松靴故障。如图 12-22 所示，将正常和各故障状态泵端盖振动信号用小波簇包络解调方法解调后，再做功率谱密度分析，发现在 172Hz（滑靴撞击斜盘基频）及其倍频上均发现有效峰值，只是幅值有所不同。为了判断柱塞泵是否发生了松靴故障，需要采集大量的柱塞泵各运行状态样本，用分类算法对各种样本进行识别，故障诊断过程如图 12-23 所示。

用智能分类算法对故障样本进行分类识别时，特征提取是难点之一，它直接关系到故障诊断的准确性和早期预报的可靠性。由图 12-22 可知，柱塞泵发生故障时，各频段的能量将发生变化，而小波包分解通过共轭正交滤波器组把振动信号分解到不同尺度下各自独立的子频带内，这些子频带上的分解系数相互之间不但是正

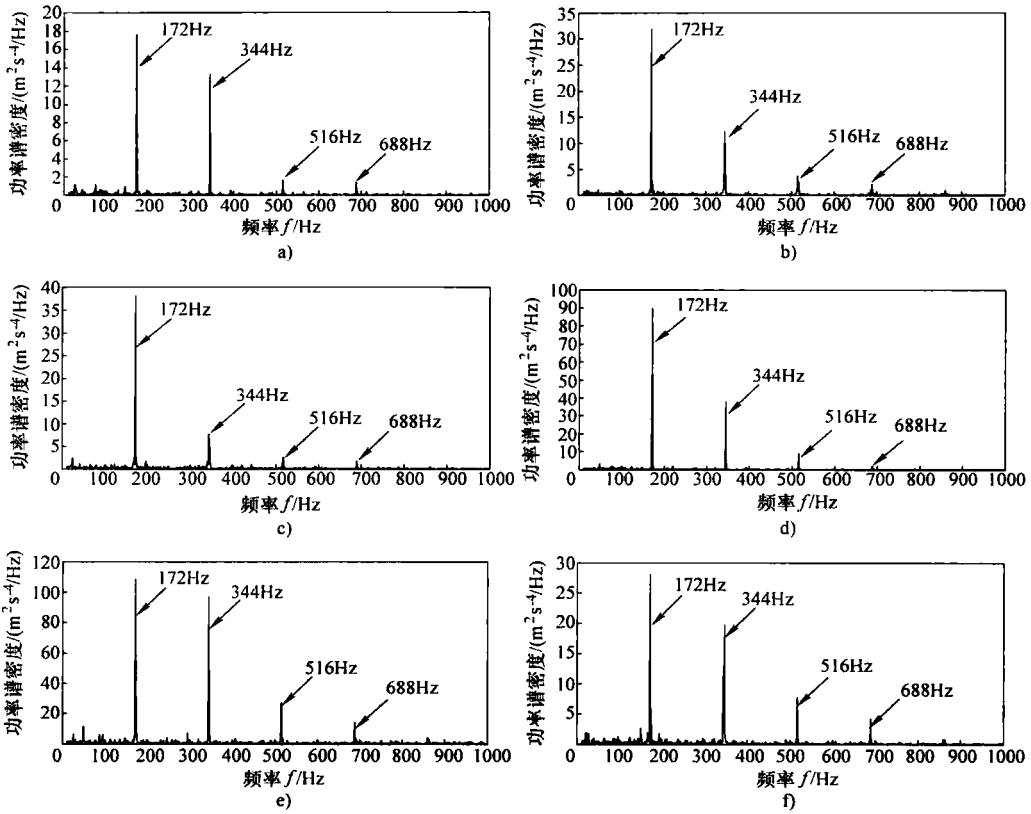

图 12-22 正常和各故障状态的振动信号小波簇包络解调功率谱密度

a）正常情况 b）一个柱塞松靴 c）二个柱塞松靴 d）三个柱塞松靴

e）四个柱塞松靴 f）配流盘磨损

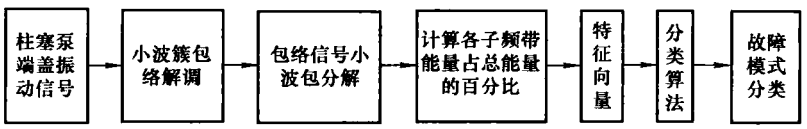

图 12-23 利用泵端盖振动信号故障诊断过程

交的、能量守恒的，而且相对于 FFT 谱来说，它们包含了大量的非平稳非线性诊断信息，可以用每个子频带里信号能量作为特征来表征设备的运行状态，因而可作为柱塞泵故障诊断的特征向量。

利用以上信号处理及特征提取方法，将工作压力 17MPa，采样频率 100kHz 时采集的正常和各故障状态泵端盖振动信号进行特征向量提取。

原始振动信号经包络解调后的包络信号包含了柱塞泵运行状态信息，由于感兴趣的频段在 0～1kHz，所以对所得到的包络信号进行降低采样率到 2kHz 的重采样，再将其进行小波包分解。

采用 db20 小波对包络信号进行 3 层小波包分解，这样在该尺度上形成了 8 个子频带，分析频率上限为 1kHz（Nyquist 频率），其中各节点对应的频带范围见表 12-6。依据式（11-36）获得各子频带的能量，各子带能量直方图如图 12-24 所示。依据式（12-38）将各子频带能量占总能量的百分比构成信号的特征向量。

表 12-6　小波包分解各节点对应的频带范围

小波系数	频带/Hz	小波系数	频带/Hz
d(3,0)	0 ~ 125	d(3,4)	500 ~ 625
d(3,1)	125 ~ 250	d(3,5)	625 ~ 750
d(3,2)	250 ~ 375	d(3,6)	750 ~ 875
d(3,3)	375 ~ 500	d(3,7)	875 ~ 1000

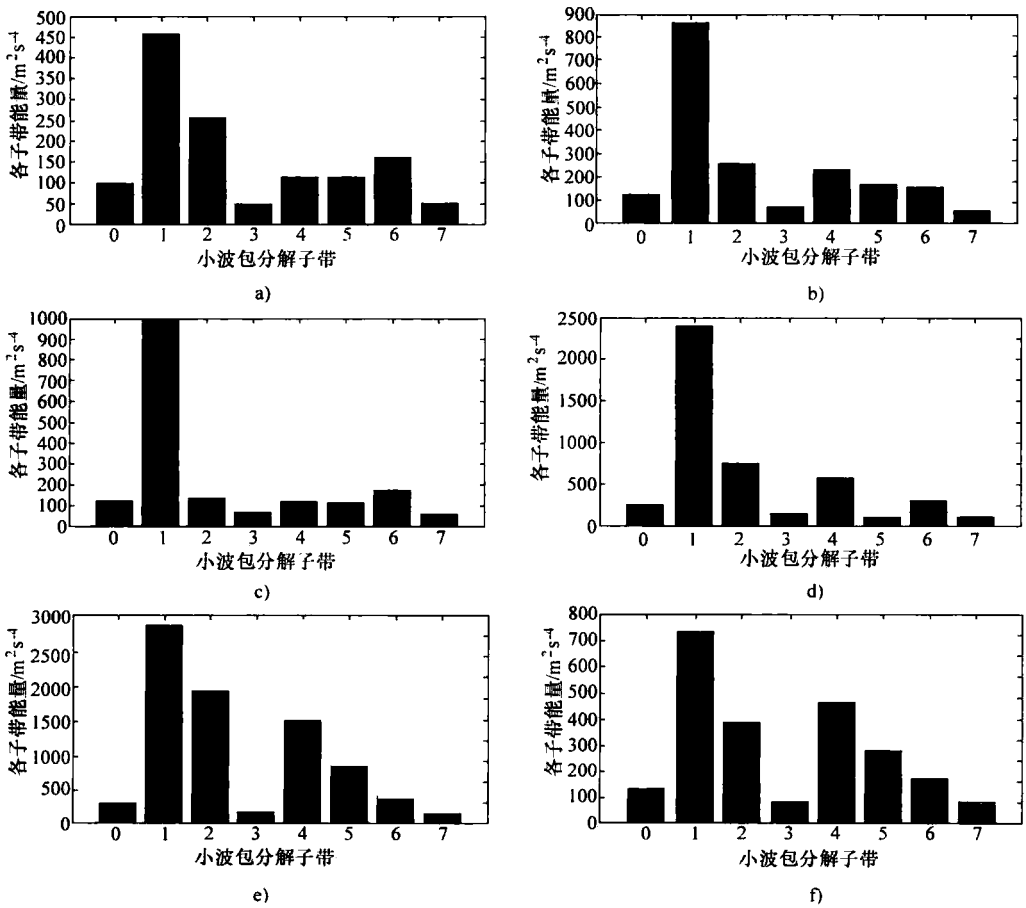

图 12-24　正常与各故障状态包络信号小波包分解子带能量直方图

a）正常情况　b）一个柱塞松靴　c）二个柱塞松靴　d）三个柱塞松靴

e）四个柱塞松靴　f）配流盘磨损

12.4.4 轴向柱塞泵故障诊断实验及结果分析

1. 基于核主元分析的故障特征降维

支持向量机理论与经典的基于统计的模式识别和机器学习方法不同，其采用结构风险最小化原则，既能有效地处理非线性数据，又能限制过学习，特别适合于小样本集的数据处理，在故障诊断方面具有独特优势。对于在故障特征模糊、噪声干扰严重的故障诊断应用中，使用时仍需进行数据的降维处理。因为一旦故障样本特征维数过高，其训练的复杂度及过拟合度都会大大增加，而且冗余特征和噪声的干扰对诊断结果会产生不利的影响。

用小波包分解子带特征能量法提取的柱塞泵运行状态样本为 8 维特征向量，维数相对较大，而且有些特征分量对故障模式分类不起作用，为了降低故障分类器的计算复杂度，需要对特征向量进行降维处理。为此，采用基于核主元分析的特征选择。

在特征选择过程中，选择柱塞泵每种状态样本各 50 个，共 300 个样本组成原始数据样本集，采用多项式核函数对原始数据样本集进行核主元分析，结果见表 12-7，采用的核函数形式为

$$K(\boldsymbol{x}_i,\boldsymbol{x}_j)=[(\boldsymbol{x}_i\cdot\boldsymbol{x}_j^{\mathrm{T}})+1]^d \tag{12-25}$$

从表 12-7 中可以看出，第一主元和第二主元累积贡献率达到了 92% 以上，降维效果明显，但是如果只选择前两个特征值对应的特征向量构成新的数据样本集的话，会损失较多的原始数据蕴含的信息，所以选择 4 个特征属性取代原来的 8 个特征属性，这样变量维数减少了一半。

表 12-7 核主元分析结果

特征值序号	多项式（$d=5$）		
	λ_i	$\lambda_i/\sum_{i=1}^{n}\lambda_i$	累积贡献率
1	45.8257	0.8250	0.8250
2	5.3682	0.0966	0.9216
3	2.5238	0.0454	0.9670
4	0.9846	0.0177	0.9847
5	0.3867	0.0069	0.9916
6	0.0273	0.0004	0.9920

2. NS 和 SVM 复合方法的诊断实验

工业现场设备故障的发生有其一定的突然性，而且一般不可重复或模拟，因此往往是可遇而不可求的。在许多故障诊断问题中，在训练阶段只能获得正常类样

本，这样，解决小样本问题占优势的 SVM 方法也无能为力了，意味着不能直接用其产生故障决策函数来进行故障诊断。

采用阴性选择算法产生检测器，通过自体与检测器来刻画正常和异常类的边界。这些数据再作为 SVM 的输入，产生故障决策函数，这样就能解决 SVM 分类算法所面临的训练样本不足的问题。

图 12-25 所示为 RNS 和 SVM 复合故障诊断方法流程图，整个故障诊断过程分为异常样本产生、训练和诊断三个阶段。

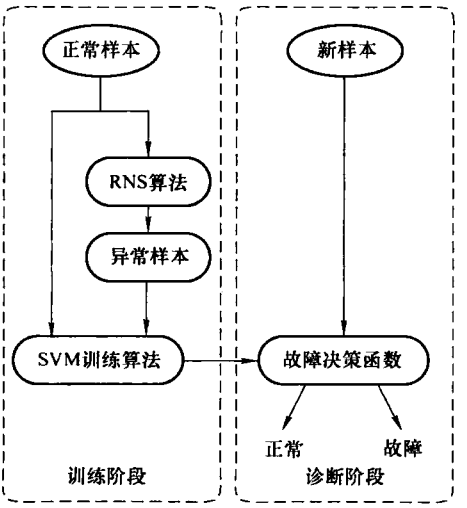

图 12-25　基于 RNS 的复合故障诊断方法流程图

（1）异常样本产生　正常样本（自体 $\boldsymbol{S}$）作为 RNS 算法的输入来产生异常样本（检测器 $\boldsymbol{D}$），使其尽可能地覆盖非己空间，具体流程如图 12-26 所示。

首先，将降维后的 50 个正常样本作为自体样本集 $\boldsymbol{S}_{4\times 50}$，设定参数：最大检测器数 $N_{\max}=100$，自体半径 $r_s=0.1$，检测半径 $r_d=0.08$。将自体样本用公式(12-26)归一化到 4 维空间 $[0,1]^4$。

$$s(i)=\frac{\boldsymbol{S}(i)-\boldsymbol{B}\cdot\min[\boldsymbol{S}(i)]}{\max[\boldsymbol{S}(i)]-\min[\boldsymbol{S}(i)]}\quad i=1,2,3,4 \tag{12-26}$$

式中，$\boldsymbol{S}(i)$ 是自体样本集 $\boldsymbol{S}$ 中的第 i 个；$\min[\boldsymbol{S}(i)]$ 为 $\boldsymbol{S}(i)$ 中所有元素的最小元素；$\max[\boldsymbol{S}(i)]$ 为 $\boldsymbol{S}(i)$ 中所有元素的最大元素，$\boldsymbol{B}'=[1,1,1,1]_{1\times 4}$，4 为样本的维数，$s(i)$ 为归一化后的自体样本集 $\boldsymbol{s}$ 中的第 i 个。

再从 $[0,1]^4$ 空间中随机产生样本 $\boldsymbol{x}$，计算 $\boldsymbol{x}$ 与检测器集合 $\boldsymbol{D}$ 中的每个检测器 $\boldsymbol{D}_j$ 的欧氏距离 d_d 和 $\boldsymbol{x}$ 与每个自体样本 $\boldsymbol{s}_j$ 的欧氏距离 d。$\boldsymbol{D}_j$，$\boldsymbol{s}_j$ 和 $\boldsymbol{x}$ 分别为 4 维向量，是空间 $[0,1]^4$ 中的一个点。

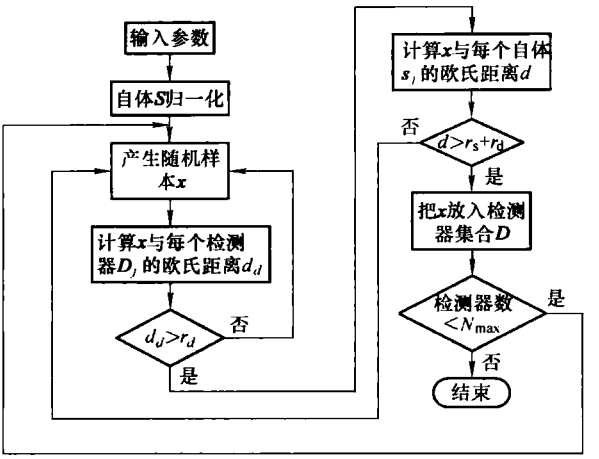

图 12-26 RNS 算法检测器产生流程图

$$d_d = \| \boldsymbol{x} - \boldsymbol{D}_j \| = \sqrt{\sum_{i=1}^{4} (x_i - D_{ij})^2} \tag{12-27}$$

$$d = \| \boldsymbol{x} - \boldsymbol{s}_j \| = \sqrt{\sum_{i=1}^{4} (x_i - s_{ij})^2} \tag{12-28}$$

最后，满足条件 $d_d > r_d$ 且 $d > r_s + r_d$ 的 $\boldsymbol{x}$ 为非自体，将其放入检测器集合 $\boldsymbol{D}$ 中直到检测器个数等于 100，这样就产生了 100 个异常样本用于下一步的训练。

（2）训练阶段 将降维后的 50 个正常样本和 RNS 算法产生的 100 个异常样本作为训练样本集输入支持向量机。由于柱塞泵各状态样本使用的是多项式核主元分析降维，所以在故障分类器的训练过程中采用 d 阶多项式核函数，取 $d=3$，惩罚因子 $C=10$，将正常样本作为一类，标识为 1，将产生的故障样本作为另一类，标识为 -1，生成故障决策函数。

（3）诊断阶段 柱塞泵各故障样本降维后作为新样本进行诊断测试，由故障决策函数将其分为正常或故障。这样在只有正常样本集可用的情况下，由 RNS 算法产生故障样本集，完成系统的故障诊断任务。

3. 实验结果分析

使用正常样本集和 5 种故障样本集（分别各包含 50 个样本）进行诊断测试，训练及诊断结果见表 12-8。以一个柱塞松靴诊断测试结果为例说明 N_{max} 取不同值时对诊断结果的影响：当用 RNS 算法产生的检测器（生成故障样本）的数量不足够多时，如 $N_{max}=100$，这时产生的故障样本不能尽可能大地覆盖非己空间，这样最后的正确诊断率只有 46%；当 $N_{max}=500$ 时，故障样本较大程度地覆盖了非己空间，正确诊断率提高到 72%；当 $N_{max}=1000$ 时，故障样本更大程度地覆盖了非己

空间，这时正确率可达92%，这样的诊断效果比较令人满意。当然不能无限制地提高 N_{max}，这样将大大增加训练、诊断时间和浪费计算机的资源，降低诊断效率，用这样的成本换取正确率的再提高是不合算的。对于其余几种故障形式，随着 N_{max} 的增加，正确诊断率也相应增加。

表 12-8　训练及诊断结果

		$N_{max}=100$	$N_{max}=500$	$N_{max}=1000$
训练阶段	支持向量（SV）个数	38	126	260
	SV 占总训练样本比例	19%	21%	23.63%
	训练时间	1.365s	157.13s	1786s
正常信号诊断测试	诊断时间	0.059s	0.271s	1.725s
	正确诊断率	100%	100%	100%
一个柱塞松靴诊断测试	诊断时间	0.061s	0.282s	1.735s
	正确诊断率	46%	72%	92%
二个柱塞松靴诊断测试	诊断时间	0.042s	0.301s	1.813s
	正确诊断率	38%	66%	90%
三个柱塞松靴诊断测试	诊断时间	0.066s	0.296s	1.716s
	正确诊断率	42%	68%	94%
四个柱塞松靴诊断测试	诊断时间	0.071s	0.289s	1.739s
	正确诊断率	44%	76%	92%
配流盘磨损诊断测试	诊断时间	0.066s	0.268s	1.694s
	正确诊断率	36%	78%	90%

参 考 文 献

[1] Ishida Y. Fully Distributed Diagnosis by PDP Learning Algorithm: Towards Immune Network PDP Model [C]// International Joint Conference on Neural Networks, San Diego, CA, USA, 1990, 1: 777-782.

[2] S Forrest, A Perelson, L Allen, et al. Self-nonself discrimination in a computer [C]// Proceedings IEEE Symposium on Research in Security and Privacy, IEEE Computer Society Press: Los Alamitos, CA, 1994: 202-212.

[3] Dasgupta D, Forrest S. Artificial immune system in industrial applications [C]// Proc 2nd International Conference on Intelligent Processing and Manufacturing of materials, Honolulu, 1999: 257-267.

[4] Ishiguro A, Watanabe Y, Uchikawa Y. Fault diagnosis of plant systems using immune networks [C]// Proc IEEE International Conference on multi-sensor Fusion and Integration for Intelligent Systems, LasVegas, NV, 1994: 34-42.

[5] Tang Z, Yamaguchi T, Tashima K, et al. Multiple-valued immune network model and its simulation [C]// Proc 27th International Symposium on Multiple-Valued Logic, Antigonish, Nova Scotia, Canada, 1997: 519-524.

[6] Djurdjanovic Dragan, Liu Jianbo, Marko Kenneth A, et al. Immune systems inspired approach to anomaly detection and fault diagnosis for engines [C]// The 2007 International Joint Conference on Neural Networks, Orlando, FL, United states, 2007: 1375-1382.

[7] 戴一阳，陈宁，赵劲松，等. 人工免疫系统在间歇化工过程故障诊断中的应用 [J]. 化工学报，2009，60 (1)：172-176.

[8] 谢珺，郝伟，谢克明. 免疫群体网络算法及其在电站风机故障诊断中的应用 [J]. 北京工业大学学报，2008，34 (11)：1207-1210.

[9] 周鹏，秦树人. 基于切片谱免疫系统的旋转机械故障诊断 [J]. 仪器仪表学报，2008，29 (6)：1198-1202.

[10] 熊浩，张晓星，廖瑞金，等. 基于动态聚类的电力变压器故障诊断 [J]. 仪器仪表学报，2007，28 (3)：456-459.

[11] 陈慰峰. 医学免疫学 [M]. 3 版. 北京：人民卫生出版社，2001.

[12] Dasgupta D, Attoh-Okine N. Immunity-based System: A survey [C]// Proceedings of IEEE International Conference on Systems, Man and Cybernetics, Orlando, FL, USA, 1997 (1): 869-874.

[13] Jon Timmis, Mark Neal, John Hunt. An artificial immune system for data analysis [J]. Biosystems, 2000 (55): 143-150.

[14] Dasgupta D, K KrishnaKumar, D Wong, et al. Negative Selection Algorithm for Aircraft Fault Detection [C]// Proceedings of the 3rd International Conference on Artificial Immune System. New York: Springer-Verlag Publisher, 2004 (23): 1-13.

[15] Cherkassky V, Ma Yunqian. Practical selection of SVM parameters and noise estimation for SVM regression [J]. Neural Networks, 2004, 17 (1): 113-127.

[16] Fabio A. González, Dasgupta. D. Anomaly Detection Using Real-Valued Negative Selection [J]. Genetic Programming and Evolvable Machines, 2003, 4 (4): 383-403.

[17] 陈长征，杨璐. 基于小波分析技术的通风机振动故障诊断研究 [J]. 风机技术，1999 (6)：34-36.

[18] 诸葛起，路甬祥. 用振动信号检测柱塞泵松靴故障 [J]. 振动、测试与诊断，1989，9 (3)：11-15.

[19] 李国华，张永忠. 机械故障诊断 [M]. 北京：化学工业出版社，1999.

[20] 牛慧峰. 免疫机理与支持向量机复合的故障诊断理论及试验研究 [D]. 秦皇岛：燕山大学，2009：15-97.

[21] 姜万录，牛慧峰，刘思远. 免疫支持向量机复合故障诊断方法及试验研究 [J]. 振动与冲击，2011，30 (6)：176-180.

[22] Huifeng Niu, Wanlu Jiang (姜万录), Siyuan Liu. Research on the Hybrid Fault Diagnosis Approach Based on Artificial Immune Algorithm [C]// Proceedings of 4th International Conference

on Natural Computation (ICNC' 2008), 2008, Vol. 6, Jinan, Shandong, China, 18-20 Oct. 2008: 667-670.

[23] 牛慧峰，姜万录．免疫支持向量机方法在液压泵故障诊断中的应用［J］．中国机械工程，2008，19（14）：1736-1739/1743.

[24] 牛慧峰，姜万录．支持向量机在工业控制故障诊断中的应用［J］．东北大学学报（自然科学版），2008，29（s2）：213-216.

[25] Huifeng Niu, Wanlu Jiang（姜万录）, Siyuan Liu. Hybrid Approach Based on Immune Algorithm and Support Vector Machine and its Application for Fault Diagnosis of Hydraulic Pump［C］// Proceedings of 4th International Symposium on Precision Mechanical Measurements (ISPMM' 2008), 2008, Hefei, Anhui, China, 25-29 August. 2008: 71304X-1-71304-6.

[26] 牛慧峰，姜万录，李刚．内禀模态特征能量法在柱塞泵故障诊断中的应用［J］．机床与液压，2008，36（10）：179-183.

[27] 牛慧峰，姜万录，王文杰．阴性选择算法在工业控制系统故障诊断中的应用［J］．燕山大学学报，2008，32（4）：362-366.

[28] 牛慧峰，姜万录．基于人工免疫系统的网络化智能故障诊断展望［J］．机床与液压，2007，35（11）：146-150.

[29] Niu Huifeng, Jiang Wanlu（姜万录）, Wu Shengqiang. Research on Remote Intelligent Fault Diagnosis Technology Based on Virtual Instrument［C］// Proceedings of 5th International Symposium on Fluid Power Transmission and Control (ISFP' 2007), June 6-8, 2007, Beidaihe, China: 1044-1048.

第 13 章　信息融合和贝叶斯网络集成的故障诊断方法

本章针对特征向量集中存在冗余属性的问题，提出了基于粗糙集理论的启发式属性约简算法，得到了“最佳属性约简”，有效地去除了冗余属性。以粗糙集理论为基础结合主元分析方法构造了多变量决策树，得到了最小诊断规则信息表。针对现代液压系统故障信息模糊性和不完备性的特点，提出了单传感器多域特征信息融合的贝叶斯网络故障诊断方法，以及多源传感器信息融合和贝叶斯网络集成的故障诊断方法，通过液压泵多故障模式的诊断实验验证了该方法的有效性，与基于粗糙集理论的故障诊断方法和基于主元分析模型的故障检测方法比较，证实了该方法更适用于液压泵的故障诊断。

13.1　粗糙集理论在故障诊断中的应用

由于液压泵的故障形式多种多样，故障机理十分复杂，无法用特定的频率特征来描述故障形式，所以在故障诊断过程中，为了尽可能全面地描述液压泵的故障形式，提高故障诊断精度，常从多信息域获取大量的故障特征信息。虽然提取的故障特征信息能够增加知识的完备性，但是采取这种方式常带有盲目性，使特征信息中存在较多的冗余属性，干扰故障的正确判断并降低故障诊断的效率。因此，本节提出了两种利用粗糙集理论的知识约简算法对故障特征信息进行压缩并去除冗余属性。

13.1.1　知识约简

知识约简是粗糙集理论的核心内容之一。它研究近似空间中每个等价关系是否都是必要的，以及如何删去不必要的知识，这不仅不会改变决策表的分类或决策能力，反而会提高系统潜在知识的清晰度。知识约简在信息系统分析、数据挖掘以及故障诊断等领域都具有重要的实用价值。

1. 一般约简

在粗糙集理论的应用中，约简是最重要的基本概念之一。实际中，在用原始实例记录构建知识库时，由于在对象属性的选取上带有一定的主观性，所以各属性在知识库中不是同等重要的，可能有一些是冗余的，在保证信息表分类能力不变的条件下，去除其中那些不重要的冗余属性就是知识约简。

定义 13-1：设 R 是等价关系的一个族集，且设 $r \in R$。若 $\mathrm{Ind}(R) = \mathrm{Ind}(R - r)$，则称关系 r 在族集 R 之中是可省的，否则就是不可省的。若族集 R 中的每个关系 r 都是不可省的，则称族集 R 是独立的，否则就是依赖的或非独立的。

定义 13-2：若 $Q \subseteq P$ 是独立的，并且 $\mathrm{Ind}(Q) = \mathrm{Ind}(P)$，则称 Q 是关系族集 P 的一个约简。在族集 P 中所有不可省的关系的集合称为 P 的核，用 $\mathrm{Core}(P)$ 来表示。

显然，族集 P 有多个约简。下面的定理是建立核与约简之间联系的重要性质。

定理 13-1：族集 P 的核等于 P 的所有约简的交集。即

$$\mathrm{Core}(P) = \cap \mathrm{Red}(P) \tag{13-1}$$

其中 $\mathrm{Red}(P)$ 是 P 的所有约简的族集。

从上面的定理可看出，核的概念具有两方面的意义。首先，可作为计算所有约简的基础，因为核包含于每一个约简之中，并且其计算是直接的。其次，核可以解释为知识最重要部分的集合，进行知识约简时不能够删除它。

一般产生约简的方法是逐个向核中添加可省的关系，并进行检查。注意，可省的关系集合的幂集的基数是多少，就有多少种添加的方式。最好的情况是所有不可省的关系集合本身就是约简，此时的约简是唯一的。所以，计算所有约简与计算一个最佳约简都是 NP 难题。

2. 相对约简

一般约简往往需要考虑知识库 $K = (U, R)$ 中的一种分类（知识甲）相对于另一种分类（知识乙）的分类能力，即在分类过程中，就知识乙而言知识甲中的哪些知识是冗余的，去除知识甲中相对于知识乙的冗余知识的过程称为相对约简。首先需要定义一种分类相对于另一种分类的正域概念。

定义 13-3：设 P 和 Q 是全域 U 上的等价关系的族集，所谓族集 Q 的 P 正区域，记作 $\mathrm{Pos}_P(Q)$，定义为

$$\mathrm{Pos}_P(Q) = \bigcup_{X \in U/Q} P_-(X) \tag{13-2}$$

族集 Q 的 P 正区域是全域 U 的所有那些使用分类 U/P 所表达的知识，能够正确地分类于 U/Q 的等价类之中的对象的集合。一个集合 X 相对于一个等价关系 P 的正区域就是这个集合的下近似 $P_-(X)$；而一个等价关系 Q 相对于另一个等价关系 P 的正区域的概念是解决分类 Q 的等价类之中的哪些对象可由分类 P 的等价类来分类的问题。

定义 13-4：设 P 和 Q 是全域 U 上的等价关系的族集，$R \in P$。若

$$\mathrm{Pos}_{\mathrm{Ind}(P)}(\mathrm{Ind}(Q)) = \mathrm{Pos}_{\mathrm{Ind}(P-\{R\})}(\mathrm{Ind}(Q)) \tag{13-3}$$

则称关系 R 在族集 P 中是 Q 可省的，否则称为 Q 不可省的；如果在族集 P 中的每个关系 R 都是 Q 不可省的，则称 P 关于 Q 是独立的，否则就称为是依赖的。

定义 13-5：$S\subseteq P$ 称为 P 的 Q 约简，当且仅当 S 是 P 的 Q 独立的子族集，且 $\mathrm{Pos}_S(Q)=\mathrm{Pos}_P(Q)$；族集 P 中的所有 Q 不可省的初等关系的集合，称为族集 P 的 Q 核，记作 $\mathrm{Core}_Q(P)$。

定义 13-6：设 P 和 Q 是知识库 $K=(U, R)$ 中的两个等价关系族，若 $S\subseteq P$，当 S 是 P 的 Q 独立子集且有 $\mathrm{Pos}_S(Q)=\mathrm{Pos}_P(Q)$，则称 S 为 P 的 Q 约简。P 的 Q 约简简称相对约简，即 P 相对于 Q 的约简。

定义 13-7：设 P 和 Q 是知识库 $K=(U, R)$ 中的两个等价关系族，$\mathrm{Core}_Q(P)=\cap\mathrm{Red}_Q(P)$，$\mathrm{Red}_Q(P)$ 为 P 的所有 Q 约简。

13.1.2 决策表属性约简算法

本节在研究粗糙集理论应用的过程中，基于方法互补融合的思想，提出了基于主元模型的粗糙集理论启发式属性约简算法。该算法利用粗糙集理论构造分辨矩阵，利用主元分析方法结合分辨矩阵引入启发式函数，依据属性选择规则，得到最佳属性约简，获得最小诊断规则信息。最后通过实例证明，该方法应用在故障诊断的属性约简过程中是有效的。

1. 基于分辨矩阵的属性约简算法

基于粗糙集理论的知识获取，主要是通过对原始决策表的约简，在保持决策表决策属性和条件属性之间的依赖关系不发生变化的前提下对决策表进行属性约简。以下介绍一种基于分辨矩阵和逻辑运算的属性约简算法。

分辨矩阵是由 Skowron 教授提出的，其内容是：令 $S=(U, C, D, f)$ 是一个故障诊断决策系统。C 为故障特征条件属性集合；D 为故障决策属性集合；f：$U\times R\rightarrow V$ 是一个信息函数，它指定 U 中每一个对象 x 的属性值；$V=\bigcup\limits_{r\in R}V_r$ 是属性值的集合，V_r 表示属性 $r\in R$ 的属性值范围，即属性 r 的值域。$U/\mathrm{Ind}(C)$ 表示根据故障征兆属性 C 将 U 上的对象进行划分而得到的所有等价类，等价类的数量用 n 表示。$a(x_j)$ 是样本 x_j 在属性 a 上的取值，$D(x_j)$ 是样本 x_j 在属性 D 上的取值。称 $(m_{ij})_{n\times n}$ 为 S 的分辨矩阵，即

$$m_{ij}=\begin{cases}\{a\mid a\in C\} & a(x_i)\neq a(x_j)\,\&\,D(x_i)\neq D(x_j)\\ \varnothing & D(x_i)=D(x_j);a(x_i)=a(x_j)\,\&\,D(x_i)\neq D(x_j)\end{cases}$$
$$i,j=1,2,\cdots,n. \tag{13-4}$$

其中，$\varnothing$ 为空集。

性质 13-1：给定决策系统 $S=(U, C, D, f)$，M 为 S 的分辨矩阵，Q 为 S 的一个约简，则对任意 $m_{ij}\neq\varnothing$ 必有 $Q\cap m_{ij}\neq\varnothing$ 成立。

性质 13-2：给定决策系统 $S=(U, C, D, f)$，M 为 S 的分辨矩阵，若有 $|m_{ij}|=1$，则该属性必为核属性。

算法的具体步骤如下：

1）计算决策表的分辨矩阵 $(m_{ij})_{n\times n}$。

2）对于分辨矩阵中的所有取值为非空集合的元素 m_{ij}（$m_{ij}\neq 0$，$m_{ij}\neq\varnothing$），建立相应的析取逻辑表达式 L_{ij}

$$L_{ij}=\bigvee_{a_l\in m_{ij}} a_l \tag{13-5}$$

3）将所有的析取逻辑表达式 L_{ij} 进行合取运算，得一个合取范式 L，即

$$L=\bigwedge_{m_{ij}\neq 0,m_{ij}\neq\varnothing} L_{ij} \tag{13-6}$$

4）将合取范式 L 转换为析取范式的形式，得

$$L'=\bigvee L \tag{13-7}$$

5）输出属性约简结果。析取范式中的每个合取项就对应一个属性约简的结果，每个合取项中所包含的属性组成约简后的条件属性集合。

2. 基于主元模型的启发式属性约简算法

根据主元分析方法的特点，引入了一个启发式函数，结合粗糙集理论的分辨矩阵提出了一种基于主元模型的启发式属性约简算法。该算法通过粗糙集理论建立信息系统的分辨矩阵，利用主元分析方法得到各主元的表达式和主元贡献率。引入一个启发式函数将这两种方法的结果相结合，通过启发式算法得到决策信息表的最佳属性约简。

引入的启发式函数为

$$f(a_k)=\alpha\frac{1}{|U|^2}\sum_{a_k\in m_{ij}}\frac{1}{|m_{ij}|}+\beta K(a_k) \tag{13-8}$$

其中 $\alpha+\beta=1$，$k=1$，…，n。由于 Y_1，…，Y_n 为决策系统 $S=(U, C, D, f)$ 的主元变量，Y_l 是第 l 个主元，c_l 为 Y_l 的贡献率，当累计方差贡献率 $\eta_k\geqslant 85\%$ 时

$$Z=Y_1c_1+\cdots+Y_kc_k=(K(a_1),\cdots,K(a_l),\cdots,K(a_n)) \tag{13-9}$$

$K(a_l)$ 为向量 Z 在属性 a_l 上的系数，$l=1$，…，n。

由性质 13-1 可知，约简与分辨矩阵中每一项的交集不能为空，因此，可以首先设候选约简集合 $Q=\varnothing$，然后计算分辨矩阵中的每一项 m_{ij} 和 Q 的交集。若交集为空，则按照启发式规则选取某一属性加入到约简集 Q 中。选取规则如下：

1）分辨矩阵的某项若只有一个属性，该属性必是约简的成员，故必加入 Q 中。

2）按照启发式函数值由大到小的顺序选择启发函数值最大的属性加入到 Q 中。

若交集不为空则跳过这一项。重复这一过程，直到分辨矩阵的每一项都检查过为止，此时在候选约简集 Q 中就得到了一个“最佳属性约简”。

下面通过一个实际的算例来说明这种属性约简算法的有效性，并与分辨矩阵的属性约简算法进行优劣比较。

3. 实例分析

用轴向柱塞泵振动信号的历史数据进行故障诊断为例来说明上述方法的有效性。根据历史数据构造的故障诊断决策系统信息表如表 13-1 所示。

表 13-1 故障诊断决策信息表

U	k	d_1	d_2	d_3	d_4	d_5	a_5	D	U	k	d_1	d_2	d_3	d_4	d_5	a_5	D
1	8	2	0	2	0	0	1	1	6	15	2	1	1	1	2	2	2
2	14	0	0	0	0	0	0	1	7	15	0	0	2	1	2	2	4
3	10	2	0	1	1	0	0	2	8	16	1	0	0	0	2	2	4
4	4	0	0	0	0	0	0	3	9	6	0	0	0	0	1	1	5
5	15	1	1	2	1	0	2	3	10	3	1	0	0	0	1	1	6

其中，$U=\{1, 2, \cdots, 10\}$ 为液压泵的 10 种故障状态，每种故障状态的样本个数用 k 表示。$C=\{d_1, d_2, d_3, d_4, d_5, a_5\}$ 为描述液压泵故障的 6 个条件属性集合，由小波分析 5 层分解的各频带能量特征组成；D 为描述诊断结果的决策属性。各属性表示的含义如表 13-2 所示。条件属性的取值由 FCM 聚类算法对历史数据信息表进行离散化得到：0—低；1—中；2—高。

表 13-2 各属性的含义

条件属性	频带/Hz	决策属性	状态类型
d_1	250 ~ 500	$D(1)$	正常状态
d_2	125 ~ 250	$D(2)$	单柱塞松靴
d_3	62.5 ~ 125	$D(3)$	单柱塞脱靴
d_4	31.25 ~ 62.5	$D(4)$	滑靴磨损
d_5	15.63 ~ 31.25	$D(5)$	斜盘磨损
a_5	0 ~ 15.63	$D(6)$	中心弹簧失效

从中选取 76 个样本作为训练样本，30 个样本作为测试样本。通过决策信息表利用训练样本建立分辨矩阵，从分辨矩阵中得出 d_5 是核属性，所以 $d_5 \in Q$。

用主元分析方法得到各主元贡献率如图 13-1 所示。

图 13-1 中 Y_1，Y_2，Y_3，Y_4，Y_5 是前五个主元的贡献率，可以看出前四个主元的累积贡献率 $\eta_4 = \sum_{i=1}^{4} c_i = 93.2\%$，

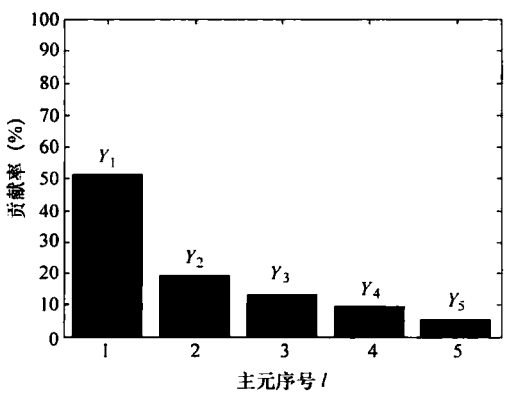

图 13-1 各主成分贡献图

这表明用主元 Y_1，Y_2，Y_3，Y_4 完全可以代替原来的 6 个初始条件属性。运用启发式函数公式（13-8）比较各属性启发函数值的大小。由于 $d_5 \in Q$，所以 d_5 不在被比较范围内。其他属性的比较结果为：

$$f(d_1) > f(d_2) > f(d_4) > f(d_3) > f(a_5)$$

根据启发式属性选取规则可得到最佳约简为 $Q = \{d_1, d_2, d_4, d_5\}$。根据约简结果建立诊断规则如表 13-3 所示。

表 13-3　诊断规则信息表

序　号	规　则	粗糙隶属度	置 信 度
1	$d_1=2 \wedge d_2=0 \wedge d_4=0 \Rightarrow D=1$	1	0.36
2	$d_1=2 \wedge d_2=1 \Rightarrow D=2$	1	0.6
3	$d_1=2 \wedge d_2=0 \wedge d_4=1 \Rightarrow D=2$	1	0.4
4	$d_1=1 \wedge d_2=1 \Rightarrow D=3$	1	0.79
5	$d_1=0 \wedge d_2=0 \wedge d_4=1 \Rightarrow D=4$	1	0.48
6	$d_1=1 \wedge d_2=0 \wedge d_4=0 \wedge d_5=2 \Rightarrow D=4$	1	0.52
7	$d_1=0 \wedge d_2=0 \wedge d_4=0 \wedge d_5=1 \Rightarrow D=5$	1	1.0
8	$d_1=1 \wedge d_2=0 \wedge d_4=0 \wedge d_5=1 \Rightarrow D=6$	1	1.0
9	$d_1=0 \wedge d_2=0 \wedge d_4=0 \wedge d_5=0 \Rightarrow D=1$ OR $D=3$	0.5/0.5	0.64/0.21

使用传统的基于粗糙集分辨矩阵的属性约简算法得到的约简结果为 $\{d_1, d_5, a_5\}$，$\{d_1, d_4, d_5\}$，$\{d_1, d_3, d_5\}$，$\{d_3, d_5, a_5\}$，$\{d_2, d_4, d_5, a_5\}$ 共 5 组。建立的决策信息表拥有诊断规则的数量为 78 条。

最后通过决策信息表中的诊断规则对测试样本进行验证。结果表明：基于粗糙集分辨矩阵的属性约简算法诊断的正确率为 93%，而基于主元模型的启发式属性约简算法诊断的正确率为 91%。从诊断结果看，两种方法都能在保证诊断精度的前提下达到属性约简的要求。但是从约简的结果来看，显然，基于主元模型的启发式约简算法得到的约简结果更简洁、诊断规则更少、实用性更强。

13.1.3　多变量决策树的诊断规则提取方法

上述两种方法在故障诊断过程中虽然都能有效地进行属性约简，但是仅局限在规模小和有限变量的数据信息条件下使用，所以这两种方法不具有普遍性。为解决这一问题本节提出了一种主元分析和粗糙集理论相结合的多变量决策树诊断规则提取方法。该方法利用主元分析和粗糙集理论的特点，能够对规模大、变量多的历史数据进行降维解耦处理，使方法的应用更具有普遍性。

1. 决策树算法

决策树算法是分类发现算法中最常见的一种方法。这种方法在对数据进行处理

的过程中，将数据按树状结构分成若干分枝形成决策树，每个分枝包含数据元组的类别归属共性（相当于分类发现中的类及其特征），从每个分枝中提取有用信息，形成规则。

决策树算法包含许多种不同的算法，主要分为三类：

1）基于统计学理论的方法，以 CART（Classification And Regression Tree，分类回归树）为代表，在这类算法中，对于非终端节点来说，有两个分支。

2）基于信息理论的方法，以 ID3（Interative Dichotomic Version3，交互二分树 3 代）算法为代表，此类算法中，非终端节点的分支由样本类别个数决定。

3）以 AID（Automatic Interaction Detection，自动交互检测）、CHAID（Chi-squared Automatic Interaction Detection，卡方自动交互检测）为代表的算法，在此类算法中，非终端节点的分支数在从两个至样本类别总个数的范围内分布。

这些算法在分类中应用的过程与思路基本上是一致的。ID3 算法是目前有较大影响的一个算法，在故障诊断的决策信息规则提取中有着广泛的应用。包括 ID3 算法在内的大多数决策树的方法仅在每一个节点上检验单个属性，这种决策树被称为单变量决策树。而这种决策树在很多复杂问题的处理和表达上都显得十分困难，而且在测量变量数目较大时，单变量决策树的表达将非常复杂，对规则的提取十分不利。决策树中子树的重复及有些属性在一棵决策树中的某一路径上被多次检验也限制了单变量决策树方法的实际应用。

为了解决上述这些问题，人们提出了多变量归纳学习系统。它是在单变量决策树方法的基础上建立起来的，不同之处是在树的节点上可以同时检验多个变量属性，这种决策树被称为多变量决策树。这种决策系统能够产生新的、更相关的属性，以及修改或去掉初始提供的不相关的属性。

2. 多变量决策树

基于构造多变量决策树的理念，很多研究人员提出了各种方法，其中最广泛的就是基于粗糙集理论的方法，也有人利用主元分析的方法来构造多变量决策树，这些方法的有效性都已得到验证。但是在故障诊断的实际应用中需要处理大规模数据，由于计算复杂度高、运算量大，这些方法的运算很难达到需要的精度，方法的局限性很大，适应性较差。因此，本节提出利用主元分析对历史数据进行降维解耦处理，得到由主元变量组成的决策信息。通过粗糙集理论中核属性和相对泛化的概念对此决策信息进行属性选择和样本集划分，构造出多变量决策树。

（1）属性选择及相对泛化　核属性对决策来说是至关重要的，因此选择核属性作为构造多变量检验的属性，组成核属性的集合。

定义 13-8：设 P 和 Q 是 U 上的两个等价关系族，且 $U/\mathrm{IND}(P)=\{B_1, B_2, \cdots, B_n\}$，$U/\mathrm{IND}(Q)=\{E_1, E_2, \cdots, E_n\}$。令

$$F_i=\bigcup_{B_j\in U/\mathrm{IND}(P)}\{B_j: B_j\subseteq E_i\} \qquad i=1, 2, \cdots, m \tag{13-10}$$

$$F_{m+1}=\bigcup_{B_j\in U/\mathrm{IND}(P)}\{B_j: B_j\not\subset E_i,\ \forall i\} \tag{13-11}$$

则称 $\{F_1, F_2, \cdots, F_{m+1}\}$ 在 U 上确定的等价关系为 P 相对于 Q 的泛化，记作 $\mathrm{GEN}_Q(P)$。$\{F_1, F_2, \cdots, F_{m+1}\}$ 构成了 U 上的一个划分，其中 $F_i(i=1, 2, \cdots, m, m+1)$ 由式（13-10）和式（13-11）定义。

（2）多变量决策树的构造方法及规则提取　本节多变量决策树的构造方法结合了主元分析和粗糙集理论的特点，并将两种方法有效地进行了融合。从主元分析的定义可知：主元变量的信息之间彼此相互独立，利用这样的信息作为特征向量能够去除原始变量间的相关性，并能降低特征向量维数，达到解耦降维的目的。由于运用粗糙集理论处理决策信息时，要求各值用离散值表达，所以主元分析过程得到的连续性数据信息必须进行离散化处理。模糊聚类是一种广泛应用于机器学习与数据挖掘的离散方法，该方法无需用户提供很多先验知识，但是能将用户对研究对象的语言描述习惯与数据处理结合起来。因此本章采用模糊 C 平均（Fuzzy C-Means，FCM）算法对连续属性进行离散化。根据相对核的定义，条件属性集相对于决策属性集的核属性对于制定决策是至关重要的，所以选择相对核中的属性作为构造多变量检验的属性，使用属性的区分能力作为划分度量准则。核属性利用主元变量建立的分辨矩阵来获取。在此基础上，采用相对泛化的概念构造多变量决策树，使得多变量检验并不是被选属性的简单合取，而是导出的一个新属性。

构造方法及规则提取的具体步骤如下：

① 应用主元分析方法建立主元的表达式。

② 提取出可用于分类的主元变量属性集。此属性集表达的矩阵用 $\boldsymbol{Y}$ 表示，其维数为 $m\times k$。

③ 对矩阵 $\boldsymbol{Y}$ 进行 FCM 离散化处理得到 $\boldsymbol{Y}_d$。

④ 利用矩阵 $\boldsymbol{Y}_d$ 中的特征信息及其在原始数据集合中所对应的分类类别构成决策表 DT_m。

⑤ 利用决策表 DT_m 构造的分辨矩阵选择核属性，并确定核属性集。

⑥ 利用粗糙集理论相对泛化的概念构造多变量决策树。

⑦ 从决策树中提取诊断规则。

（3）FCM 聚类算法　此算法最初是由 Jin Bekek 提出，它利用迭代算法来近似得到目标函数的最优值。考虑一个样本集 $\boldsymbol{X}=\{\boldsymbol{x}_1, \boldsymbol{x}_2, \cdots, \boldsymbol{x}_n\}$，其中 $\boldsymbol{x}_i=(x_{i1}, x_{i2}, \cdots, x_{ik})'$ 为一 k 维向量，将此集合依据一定的准则分成 c 个模糊子集，其中 c 是由用户给定的聚类数，聚类的结果用一个聚类中心矩阵和隶属度矩阵来表示：

$$\boldsymbol{V}=(\boldsymbol{v}_1, \boldsymbol{v}_2, \cdots, \boldsymbol{v}_c),\quad \boldsymbol{u}=[u_{ij}]_{i=1,\cdots,c;\,j=1,\cdots,n} \tag{13-12}$$

其中，u_{ij} 为样本 x_j 属于类别 i 的隶属度，u_{ij} 满足：

$$\begin{cases} \sum_{i=1}^{c} u_{ij} = 1 & j = 1, 2, \cdots, n \\ 0 < \sum_{j=1}^{n} u_{ij} < n & i = 1, 2, \cdots, c; i < j \end{cases} \tag{13-13}$$

3. 诊断实例分析

以轴向柱塞泵故障的振动信号实测数据为例进行分析。取 40 组样本数据，表 13-4 为历史数据构成的部分样本决策信息表。

每组样本有 8 个条件属性分别为 d_{30}，d_{31}，…，d_{37}，是由小波包 3 层分解的频带归一化特征能量组成；D 为描述诊断结果的决策属性。各属性表示的含义如表 13-5 所示。

（1）构造由主元变量作为条件属性的决策信息表　首先，对表 13-4 中条件属性对应的数据矩阵进行主元分析。前 5 个主元的贡献率如图 13-2 所示。根据图 13-2贡献率的数值，取累计贡献率 $\eta_k \geqslant 85\%$ 的主元。前 3 个主元 Y_1，Y_2，Y_3的累积贡献率为 89.33%，大于要求的 85% 的取值，所以用这 3 个主元变量对整个信息系统进行描述不会损失太多的信息。

令 $\boldsymbol{Y} = [Y_1, Y_2, Y_3]$，$\boldsymbol{G}$ 表示表 13-4 中各条件属性对应的数据矩阵，维数为 40×8。$\boldsymbol{P}_3$表示前 3 个主元表达式对应的系数矩阵，其维数为 8×3。将矩阵 $\boldsymbol{G}$ 与矩阵 $\boldsymbol{P}_3$相乘得到 $\boldsymbol{Y} = \boldsymbol{G} \times \boldsymbol{P}_3$。由于 Y_1，Y_2，Y_3中每个主元都可以用原始变量 d_{30}，d_{31}，…，d_{37}线性表示，所以数据矩阵 $\boldsymbol{Y}$ 与表 13-4 中的决策值一一对应。由此建立由主元作为条件属性的决策信息表。

表 13-4　部分样本信息表

样本	d_{30}	d_{31}	d_{32}	d_{33}	d_{34}	d_{35}	d_{36}	d_{37}	D
1	0.1083	0.1494	0.1261	0.1716	0.0968	0.1084	0.1124	0.1270	1
2	0.1125	0.1558	0.1278	0.1825	0.0958	0.1044	0.1041	0.1171	1
3	0.1167	0.1530	0.1345	0.1572	0.1052	0.0907	0.1100	0.1326	1
4	0.1563	0.1067	0.1452	0.1237	0.1080	0.1277	0.1225	0.1098	2
5	0.1541	0.1084	0.1413	0.1257	0.1048	0.1286	0.1254	0.1119	2
6	0.1768	0.1718	0.1250	0.1507	0.0815	0.0886	0.1068	0.0987	3
7	0.1698	0.1628	0.1242	0.1575	0.0866	0.0905	0.1043	0.1044	3
8	0.1743	0.1320	0.1117	0.1420	0.1044	0.1071	0.1088	0.1196	4
9	0.1666	0.1421	0.1110	0.1356	0.1002	0.1102	0.1091	0.1252	4
10	0.1085	0.1504	0.1180	0.1815	0.1002	0.1037	0.1136	0.1241	5

表 13-5　符号说明

符　号	说　明	符　号	说　明
d_{30}	0 ~ 125Hz	d_{37}	875 ~ 1000Hz
d_{31}	125 ~ 250Hz	D	决策属性
d_{32}	250 ~ 375Hz	$D(1)$	滑靴磨损
d_{33}	375 ~ 500Hz	$D(2)$	单柱塞松靴
d_{34}	500 ~ 625Hz	$D(3)$	单柱塞脱靴
d_{35}	625 ~ 750Hz	$D(4)$	中心弹簧失效
d_{36}	750 ~ 875Hz	$D(5)$	正常状态

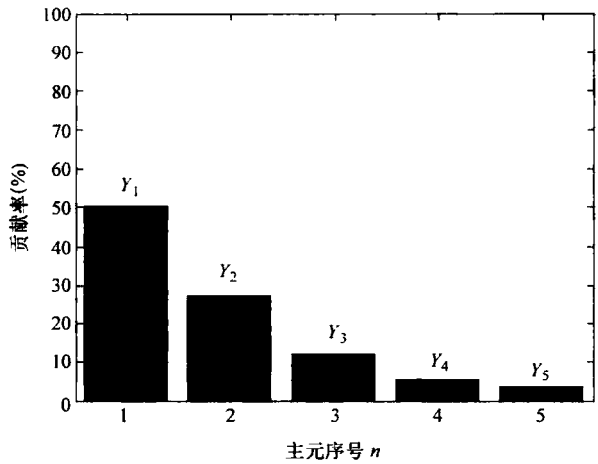

图 13-2　前 5 个主元贡献率

对该表进行 FCM 算法的离散化处理。定义“低、中、高、很高”4 个语言变量对主元属性的数值型变量进行描述，输入的聚类数为 4，其中 0—低、1—中、2—高、3—很高。离散化后去掉重复信息得到数据矩阵 $\boldsymbol{Y}_d$，其决策信息用 DT_m 表示，见表 13-6。

表 13-6　主元表示的决策信息表

样本	Y_1	Y_2	Y_3	D	样本	Y_1	Y_2	Y_3	D
1	1	1	3	1	6	3	1	2	2
2	0	1	3	1	7	3	1	3	2
3	1	0	2	1	8	2	3	3	3
4	1	1	2	1	9	1	3	3	3
5	0	0	1	1	10	1	3	2	3

（续）

样本	Y_1	Y_2	Y_3	D	样本	Y_1	Y_2	Y_3	D
11	2	2	1	3	15	2	2	0	4
12	2	1	0	3	16	0	0	2	5
13	2	2	2	3	17	0	1	3	5
14	2	3	2	3	18	0	1	2	5

（2）利用相对泛化的概念构造多变量决策树　根据粗糙集中核属性的概念，通过表 13-6 得到条件属性 $\boldsymbol{Y}$ 关于决策属性 D 的核属性集合为 $\{Y_1, Y_2, Y_3\}$。

利用相对泛化的概念，令 $\boldsymbol{M}=Y_1 \wedge Y_2 \wedge Y_3$，采用式（3-10）和式（3-11）可以算出 $\boldsymbol{M}$ 相对于 D 的泛化在 U 上导出的划分为

$$\mathrm{GEN}_D(\boldsymbol{M})=\{\{1,3,4,5\},\{6,7\},\{8,9,10,11,12,13,14\},\{15\},\{16,18\},\{2,17\}\}$$

由于划分与属性之间存在一一对应关系，所以此划分唯一确定 U 上的一个新属性，即构造的多变量检验 $\mathrm{GEN}_D(\boldsymbol{M})$。以 $\mathrm{GEN}_D(\boldsymbol{M})$ 作为决策树的根，根据上面的划分构造多变量决策树如图 13-3 所示。

① $\rightarrow\{(Y_1=1 \wedge Y_2=0 \wedge Y_3=2) \vee (Y_1=1 \wedge Y_2=1 \wedge Y_3=2) \vee (Y_1=0 \wedge Y_2=0 \wedge Y_3=1)\}$

② $\rightarrow\{(Y_1=3 \wedge Y_2=1 \wedge Y_3=2) \vee (Y_1=3 \wedge Y_2=1 \wedge Y_3=3)\}$

③ $\rightarrow\left\{\begin{array}{l}(Y_1=2 \wedge Y_2=3 \wedge Y_3=3) \vee (Y_1=1 \wedge Y_2=3 \wedge Y_3=3) \vee (Y_1=1 \wedge Y_2=3 \wedge Y_3=2) \\ \vee (Y_1=2 \wedge Y_2=2 \wedge Y_3=1) \vee (Y_1=2 \wedge Y_2=1 \wedge Y_3=0) \vee (Y_1=2 \wedge Y_2=2 \wedge Y_3=2) \\ \vee (Y_1=2 \wedge Y_2=3 \wedge Y_3=2)\end{array}\right\}$

④ $\rightarrow\{(Y_1=2 \wedge Y_2=2 \wedge Y_3=0)\}$

⑤ $\rightarrow\{(Y_1=0 \wedge Y_2=0 \wedge Y_3=2) \vee (Y_1=0 \wedge Y_2=1 \wedge Y_3=2)\}$

⑥ $\rightarrow\{(Y_1=0 \wedge Y_2=1 \wedge Y_3=3)\}$

其中，1—滑靴磨损，2—单柱塞松靴，3—单柱塞脱靴，4—中心弹簧失效，5—正常状态。诊断决策规则信息表如表 13-7 所示。

（3）结果分析　从图 13-3 可以看出，此多变量决策树具有简单、易懂、复杂度低、可观性强，易于提取诊断规则的特点。数据从规模和数量上都得到了很好的挖掘，取得了大量数据中最为关键的知识，为液压泵振动故障的判断提供了简洁而直接的表达。最后对 20 个测量样本进行分析，诊断结果中有两个样本产生错误，其故障识别率为 90%，由此证明利用该方法对诊断规则进行提取是有效的。

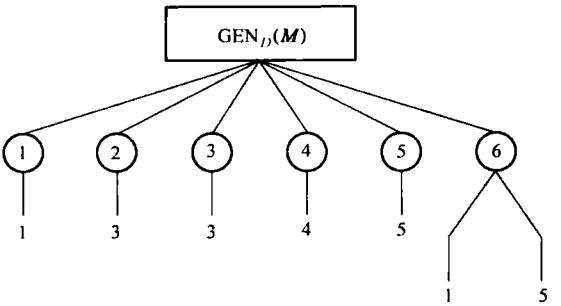

图 13-3　多变量决策树

表 13-7　诊断决策规则表

序　号	规　则
1	$Y_1=1 \wedge Y_2=0 \wedge Y_3=2 \Rightarrow DEC(1)$
2	$Y_1=1 \wedge Y_2=1 \wedge Y_3=2 \Rightarrow DEC(1)$
3	$Y_1=0 \wedge Y_2=0 \wedge Y_3=1 \Rightarrow DEC(1)$
4	$Y_1=3 \wedge Y_2=1 \wedge Y_3=2 \Rightarrow DEC(2)$
5	$Y_1=3 \wedge Y_2=1 \wedge Y_3=3 \Rightarrow DEC(2)$
6	$Y_1=2 \wedge Y_2=3 \wedge Y_3=3 \Rightarrow DEC(3)$
7	$Y_1=1 \wedge Y_2=3 \wedge Y_3=3 \Rightarrow DEC(3)$
8	$Y_1=1 \wedge Y_2=3 \wedge Y_3=2 \Rightarrow DEC(3)$
9	$Y_1=2 \wedge Y_2=2 \wedge Y_3=1 \Rightarrow DEC(3)$
10	$Y_1=2 \wedge Y_2=1 \wedge Y_3=0 \Rightarrow DEC(3)$
11	$Y_1=2 \wedge Y_2=2 \wedge Y_3=2 \Rightarrow DEC(3)$
12	$Y_1=2 \wedge Y_2=3 \wedge Y_3=2 \Rightarrow DEC(3)$
13	$Y_1=2 \wedge Y_2=2 \wedge Y_3=0 \Rightarrow DEC(4)$
14	$Y_1=0 \wedge Y_2=0 \wedge Y_3=2 \Rightarrow DEC(5)$
15	$Y_1=0 \wedge Y_2=1 \wedge Y_3=2 \Rightarrow DEC(5)$
16	$Y_1=0 \wedge Y_2=1 \wedge Y_3=3 \Rightarrow DEC(1)$ OR $DEC(5)$

13.2　单传感器多特征信息融合的贝叶斯网络故障诊断方法

本节首先介绍多传感器信息融合技术，对各种融合方法进行阐述，重点讨论基于贝叶斯参数估计的信息融合方法。针对液压泵故障特征信息不完备性的特点，提出利用贝叶斯参数估计算法对单振动传感器多故障特征向量进行信息融合以增加特征信息的完备性。介绍贝叶斯网络的概念，讨论贝叶斯网络的几种构造方法并给出相应的贝叶斯网络分类器的数学模型。贝叶斯网络的并行推理方式不仅能够提高诊断速度，而且能够消除故障特征信息模糊性的影响。因此，针对液压泵故障特征信息模糊性的特点，将朴素贝叶斯网络引入到故障诊断过程中，来简化信息融合故障诊断模型。最后通过简化后的故障诊断模型计算最大后验概率估计值进行故障识

别。经过对轴向柱塞泵多种形式松靴故障的振动信号进行分析和诊断，验证该方法的有效性。

13.2.1 多传感器信息融合技术

1. 信息融合的融合结构

多传感器信息融合，主要是指利用计算机进行多源信息处理，从而得到可综合利用多源信息的理论和方法，其中也包含对人和动物大脑进行多传感器信息融合机理的探索。信息融合研究的关键问题，就是提出一些理论和方法，对具有相似或不同特征模式的多源信息进行处理，以获得具有相关和集成特性的融合信息。这里所说的传感器也是广义的，不仅包括物理上的各种传感器系统，也包括与观测环境匹配的各种信息获取系统。信息融合可以提高一个具有多个传感器的检测系统的性能，减少全体或单个传感器检测信息的损失。其结构有串行、并行和混合融合三种形式，如图 13-4 所示。

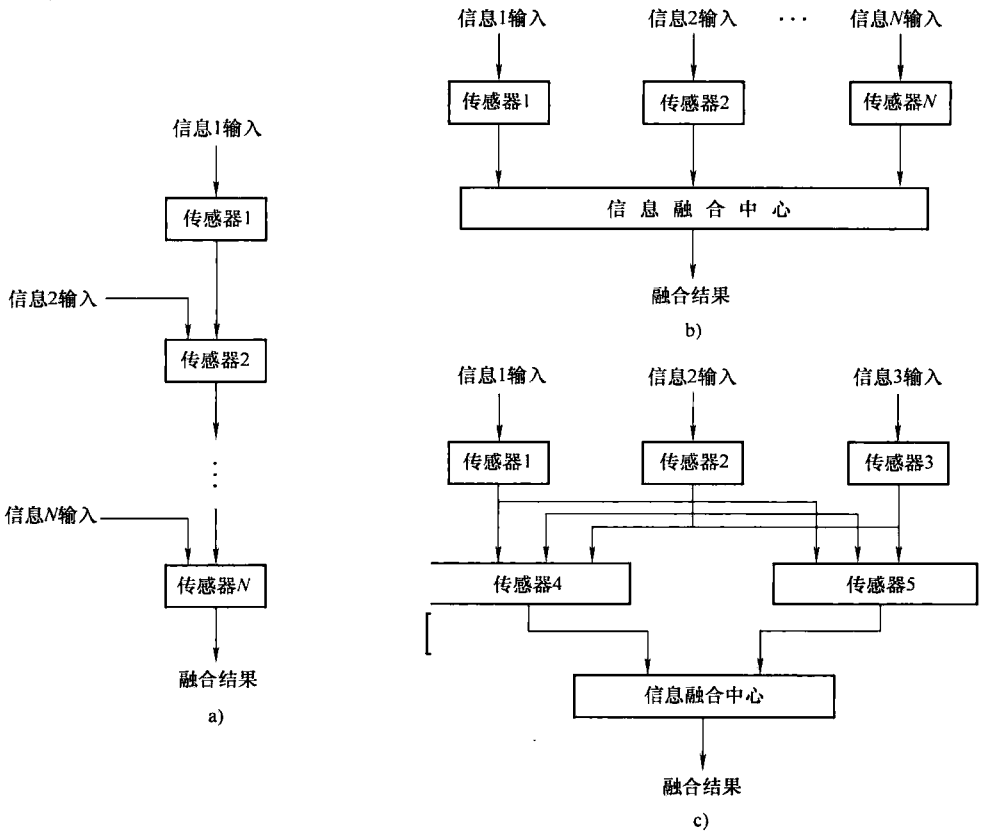

图 13-4 多传感器信息融合的结构形式

a）串行融合 b）并行融合 c）混合融合

由图可见，串行融合时，当前传感器要接收前一级传感器的输出结果，每个传感器既有接收信息和处理信息的功能，又有信息融合的功能。因此，串行融合时，前级传感器的输出对后级传感器输出的影响较大。最后一个传感器综合了所有前级传感器输出的信息，得到的输出将作为串行融合系统的结论。

并行融合时，各个传感器直接将各自的输出信息传输到信息融合中心，传感器之间没有影响，融合中心对各信息按适当方法综合处理后，输出最终结果。由于简单的串行融合会提高特征空间的维数，降低识别的速度，所以目前并行融合形式是故障诊断领域中应用最广泛的信息融合结构。

混合融合形式是串行和并行融合形式的结合，或总体串行，局部并行；或总体并行，局部串行。

2. 信息融合的方法

信息融合方法可分为两大类：一是随机类方法，二是人工智能方法。

（1）随机类方法　经典的统计和推理方法包括贝叶斯推理、D-S 证据理论等。贝叶斯推理方法解决了传统推理方法的某些缺点，它把每个传感器看做是一个贝叶斯估计器，用于将每一个目标各自的关联概率分布综合成一个联合后验分布函数，然后随观测值的到来，不断更新假设的该联合分布的似然函数，并通过该似然函数的极大或极小值进行信息的最后融合。D-S 证据理论是贝叶斯推理的扩充，在多传感器目标识别、军事指挥和控制等方面得到广泛的应用。模糊推理方法是应用模糊理论建立的模糊数据关联算法，尤其是在决策级信息融合中起到重要的作用。聚类分析是一种分类算法，它根据事先给定的相似标准，把观测值分为类，也可以分为等级。这对真假目标分类、航迹起始和目标属性判别是十分必要的。估计理论是信息融合与跟踪的基本理论，主要有经典估计理论（如最大似然估计，贝叶斯估计等）和最优估计理论（如卡尔曼滤波器，鲁棒估计等）两种理论。熵法用熵概念计算与假设有关的信息内容度量值，在对采用经验或主观概率进行备选假设估计的系统中有广泛的应用。品质因数算法是根据观测数据和先验加权系数计算两个观测实体之间的相似度的方法，这种方法经常用于关联和自关联方案中，其优点是对环境变化不敏感。

（2）人工智能方法　专家系统作为人工智能的一个应用分支，在信息融合系统中得到广泛应用。近几年来神经网络在多传感器信息融合研究中也受到了高度重视。随着人工智能技术的进步，新的信息融合方法将不断推出，推动信息融合技术的发展。相信在不久的将来，信息融合技术一定能渗透到各领域中获得广泛应用，为社会创造价值。

13.2.2　基于贝叶斯参数估计算法的信息融合数学模型

该方法是在贝叶斯公式的基础上，由 N 个传感器得到的测量值 X_1，X_2，…，

X_N，按照某种估计准则函数，从 X_1，X_2，…，X_N 中估计出状态 Y 的真实值，从而得到信息融合的结果。

设某一时刻被测样本的状态为 $Y=\{Y_1, Y_2, \cdots, Y_m\}$，传感器的 n 个特征信息的特征值为 $X=\{X_1, X_2, \cdots, X_n\}$，则此特征信息的测量模型是

$$X=f(Y)+v \tag{13-14}$$

其中，$f(Y)$ 是 X 与 Y 的函数关系；v 是随机噪声。

该信息融合算法是由 n 个传感器得到的测量值 X_1，X_2，…，X_n，按照某种估计准则函数 $Z(X)$，从 X_1，X_2，…，X_n 中估计出状态 Y 的真实值。

以下为故障诊断系统信息融合算法中单个传感器特征信息的估计值计算过程。

设其特征值为 X_i，状态 Y 的估计值为 $\hat{Y}(X_i)$，并定义 $L[\hat{Y}(X_i), Y]$ 为损失函数。根据贝叶斯估计，相应的损失函数的期望值，即风险表达式为

$$R=E\{L[\hat{Y}(X_i), Y]\}=\int \mathrm{d}X_i \cdot P(X_i)\int \mathrm{d}Y \cdot P(Y \mid X_i)L[\hat{Y}(X_i), Y] \tag{13-15}$$

其中，$P(X_i)$ 是特征信息的分布概率；$P(Y \mid X_i)$ 是状态 Y 的后验概率。

取风险最小的估计准则，必须使

$$\left.\frac{\partial R}{\partial Y}\right|_{Y=\hat{Y}(X_i)}=0 \tag{13-16}$$

依据式（13-16）建立的准则，单个传感器特征信息的最大后验概率估计值为

$$\hat{Y}_{opt}(X_i)=\max_{\hat{Y}} P(Y \mid X_i) \tag{13-17}$$

在系统中再加入 $n-1$ 个独立的传感器后，最大后验概率估计值的算法与单个传感器时是一致的。因此，n 个传感器特征信息的融合值为

$$\hat{Y}_{opt}(X_1, X_2, \cdots, X_n)=\max_{\hat{Y}} P(Y \mid X_1 X_2 \cdots X_n) \tag{13-18}$$

至此，多传感器信息融合问题就转化为如何得到状态 Y 的后验概率 $P(Y \mid X)$ 的问题，并找到相应的最大后验估计值。

13.2.3 贝叶斯网络

1. 贝叶斯网络的表示

贝叶斯网络（Bayesian Network）是一种概率网络，它是基于概率推理的图形化网络，而贝叶斯公式则是这个概率网络的基础。贝叶斯网络是基于概率推理的数学模型，所谓概率推理就是通过一些变量的信息来获取其他概率信息的过程，基于概率推理的贝叶斯网络是为了解决不确定性和不完整性问题而提出的，它在解决复杂设备不确定性和关联性引发的故障的诊断方面有很大的优势，在多个领域中获得了广泛应用。

贝叶斯网络是贝叶斯方法与图形理论的有机结合。是用有向无环图来表示随机变量的因果关系，通过条件概率将这种关系数量化。贝叶斯网络可以用一个二元组 $B=(G, \theta)$ 表示。其中 G 是有向无环图，是对特征间依赖关系的定性说明，由一系列节点和从父节点指向子节点的有向边构成。节点对应于问题中的特征，有向边表示特征间依赖关系，没有有向边相连接的节点表示特征间条件独立。θ 是描述网络布局条件概率的参数集合，定量地表示了各特征与其父节点的依赖关系。

从定性的角度，贝叶斯网络中的有向边表示直接的因果关系。因此，贝叶斯网络能表达和解释那些相关关系无法表示和处理的模式。从定量的角度，贝叶斯网络是概率信息的载体，是联合概率分布的图形表示方式。贝叶斯网络的一个关键作用是提供了一种把联合概率分布分解为局部分布的方法。它利用图形结构表达了变量间的概率依赖关系，具有清晰的独立性语义特征，指明了如何组合这些局部分布来计算变量间联合分布的方法。网络的定量部分给出了变量间不确定性的数值度量。

假定一个有限离散随机变量集合 $X=\{X_1, X_2, \cdots, X_n\}$，其中 $X_1, X_2, \cdots, X_n$ 表示领域变量，对应于网络的各节点。贝叶斯网络 B 所描述的 X 上的联合概率分布可以由下式唯一确定

$$P(X)=\prod_{i=1}^{n} P(X_i \mid C_i) \tag{13-19}$$

其中，C_i 为 X_i 父节点的集合。

这样做的优点是：由于在一个由多变量组成的贝叶斯网络中，变量间交互作用的关系是稀疏的，这种局部概率分布能指数级地降低联合分布的复杂度；存在许多适合于局部分布的贝叶斯推理算法；贝叶斯网络中的定量表示与定性表示的分离有利于知识工程的建模。

2. 贝叶斯网络的构建

贝叶斯网络构建步骤为：

1）确定各故障模式和特征向量与网络节点的对应关系。

2）建立表征条件独立的有向无环图。概率乘法公式为

$$P(X)=\prod_{i=1}^{n} P(X_i \mid X_1 X_2 \cdots X_{i-1}) \tag{13-20}$$

利用式（13-20）可推导出式（13-19）。

3）确定节点概率分布参数。

现在通过一个示例说明贝叶斯网络的构建过程。假设给定特征集合 $U=\{X_1, X_2, X_3, X_4, X_5, Y\}$，$Y$ 为故障类型集。依据贝叶斯网络的构建步骤建立特征间的贝叶斯网络。各节点的条件概率如图 13-5 所示。

通过此示例可以看出，构建贝叶斯网络的同时也相应地得到了网络中每个节点的条件概率。贝叶斯网络构建后，故障诊断的过程就转化成贝叶斯网络逆向推理的过程，即利用已知征兆信息去计算故障原因的概率信息。

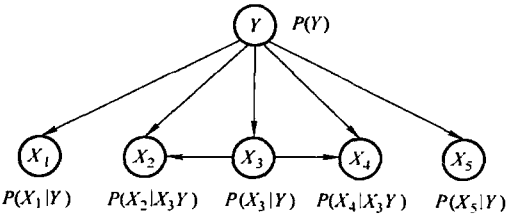

图 13-5 贝叶斯网络结构

13.2.4 贝叶斯网络分类器

1. 贝叶斯分类器

贝叶斯分类器是一种典型的基于统计方法的分类模型。它以贝叶斯定理为理论基础，巧妙地将事件的先验概率与后验概率联系起来，利用先验信息和样本数据确定事件的后验概率。即某个对象属于某一类的概率，选择具有最大后验概率的类作为该对象所属的类。

根据贝叶斯公式，$X=\{X_1, X_2, \cdots, X_n\}$ 属于类 Y_j的概率为

$$P(Y_j \mid X_1X_2\cdots X_n)=\frac{P(X_1X_2\cdots X_n \mid Y_j)P(Y_j)}{P(X_1X_2\cdots X_n)}=\alpha P(Y_j)P(X_1X_2\cdots X_n \mid Y_j) \tag{13-21}$$

其中，$\alpha=1/P(X_1X_2\cdots X_n)$，定义为正则化因子；$P(Y_j)$ 为类 Y_j的先验概率，即根据以往的数据分析得到的类 Y_j发生的概率；$P(Y_j \mid X_1X_2\cdots X_n)$为类 Y_j的后验概率，即得到某些信息后重新修正的类 Y_j发生的概率，后验概率反映了样本数据对类 Y_j的影响。式（13-21）还可以表示为

$$P(Y_j \mid X_1X_2\cdots X_n)=\alpha\prod_{i=1}^{n}P(X_i \mid X_1X_2\cdots X_{i-1}Y_j) \tag{13-22}$$

以贝叶斯最大后验概率为准则，对给定的 $X=\{X_1, X_2, \cdots, X_n\}$，贝叶斯分类器选择使后验概率 $P(Y_j \mid X_1X_2\cdots X_n)$ 最大的类 Y_j为 X 的类标签。因此，贝叶斯分类器的关键是如何计算 $P(X_i \mid X_1X_2\cdots X_{i-1}Y_j)$，各类贝叶斯分类器的区别就在于求取 $P(X_i \mid X_1X_2\cdots X_{i-1}Y_j)$ 值的方式不同。

2. 贝叶斯网络分类器的分类

目前研究较多的贝叶斯网络分类器主要有三种，分别是朴素贝叶斯网络(Naive Bayesian Network，NBN）分类器、树形增强朴素贝叶斯网络（Tree Augmented Naive Bayesian Network，TAN）分类器、增强的贝叶斯网络（Bayesian Network Augmented Naive Bayesian，BAN）分类器。

（1）NBN 分类器 NBN 分类器假定属性变量间相互类条件独立，每个属性节点 X_i只与类节点 Y 相关联，这种假设降低了贝叶斯网络构建的复杂性。因此

(13-22)又可以表示为

$$P(Y_j \mid X_1X_2\cdots X_n) = \alpha\prod_{i=1}^{n} P(X_i \mid Y_j) \tag{13-23}$$

NBN 分类器属于两层贝叶斯网路，仅含一个父节点（代表类变量），其余为子节点（代表属性变量）。NBN 分类器模型如图 13-6 所示。

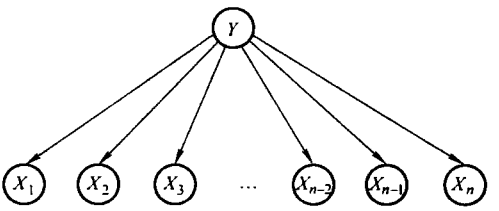

图 13-6　NBN 分类器模型

（2）TAN 分类器　TAN 分类器是 NBN 分类器基础上的一种改进模型，它假定属性变量间的关系符合限定性树状结构，放松了 NBN 中属性变量间条件独立的假定，每一个属性都将类属性作为父节点，每一个属性除了类属性外最多只有一个其他的父节点，具有较好的综合性能，体现了学习效率与分类精度之间的一种适当的折中。因此，式（13-22）在 TAN 分类器中可以表示为

$$P(Y_j \mid X_1X_2\cdots X_n) = \alpha\prod_{i=1}^{n} P(X_i \mid \text{Parent}(X_i)) \tag{13-24}$$

其中 Parent（X_i）为 X_i的父节点集。

建立 TAN 分类器首先根据（13-25）计算属性对的互信息，建立以 $I_p(X_iX_j \mid Y)$ 为边权重的加权无向图。

$$I_p(X_iX_j \mid Y) = \sum_{X_i,X_j,Y} P(X_iX_jY)\lg\frac{P(X_iX_jY)}{P(X_i \mid Y)P(X_j \mid Y)} \tag{13-25}$$

其次，由无向图建立最大权重跨度树，选择一个根节点，设置所有边的方向为由根节点向外，将无向图转化为有向图；增加类变量节点和由类变量节点到各属性节点之间的边；最后学习条件概率参数，完成该模型的建立。TAN 分类器示例如图 13-7 所示。

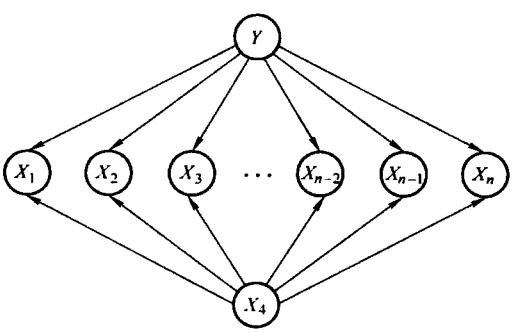

图 13-7　TAN 分类器模型

（3）BAN 分类器　BAN 分类器是朴素分类器的一种改进模型，其基本思想是放松朴素贝叶斯的条件独立性假设，并取消了 TAN 分类器

有关属性变量之间必须符合限定性树状结构的要求，借鉴贝叶斯网络中表示依赖关系的方法，扩展朴素贝叶斯的结构，使其能容纳属性间存在的依赖关系，但对其表示依赖关系的能力加以限制。

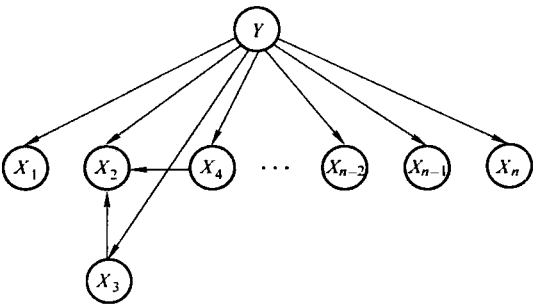

图 13-8 BAN 分类器模型

BAN 分类器是增强的朴素贝叶斯分类器，它使属性之间的关系不止局限于树形，而是任意的贝叶斯网络。以类节点为根节点的贝叶斯网络，建立 BAN 分类器算法，它和 TAN 分类器算法的区别在于分类器中添加的每条边都需要通过测度检验。类属性是每个属性的父节点，类属性外的每个属性可以构成任意的贝叶斯网络。BAN 分类器模型示例如图 13-8 所示。

3. 贝叶斯网络分类器

针对液压泵故障特征信息不完备性和模糊性的特点，以及故障诊断方法在实际工程应用中必须满足准确性和快速性的条件。提出了多特征信息融合和贝叶斯网络相结合的故障诊断方法。该方法利用单振动传感器采集的泵端盖振动信号提取幅值域和时频域的多域故障特征，根据多传感器信息融合的广义定义，将来自单传感器的多域故障特征当做来自多个不同传感器的多源信息。利用贝叶斯参数估计算法进行多特征信息融合，通过构造贝叶斯网络分类器简化融合结果，通过计算最大后验概率估计值进行故障识别。

（1）诊断方法的实现过程　根据对轴向柱塞泵故障振动机理的分析，制定故障诊断方法验证的流程如图 13-9 所示。其诊断方法实现的步骤如下：

1）对柱塞泵脱靴故障数据及松靴故障数据进行整理，分别选择一种故障振动信号用于本节诊断方法的验证。

2）对选择的信号进行小波消噪处理得到有用信号。

3）提取幅值域和小波包分解的时频域特征信息并进行 FCM 算法的聚类离散化处理。

4）根据多传感器信息融合的广义定义，利用贝叶斯参数估计算法对故障特征信息进行多特征信息融合，得到最大后验估计值的计算公式。

5）运用训练样本根据贝叶斯网络的构建过程，通过 NBN 分类器确定故障特征信息与故障模式之间的关系。

6）利用建立的 NBN 分类器简化最大后验估计值公式，得到该方法的故障诊断模型。

7）通过测试样本验证故障诊断模型的有效性并完成诊断。

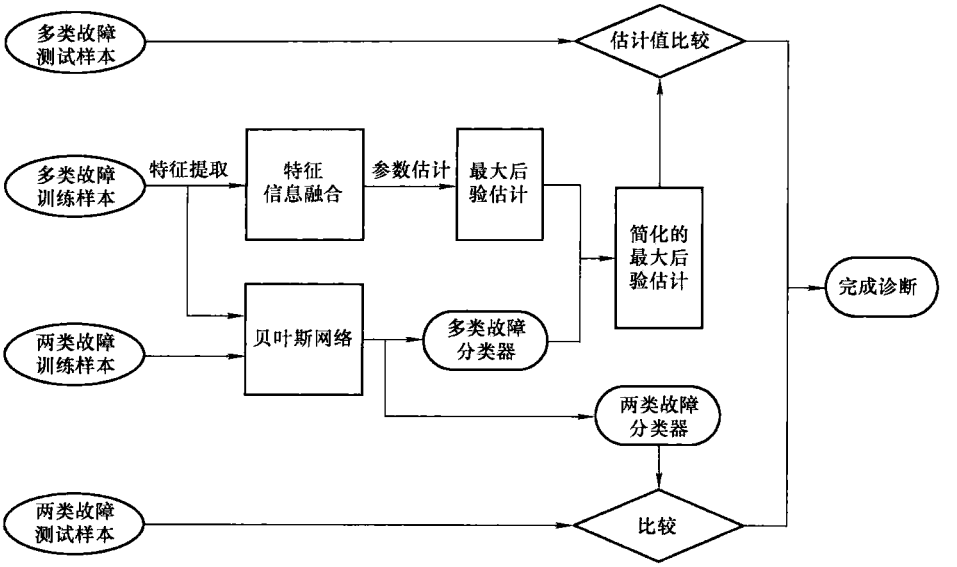

图 13-9　贝叶斯网络故障诊断流程图

（2）贝叶斯网络分类器的设计　下面基于上述故障诊断方法，设计了两种分类器。在对两种故障模式的分类识别诊断中，给出了判别函数并利用 NBN 分类器简化了判别函数。在多故障模式的故障诊断中，选用 NBN 分类器来简化信息融合最大后验概率估计值公式并建立故障诊断模型。

1）两种故障模式识别的分类器：设 $\boldsymbol{Y}_l=(Y_1,\ Y_2)$，$\boldsymbol{X}=\{X_1,\ X_2,\ \cdots,\ X_N\}$。其中 $\boldsymbol{Y}_l$ 表示故障模式类别，$\boldsymbol{X}$ 表示特征向量空间。

① 定义判别函数为

$$g(\boldsymbol{X})=g_1(\boldsymbol{X})-g_2(\boldsymbol{X}) \tag{13-26}$$

将分类规则表示为 $g(\boldsymbol{X})>0$ 属于 Y_1 类；$g(\boldsymbol{X})<0$ 属于 Y_2 类；$g(\boldsymbol{X})=0$ 表示的是分类决策面方程，$\boldsymbol{X}$ 为 n 维空间时，决策面为 n 维超平面，满足此方程则为故障误判。

式（13-26）中

$$\begin{cases} g_1(\boldsymbol{X})=P(Y_1\mid\boldsymbol{X})P(\boldsymbol{X}) \\ g_2(\boldsymbol{X})=P(Y_2\mid\boldsymbol{X})P(\boldsymbol{X}) \end{cases} \tag{13-27}$$

构建 NBN 分类器简化式（13-27）得

$$\begin{cases} g_1(\boldsymbol{X})=P(Y_1)\prod\limits_{i=1}^{n}P(X_i\mid Y_1) \\ g_2(\boldsymbol{X})=P(Y_2)\prod\limits_{i=1}^{n}P(X_i\mid Y_2) \end{cases} \tag{13-28}$$

② 两种故障模式的分类器可以看作只是计算判别函数 $g(\boldsymbol{X})$ 的一个“机器”，它根据计算结果符号对 $\boldsymbol{X}$ 分类。

2）多种故障模式识别的分类器：设 $\boldsymbol{Y}_k = \{Y_1, Y_2, \cdots, Y_m\}$，$\boldsymbol{X} = \{X_1, X_2, \cdots, X_n\}$，对提取的故障特征进行信息融合后，将式（13-22）代入式（13-18）中得到融合后的最大后验概率估计值的计算公式

$$\hat{Y}_{opt}(X_1, X_2, \cdots, X_n) = \alpha \max_{\hat{Y}} \left[\prod_{i=1}^{n} P(X_i \mid X_1 X_2 \cdots X_{i-1} \boldsymbol{Y}_k) \right] \tag{13-29}$$

由此采用 NBN 分类器，假定特征向量间相互条件独立，每个属性节点 X_i 与故障类节点 $\boldsymbol{Y}_k$ 相关联，这种假定降低了贝叶斯网络构建的复杂性。因此通过构造 NBN 分类器可以使式（13-29）表示为

$$\hat{Y}_{opt}(X_1, X_2, \cdots, X_n) = \alpha \max_{\hat{Y}} \left[\prod_{i=1}^{n} P(X_i \mid \boldsymbol{Y}_k) \right] \tag{13-30}$$

由此可知，式（13-30）是信息融合与贝叶斯网络相结合的推理结果。通过式（13-30）计算出最大后验概率估计值，相对应的 Y_j 类为诊断后得出的故障类型。

13.2.5 液压泵振动信号的故障诊断分析

下面对液压泵故障振动信号进行诊断分析，验证多域特征信息融合贝叶斯网络的故障诊断方法的有效性。采集脱靴故障和松靴故障条件下的振动信号数据，采样频率为 1000Hz，每次采集时间为 1s。被诊对象是 MCY14-1B 型轴向柱塞泵。脱靴故障实验将主溢流阀压力设置为 5MPa，而松靴故障实验则将主溢流阀压力设置为 15MPa。

1. 两种模式的故障诊断

第 1 次故障识别分析。对轴向柱塞泵单柱塞脱靴故障和正常工作状态两种模式进行故障诊断。先对原始振动信号选用 db5 小波进行 3 层分解阈值消噪处理以提高信噪比，再选用 db5 小波包进行 3 层分解，提取出各子频带归一化能量信息表示的特征向量。从采样频率可知分析频率为 500Hz，分解系数对应的各子频带频率范围如表 13-8 所示。

表 13-8 分解系数对应的频带

系 数	频带/Hz	系 数	频带/Hz
d_{30}	0 ~ 62.5	d_{34}	250 ~ 312.5
d_{31}	62.5 ~ 125	d_{35}	312.5 ~ 375
d_{32}	125 ~ 187.5	d_{36}	375 ~ 437.5
d_{33}	187.5 ~ 250	d_{37}	437.5 ~ 500

提取 110 组数据作为实验样本，60 组为训练样本（30 组正常样本，30 组故障样本），50 组为测试样本（30 组正常样本，20 组故障样本），将全部样本数据利用 FCM 算法进行聚类离散化处理。用训练样本构造贝叶斯网络，其网络结构如图 13-10所示，由此构造 NBN 分类器。正常状态用 Y_1 表示，脱靴故障用 Y_2 表示。

利用其中一个离散化后的测试样本 $\boldsymbol{X}=\{0,0,1,2,2,2,1,1\}$ 说明诊断过程。定义“低、中、高”三个语言变量对原始数据中数值型变量进行描述，其中 0-低、1-中、2-高。两种故障模式的先验概率取为 $P(Y_1)=0.8$，$P(Y_2)=0.2$，其条件概率 $P(d_{3i}\mid Y_j)$（$i=0,1,\cdots,7$；$j=1,2$)的值，见表 13-9。

将得出的结果带入式（13-26）中得到 $g(\boldsymbol{X})=g_1(\boldsymbol{X})-g_2(\boldsymbol{X})=5.57\times10^{-6}>0$，由此判断此样本为正常样本，诊断结果与测试样本的状态类别相吻合。

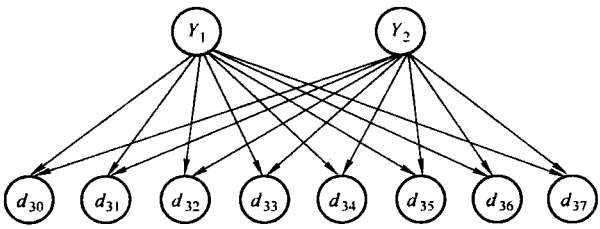

图 13-10　两类故障的贝叶斯网络

重复上述过程对测试样本进行逐一验证，结果正常样本共 28 个诊断正确，确诊率为 93.3%。故障样本有 19 个诊断正确，确诊率为 95%。总体的诊断正确率为 94.0%。这说明在只有两种故障模式的条件下，单从小波包分解的时频域方面提取振动信号的故障特征通过贝叶斯网络就能准确地诊断故障。

表 13-9　各特征向量的条件概率

编号	d_{30}	d_{31}	d_{32}	d_{33}	d_{34}	d_{35}	d_{36}	d_{37}
Y_1	0.20	0.25	0.35	0.05	0.25	0.33	0.38	0.26
Y_2	0.03	0.23	0.53	0.15	0.3	0.25	0.10	0.17

2. *增加故障模式后的故障诊断*

第 2 次故障识别分析。将故障模式增加到了 6 个，使用多故障模式识别的分类器进行故障诊断。其故障类型见表 13-10。

表 13-10　故障类型集

编　号	故障类型	编　号	故障类型
Y_1	正常状态	Y_4	3 个柱塞松靴
Y_2	1 个柱塞松靴	Y_5	4 个柱塞松靴
Y_3	2 个柱塞松靴	Y_6	5 个柱塞松靴

提取360组数据作为试验样本，其中240组为训练样本（每种故障类型有40组样本），120组为测试样本（每种故障类型有20组样本）。采用特征提取方法并利用多故障模式贝叶斯分类器故障诊断方法进行分析，中间计算过程略去，得到的诊断结果见表13-11。

从表13-11中可以看出，增加故障模式后故障诊断的正确率明显下降。但是随着松靴柱塞数量的增加，诊断的正确率有显著上升的趋势。这说明松靴柱塞数量越多，故障与正常振动信号的时频域特征区别越大。从以上分析结果说明，单从小波包分解的时频域角度提取故障特征信息存在明显的不完备性，综合故障确诊率低。当故障程度较大时，虽然有故障特征模糊性的影响，但是贝叶斯网络的故障诊断方法仍然能得到较高的确诊率，这充分说明贝叶斯网络方法能够有效地消除故障特征模糊性的影响。

表13-11 各故障模式的诊断结果

故障类型	样本数	诊断正确数	确诊率
Y_1	20	6	30.0%
Y_2	20	4	20.0%
Y_3	20	6	30.0%
Y_4	20	7	35.0%
Y_5	20	11	55.0%
Y_6	20	12	60.0%

3. *增加特征信息的多模式故障诊断*

第3次故障识别分析。由于单从时频域角度提取的特征信息存在明显的不完备性，使得第2次分析的诊断结果过低，所以本次识别分析时通过增加幅值域特征来提高特征信息的完备性。利用第2次分析同样的分析条件，首先对采集的振动信号利用db5小波进行3层分解并阈值消噪处理；然后从消噪后的振动信号中提取小波包分解的时频域和幅值域参数共13个特征信息，将这些信息当做来自多个传感器的多源信息，通过贝叶斯参数估计算法将多源信息进行有效的融合，融合过程如图13-11所示。

小波包分解得到归一化各子频带能量值表示的时频域特征信息从低频子带到高频子带依次表示为 $d_{30}\sim d_{37}$；幅值域无量纲参数表示的特征信息分别为波形指标 S、峰值指标 C、脉冲指标 I、裕度指标 L，峭度指标 K。

对训练样本首先采用贝叶斯参数估计算法进行多源信息融合，再利用图13-12构造的NBN分类器简化图13-11所示的最大后验估计值计算公式并建立故障诊断模型。最后，用测试样本计算最大后验估计值，完成柱塞泵的故障诊断验证。

其中，以某一故障类型为 Y_3 的测试样本 $\boldsymbol{X}=\{1,\ 1,\ 0,\ 2,\ 1,\ 2,\ 0,\ 1,\ 1,$

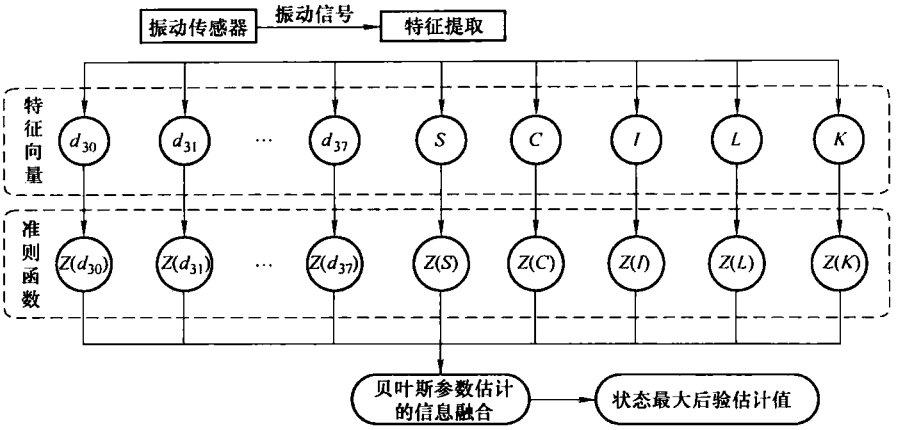

图 13-11　信息融合框架图

2，0，1，1｝为例，诊断过程如下。

由式（13-22）得

$$P(Y_j \mid X_1X_2\cdots X_{13}) = \alpha P(Y_j)P(X_1 \mid Y_j)\cdots P(X_{13} \mid Y_j)$$

进而得到

$$\begin{aligned}
P(Y_1 \mid X_1X_2\cdots X_{13}) &= 1.6\times10^{-14}\alpha\\
P(Y_2 \mid X_1X_2\cdots X_{13}) &= 6.08\times10^{-15}\alpha\\
P(Y_3 \mid X_1X_2\cdots X_{13}) &= 1.57\times10^{-13}\alpha\\
P(Y_4 \mid X_1X_2\cdots X_{13}) &= 1.14\times10^{-14}\alpha\\
P(Y_5 \mid X_1X_2\cdots X_{13}) &= 2.03\times10^{-14}\alpha\\
P(Y_6 \mid X_1X_2\cdots X_{13}) &= 9.76\times10^{-15}\alpha
\end{aligned}$$

由 $\sum_{j=1}^{6} P(Y_j \mid X_1X_2\cdots X_{13}) = 1$，可解出 $\alpha = 4.54\times10^{12}$，由此得出 $Y_1 \sim Y_6$ 的后验概率见表 13-12。

表 13-12　各故障对应的后验概率

$P(Y_j \mid X_1X_2\cdots X_{13})$		
Y_1	Y_2	Y_3
0.0728	0.0276	0.7116
Y_4	Y_5	Y_6
0.0517	0.0920	0.0443

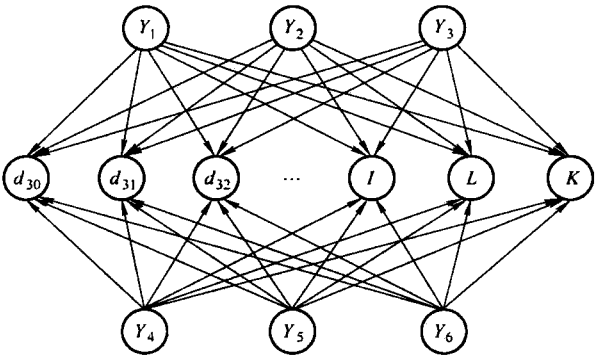

图 13-12 多特征 NBN 分类器

表 13-13 各故障模式的诊断结果

故障类型	样本数	诊断正确	正确率
Y_1	20	15	75.0%
Y_2	20	13	65.0%
Y_3	20	13	65.0%
Y_4	20	14	70.0%
Y_5	20	16	80.0%
Y_6	20	15	75.0%

根据表 13-22 的结果通过式（13-30）计算出最大后验估计值为 $\hat{Y}_{opt}(X_1, X_2, \cdots, X_{13}) = 0.7116$。由此可以确定此故障为 Y_3 类，即两个柱塞松靴故障，诊断结果与测试样本故障状态的类型相吻合。利用同样的方法对其余样本进行测试得到的诊断结果如表 13-13 所示。

对表 13-13 与表 13-11 的诊断结果相比较可以看出，增加幅值域特征参数后特征信息的完备性得到了增强，诊断的正确率与第二次分析相比有了较大幅度的提高。

4. 结果分析

从以上三次故障识别分析结果看，第 1 次分析单独从时频域获取小波包分解的归一化子频带能量作为特征信息进行贝叶斯网络的故障识别，能够很好地区分两种故障模式。增加故障模式后进行第 2 次分析，仍采用第 1 次分析的单一时频域特征提取方法进行多模式故障诊断，诊断正确率过低，不能满足故障诊断确诊率的要求。这表明单独从时频域进行特征提取使故障特征信息存在明显的不完备性。

第 3 次分析时，从时频域和幅值域两个不同域进行特征提取，在特征信息中增加了振动信号的幅值域特征参数，并利用贝叶斯参数估计算法对特征信息进行融

合，以此增加了信息的完备性。结果表明，诊断的正确率有了明显提高。由此，验证了多特征信息融合与贝叶斯网络相结合的方法用于液压泵故障诊断是非常有效的。

表 13-13 的诊断结果说明，与第 2 次分析结果（表 13-11）相比虽然诊断的正确率有了明显提高，但是诊断结果仍然没有达到理想的效果，误判率还是比较高。所以，单从泵端盖的振动信号提取特征信息不能满足液压泵故障诊断的要求。必须从其他信号中获取更多的特征信息进一步增强信息的完备性，才能使诊断的正确率提高到故障诊断要求的确诊率，达到令人满意的诊断效果。

13.3　多源传感器信息融合与贝叶斯网络集成的故障诊断方法

上节说明，由于受流体的压缩性、泵与伺服系统的液固耦合作用、液压泵本身具有的固有机械振动和强噪声背景干扰的影响，使液压泵故障特征信息呈现出模糊性。仅采用泵端盖振动信号进行故障分析不能满足液压泵多故障模式故障诊断的要求，故障特征信息存在不完备性。这两方面因素的影响给液压泵的状态监测与故障诊断带来了极大的困难，正如 13.2 节的分析，仅利用单一信号进行故障识别难以达到满意的诊断精度。

本节提出了多源传感器信息融合和贝叶斯网络集成的故障诊断方法。该方法采用多个传感器获取轴向柱塞泵故障的多源信息，利用信息融合的贝叶斯参数估计算法对多源信息进行融合，通过构造贝叶斯网络并建立贝叶斯分类器简化信息融合结果，最后通过最大后验估计值公式对故障进行识别，完成故障诊断过程。

13.3.1　多源传感器信息融合与贝叶斯网络集成的故障诊断方法

把装有多种传感器的诊断对象看作一个信息系统，来自不同传感器的信息从不同的侧面反映了诊断对象当前的运行状态。把这些信息进行预处理，提取对诊断对象运行状态比较敏感的故障特征向量。通过贝叶斯参数估计的信息融合算法进行信息融合，并利用贝叶斯网络对信息融合后的最大后验估计结果进行简化，从而达到建立诊断模型的目的。

1. 故障特征信号提取的预处理方法

信号预处理部分是故障诊断过程能否顺利进行的前提，本节采取了多种信号处理和特征提取的方法，如图 13-13 所示。

预处理过程为：

1）对已采集的各种运行状态下的多源信号（a_x，a_y，a_z分别为 x，y，z 方向的振动信号，p 为泵的出口压力信号，s 为声音信号）进行处理。首先利用小波理论方法对信号进行带通滤波和消噪处理。然后采用基于 Hilbert 变换的算法对滤波消

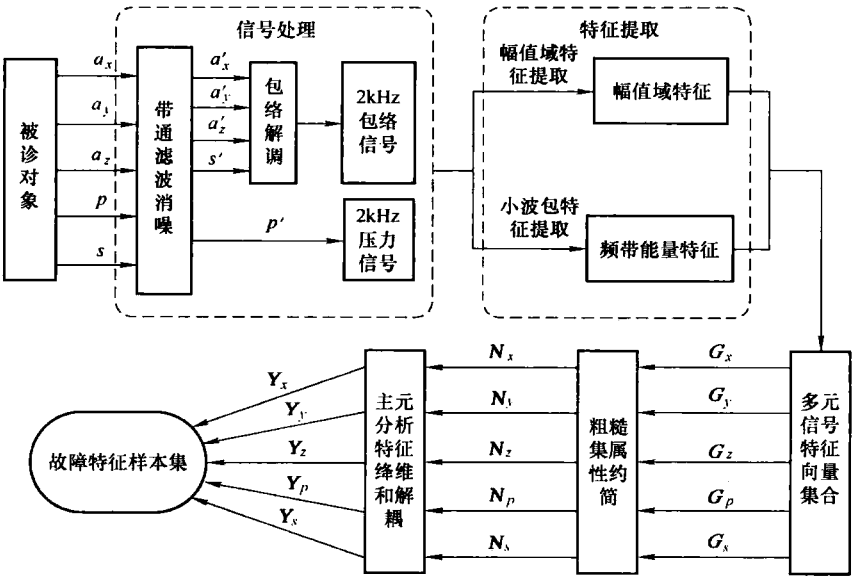

图 13-13 信号预处理

噪后的信号 a_x'，a_y'，a_z'，s'进行包络解调，得到包络信号。

2）对处理后的信号在时频域利用小波包分解提取信号的归一化子频带能量特征，同时从幅值域提取信号无量纲特征参数。按此方法对 5 种信号分别进行特征提取得到 5 个特征向量集合。图 13-13 中 $\boldsymbol{G}_x$、$\boldsymbol{G}_y$、$\boldsymbol{G}_z$分别为为 x、y、z 方向振动信号的特征向量集，$\boldsymbol{G}_p$、$\boldsymbol{G}_s$分别为泵出口压力信号和声音信号的特征向量集。

3）利用粗糙集理论中基于分辨矩阵的属性约简算法，分别对 5 个特征向量集进行属性约简，去除冗余属性。约简后的特征向量集合分别为：$\boldsymbol{N}_x$、$\boldsymbol{N}_y$、$\boldsymbol{N}_z$、$\boldsymbol{N}_p$和 $\boldsymbol{N}_s$。

4）利用主元分析方法对约简后的特征向量集分别进行降维，得到由主元变量组成的故障特征向量集 $\boldsymbol{Y}_x$、$\boldsymbol{Y}_y$、$\boldsymbol{Y}_z$、$\boldsymbol{Y}_p$和 $\boldsymbol{Y}_s$。

5）最后，将 4）中得到的 5 个集合组成一个完整的故障特征样本集，完成信号的预处理过程。

2. 诊断过程的实现

由于液压泵故障特征存在不完备性和模糊性，所以可以利用贝叶斯参数估计算法进行信息融合来增强信息的完备性，并利用贝叶斯网络建立朴素贝叶斯分类器消除故障特征模糊性的影响。其故障诊断过程如下：

1）根据信号类型和测量方法安置各类传感器，设置液压泵多种故障模式，利用所开发的虚拟仪器故障诊断平台采集各故障状态下的上述 5 种信号。

2）对采集的原始信号按图 13-13 进行预处理，得到主元变量表示的故障特征

向量样本集。

3）采用信息融合技术中的贝叶斯参数估计算法对故障特征进行多源信息融合，得到最大后验概率估计值的计算公式。

4）构造 NBN 分类器，利用 NBN 分类器简化最大后验估计值的计算公式，从而完成故障诊断模型的建立。

5）利用测试样本数据，通过故障诊断模型计算最大后验估计值，相对应的故障模式就是诊断的结果。

13.3.2　液压泵多故障模式诊断的实验研究

下面介绍基于虚拟仪器的实验系统组成方案，选择了 3 个相互垂直方向的振动信号、泵的声音信号和出口压力信号作为监测信号。对轴向柱塞泵的松靴、滑靴磨损、中心弹簧失效及斜盘磨损四种故障进行机理分析，通过模拟这 4 种故障，利用所提出的多源传感器信息融合贝叶斯网络集成故障诊断方法对各种故障进行模式识别，验证该理论方法用于液压泵故障诊断的适用性。最后，将该方法与基于粗糙集理论的诊断方法和基于主元分析的故障检测方法进行比较，以此说明本节所创方法更适用于液压泵的故障诊断。

1. 基于虚拟仪器的液压泵故障诊断实验系统

（1）实验系统组成　某材料实验机液压伺服系统中的斜盘式轴向柱塞泵状态监测与故障诊断实验系统结构原理如图 13-14 所示。用三个振动加速度传感器对泵三个垂直方向进行振动信号监测；通过声级计监测泵的近场声音信号；用数字压力传感器对泵出口压力信号进行监测。传感器输出信号经 NI-USB-6221 卡通过自行开发的基于虚拟仪器的液压泵状态监测与故障诊断系统进行采集并进行分析处理。

相关元部件型号及性能参数如下：

① 轴向柱塞泵型号及参数为：型号 MCY14-1B，7 柱塞，理论排量 10ml/r，公称压力 31.5MPa，驱动电动机 Y132M-4，额定转速 1480r/min。

② 加速度传感器：型号 YD72D，电荷灵敏度 0.35pC/ms^{-2}，频率范围 1Hz ~ 18kHz，幅值线性范围 1000ms^{-2}。

③ 精密脉冲声级计：型号 AWA5661，标称灵敏度 40mV/Pa，频率范围 10Hz ~ 16kHz，总量程范围 35 ~ 130dB。

④ 电荷放大器：

型号 DHF-6A，最大输出电压 ± 10V，最大输入电荷量 10^5 pC，增益 0.1mV/pC ~ 1V/pC，频响 0.3Hz ~ 100kHz，精度小于 1.5%，供电电源 AC220V/50Hz，单通道。用于对泵端盖上安置的加速度传感器进行输出电荷放大及转换。

型号 DHF-10：最大输出电压 ±10V，最大输入电荷量 10^5pC，增益 1 ~ 100mV/pC，频响 0.1Hz ~ 100kHz，精度小于 1.5%，供电电源 AC220V/50Hz，2 通道。完

成对另两个加速度传感器进行电荷放大及转换。

⑤ 数字压力变送器：型号 SYB-351，测量范围 0～25MPa，电源电压 DC24V，输出范围 0～5V。

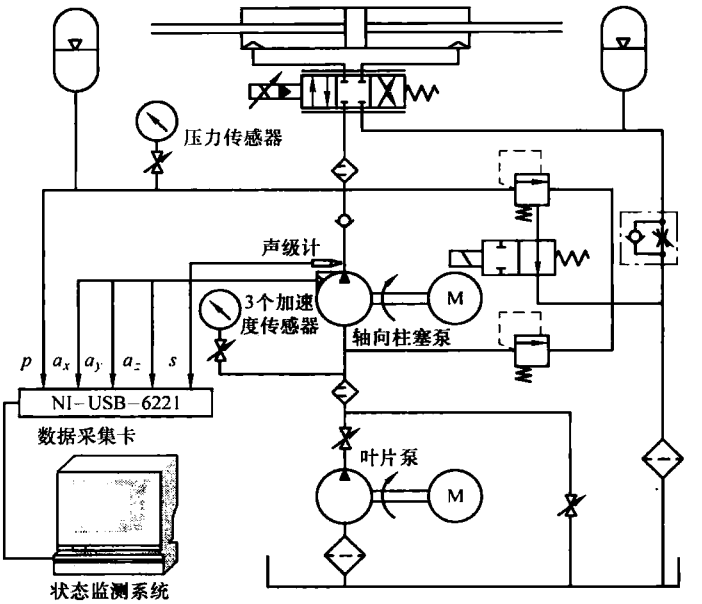

图 13-14 状态监测与故障诊断实验系统结构原理图

（2）虚拟仪器状态监测系统 各传感器的安置位置如图 13-15 所示。图中 a_x、a_y和 a_z分别表示 x、y 和 z 三个方向的加速度传感器，传声器负责声音信号的采集，压力信号的采集由安置在泵出口的压力传感器负责。

实验系统的数据采集设备选用美国 NI 公司的 USB-6221 多功能数据采集卡。其主要参数为：USB 总线；16 路模拟输入，16 位精度，250kS/s 采样速率，2 路模拟输出、更新速率 833kS/s，24 路数字 I/O（8 路高速可达 1MHz），2 个 32 位计数器/定时器。利用此采集卡对柱塞泵 5 种信号进行 5 通道同时采集。监测系统信号传递图如图 13-16 所示。

2. 轴向柱塞泵的故障分析

轴向柱塞泵的振动是由机械振动与流体振动两部分组成。机械振动主要是由泵轴带动缸体和轴承旋转产生的。流体振动主要是由缸体的柱塞腔在吸、排油转换过程中周期性液压冲击形成的，其次是轴向柱塞泵吸油时，由于吸油阻力过大引起气穴以及吸空现象产生的。其中，液压冲击引起的振动是轴向柱塞泵振动的主要原因。液压冲击引起振动的基频 $f=nz/60$（n—电动机转速，z—柱塞数），这个频率及其高次谐波频率是在对轴向柱塞泵状态监测和故障诊断时应重点监测的对象。

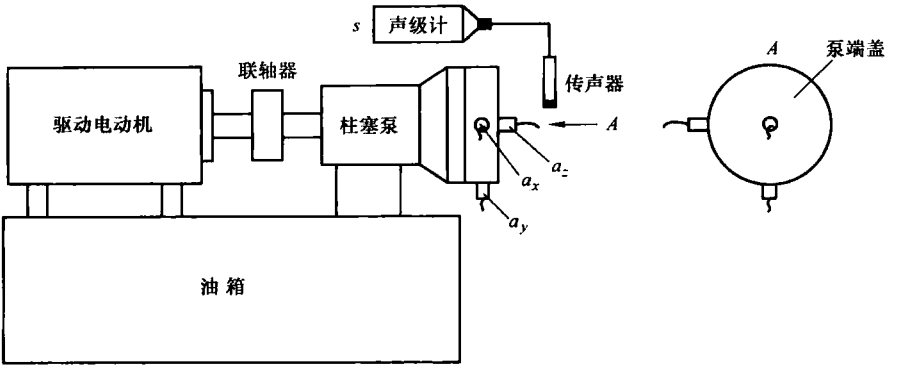

图 13-15　传感器的安置位置示意图

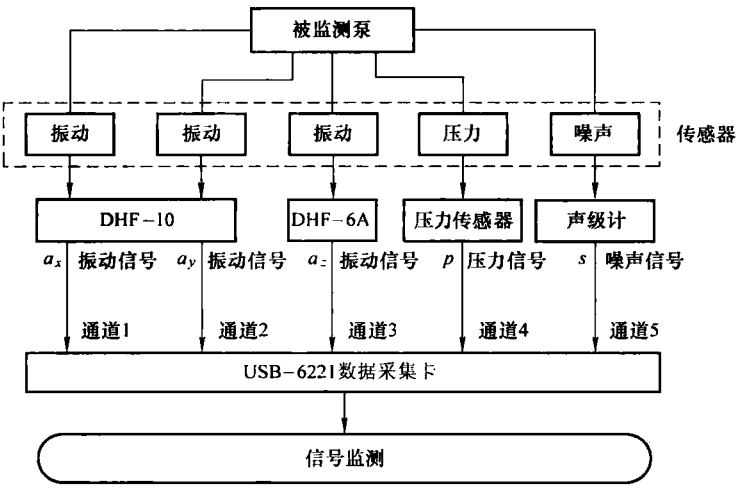

图 13-16　监测系统信号传递图

（1）滑靴与斜盘磨损故障　滑靴与斜盘的滑动摩擦是斜盘式柱塞泵摩擦副中最为复杂的一对。滑靴在斜盘上除进行自转外还进行公转，滑靴与斜盘的接触呈浮动式非接触静压卸载形式，即从柱塞腔引出的高压油在滑靴与斜盘间形成 10～30μm 厚的油膜，依靠液体压力承受柱塞载荷，避免金属直接接触磨损。柱塞杆球头与滑靴球窝有一定的间隙，两者的间隙不能超过对应的极限间隙，否则柱塞腔中的高压油就会从柱塞球头与滑靴间隙中泄出，滑靴与斜盘油膜减薄，严重时会造成静压支承失效，滑靴与斜盘发生金属接触摩擦，滑靴烧蚀脱落，柱塞球头划伤斜盘。

（2）中心弹簧失效故障　斜盘式轴向柱塞泵的中心弹簧使缸体和配流盘之间保持预封，弹簧的预压力同时还能压紧回程盘使柱塞和滑靴回程。中心弹簧太短或折断会使柱塞回程不够或不能回程，缸体与配油盘之间失去其密封性能，产生内部

泄漏导致泵排油不足，执行机构动作迟缓。

3. 柱塞泵监测信号的采集

首先对泵正常工作时泵三个方向的振动信号、声音信号和出口压力信号进行采集，将主溢流阀压力分别调定为2MPa、5MPa、8MPa、10MPa和15MPa，在每一种压力下，按采样频率10kHz、20kHz、50kHz进行5通道同时多次采集。采样频率为10kHz和20kHz时，每次采样时间为10s；采样频率为50kHz时，每次采样时间为2s。按采样频率100kHz对泵端盖振动信号和声音信号进行两通道同时多次采集，每次采样时间为1s。按采样频率220kHz对泵端盖振动信号进行单通道多次采集，每次采样时间为1s。然后将故障元件分别与泵的正常元件替换，模拟各种故障形式，分别采集上述各压力和各采样频率下的故障信号。

（1）正常工作时的信号　下面采用调定压力为15MPa的数据进行分析。泵每转一周的时间约为0.04s。图13-17为正常工作状态下，振动和声音信号在泵旋转1周时间内的波形。

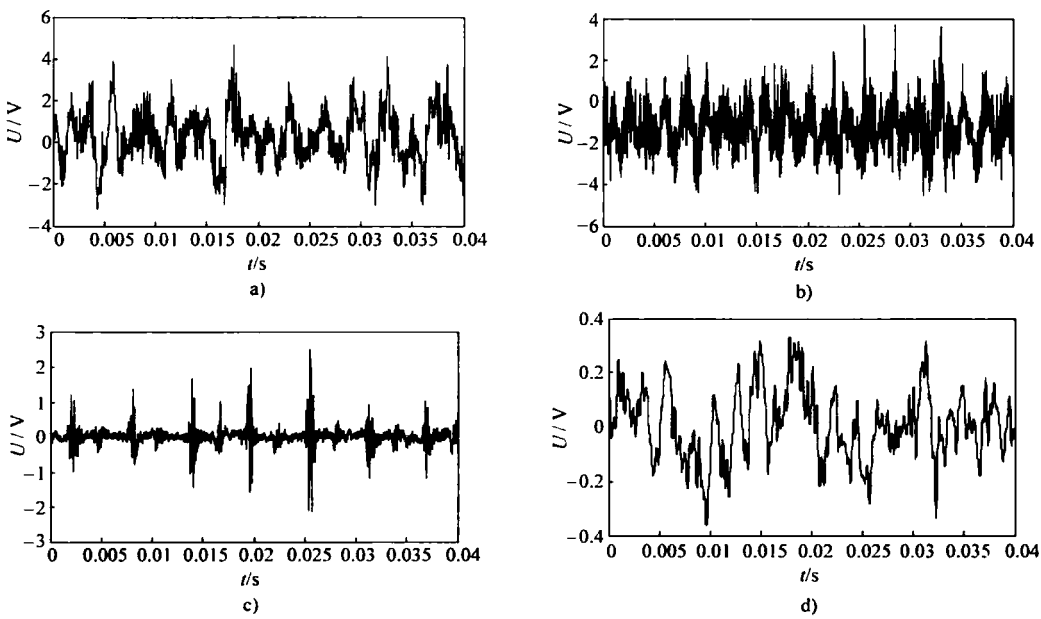

图13-17　泵正常状态下振动和声音信号的时域波形

a）x方向振动加速度信号　b）y方向振动加速度信号

c）z方向振动加速度信号　d）声音信号

从z方向振动加速度信号的波形上可以明显地看出，在泵旋转1周内振动的幅值共有7次突变。这是由于柱塞泵共有7个柱塞，在1周内每个柱塞对斜盘都有一次撞击，所以共有7次撞击。

（2）柱塞泵故障状态的压力信号　研究表明，柱塞泵振动信号和声音信号的时域波形对故障不敏感，从波形图中看不出各故障的明显特征，而压力信号在时域波形上对故障比较敏感。所以，在时域波形分析上本节重点研究泵出口压力信号，如图 13-18 所示。由于柱塞泵的柱塞数为 7，由图 13-18a 可见，柱塞泵的压力脉动频率与理论流量脉动频率一致，为基频的 14 倍。

从图 13-18b、c 和 e 可以看出，泵发生这三种故障时压力信号的波形与正常状态的波形相比有明显的变化。可以通过压力信号的时域波形判断液压泵是否发生故障，但是，不能识别液压泵发生哪种故障。图 13-18d 显示，当液压泵发生中心弹簧失效故障时，泵每转一周有两次压力突降。图 13-18f 则显示，当液压泵发生脱靴故障时，泵每转一周有一次压力突降。通过这两个特征能够识别出相应的故障类型。

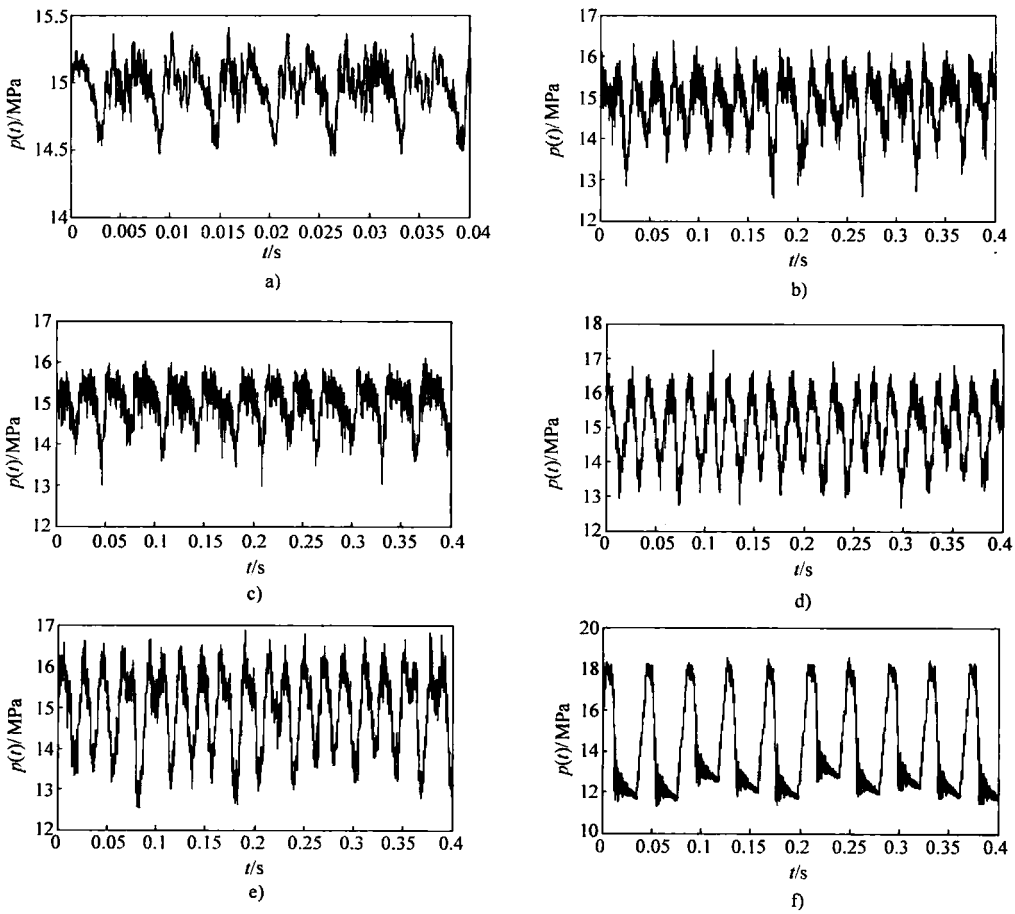

图 13-18　泵正常及故障状态下压力信号的时域波形

a）正常状态　b）单柱塞松靴　c）滑靴磨损　d）中心弹簧失效　e）斜盘磨损　f）单柱塞脱靴

4. 多源信号的预处理

由于采集的信号中伴有各种噪声和干扰，要消除或减少噪声和干扰的影响，就需要对信号进行预处理，提取诊断用故障特征样本集。信号预处理方法如图 13-13 所示，其过程概括为：

① 信号的滤波消噪和包络解调处理。

② 信号的特征提取。

③ 粗糙集理论的特征属性约简。

④ 主元分析方法的特征降维。

人为模拟的轴向柱塞泵各种故障类型如表 13-14 所示。

表 13-14 柱塞泵的各故障类型

状 态	正常状态	单柱塞松靴	单柱塞脱靴	滑靴磨损
符号	DEC（0）	DEC（1）	DEC（2）	DEC（3）
状态	斜盘磨损	中心弹簧失效（磨损量 1.0mm）	中心弹簧失效（磨损量 1.2mm）	中心弹簧失效（磨损量 1.4mm）
符号	DEC（4）	DEC（5）	DEC（6）	DEC（7）

设置采样频率为 50kHz、采样时间为 2s 对泵 8 类状态下的 5 种监测信号进行同时采集，并按图 13-13 的预处理方案对 5 种信号进行预处理。由于柱塞泵每转一周的时间约为 0.04s，由此截取时间长度为 0.8s 的一段数据提取一组特征样本，共提取 800 组（每种状态各 100 组样本）作为实验样本。下面以 z 方向振动信号为例来说明预处理过程。

（1）特征提取

① 幅值域特征提取：对幅值域特征各参数的研究发现，有量纲的幅值域参数不适合作为故障特征参数，而无量纲各参数对不同类型故障的敏感性和稳定性差异较大，所以需将它们同时取作故障特征参数。由此，从幅值域中同时提取波形指标 S_f、峰值指标 C_f、脉冲指标 I_f、裕度指标 CL_f和峭度指标 K_v作为故障的特征参数，得到 z 方向振动信号幅值域特征向量样本。部分幅值域特征样本见表 13-15。

② 时频域特征提取：包络信号中 0～1000Hz 的频段包含丰富的故障信息，因此采用小波包分解的子频带归一化能量方法对包络信号 0～1000Hz 的频段进行时频域特征向量提取。由于每种故障信号都表现在特定的频段中，所以对故障信号进行滤波消噪时，针对不同的频率段要选用不同的滤波方法。以中心弹簧失效故障为例，则选用 db5 小波 4 层分解的滤波方法，得到（12.5～25kHz）高频段的小波系数 d_1的重构信号；对重构信号进行消噪处理和 Hilbert 包络解调能够得到富含故障真实特征的包络信号。对包络信号降低采样频率至 2kHz，再利用小波包分解的子频带能量方法提取出各子频带归一化能量信息表示的特征向量。

表 13-15　z 方向振动信号的部分幅值域特征样本

样　本	S_f	C_f	CL_f	I_f	K_v	状　态
1	1.6301	8.4077	17.1997	13.7049	18.3294	DEC (0)
2	1.8691	12.3809	29.7170	23.1411	46.3392	DEC (1)
3	3.9922	18.6054	125.9694	74.2774	200.7274	DEC (2)
4	1.7826	16.4235	39.9028	29.2769	29.3617	DEC (3)
5	1.6216	10.0015	20.2397	16.2182	24.1902	DEC (4)
6	7.8726	49.9888	12151.9706	393.5426	516.2595	DEC (5)
7	8.3571	47.7042	12500.5559	398.6674	593.0955	DEC (6)
8	8.2961	48.6816	12641.0926	403.8687	569.7124	DEC (7)

表 13-16　各特征能量对应的频带

特征能量	W_{30}	W_{31}	W_{32}	W_{33}
频率范围/Hz	0 ~ 125	125 ~ 250	250 ~ 375	375 ~ 500
特征能量	W_{34}	W_{35}	W_{36}	W_{37}
频率范围/Hz	500 ~ 625	625 ~ 750	750 ~ 875	875 ~ 1000

表 13-17　z 方向振动信号的部分时频域特征样本

样本	W_{30}	W_{31}	W_{32}	W_{33}	W_{34}	W_{35}	W_{36}	W_{37}	状态
1	0.1085	0.1504	0.118	0.1815	0.1002	0.1037	0.1136	0.1241	DEC (0)
2	0.1138	0.1667	0.1233	0.1634	0.0972	0.1116	0.1148	0.1092	DEC (1)
3	0.1698	0.1628	0.1242	0.1575	0.0866	0.0905	0.1042	0.1044	DEC (2)
4	0.1064	0.1537	0.1258	0.1629	0.1107	0.092	0.1136	0.1349	DEC (3)
5	0.125	0.134	0.1189	0.1631	0.1015	0.1073	0.1058	0.1446	DEC (4)
6	0.1392	0.1408	0.1125	0.1702	0.1001	0.1056	0.0992	0.1323	DEC (5)
7	0.1589	0.1581	0.1083	0.1496	0.089	0.1075	0.1037	0.1249	DEC (6)
8	0.1746	0.1412	0.1144	0.1284	0.1096	0.1103	0.1038	0.1176	DEC (7)

对 z 方向振动信号滤波消噪和包络解调处理后得到采样频率为 50kHz 的包络信号 C_1，利用隔点采样的方法得到采样频率为 2kHz 的包络信号 C_2。用 db5 小波包对 C_2进行 3 层分解，如图 13-19 所示，图中横坐标为离散采样点，对应时间长度为 0.8s。

图中 S_{30} ~ S_{37}分别为第 0 ~ 7 子频带对应的重构信号时域波形，可计算出 S_{30} ~ S_{37}子频带信号的能量，各能量对应的频带范围如表 13-16 所示，表 13-17 为部分时频域特征样本。小波包分解能将信号的不同频率成分分开，由表 13-16 可知，S_{30}

中明显地提取了故障特征频率 24.6Hz（转轴频率），S_{31} 中明显地提取了滑靴与斜盘撞击的频率 172.2Hz。

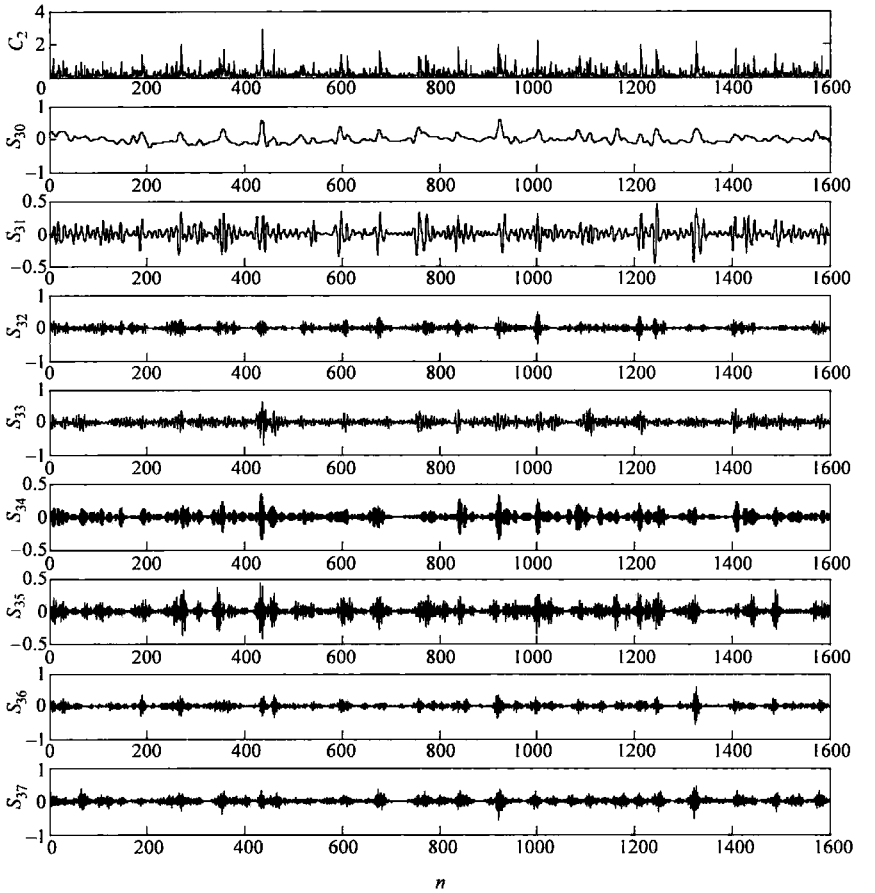

图 13-19 包络信号的小波包分解

（2）粗糙集理论的特征属性约简 利用幅值域和时频域特征提取的结果，建立 8 种故障共 800 组样本的决策信息表。由于决策信息表不可避免地包含一些冗余属性，这些冗余属性增加了故障诊断过程的复杂性，给实际的故障诊断系统的开发和工程应用带来很大困难，所以必须想法消除冗余属性对故障诊断过程造成的影响。为此，采用基于主元模型的粗糙集理论启发式属性约简算法对决策信息表进行属性约简，得到最佳属性约简集，达到去除冗余属性的目的。

具体步骤是，首先对决策信息表中的数据进行基于 FCM 算法的聚类离散化处理。定义“低、中、高”三个语言变量对原始数据中数值型变量进行描述，其中 0—低、1—中、2—高。得到离散化后的决策信息表，表 13-18 为表 13-15 和表

13-17相对应的离散化决策信息表。

利用启发式属性约简算法对离散化后的决策信息表进行属性约简处理，得到最佳属性约简为 $R=\{S_f, C_f, CL_f, W_{30}, W_{31}, W_{32}, W_{33}, W_{34}, W_{35}, W_{36}\}$，见表 13-19。

表 13-18　离散化后的决策信息表

样本	S_f	C_f	CL_f	I_f	K_v	W_{30}	W_{31}	W_{32}	W_{33}	W_{34}	W_{35}	W_{36}	W_{37}	状态
1	0	0	0	0	0	0	1	1	2	1	1	2	1	DEC (0)
2	0	0	0	0	0	0	2	2	1	1	2	2	0	DEC (1)
3	1	0	0	1	1	2	2	2	1	0	0	1	0	DEC (2)
4	0	0	0	0	0	0	1	2	1	2	0	2	2	DEC (3)
5	0	0	0	0	0	1	0	1	1	1	1	1	2	DEC (4)
6	2	2	1	2	2	1	0	0	2	1	1	0	2	DEC (5)
7	2	1	2	2	2	2	1	0	1	0	1	1	1	DEC (6)
8	2	1	2	2	2	2	0	0	0	2	2	1	1	DEC (7)

表 13-19　属性约简后的部分决策信息表

样本	S_f	C_f	CL_f	W_{30}	W_{31}	W_{32}	W_{33}	W_{34}	W_{35}	W_{36}	状态
1	1.6301	8.4077	17.200	0.1085	0.1504	0.118	0.1815	0.1002	0.1037	0.1136	DEC (0)
2	1.8691	12.381	29.717	0.1138	0.1667	0.1233	0.1634	0.0972	0.1116	0.1148	DEC (1)
3	3.9922	18.605	125.97	0.1698	0.1628	0.1242	0.1575	0.0866	0.0905	0.1042	DEC (2)
4	1.7826	16.424	39.903	0.1064	0.1537	0.1258	0.1629	0.1107	0.092	0.1136	DEC (3)
5	1.6216	10.002	20.240	0.125	0.134	0.1189	0.1631	0.1015	0.1073	0.1058	DEC (4)
6	7.8726	49.989	12151.97	0.1392	0.1408	0.1125	0.1702	0.1001	0.1056	0.0992	DEC (5)
7	8.3571	47.704	12500.56	0.1589	0.1581	0.1083	0.1496	0.089	0.1075	0.1037	DEC (6)
8	8.2961	48.682	12641.09	0.1746	0.1412	0.1144	0.1284	0.1096	0.1103	0.1038	DEC (7)

（3）基于主元分析方法的特征降维　通过粗糙集理论的属性约简过程虽然选出了最有效的单个特征集合，但是这个集合却不一定是特征属性的最佳组合。这是因为两个不同特征间可能存在相关性，组合在一起实质上只相当于一个特征，这种现象被称为特征耦合。所以需要利用其他一些特征选择的方法，利用原有各个特征去构造一批新特征，既能够保留原有各特征的主要信息，又能达到降维的目的，并实现特征解耦。主元分析是最常用的降维映射方法之一，对降维解耦有很好的效果。下面采用该方法对柱塞泵的特征向量集合 R 进行新特征提取。

首先对 800 组样本数据，采用主元分析方法提取出各主元变量 Y_{1z}，Y_{2z}，…，Y_{13z}，前 6 个主元的分析结果如见表 13-20。

表 13-20 主元变量的分析结果

主 元	λ_i	$\lambda_i / \sum_{i=1}^{n} \lambda_i$	累计贡献率（%）
Y_{1z}	4.9566	49.5659	49.5659
Y_{2z}	1.3121	13.1214	62.6873
Y_{3z}	1.2354	12.3538	75.0411
Y_{4z}	0.8952	8.9518	83.9929
Y_{5z}	0.6537	6.5368	90.5297
Y_{6z}	0.45	4.5002	95.0299

从表 13-20 中可以看出，前 5 个主元的累计贡献率为 90.5297%，达到了主元变量选择时累计贡献率应大于 85% 的要求。所以完全可以用这 5 个主元变量代替属性集合 R 中的 11 个特征信息。由降维后的主元变量作为特征表示的决策信息表的部分信息见表 13-21。

表 13-21 降维后主元变量的部分决策信息表

样 本	Y_{1z}	Y_{2z}	Y_{3z}	Y_{4z}	Y_{5z}	状 态
1	15.2846	8.5297	0.5197	1.0468	-2.2911	DEC (0)
2	17.4529	9.7751	-0.0939	-1.7969	-1.7893	DEC (1)
3	21.2049	7.6748	-2.0277	0.2182	-2.6757	DEC (2)
4	16.5189	8.5963	-0.8815	0.2527	-2.5014	DEC (3)
5	13.7495	8.9915	-1.6621	-0.2624	-2.9901	DEC (4)
6	14.0628	7.8947	-0.3193	-0.1393	-3.4311	DEC (5)
7	14.3486	7.2289	1.0052	-0.5771	-2.0319	DEC (6)
8	13.7728	6.9531	-1.8554	1.2022	-0.8754	DEC (7)

从表 13-21 可以看出 z 方向振动信号特征参数数量由原来的 11 个降维到了 5 个（$\boldsymbol{Y}_3 = \{Y_{1z}, Y_{2z}, Y_{3z}, Y_{4z}, Y_{5z}\}$），而且通过线性变换使得主元变量之间互不相关，消除了特征参数间的耦合性。

采用同样的方法和过程，可以得到另外 4 种信号的预处理结果，即 x 方向振动信号有 4 个特征参数 $\boldsymbol{Y}_1 = \{Y_{1x}, Y_{2x}, Y_{3x}, Y_{4x}\}$、$y$ 方向振动信号有 3 个特征参数 $\boldsymbol{Y}_2 = \{Y_{1y}, Y_{2y}, Y_{3y}\}$、压力信号有 4 个特征参数 $\boldsymbol{Y}_4 = \{Y_{1p}, Y_{2p}, Y_{3p}, Y_{4p}\}$、声音信号有 5 特征参数 $\boldsymbol{Y}_5 = \{Y_{1s}, Y_{2s}, Y_{3s}, Y_{4s}, Y_{5s}\}$。特征参数总数由属性约简前的 65 个降维到了 21 个。

5. 多源信息融合贝叶斯网络集成的故障诊断方法应用

（1）诊断模型的建立 降维处理得到的 21 个特征参数实际上是来自 5 个不同

传感器的多源信息，利用这些信息建立故障样本集。然后采用贝叶斯参数估计算法对多源信息进行有效融合，建立用最大后验估计值表示的故障诊断模型 G，如图 13-20 所示。

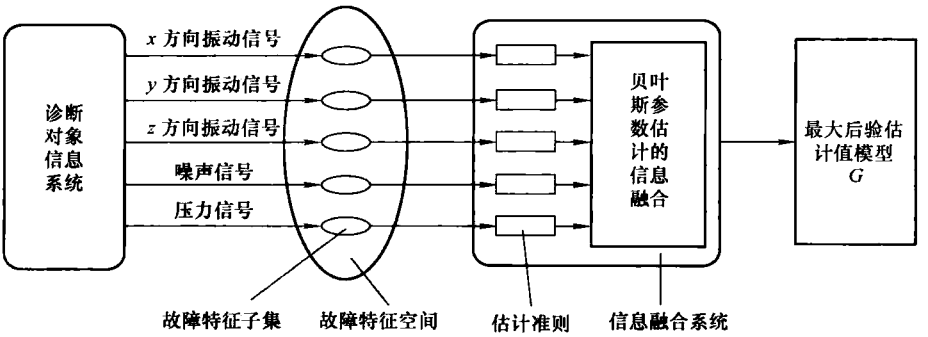

图 13-20　贝叶斯参数估计的信息融合故障诊断模型

将 21 个特征组成一个特征信息空间集合 $\boldsymbol{Y}=\{\boldsymbol{Y}_1, \boldsymbol{Y}_2, \boldsymbol{Y}_3, \boldsymbol{Y}_4, \boldsymbol{Y}_5\}$，故障类型集合用 $D=\{\mathrm{DEC}(0), \mathrm{DEC}(1), \cdots, \mathrm{DEC}(7)\}$表示。由式（13-18）得 21 个传感器信息融合值为

$$\hat{\boldsymbol{Y}}_{opt}(\boldsymbol{Y}_1, \boldsymbol{Y}_2, \cdots, \boldsymbol{Y}_5)=\max_{\hat{\boldsymbol{Y}}} P(D \mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5) \tag{13-31}$$

由此，信息融合的问题就转化为如何求状态 D 的后验概率 $P(D \mid \boldsymbol{Y})$的问题，并找到相应的最大后验概率估计值。由于特征参数较多，逐一计算各条件概率将十分复杂并且计算量大，不适合诊断方法的应用，所以必须通过一种恰当的方法建立 $\boldsymbol{Y}$ 和 D 两个集合的关系来简化求解信息融合值的公式。最后计算最大后验概率估计值，并判断故障的类型，完成故障诊断过程。所以，确定这两个集合的关系是信息融合故障诊断方法实现的关键。

贝叶斯网络采用有向无环图来表示随机变量间的因果关系，可以通过条件概率将这种关系数量化。所以，利用构造贝叶斯网络的方法建立 NBN 分类器来确定 $\boldsymbol{Y}$ 和 D 的关系。构造的贝叶斯网络如图 13-21 所示。

对式（13-31）进一步推导得

$$\hat{\boldsymbol{Y}}_{opt}(\boldsymbol{Y}_1, \boldsymbol{Y}_2, \cdots, \boldsymbol{Y}_5) = \alpha\max_{\hat{\boldsymbol{Y}}}\left[\prod_{i=1}^{5} P(\boldsymbol{Y}_i \mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_{i-1}D)\right] \tag{13-32}$$

图 13-21 构造的 NBN 分类器，假定了特征向量间相互条件独立，$\boldsymbol{Y}_i$子集中每个属性节点都与故障节点相关联，这种假定大大地降低了网络的复杂性并减少了计算量。因此式（13-32）可以简化为

$$\hat{\boldsymbol{Y}}_{opt}(\boldsymbol{Y}_1, \boldsymbol{Y}_2, \cdots, \boldsymbol{Y}_5) = \alpha\max_{\hat{\boldsymbol{Y}}}\left[\prod_{i=1}^{5} P(\boldsymbol{Y}_i \mid D)\right] \tag{13-33}$$

式（13-33）就是对模型 G 简化后的诊断模型，相对应的 D 集合中的元素为故障诊断后得出的故障类型。

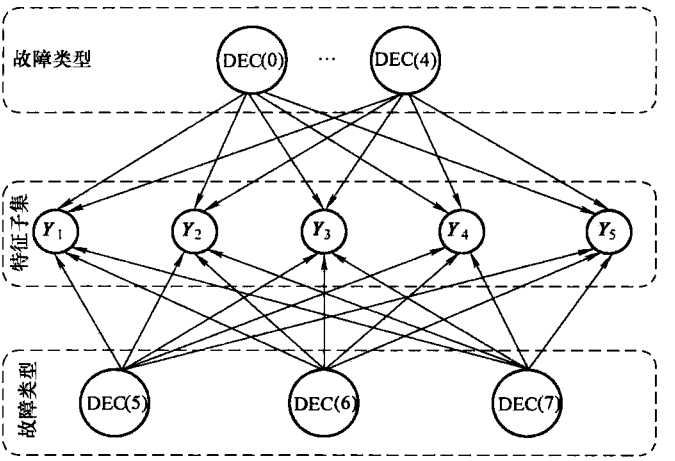

图 13-21 NBN 分类器

（2）故障诊断过程 每种故障类型取 40 个样本作为测试集，利用其中一个测试样本来说明诊断过程。取某个故障类型为 DEC（3）的测试样本，经 FCM 算法的聚类离散化处理后表示为 $N=\{1, 2, 1, 2, 1, 1, 0, 1, 1, 1, 2, 1, 0, 1, 1, 1, 1, 0, 0, 2, 2\}$ 诊断过程如下。

由式（13-33）可得

$$P(\mathrm{DEC}(j)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)=\alpha P(\mathrm{DEC}(j))P(\boldsymbol{Y}_1\mid \mathrm{DEC}(j))\cdots P(\boldsymbol{Y}_5\mid \mathrm{DEC}(j)) \tag{13-34}$$

由此可以计算出

$$\begin{aligned}
P(\mathrm{DEC}(0)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=7.57\times10^{-18}\alpha\\
P(\mathrm{DEC}(1)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=4.86\times10^{-18}\alpha\\
P(\mathrm{DEC}(2)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=3.86\times10^{-19}\alpha\\
P(\mathrm{DEC}(3)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=7.20\times10^{-17}\alpha\\
P(\mathrm{DEC}(4)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=2.01\times10^{-17}\alpha\\
P(\mathrm{DEC}(5)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=5.43\times10^{-18}\alpha\\
P(\mathrm{DEC}(6)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=4.17\times10^{-18}\alpha\\
P(\mathrm{DEC}(7)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)&=1.03\times10^{-18}\alpha
\end{aligned}$$

由 $\sum_{j=1}^{8}P(\mathrm{DEC}(j)\mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)=1$，可解出 $\alpha=8.65\times10^{15}$，由此得出 DEC(0)～DEC(7) 的后验概率如表 13-22 所示。

表 13-22　各故障对应的后验概率

$P(\mathrm{DEC}\ (j)\ \mid \boldsymbol{Y}_1\boldsymbol{Y}_2\cdots\boldsymbol{Y}_5)$			
DEC（0）	DEC（1）	DEC（2）	DEC（3）
0.0655	0.0420	0.0033	0.6232
DEC（4）	DEC（5）	DEC（6）	DEC（7）
0.1740	0.0470	0.0361	0.0089

利用表 13-22 的结果通过式（13-33）得到最大后验估计值为 $\hat{Y}_{opt}(\boldsymbol{Y}_1, \boldsymbol{Y}_2, \cdots, \boldsymbol{Y}_5) = 0.6232$。由此可以判定此故障为 DEC（3）类，即滑靴磨损故障。

利用同样的方法对其余样本进行测试得到的诊断结果见表 13-23。从表 13-23 的诊断结果中可以看出，本章提出的故障诊断方法可以对故障进行较好的识别，故障的确诊率高。验证了多传感器信息融合贝叶斯网络集成的故障诊断方法的有效性。

以上研究表明，基于信息融合技术能够使不同的信息源相互补充。通过贝叶斯网络能够很好地建立故障与特征信息之间的定量映射关系，从而降低系统的模糊性，使系统信息具有更高的确定性和可靠性，从而能够得到故障状态的最优估计和判断，进而提高故障识别的正确率。轴向柱塞泵是典型的复杂旋转机械，所以针对它的故障诊断方法可以推广到其他旋转机械设备的故障诊断中，该方法具有较好的应用前景。

6. *三种诊断方法比较*

本章研究了三种故障诊断的方法：

① 基于信息融合和 NBN 分类器的诊断方法。

② 以启发式属性约简算法为基础的粗糙集（Rough Set，RS）理论的故障诊断方法。

③ 基于主元分析的故障检测方法。

由于三种方法所使用的数学工具不同，每种方法都有其优势和劣势，所以针对液压泵故障诊断的特点，三种方法表现出的诊断效果也各有不同，下面利用相同的数据信息对三种方法的诊断效果进行比较。

（1）基于粗糙集模型的诊断方法　目前，基于粗糙集的诊断模型多是利用粗糙集的属性约简结果得到的诊断规则信息表建立的。所以利用启发式属性约简算法对 13.3.2 节第 4 条所得到的 21 个特征组成的多源信息故障样本集进行处理。取其中 480 组样本作为训练样本，其余 320 组样本作为测试样本。通过训练样本得到的最佳属性约简结果为

$$R_{best} = \{Y_{1x}, Y_{4x}, Y_{1y}, Y_{3y}, Y_{1z}, Y_{2z}, Y_{3z}, Y_{4z}, Y_{1p}, Y_{4p}, Y_{2s}, Y_{4s}, Y_{5s}\}$$

由此得到拥有 459 条诊断规则的信息表，该信息表各项规则组成的知识信息库

即为粗糙集故障诊断模型。由于该信息表的诊断规则数目较大，限于篇幅具体诊断规则在此不再列出。最后利用测试样本对粗糙集模型进行故障检验，得到如表13-23所示的诊断结果。

（2）诊断结果分析比较　表13-23为基于信息融合NBN分类器和基于RS模型的两种方法的诊断结果比较。表中结果说明，前一方法的诊断正确率更高，更适合对液压泵多故障模式的故障诊断。究其原因有二：

① 前一方法中NBN分类器与信息融合算法进行了有机结合，充分发挥了信息融合的优势，使故障信息更完备。而基于RS模型的方法只能通过多源信息简单组合的数据来建立，所以基于RS模型的方法在故障信息的完备性上就逊色于基于信息融合NBN分类器的方法。

② RS方法的诊断模型是基于某一状态下的原始数据而建立的，必然存在诊断规则知识的缺失。因此，利用该模型对获得的新故障样本进行诊断时，发生误诊的可能较大，所以该方法的适应性较差。而基于信息融合的NBN分类器方法则能够在新故障样本的特征信息中，找出与诊断模型相似的部分并计算出最有可能发生的故障类型，所以该方法的适应性较强，诊断效果较好。

液压泵的故障特征信息存在模糊性和不完备性的缺点，粗糙集方法虽然可以解决故障信息的模糊性问题，但是却不能增加特征信息的完备性。所以，单独使用该方法难以满足液压泵多模式故障诊断的要求。而本章所创的多源传感器信息融合贝叶斯网络集成的故障诊断方法，则能同时消除液压泵故障信息的模糊性和不完备性这两方面因素对诊断结果的影响。

表13-23　两种诊断方法的结果比较

故障类型	样本数	诊断正确数		正确率	
		NBN分类器	RS模型	NBN分类器	RS模型
DEC(0)	40	39	27	97.5%	67.5%
DEC(1)	40	37	15	92.5%	37.5.0%
DEC(2)	40	40	32	100%	80.0%
DEC(3)	40	35	17	87.5%	42.5%
DEC(4)	40	36	24	90%	60.0%
DEC(5)	40	36	26	90%	65.0%
DEC(6)	40	37	30	92.5%	75.0%
DEC(7)	40	39	34	97.5%	85.0%

基于粗糙集理论的方法也有其独特优势。可以作为一种智能方法，利用自学习功能获得新知识使诊断模型更加完善，诊断精度也会越来越高。因此，对粗糙集理论方法的深入研究将有助于液压系统智能故障诊断技术的进一步发展。

主元分析方法在故障程度较严重时能够检测出故障，并能准确找出该故障是由哪些特征参数引起的，但是通过这些特征参数的变化难以判断具体发生了何种类型故障。在故障程度较轻时，该方法则完全检测不出故障，而且找出的引起故障的特征参数也不够准确。因此，该方法的适用性是这三种诊断方法中最差的。然而，它也有另两种方法不具备的独特优势，它可以实现在线状态检测和故障诊断功能。因此，主元分析故障检测方法在液压系统故障诊断领域具有重要的工程实用价值。

参 考 文 献

[1] Potamianos Alexandros, Maragos Petros. Comparison of the energy operator and the Hilbert transform approach to signal and speech demodulation [C]// Signal Processing,1994, 37 (1): 95-120.

[2] Liu Hui, Liu Guohai, Shen Yue. Novel method for non-integer harmonics measurement using hilbert vibration decomposition [J]. Gaodianya Jishu/High Voltage Engineering, 2009, 35 (7): 1758-1764.

[3] 成大先. 机械设计手册：弹簧·起重运输件·五金件 [M]. 北京：化学工业出版社，2004.

[4] 韩捷，张瑞林. 旋转机械故障机理及诊断技术 [M]. 北京：机械工业出版社，1997.

[5] 李宏坤，鞠培刚，张志新，等. 基于小波包频带能量分布的往复机故障诊断方法研究[J]. 机械工程师，2008 (3)：35-37.

[6] Skowron A, Rauszer C. The discernibility matrices and functions in information system. Slowinski R. Intelligent Decision Support-Handbook of Applications and Advances of the Rough Sets Theory [M]. Dordrecht: Kluwer Academic Publishers, 1992.

[7] 黄文涛，赵学增，王伟杰，等. 基于粗糙集理论的故障诊断决策规则提取方法 [J]. 中国电机工程学报，2003，23 (11)：150-154.

[8] 管红波，田大钢. 基于属性重要性的决策树规则提取算法 [J]. 系统工程与电子技术，2004，26 (3)：334-337.

[9] 张树瑜，朱仲英. 一种基于 AF 的决策树算法 [J]. 系统工程与电子技术，2005，27 (7)：1292-1296.

[10] 王宏. 基于粗糙集数据挖掘技术的客户价值分析 [M]. 北京：经济科学出版社，2003.

[11] Quinlan J R. Induction of decision trees [J]. Machine Learning, 1986, (1): 81-106.

[12] Chen Jin, Luo Delin, Mu Fenxiang. An improved ID3 decision tree algorithm [C]// 4th International Conference on Computer Science and Education. Nanning, China, 2009: 127-130.

[13] Song Danwa, Han Ning, Liu Dandan. Construction of forestry resource classification rule decision tree based on ID3 Algorithm [C]// 1st International Workshop on Education Technology and Computer Science. Wuhan, Hubei, China, 2009: 867-870.

[14] 黎静华，栗然. 基于知识粗糙度的多变量决策树在变压器故障诊断系统中的应用 [J]. 电力自动化设备，2005，25 (10)：40-43.

[15] 李尔国，俞金寿. PCA 在过程故障检测与诊断中的应用 [J]. 华东理工大学学报，2001，27 (5)：572-576.

[16] Kourti T, MacGregor J F. Multivariate SPC methods for process and product monitoring [J]. J Qual Technol, 1996, 28: 409.

[17] Jackson J E. A User's Guide to Principle Components [M]. New York: Wiley-Inter-Science, 1991.

[18] Dasarathy B V. Sensor fusion potential exploitation-innovative architecture and illustrative application [C]// Proceedings of the IEEE,1997, 85 (1): 24-38.

[19] 滕召胜, 罗隆福, 童调生. 智能检测系统与数据融合 [M]. 北京: 机械工业出版社, 2000.

[20] 李俭川, 胡茑庆, 秦国军, 等. 贝叶斯网络理论及其在设备故障诊断中的应用 [J]. 中国机械工程, 2003, 14 (10): 896-900.

[21] Bezdek J C. Pattern recognition with fuzzy objective function algorithms [M]. New York: Plenum Press, 1981.

[22] 陈季萍. 轴向柱塞泵松靴故障监测与诊断的实验研究 [J]. 煤矿机械, 2004 (1): 115-117.

[23] 张力, 项辉宇, 赵罘, 等. 斜盘式轴向柱塞泵摩擦副分析 [J]. 机床与液压, 2007, 35 (6): 120-122.

[24] 刘思远. 信息融合和贝叶斯网络集成的故障诊断理论方法及实验研究 [D]. 秦皇岛: 燕山大学, 2010: 16-118.

[25] Siyuan Liu, Wanlu Jiang (姜万录), Huifeng Niu. Fault Diagnosis of Hydraulic Pump Based on Rough Set and PCA Algorithm [C]// Proceedings of 5th International Conference on Fuzzy Systems and Knowledge Discovery (FSKD' 2008), 2008, Vol. 5, Jinan, Shandong, China, 18-20 Oct. 2008: 256-260.

[26] 刘思远, 姜万录. 主元分析方法在多元统计过程控制中的发展综述 [J]. 东北大学学报: 自然科学版, 2008, 29 (s2): 229-232.

[27] 刘思远, 姜万录, 牛慧峰. 主元分析及粗糙集的多变量决策树构造方法 [J]. 系统工程与电子技术, 2009, 31 (5): 1133-1137.

[28] Liu Siyuan, Jiang Wanlu (姜万录), Wu Shengqiang. Fault diagnosis of characteristics fusion based on rough set and principal component analysis in hydraulic pump [C]// 7th International Conference on Fluid Power Transmission and Control (ICFP 2009), 2009, Hangzhou, zhejiang, China, 07-10 Apr. 2009: 860-864.

[29] 姜万录, 刘思远. 多特征信息融合的贝叶斯网络故障诊断方法研究 [J]. 中国机械工程, 2010, 21 (8): 940-945/967.

[30] 刘思远, 姜万录. 粗糙集在液压泵故障诊断研究中的应用 [J]. 机床与液压, 2008, 36 (10): 196-198.

[31] 姜万录, 刘思远. 粗糙集及主元分析的机械故障诊断研究 [J]. 机床与液压, 2009, 37 (12): 215-218.

[32] Huifeng Niu, Wanlu Jiang (姜万录), Siyuan Liu. Hybrid Approach Based on Immune Algorithm and Support Vector Machine and its Application for Fault Diagnosis of Hydraulic Pump [C]//

Proceedings of 4th International Symposium on Precision Mechanical Measurements (ISPMM' 2008), 2008, Hefei, Anhui, China, 25-29 August. 2008: 71304X-1-71304X-6.

[33] Huifeng Niu, Wanlu Jiang (姜万录), Siyuan Liu. Research on the Hybrid Fault Diagnosis Approach Based on Artificial Immune Algorithm [C]// Proceedings of 4th International Conference on Natural Computation (ICNC' 2008), 2008, Vol. 6, Jinan, Shandong, China, 18-20 Oct. 2008: 667-670.

[34] Liu Siyuan, Ding linlin, Jiang Wanlu (姜万录). Study on Application of Principal Component Analysis to Fault Detection in Hydraulic Pump [C]// Proceedings of the 2011 International Conference on Fluid Power and Mechatronics, 173-178.

[35] 姜万录, 刘思远. 幅值域无量纲指标对液压泵故障敏感性的实验研究 [J]. 燕山大学学报, 2010, 34 (5): 383-389.